

- 강의명: BADM-572: Data-Driven Decision Making (데이터 탐색 및 생성)
- 주차: Module 3 - 파트 1/2
- 교수명: Prof. Fataneh Taghaboni-Dutta
- 목적: 데이터 수집, 연구 유형, 샘플링 기법 등 비즈니스 의사 결정을 위한 데이터 탐색 및 생성 방법을 학습하고, 편향 없는 데이터의 중요성과 Excel 샘플링 실습을 다룹니다.

Contents

1	개요	2
	개요	2
2	용어 정리	3
	용어 정리	3
3	Preface	4
	Preface	4
4	Module 3: Exploring and Producing Data for Business Decision Making	5
	Module 3: Exploring and Producing Data for Business Decision Making	5
	4.1 Lesson 3-1: Producing Data	6
	Lesson 3-1: Producing Data	6
	4.1.1 Lesson 3-1.1: Producing Data	6
	Lesson 3-1.1: Producing Data	6
	4.2 Lesson 3-2: Sampling	11
	Lesson 3-2: Sampling	11
	4.2.1 Lesson 3-2.1: Sampling	11
	Lesson 3-2.1: Sampling	11
	4.2.2 Lesson 3-2.2: Sampling Function in Excel	16
	Lesson 3-2.2: Sampling Function in Excel	16
5	개요	19
6	용어 정리	20
7	핵심 개념 및 원리	21
	7.1 3-3.1 중심 극한 정리와 표본 평균 (Central Limit Theorem and Sampling Means)	21
	7.2 3-3.2 중심 극한 정리 시각화 (Animating the Central Limit Theorem)	25
	7.3 3-3.3 표본 분포와 경험적 규칙 (Sampling Distribution and Empirical Rule in Excel)	27
	7.4 3-4.1 중심 극한 정리와 표본 비율 (Central Limit Theorem – Sampling Proportion)	29
8	빠르게 훑어보기 (1 페이지 요약)	31
9	FAQ	32

1 개요

이 문서는 BADM-572 과목의 'Exploring and Producing Data Module 3' 중 파트 1/2에 해당하는 내용을 다룹니다. 데이터를 비즈니스 의사 결정에 활용하기 위한 핵심적인 개념과 절차를 학습합니다. 주요 목표는 데이터 수집 방법, 다양한 연구 유형, 그리고 대표성 있는 샘플을 생성하는 다양한 샘플링 기법을 이해하는 것입니다. 특히, 편향되지 않은 데이터를 얻는 것의 중요성과 Excel을 활용한 샘플링 실습 방법을 상세히 설명합니다. 이 문서는 비전공자나 처음 배우는 사람도 완벽히 이해할 수 있도록 쉬운 설명, 풍부한 예시, 그리고 실용적인 절차를 제공하여 시험 대비 및 실무 적용에 필요한 모든 정보를 담고 있습니다.

2 용어 정리

데이터 분석 및 통계 학습에 필수적인 주요 용어들을 정리했습니다. 각 용어의 쉬운 설명과 원어를 함께 제공하여 이해를 돕습니다.

용어	쉬운 설명	원어	비고
반응 변수	우리가 알고 싶어 하는, 다른 요인에 의해 영향을 받는 변수	Response Variable	종속 변수라고도 함
독립 변수	반응 변수에 영향을 미칠 수 있다고 생각되는 변수	Independent Variable	설명 변수라고도 함
실험 연구	연구자가 독립 변수를 직접 조작하여 결과를 관찰하는 연구	Experimental Study	원인-결과 관계 파악에 유리
관찰 연구	연구자가 독립 변수를 조작하지 않고 자연 상태를 관찰하는 연구	Observational Study	윤리적, 현실적 제약이 있을 때 사용
횡단면 데이터	특정 시점에 여러 대상으로부터 수집된 데이터	Cross-Sectional Data	스냅샷과 같음
시계열 데이터	일정 기간 동안 동일 대상으로부터 반복적으로 수집된 데이터	Time-Series Data	시간의 흐름에 따른 변화 분석
빅 데이터	매우 방대하고 다양한 형태의 데이터 집합	Big Data	구조화/비구조화 데이터 모두 포함
샘플링	전체 모집단에서 일부를 선택하여 표본을 추출하는 과정	Sampling	모집단 특성 추론의 기초
비확률 샘플링	각 개체가 선택될 확률이 알려져 있지 않거나 동일하지 않은 샘플링	Non-Probability Sampling	편향될 가능성이 높음
자발적 샘플링	개체 스스로 연구 참여를 선택하는 샘플링	Volunteer Sampling	강한 의견을 가진 사람 위주로 편향
편의 샘플링	접근하기 쉬운 개체를 선택하는 샘플링	Convenience Sampling	시간/비용 절약, 편향 가능성 높음
편향	샘플이 모집단을 정확하게 대표하지 못하여 발생하는 오차	Bias	잘못된 결론으로 이어질 수 있음
확률 샘플링	각 개체가 선택될 확률이 알려져 있고 무작위로 선택되는 샘플링	Probability Sampling	모집단에 대한 일반화 가능
단순 무작위 샘플링	모집단의 모든 개체가 동일한 확률로 선택되는 샘플링	Simple Random Sampling	가장 기본적인 확률 샘플링
층화 샘플링	모집단을 특정 기준으로 층(strata)으로 나눈 후, 각 층에서 무작위 샘플링	Stratified Sampling	각 하위 그룹의 대표성 보장
군집 샘플링	모집단을 군집(clusters)으로 나눈 후, 일부 군집을 무작위로 선택하여 전체 또는 일부 조사	Cluster Sampling	지리적으로 넓은 지역에 유용

3 Preface

Gies eBook을 선택해 주셔서 감사합니다.

이 Gies eBook은 Coursera의 Fataneh Taghaboni-Dutta 교수님의 'Exploring and Producing Data for Business Decision Making' Module 3의 확장된 비디오 강의 스크립트를 기반으로 합니다. Gies eBook은 MOOC 비디오의 모든 정보를 완전히 접근 가능한 형식으로 제공하여 독서 경험을 제공합니다. 이 Gies eBook은 ePUB 3.0 형식을 지원하는 모든 표준 기반 e-리딩 소프트웨어와 함께 사용할 수 있습니다.

각 Gies eBook은 e-리더의 목차 기능을 사용하여 탐색할 수 있는 레슨(lessons)으로 나뉘어 있습니다. 각 레슨 내에서는 다음 콘텐츠 순서가 항상 나타납니다:

- 레슨 제목 (Lesson title)
- 각 레슨의 웹 기반 비디오 링크 (온라인 상태여야 시청 가능)

레슨 내에서 슬라이드가 변경되거나 다음 정보 비디오 장면으로 전환될 때마다 다음이 제공됩니다:

- 현재 슬라이드 또는 비디오 장면의 **썸네일 이미지**
- 비디오 슬라이드에 있는 모든 텍스트는 썸네일 아래에 검색 가능하고 스크린 리더 친화적인 형식으로 재구성됩니다.
- 슬라이드에 제시된 그래프 및 차트와 같은 중요한 시각 자료에 대한 **확장된 텍스트 설명**
- 비디오의 모든 표 형식 데이터는 스크린 리더 탐색 및 읽기를 위해 **재구성되고 적절하게 레이블**됩니다.
- 모든 수학 방정식은 화면에 표시될 경우 내용과 표현을 모두 제공하는 **MathML**로 제시됩니다.
- 말하는 사람별로 레이블이 지정된 비디오의 모든 원본 음성을 캡처한 **스크립트 (Transcript)**

모든 Gies eBook은 접근성과 유용성을 최우선으로 설계되었습니다. 이 디자인은 독자들이 어떤 디지털 독서 도구를 선택하든 유연한 방식으로 모든 독자에게 서비스를 제공하기 위한 것입니다.

이 Gies eBook에 대한 질문이나 개선 제안이 있으시면 Giesbooks@illinois.edu로 문의하십시오.

4 Module 3: Exploring and Producing Data for Business Decision Making

이 모듈에서는 비즈니스 의사 결정을 위한 데이터를 탐색하고 생성하는 방법에 대해 학습합니다. 데이터는 모든 분석의 출발점이며, 올바른 데이터를 올바른 방식으로 얻는 것이 중요합니다.

4.1 Lesson 3-1: Producing Data

4.1.1 Lesson 3-1.1: Producing Data

데이터를 생산하는 것은 우리가 알고자 하는 바를 명확히 정의하고, 그에 맞는 데이터를 수집하는 일련의 과정을 의미합니다. 이 과정은 크게 기존 데이터를 활용하거나, 직접 연구를 수행하여 새로운 데이터를 생성하는 두 가지 방식으로 나눌 수 있습니다.

데이터는 어디에서 오는가? (Where Does the Data Come From?)

우리가 무엇을 알고 싶은지 결정한 후에는 데이터가 필요합니다. 예를 들어, 미국인이 오락에 지출하는 평균 금액이나 온라인 교육을 추구하는 사람의 평균 연령과 같은 무작위 변수(random variables)를 정의했다면, 다음 단계는 데이터를 찾는 것입니다.

핵심 요약

데이터 출처: 데이터는 크게 기존 출처(Existing Sources)에서 찾거나, 직접 연구(Conducting a Study)를 통해 생성할 수 있습니다.

1. 기존 출처 (Existing Sources) 이미 공공 또는 민간 기관에서 수집해 놓은 방대한 양의 데이터가 존재합니다. 이러한 데이터는 시간과 비용을 절약할 수 있다는 장점이 있습니다.

- **정부 및 국제 기구:** 미국 정부 간행물, 세계 기구 보고서 등 전자 버전으로 제공되는 자료가 많습니다.
- **인터넷:** 다양한 웹사이트와 데이터베이스에서 정보를 얻을 수 있습니다. **예시:** 온라인 백과사전, 공개 데이터 포털, 기업 웹사이트 등.
- **도서관:** 좋은 도서관의 참고 자료 섹션이나 카운티 법원 기록에도 풍부한 정보가 있습니다. **예시:** 역사적 기록, 인구 통계 자료, 법률 문서 등.
- **데이터 수집 기관:** Bloomberg, Dow Jones and Company, Travel Industry of America, Graduate Management Admission Council, Educational Testing Services와 같은 전문 기관에서 구독료를 내거나 개별 보고서를 구매하여 데이터를 얻을 수 있습니다. **예시:** 금융 시장 데이터, 산업 보고서, 시험 성적 데이터 등.

이러한 기존 데이터는 이미 수집되어 있으므로, 연구를 시작하기 전에 먼저 필요한 데이터가 이미 존재하는지 확인하는 것이 효율적입니다.

2. 직접 연구 수행 (Conducting a Study) 때로는 우리가 필요로 하는 데이터가 기존에 존재하지 않을 수 있습니다. 이런 경우에는 직접 연구를 수행하여 데이터를 수집해야 합니다. 연구를 시작하는 단계는 다음과 같습니다.

연구 시작의 첫 번째 단계: 반응 변수 정의 (Step One in Initiating a Study)

반응 변수 (Response Variable): 우리가 관심을 가지고 이해하고자 하는 변수를 정의합니다. 이 변수는 다른 요인에 의해 영향을 받는다고 가정합니다. 통계학에서는 이 용어를 자주 사용하므로 익숙해지는 것이 중요합니다.

- **예시:** 작업자 생산성 (Worker productivity)

□ 예제

예시: 작업자 생산성 직원들이 업무를 얼마나 효율적으로 수행하는지 알고 싶다고 가정해 봅시다. 이 경우, 우리의 관심 변수는 '작업자 생산성'이 됩니다. 이를 '시간당 서비스하는 고객 수'로 측정할 수 있습니다. 우리는 작업자 생산성이 여러 요인에 반응한다고 믿기 때문에, 이것이 반응 변수가 됩니다. 즉, 생산성은 다른 요인에 의해 영향을 받는 결과 변수입니다.

연구 시작의 두 번째 단계: 독립 변수 정의 (Step Two in Initiating a Study)

독립 변수 (Independent Variables): 관심 변수(반응 변수)와 관련이 있을 수 있으며 측정될 다른 변수들을 정의합니다. 이 변수들은 반응 변수에 영향을 미친다고 가정합니다.

- **예시:** 훈련량 (Amount of training), 장비 신뢰성 (Reliability of equipment), 해당 직무 경력 (Number of years at this job)

□ 예제

예시: 작업자 생산성에 영향을 미치는 요인 작업자 생산성(반응 변수)에 영향을 미칠 수 있는 요인들(독립 변수)은 다음과 같습니다:

- 작업자가 받은 훈련량
- 사용하는 장비의 신뢰성
- 해당 직무에서의 경력

이러한 요인들은 작업자 생산성이라는 반응 변수에 영향을 미치는 독립 변수가 됩니다. 즉, 이 변수들은 생산성에 영향을 주는 원인 변수들입니다.

연습 문제: 학습 시간이 성적에 미치는 영향 신입생 그룹에게 주당 학습 시간을 기록하도록 요청하고, 4년 동안의 GPA를 추적합니다. 이 연구에서 관심 변수(반응 변수)는 무엇이며, 독립 변수는 무엇입니까?

풀이: 학습 시간이 성적에 미치는 영향

- 관심 변수 (반응 변수): 학생들의 GPA (학습 시간에 반응하여 변동한다고 가정)
- 독립 변수: 주당 학습 시간 (GPA에 영향을 미친다고 가정)

연구의 유형 (Type of Study) 연구를 수행할 때는 독립 변수를 조작할 수 있는지 여부에 따라 연구 유형이 달라집니다.

연구의 유형 (1/2): 실험 연구 (Experimental Study)

실험 연구 (Experimental Study): 독립 변수를 조작(manipulated)할 수 있는 연구입니다. 연구자가 의도적으로 독립 변수의 조건을 변경하고 그에 따른 반응 변수의 변화를 관찰합니다. 이는 원인과 결과 관계를 명확히 파악하는 데 유리합니다.

- **예시:** 비료가 식물 수확량에 미치는 영향
 - 반응 변수: 식물 수확량 (Plant yield)
 - 독립 변수: 사용된 비료의 양 (Amount of fertilizer used)

□ 예제

예시: 비료와 식물 수확량 특정 비료가 식물 수확량에 미치는 영향을 측정하고 싶다고 가정해 봅시다.

- 우리는 여러 구획의 땅에 **다른 양의 비료**를 주고 (독립 변수 조작)
- 수확 시점에 **수확량**을 측정합니다 (반응 변수 관찰).

이 경우, 비료의 양을 조작할 수 있으므로 실험 연구에 해당합니다. 물론, 토양 조건, 물 공급 등 다른 모든 요인은 동일하게 유지된다고 가정합니다. 연구의 질을 결정하는 주요 문제 중 하나는 연구자들이 독립 변수들을 얼마나 잘, 그리고 완벽하게 식별했는지입니다. 이를 실패하면 잘못된 결론이나 불완전한 이해로 이어질 수 있습니다.

연구의 유형 (2/2): 관찰 연구 (Observational Study)

관찰 연구 (Observational Study): 독립 변수를 **통제(control)**할 수 없거나 통제하는 것이 비윤리적인 연구입니다. 연구자는 자연적으로 발생하는 현상을 관찰하고 데이터를 수집합니다. 이 연구는 변수들 간의 관계를 파악하는 데 유용하지만, 인과 관계를 직접적으로 증명하기는 어렵습니다.

- **예시:** 아이들이 언어 능력을 어떻게 발달시키는가?
 - **반응 변수:** 한 살 때 아는 단어 수 (Number of words by age one)
 - **독립 변수:** 아이에게 말해준 단어 수 (Number words spoken to the child)

□ 예제

예시: 아이들의 언어 발달 아이들이 언어 능력을 어떻게 발달시키는지에 대한 연구를 생각해 봅시다.

- 관심 변수는 '한 살 때 아기가 아는 단어 수'일 수 있습니다.
- 만약 '아기에게 말해준 단어 수'가 언어 발달에 영향을 미친다고 믿는다면, 일부 부모에게 1년 동안 아이에게 전혀 말을 걸지 못하게 하거나, 다른 부모에게 하루 18시간씩 말을 걸도록 지시하는 것은 **비윤리적**입니다.

이러한 연구는 참가자들이 스스로 아기에게 얼마나 말을 걸었는지, 아기가 한 살 때 몇 단어를 말할 수 있었는지 **자율적으로 보고(self-report)**하는 관찰 연구로만 수행될 수 있습니다.

데이터 수집 기간 (Data Collection Time Frame) 데이터를 수집하는 시점에 따라 데이터의 유형이 달라집니다.

데이터 수집 기간 (1/2): 횡단면 데이터 (Cross-Sectional Data)

횡단면 데이터 (Cross-Sectional Data): **동일하거나 거의 동일한 시점에** 수집된 데이터입니다. 여러 개체(사람, 회사, 지역 등)에 대한 정보를 한 시점에서 수집합니다. 마치 특정 순간의 '스냅샷'과 같습니다.

□ 예제

예시: 은행 직원의 휴대폰 요금 분석 직원들의 휴대폰 사용 요금을 지불하는 은행이 지난달(예: 5월) 직원들의 휴대폰 요금 청구서를 분석하고자 합니다.

- 5월 한 달 동안의 **여러 직원들의 청구서**를 살펴보는 것은 횡단면 데이터를 제공합니다. 이는 특정 시점(5월)에 여러 개체(직원)에 대한 데이터를 수집하는 방식입니다.

데이터 수집 기간 (2/2): 시계열 데이터 (Time-Series Data)

시계열 데이터 (Time-Series Data): 서로 다른 시간 기간에 걸쳐 수집된 데이터입니다. 동일한 개체 (사람, 회사, 주식 등)에 대한 정보를 여러 시점에서 반복적으로 수집합니다. 시간의 흐름에 따른 변화와 추세를 분석하는 데 적합합니다.

□ 예제

예시: 간호사 연구 (Nurses Study) 1976년에 시작되어 1989년에 확장된 유명한 '간호사 연구'는 시계열 데이터의 훌륭한 예시입니다.

- 이 연구는 여성 건강을 연구하기 위해 **20만 명 이상의 간호사들로부터 오랜 기간 동안 건강 관련** 데이터를 수집했습니다.
- 이는 간호사들이 연구자들의 개입 없이 생활하며 주기적으로 건강에 대한 질문에 답하고 의료 검사를 받은 **관찰 연구**였습니다.

이처럼 여러 해에 걸쳐 데이터를 수집하는 것은 시계열 데이터에 해당합니다.

연습 문제: 학습 시간이 성적에 미치는 영향 (재검토) 신입생 그룹에게 주당 학습 시간을 기록하도록 요청하고, 4년 동안의 GPA를 추적합니다. 이 연구는 관찰 연구입니까, 실험 연구입니까? 데이터는 시계열입니까, 횡단면입니까?

풀이: 학습 시간이 성적에 미치는 영향 (재검토)

- **연구 유형:** 학생들에게 학습 습관을 기록하도록 요청했지만, 이를 조작하지 않았으므로 관찰 연구 (Observational Study)입니다.
- **데이터 유형:** 데이터가 4년이라는 기간에 걸쳐 수집되므로 시계열 데이터 (Time-Series Data)입니다.

연습 문제: 맥주가 비만에 미치는 영향 맥주 섭취와 허리-엉덩이 비율(WHR), 체질량 지수(BMI) 간의 관계를 조사하기 위해, 연구자들은 25~64세 남성 1,141명과 여성 1,212명의 무작위 표본을 대상으로 연구를 수행했습니다. 피험자들은 설문지를 작성하고 클리닉에서 간단한 검사를 받았습니다. 일반적인 주간 맥주, 와인, 증류주 섭취량, 음주 빈도 및 기타 여러 요인들이 설문지를 통해 측정되었습니다. 이것은 어떤 종류의 연구입니까? 데이터는 어떻게 수집되었습니까?

풀이: 맥주가 비만에 미치는 영향

- **연구 유형:** 연구자들이 맥주 섭취량을 조작하지 않고 설문지와 검사를 통해 데이터를 수집했으므로 관찰 연구 (Observational Study)입니다.
- **데이터 유형:** 모든 피험자로부터 동일한 시점(특정 주간, 특정 검사 시점)에 데이터가 수집되었으므로 횡단면 데이터 (Cross-Sectional Data)입니다.

빅 데이터 (Big Data) 오늘날 비즈니스 세계에서 중요한 개념인 빅 데이터는 통계 분석에 많은 기회를 제공합니다.

빅 데이터 (Big Data)

빅 데이터 (Big Data): 구조화된(structured) 데이터와 비구조화된(unstructured) 데이터 모두의 방대한 양을 의미합니다.

- **데이터 출처:** GPS 장치, 스마트폰, 신용카드, 건강 추적 장치, 게임 콘솔 등 다양한 수단을 통해 기업들은 데이터를 수집하고 있습니다. 이러한 장치들은 끊임없이 데이터를 생성하며, 이 데이터는 기업의

의사 결정에 활용될 수 있습니다.

- **기회:** 빅 데이터의 가용성은 다음과 같은 흥미로운 질문에 답할 수 있는 추가적인 기회를 제공합니다:
 - 누군가 심장마비 증상을 보이기 전에 심장마비가 올 것을 예측할 수 있는가? (예: 웨어러블 기기 데이터 분석)
 - 누군가 대출을 받기 전에 대출 불이행 가능성을 예측할 수 있는가? (예: 신용 기록, 거래 패턴, 소셜 미디어 데이터 분석)

이러한 방대한 데이터를 이해하는 능력은 우리가 관심 있는 변수에 대한 이해를 얻기 위해 데이터를 찾는 또 다른 방법입니다. 통계에서 수행되는 모든 분석은 관심 모집단의 부분 집합인 표본(sample)으로 시작합니다. 따라서 어떤 데이터가 필요한지 알게 되면, 표본을 생성해야 합니다. 다음 레슨에서는 이러한 표본을 생성하는 방법을 논의할 것입니다.

학술 인용 (Academic Citation)

Bobak, M., Skodove, Z., and Marmot, M. (2003). Beer and obesity: A cross-sectional study. *European Journal of Clinical Nutrition*, 57(10). Retrieved from <https://www.ncbi.nlm.nih.gov/pubmed/14506485>.

4.2 Lesson 3-2: Sampling

4.2.1 Lesson 3-2.1: Sampling

지금까지 데이터를 요약하고 분포에 대해 배웠습니다. 또한 표본에서 데이터를 얻는 것에 대해서도 이야기했습니다. 이제 데이터를 생성하는 방법, 즉 샘플링(Sampling)에 대해 이야기할 시간입니다. 뉴스 프로그램이나 기사를 읽을 때 '과학적 연구(scientific study)' 또는 '과학적 여론조사(scientific poll)'와 같은 용어를 들어본 적이 있을 것입니다. 이는 비과학적인 방식으로 데이터가 생성될 수도 있다는 것을 의미합니다.

핵심 요약

샘플링 방법: 표본을 추출할 때는 크게 두 가지 방법 중 하나를 사용합니다.

1. 비확률 방법 (Non-Probability Methods): 각 개체가 선택될 확률이 알려져 있지 않거나 동일하지 않습니다.
2. 확률 방법 (Probability Methods): 각 개체가 선택될 확률이 알려져 있고 무작위로 선택됩니다. 이러한 방법들을 자세히 살펴보겠습니다.

비확률 방법 (Non-Probability Method) 비확률 샘플링은 모집단의 각 개체가 표본으로 선택될 확률이 알려져 있지 않거나 동일하지 않은 방법입니다. 이 방법은 편리하고 비용 효율적일 수 있지만, 표본이 모집단을 대표하지 못하여 편향(bias)이 발생할 위험이 높습니다. 따라서 이 방법으로 얻은 결과는 모집단에 대해 일반화하기 어렵습니다.

비확률 방법 (1/2): 자발적 샘플링 (Volunteer Sampling)

자발적 샘플링 (Volunteer Sampling): 개인이 스스로 연구 참여를 선택하여 표본에 포함되기를 선택하는 방식입니다.

- **문제점:**
 - **편향 (Bias):** 특정 문제에 대해 강한 의견을 가진 사람들이 주로 참여하므로, 표본이 모집단을 대표하지 못합니다.
 - **결과 일반화 불가 (Results are not generalizable):** 표본에서 얻은 결과를 더 큰 모집단에 적용하기 어렵습니다.

□ 예제

예시: 제품 리뷰 구매한 제품에 대한 리뷰를 남기는 것은 자발적 샘플링의 예시입니다. 리뷰를 남기는 고객은 특정 의견(매우 만족 또는 매우 불만족)을 가지고 있을 가능성이 높습니다.

- **문제점:** 이러한 데이터는 통계적으로 '비과학적'으로 간주됩니다. 왜냐하면 대부분의 경우 특정 문제에 대해 강한 의견을 가진 개인의 데이터만 포함되어 편향될 가능성이 높기 때문입니다.
- **일반화의 한계:** 자발적 응답 표본에서 얻은 데이터는 표본으로 추출된 개인이 자신에 대한 정보만 제공하므로, 더 큰 그룹에 대해 일반화하기 어렵습니다.

예외: 그러나 의료 치료를 위한 임상 시험과 같이, 개인이 의료 연구에 참여하도록 강요하는 것이 비윤리적인 경우에는 자발적 샘플링이 유일한 방법일 수 있습니다. 이 경우, 여러 치료법을 비교할 때는 자발적 샘플링이 덜 문제가 됩니다. (이 시리즈의 두 번째 과정에서 더 자세히 논의될 예정입니다.)

비확률 방법 (2/2): 편의 샘플링 (Convenience Sampling)

편의 샘플링 (Convenience Sampling): 연구자가 접근하기 편리하다는 이유로 대상을 선택하는 방식입니다.

□ 예제

예시: 투표소 앞 여론조사 뉴스 매체에서 투표소 밖에 서서 투표를 마치고 나오는 유권자들에게 누구에게 투표했는지 묻는 경우가 편의 샘플링의 예시입니다.

- **문제점:** 각 개인이 응답을 거부하거나 응답하기로 선택할 수 있으므로, 자발적 샘플링의 요소도 포함되어 편향이 발생할 수 있습니다.
- **상황에 따른 유용성:** 그러나 수집되는 변수에 따라서는 이 유형의 표본이 상당히 대표적인 그룹을 제공할 수도 있습니다. 하지만 일반적으로 편향은 표본에서 가장 문제가 되는 문제입니다.

비대표성 표본 사용의 문제점: 편향 (The Problem With Using a Non-Representative Sample - Bias) 편향된 표본은 잘못된 결론으로 이어질 수 있습니다. 역사적인 사례를 통해 이를 이해해 봅시다.

1936년 미국 대통령 선거 (1936 Presidential Election)

- **후보:** 프랭클린 D. 루즈벨트 (Franklin D. Roosevelt) vs. 알프레드 랜던 (Alfred Landon)
- **배경:** 대공황 직후로, 실업률과 정부 지출과 같은 경제 문제가 주요 쟁점이었습니다. 루즈벨트는 정부 지출을 통한 고용 증대를 지지했고, 랜던은 이를 제한하는 것을 선호했습니다. 랜던은 주로 부유층 유권자들에게 선호되었습니다.
- **예측:** 당시 가장 존경받는 잡지 중 하나인 *The Literary Digest*는 루즈벨트의 패배를 예측했습니다.
- **결과:** 루즈벨트가 압도적인 승리를 거두었습니다. *The Literary Digest*의 예측은 틀렸습니다. (랜던은 단 두 개 주에서만 승리했습니다.)

□ 예제

무엇이 잘못되었는가? *The Literary Digest*는 전화번호부에서 표본을 추출했습니다.

- **문제점:** 1930년대에는 전화가 부유층만이 가질 수 있는 사치품이었습니다.
- **결과:** 따라서 그들의 표본은 편향되었고, 유권자 모집단을 정확하게 대표하지 못했습니다. 여론조사에 참여한 사람들이 부유층이었기 때문에 랜던이 당선될 것이라는 인상을 주었지만, 실제로는 정반대였습니다.

이 사례는 대표성 없는 표본이 얼마나 심각한 오류를 초래할 수 있는지를 보여줍니다.

대표성 있는 표본 (Representative Sample) 데이터 분석을 올바르게 수행하려면, 편향되지 않고 모집단을 잘 대표하는 표본으로 시작해야 합니다.

대표성 있는 표본 (Representative Sample)

무작위로 선택된 표본 (A Randomly Selected Sample)은 다음과 같은 특징을 가집니다:

- **모집단 대표성:** 전체 모집단을 대표합니다.
- **편향 방지:** 표본의 평균이 모집단의 평균과 유사하게 만들어 편향을 피합니다.

- **모집단 특성 추론 가능:** 표본으로부터 모집단의 특성을 추론할 수 있게 합니다.
- **표본 크기와 모집단 크기:** 더 큰 모집단이라고 해서 더 큰 표본이 필요한 것은 아닙니다.

□ 예제

표본 크기에 대한 오해 해소 "더 큰 모집단이라고 해서 더 큰 표본이 필요한 것은 아닙니다." 이 말은 매우 중요합니다.

- 예를 들어, 중국 소비자에 대해 알고 싶다고 해서 미국 소비자에 대한 연구보다 더 큰 표본을 취할 필요는 없습니다.
- 중요한 것은 **표본이 얼마나 잘 무작위로 추출되어 모집단을 대표하는가**이지, 모집단의 절대적인 크기가 아닙니다.

이러한 방식으로 표본을 올바르게 선택하면, '과학적 여론조사' 또는 '과학적 연구'라고 불릴 수 있는 결과를 얻을 수 있습니다.

확률 샘플링 기법 (Probability Sampling Techniques) 과학적인 여론조사나 연구를 위해서는 확률 샘플링 방법을 사용해야 합니다. 이 방법들은 표본에서 얻은 결과를 모집단에 일반화할 수 있게 해줍니다.

확률 샘플링 기법 (1/3): 단순 무작위 샘플링 (Simple Random Sampling)

단순 무작위 샘플링 (Simple Random Sampling): 모집단의 모든 개체가 다른 개체와 **동일한 확률**로 선택될 기회를 가집니다. 이는 가장 기본적인 확률 샘플링 계획입니다.

□ 예제

예시: 제비뽑기 이름이 적힌 모자에서 이름을 뽑는 것과 같습니다. 각 개인이 선택될 확률이 동일합니다.

- **장점:** 선택 과정에서 편향이 발생하지 않도록 보장하는 한 가지 방법입니다.
- **주의점:** 그러나 선택된 구성원들의 **무응답(non-response)**과 관련된 편향이 발생할 수 있습니다. 예를 들어, 전화나 우편으로 설문 요청을 받았을 때 응답하지 않으면 무응답으로 분류됩니다. 연구자들은 편향을 줄이기 위해 응답률을 높이는 데 많은 노력을 기울입니다.

확률 샘플링 기법 (2/3): 층화 샘플링 (Stratified Sampling)

층화 샘플링 (Stratified Sampling): 모집단이 **자연적으로 하위 모집단(층, strata)**으로 나눌 수 있을 때 사용됩니다. 각 층에서 단순 무작위 샘플을 추출하여 전체 표본을 구성합니다. 이 방법은 각 하위 그룹의 대표성을 보장하는 데 효과적입니다.

- **예시:** 여성 (200명) + 남성 (200명) = 총 400명

□ 예제

예시: **성별 대표성 보장** 여론조사를 실시할 때, 남성과 여성 모두가 표본에 공정하게 대표되도록 하고 싶다고 가정해 봅시다. 이 경우, 성별을 기준으로 두 개의 층(strata)을 만듭니다.

- 여성 층에서 200명의 여성을 단순 무작위로 선택하고,
- 남성 층에서 200명의 남성을 단순 무작위로 선택합니다.
- 이렇게 선택된 총 400명이 우리의 최종 표본이 됩니다.

층화 샘플링은 각 하위 그룹의 대표성을 보장하는 데 효과적입니다.

확률 샘플링 기법 (3/3): 군집 샘플링 (Cluster Sampling)

군집 샘플링 (Cluster Sampling): 모집단이 자연적으로 그룹(군집, clusters)으로 나뉘어 있을 때 사용됩니다. 각 군집은 모집단의 축소판처럼 행동할 것으로 예상됩니다.

• 절차:

1. 무작위로 일부 군집을 선택합니다.
2. 선택된 군집의 모든 구성원을 표본에 포함하거나, 선택된 군집 내에서 일부 구성원을 무작위로 선택합니다.

□ 예제

예시: 지역별 소득 조사 넓은 지리적 영역에 퍼져 있는 모집단이나, 지역별로 관심 변수에 차이가 있는 경우(예: 동네별 소득 조사)에 군집 샘플링이 적합합니다.

- 큰 도시를 15개의 군집(예: 동네)으로 나눈 후, 이 중 8개의 군집을 무작위로 선택하여 표본을 추출할 수 있습니다.

층화 샘플링과의 차이점:

- 층화 샘플링: 모든 층에서 무작위 표본을 추출합니다. 각 층은 동질적이지만 층 간에는 이질적입니다.
- 군집 샘플링: 일부 군집에서만 표본을 추출합니다. 각 군집은 이질적이지만 군집 간에는 동질적입니다.

두 방법 모두 무작위 표본을 추출하기 전에 모집단을 나누는 작업이 필요하지만, 군집 샘플링은 더 작은 표본으로도 좋은 대표성 있는 표본을 얻을 수 있습니다.

연습 문제: 패스트푸드점 고객 만족도 조사 총 10개의 패스트푸드점 네트워크를 운영하고 있으며, 고객들이 음식과 서비스 품질에 만족하는지 알고 싶습니다. 다음 샘플링 기법들을 분류하십시오:

1. 모든 고객은 계산서와 함께 전화번호를 받고 의견을 제시하도록 권장됩니다.
2. 3개의 식당을 선택하고, 지난주에 이 3개 지점을 방문한 모든 고객에게 연락하여 설문조사를 실시합니다.
3. 각 식당에서 무작위로 50명의 고객을 선택하여 설문조사를 실시합니다.
4. 과거 고객 데이터베이스에서 무작위로 500명의 고객을 선택하여 설문조사를 실시합니다.

풀이: 패스트푸드점 고객 만족도 조사 (1/4)

1. 모든 고객은 계산서와 함께 전화번호를 받고 의견을 제시하도록 권장됩니다.
 - 유형: 자발적 샘플링 (Volunteer Sampling)
 - 설명: 이는 비확률 방법입니다. 매우 만족하거나 매우 불만족한 고객의 비율이 불균형하게 나타나 잘못된 인상을 줄 수 있습니다. 불만족한 고객은 연락하지 않고 단순히 재방문하지 않을 수 있어, 개선에 필요한 피드백을 놓칠 수 있습니다.

풀이: 패스트푸드점 고객 만족도 조사 (2/4)

2. 3개의 식당을 선택하고, 지난주에 이 3개 지점을 방문한 모든 고객에게 연락하여 설문조사를 실시합니다.
 - 유형: 군집 샘플링 (Cluster Sampling)

- **설명:** 전체 고객 기반이 방문한 식당(군집)으로 나뉩니다. 우리는 3개의 군집을 선택했고, 이 3개 식당을 지난주에 방문한 모든 고객에게 설문조사를 실시했습니다.

풀이: 패스트푸드점 고객 만족도 조사 (3/4)

각 식당에서 무작위로 50명의 고객을 선택하여 설문조사를 실시합니다.

- **유형:** 층화 샘플링 (Stratified Sampling)
- **설명:** 10개의 식당이 있으므로 10개의 층(strata)이 있습니다. 각 식당에서 고객을 조사함으로써, 최악의 서비스 기록이나 최고의 서비스 기록을 가진 식당을 놓치지 않고 모든 10개 지점의 대표성을 확보할 수 있습니다.

풀이: 패스트푸드점 고객 만족도 조사 (4/4)

과거 고객 데이터베이스에서 무작위로 500명의 고객을 선택하여 설문조사를 실시합니다.

- **유형:** 단순 무작위 샘플링 (Simple Random Sample)
- **설명:** 고객이 어떤 식당을 방문했는지와 관계없이 무작위로 선택되었으므로 단순 무작위 샘플링의 예시입니다.

표본 크기 (Sample Size) 지금까지 표본 크기에 대해서는 언급하지 않았습니다. 가장 중요한 우선순위는 확률 샘플링 계획을 사용하여 모집단을 대표하는 표본을 확보하는 것입니다.

핵심 요약

표본 크기 고려 사항:

- **대표성 우선:** 가장 먼저 해야 할 일은 확률 샘플링 계획을 사용하여 모집단을 대표하는 표본을 확보하는 것입니다. 편향되지 않은 표본이 좋은 분석의 기초입니다.
- **정확도 향상:** 표본이 클수록 모집단에 대해 더 정확한 아이디어를 얻을 수 있습니다. 즉, 표본 크기가 클수록 추정치의 정밀도가 높아집니다.
- **비용 문제:** 더 큰 표본을 수집하는 데는 항상 시간과 비용이 수반됩니다. 따라서 연구의 목적과 예산에 맞춰 적절한 표본 크기를 결정해야 합니다.
- **필요에 따른 계산:** 우리의 요구 사항(예: 원하는 오차 범위, 신뢰 수준)에 따라 필요한 표본의 크기를 계산할 수 있습니다.

이 레슨에서는 모집단에서 개인 또는 데이터 포인트를 선택하는 다양한 기술을 배웠습니다. 이는 겉보기에는 간단한 단계이지만, 실제로는 매우 중요한 단계입니다. 좋은 표본 없이는 좋은 분석이 불가능합니다. 일반적으로 확률 샘플링 방법은 편향되지 않은 표본을 생성하며, 이를 통해 우리의 발견을 안전하게 일반화할 수 있습니다. 그러나 비확률 샘플링 기술을 사용하는 것이 유일한 선택인 경우도 있습니다. 이러한 기술이 사용될 때는 그들이 도입하는 편향의 유형과 그 결과로 얻은 표본에서 도출할 수 있는 결론의 한계를 인식하는 것이 중요합니다.

4.2.2 Lesson 3-2.2: Sampling Function in Excel

이 섹션에서는 Excel의 데이터 분석 기능을 사용하여 모집단에서 표본을 추출하는 방법을 실습합니다.

주의사항

사전 준비: 이 실습을 위해서는 'Daily Temperature' Excel 파일이 필요합니다. 이 파일은 일반적으로 강의 자료에서 제공되며, 첫 번째 워크시트에 데이터가 포함되어 있습니다.

Excel에서 샘플링 기능 사용하기 우리는 샴페인, 시카고, 뉴욕 세 도시의 일일 기온 데이터를 가지고 있습니다. 여기서는 뉴욕의 기온 데이터를 사용하여 샘플링을 진행합니다.

일일 기온 Excel 시트 (Daily Temperature Excel Sheet)

데이터 설명: Excel 워크시트에는 일련번호(day #), 날짜(date), 그리고 샴페인, 시카고, 뉴욕 공항의 기온 데이터가 다섯 개의 열로 구성되어 있습니다. 이 데이터는 수만 개의 관측치를 포함할 수 있습니다.

1. 데이터 선택:

- 뉴욕 기온 데이터가 있는 열(예: E열)을 선택합니다.
- 첫 번째 데이터 셀(예: E2)을 클릭한 후, Ctrl + Shift + 아래쪽 화살표를 눌러 해당 열의 모든 데이터를 빠르게 선택합니다. 이 예시에서는 26,000개가 넘는 일일 기온 데이터가 있습니다 (예: E1부터 E26771까지).

2. 데이터 분석 도구 열기:

- Excel 리본 메뉴에서 데이터 (Data) 탭을 클릭합니다.
- 데이터 분석 (Data Analysis)을 클릭합니다 (일반적으로 리본 메뉴의 오른쪽 끝에 위치). 만약 이 옵션이 보이지 않는다면, Excel 추가 기능에서 '분석 도구(Analysis ToolPak)'를 활성화해야 합니다.

3. 샘플링 기능 선택:

- '데이터 분석' 팝업 창에서 목록을 아래로 스크롤하여 샘플링 (Sampling)을 선택한 후 확인 (OK)을 클릭합니다.

4. 샘플링 설정: '샘플링' 팝업 창이 나타나면 다음을 설정합니다.

- **입력 범위 (Input Range):** 뉴욕 기온 데이터가 있는 전체 범위를 입력합니다 (예: \$E\$1:\$E\$26771). 이 범위는 첫 번째 셀(E1)에 열 이름('New York')이 포함되어야 합니다.
- **레이블 (Labels):** 첫 번째 셀(E1)에 'New York'과 같은 레이블이 포함되어 있다면, 레이블 확인란을 선택합니다. 이렇게 하면 Excel이 첫 번째 셀을 데이터가 아닌 레이블로 인식하여 샘플링에서 제외합니다.
- **샘플링 방법 (Sampling Method):**
 - 주기적 (Periodic): 특정 간격(예: 4)을 지정하면 원본 데이터에서 매 4번째 데이터를 선택합니다. 이는 무작위성이 낮아 편향될 수 있습니다.
 - 무작위 (Random): 무작위로 데이터를 선택합니다. 여기서는 무작위를 선택하여 대표성 있는 샘플을 얻습니다.
- **샘플 수 (Number of Samples):** 이 필드는 통계학에서 말하는 '샘플의 수'가 아니라, 하나의 샘플에 포함될 관측치의 수(샘플 크기)를 의미합니다. 예를 들어, 130을 입력하여 130개의 관측치를 가진 샘플을 추출합니다.

- **출력 옵션 (Output Options):**

- 출력 범위 (Output range): 특정 셀을 지정하여 결과를 출력합니다.
 - 새 워크시트 (New Worksheet Ply): 새 워크시트에 결과를 출력합니다 (기본적으로 선택). 새 통합 문서 (New Workbook): 새 통합 문서에 결과를 출력합니다.
- 여기서는 새 워크시트를 선택하고 확인 (OK)을 클릭합니다.

5. **첫 번째 샘플 확인:**

- 새로운 워크시트가 생성되고, A 열에 130개의 무작위로 선택된 뉴욕 기온 데이터가 나타납니다. 첫 번째 데이터는 레이블로 인식되어 제외됩니다.
- A1 셀에 'Sample 1'과 같이 이름을 지정합니다.

6. **여러 샘플 추출 (선택 사항):** 중심 극한 정리 (Central Limit Theorem)를 이해하기 위해 여러 개의 샘플을 추출하는 것이 유용합니다.

- 새 워크시트의 B1 셀에 'Sample 2'를 입력하고, C1, D1, E1에 각각 'Sample 3', 'Sample 4', 'Sample 5'를 입력합니다.
- 원본 데이터 시트 (Sheet 1)로 돌아가서 2~4 단계를 반복합니다.
- 이때, 출력 옵션에서 출력 범위를 선택하고, 새 워크시트 (Sheet 2)의 B2 셀을 지정하여 두 번째 샘플이 첫 번째 샘플 옆에 위치하도록 합니다. **주의:** 출력 범위를 지정할 때, 이전에 입력 범위가 자동으로 다시 강조 표시될 수 있습니다. 출력 범위 셀을 클릭한 후 다른 곳을 클릭하기 전에 반드시 출력 범위 입력 상자가 활성화되어 있는지 확인해야 합니다.
- 이 과정을 5번 반복하여 5개의 다른 샘플을 추출합니다. 각 샘플은 130개의 관측치를 가집니다. (샘플 크기는 매번 동일할 필요는 없지만, 이 예시에서는 130으로 고정했습니다.)

7. **샘플 평균 계산:** 각 샘플의 평균을 계산하여 샘플 평균이 어떻게 다른지 확인합니다.

- 예를 들어, G 열에 'Sample 1 average', 'Sample 2 average' 등을 입력합니다.
- H 열에 다음 수식을 사용하여 각 샘플의 평균을 계산합니다:

```

1 =AVERAGE(A2:A131) % Sample 의1 평균 (부터A2 까지A131 개130 데이터)
2 =AVERAGE(B2:B131) % Sample 의2 평균
3 =AVERAGE(C2:C131) % Sample 의3 평균
4 =AVERAGE(D2:D131) % Sample 의4 평균
5 =AVERAGE(E2:E131) % Sample 의5 평균

```

Listing 1: 샘플 평균 계산 예시

- 결과는 다음과 같을 수 있습니다 (예시 값):
- Sample 1 평균: 55.97807693
- Sample 2 평균: 54.91192308
- Sample 3 평균: 58.03353846
- Sample 4 평균: 57.76907692
- Sample 5 평균: 55.77107692

핵심 요약

샘플링 결과 분석: 동일한 대규모 데이터 세트에서 추출된 5개의 샘플(각 130개 관측치)은 서로 다른 평균값을 가집니다. 예를 들어, 샘플 3이 가장 높은 평균을, 샘플 2가 가장 낮은 평균을 보였습니다.

이러한 샘플 평균의 차이를 이해하는 것이 중심 극한 정리 (Central Limit Theorem)의 핵심입니다. 나중엔 샘플 평균의 분포를 살펴보고 중심 극한 정리가 어떻게 작동하는지 이해하게 될 것입니다. 이 실습은 중심 극한 정리의 개념을 시각적으로 이해하는 데 중요한 기초를 제공합니다.

5 개요

□ 핵심 요약

이 문서는 'Exploring and Producing Data Module 3'의 후반부 내용을 다루며, 통계학의 핵심 개념인 **중심 극한 정리(Central Limit Theorem, CLT)**를 심층적으로 탐구합니다. 표본 평균과 표본 비율의 분포가 모집단의 형태와 관계없이 충분히 큰 표본 크기에서 정규 분포를 따른다는 원리를 이해하고, 이를 통해 단일 표본으로 모집단에 대한 신뢰성 있는 추론을 수행하는 방법을 학습합니다. 실제 데이터와 시뮬레이션, Excel 실습을 통해 CLT의 강력한 힘과 경험적 규칙(Empirical Rule)의 적용을 시각적으로 확인하며, 데이터 기반 의사결정의 기초를 다집니다.

6 용어 정리

Table 1: 주요 통계 용어 정리

용어	쉬운 설명	원어	비고
중심 극한 정리	표본 평균의 분포가 모집단 형태와 무관하게 정규 분포를 따르는 현상	Central Limit Theorem (CLT)	통계적 추론의 기반
표본 평균	여러 표본에서 계산된 평균들의 분포	Sampling Distribution of Sample Means	표본 크기가 커질수록 정규 분포에 가까워짐
표본 비율	여러 표본에서 계산된 비율들의 분포	Sampling Distribution of Sample Proportions	표본 크기가 커질수록 정규 분포에 가까워짐
표준 오차	표본 평균 또는 표본 비율 분포의 표준 편차	Standard Error (SE)	표본 크기가 클수록 작아짐 (정확도 증가)
모집단	연구 대상이 되는 전체 집단	Population	모든 개체의 특성
표본	모집단에서 추출된 일부 집단	Sample	모집단을 대표하도록 무작위 추출
점 추정량	모집단 모수를 추정하기 위해 표본에서 계산된 값	Point Estimator	표본 평균($\bar{x}$), 표본 비율($\hat{p}$) 등
경험적 규칙	정규 분포에서 평균으로부터 표준 편차의 배수 내에 데이터가 포함되는 비율	Empirical Rule (68-95-99.7 Rule)	표본 평균 분포에 적용 가능
모집단 평균	모집단 전체의 평균	Population Mean (μ)	미지의 값인 경우가 많음
표본 평균	표본에서 계산된 평균	Sample Mean ($\bar{x}$)	모집단 평균의 추정치
모집단 표준 편차	모집단 전체의 표준 편차	Population Standard Deviation (σ)	모집단 데이터의 퍼짐 정도
표본 표준 편차	표본에서 계산된 표준 편차	Sample Standard Deviation (s)	표본 데이터의 퍼짐 정도
모집단 비율	모집단 전체에서 특정 범주에 속하는 비율	Population Proportion (p)	미지의 값인 경우가 많음
표본 비율	표본에서 특정 범주에 속하는 비율	Sample Proportion ($\hat{p}$)	모집단 비율의 추정치

7 핵심 개념 및 원리

7.1 3-3.1 중심 극한 정리와 표본 평균 (Central Limit Theorem and Sampling Means)

□ 핵심 요약

대부분의 사람들은 작은 표본으로 얻은 결과에 대해 의심을 품습니다. 하지만 통계학의 '슈퍼히어로'인 중심 극한 정리(CLT) 덕분에, 우리는 편향되지 않고 대표성 있는 표본만 있다면, 그 크기가 상대적으로 작더라도 모집단에 대한 정확한 결론을 내릴 수 있습니다. 이 정리는 표본 평균의 분포가 특정 조건을 만족할 때 정규 분포를 따른다는 강력한 통찰을 제공합니다.

CLT의 기본 원리: 표본 평균의 분포

우리는 모집단 전체를 연구할 시간이나 수단이 없는 경우가 많습니다. 그래서 표본 연구에 의존하게 되는데, 이때 중심 극한 정리가 큰 역할을 합니다. 이 정리는 다음과 같은 핵심 아이디어를 제공합니다:

- **작은 표본으로 큰 결론:** 소수의 사람들에게 신약을 테스트하고 전 세계에 안전하고 효과적이라고 결정하는 것과 같이, 작은 표본으로도 광범위한 결론을 도출할 수 있는 근거가 됩니다.
- **통계학의 슈퍼히어로:** 통계학에서 가장 강력한 정리 중 하나로, 표본을 통해 모집단을 이해하는 데 필수적인 도구입니다.

이 정리를 이해하기 위해 구체적인 예시를 살펴보겠습니다.

□ 예제

영화 스튜디오는 수익을 위해 영화를 제작하며, 십대(13-19세)는 중요한 고객층입니다. 스튜디오는 어떤 유형의 영화를 우선 제작할지 결정하기 위해 십대들이 영화 관람에 얼마나 돈을 쓰는지 알고 싶어 합니다.

- **모집단 질문:** 전국의 모든 십대들이 영화 관람에 얼마나 돈을 쓸까요?
- **이상적인 시나리오:** 모든 십대에게 물어본다면, 대부분의 지출액은 평균 근처에 모여 있을 것이고, 평균에서 멀어질수록 해당 금액을 지출하는 십대는 줄어들 것입니다.
- **현실적인 제약:** 모든 십대에게 물어볼 수는 없습니다. 따라서 우리는 무작위 표본을 추출하여 조사합니다.

첫 번째 연구: 25명의 십대 그룹에게 연간 영화 관람 지출액을 물어봅니다.

- **표본 크기:** $n = 25$
- **개별 응답 분포:** 히스토그램은 3,000달러에서 10,500달러까지 넓은 범위의 지출액을 보여줍니다.
- **그룹 평균:** 이 25명의 평균 지출액은 약 **\$728**입니다.

이 한 그룹의 평균이 전체 모집단을 대표하지 않을 수 있으므로, 우리는 이러한 표본을 여러 번 추출하여 그 평균들을 살펴봅니다. 이 연구에서는 25명의 십대로 구성된 그룹 99개를 더 추출하여 각 그룹의 평균 지출액을 기록할 것입니다. 최종적으로 총 100개의 평균 지출액을 얻게 됩니다.

표본 크기 변화에 따른 표본 평균 분포의 변화

100개의 표본 평균(각 표본 크기 $n = 25$)을 히스토그램으로 그리면, 그 분포는 다소 종 모양(bell-shaped)을 띠는 것을 확인할 수 있습니다.

이제 표본 크기를 늘려가면서 표본 평균의 분포가 어떻게 변하는지 관찰해 봅시다.

Figure 1: 표본 크기 $n = 25$ 일 때 100개 표본 평균의 분포 (가상 이미지)

설명: 이 히스토그램은 6,000달러에서 7,500달러 사이에 집중되어 있으며, 대략적인 종 모양을 보여줍니다.

- **표본 크기 $n = 50$:** 각 그룹의 표본 크기를 50으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,000달러에서 7,000달러 사이에 더 밀집된 형태를 보입니다.
- **표본 크기 $n = 100$:** 각 그룹의 표본 크기를 100으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,000달러에서 6,800달러 사이에 더욱 밀집됩니다.
- **표본 크기 $n = 250$:** 각 그룹의 표본 크기를 250으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,200달러에서 6,600달러 사이에 훨씬 더 밀집된 형태를 보입니다.

Figure 2: 표본 크기 증가에 따른 표본 평균 분포의 변화 (가상 이미지)

설명: 5개의 히스토그램이 나란히 표시되어 있으며, 표본 크기가 증가할수록 분포가 더욱 정규 분포에 가까워지고 평균 주변에 밀집되는 것을 시각적으로 보여줍니다.

□ 핵심 요약

표본 크기가 증가함에 따라, 표본 평균의 분포는 다음과 같이 변합니다:

- **분포의 퍼짐 감소:** 분포의 폭(spread)이 줄어듭니다.
- **정규 분포에 수렴:** 분포가 평균을 중심으로 더욱 고르게 퍼지면서 전형적인 정규 분포(normal distribution) 형태에 가까워집니다.
- **좁아지는 분포:** 분포가 좁아진다는 것은 표준 편차가 작아진다는 의미이며, 이는 표본 평균이 모집단 평균을 훨씬 더 잘 대표하게 됨을 뜻합니다.

비정규 모집단에도 적용되는 CLT

그렇다면 모집단 자체가 정규 분포를 따르지 않는 경우에도 이러한 현상이 나타날까요? 중심 극한 정리의 진정한 힘은 바로 여기에 있습니다.

□ 예제

시카고의 수년간 일일 평균 기온 분포를 살펴보면, 이는 정규 분포가 아닌 **이봉 분포(bimodal distribution)**를 보입니다. 두 개의 봉우리는 추운 달과 따뜻한 달에 가장 자주 관측되는 기온을 나타냅니다.

이러한 비정규 모집단에서 표본 평균의 표본 분포는 어떻게 나타날까요? 우리는 시카고의 평균 기온을 추정하기 위해 다음과 같이 여러 표본을 추출해 보겠습니다.

- **표본 크기 $n = 5$:** 100개의 표본을 추출하고 각 표본에서 5개의 관측치를 선택합니다. 표본 평균의 분포는 36도에서 60도 사이에 집중되며, 48.71도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 25$:** 표본 크기를 25로 늘립니다. 표본 평균의 분포는 38.9680도에서 59도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 50$:** 표본 크기를 50으로 늘립니다. 표본 평균의 분포는 41도에서 57도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 100$:** 표본 크기를 100으로 늘립니다. 표본 평균의 분포는 42도에서 56.5도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.

□ 핵심 요약

비정규 모집단에서도 표본 크기가 증가함에 따라, 표본 평균의 분포는 다음과 같이 변합니다:

- 정규 분포에 수렴: 표본 평균의 분포는 더욱 정규 분포에 가까워집니다.
- 좁아지는 분포: 분포가 더욱 좁아집니다.

이는 모집단의 실제 분포가 무엇이든 상관없이, 표본 크기가 충분히 크다면 표본 평균의 분포는 항상 대략적으로 정규 분포를 따른다는 것을 의미합니다. 이 특별한 현상 덕분에 우리는 실제 모집단이 정규 분포를 따르든 아니든 상관없이 정규 분포의 속성을 활용할 수 있습니다.

표본 평균 분포의 특성: 표준 오차

표본 평균의 분포를 설명할 때, 우리는 중심 경향성(central tendency)과 변동성(variability)을 사용합니다.

- 중심 경향성: 표본 평균 분포의 중심은 **표본 평균($\bar{x}$)**으로 나타냅니다. 이는 모집단 평균(μ)에 대한 점 추정량(point estimator)이 됩니다.
- 변동성: 표본 평균 분포의 변동성은 **표준 오차(Standard Error, SE)**라고 부릅니다. 표준 오차는 다음 공식으로 계산됩니다:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

여기서 σ 는 모집단 표준 편차이고, n 은 표본 크기입니다. 만약 모집단 표준 편차 σ 를 모른다면, 표본 표준 편차 s 를 대신 사용하여 추정할 수 있습니다.

주의사항

수학적으로 이 공식을 보면, **표본 크기(n)**가 증가할수록 분모가 커지므로 표준 오차($\sigma_{\bar{x}}$)는 감소합니다. 이는 표본 평균 분포의 변동성이 줄어든다는 것을 의미합니다.

- 신뢰성 증가: 표본 크기가 클수록 표준 오차가 작아지므로, 더 큰 표본 크기에서 얻은 결과는 더 신뢰할 수 있습니다.
- 대표성 증가: 표본 평균 분포가 좁아질수록, 표본 평균이 모집단의 참 평균에 더 가까워집니다. 이것이 바로 모든 통계 분석에서 **표본 크기가 매우 중요한 이유**입니다. 다음 모듈에서는 적절한 표본 크기를 결정하는 방법에 대해 더 자세히 배울 것입니다.

중심 극한 정리의 궁극적인 활용: 경험적 규칙

중심 극한 정리 덕분에 표본 평균이 정규 분포를 따른다는 것을 알게 되었으므로, 우리는 정규 곡선의 강력한 속성인 **경험적 규칙(Empirical Rule)**을 활용할 수 있습니다.

Figure 4: 정규 분포와 경험적 규칙 (가상 이미지)

설명: 평균을 중심으로 종 모양의 곡선이 그려져 있으며, ± 1 표준 편차 내에 68

- **68% 규칙:** 모든 표본 평균의 약 **68%**는 모집단 평균으로부터 **1 표준 오차** 이내에 놓일 것으로 예상됩니다.
- **95% 규칙:** 모든 표본 평균의 약 **95%**는 모집단 평균으로부터 **2 표준 오차** 이내에 놓일 것으로 예상됩니다.
- **99.7% 규칙:** 모든 표본 평균의 약 **99.7%**는 모집단 평균으로부터 **3 표준 오차** 이내에 놓일 것으로 예상됩니다.

이러한 지식을 바탕으로 우리는 단 하나의 표본만 추출하더라도, 그 표본 평균이 분포의 중심(모집단 평균에 가까운 값)에 있는지 아니면 꼬리 부분(이상치)에 가까운지에 대해 평가할 수 있습니다. 이러한 평가 능력은 우리가 수행한 표본 연구 결과에 대해 얼마나 확신할 수 있는지를 알려주며, 이는 다음 모듈에서 다룰 주제인 신뢰 구간(confidence interval)의 기초가 됩니다.

7.2 3-3.2 중심 극한 정리 시각화 (Animating the Central Limit Theorem)

이 섹션에서는 애니메이션을 통해 중심 극한 정리가 실제로 어떻게 작동하는지 시각적으로 보여줍니다.

애니메이션 설정: 모집단 분포 변경

- **초기 상태:** 먼저 정규 분포를 따르는 모집단을 가정합니다. 이 모집단에서 표본을 반복적으로 추출하면, 표본 평균 또한 정규 분포를 따를 것이라는 것은 놀라운 일이 아닙니다.
- **모집단 사용자 정의:** 애니메이션에서는 모집단 분포를 임의로 클릭하여 비정규 분포로 변경합니다. 예를 들어, 여러 지점에 데이터를 집중시켜 비대칭적이거나 다봉형의 분포를 만듭니다.

Figure 5: 사용자 정의된 비정규 모집단 분포 (가상 이미지)

설명: 히스토그램에서 여러 무작위 지점을 클릭하여 생성된 비정규 분포를 보여줍니다. 이 분포는 평균 14.80, 중앙값 11.00, 표준 편차 9.45, 왜도 0.28, 첨도 -1.35를 가집니다. 평균과 중앙값이 크게 다르므로 종 모양이 아님을 알 수 있습니다.

표본 추출 및 평균 분포 관찰

애니메이션은 다음과 같은 과정을 반복합니다.

1. **첫 번째 클릭:**
 - 모집단에서 5개의 무작위 관측치를 추출하여 'Sample Data' 그래프에 표시합니다.
 - 이 5개 관측치의 평균을 계산하여 'Distribution of Means N=5' 그래프에 점으로 표시합니다.
 - 모집단에서 25개의 무작위 관측치를 추출하여 'Sample Data' 그래프에 표시합니다.
 - 이 25개 관측치의 평균을 계산하여 'Distribution of Means N=25' 그래프에 점으로 표시합니다.
2. **반복:** 이 과정을 여러 번 반복하여 각 표본 크기(N=5, N=25)에 대한 표본 평균 분포가 어떻게 형성되는지 시각적으로 보여줍니다.
3. **관찰:** 초기에는 N=5의 분포가 왼쪽으로 치우치는 등 비대칭적일 수 있지만, N=25의 분포는 상대적으로 중앙에 더 가깝게 위치하는 경향을 보입니다.

Figure 6: 애니메이션을 통한 표본 추출 및 평균 분포 형성 (가상 이미지)

설명: 상단에 사용자 정의된 모집단 히스토그램이 있고, 그 아래에 'Sample Data', 'Distribution of Means N=5', 'Distribution of Means N=25' 그래프가 있습니다. 애니메이션 버튼을 클릭하면 데이터 블록이 'Sample Data'로 떨어지고, 그 평균이 아래 두 그래프에 점으로 추가됩니다. N=25의 평균이 N=5의 평균보다 그래프 중앙에 더 가깝게 위치하는 경향을 보여줍니다.

대규모 반복을 통한 정규 분포 수렴

- **소규모 반복:** 5회 반복 시에는 여전히 정규 분포와 거리가 멀어 보일 수 있습니다.
- **대규모 반복 (10,000회):** 10,000번 반복하면, 표본 평균의 분포는 훨씬 더 정규 분포에 가까워집니다. 특히 N=25의 분포는 N=5의 분포보다 훨씬 더 좁고 종 모양을 띠게 됩니다.
- **초대규모 반복 (100,000회):** 100,000번 반복하면, 두 분포 모두 거의 완벽한 정규 분포를 보이며, N=25의 분포는 N=5의 분포보다 훨씬 더 밀집되어 있습니다.

□ 핵심 요약

중심 극한 정리의 아름다움은 여기에 있습니다: 어떤 모집단 분포를 가지고 있는 상관없이, 충분히 큰 표본 크기(일반적으로 30 이상)만 있다면, 표본 평균의 표본 분포는 정규 분포를 따르기 시작합니다. 이 덕분에 우리는 단 하나의 표본을 추출하더라도 그 표본 평균이 모집단 평균으로부터 얼마나 변동할지 예측할 수 있습니다.

표준 오차의 시각적 이해와 계산

애니메이션은 표준 오차의 개념을 시각적으로도 보여줍니다.

- 표준 오차의 형태: 표본 평균 분포의 퍼짐 정도를 나타내는 것이 표준 오차입니다.
- 공식: 표준 오차는 모집단 표준 편차를 표본 크기의 제곱근으로 나눈 값입니다.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

- 계산 예시:
 - 모집단 표준 편차가 9.45라고 가정할 때:
 - N=5일 때: $\sigma_{\bar{x}} = \frac{9.45}{\sqrt{5}} \approx 4.22$
 - N=25일 때: $\sigma_{\bar{x}} = \frac{9.45}{\sqrt{25}} = \frac{9.45}{5} \approx 1.89$

주의사항

이 계산 결과는 표본 크기가 커질수록 표준 오차가 크게 감소한다는 것을 명확히 보여줍니다. 즉, 표본 크기가 클수록 표본 평균들이 하나의 중심점(모집단 평균) 주위에 훨씬 더 밀집되어 분포하게 됩니다. 이는 표본이 모집단을 더 정확하게 대표한다는 의미입니다.

표본 평균을 통한 모집단 평균 추정

애니메이션의 최종 결과는 표본 평균의 분포 평균이 모집단 평균에 매우 가깝다는 것을 보여줍니다.

- 모집단 평균: 14.80
- N=5일 때 표본 평균 분포의 평균: 14.78 (모집단 평균에 매우 근접)
- N=25일 때 표본 평균 분포의 평균: 14.79 (모집단 평균에 더욱 근접)

□ 핵심 요약

중심 극한 정리의 아름다움과 강점은 바로 여기에 있습니다. 만약 표본 추출을 올바르게 수행한다면, 추출된 표본은 모집단을 잘 대표하게 됩니다. 따라서 표본 정보를 사용하여 얻은 통계량(예: 표본 평균)은 모집단 모수(예: 모집단 평균)에 대한 훌륭한 점 추정량(point estimator)이 됩니다.

7.3 3-3.3 표본 분포와 경험적 규칙 (Sampling Distribution and Empirical Rule in Excel)

이 섹션에서는 Excel을 사용하여 중심 극한 정리와 경험적 규칙의 개념을 실제 데이터로 시연합니다.

데이터 준비: 뉴욕 일일 기온 데이터

- 데이터셋: 뉴욕시의 지난 25년간 26,000개 이상의 일일 평균 기온 데이터 포인트를 사용합니다.
- 모집단 특성:
 - 최소 일일 평균 기온: **2.6도** (화씨)
 - 최대 일일 평균 기온: **94.5도** (화씨)
 - 평균 일일 기온 (모집단 평균): **55.2도** (화씨)
 - 표준 편차 (모집단 표준 편차): 약 **17.38**

표본 추출 및 표본 평균 계산

- 표본 크기: 각 표본은 72개의 관측치(무작위로 선택된 72일)를 가집니다. ($n = 72$)
- 반복 횟수: 이 과정을 총 **100,000**번 반복하여 100,000개의 표본 평균을 얻습니다.
- 예시: 첫 번째 표본의 평균은 54.7도였습니다.

Figure 7: Excel에서 100,000개의 표본 평균 데이터 (가상 이미지)

설명: 'Sample Number'와 'Sample Average' 두 열로 구성된 Excel 시트의 일부를 보여줍니다. 각 행은 하나의 표본과 그 평균을 나타냅니다.

표본 평균 분포의 특성 분석

100,000개의 표본 평균 데이터를 사용하여 그 분포의 특성을 분석합니다.

- 표본 평균의 최소/최대:
 - 최소 표본 평균: **47.2도**
 - 최대 표본 평균: **64.2도**
 이는 모집단 평균 55.2도에서 상당히 벗어난 표본 평균도 존재함을 보여줍니다.
- 표본 평균들의 평균: 100,000개 표본 평균들의 평균을 계산하면 **55.2도**가 나옵니다. 이는 모집단 평균과 정확히 일치합니다.
- 표본 평균들의 표준 편차 (실제 계산): 100,000개 표본 평균들의 표준 편차를 Excel의 STDEV.S 함수로 계산하면 약 **2.05**가 나옵니다.
- 표준 오차 (이론적 계산): 표준 오차 공식($\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$)을 사용하여 이론적인 표준 오차를 계산합니다.

$$\sigma_{\bar{x}} = \frac{17.38}{\sqrt{72}} \approx 2.048$$

□ 핵심 요약

Excel에서 직접 계산한 표본 평균들의 표준 편차(2.05)와 이론적인 표준 오차(2.048)가 거의 일치하는 것을 확인할 수 있습니다. 이는 중심 극한 정리와 표준 오차 공식이 실제 데이터에서도 정확하게 작동함을 보여줍니다.

모집단 분포와 표본 평균 분포의 비교

- **모집단 히스토그램 (뉴욕 기온):** 26,000개 이상의 기온 기록에 대한 히스토그램은 40도와 76도 부근에 두 개의 봉우리가 있는 **이봉 분포**를 보이며, 이는 정규 분포가 아닙니다.
- **표본 평균 히스토그램:** 100,000개 표본 평균에 대한 히스토그램을 생성합니다.
 - **빈(Bin) 설정:** 표본 평균의 최소(47.2)와 최대(64.2) 값을 고려하여 45도에서 66도까지 0.5도 간격으로 빈을 설정합니다.
 - **결과:** 생성된 히스토그램은 **종 모양의 정규 분포**와 매우 유사한 형태를 보입니다. 중심은 55.2도에 위치하며, 분포의 퍼짐은 표준 오차인 2.048에 해당합니다.

Figure 8: 뉴욕 기온 모집단 분포와 표본 평균 분포 히스토그램 비교 (가상 이미지)

설명: 왼쪽에는 이봉 분포를 보이는 뉴욕 기온 모집단 히스토그램이, 오른쪽에는 종 모양의 정규 분포를 보이는 표본 평균 히스토그램이 나란히 배치되어 있습니다. 표본 평균 히스토그램은 55도 근처에 중앙값이 위치하며, 모집단 분포보다 훨씬 좁고 대칭적입니다.

□ 핵심 요약

이 시각적 비교는 중심 극한 정리의 핵심을 명확히 보여줍니다. 모집단 분포가 정규 분포가 아니더라도, 충분히 큰 표본 크기(여기서는 $n = 72$)로 추출된 표본 평균들의 분포는 **정규 분포를 따르게** 됩니다. 또한, 이 분포는 모집단 분포보다 훨씬 더 **밀집되어(좁게)** 있습니다.

표본 평균 분포에 경험적 규칙 적용

표본 평균 분포가 정규 분포를 따르므로, 우리는 여기에 경험적 규칙을 적용할 수 있습니다. 우리의 표본 평균 분포의 평균은 55.2도이고, 표준 오차는 약 2.05도입니다.

- **1 표준 오차 이내 (68%):**
 - 범위: $55.2 \pm 1 \times 2.05 = [53.15, 57.25]$
 - 의미: 약 68%의 표본들이 53.15도에서 57.25도 사이의 평균을 가질 것입니다.
- **2 표준 오차 이내 (95.5%):**
 - 범위: $55.2 \pm 2 \times 2.05 = [51.1, 59.3]$
 - 의미: 약 95.5%의 표본들이 51.1도에서 59.3도 사이의 평균을 가질 것입니다.
- **3 표준 오차 이내 (99.7%):**
 - 범위: $55.2 \pm 3 \times 2.05 = [49.05, 61.35]$
 - 의미: 약 99.7%의 표본들이 49.05도에서 61.35도 사이의 평균을 가질 것입니다.

Figure 9: 표본 평균 히스토그램에 적용된 경험적 규칙 (가상 이미지)

설명: 표본 평균 히스토그램 위에 68

주의사항

이 예시에서 보듯이, 우리의 데이터에서도 경험적 규칙이 완벽하게 적용됩니다. 이는 중심 극한 정리가 '정리(theorem)'인 이유입니다. 모집단의 근본적인 분포가 정규 분포이든 아니든 상관없이, **충분히 큰 표본 크기**를 가진다면 표본 평균의 분포는 정규 분포를 따를 것이고, 따라서 경험적 규칙도 항상 성립합니다.

7.4 3-4.1 중심 극한 정리와 표본 비율 (Central Limit Theorem – Sampling Proportion)

중심 극한 정리는 표본 평균에만 적용되는 것이 아닙니다. **표본 비율(sample proportion)**의 경우에도 정규 분포 현상이 나타납니다.

표본 비율의 개념

- **비율의 정의:** 비율은 특정 범주에 속하는 그룹의 **백분율(percentage)**을 의미합니다.
- **예시:**
 - 온라인 बैंकिंग을 선호하는 인구의 비율
 - 특정 후보에게 투표할 유권자의 비율
- **추론의 필요성:** 이러한 질문에 답하기 위해 우리는 다시 표본 연구에 의존하며, 표본에서 관찰된 비율을 바탕으로 모집단에 대해 일반화합니다.

Table 2: 모집단 비율과 표본 비율 표기

개념	표기
모집단 비율	p
표본 비율	$\hat{p}$ (p-hat)

주의사항

표본 비율($\hat{p}$)은 관심 있는 범주에 속하는 관측치 수를 전체 표본 크기로 나눈 값입니다.

$$\hat{p} = \frac{\text{관심 범주에 속하는 관측치 수}}{\text{총 표본 크기}}$$

예시: 온라인 쇼핑 광고 효과

우리는 온라인 쇼핑 사이트를 운영하며 다양한 온라인 광고를 통해 고객을 유치합니다. 어떤 광고가 실제로 구매로 이어지는 고객을 데려오는지 알고 싶습니다.

- **고객 유형:**
 1. 구매하는 고객
 2. 구매하지 않는 고객
- **데이터 분석:** 마케팅 부서에서 특정 광고를 호스팅하는 웹사이트의 데이터를 분석합니다.
- **관찰된 표본:** 특정 기간 동안 400명의 고객이 광고 링크를 클릭했고, 그중 118명이 구매했습니다.
- **표본 비율 계산:**

$$\hat{p} = \frac{118}{400} = 0.295$$

이는 이 링크를 통해 들어온 고객의 29.5%가 구매자임을 추정할 수 있습니다.

하지만 다른 날에는 어떤 결과가 나올까요? 여기서 중심 극한 정리가 다시 한번 도움을 줍니다.

표본 크기 변화에 따른 표본 비율 분포의 변화

모집단 비율 p 를 알고 있다고 가정하고, 표본 크기를 변화시키면서 표본 비율의 분포를 살펴봅시다.

□ 예제

가정: 실제 모집단 구매 비율은 $p = 0.3$ (30%) 입니다.

1. 표본 크기 $n = 50$, 10회 반복:

- 50명의 고객으로 구성된 표본을 10번 무작위로 추출합니다.
- 각 표본에서 구매자 수를 세어 표본 비율을 계산합니다.
- 결과: 표본 비율은 0.2에서 0.48까지 넓게 분포합니다. 단 하나의 표본만 추출한다면 실제 비율에서 상당히 벗어난 값을 얻을 수도 있습니다.

2. 표본 크기 $n = 100$, 10회 반복:

- 표본 크기를 100으로 늘립니다.
- 결과: 표본 비율의 범위는 0.24에서 0.39로 줄어들며, 분포의 퍼짐이 감소하기 시작합니다.

3. 표본 크기 $n = 1000$, 10회 반복:

- 표본 크기를 1,000으로 늘립니다.
- 결과: 표본 비율의 히스토그램은 훨씬 더 좁아지고 대략적인 종 모양을 띠기 시작합니다. 범위는 0.26에서 0.34로 크게 줄어듭니다.

□ 핵심 요약

표본 크기가 충분히 크다면, 표본 비율의 분포는 다음과 같은 특성을 보입니다:

- 정규 분포에 수렴: 대략적으로 정규 분포를 따릅니다.
- 중심: 분포의 중심은 실제 모집단 비율(p) 주변에 위치합니다.
- 퍼짐 감소: 표본 크기가 커질수록 분포가 좁아집니다.

이는 중심 극한 정리의 핵심 원리인 "적절하게 추출된 큰 표본은 그 표본이 추출된 모집단을 닮는다"는 것을 다시 한번 보여줍니다. 물론 표본마다 변동은 있겠지만, 모집단에서 크게 벗어나는 표본이 나올 확률은 매우 낮습니다.

표본 비율 분포의 표준 오차

표본 비율 분포의 퍼짐 정도는 표준 오차(Standard Error)로 알려져 있으며, 다음 공식으로 계산됩니다.

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

여기서 p 는 모집단 비율(또는 그 추정치)이고, n 은 표본 크기입니다.

주의사항

중심 극한 정리의 강력함은 바로 여기에 있습니다. 모집단의 근본적인 분포가 정규 분포이든 아니든 상관없이, 충분히 큰 표본 크기만 있다면 단 하나의 표본으로도 모집단에 대한 추론을 할 수 있는 능력을 제공합니다. 다음 모듈에서는 이 표본 정보를 사용하여 모집단에 대한 추론을 수행하는 방법을 더 자세히 배울 것입니다.

8 빠르게 훑어보기 (1페이지 요약)

□ 핵심 요약

- **정의:** 표본 크기가 충분히 크다면, 모집단 분포의 형태와 관계없이 표본 평균(또는 표본 비율)의 표본 분포는 정규 분포에 가까워집니다.
- **왜 중요한가?:** 모집단 전체를 조사하기 어려울 때, 작은 표본으로도 모집단에 대한 신뢰성 있는 추론을 가능하게 합니다. 통계적 추론의 근간이 됩니다.
- **표본 평균의 분포:**
 - 표본 크기(n)가 커질수록 표본 평균 분포는 더욱 정규 분포에 가까워지고, 평균 주변에 더 밀집됩니다.
 - 분포의 중심은 모집단 평균(μ)에 가까워집니다.
 - 분포의 퍼짐은 **표준 오차**($\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$)로 측정되며, n 이 커질수록 표준 오차는 작아집니다.
- **비정규 모집단:** 모집단 자체가 정규 분포를 따르지 않아도, CLT는 여전히 유효합니다. (예: 시카고 기온 데이터)
- **표본 비율의 분포:**
 - 표본 크기(n)가 커질수록 표본 비율 분포도 정규 분포에 가까워지고, 모집단 비율(p) 주변에 밀집됩니다.
 - 분포의 퍼짐은 **표준 오차**($\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$)로 측정됩니다.
- **경험적 규칙 적용:** 표본 평균/비율 분포가 정규 분포를 따르므로, 경험적 규칙(68-95-99.7 규칙)을 적용하여 표본 평균/비율이 모집단 모수로부터 얼마나 떨어져 있을지 확률적으로 예측할 수 있습니다.
- **결론:** CLT는 단일 표본을 통해 모집단에 대한 신뢰성 있는 추론을 가능하게 하는 통계학의 핵심 원리입니다.

9 FAQ

- **Q: 중심 극한 정리(CLT)가 왜 '슈퍼히어로'라고 불리나요? A:** CLT는 통계학에서 가장 강력하고 광범위하게 적용되는 정리 중 하나이기 때문입니다. 이 정리 덕분에 우리는 모집단의 실제 분포를 모르거나 비정규 분포를 따르더라도, 충분히 큰 표본만 있다면 표본 평균(또는 비율)의 분포가 정규 분포를 따른다는 것을 확신할 수 있습니다. 이는 제한된 정보로도 모집단에 대한 신뢰성 있는 추론을 가능하게 하여, 데이터 기반 의사결정의 핵심 기반이 됩니다.
- **Q: 표본 크기가 '충분히 크다'는 것은 대략 어느 정도를 의미하나요? A:** 일반적으로 표본 크기가 30 이상이면 중심 극한 정리가 잘 적용된다고 봅니다. 하지만 모집단 분포의 형태에 따라 필요한 표본 크기는 달라질 수 있습니다. 모집단 분포가 매우 비대칭적이거나 이상치가 많다면 더 큰 표본 크기가 필요할 수 있습니다. 표본 비율의 경우, $np \geq 10$ 이고 $n(1 - p) \geq 10$ 이라는 조건을 만족하는 것이 좋습니다.
- **Q: 표준 편차와 표준 오차는 무엇이 다른가요? A: 표준 편차(Standard Deviation)**는 단일 데이터셋(예: 모집단 데이터 또는 단일 표본 데이터) 내의 개별 관측치들이 평균으로부터 얼마나 퍼져 있는지를 나타내는 척도입니다. 반면, **표준 오차(Standard Error)**는 여러 표본에서 얻은 표본 통계량(예: 표본 평균 또는 표본 비율)들이 모집단 모수로부터 얼마나 퍼져 있는지를 나타내는 척도입니다. 즉, 표준 오차는 표본 통계량의 분포(표본 분포)의 표준 편차입니다.
- **Q: 모집단이 정규 분포를 따르지 않아도 CLT가 적용된다는 것이 정말인가요? A:** 네, 그렇습니다. 이것이 CLT의 가장 놀라운 점 중 하나입니다. 시카고 기온 예시에서 보았듯이, 모집단 분포가 이봉 분포와 같이 정규 분포가 아니더라도, 충분히 큰 표본 크기로 표본을 반복적으로 추출하여 그 평균들을 모으면, 이 표본 평균들의 분포는 정규 분포를 따르게 됩니다. 이 덕분에 우리는 정규 분포의 속성을 활용하여 추론을 할 수 있습니다.
- **Q: CLT를 통해 얻은 지식이 실제 의사결정에 어떻게 활용될 수 있나요? A:** CLT는 단일 표본 연구 결과를 바탕으로 모집단 전체에 대한 결론을 내릴 수 있는 과학적 근거를 제공합니다. 예를 들어, 신제품의 시장 반응을 예측하기 위해 소수의 소비자 표본을 조사하거나, 선거 결과를 예측하기 위해 소수의 유권자 표본을 조사할 때, CLT는 표본 결과가 모집단을 얼마나 잘 대표하는지, 그리고 그 결과에 대해 얼마나 확신할 수 있는지 평가하는 데 사용됩니다. 이는 다음 모듈에서 다룰 신뢰 구간 및 가설 검정의 기초가 됩니다.