

CSCI103: Data Engineering

통합 강의 노트

Contents

Chapter 1

용어 정리

강의명: CSCI103 Lecture 1: 데이터 엔지니어링 소개

주차: Lecture 1

교수명: UIUC Student

목적: 본 문서는 CSCI103 Lecture 1 강의 자료를 통합하여 작성된 시험 대비용 LaTeX 노트입니다. 데이터 엔지니어링의 기본 개념, 빅데이터의 특성, 데이터 플랫폼의 진화 과정, 그리고 클라우드 기반 실습 환경인 Databricks 사용법을 다룹니다. 강의 목표는 비즈니스 문제 해결을 위한 데이터 엔지니어링의 중요성을 이해하고, 실제 분석 환경에서 데이터를 효과적으로 다루는 기술을 습득하는 것입니다. 주요 평가 포인트는 과제, 퀴즈, 최종 그룹 프로젝트 발표이며, 적극적인 참여가 중요합니다. 이 문서는 초심자도 완벽히 이해할 수 있도록 상세한 설명과 예시를 포함합니다.

용어 정리

다음은 강의에서 소개된 주요 용어들을 쉽게 설명한 표입니다.

용어	쉬운 설명	원어	비고
데이터 엔지니어링	원시 데이터를 가치 있는 통찰로 바꾸는 과정	Data Engineering	데이터 파이프라인 구축 및 관리
빅데이터	기존 도구로 처리하기 어려운 대규모 데이터	Big Data	5V(Volume, Velocity, Variety, Veracity, Value) 특성
Databricks	빅데이터 처리 및 머신러닝을 위한 통합 플랫폼	Databricks	Spark 기반, 레이크하우스 아키텍처
데이터 페르소나	데이터 관련 업무를 수행하는 다양한 역할	Data Personas	엔지니어, 과학자, 분석가 등
분산 컴퓨팅	여러 컴퓨터가 협력하여 작업을 처리하는 방식	Distributed Computing	빅데이터 처리에 필수적
머신러닝 (ML)	데이터 학습을 통해 예측/결정하는 인공지능 분야	Machine Learning	데이터 엔지니어링의 주요 결과물
ETL	데이터 추출, 변환, 적재 과정	Extract, Transform, Load	데이터 파이프라인의 핵심
데이터 파이프라인	데이터가 흐르고 처리되는 자동화된 경로	Data Pipeline	원시 데이터 → 정제 데이터
레이크하우스	데이터 레이크와 데이터 웨어하우스의 장점 결합	Lakehouse	Databricks의 핵심 아키텍처
ACID	데이터베이스 트랜잭션의 4가지 속성	Atomicity, Consistency, Isolation, Durability	관계형 데이터베이스의 신뢰성 보장
BASE	NoSQL 데이터베이스의 3가지 속성	Basically Available, Soft state, Eventual consistency	유연성 및 확장성 중시
CAP 이론	분산 시스템의 3가지 속성 중 2가지만 만족 가능	Consistency, Availability, Partition tolerance	시스템 설계 시 트레이드오프
OLTP	실시간 트랜잭션 처리 시스템	Online Transactional Processing	은행 거래, 온라인 쇼핑 등
OLAP	대규모 데이터 분석 시스템	Online Analytical Processing	보고서, 비즈니스 인텔리전스
Hadoop	대규모 데이터 분산 처리를 위한 오픈소스 프레임워크	Hadoop	데이터 레이크 시대의 시작
Spark	Hadoop의 한계를 극복한 인메모리 분산 처리 엔진	Spark	빠른 속도, 다양한 기능 지원
RDD	Spark의 기본 데이터 추상화 단위	Resilient Distributed Dataset	불변성, 분산 처리
데이터프레임	Spark의 구조화된 데이터 처리 API	DataFrame	RDD보다 사용하기 쉬운 추상화
IaaS	인프라를 서비스로 제공하는 클라우드 모델	Infrastructure as a Service	가상 머신, 스토리지 등
PaaS	플랫폼을 서비스로 제공하는 클라우드 모델	Platform as a Service	개발 환경, 데이터베이스 등
SaaS	소프트웨어를 서비스로 제공하는 클라우드 모델	Software as a Service	Gmail, Salesforce, Databricks 등
Unity Catalog	Databricks의 통합 데이터 거버넌스 솔루션	Unity Catalog	데이터 접근 제어, 메타데이터 관리

핵심 개념 · 원리

1. 데이터 엔지니어링의 정의와 중요성

핵심 요약

데이터 엔지니어링은 원시 데이터를 수집, 변환, 관리하여 비즈니스 통찰력을 얻고 머신러닝 모델을 구축하는 데 사용할 수 있도록 준비하는 과정입니다. 이는 현대 비즈니스에서 데이터의 가치를 극대화하는 핵심적인 역할입니다.

왜 필요한가? 오늘날 대부분의 비즈니스는 데이터를 기반으로 운영됩니다. 하지만 데이터는 종종 여러 소스에 흩어져 있고, 정제되지 않은 '날것'의 형태입니다. 이러한 원시 데이터는 그 자체로는 가치가 낮습니다. 데이터 엔지니어링은 이 원시 데이터를 분석 가능한 형태로 가공하고, 신뢰할 수 있는 파이프라인을 통해 지속적으로 제공함으로써 비즈니스 의사결정과 혁신을 가능하게 합니다.

직관적 비유: 데이터 엔지니어는 마치 정수기 필터와 배관공을 합쳐놓은 것과 같습니다. 수도꼭지에서 나오는 흙탕물(원시 데이터)을 바로 마실 수는 없습니다. 데이터 엔지니어는 이 흙탕물을 깨끗하게 정수(변환)하고, 각 가정(분석가, 데이터 과학자)에 필요한 형태로 안정적으로 공급(파이프라인)하는 역할을 합니다. 그래야 사람들이 깨끗한 물(통찰력)을 마시고 건강(비즈니스 성장)해질 수 있습니다.

기술적 설명: 데이터 엔지니어링은 소프트웨어 엔지니어링, 데이터 과학, 비즈니스 인텔리전스(BI)의 교차점에 있습니다. 주요 업무는 다음과 같습니다:

- **데이터 구조 및 분산 컴퓨팅:** 대규모 데이터를 효율적으로 저장하고 처리하기 위한 구조를 설계하고 분산 시스템을 활용합니다.
- **프로그래밍 및 도구:** Python, Scala, SQL 등 다양한 언어와 Spark, Databricks 같은 도구를 사용하여 데이터를 처리합니다.
- **ETL 및 데이터 파이프라인 구축:** 데이터를 추출(Extract), 변환(Transform), 적재(Load)하는 과정을 자동화하는 파이프라인을 설계하고 구현합니다.
- **소프트웨어 엔지니어링 원칙 적용:** 설계, 개발, 웹/모바일 앱, DevOps, 서비스 배포 등 소프트웨어 개발의 모범 사례를 따릅니다.