

February 2, 2026

- 강의명: CS109A: 데이터 과학 입문
- 주차: Lecture 01
- 교수명: Pavlos Protopapas, Kevin Rader, Chris Gumb
- 목적: Lecture 01의 핵심 개념 학습

□ 핵심 요약

본 문서는 CS109A '데이터 과학 입문' 과정의 첫 번째 강의와 실습 세션을 통합한 종합 노트입니다. 데이터 과학의 정의, 역사적 발전, 5단계 프로세스 등 핵심 이론을 다룹니다. 또한 과정의 상세한 평가 기준, 특히 중요한 출석 정책을 설명합니다. 마지막으로, 파이썬(Python)을 활용한 웹 스크레이핑(Web Scraping) 기초 실습을 단계별로 상세히 안내하여 이론과 실습을 연결합니다.

Contents

1	과정 개요 (Course Overview)	2
1.1	CS109A: 데이터 과학의 첫걸음	2
1.2	예상 학습 로드맵	2
1.3	과정의 3대 목표	2
2	데이터 과학(Data Science)이란 무엇인가?	3
2.1	데이터 과학의 정의: 3단계 접근	3
2.2	데이터 과학의 역사적 발전 4단계	3
2.3	데이터 과학의 3대 구성 요소	3
2.4	데이터 과학의 잠재력과 위험성	4
3	데이터 과학의 5단계 프로세스	5
4	CS109A 과정 상세 안내	6
4.1	교수진 및 조교(TAs)	6
4.2	학습 철학: "Wax on, Wax off"	6
4.3	학습 도구	6
4.4	도움 받는 방법 (How to get help)	6
5	평가 및 주요 정책	7

5.1	5대 평가 요소 및 비중	7
5.2	숙제 (Homework) 상세	7
5.3	선수과목 (Prerequisites) 진단	7
5.4	출석 및 지각 정책	8
6	실습 (Section 1): 웹 스크레이핑 입문	9
6.1	웹 스크레이핑이란?	9
6.2	실습 라이브러리	9
6.3	1단계: 웹 스크레이핑 윤리 및 규칙 확인	9
6.4	2단계: HTML 기초와 브라우저 '검사' 도구	9
6.5	3단계: requests로 데이터 가져오기	10
6.6	4단계: BeautifulSoup로 HTML 파싱하기	10
6.7	5단계: 데이터 추출 및 구조화 (노벨상 예제)	11
6.8	6단계: pandas로 데이터 프레임 변환	12
6.9	(심화) 비동기 (Async) 스크레이핑	12
7	자주 묻는 질문 (FAQ)	13

1 과정 개요 (Course Overview)

1.1 CS109A: 데이터 과학의 첫걸음

본 과정(CS109A)은 데이터 과학과 인공지능(AI) 분야의 전문가가 되기 위한 여정의 시작입니다. 최신 모델(예: LLM)을 단순히 사용하는 것을 넘어, 그 근간이 되는 **기초 원리(Fundamentals)**를 탄탄히 다지는 것을 목표로 합니다.

이 과정은 무술을 배울 때 기본자세(예: "Wax on, Wax off")를 반복 숙달하는 것과 같습니다. 때로는 지루하게 느껴질 수 있지만, 이 기초가 없으면 복잡한 모델을 제대로 이해하고 활용할 수 없습니다.

1.2 예상 학습 로드맵

본 과정은 데이터 과학의 전체 흐름을 따르며 다음과 같은 순서로 진행됩니다.

1. **데이터 수집 및 탐색 (Weeks 1-2):** 웹 스크레이핑, 데이터 정제(Wrangling), 탐색적 데이터 분석(EDA) 및 시각화.
2. **회귀 (Regression) (Weeks 3-5):** K-최근접 이웃(KNN), 선형 회귀, 다중/다항 회귀, 모델 선택(Cross Validation), 추론, 정규화(Ridge, Lasso).
3. **베이저안 모델링 (Bayesian) (Week 6):** 베이저안 추론 프레임워크, 베이저안 선형 회귀.
4. **분류 (Classification) (Weeks 7-9):** KNN 분류, 로지스틱 회귀, 계층적 모델링. (중간고사 포함)
5. **데이터 이슈 (Data Issues) (Week 10):** 결측치(Missingness), 인과 추론(Causal Inference), 편향성 및 윤리.
6. **트리 기반 모델 (Tree-Based) (Weeks 11-14):** 의사결정 나무, 배깅(Bagging), 랜덤 포레스트(Random Forest), 부스팅(Boosting).

1.3 과정의 3대 목표

본 과정은 이론, 실습, 그리고 실제 영향력이라는 세 가지 축을 중심으로 구성됩니다.

- **이론과 직관 (Theory/Intuition):** 통계 분석 및 머신러닝의 핵심 개념을 이해하고, 모델 평가 지표를 학습하며, 분석 결과로부터 통찰력을 추출합니다.
- **실습 (Practice):** 파이썬 라이브러리(Pandas, Scikit-learn 등)를 사용하여 머신러닝 및 딥러닝 모델을 구현하고, 다양한 종류의 데이터를 다루는 법을 배웁니다.
- **영향력 (Impact):** 데이터 과학을 사용해 실제 문제를 해결하고, 그 과정에서 발생할 수 있는 사회적, 윤리적 영향을 평가합니다.

2 데이터 과학(Data Science)이란 무엇인가?

2.1 데이터 과학의 정의: 3단계 접근

데이터 과학을 이해하는 가장 좋은 방법은 그 역사적 맥락과 구성 요소를 살펴보는 것입니다.

- **1단계 (핵심 요약):** 데이터 과학은 데이터로부터 의미 있는 통찰과 가치를 추출하는 모든 과정을 다루는 융합 학문입니다.
- **2단계 (비유):** 데이터 과학자는 데이터라는 원석을 캐내어(수집), 불순물을 제거하고(정제), 세공하여(모델링), 아름다운 보석(통찰)으로 만들어내는 장인과 같습니다.
- **3단계 (기술적 설명):** 정형/비정형 데이터를 수집, 관리, 탐색하고, 통계 및 머신러닝 모델을 적용하여 패턴을 발견하거나 미래를 예측하며, 그 결과를 시각화하여 설득력 있게 전달하는 전 과정을 포함합니다.

2.2 데이터 과학의 역사적 발전 4단계

인류가 세상을 이해하는 방식은 다음과 같이 발전해왔으며, 데이터 과학은 가장 최신의 패러다임입니다.

1. **경험적 관찰 (Empirical Observation) (고대)**
 - 밤하늘의 별을 세거나 농작물 수확량을 기록하는 등, 직접적인 관찰과 경험을 통해 데이터를 수집했습니다.
 - 이는 통계학의 초기 형태라 볼 수 있습니다.
2. **방정식 (Equations) (근대 과학)**
 - 뉴턴, 아인슈타인 등이 등장하며 세상이 작동하는 근본 원리(First Principles)를 수학 방정식으로 설명하기 시작했습니다.
 - 예: $F = ma$, $E = mc^2$
3. **컴퓨팅 (Computation) (20세기)**
 - 1단계의 방정식들이 너무 복잡하여 손으로 풀기 어려워지자, 컴퓨터를 사용하여 시뮬레이션하고 해를 구하기 시작했습니다.
4. **데이터 과학 (Data Science) (현대)**
 - **2단계(방정식)를 건너뛰는 경향이 나타납니다.**
 - 세상의 근본 원리(방정식)를 완벽히 이해하지 못하더라도, **방대한 데이터(1단계)와 강력한 컴퓨팅(3단계)**을 결합하여 세상의 작동 방식을 근사(approximate)하거나 예측합니다.

2.3 데이터 과학의 3대 구성 요소

데이터 과학은 세 가지 핵심 분야가 교차하는 지점에 있습니다.

- **컴퓨터 과학 / IT (Computer Science / IT):** 데이터 수집, 저장, 처리, 소프트웨어 개발.
- **수학 / 통계 (Math & Statistics):** 모델링, 가설 검증, 예측의 수학적 기반.
- **도메인 지식 / 비즈니스 (Domain Knowledge):** 해당 분야(예: 천문학, 의학, 금융)에 대한 전문 지식.

주의사항

도메인 지식의 중요성

도메인 지식이 없는 데이터 과학은 "엉뚱한 문제"를 풀 위험이 큼니다.

한 천문학자가 컴퓨터 과학자에게 데이터 분석을 의뢰했습니다. 한 달 후, 컴퓨터 과학자는 "문제를 완벽히 해결했다"고 했지만, 알고 보니 그는 데이터의 의미와 천문학적 맥락을 전혀 이해하지 못해 완전히 잘못된 문제를 푼 것이었습니다.

데이터 과학은 자동차 정비소에 차를 맡기듯 문제를 던지고 끝내는 것이 아닙니다. 반드시 해당 분야의 전문가와 긴밀히 소통하며 문제 자체를 함께 정의해야 합니다.

2.4 데이터 과학의 잠재력과 위험성

데이터 과학은 강력한 도구이며, 그에 따른 잠재력과 위험성을 동시에 가집니다.

데이터 과학의 잠재력

- 질병 진단: 혈액 도말 샘플 이미지로 말라리아 감염 여부 진단.
- 신약 개발: 언어 모델(LM)을 활용하여 새로운 약물 조합 발견.
- 생성형 AI (Generative AI): 텍스트 프롬프트(예: "안경 쓴 그리스인 교수")로부터 이미지 생성.
- 자율 주행: 야간에도 안전하게 운행하는 자율주행 트럭.

데이터 과학의 위험성과 윤리

- 성별 편향 (Gender Bias): 특정 직군(예: 엔지니어) 채용 모델이 남성 지원자에게 유리하게 작동.
- 인종 편향 (Racial Bias): 미국 법원에서 사용되는 재범 위험도 예측 모델이 유색인종에게 불리하게 편향됨.

이러한 위험성 때문에 우리는 데이터 과학을 맹목적으로 사용해서는 안 되며, 항상 비판적 사고(Critical Thinking)를 견지하고 모델의 공정성과 윤리성을 점검해야 합니다.

3 데이터 과학의 5단계 프로세스

데이터 과학 프로젝트는 일반적으로 다음 5단계를 순환하며 진행됩니다.

1. 흥미로운 질문하기 (Ask an interesting question)

- 가장 중요하고 첫 번째 단계입니다. "데이터가 있으니 뭔가 찾아봐"가 아니라, 명확한 가설이나 과학적 목표를 설정해야 합니다.
- (예: "우리가 예측/추정하려는 것은 무엇인가?", "모든 데이터가 있다면 무엇을 할 것인가?")

2. 데이터 획득하기 (Get the Data)

- 질문에 답하기 위해 필요한 데이터를 수집합니다.
- (예: "데이터는 어떻게 샘플링되었는가?", "어떤 데이터가 관련 있는가?", "라이선스나 개인정보 보호 문제는 없는가?")

3. 데이터 탐색하기 (Explore the Data - EDA)

- 데이터를 시각화하고 요약하며 패턴을 찾습니다. 이 단계에서 많은 시간을 절약할 수 있습니다. (때로는 이 단계만으로도 충분한 답을 얻기도 합니다.)
- (예: "데이터를 플롯팅해 보았는가?", "이상치(anomaly)나 심각한 오류는 없는가?", "어떤 패턴이 보이는가?")

4. 데이터 모델링하기 (Model the Data)

- 데이터의 패턴을 학습하거나 미래를 예측하는 통계/머신러닝 모델을 구축합니다.
- (예: "모델 구축 (Build) -> 모델 학습 (Fit) -> 모델 검증 (Validate)")

5. 결과 전달/시각화하기 (Communicate/Visualize the Results)

- 분석 결과를 비전문가도 이해할 수 있도록 스토리텔링과 시각화를 통해 전달합니다.
- (예: "우리는 무엇을 배웠는가?", "결과가 말이 되는가(make sense)?", "효과적으로 스토리를 전달할 수 있는가?")

4 CS109A 과정 상세 안내

4.1 교수진 및 조교(TAs)

- **Pavlos Protopapas**: 데이터 과학 석사 과정의 Scientific Director. 천문학과 머신러닝 연구를 수행하며, 요리 자격증을 보유하고 있습니다.
- **Kevin Rader**: 통계학과 선임 지도교수(Senior Preceptor). 학부 교육을 담당하며, 스포츠 및 의학 분야 데이터 분석에 관심이 많습니다. (필라델피아 이글스 팬 - "Go Birds!")
- **Chris Gumb**: 지도교수(Preceptor). 약 30명에 달하는 TF 팀을 조율하고 과정 운영을 지원합니다.
- **Teaching Fellows (TFs)**: 약 30명의 TF가 섹션(실습)과 오피스 아워를 담당합니다.

4.2 학습 철학: "Wax on, Wax off"

□ 예제:

영화 <베스트 키드>에서 미야기 사부는 제자에게 가라데 대신 자동차 왁스 칠(Wax on, Wax off)만 반복시킵니다. 제자는 불평하지만, 이 무의미해 보이는 반복 작업이 실제 대련에서 방어 동작의 완벽한 기초가 되었음을 깨닫습니다.

CS109A도 마찬가지입니다. 데이터 탐색, 모델 학습, 검증 등 기본적인 절차를 반복 숙달시키는 과제가 많을 것입니다. 이는 단순히 코드를 'fit()'시키는 것을 넘어, 모델이 내부에서 어떻게 작동하는지, 왜 그렇게 작동하는지를 깊이 이해하기 위한 필수 과정입니다.

4.3 학습 도구

본 과정은 두 가지 주요 플랫폼을 사용합니다.

- **Edstem**: 강의 슬라이드, 섹션(실습) 자료, 공지사항, 토론 포럼(Q&A)이 이루어지는 메인 허브입니다.
- **Canvas**: 강의 비디오 녹화본, 과제 제출, 공식 일정, 성적 확인에 사용됩니다.

4.4 도움 받는 방법 (How to get help)

문제가 생겼을 때 다음 순서로 도움을 요청하세요.

1. **Edstem (토론 포럼)**: 가장 빠른 방법. 동료 학생이나 TF가 답변해줍니다. (개인적인 내용 제외)
2. **오피스 아워 (Office Hours)**: 개념 이해나 과제에 대한 심층적인 도움이 필요할 때 가장 좋은 방법입니다.
3. **과정 헬프라인 (Email)**: 수강 변경 등 개인적인 행정 문의.
4. **교수진 (Email)**: 매우 사적인 문제나 민감한 사안.

5 평가 및 주요 정책

5.1 5대 평가요소 및 비중

학생 평가는 5가지 요소를 합산하여 이루어집니다.

Table 1: CS109A 평가 요소 및 비중

평가 요소	비중	세부 내용
숙제 (Homework)	30%	HW0 (1%) + HW 1-5 (29%). 2인 1조(Pair) 작업 권장.
섹션 퀴즈	10%	섹션(실습) 시간 중 실시하는 30분 분량의 퀴즈 2회.
중간고사 (Midterm)	18%	섹션 시간 중 치르는 개념 파트 + 별도의 코딩 파트(Take-home)로 구성.
기말고사 (Final Exam)	22%	3시간 동안 지정된 좌석에서 치르는 시험. (개념 + 코딩)
프로젝트 (Project)	20%	3-5인 1조의 그룹 프로젝트. 공개된(public) 데이터를 활용하여 주제 제안 가능.

5.2 숙제(Homework) 상세

- **HW 0:** 과정 시작 시 배포되며, 선수과목(Prerequisites) 충족 여부를 스스로 진단하기 위한 목적입니다. (성실히 제출 시 1)
- **HW 1-5:** 2인 1조(Pair)로 제출하는 것을 적극 권장합니다.
- 제출 기한: (별도 공지 없는 한) 매주 화요일 오후 10시.

5.3 선수과목 (Prerequisites) 진단

HW0는 다음 3가지 영역에 대한 준비 상태를 점검합니다.

- 파이썬 (Python) 코딩:
 - (필수) 프로그래밍 경험이 전혀 없다면 이 과정을 수강하기 매우 어렵습니다.
 - (괜찮음) 파이썬에 능숙하지 않더라도, 다른 언어(예: CS50 수강) 경험이 있다면 따라올 수 있습니다.
- 기초 수학 (Calculus): 기본적인 미적분 지식이 필요합니다. (예: Math 1B 수준)
- 기초 통계/확률 (Stats/Probability):
 - Stat 104 (데이터 분석 중심) 수강생이 가장 이상적입니다.
 - Stat 110 (수학적 확률론 중심)도 좋지만, 실제 데이터를 다루는 부분은 본 과정에서 새로 배워야 할 수 있습니다.
- 결론: 수학/통계 지식의 공백은 TF와 교수진의 도움으로 메울 수 있지만, 코딩 경험의 부재는 심각한 장애물이 될 수 있습니다.

5.4 출석 및 지각 정책

주의사항

CS109A 출석 정책은 매우 중요하며 성적에 직접적인 영향을 미칩니다.

- 출석은 필수입니다 (On-campus 학생): 모든 강의와 섹션은 출석이 요구됩니다.
- 성적 등급 자격 (Qualification): 출석률은 받을 수 있는 최고 성적을 제한하는 "자격" 요건입니다. (이 출석률을 만족한다고 해당 성적을 보장하는 것은 아닙니다.)
 - A 등급을 받으려면 → 최소 66% (2/3) 출석 필요
 - A- 등급을 받으려면 → 최소 50% (1/2) 출석 필요
 - B+ 등급을 받으려면 → 최소 33% (1/3) 출석 필요
- 지각 제출권 (Late Days) 획득:
- 출석(강의 또는 섹션) 4회당 1개의 지각 제출권(Late Day)을 획득합니다.
- (예: 24회 출석 시 6개의 Late Day 획득)
- DCE 학생은 출석 확인이 어려운 점을 감안하여 자동으로 4개의 Late Day가 부여됩니다.
- Late Day 사용:
- 획득한 Late Day는 숙제(HW) 제출 시 사용할 수 있습니다.
- 한 숙제당 최대 2개의 Late Day만 사용할 수 있습니다.

6 실습 (Section 1): 웹 스크레이핑 입문

6.1 웹 스크레이핑이란?

웹 스크레이핑(Web Scraping)은 웹사이트에서 프로그래밍 방식을 통해 자동으로 데이터를 추출하고 수집하는 기술입니다.

첫 번째 실습과 숙제(HW1)는 이 기술을 사용하여 노벨상(Nobel Prize) 웹사이트에서 데이터를 수집하는 것을 목표로 합니다.

6.2 실습 라이브러리

- **requests**: 웹사이트에 접속하여 원본 HTML 코드를 가져오는 라이브러리. (HTTP 요청)
- **BeautifulSoup**: 가져온 HTML 코드를 파이썬이 다루기 쉬운 객체 구조로 변환(Parsing)하고, 원하는 정보를 쉽게 찾도록 도와주는 라이브러리.
- **pandas**: 추출한 데이터를 표(DataFrame) 형태로 정리하고 분석하는 라이브러리.
- **matplotlib**: 데이터를 시각화하는 라이브러리.

6.3 1단계: 웹 스크레이핑 윤리 및 규칙 확인

주의사항

모든 웹사이트가 데이터 수집을 허용하는 것은 아닙니다.

- **robots.txt 확인**: 웹사이트 도메인 뒤에 `/robots.txt`를 붙여(예: `google.com/robots.txt`) 어떤 페이지의 수집을 허용/금지하는지 확인해야 합니다.
- **과도한 요청 금지 (Rate Limit)**: 서버에 부담을 주지 않도록 짧은 시간에 너무 많은 요청을 보내지 않아야 합니다. (예: "1분에 500회 요청 제한")

6.4 2단계: HTML 기초와 브라우저 '검사' 도구

웹사이트는 HTML(HyperText Markup Language)이라는 언어로 구성됩니다.

- **요소 (Element)**: `<tag>`로 시작하여 `</tag>`로 끝나는 전체 구조.
- **태그 (Tag)**: 요소의 종류를 정의합니다. (예: `<h1>`(제목), `<p>`(문단), `<a>`(링크), `<div>`(구역))
- **속성 (Attribute)**: 태그에 추가 정보를 제공합니다. (예: `<a href="..." >`(링크 주소), `<div class="..." >`(요소의 별명))

□ 예제:

브라우저 '검사' 도구 활용하기

웹사이트에서 원하는 정보(예: 수상자 이름)가 어떤 태그와 클래스(class)로 구성되어 있는지 확인하는 가장 쉬운 방법입니다.

1. 웹페이지에서 원하는 부분에 마우스 오른쪽 클릭
2. '검사(Inspect)' 메뉴 선택
3. 개발자 도구가 열리면, 왼쪽 상단의 '선택 도구(Picker Tool)' 아이콘(화살표 모양)을 클릭

4. 페이지에서 원하는 요소를 클릭하면, 해당 요소의 HTML 코드가 하이라이트됩니다.

6.5 3단계: requests로 데이터 가져오기

먼저 웹사이트의 HTML 소스 코드를 가져와야 합니다.

```

1 import requests
2
3 # 1. 수집할웹사이트 URL
4 url = "https://www.nobelprize.org/all-nobel-prizes/"
5
6 # 2. HTTP GET 요청보내기
7 response = requests.get(url)
8
9 # 3. 상태코드확인이면 (200 성공)
10 print(f"상태 코드: {response.status_code}")
11
12 # 4. HTML 텍스트내용확인일부만 ()
13 html_text = response.text
14 print(html_text[:200])

```

Listing 1: requests를 사용한 HTML 코드 요청

- **Status Code 200:** 요청이 성공적으로 완료되었음을 의미합니다. (OK)
- **Status Code 404:** 해당 URL을 찾을 수 없음을 의미합니다. (Not Found)

6.6 4단계: BeautifulSoup로 HTML 파싱하기

`response.text`는 다루기 힘든 거대한 문자열입니다. 이를 BeautifulSoup를 이용해 "수프(soup)" 객체로 만듭니다.

```

1 from bs4 import BeautifulSoup
2
3 # 1. 'html.parser'를 이용해 html_text soup 객체로변환
4 soup = BeautifulSoup(html_text, 'html.parser')
5
6 # 2. 원하는정보찾기에 (: 페이지제목 )
7 page_title = soup.title.get_text()
8 print(f"페이지 제목: {page_title}")
9
10 # 3. CSS 선택자(Selector)로 특정요소찾기
11 # 예 (: 클래스가 'card-prize인' 모든 div 요소)
12 prize_blocks = soup.select('div.card-prize')
13 print(f"총 수상블록개수 : {len(prize_blocks)}")
14
15 # 4. 첫번째블록에서텍스트만추출공백 ( 제거)
16 first_block = prize_blocks[0]
17 block_text = first_block.get_text().strip()
18 print(block_text)

```

Listing 2: BeautifulSoup로 HTML 파싱하기

6.7 5단계: 데이터 추출 및 구조화 (노벨상 예제)

여러 개의 수상 블록(prize_blocks)을 순회하며 원하는 정보를 추출하여 리스트와 딕셔너리로 저장합니다.

```

1 import re # 정규표현식 (Regular Expression) 라이브러리
2 from collections import defaultdict, Counter
3
4 # 1. 람다(lambda)를 이용한간단한헬퍼함수정의
5 get_title = lambda block: block.select_one('h3').get_text().strip()
6 get_year = lambda block: re.search(r'(\d{4})', block.select_one('h3').get_text
7     ()).group(1)
8 get_description = lambda block: block.select_one('blockquote').get_text().
9     strip()
10
11 # 2. 데이터를저장할리스트
12 nobel_data = []
13
14 # 3. 모든수상블록을순회 (loop)
15 for block in prize_blocks:
16     try:
17         title = get_title(block)
18         year = get_year(block)
19         description = get_description(block)
20
21         # 4. 딕셔너리형태로저장
22         nobel_data.append({
23             'title': title,
24             'year': int(year),
25             'description': description
26         })
27     except Exception as e:
28         print(f"데이터 추출중오류발생 : {e}")
29
30 # 5. 예제 () 고유한수상분야찾기
31 unique_titles = set(item['title'] for item in nobel_data)
32 print(f"고유 수상분야 : {unique_titles}")
33
34 # 6. 예제 () 경제학상이처음수여된연도찾기
35 econ_years = [item['year'] for item in nobel_data if 'Economic Sciences' in
36     item['title']]
37 first_econ_year = min(econ_years)
38 print(f"경제학상 최초수여연도 : {first_econ_year}")
39
40 # 7. 예제 () 연도별수상자수집계 (defaultdict 사용)
41 winners_per_year = defaultdict(int)

```

```

39 for item in nobel_data:
40     winners_per_year[item['year']] += 1 # 으로 0 자동초기화됨
41 print(f"년2023 수상자수 : {winners_per_year[2023]}")

```

Listing 3: 반복문을 통한 데이터 추출 및 구조화

6.8 6단계: pandas로 데이터 프레임 변환

스크레이핑한 데이터(딕셔너리 리스트)는 pandas의 DataFrame으로 변환하면 분석하기 매우 용이합니다.

```

1 import pandas as pd
2
3 # 1. 리스트를데이터프레임으로변환
4 df = pd.DataFrame(nobel_data)
5
6 # 2. 데이터프레임상위개 5 확인
7 print(df.head())
8
9 # 3. CSV 파일로저장
10 df.to_csv('nobel_prizes.csv', index=False)

```

Listing 4: pandas DataFrame으로 변환 및 저장

6.9 (심화) 비동기(Async) 스크레이핑

수백, 수천 개의 페이지를 스크레이핑할 때는 한 번에 하나씩 요청하면 매우 느립니다.

비동기(Asynchronous) 프로그래밍 (예: asyncio, httpx 라이브러리)은 여러 개의 요청을 동시에 처리하여 속도를 높이는 고급 기법입니다.

이는 서버의 "Rate Limit"(요청 제한)을 존중하면서도 효율적으로 데이터를 수집하기 위해 사용됩니다. (예: "1초에 5개씩" 또는 "한 번에 10개씩 묶어서(batch) 요청")

7 자주 묻는 질문 (FAQ)

- Q: 이 수업을 청강(Audit)할 수 있나요?
- A: 네, 가능합니다. 다만 청강으로 수강한 경우, 나중에 동일 과목을 학점 이수(for grade)로 다시 수강할 수 없습니다.
- Q: 비동기(Asynchronous) 방식(녹화본 시청)으로만 수강할 수 있나요?
- A: (대학생) 허용되지 않습니다. (대학원생) 권장하지 않습니다. 출석은 이 수업의 매우 중요한 부분이며, 출석률이 33% 미만일 경우 B+ 이상의 성적을 받을 자격이 박탈됩니다.
- Q: 선수과목이 부족한데 수강할 수 있을까요?
- A: HW0를 풀어보고 판단하세요. 수학/통계 지식은 도움을 받아 채울 수 있지만, 프로그래밍(코딩) 경험이 전혀 없다면 수강을 다음 학기로 미루는 것을 강력히 권장합니다.
- Q: 중간고사 기간에 여행 계획이 있습니다. 시험을 일찍 보거나 미룰 수 있나요?
- A: 아니요. 중간고사(10/22-24주간)와 기말고사(12/11 예정)는 지정된 날짜에만 치러야 합니다. 일정을 미리 확인하세요.
- Q: 제가 가진 개인 프로젝트 아이디어를 사용해도 되나요?
- A: 네, 가능합니다. 단, 데이터가 공개(public)되어 있어야 하며, 3-5명의 그룹 프로젝트로 진행해야 합니다.