

February 2, 2026

- 강의명: CS109A: 데이터 과학 입문
- 주차: Lecture 11
- 교수명: Pavlos Protopapas, Kevin Rader, Chris Gumb
- 목적: Lecture 11의 핵심 개념 학습

Contents

1	베이지안 용어 정리	1
2	베이지안 추론이란 무엇인가?	3
2.1	1. 빈도주의 (Frequentist) 관점	3
2.2	2. 베이지안 (Bayesian) 관점	3
3	베이즈 정리: 믿음을 업데이트하는 공식	5
4	사전분포(Prior) 선택하기	7
4.1	1. 정보적 사전분포 (Informative Prior)	7
4.2	2. 비정보적 사전분포 (Uninformative Prior)	7
4.3	3. 켄레 사전분포 (Conjugate Prior)	7
5	핵심 예제: 정규-정규 모델 (Normal-Normal Model)	9
6	베이지안 추정: 점과 구간	9
6.1	점 추정 (Point Estimation)	9
6.2	구간 추정 (Interval Estimation)	10
7	베이지안 선형 회귀 (Bayesian Linear Regression)	11
8	심화: 릿지(Ridge)와 라쏘(Lasso)의 베이지안 해석	12
8.1	1. 릿지(Ridge) = MAP + 정규(Normal) 사전분포	12
8.2	2. 라쏘(Lasso) = MAP + 라플라스(Laplace) 사전분포	13
9	계산 방법: MCMC와 깁스 샘플링	14
9.1	문제: 사후 분포가 너무 복잡할 때	14
9.2	해결: 시뮬레이션 (MCMC)	14
9.3	깁스 샘플링 (Gibbs Sampling)	14

10 자주 묻는 질문 (FAQ) 및 점검	16
11 빠르게 훑어보기 (1-Page Summary)	16

□ 핵심 요약

이 문서는 베이시안(Bayesian) 모델링의 핵심 개념을 설명합니다.

베이시안 추론은 데이터(증거)를 바탕으로 기존의 믿음(사전 확률)을 업데이트하여, 더 합리적인 새로운 믿음(사후 확률)을 도출하는 과정입니다.

단 하나의 '정답'을 찾는 대신, 파라미터의 '가능성'을 확률 분포로 표현합니다.

이 문서를 통해 베이지 정리, 기본 원리를 이해하고, 이것이 어떻게 릿지(Ridge), 라쏘(Lasso)와 같은 머신러닝 회귀 모델과 연결되는지 학습합니다.

1 베이시안 용어 정리

베이시안 모델링을 처음 접할 때 가장 혼란스러운 것은 용어입니다. 핵심 용어들을 일상적인 언어로 먼저 정리합니다.

용어	쉬운 설명 (직관)	원어	비고
베이지 정리	나의 '기존 믿음'과 '새로운 증거'를 합쳐 '최종 결론'을 내는 수학 공식	Bayes' Rule / Theorem	$P(A B) = \frac{P(B A)P(A)}{P(B)}$
사전 확률	데이터를 보기 전, 내가 이미 가지고 있던 믿음 (가설)	Prior Probability	$P(A)$
가능도	나의 '믿음'이 맞다고 가정할 때, 이 '증거'가 나타날 확률	Likelihood	$P(B A)$
사후 확률	'증거'를 반영하여 새롭게 업데이트 된 '최종 믿음' (결론)	Posterior Probability	$P(A B)$
증거	그냥 '증거'가 관찰될 확률 (전체 확률). 주로 정규화 상수로 쓰임.	Evidence / Marginal	$P(B)$
빈도주의	파라미터(예: 평균)는 '고정된 값'이며, 데이터가 무작위라고 보는 관점.	Frequentist	베이시안과 대비되는 통계학의 주류 관점.
베이시안	파라미터 자체를 '확률 변수' (믿음의 대상)로 보는 관점.	Bayesian	주관적 확률(belief)을 다룸.
초매개변수	'사전 확률'을 정의하기 위해 필요한 또 다른 파라미터. (예: $\mu \sim N(\mu_0, \sigma_0^2)$ 에서 μ_0, σ_0^2)	Hyperparameter	Prior의 파라미터.
결합 사전분포	계산을 편하게 해주는 '특수 조합'. (예: 이항-베타, 정규-정규)	Conjugate Prior	특정 가능도와 결합 시, 사후 분포가 사전 분포와 '같은 가족'이 됨.
MAP	사후 확률 분포에서 '가장 높은 지점 (최빈값)'을 추정치로 사용.	Max A Posteriori	사후 확률을 최대화하는 파라미터.
신용 구간	"파라미터가 이 구간 안에 있을 확률이 95%다." (매우 직관적)	Credible Interval	베이시안 버전의 구간 추정.
신뢰 구간	"같은 실험 100번 시, 95개의 구간이 '참 값'을 포함할 것이다."	Confidence Interval	빈도주의 버전의 구간 추정. (해석이 까다로움)

2 베이저안 추론이란 무엇인가?

통계학에는 세상을 바라보는 두 가지 큰 관점이 있습니다: 빈도주의(Frequentist)와 베이저안(Bayesian)입니다.

2.1 1. 빈도주의 (Frequentist) 관점

빈도주의는 우리가 흔히 배우는 전통적인 통계학입니다.

* **핵심 가정:** 우리가 찾으려는 파라미터(모수, θ , 예: 전교생의 실제 평균 키)는 하나의 '고정된' 상수입니다. * **데이터:** 이 '참 값'을 알기 위해 우리가 뽑는 표본(데이터, X)이 무작위(random)입니다. * **목표:** 데이터를 많이 뽑아서 저 '고정된 참 값'(θ)을 정확히 추정(estimate)하는 것입니다.

□ 예제: 빈도주의 비유: 고정된 보물 찾기

어딘가에 하나의 '보물'(θ)이 숨겨져 있습니다.

우리는 이 보물의 위치를 모르지만, 보물에 대한 힌트(X , 데이터)를 여러 번 얻을 수 있습니다.

빈도주의는 이 힌트(데이터)들을 조합하여 "보물은 (x, y) 지점에 있을 것이다"라고 하나의 지점을 추정하는 방식입니다.

2.2 2. 베이저안 (Bayesian) 관점

베이저안 통계학은 '믿음(belief)'의 관점에서 접근합니다.

* **핵심 가정:** 우리가 가진 데이터(X)는 '고정된' 관찰 값입니다. (일단 관찰했으므로) * **파라미터:** 오히려 우리가 모르는 파라미터(θ)가 무작위(random)이며, 확률 분포를 가집니다. * **목표:** 데이터(X)를 관찰함으로써, 파라미터 θ 에 대한 우리의 믿음(belief)을 업데이트하는 것입니다.

□ 예제: 베이저안 비유: 확률적인 보물 지도

베이저안은 보물이 "어디쯤 있을지"에 대한 '믿음의 지도'(사전 확률)로 시작합니다. (예: "A 지역 60%, B 지역 40%")

이때 힌트(X , 데이터)를 하나 얻습니다. (예: "보물은 강 근처에 있다.")

이 힌트를 바탕으로, "A 지역이 강 근처일 확률"과 "B 지역이 강 근처일 확률"을 계산하여, 원래의 믿음을 업데이트한 '새로운 지도'(사후 확률)를 만듭니다. (예: "A 지역 80%, B 지역 20%")

colback=mygray, colframe=darkgray, breakable, title=□ 빈도주의 vs. 베이저안 핵심 비교

- 빈도주의 (Frequentist):

- 파라미터 (θ): 고정된 상수 (Unknown constant)
- 데이터 (X): 랜덤 변수 (Random variable)
- 해석: "무한히 반복하면, 95%의 신뢰 구간이 참 값을 포함한다."

- 베이저안 (Bayesian):

- 파라미터 (θ): 랜덤 변수 (Random variable)
- 데이터 (X): 고정된 관찰 값 (Fixed data)
- 해석: "우리의 데이터에 따르면, 95% 확률로 파라미터가 이 신용 구간 안에 있다."

베이저안의 '신용 구간'이 우리가 일상적으로 "확률"을 이해하는 방식과 더 가깝습니다.

3 베이즈 정리: 믿음을 업데이트하는 공식

베이저안 추론은 베이즈 정리(Bayes' Rule)라는 하나의 공식에서 출발합니다.

$$P(\theta|X) = \frac{P(X|\theta)P(\theta)}{P(X)}$$

이 공식의 각 항은 다음과 같은 의미를 가집니다.

- $P(\theta|X)$: 사후 확률 (Posterior)
 - "데이터 X 를 관찰한 후에, 파라미터 θ 에 대한 우리의 최종 믿음"
 - 이것이 우리가 구하고자 하는 결과물입니다.
- $P(X|\theta)$: 가능도 (Likelihood)
 - "파라미터 θ 가 참이라고 가정할 때, 데이터 X 가 관찰될 가능성"
 - 이것은 우리가 가진 데이터로부터 계산되는 증거의 힘입니다.
- $P(\theta)$: 사전 확률 (Prior)
 - "데이터 X 를 관찰하기 전에, 파라미터 θ 에 대해 우리가 가졌던 초기 믿음"
 - 이것은 우리의 주관적인 지식이나 가정입니다.
- $P(X)$: 증거 (Evidence)
 - "그냥 데이터 X 가 관찰될 전체 확률"
 - 실제 계산에서는 θ 와 관련이 없으므로, $P(\theta|X)$ 의 합이 1이 되도록 만드는 정규화 상수(Normalizing Constant) 역할을 합니다.

따라서 베이즈 정리는 다음과 같이 요약할 수 있습니다.

□ 핵심 요약

사후 확률 (최종 믿음) $\propto$ 가능도 (증거의 힘) $\times$ 사전 확률 (초기 믿음)

$$f(\theta|X) \propto f(X|\theta)f(\theta)$$

□ 예제: 동전 뒤집기 예제 (이산 확률)

주머니 속에 3개의 동전이 있습니다:

- 동전 A: 앞면이 나올 확률 $p = 0.1$ (불량 동전)
- 동전 B: 앞면이 나올 확률 $p = 0.5$ (공정 동전)
- 동전 C: 앞면이 나올 확률 $p = 0.9$ (불량 동전)

1. **사전 확률 (Prior):** 내가 동전 하나를 무작위로 뽑았습니다. 이 동전이 A, B, C일 확률은 얼마일까요? 데이터가 없으므로, 각각 $1/3$ 입니다.

$$P(\theta = 0.1) = 1/3 \quad | \quad P(\theta = 0.5) = 1/3 \quad | \quad P(\theta = 0.9) = 1/3$$

2. **데이터 (Data):** 이 동전을 4번 던졌더니, 앞면이 3번, 뒷면이 1번 나왔습니다. ($X = 3$)

3. **가능도 (Likelihood):** 각 동전(가설)이 이 데이터를 만들어낼 가능성은 얼마일까요? (이항 분포 사용: $\binom{4}{3}p^3(1-p)^1$)

- $P(X = 3|\theta = 0.1) = \binom{4}{3}(0.1)^3(0.9)^1 = 4 \times 0.001 \times 0.9 = 0.0036$
- $P(X = 3|\theta = 0.5) = \binom{4}{3}(0.5)^3(0.5)^1 = 4 \times 0.125 \times 0.5 = 0.2500$
- $P(X = 3|\theta = 0.9) = \binom{4}{3}(0.9)^3(0.1)^1 = 4 \times 0.729 \times 0.1 = 0.2916$

데이터는 동전 C ($p = 0.9$) 일 가능성을 가장 높게 시사합니다.

4. 사후 확률 (Posterior): 이제 $Posterior \propto Likelihood \times Prior$ 를 계산합니다.

- $P(\theta = 0.1|X = 3) \propto 0.0036 \times (1/3) \approx 0.0012$
- $P(\theta = 0.5|X = 3) \propto 0.2500 \times (1/3) \approx 0.0833$
- $P(\theta = 0.9|X = 3) \propto 0.2916 \times (1/3) \approx 0.0972$

5. 정규화 (Normalize): 사후 확률의 총합($0.0012 + 0.0833 + 0.0972 = 0.1817$)으로 나누어 합이 1 이 되게 합니다.

- $P(\theta = 0.1|X = 3) = 0.0012/0.1817 \approx \mathbf{0.7\%}$
- $P(\theta = 0.5|X = 3) = 0.0833/0.1817 \approx \mathbf{45.8\%}$
- $P(\theta = 0.9|X = 3) = 0.0972/0.1817 \approx \mathbf{53.5\%}$

결론: 데이터를 보기 전 우리의 믿음은 (33%, 33%, 33%)였지만, "4번 중 3번 앞면"이라는 데이터를 본 후, 우리의 믿음은 (0.7%, 45.8%, 53.5%)로 업데이트되었습니다. 우리는 이제 이 동전이 $p = 0.9$ 동전(C) 이라고 가장 강하게 믿게 되었습니다.

4 사전분포(Prior) 선택하기

베이지안 모델링의 가장 중요하고 주관적인 부분이 바로 **사전분포(Prior, $f(\theta)$)**를 정하는 것입니다. 사전분포는 "내가 데이터를 보기 전에 파라미터에 대해 무엇을 알고 있는가?"를 확률 분포로 표현하는 것입니다. 사전분포를 선택하는 3가지 주요 접근 방식이 있습니다.

4.1 1. 정보적 사전분포 (Informative Prior)

이전 연구, 전문가의 의견, 또는 과거의 데이터를 바탕으로 '정보가 있는' 사전분포를 설정합니다.

* **목적:** 이미 알고 있는 지식을 모델에 적극적으로 반영합니다. * **예시:** * 내일 정오의 기온(μ)을 예측하는 모델을 만든다고 가정합니다. * **사전분포:** "어제 정오 기온이 20도였고, 최근 30일간 일교차 표준편차가 2도였다"는 정보를 바탕으로, * $\mu \sim N(\mu_0 = 20, \sigma_0^2 = 2^2)$ 처럼 정규분포를 설정할 수 있습니다. * 이는 "내일 기온도 20도 근처일 것이고, 95% 확률로 16도에서 24도 사이일 것이다"라는 **강한 믿음**을 표현합니다.

4.2 2. 비정보적 사전분포 (Uninformative Prior)

파라미터에 대해 아는 것이 거의 없거나, 의도적으로 데이터의 영향력을 극대화하고 싶을 때 사용합니다. "최소한의 정보"를 제공하는 사전분포입니다.

* **목적:** 사전 지식의 영향을 최소화하고, 데이터(X)가 사후 분포를 거의 결정하도록 만듭니다. * **예시:** * 새로운 치료법의 성공 확률 p (0에서 1 사이)를 모델링합니다. * **사전분포:** p 에 대해 아는 것이 전혀 없으므로, 0과 1 사이의 모든 값이 동일하게 가능하다고 가정합니다. * $p \sim \text{Uniform}(0, 1)$ (0과 1 사이의 균등 분포) * 이는 "모든 확률값이 공평하다"는 **약한 믿음**을 표현합니다.

4.3 3. 켈레 사전분포 (Conjugate Prior)

수학적, 계산적 편의성을 위해 특정 '궁합이 잘 맞는' 사전분포-가능도 조합을 사용하는 것입니다.

* **정의:** 어떤 가능도 함수 $f(X|\theta)$ 에 대해, 특정 사전분포 $f(\theta)$ 를 사용했더니, 그 결과물인 사후분포 $f(\theta|X)$ 가 사전분포와 **동일한 분포 가족(family)**이 되는 경우, 이 사전분포를 '켈레 사전분포'라고 부릅니다. * **비유:** "파란색 물감(Prior) + 노란색 물감(Likelihood) = 초록색 물감(Posterior)" 켈레 관계는 '파란색 + 노란색 = 초록색'이라는 공식을 아는 것과 같습니다. 만약 켈레가 아니면, "파란색 + 분홍색 = ???" 처럼, 그 결과를 한눈에 알 수 없고 계산이 복잡해집니다. * **왜 사용하는가?** 복잡한 적분 계산 ($P(X) = \int f(X|\theta)f(\theta)d\theta$)을 피하고, 사후 분포의 파라미터를 간단한 공식으로 바로 유도할 수 있게 해줍니다.

colback=mygray, colframe=darkgray, breakable, title= □ 주요 켄레 사전분포 조합

가능도 (데이터)	파라미터	켄레 사전분포	→ 사후 분포
Binomial (이항)	p (성공 확률)	Beta (베타)	→ Beta (베타)
Poisson (푸아송)	λ (비율)	Gamma (감마)	→ Gamma (감마)
Normal (정규)	μ (평균)	Normal (정규)	→ Normal (정규)
Normal (정규)	$1/\sigma^2$ (정밀도)	Gamma (감마)	→ Gamma (감마)
Exponential (지수)	λ (비율)	Gamma (감마)	→ Gamma (감마)

5 핵심 예제: 정규-정규 모델 (Normal-Normal Model)

베이지안 추론의 가장 기본이 되는 "정규-정규" 모델을 통해 사전-사후 분석이 어떻게 작동하는지 살펴봅시다. 이는 "데이터(가능도)도 정규분포를 따르고, 파라미터(사전분포)도 정규분포를 따른다"는 의미입니다.

문제 설정:

- **가능도 (데이터):** $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ (우리가 관찰한 데이터는 평균이 μ 이고 분산이 σ^2 인 정규분포에서 나왔다.)
- **가정:** σ^2 (데이터의 분산)는 이미 알고 있다고 가정합니다.
- **파라미터:** μ (데이터의 평균)는 모른다.
- **사전분포 (초기 믿음):** μ 역시 정규분포를 따를 것이라고 가정합니다. $\mu \sim N(\mu_0, \sigma_0^2)$ (여기서 μ_0 는 '사전 평균', σ_0^2 는 '사전 분산'이며, 둘 다 **초매개변수 (Hyperparameter)** 입니다.)

결과 (사후 분포): 켈레 관계에 의해, 사후 분포 $f(\mu|X)$ 역시 정규분포가 됩니다! $f(\mu|X) \sim N(\mu_n, \sigma_n^2)$

이때 업데이트된 사후 평균(μ_n)과 사후 분산(σ_n^2)은 다음과 같습니다.

$$\mu_n = \frac{\sigma^2 \mu_0 + n \sigma_0^2 \bar{X}}{\sigma^2 + n \sigma_0^2} \quad | \quad \sigma_n^2 = \frac{\sigma^2 \sigma_0^2}{\sigma^2 + n \sigma_0^2}$$

□ 핵심 요약

정규-정규 모델의 직관적 해석

위 공식은 복잡해 보이지만, 매우 중요한 직관을 담고 있습니다.

1. **사후 평균(μ_n) = "사전 믿음과 데이터의 가중 평균"** * μ_n 은 사전 평균(μ_0)과 데이터 평균($\bar{X}$)의 가중 평균입니다. * 데이터가 많아지면 ($n \rightarrow \infty$)? 분자의 $n \sigma_0^2 \bar{X}$ 항이 압도적으로 커집니다. μ_n 은 $\bar{X}$ (데이터 평균)에 수렴합니다. **결론: 충분한 데이터는 결국 사전 믿음을 이깁니다.** * 사전 믿음이 매우 강하면 ($\sigma_0^2 \rightarrow 0$)? "나의 초기 믿음 μ_0 는 절대 틀리지 않아!" (분산=0) μ_n 은 μ_0 (사전 평균)에 수렴합니다. 데이터($\bar{X}$)는 무시됩니다. * 사전 믿음이 매우 약하면 ($\sigma_0^2 \rightarrow \infty$)? "나는 아무것도 몰라!" (분산=무한대) μ_n 은 $\bar{X}$ (데이터 평균)에 수렴합니다.
2. **사후 분산(σ_n^2) = "데이터가 많을수록 확신이 커진다"** * σ_n^2 의 분모에 $n \sigma_0^2$ 항이 있습니다. * 데이터가 많아질수록 ($n \rightarrow \infty$), 분모가 커져서 σ_n^2 는 0에 수렴합니다. * **결론: 데이터를 더 많이 관찰할수록, 우리의 사후 믿음(추정)은 더욱 확실해집니다. (분산 감소)**

6 베이지안 추정: 점과 구간

사후 분포 $f(\theta|X)$ 는 파라미터 θ 에 대한 우리의 최종 믿음을 나타내는 '분포'입니다. 하지만 종종 보고를 위해 하나의 '값'(점 추정)이나 '구간'(구간 추정)이 필요합니다.

6.1 점 추정 (Point Estimation)

사후 분포(PDF)를 대표하는 하나의 값을 뽑는 방법입니다.

- **사후 평균 (Posterior Mean):** $E[\theta|X]$. 사후 분포의 기댓값(평균)을 사용합니다.
- **사후 최빈값 (Posterior Mode, MAP):** $\operatorname{argmax}_{\theta} f(\theta|X)$. 사후 분포에서 확률 밀도가 가장 높은 지점

(가장 높은 봉우리)을 사용합니다. 이를 **MAP (Maximum A Posteriori)** 추정이라고 부릅니다.

- **사후 중앙값 (Posterior Median):** 사후 분포의 50% 지점을 사용합니다.

6.2 구간 추정 (Interval Estimation)

주의사항

신용 구간 (Credible Interval) vs. 신뢰 구간 (Confidence Interval)

이 둘은 매우 다르며, 베이지안의 '신용 구간'이 훨씬 직관적입니다.

- **베이지안 95% 신용 구간 (Credible Interval)**
 - 해석: "관찰된 데이터를 바탕으로, 파라미터 θ 가 이 구간 안에 있을 확률이 95%이다."
 - 계산: 사후 분포 $f(\theta|X)$ 의 양쪽 꼬리 2.5%를 잘라내고 남은 95%의 중앙 구간.
 - 직관: 우리가 원하는 확률적 해석과 일치합니다.
- **빈도주의 95% 신뢰 구간 (Confidence Interval)**
 - 해석: "이 실험(표본 추출)을 100번 반복하면, 100개의 '신뢰 구간' 중 95개의 구간이 '고정된 참 값 θ '를 포함할 것이다."
 - 주의: 이미 계산된 하나의 신뢰 구간(예: [10, 20])을 보고 " θ 가 [10, 20] 사이에 있을 확률이 95%다"라고 말하면 틀립니다. 빈도주의에서 θ 는 고정된 값이라 확률이 없으며, 확률은 '구간'에 걸려있습니다.

7 베이저안 선형 회귀 (Bayesian Linear Regression)

이러한 베이저안 원리를 선형 회귀 모델 $y = \beta_0 + \beta_1 x + \epsilon$ 에 적용할 수 있습니다.

1. **가능도 (데이터 모델):** 선형 회귀의 기본 가정은 "오차(ϵ)가 정규분포를 따른다"는 것입니다. 이는 y 역시 x 에 따라 평균이 변하는 정규분포를 따른다는 의미입니다.

$$y_i \sim N(\mu_i, \sigma^2), \text{ 여기서 } \mu_i = \beta_0 + \beta_1 x_i$$

2. **파라미터:** 우리가 추정해야 할 파라미터는 β_0 (절편), β_1 (기울기), σ^2 (오차 분산) 입니다.

3. **사전분포 (초기 믿음):** 베이저안 접근법은 이 모든 파라미터에 사전분포를 할당합니다. (결례 사전분포를 사용한다고 가정)

* $\beta_0 \sim N(\mu_0, \sigma_0^2)$ (절편에 대한 사전 믿음) * $\beta_1 \sim N(\mu_1, \sigma_1^2)$ (기울기에 대한 사전 믿음) * $1/\sigma^2 \sim \text{Gamma}(a_0, \lambda_0)$ (오차의 정밀도(분산의 역수)에 대한 사전 믿음)

4. **사후분포 (결과):** 데이터(X, y)를 관찰하고 베이즈 정리를 적용하면, $\beta_0, \beta_1, \sigma^2$ 각각에 대한 사후 분포를 얻게 됩니다.

□ 핵심 요약

베이저안 회귀의 의미

일반 선형 회귀(빈도주의)는 $\beta_1 = 5.0$ 처럼 **하나의 값**을 추정합니다.

베이저안 회귀는 β_1 에 대한 **하나의 확률 분포**를 제공합니다. (예: " β_1 의 사후 분포는 평균이 5.0이고 표준편차가 0.5인 정규분포와 유사하다.")

이를 통해 우리는 다음과 같은 강력한 확률적 해석이 가능해집니다:

- " β_1 (기울기)가 0보다 클 확률은 99.8%이다."
- " β_1 의 95% 신용 구간은 [4.02, 5.98]이다."

□ 예제: 범주형 변수(더미 변수) 해석하기

한 강의의 수강생 그룹(4개)에 따라 숙제 시간을 예측하는 회귀 모델이 있습니다.

$$\hat{y} = 11.0 - 2.0x_{cs1090} + 3.5x_{csci_{e109}} + 5.0x_{stat109}$$

- **기준 그룹 (Reference Group):** 모델 식에 없는 그룹, 즉 ac_{209} 가 기준 그룹(Baseline)입니다.
- **절편 (Intercept = 11.0) 해석:** 모든 x 가 0일 때의 $\hat{y}$ 값입니다. 즉, 기준 그룹(ac_{209}) 학생들의 평균 숙제 시간은 11.0 시간입니다.
- **계수 (Coefficient = 5.0) 해석:** $x_{stat109}$ 의 계수 5.0은 기준 그룹(ac_{209})과의 평균 시간 '차이'를 의미합니다. " $stat_{109}$ 그룹 학생들은 ac_{209} 그룹 학생들보다 평균 5.0시간 더 많이 숙제한다." ($stat_{109}$ 의 평균 시간 = $11.0 + 5.0 = 16.0$ 시간)
- **예측 (Prediction):** $csci_{e109}$ 학생의 숙제 시간을 예측하려면, $x_{csci_{e109}} = 1$ 이고 나머지는 0을 대입합니다. $\hat{y} = 11.0 - 2.0(0) + 3.5(1) + 5.0(0) = 14.5$ 시간

8 심화: 릿지(Ridge)와 라쏘(Lasso)의 베이지안 해석

베이지안 모델링은 릿지(Ridge)와 라쏘(Lasso) 회귀가 왜 그렇게 작동하는지에 대한 강력한 직관을 제공합니다.

배경: 손실 함수 (Loss Function)

* **OLS (최소제곱법):** $\text{Loss} = \sum (y_i - \hat{y}_i)^2$ (오차의 제곱합, L_2 -loss) * **Ridge (릿지):** $\text{Loss} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2$ (오차의 제곱합 + L_2 -Penalty) * **Lasso (라쏘):** $\text{Loss} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum |\beta_j|$ (오차의 제곱합 + L_1 -Penalty)

핵심 연결 고리: MAP 추정

베이지안에서 **MAP (사후 최빈값)** 추정은 사후 확률 $f(\beta|X)$ 를 최대화하는 β 를 찾는 것입니다.

$$\hat{\beta}_{MAP} = \underset{\beta}{\operatorname{argmax}} f(\beta|X) = \underset{\beta}{\operatorname{argmax}} [f(X|\beta)f(\beta)]$$

로그(log)를 씌워도 최대화 지점은 동일합니다. (로그는 단조 증가 함수이므로)

$$\hat{\beta}_{MAP} = \underset{\beta}{\operatorname{argmax}} [\log(f(X|\beta)) + \log(f(\beta))]$$

이를 '최소화' 문제로 바꾸면, 음수(-)를 붙이면 됩니다.

$$\hat{\beta}_{MAP} = \underset{\beta}{\operatorname{argmin}} [-\log(f(X|\beta)) - \log(f(\beta))]$$

이제 이 식을 위 손실 함수들과 비교해 봅시다.

- $f(X|\beta)$ 는 $y \sim N(\beta X, \sigma^2)$ 정규분포(가능도)입니다. $-\log(f(X|\beta))$ 는 $\sum (y_i - \hat{y}_i)^2$ (오차 제곱합) 항에 비례합니다.
- $f(\beta)$ 는 β 계수들에 대한 사전분포(Prior)입니다. $-\log(f(\beta))$ 는 페널티(Penalty) 항에 비례합니다.

□ 핵심 요약

손실 함수 최소화 $\equiv$ 사후 확률 최대화 (MAP)

(OLS Loss + Penalty) $\equiv$ (로그-가능도 + 로그-사전분포)

8.1 1. 릿지(Ridge) = MAP + 정규(Normal) 사전분포

릿지의 L_2 -페널티 $\lambda \sum \beta_j^2$ 는 어떤 사전분포 $f(\beta)$ 에서 유래할까요? $-\log(f(\beta)) \propto \beta^2$ 를 만족하는 분포를 찾으면 됩니다.

이는 평균이 0인 정규분포(Gaussian Prior)입니다. $f(\beta) \propto \exp(-\frac{\beta^2}{2\sigma_p^2}) \implies -\log(f(\beta)) \propto \beta^2$

colback=myblue!5!white, colframe=myblue!75!black, title=□ 릿지(Ridge)의 베이지안 해석 릿지 회귀는 β 계수들에 대해 평균 0의 정규(Normal) 사전분포를 가정한 베이지안 회귀의 MAP 추정치와 같습니다.

직관: 이 사전분포는 " β 계수들은 0 근처에 완만하게(bell-curve) 모여있을 것이다"라고 믿습니다. 이 믿음이 계수들을 0에 가깝게 '당기지만(shrinkage)' 0으로 만들지는 않습니다.

8.2 2. 라쏘(Lasso) = MAP + 라플라스(Laplace) 사전분포

라쏘의 L_1 -페널티 $\lambda \sum |\beta_j|$ 는 어떤 사전분포 $f(\beta)$ 에서 유래할까요? $-\log(f(\beta)) \propto |\beta|$ 를 만족하는 분포를 찾으면 됩니다.

이는 평균이 0인 라플라스(Laplace) 사전분포 (이중 지수 분포)입니다. $f(\beta) \propto \exp(-\frac{|\beta|}{b}) \implies -\log(f(\beta)) \propto |\beta|$

colback=mygreen!5!white, colframe=mygreen!75!black, title=□ 라쏘(Lasso)의 베이지안 해석 라쏘 회귀는 β 계수들에 대해 평균 0의 라플라스(Laplace) 사전분포를 가정한 베이지안 회귀의 MAP 추정치와 같습니다.

직관 (Sparsity): 라플라스 분포는 정규분포와 달리 $\beta = 0$ 지점에서 '매우 뽕족한 침탑' 모양을 가집니다. 이 사전분포는 "대부분의 β 계수들은 정확히 0일 것이다"라고 매우 강하게 믿습니다. 이 강한 믿음이 중요하지 않은 계수들을 0으로 만들어 변수 선택(feature selection)을 수행합니다.

colback=mygray, colframe=darkgray, breakable, title=시각적 비교: 정규 사전분포 vs. 라플라스 사전분포

- 정규분포 (Normal, for Ridge): $\beta = 0$ 주변이 '둥근 언덕' 모양입니다. 0 근처의 값을 선호하지만, 정확히 0이어야 한다고 강하게 주장하지 않습니다.
- 라플라스분포 (Laplace, for Lasso): $\beta = 0$ 지점이 '뽕족한 침탑' 모양입니다. 확률 질량이 0에 훨씬 많이 몰려있어, β 가 0이 될 확률을 훨씬 높게 부여합니다.
(슬라이드 37의 두 그래프에 대한 텍스트 설명입니다.)

9 계산 방법: MCMC와 깃스 샘플링

9.1 문제: 사후 분포가 너무 복잡할 때

결레 사전분포를 사용하면 사후 분포를 수학 공식으로 깔끔하게 유도할 수 있습니다. 하지만 모델이 복잡해지거나 결레가 아닌 사전분포를 사용하면, 사후 분포 $f(\theta|X)$ 의 공식을 해석적으로(analytically) 풀 수 없습니다.

9.2 해결: 시뮬레이션 (MCMC)

공식을 직접 푸는 대신, 그 사후 분포에서 수많은 샘플을 추출(sampling)하여 분포의 모양을 근사합니다. 이를 MCMC (Markov Chain Monte Carlo) 방법이라고 부릅니다.

* 비유 (케이크 레시피): 내가 모르는 '신비한 케이크'(사후 분포)가 있습니다.

해석적 방법 (Conjugate): 케이크의 '레시피'(수학 공식)를 알아내는 것입니다.

MCMC 방법 (Simulation): 레시피는 모르지만, 이 케이크를 수만 조각 '샘플링'하여 맛볼 수 있는 기계가 있습니다. 수만 조각을 맛본(샘플링) 후, 우리는 이 케이크의 평균 당도(사후 평균), 당도의 편차(사후 분산) 등을 경험적으로(empirically) 추정할 수 있습니다.

MCMC 샘플($\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$)을 얻은 후, 추정은 매우 간단해집니다.

* 사후 평균: 샘플들의 단순 평균 $\frac{1}{N} \sum \theta^{(i)}$ * 95% 신용 구간: 샘플들을 정렬한 뒤, 2.5% 분위수와 97.5% 분위수를 찾습니다.

9.3 깃스 샘플링 (Gibbs Sampling)

MCMC의 대표적인 알고리즘 중 하나로, 다차원 파라미터를 다룰 때 유용합니다. (예: $\theta_1, \theta_2, \theta_3$ 세 개의 파라미터를 동시에 추정해야 할 때)

깃스 샘플링은 결합 사후 분포 $f(\theta_1, \theta_2, \theta_3|X)$ 를 직접 샘플링하기 어려울 때, 대신 '전체 조건부 분포 (Full Conditional Distributions)'를 이용해 번갈아 샘플링합니다.

* $f(\theta_1|\theta_2, \theta_3, X) * f(\theta_2|\theta_1, \theta_3, X) * f(\theta_3|\theta_1, \theta_2, X)$

알고리즘 (3개 파라미터 기준): 1. 초기값 ($\theta_1^{(0)}, \theta_2^{(0)}, \theta_3^{(0)}$)을 임의로 설정합니다. 2. 반복 (Iteration $t = 1, 2, \dots$): a. $\theta_1^{(t)}$ 를 $f(\theta_1|\theta_2^{(t-1)}, \theta_3^{(t-1)}, X)$ 에서 샘플링. b. $\theta_2^{(t)}$ 를 $f(\theta_2|\theta_1^{(t)}, \theta_3^{(t-1)}, X)$ 에서 샘플링 (방금 뽑은 새 값 사용). c. $\theta_3^{(t)}$ 를 $f(\theta_3|\theta_1^{(t)}, \theta_2^{(t)}, X)$ 에서 샘플링 (방금 뽑은 새 값들 사용). 3. 초기 수천 개의 샘플(예: 1 1000번째)은 초기값의 영향을 받으므로 'Burn-in' 기간이라 부르며 폐기합니다. 4. Burn-in 이후의 샘플 ($\theta_1^{(k)}, \theta_2^{(k)}, \theta_3^{(k)}$)들이 우리가 원하는 결합 사후 분포의 샘플이 됩니다.

colback=mygray, colframe=darkgray, breakable, title=시각적 비유: 메트로폴리스-헤이스팅스 (Metropolis-Hastings) MCMC의 또 다른 유명한 알고리즘은 '산(사후 분포)을 오르는 맹인 등반가'로 비유할 수 있습니다.

1. 등반가는 현재 위치(θ)에서 임의의 다음 지점(θ^*)을 제안합니다.
 2. **UPHILL (오르막):** $f(\theta^*) > f(\theta)$ 이면, 무조건 이동합니다. (더 가능성 높은 곳)
 3. **DOWNHILL (내리막):** $f(\theta^*) < f(\theta)$ 이면, 확률적($f(\theta^*)/f(\theta)$)으로 이동합니다. (가파른 내리막(낭떠러지)은 거의 가지 않고, 완만한 내리막은 가끔 갑니다.)
 4. 이 과정을 반복하면, 등반가는 결국 산의 정상(MAP) 주변에서 대부분의 시간을 보내게 됩니다.
- (슬라이드 48의 그림에 대한 텍스트 설명입니다.)

10 자주 묻는 질문 (FAQ) 및 점검

주의사항

Q: 릿지(Ridge) 모델을 '훈련'할 때는 페널티 항($\lambda \sum \beta^2$)을 쓰는데, 왜 '검증(validation)'할 때는 페널티 항을 제외한 MSE만 사용하나요?

A: '훈련'과 '검증'의 목적이 다르기 때문입니다.

- **훈련 (Training)의 목적:** 최적의 β 계수를 찾는 것입니다. 이때 페널티 항($\lambda \sum \beta^2$)은 계수가 너무 커지지 않도록 막는 '규제 장치(regularizer)'입니다. 이 장치는 모델을 만드는 과정(process)의 일부입니다.
- **검증 (Validation)의 목적:** 완성된 모델이 새로운 데이터를 얼마나 잘 예측하는지 평가하는 것입니다. 평가를 할 때는 "그래서 예측값($\hat{y}$)이 실제값(y)과 얼마나 차이 나는가?"라는 '자연스러운' 예측 오차(natural error metric)만 측정해야 합니다. 훈련 과정의 도구였던 페널티 항을 평가에까지 포함시키면, 모델의 순수한 예측 성능을 왜곡하게 됩니다.

11 빠르게 훑어보기 (1-Page Summary)

□ 핵심 요약

1. 베이저언이란?

- 파라미터(θ)를 '고정된 값'이 아닌 '확률 분포(믿음)'로 본다.
- $P(\theta|X) \propto P(X|\theta)P(\theta)$ 공식을 사용한다.
- (최종 믿음) $\propto$ (증거의 힘) $\times$ (초기 믿음)

2. 4가지 핵심 요소

- 사전확률 (Prior $P(\theta)$): 내 초기 믿음. (예: $Uniform(0, 1)$, $N(0, 10)$)
- 가능도 (Likelihood $P(X|\theta)$): 데이터가 말하는 증거. (예: $Binomial(n, \theta)$)
- 사후확률 (Posterior $P(\theta|X)$): 데이터 반영 후 업데이트된 최종 믿음. (우리의 결과물)
- 증거 (Evidence $P(X)$): 정규화 상수. (합을 1로 만들)

3. 사전분포의 종류

- **Informative (정보적):** 전문가 지식 반영.
- **Uninformative (비정보적):** 데이터가 말하게 함. (예: $Uniform$)
- **Conjugate (켈레):** 계산의 편의성. (예: 이항-베타, 정규-정규)

4. 베이저언 vs. 빈도주의 구간

- 신용 구간 (Bayesian): " θ 가 이 안에 있을 확률 95%" (직관적)
- 신뢰 구간 (Frequentist): "구간 100개 뽑으면 95개가 θ 를 포함" (해석 주의)

5. 릿지/라쏘와의 연결 (MAP 추정)

- **Ridge (릿지):** β 에 정규(Normal) 사전분포를 가정한 것. (계수를 0 근처로 당김)
- **Lasso (라쏘):** β 에 라플라스(Laplace) 사전분포를 가정한 것. (뽕족한 분포 $\rightarrow$ 계수를 0으로 만들 $\rightarrow$ 변수 선택)

6. 계산 (MCMC)

- 사후 분포의 공식을 풀기 어려울 때, 대신 수만 개의 샘플을 뽑아 분포를 근사한다.

- **Gibbs Sampling:** 조건부 분포를 이용해 파라미터를 하나씩 번갈아 샘플링.