

■ 강의명: CS109A: Introduction to Data Science

■ 주차: Lecture 17

■ 교수명: UIUC Student

■ 목적: 베イズ 분석의 사후 분포 샘플링 기법과 결측치 처리 전략 학습

Contents

1 용어 정리	3
2 강의 공지 및 중간고사 리뷰	4
3 핵심 개념·원리: 사후 분포 샘플링	6
4 절차/방법: 사후 분포 샘플링 기법	8
5 실습/코드/오류와 해결: MCMC를 이용한 로지스틱 회귀	11

□ 강의 개요

이 문서는 베이즈(Bayes) 분석에서 복잡한 사후 분포(Posterior Distribution)를 다루는 방법과 데이터의 결측치(Missing Data)를 효과적으로 처리하는 전략을 다룹니다. 주요 목표는 사후 분포의 특성을 추정하기 위한 몬테카를로(Monte Carlo) 시뮬레이션 기법, 특히 거부 샘플링(Rejection Sampling)과 마르코프 체인 몬테카를로(MCMC)의 메트로폴리스-헤이스팅스(Metropolis-Hastings) 알고리즘을 이해하는 것입니다. 또한, 데이터 분석 시 흔히 발생하는 결측치의 유형을 파악하고, 통계적 편향을 최소화하면서 데이터를 활용하는 다양한 처리 방안을 학습합니다. 이론적 배경과 실제 코드 예시를 통해 비전공자도 쉽게 접근할 수 있도록 설명합니다.

1 용어 정리

데이터 과학에서 사용되는 주요 용어들을 정리했습니다. 각 용어의 개념과 중요성을 이해하는 데 도움이 될 것입니다.

용어	쉬운 설명	원어	비고
사전 분포	데이터를 관찰하기 전, 모수에 대한 우리의 믿음	Prior Distribution	베이즈 추론의 시작점
가능도	주어진 모수에서 현재 데이터가 관찰될 확률	Likelihood	데이터가 모수에 대해 알려주는 정보
사후 분포	데이터를 관찰한 후, 모수에 대한 업데이트된 믿음	Posterior Distribution	베이즈 추론의 최종 결과
켈레 사전 분포	사후 분포가 사전 분포와 같은 형태를 유지하게 하는 사전 분포	Conjugate Prior	수학적 계산을 단순화
몬테카를로 방법	무작위 샘플링을 통해 분포의 특성을 추정하는 시뮬레이션 기법	Monte Carlo Methods	복잡한 문제 해결에 유용
거부 샘플링	제안 분포에서 샘플을 생성하고, 특정 기준에 따라 일부를 버려 목표 분포를 따르는 샘플을 얻는 방법	Rejection Sampling	고차원에서는 비효율적일 수 있음
마르코프 체인	다음 상태가 현재 상태에만 의존하고 과거 상태에는 독립적인 확률 과정	Markov Chain	"기억 상실" 속성
MCMC	마르코프 체인을 사용하여 목표 분포에서 샘플을 생성하는 몬테카를로 방법	Markov Chain Monte Carlo	복잡한 사후 분포 샘플링에 널리 사용
메트로폴리스-헤이스팅스	MCMC의 한 종류로, 제안된 샘플을 수락하거나 거부하는 확률적 규칙을 사용	Metropolis-Hastings Algorithm	MCMC의 핵심 알고리즘 중 하나
번인 기간	MCMC 체인이 목표 분포에 수렴하기까지 초기 샘플을 버리는 기간	Burn-in Period	초기화 지점의 영향을 줄임
트레이스 플롯	MCMC 샘플이 시간(반복)에 따라 어떻게 변화하는지 보여주는 시계열 그래프	Trace Plot	수렴 여부 진단에 사용
유효 샘플 크기	MCMC 샘플의 독립적인 정보량을 나타내는 지표	Effective Sample Size (ESS)	샘플 간 상관관계를 고려
R-hat	MCMC 체인의 수렴 여부를 진단하는 통계량	R-hat	1에 가까울수록 수렴을 의미
결측치	데이터셋에 값이 없는 경우	Missing Data	데이터 분석의 일반적인 문제
MCAR	결측이 다른 변수나 결측 자체와 완전히 무관하게 발생	Missing Completely At Random	가장 이상적인 결측 유형
MAR	결측이 관측된 다른 변수와 관련되어 발생	Missing At Random	관측된 변수로 결측을 설명 가능
MNAR	결측이 관측되지 않은 변수나 결측 자체의 값과 관련되어 발생	Missing Not At Random	가장 다루기 어려운 결측 유형
대체 (결측치)	결측된 값을 다른 값으로 채우는 과정	Imputation	데이터 손실을 줄이는 방법
결측 지시 변수	특정 값이 결측되었음을 나타내는 이진 변수	Missingness Indicator Variable	결측의 영향을 모델링

2 강의 공지 및 중간고사 리뷰

11월 첫 수업 공지

11월의 첫 수업에 오신 것을 환영합니다! 할로윈 주말은 잘 보내셨기를 바랍니다. 가끔은 즐거운 시간을 보내는 것도 중요합니다. 저는 아이들과 함께 트릭 오어 트릿을 다녀왔고, 두 개의 베개 커버를 가득 채웠습니다. 작은 아이는 20파운드, 큰 아이는 10파운드 정도의 사탕을 모았습니다. 제 아이들은 사탕을 잘 먹지 않으니, 이번 주 언제든 제 사무실에 들러 사탕을 가져가세요!

이번 주 마감 기한

- **프로젝트 마일스톤:** 프로젝트 주제를 업데이트하는 것입니다. 데이터를 탐색하고 프로젝트 질문을 재정의하는 시간을 가지세요.
- **과제 (Problem Set):** 내일(수업 다음 날)까지 제출해야 하는 과제가 있습니다. 모델링, 결과 해석, 그리고 베이즈(Bayes) 개념이 포함됩니다. 오피스 아워에 참여하여 도움을 받으세요.

강의 중 언급: 오늘의 비밀 단어

오늘의 비밀 단어는 **Rainbow**입니다.

중간고사 성적 분포 및 평가 기준

중간고사 성적 분포와 전반적인 평가 기준에 대해 안내합니다.

Figure 1: CS109A 및 CS209 중간고사 성적 분포 (백분율)

중간고사 성적 요약

- **CS109A:** 평균 75점, 중앙값 77점, 표준편차 13점. 최고점은 100점.
- **CS209:** 평균 77.5점 (109A보다 약 2.5점 높음).
- **분포 특징:** 두 과목 모두 왼쪽으로 치우친(Left-skewed) 분포를 보입니다. 이는 평균이 50점 이상일 때 흔히 나타나는 현상입니다. 80-90점대에 데이터가 집중되어 있습니다.
- **이봉성(Bimodality) 가능성:** 분포에서 두 개의 봉우리(mode)가 나타날 수 있으며, 이는 그룹 내에 잠재적인 하위 그룹이 존재할 수 있음을 시사합니다.
- **점수 조정:** Canvas에는 80점 만점으로 표시되지만, 이는 코딩 부분이 아직 반영되지 않았기 때문입니다. 코딩 부분(총점의 20%)이 추가되면 대부분의 성적이 상향 조정될 것입니다.

성적 평가 철학

- **목표:** 학생들의 이해도와 숙련도를 정확하게 반영하는 성적을 부여하는 것이 목표입니다. 성적을 인위적으로 낮추려는 시도는 없습니다.
- **최종 성적 기여 요소:** 중간고사는 최종 성적의 한 부분일 뿐입니다. 과제(Problem Sets), 퀴즈(Quizzes), 기말고사(Final Exam), 프로젝트(Project) 등 모든 요소가 최종 성적에 기여합니다.
- **등급 기준:**
 - 90점 이상: A- 또는 A

– 80점대: B 범위

- **경계 조정:** 등급 경계는 자연스러운 점수 간의 간격(gap)을 찾아 미세하게 조정될 수 있습니다. 예를 들어, 90점과 89.99점 사이의 학생은 동일한 수준으로 간주하여 등급 경계를 유연하게 적용합니다.
- **과거 이력:** 과거에는 대다수의 학생들이 A 또는 A-를 받았고, 그 다음으로 B를 받았으며, 그 이하의 성적을 받은 학생은 소수였습니다.

성적에 대해 궁금한 점이 있다면 언제든지 저희에게 문의해 주세요. 중간고사 해답은 Ed에 게시되어 있습니다.

3 핵심 개념·원리: 사후 분포 샘플링

베이즈 분석과 사후 분포의 중요성

베이즈 분석은 사전 믿음(prior belief)과 데이터를 통해 얻은 가능도(likelihood)를 결합하여 모수(parameter)에 대한 사후 분포(posterior distribution)를 도출하는 통계적 접근 방식입니다. 이 사후 분포는 미지의 모수를 확률 변수처럼 취급하며, 모수에 대한 우리의 업데이트된 믿음을 나타냅니다.

사후 분포의 활용

- **모수 추정:** 미지의 모수에 대한 분포를 제공합니다.
- **미래 관측치 예측:** 수집된 데이터를 바탕으로 미래 관측치가 어디에 있을지 예측하는 데 사용됩니다. 이는 모수의 자연적인 변동성과 분포를 모두 고려해야 하므로 복잡한 과정입니다.

켈레 사전 분포(Conjugate Prior)의 편리함

베이즈 분석에서 사전 분포와 가능도를 결합했을 때 사후 분포가 사전 분포와 동일한 형태를 가지는 경우, 이를 켈레 사전 분포라고 합니다. 이는 수학적 계산을 매우 편리하게 만들어 줍니다.

켈레 사전 분포의 예시

- **회귀 문제 (정규 분포 응답 변수):**
 - 모수 μ 또는 β 에 정규 분포(Normal Distribution) 사전 분포를 사용하면, 사후 분포도 정규 분포가 됩니다.
 - 분산(variance)의 역수(inverse)에 감마 분포(Gamma Distribution) 사전 분포를 사용하면, 사후 분포도 감마 분포가 됩니다.
- **분류 문제 (이항 분포 응답 변수):**
 - 이항 분포(Binomial Distribution)의 모수 P 에 베타 분포(Beta Distribution) 사전 분포를 사용하면, 사후 분포도 베타 분포가 됩니다. (베타-이항 모델)

켈레 사전 분포가 깨지는 경우: 로지스틱 회귀

하지만 모든 경우에 켈레 사전 분포를 사용할 수 있는 것은 아닙니다. 특히 로지스틱 회귀(Logistic Regression)와 같이 비선형 함수(logistic function)를 통해 모수와 확률을 연결하는 모델에서는 켈레 사전 분포의 이점이 사라집니다.

로지스틱 회귀의 문제점

로지스틱 회귀에서는 미지의 β 모수에 정규 분포 사전 분포를 사용하더라도, 사후 분포는 특정 이름이 없는 복잡한 형태를 가지게 됩니다. 이러한 경우, 사후 분포의 수학적 형태를 직접적으로 알 수 없으므로, 이 분포에서 샘플을 추출하는 것이 어려워집니다.

사후 분포 샘플링의 필요성: 몬테카를로 방법

사후 분포가 복잡하여 명확한 수학적 형태를 가지지 않을 때, 우리는 시뮬레이션을 통해 이 분포의 특성을 추정해야 합니다. 이를 위해 몬테카를로(Monte Carlo) 방법이 사용됩니다. 몬테카를로는 무작위 샘플링

을 통해 분포의 평균, 중앙값, 신뢰 구간(credible interval) 등을 추정하는 기법입니다.

몬테카를로 방법의 핵심

- 무작위 샘플 생성: 분포에서 무작위로 많은 샘플을 생성합니다.
- 경험적 추정: 생성된 샘플들의 히스토그램을 통해 분포의 모양을 파악하고, 샘플 통계량(평균, 중앙값, 분위수 등)을 계산하여 분포의 특성을 추정합니다.
- 유사 사례: 부트스트랩(Bootstrapping)이나 순열 검정(Permutation Testing)과 같이 확률 이론을 직접 적용하기 어려울 때 분포를 경험적으로 추정하는 방식과 유사합니다.

두 가지 주요 샘플링 접근 방식

복잡한 사후 분포에서 샘플을 추출하기 위한 두 가지 주요 몬테카를로 접근 방식은 다음과 같습니다.

1. 거부 샘플링 (Rejection Sampling): 다트 던지기과 유사한 방식으로 샘플을 수락하거나 거부합니다.
2. 마르코프 체인 몬테카를로 (Markov Chain Monte Carlo, MCMC): 특히 메트로폴리스-헤이스팅스(Metropolis-Hastings) 알고리즘을 사용하여 마르코프 체인을 따라 분포를 탐색합니다.

4 절차/방법: 사후 분포 샘플링 기법

1. 거부 샘플링 (Rejection Sampling)

거부 샘플링은 목표 분포(target distribution)에서 직접 샘플링하기 어려울 때, 더 쉽게 샘플링할 수 있는 제안 분포(proposal distribution)를 사용하여 목표 분포를 따르는 샘플을 얻는 방법입니다.

거부 샘플링 비유: 다트 던지기

단위 원(unit circle)에서 샘플링하고 싶지만, 단위 사각형(unit square)에서만 샘플을 얻을 수 있다고 가정해 봅시다.

1. 단위 사각형 내에서 무작위로 점(다트)을 던집니다.
2. 만약 그 점이 단위 원 안에 떨어지면(목표에 맞으면), 그 점을 유지합니다.
3. 만약 그 점이 단위 원 밖에 떨어지면(목표를 벗어나면), 그 점을 버립니다.

이 과정을 반복하면, 단위 원 안에 있는 점들만 남게 되어 단위 원의 분포를 따르는 샘플을 얻을 수 있습니다.

거부 샘플링의 원리

1. 목표 분포 ($P(x)$): 우리가 샘플링하고자 하는 복잡한 사후 분포입니다.
2. 제안 분포 ($Q(x)$): 우리가 쉽게 샘플링할 수 있는 알려진 분포입니다 (예: 정규 분포).
3. 스케일링: 제안 분포 $Q(x)$ 에 상수 M 을 곱하여 $M \cdot Q(x)$ 가 목표 분포 $P(x)$ 의 모든 지점에서 $P(x)$ 보다 크거나 같도록 만듭니다. 즉, $P(x) \leq M \cdot Q(x)$ 를 만족해야 합니다.

Figure 2: 거부 샘플링의 시각적 원리: 제안 분포(빨간색)와 목표 분포(검은색)

거부 샘플링 절차

1. 샘플 제안: 제안 분포 $Q(x)$ 에서 후보 샘플 x^* 를 추출합니다.
2. 균일 분포 샘플링: 0과 1 사이의 균일 분포(Uniform Distribution)에서 무작위 값 u 를 추출합니다.
3. 수락/거부 결정:
 - 만약 $u < \frac{P(x^*)}{M \cdot Q(x^*)}$ 이면, x^* 를 수락(accept)합니다.
 - 그렇지 않으면, x^* 를 거부(reject)하고 1단계로 돌아갑니다.

이 과정을 충분히 반복하면, 수락된 샘플들은 목표 분포 $P(x)$ 를 따르게 됩니다.

쿠키 몬스터 예시: 다봉형 분포 샘플링

쿠키 몬스터가 여러 종류의 쿠키(초콜릿 칩,オート밀 건포도, 땅콩 버터, 설탕) 직경 분포를 알고 싶어 합니다. 각 쿠키 종류는 다른 정규 분포를 따르며, 이들을 합치면 여러 개의 봉우리(peak)를 가진 복잡한 분포(예: 3개의 봉우리)가 됩니다. 이 복잡한 분포에서 샘플링하는 것이 목표입니다.

- 목표 분포: 여러 정규 분포가 결합된 복잡한 쿠키 직경 분포 (검은색 곡선).
- 제안 분포: 단일 정규 분포 (빨간색 곡선). 이 제안 분포는 목표 분포를 완전히 덮도록 스케일링됩니다.
- 샘플링 과정:

1. 빨간색 제안 분포에서 쿠키 직경 값 x^* 를 샘플링합니다.
 2. 0 1 사이의 균일 분포에서 u 를 샘플링합니다.
 3. x^* 지점에서 검은색 곡선의 높이와 빨간색 곡선의 높이를 비교합니다.
 4. 만약 u 가 $\frac{\text{검은색 곡선 높이}(x^*)}{\text{빨간색 곡선 높이}(x^*)}$ 보다 작으면 x^* 를 유지하고, 그렇지 않으면 버립니다.
- **결과:** 이 과정을 반복하면, 수락된 샘플들의 히스토그램은 검은색 목표 분포의 모양을 정확하게 반영하게 됩니다. 이 히스토그램을 통해 사후 평균, 95% 신뢰 구간(credible interval) 등을 추정할 수 있습니다.

거부 샘플링의 한계

- **계산 비효율성:** 고차원 모수 공간(예: 20개 이상의 모수)에서는 제안 분포가 목표 분포를 완전히 덮도록 스케일링하기가 매우 어렵습니다. 이 경우 대부분의 샘플이 거부되어 수락률이 극히 낮아지고, 매우 많은 샘플을 생성해야 하므로 계산 비용이 커집니다(차원의 저주, Curse of Dimensionality).
- **제안 분포의 선택:** 제안 분포를 목표 분포와 유사하게 설정하는 것이 중요하지만, 이는 쉽지 않은 문제입니다.

2. 마르코프 체인 몬테카를로 (MCMC)

MCMC는 거부 샘플링의 비효율성을 극복하기 위해 고안된 방법입니다. 특히 메트로폴리스-헤이스팅스(Metropolis-Hastings) 알고리즘은 복잡한 사후 분포에서 샘플을 추출하는 데 널리 사용됩니다.

마르코프 체인 (Markov Chain)의 개념

마르코프 속성 (Markovian Property): 기억 상실

마르코프 체인은 "기억 상실(memoryless)" 속성을 가진 확률 과정입니다. 이는 다음 상태(time $t+1$)가 오직 현재 상태(time t)에만 의존하며, 그 이전의 과거 상태(time $t-1, t-2, \dots$)에는 의존하지 않는다는 의미입니다.

마르코프 속성 비유

- **날씨 예측:** 내일의 날씨를 예측하기 위해 오늘 날씨만 알면 충분하다고 가정한다면, 이는 마르코프 속성을 따릅니다. 과거의 모든 날씨 기록을 알 필요는 없습니다.
- **주식 시장:** 오늘 주식 가격이 어제 주식 가격에만 의존하고, 그 이전의 가격 변동 과정에는 의존하지 않는다고 가정한다면, 이는 마르코프 과정으로 볼 수 있습니다.

MCMC의 목표

MCMC는 마르코프 체인을 구성하여 이 체인이 충분히 오랜 시간 동안 진화하면, 체인의 상태들이 우리가 샘플링하고자 하는 목표 분포(사후 분포)를 따르게 하는 것을 목표로 합니다. 즉, 분포를 통해 무작위 걸음(random walk)을 수행하는 것입니다.

메트로폴리스-헤이스팅스 (Metropolis-Hastings) 알고리즘

메트로폴리스-헤이스팅스 알고리즘은 MCMC의 핵심으로, 현재 위치에서 다음 위치로 이동할지 여부를 확률적으로 결정하여 목표 분포를 탐색합니다.

Figure 4: 메트로폴리스-헤이스팅스 알고리즘의 무작위 걸음 개념

메트로폴리스-헤이스팅스 알고리즘의 핵심 아이디어

1. 현재 위치: 분포 내의 현재 모수 값(θ_t)을 알고 있습니다.
2. 새로운 위치 제안: 제안 분포($Q(\theta'|\theta_t)$)를 사용하여 새로운 모수 값(θ')을 제안합니다. 이 제안 분포는 현재 위치 θ_t 에 따라 달라질 수 있습니다.
3. 수락/거부 결정: 제안된 θ' 로 이동할지 말지를 확률적으로 결정합니다. 이 결정은 목표 분포(사후 분포)의 높이와 제안 분포의 확률을 고려합니다.

메트로폴리스-헤이스팅스 절차

1. 초기화: 모수 θ 의 초기 값 θ_0 를 설정합니다.
2. 반복: $t = 0, 1, 2, \dots$ 에 대해 다음을 반복합니다.
 - (a) 새로운 값 제안: 현재 값 θ_t 에서 제안 분포 $Q(\theta'|\theta_t)$ 를 사용하여 새로운 후보 값 θ' 를 샘플링합니다. (예: θ_t 를 중심으로 하는 정규 분포에서 샘플링)
 - (b) 수락 확률 계산: 다음 수락 확률 α 를 계산합니다.

$$\alpha = \min \left(1, \frac{P(\theta'|\text{data}) \cdot Q(\theta_t|\theta')}{P(\theta_t|\text{data}) \cdot Q(\theta'|\theta_t)} \right)$$

여기서 $P(\theta|\text{data})$ 는 목표 사후 분포의 밀도 함수입니다. 중요한 점은 사후 분포의 정규화 상수 (normalizing constant)를 몰라도 비율 계산에는 문제가 없다는 것입니다.

- (c) 수락/거부: 0과 1 사이의 균일 분포에서 무작위 값 u 를 샘플링합니다.
 - 만약 $u < \alpha$ 이면, 새로운 값 θ' 를 수락합니다. 즉, $\theta_{t+1} = \theta'$.
 - 그렇지 않으면, 새로운 값을 거부하고 현재 값에 머무릅니다. 즉, $\theta_{t+1} = \theta_t$.

수락 확률 α 의 직관적 의미

- 확률이 더 높은 곳으로 이동: 만약 제안된 θ' 의 사후 확률 밀도가 현재 θ_t 보다 높다면 (즉, "언덕 위로" 이동한다면), α 는 1에 가까워져 거의 항상 수락됩니다.
- 확률이 더 낮은 곳으로 이동: 만약 제안된 θ' 의 사후 확률 밀도가 현재 θ_t 보다 낮다면 (즉, "언덕 아래로" 이동한다면), α 는 1보다 작아져 특정 확률로만 수락됩니다. 이는 체인이 지역 최댓값 (local maximum)에 갇히지 않고 분포 전체를 탐색할 수 있도록 돕습니다.
- 제안 분포의 영향: $Q(\theta_t|\theta')$ 와 $Q(\theta'|\theta_t)$ 항은 제안 분포가 대칭적이지 않을 때 편향을 보정하는 역할을 합니다.

5 실습/코드/오류와 해결: MCMC를 이용한 로지스틱 회귀

예시: 스키틀즈(Skittles) 맛 선호도 모델링

스키틀즈에서 새로운 망고 맛을 출시하려고 합니다. 각 배치에 들어갈 망고 에센스 재료의 양(dosage, X) 이 맛 선호도(Y)에 미치는 영향을 파악하여 최적의 레시피를 찾고자 합니다.

데이터 및 모델 설정

- 독립 변수 (X): 망고 에센스 재료의 양 (연속형 수치).
- 종속 변수 (Y): 맛을 좋아하는 사람의 수.
- 데이터 구조: 각 재료 양(X)에 대해 N 명의 테스터가 맛을 보고, 그 중 Y 명이 맛을 좋아한다고 응답한 데이터.
- 데이터 생성 과정: 각 테스터의 응답은 베르누이 분포(Bernoulli Distribution)를 따르며, 이를 합산한 Y 는 이항 분포(Binomial Distribution)를 따릅니다.
- 모델: 로지스틱 회귀 모델을 사용하여 재료 양(X)과 맛을 좋아할 확률(P) 사이의 관계를 모델링 합니다.

$$\text{logit}(P) = \log\left(\frac{P}{1-P}\right) = \alpha + \beta X$$

여기서 α 는 절편(intercept), β 는 기울기(slope)입니다.

베이즈적 접근: 사전 분포 설정

α 와 β 는 미지의 모수이므로, 베이즈적 접근을 위해 이들에 대한 사전 분포를 설정해야 합니다. 로짓 스케일에서 α 와 β 는 무한한 값을 가질 수 있으므로, 무한한 범위를 가지는 정규 분포(Normal Distribution)를 사전 분포로 사용합니다.

사전 분포 설정 예시

- 기울기 β : 관계가 없을 것이라는 중립적인 믿음으로 평균 0을 설정합니다. 사전 정보가 많지 않으므로, 분산(표준편차)을 매우 크게 설정하여 비정보적(non-informative) 사전 분포를 만듭니다.
- 절편 α : 재료 양이 0일 때 50:50의 확률로 맛을 좋아할 것이라는 믿음으로 평균 0을 설정하고, 마찬가지로 큰 분산을 부여합니다.

사후 분포의 형태

이항 분포 가능도와 정규 분포 사전 분포를 결합하면, 사후 분포는 복잡한 형태를 가지며, 켈레 사전 분포가 아니므로 명확한 수학적 이름이 없습니다.

$$P(\alpha, \beta | \text{data}) \propto P(\text{data} | \alpha, \beta) \cdot P(\alpha) \cdot P(\beta)$$

$$P(\alpha, \beta | \text{data}) \propto \left(\prod_{i=1}^N \binom{n_i}{y_i} p_i^{y_i} (1-p_i)^{n_i-y_i} \right) \cdot N(\alpha | \mu_\alpha, \sigma_\alpha^2) \cdot N(\beta | \mu_\beta, \sigma_\beta^2)$$

여기서 $p_i = \frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}}$ 입니다. 이 사후 분포의 정확한 형태는 모르지만, 주어진 α 와 β 값에 대해 사후 분포의 "높이" (정규화 상수를 제외한 부분)는 계산할 수 있습니다.

pymc를 이용한 MCMC 샘플링

Python의 pymc와 같은 라이브러리는 메트로폴리스-헤이스팅스 알고리즘을 사용하여 복잡한 사후 분포에서 샘플을 추출하는 과정을 자동화합니다.

```

1 import pymc as pm
2 import numpy as np
3
4 # 가상의데이터강의 ( 자료의표와유사 )
5 # dosage (X), total_testers (N), liked_flavor (Y)
6 data = {
7     'X': np.array([1.88, 1.86, 1.89, 1.90, 1.87, 1.85, 1.91, 1.84]),
8     'N': np.array([60, 62, 58, 61, 59, 60, 63, 57]),
9     'Y': np.array([50, 51, 48, 52, 49, 50, 53, 47])
10 }
11
12 with pm.Model() as skittles_model:
13     # 1. 사전분포정의 (Priors)
14     # 비정보적사전분포를위해큰표준편차를가진정규분포사용
15     alpha = pm.Normal("alpha", mu=0, sigma=100) # 절편
16     beta = pm.Normal("beta", mu=0, sigma=100) # 기울기
17
18     # 2. 로지스틱모델정의 (Likelihood Link)
19     # logit(p) = alpha + beta * X
20     # p = exp(alpha + beta * X) / (1 + exp(alpha + beta * X))
21     p = pm.Deterministic("p", pm.math.invlogit(alpha + beta * data['X']))
22
23     # 3. 데이터의가능도정의 (Likelihood of Data)
24     # 는Y 이항분포를따름 (N, p)
25     observed_data = pm.Binomial("observed_data", n=data['N'], p=p, observed=
26         data['Y'])
27
28     # 4. MCMC 샘플링수행
29     # draw: 샘플링할반복횟수
30     # tune: 번인(burn-in) 기간초기 ( 불안정한샘플버림 )
31     trace = pm.sample(draws=2000, tune=2000, cores=1) # cores은=1 단일체인실행

```

Listing 1: pymc를 이용한 MCMC 모델 설정 및 샘플링 예시

MCMC 샘플링 과정의 주요 파라미터

- **draws:** 번인 기간 이후에 수집할 샘플의 수입니다. 이 샘플들이 사후 분포를 추정하는 데 사용됩니다.
- **tune (번인 기간, Burn-in Period):** MCMC 체인이 목표 분포에 수렴하기까지 초기 불안정한 샘플들을 버리는 기간입니다. 초기화 지점의 영향을 최소화하고 안정적인 샘플을 얻기 위함입니다.
- **cores:** 병렬로 실행할 MCMC 체인의 수입니다. 여러 체인을 실행하면 수렴 진단에 도움이 됩니다.