

- 강의명: CS109A: 데이터 과학 입문
- 주차: Lecture 22
- 교수명: Pavlos Protopapas, Kevin Rader, Chris Gumb
- 목적: Lecture 22의 핵심 개념 학습

Contents

1 용어 정리	3
2 핵심 개념: 랜덤 포레스트의 원리	4
2.1 배깅 (<i>Bagging</i>)의 한계: 트리의 상관관계	4
2.2 랜덤 포레스트: 비상관화 (<i>Decorrelation</i>)의 도입	4
2.3 하이퍼파라미터 튜닝	4
3 변수 중요도 (<i>Variable Importance</i>) 평가	6
3.1 1. 불순도 감소량 평균 (<i>Mean Decrease in Impurity, MDI</i>)	6
3.2 2. 순열 중요도 (<i>Permutation Importance</i>)	6
3.3 랜덤 포레스트 vs. 배깅 변수 중요도 비교	7
4 불균형 데이터 (<i>Class Imbalance</i>) 처리	8
4.1 처리 방법	8
5 결측값 (<i>Missing Data</i>) 처리: 서러게이트 분할	9
5.1 서러게이트 분할의 개념	9
5.2 서러게이트 분할의 이점	9
6 FAQ 및 초심자 체크리스트	10
6.1 자주 묻는 질문 (FAQ)	10
6.2 학습 및 구현 체크리스트	10

개요: 랜덤 포레스트와 변수 중요도

문서 핵심 요약

랜덤 포레스트(*Random Forest*)는 배깅(*Bagging*)의 변형으로, 다수의 결정 트리(*Decision Tree*)를 훈련하고 결과를 집계하여 예측의 분산(*Variance*)을 줄이는 앙상블 학습 기법입니다. 핵심은 각 트리의 분할 시마다 전체 특징(*Feature*, 변수)의 부분집합을 무작위로 선택하여, 트리 간의 상관관계를 낮춰 성능을 극대화하는 것입니다. 트리 간의 낮은 상관관계는 모델의 안정성(*Robustness*)을 높이고 과적합(*Overfitting*) 위험을 줄입니다. 변수 중요도(*Variable Importance*)는 모델의 해석력을 높이는 수단이며, 불순도 감소량 평균(*Mean Decrease in Impurity*, MDI)과 순열 중요도(*Permutation Importance*) 두 가지 방법으로 계산됩니다. 또한, 불균형 데이터(*Imbalanced Data*) 문제와 결측값(*Missing Data*) 처리 방법도 함께 다룹니다.

1 용어 정리

주요 용어 및 직관적 설명

2 핵심 개념: 랜덤 포레스트의 원리

2.1 배깅(Bagging)의 한계: 트리의 상관관계

배깅은 부트스트랩 샘플(Bootstrap Sample)을 사용하여 다수의 결정 트리를 학습하고 그 결과를 집계(Aggregate)하여 분산을 줄이는 앙상블 기법입니다. 그러나 배깅에서 생성된 트리는 서로 상관관계(Correlation)가 높게 나타나는 경향이 있습니다.

상관관계가 높은 이유에 대한 비유

강력한 예측 변수(Strong Predictor)가 있는 경우, 모든 부트스트랩 샘플에서도 이 예측 변수가 가장 높은 불순도 감소 효과를 보일 것입니다. 마치 모든 의사(Estimator)가 동일한 환자 데이터를 기반으로 훈련받고, '휴식, 수분 섭취'와 같은 가장 확실한 조언을 첫 번째 조치로 내리는 것과 같습니다. 따라서, 대부분의 트리는 최상위 노드(Root Node)에서 동일한 특징으로 분할을 시작하게 되어, 트리가 서로 비슷한 구조와 예측을 하게 됩니다. 이러한 상관관계는 앙상블이 기대하는 분산 감소 효과($1/\sqrt{n}$)를 약화시킵니다.

2.2 랜덤 포레스트: 비상관화(Decorrelation)의 도입

랜덤 포레스트는 배깅을 개선하여 트리 간의 상관관계를 낮추는 방법입니다. 트리의 상관관계를 낮추는 것이 분산(Variance)을 효과적으로 줄이는 핵심입니다.

랜덤 포레스트의 핵심 아이디어

각 분할 노드(Split Node)마다, 전체 특징 J 개 중 무작위로 선택된 $J' < J$ 개의 특징 부분집합만 고려합니다. 즉, 트리가 자라날 때마다 최고의 특징을 선택할 때 전체 특징이 아닌 일부 특징 중에서만 선택하게 강제합니다. 이로 인해 강력한 특징이 매번 선택될 확률이 낮아지고, 결과적으로 트리가 다양해지고 서로 덜 유사해집니다.

랜덤 포레스트 요약 단계

1. B 개의 부트스트랩 데이터셋을 생성합니다 (배깅과 동일).
2. B 개의 결정 트리를 초기화합니다.
3. 각 트리 내의 각 분할(Split)마다:
 - (a) 전체 특징 J 개 중 무작위로 J' 개의 특징 부분집합을 선택합니다 ($J' < J$).
 - (b) 이 J' 개의 특징 중에서 최적의 특징과 최적의 임계값(Threshold)를 선택하여 분할합니다.
4. 최종적으로 모든 트리의 예측을 집계합니다 (분류는 다수결, 회귀는 평균).

이때 J' 는 각 분할마다 새롭게 무작위로 선택됩니다.

2.3 하이퍼파라미터 튜닝

랜덤 포레스트는 여러 개의 하이퍼파라미터를 가지며, 이는 모델의 성능과 훈련 속도에 영향을 미칩니다.

주요 하이퍼파라미터

- 분할 시 무작위 선택할 특징의 개수 J' : 트리 간의 상관관계를 조절하는 가장 중요한 파라미터입니다.
- 앙상블 내 트리의 총 개수 B : 분산 감소량을 결정합니다. 트리가 많을수록 분산은 줄어들지만 계산 시간이 늘어납니다.
- 트리 정지 조건: 최대 깊이 (*Maximum Depth*), 최소 리프 노드 크기 (*Minimum Leaf Node Size*) 등.
- 분할 기준: 지니 불순도 (*Gini Impurity*) 또는 엔트로피 (*Entropy*).

하이퍼파라미터 튜닝과 전문가의 권장 사항

1. 최적의 J' 선택: 교차 검증 (*Cross-Validation*)을 사용해야 하지만, 일반적인 경험 법칙 (*Rule of Thumb*)이 있습니다.
 - 분류 (*Classification*): $\sqrt{N_j}$ (전체 특징 개수의 제곱근)
 - 회귀 (*Regression*): $N_j/3$
2. 트리의 개수 B : OOB 오류가 더 이상 감소하지 않고 안정화되는 지점까지 늘립니다. 트리의 개수는 과적합 (*Overfitting*)을 유발하지 않습니다. 단지 분산만 감소시킬 뿐입니다.
3. 정지 조건 및 기준: 보통 최대 깊이 (*Maximum Depth*)나 지니 불순도 (*Gini*)를 기본값으로 사용하고, 모델이 작동한 후에 더 세밀한 튜닝을 시도할 수 있습니다.

OOB 오류를 활용한 검증

랜덤 포레스트는 OOB(Out-of-Bag) 샘플, 즉 부트스트랩 과정에서 특정 트리 훈련에 사용되지 않은 데이터 포인트들을 사용하여 별도의 검증 세트 없이 모델을 평가할 수 있습니다. 이것이 교차 검증을 대체할 수 있는 효율적인 방법입니다.

3 변수 중요도 (Variable Importance) 평가

앙상블 모델은 단일 결정 트리처럼 쉬운 규칙(Rule) 형태로 해석하기 어렵기 때문에, 어떤 특징이 예측에 가장 큰 영향을 미쳤는지 평가하여 모델의 해석력(Interpretability)을 높여야 합니다.

3.1 1. 불순도 감소량 평균 (Mean Decrease in Impurity, MDI)

MDI는 특정 특징이 트리의 불순도(예: 지니 불순도)를 평균적으로 얼마나 감소시켰는지를 측정하여 중요도를 산출하는 방법입니다.

MDI 계산 절차

1. 노드별 불순도 감소량 계산: 단일 트리 내의 각 노드 q 에서 분할로 인한 불순도 감소량 ΔI_q 를 계산합니다.

$$\Delta I_q = \left(\frac{n}{N}\right) \left[Gini_n - \sum_{m \in \text{children}} \left(\frac{m}{n}\right) Gini_m \right]$$

(n : 노드의 샘플 수, N : 전체 데이터 샘플 수, m : 자식 노드의 샘플 수)

2. 특징별 중요도 합산: 특정 특징 j 가 사용된 모든 노드 n 의 불순도 감소량을 합하여 해당 특징의 중요도 $F_j^{(t)}$ 를 계산합니다.
3. 정규화: 중요도 합계를 모든 특징의 중요도 합계로 나누어 0에서 1 사이 값으로 정규화합니다.
4. 앙상블 평균: 모든 트리 T 에 대해 정규화된 특징 중요도 $\hat{F}_j^{(t)}$ 를 평균하여 최종 MDI 중요도를 구합니다.

$$\mathcal{F}_j = \frac{\sum_t \hat{F}_j^{(t)}}{T}$$

MDI의 장단점

- 장점: 계산 속도가 빠릅니다. 모든 필요한 값은 랜덤 포레스트 훈련 중에 계산됩니다.
- 단점: 수치형 특징 (Numerical Feature) 이나 범주형 특징 중 고유값이 많은 특징 (High Cardinality Categorical Feature)에 편향(Bias)되어 중요도를 과대평가하는 경향이 있습니다. 이들은 분할 지점 (Split Point)이 많기 때문에 우연히 불순도를 크게 감소시키는 분할을 찾을 가능성이 높습니다.

3.2 2. 순열 중요도 (Permutation Importance)

순열 중요도는 특징의 값들을 무작위로 섞어(Permute) 해당 특징과 결과 변수 간의 관계를 끊었을 때, 모델의 검증/OOB 성능이 얼마나 하락하는지를 측정하여 중요도를 산출하는 방법입니다.

순열 중요도 계산 절차

1. 기준 성능 기록: 원본 데이터셋에서의 OOB 또는 검증 정확도 s 를 기록합니다.
2. 특징 순열: 관심 있는 특징 j 의 데이터 열을 무작위로 섞습니다.
3. 순열 성능 측정: 섞인 데이터셋으로 모델을 실행하여 새로운 OOB/검증 정확도 $s_{k,j}$ 를 기록합니다.

4. **반복 및 평균**: 2, 3단계를 K 번 반복하고 평균 순열 정확도 s_j 를 계산합니다.

$$s_j = \frac{1}{K} \sum_{k=1}^K s_{k,j}$$

5. **중요도 산출**: 기준 성능과 평균 순열 성능의 차이를 계산하여 중요도를 산출합니다.

$$\text{특징 중요도} = s - s_j$$

순열 중요도의 장단점

- **장점**: MDI의 편향이 없으며, 실제 모델 성능에 미치는 영향을 직접적으로 측정하므로 더 직관적이고 신뢰할 만한 중요도를 제공합니다.
- **단점**: MDI보다 계산 비용이 더 많이 듭니다. (각 특징마다 K 번의 예측이 필요)

3.3 랜덤 포레스트 vs. 배깅 변수 중요도 비교

트리 간 상관관계가 높은 **배깅 (Bagging)**은 소수의 강력한 예측 변수(예: ChestPain, Ca)에 중요도가 집중되는 경향을 보입니다. 반면, 비상관화 과정을 거친 **랜덤 포레스트 (Random Forest)**의 중요도는 여러 특징에 걸쳐 더 부드럽고 분산된 분포를 보여줍니다. 이는 트리들이 다양한 특징을 고려하도록 강제되었기 때문입니다.

랜덤 포레스트가 잘 작동하지 않는 경우

전체 특징의 수가 매우 많지만, 실제로 중요한 특징의 수가 적을 때 (예: 1000개의 특징 중 10개만 중요), 랜덤 포레스트는 오히려 성능이 떨어질 수 있습니다. 각 분할에서 무작위로 선택된 특징 부분집합에 중요한 특징이 포함되지 않을 확률이 높아지기 때문에, 생성된 트리들이 대부분 '약한 모델'이 될 수 있습니다. 이 경우 PCA나 다른 특징 선택 기법을 사용해 불필요한 특징을 미리 제거하는 것이 좋습니다.

4 불균형 데이터(Class Imbalance) 처리

데이터셋에서 특정 클래스(소수 클래스)의 샘플 수가 다른 클래스(다수 클래스)에 비해 현저히 적을 때 발생하는 문제입니다. 이 경우 모델이 다수 클래스만 예측해도 높은 '정확도'를 얻을 수 있어, 실제로는 소수 클래스 예측 능력이 매우 낮아집니다.

불균형 데이터 문제 진단

정확도(Accuracy)는 좋은 평가 지표가 아닙니다. 99% 대 1%의 클래스 불균형에서 모델이 항상 99%의 다수 클래스만 예측해도 정확도는 99%가 나옵니다. 따라서, 불균형 데이터셋에서는 **F1-점수**나 **ROC 곡선 하 면적(AUC)**과 같은 지표를 사용해야 합니다.

4.1 처리 방법

1. 언더샘플링(Under-sampling): 다수 클래스 샘플 수 감소

- 무작위 언더샘플링: 다수 클래스에서 무작위로 샘플을 제거하여 클래스 균형을 맞춥니다. (단점: 중요한 정보를 포함하는 샘플이 손실될 수 있습니다.)
- 니어 미스(Near Miss): 결정 경계(Decision Boundary)에서 멀리 떨어진, 즉 분류에 덜 유익한 다수 클래스 샘플을 제거하여 정보 손실을 최소화합니다. (경계 근처의 샘플은 보존)

2. 오버샘플링(Over-sampling): 소수 클래스 샘플 수 증가

- 무작위 오버샘플링: 소수 클래스의 샘플을 복원 추출(with replacement)하여 수를 늘립니다. (단점: 단순 복제이므로 과적합을 유발하거나 데이터의 다양성을 해칠 수 있습니다.)
- SMOTE (Synthetic Minority Oversampling Technique): 소수 클래스 샘플 주변에 새로운 합성 데이터(Synthetic Data)를 생성하여 수를 늘립니다. 데이터 영역을 확장하여 모델의 일반화 성능을 높입니다.

3. 클래스 가중치(Class Weighting)

- 모델의 손실 함수(Loss Function)에서 소수 클래스의 오류에 더 높은 가중치를 부여하여 학습 시 소수 클래스에 더 많은 관심을 기울이도록 합니다.
- 사이킷런(scikit-learn)에서는 `class_weight='balanced'` 옵션을 통해 자동으로 클래스 빈도에 반비례하여 가중치를 조정할 수 있습니다.

$$W_K = \frac{N}{K \times N_K}$$

(N : 전체 샘플 수, K : 클래스 수, N_K : 클래스 K 의 샘플 수)

실제 사용 전략

데이터 균형을 맞출 때에는 세 가지 방법(언더샘플링, 오버샘플링, 가중치) 중 하나 또는 그 조합을 사용합니다. 예를 들어, 오버샘플링과 언더샘플링을 결합하거나, 데이터 재조정 후 클래스 가중치를 적용할 수 있습니다. 중요한 것은 항상 데이터를 균형 있게 처리하는 것입니다 (40%/60% 불균형에서도 적용 권장).

5 결측값(Missing Data) 처리: 서러게이트 분할

결정 트리 기반 모델은 결측값을 처리하는 독특한 방법인 서로게이트 분할(*Surrogate Split*)을 사용할 수 있습니다.

5.1 서로게이트 분할의 개념

서로게이트 분할은 트리를 훈련하는 과정에서 최적의 분할 특징(*Optimal Splitter*)의 결측값(*Missing Value*)을 대신할 수 있는 차선택의 특징(*Alternative Feature*)을 미리 찾아 순위를 매겨 놓는 방법입니다.

작동 원리

1. **최적 분할 특징 선택:** 노드 N 에서 불순도를 가장 크게 줄이는 최적의 분할 특징 P_{opt} 를 찾습니다.
2. **분할 분포 기록:** P_{opt} 를 사용해 노드를 분할했을 때, 각 자식 노드로 이동하는 반응 변수(*Response Variable*)의 분포(예: Yes/No 개수)를 기록합니다.
3. **대리 특징 찾기:** 나머지 모든 특징 P_i 에 대해 P_{opt} 와 동일한 분할을 시도했을 때, 반응 변수의 분포가 P_{opt} 의 분포와 가장 유사한 특징을 찾습니다.
4. **유사도 측정:** 두 특징의 분할 분포가 얼마나 유사한지(즉, 분포를 일치시키기 위해 얼마나 많은 '플립'이 필요한지)를 측정하여 유사도를 산출하고 순위를 매깁니다.
5. **예측 시 사용:** 실제 예측 시점에 입력 데이터의 P_{opt} 값이 결측이면, 미리 정의된 순위에 따라 가장 유사한 서러게이트 분할 특징을 대신 사용하여 데이터를 분할합니다.

서러게이트 분할 예시

주요 특징이 'Arteries Blocked'라고 가정합니다. 이 특징으로 분할했을 때, 환자들의 '심장병 유무' 분포가 나옵니다.

- **최적 분할 특징 (Arteries Blocked):** FALSE $\rightarrow$ [3 No, 1 Yes], TRUE $\rightarrow$ [0 No, 2 Yes]
- **대리 특징 후보 (Chest Congested):** FALSE $\rightarrow$ [3 No, 2 Yes], TRUE $\rightarrow$ [0 No, 1 Yes]
- 두 분포를 비교하여 유사도를 측정합니다. 이 예시에서는 'Chest Congested'가 'Arteries Blocked'와 가장 유사한 분할 분포를 보였으므로 최적의 서러게이트가 됩니다.

따라서, 예측할 데이터에서 'Arteries Blocked' 값이 결측이면, 대신 'Chest Congested' 특징을 사용하여 트리를 따라 내려갑니다.

5.2 서러게이트 분할의 이점

- **해석력 향상:** 서러게이트는 최적 분할 특징과 비슷한 역할을 하는 보조 특징을 보여주므로, 주 분할기의 작동 방식을 이해하는 데 도움이 됩니다.
- **다중 공선성 (Multi-collinearity) 활용:** 다중 공선성이 있는 경우(특징들이 서로 높은 상관관계를 가지는 경우), 대체할 서러게이트를 찾을 가능성이 높고 성능도 좋습니다.
- **명시적 대체 불필요:** 데이터 분석가가 별도의 결측값 대체(*Imputation*) 방법을 고민할 필요 없이, 트리가 자체적으로 결측값을 처리할 수 있습니다.

6 FAQ 및 초심자 체크리스트

6.1 자주 묻는 질문 (FAQ)

1. Q: 랜덤 포레스트에서 트리의 개수(*Number of Trees*)가 많아지면 과적합되나요?
A: **아닙니다.** 트리의 개수를 늘리는 것은 분산(**Variance**)만 줄이는 역할을 합니다. 이는 앙상블의 예측을 안정화할 뿐이며, 다른 하이퍼파라미터처럼 모델의 복잡도(*Complexity*)를 제어하지 않으므로 과적합 위험을 증가시키지 않습니다.
2. Q: 랜덤 포레스트는 어떻게 클래스 예측 확률(*Class Probabilities*)을 반환하나요?
A: 각 개별 트리는 최종적으로 클래스 예측 결과를 내놓습니다. 랜덤 포레스트 분류기(*Classifier*)는 모든 트리가 예측한 클래스 예측의 평균을 계산하여 이를 확률의 근사치(*Proxy*)로 사용합니다. 이 값을 임계값(*Threshold*)과 결합하여 ROC 곡선 등을 그릴 수 있습니다.
3. Q: MDI와 순열 중요도 중 어떤 것을 사용해야 하나요?
A: **순열 중요도(Permutation Importance)**가 더 신뢰할 수 있습니다. MDI는 계산이 빠르다는 장점이 있지만, 수치형이나 고유값이 많은 범주형 특징에 편향되어 중요도를 과대평가하는 경향이 있습니다. 순열 중요도는 모델의 실제 성능 변화를 측정하므로 더 직관적이고 정확합니다.
4. Q: 결정 트리는 단일 모델로 불안정한데, 왜 배깅이나 랜덤 포레스트에서는 안정적인가요?
A: 단일 결정 트리는 훈련 데이터의 작은 변화에도 민감하게 반응하여 매우 다른 구조로 학습될 수 있습니다(**고분산**). 앙상블은 부트스트랩을 통해 생성된 다양한 불안정한 트리를 평균하여, 그 '노이즈'로 인한 예측의 변동성(*Variability*)을 상쇄하고 **평균적인 안정적인 예측**을 얻습니다.

6.2 학습 및 구현 체크리스트

랜덤 포레스트 구현 전 점검 사항

- **핵심 원리 이해:** 랜덤 포레스트가 배깅과의 차이점(특징 무작위 부분집합 선택)과 분산 감소 메커니즘을 명확히 설명할 수 있는가?
- **하이퍼파라미터 튜닝:** 가장 중요한 하이퍼파라미터 J' 와 B 의 역할 및 권장 기본값($\sqrt{N_j}$, $N_j/3$)을 아는가?
- **평가 지표 선택:** 데이터 불균형 여부를 확인하고, 불균형 시 F1-점수 또는 AUC를 주 평가 지표로 사용하는가?
- **불균형 처리:** 언더샘플링(Near Miss)이나 오버샘플링(SMOTE) 또는 클래스 가중치 중 최소한 가지 방법을 적용하여 데이터를 균형 있게 조정했는가?
- **변수 중요도 평가:** MDI의 편향성을 인지하고, 가능하면 순열 중요도를 사용하여 특징의 기여도를 평가했는가?
- **성능 비교:** 단일 결정 트리, 배깅, 랜덤 포레스트의 RMSE 또는 정확도를 비교하여 분산 감소 효과를 확인했는가?