

■ 강의명: CSCI103

■ 주차: Lecture 2

■ 교수명: UIUC Student

■ 목적: 이 문서는 CSCI103 Lecture 2 강의 자료를 통합하여 작성된 시험 대비용 LaTeX 노트입니다. 데이터 모델링, 메타데이터, 데이터 형식, 압축, 프로파일링 등 핵심 개념을 다룹니다. 특히, OLTP와 OLAP 시스템의 차이, 다양한 데이터 모델링 기법(스타, 스노우플레이크, 데이터 볼트), 그리고 데이터브릭스 환경에서의 실습(Lab 01) 과정을 상세히 설명합니다. 비전 공자도 쉽게 이해할 수 있도록 배경 설명, 비유, 예시를 풍부하게 포함하며, 과제 및 시험 준비에 필요한 모든 정보를 제공합니다.

Contents

1 용어 정리

다음 표는 강의에서 다루는 주요 용어들을 쉽게 설명하고 원어와 함께 정리한 것입니다.

Table 1: 주요 용어 정리

용어 (Term)	쉬운 설명 (Easy Explanation)	원어 (Original)	비고 (Notes)
ACID	데이터베이스 트랜잭션의 안정성을 보장하는 네 가지 속성	Atomicity, Consistency, Isolation, Durability	주로 관계형 데이터베이스와 연관
BASE	분산 시스템의 가용성과 확장성을 강조하는 속성	Basically Available, Soft state, Eventual consistency	NoSQL 시스템에서 주로 사용
CAP 이론	분산 시스템에서 일관성, 가용성, 분할 내성 중 두 가지만 선택 가능	Consistency, Availability, Partition tolerance	관계형 DB는 C, NoSQL은 A 선호
IaaS	가상 서버, 스토리지 등 IT 인프라를 서비스로 제공	Infrastructure as a Service	클라우드 컴퓨팅 모델
PaaS	개발 환경 및 플랫폼을 서비스로 제공	Platform as a Service	클라우드 컴퓨팅 모델
SaaS	소프트웨어 애플리케이션을 서비스로 제공	Software as a Service	클라우드 컴퓨팅 모델
레이크하우스	데이터 웨어하우스와 데이터 레이크의 장점을 결합한 아키텍처	Lakehouse	데이터브릭스의 핵심 개념
DAG	작업의 의존성을 방향성 있는 그래프로 표현	Directed Acyclic Graph	스파크 작업 스케줄링에 사용
ETL	데이터를 추출, 변환, 로드하는 과정	Extract, Transform, Load	데이터 통합의 기본 과정
스파크 (Spark)	대규모 데이터 처리를 위한 분산 컴퓨팅 프레임워크	Spark	하둡보다 100배 빠름 (메모리 사용)
폴리글랏 (Polyglot)	여러 프로그래밍 언어를 지원하는 능력	Polyglot	스파크가 여러 언어(Python, Scala 등) 지원
5 Vs of Big Data	빅데이터의 특징을 나타내는 다섯 가지 요소	Volume, Velocity, Veracity, Variety, Value	빅데이터의 본질 이해에 중요
Veracity	데이터의 정확성, 신뢰성, 유효성	Veracity	데이터 품질과 직결
개념적 데이터 모델	비즈니스 관점에서 데이터의 큰 그림을 정의	Conceptual Data Model	비즈니스 사용자 이해에 초점
논리적 데이터 모델	데이터 구조, 관계, 속성 유형을 상세히 정의	Logical Data Model	기술적 구현 전 단계
물리적 데이터 모델	실제 데이터 저장 방식에 맞춰 모델을 정의	Physical Data Model	특정 데이터베이스 기술에 의존
NoSQL	관계형 데이터베이스 외의 다양한 데이터 저장 방식	Not only SQL	유연한 스키마, 수평 확장성
메타데이터	데이터에 대한 데이터	Metadata	데이터 이해, 관리, 활용에 필수
데이터 카탈로그	메타데이터를 저장하고 관리하는 기술적 리소스	Data Catalog	데이터 검색, 거버넌스 지원
OLTP	온라인 트랜잭션 처리 시스템	Online Transaction Processing	실시간 트랜잭션, 빠른 읽기/쓰기
OLAP	온라인 분석 처리 시스템	Online Analytical Processing	대규모 데이터 분석, 복잡한 쿼리
스타 스키마	중앙의 팩트 테이블과 주변의 차원 테이블로 구성	Star Schema	분석 쿼리 성능 최적화
스노우플레이크 스키마	차원 테이블이 다른 차원 테이블을 참조하는 계층 구조	Snowflake Schema	데이터 정규화 수준 높음, 복잡성 증가
데이터 볼트	데이터 웨어하우스 모델링 기법 (허브, 링크, 위성)	Data Vault	변경 관리 및 감사에 강점
데이터 컨포먼스	데이터의 일관성과 표준화를 보장하는 과정	Data Conformance	분석 품질 향상에 필수
델타 레이크	파케이 파일 위에 ACID 트랜잭션 등을 추가한 프로토콜	Delta Lake	데이터브릭스의 핵심 데이터 형식
데이터 압축	정보 인코딩에 더 적은 비트를 사용하는 과정	Data Compression	저장 공간 절약, I/O 대역폭 감소
데이터 프로파일링	데이터의 품질, 구조, 관계를 분석하는 과정	Data Profiling	데이터 품질 문제 식별
RMSSE	예측값과 실제값 간의 평균 오차 크기를 측정하는 지표	Root Mean Square Scaled Error	모델 성능 평가 지표