

- 강의명: CSCI E-103: 재현 가능한 머신러닝
- 주차: Lecture 14
- 교수명: Anindita Mahapatra & Eric Gieseke
- 목적: Lecture 14의 핵심 개념 학습

- 강의명: Big Data Analysis & Engineering
- 주차: Day 14 - Databricks Roadmap & Review
- 교수명: Prof. & Teaching Staff
- 목적: Databricks의 최신 기능(Lakebase, AI/BI, Agent) 이해 및 Quiz 2, Assignment 3의 주요 개념(Spark 최적화, Streaming) 심층 리뷰

## Contents

|                                                            |          |
|------------------------------------------------------------|----------|
| <b>1 Databricks Data Intelligence Platform (Roadmap)</b>   | <b>2</b> |
| 1.1 주요 구성 요소 요약                                            | 2        |
| 1.2 Lakebase (Managed Postgres)                            | 2        |
| 1.3 AI/BI: Genie & Research Mode                           | 2        |
| 1.4 Apps & Model Serving                                   | 2        |
| <b>2 Quiz 2 Review: Spark &amp; Delta Lake Concepts</b>    | <b>3</b> |
| 2.1 Spark Optimization & Troubleshooting                   | 3        |
| 2.2 Delta Lake Internals                                   | 3        |
| 2.3 Data Frame Operations                                  | 3        |
| <b>3 Assignment 3 Review: Streaming &amp; Architecture</b> | <b>4</b> |
| 3.1 Kafka vs. Kinesis                                      | 4        |
| 3.2 Slowly Changing Dimensions (SCD)                       | 4        |
| 3.3 Spark Streaming Logic                                  | 4        |
| <b>4 Next Steps &amp; Action Items</b>                     | <b>4</b> |

# 1 Databricks Data Intelligence Platform (Roadmap)

이번 강의에서는 Databricks 로드맵에 포함된 최신 기능들을 다룹니다. 이 기능들은 주로 **Data Intelligence Capabilities**를 강화하여 플랫폼을 더 스마트하게 만들고 데이터 담당자의 업무를 줄이는 데 초점을 맞춥니다.

## 1.1 주요 구성 요소 요약

| Category         | Feature             | Description                                                         |
|------------------|---------------------|---------------------------------------------------------------------|
| Data Warehousing | Lakebase (Postgres) | Lakehouse 환경 내에서 OLTP 트랜잭션 처리를 지원하는 관리형 Postgres.                   |
| AI & Agents      | Agent Bricks        | AutoML처럼 데이터셋만 지정하면 에이전트를 자동 생성해주는 프레임워크.                           |
|                  | Genie               | 정형화된 "What" 질문에 대한 답변을 제공하는 BI 도구.                                  |
|                  | Research Mode       | 가설 기반의 "Why" 질문에 대해 Chain of Thought를 통해 심층 답변 제공.                  |
| Governance       | ABAC                | 속성 기반 접근 제어(Attribute-Based Access Control). PII 태그 등에 따라 자동 권한 부여. |
| Apps             | Lakehouse Apps      | 데이터가 있는 곳에서 바로 실행되는 Python(Streamlit 등) 기반 앱. 보안 및 확장성 보장.          |

Table 1: Databricks 주요 신규 기능 요약

## 1.2 Lakebase (Managed Postgres)

기존의 Databricks는 OLAP(분석용)에 최적화되어 있었으나, **Lakebase**의 도입으로 OLTP(트랜잭션용) 워크로드까지 커버하게 되었습니다.

- **구조적 특징:** Compute와 Storage가 분리되어 있습니다.
- **장점:**
  - 사용량이 늘어나면 Compute가 확장(Scale-up)되고, 사용하지 않으면 0으로 축소(Scale-to-Zero)되어 비용 효율적입니다.
  - Production과 Development 브랜치를 기본 제공하여, 운영 환경에 영향을 주지 않고 테스트가 가능합니다.
- **통합:** Unity Catalog와 연동되며, Lakehouse와 Lakebase 간 양방향 데이터 동기화(Reverse Sync)가 가능합니다.

## 1.3 AI/BI: Genie & Research Mode

- **Genie:** 정형 데이터에 대한 사실적 질문(Fact-based questions)을 SQL로 변환하여 답변합니다.
- **Research Mode:** "왜(Why)"에 대한 질문을 처리합니다. 단순 검색이 아니라 가설을 세우고 여러 경로를 탐색(Reasoning)하여 답변을 도출합니다. (예: "관세 인상이 포트폴리오에 미칠 영향은?")

## 1.4 Apps & Model Serving

- **Apps:** Streamlit, Flask 등으로 만든 앱을 데이터가 저장된 플랫폼 위에서 직접 구동합니다. 데이터 이동 없이 보안이 유지된 상태로 대시보드 이상의 상호작용(Write-back 등)이 가능합니다.
- **Model Serving:** 최신 LLM(Llama, Gemini, Claude 등)을 즉시 사용할 수 있도록 제공하며, MCP(Model Context Protocol) 서버를 통해 에이전트가 외부 도구나 데이터에 접근하도록 지원합니다.

## 2 Quiz 2 Review: Spark & Delta Lake Concepts

퀴즈에서 많이 혼동했던 Spark와 Delta Lake의 핵심 개념을 정리합니다.

### 2.1 Spark Optimization & Troubleshooting

1. **Spark 최적화 4대 요소:** Data Skew, Shuffle, Spill, Small Files.
2. **Broadcast Variables:**
  - **Immutable (불변):** 생성 후 변경할 수 없습니다.
  - **Local to Workers:** 클러스터 간 공유되는 것이 아니라, 각 워커 노드에 복사본이 저장됩니다.
3. **Repartition vs Coalesce:**
  - 파티션을 늘릴 때 (예: 12 → 24): 'repartition()' 사용 (Shuffle 발생).
  - 파티션을 줄일 때: 'coalesce()' 사용 (Shuffle 최소화).
4. **Action 함수 주의사항:**
  - 'collect()': 모든 데이터를 드라이버로 가져오므로 OOM(Out of Memory) 위험이 큼. 디버깅용으로만 사용 권장.
  - 'take(n)': 필요한  $n$  개 행만 가져오므로 대용량 데이터에서 안전함.

### 2.2 Delta Lake Internals

- **Transaction Log:** '*delta\_log*' .
- **구조:** 각 트랜잭션은 개별 **JSON 파일**로 기록됩니다. (하나의 JSON이 아님). 10번째 트랜잭션마다 Checkpoint(Parquet) 파일이 생성됩니다.
- **Time Travel:** 별도의 복사본을 만드는 것이 아니라, 트랜잭션 로그를 통해 과거 시점의 데이터 상태를 조회합니다.

### 2.3 Data Frame Operations

- **Explode:** DataFrame의 메서드가 아니라 'select' 문 내에서 사용해야 합니다. (예: 'df.select(explode(col))')
- **Drop Duplicates:** 'df.dropDuplicates(['col1', 'col2'])' 형태로 리스트를 전달해야 합니다.

### 3 Assignment 3 Review: Streaming & Architecture

#### 3.1 Kafka vs. Kinesis

| Feature | AWS Kinesis                      | Apache Kafka                             |
|---------|----------------------------------|------------------------------------------|
| 관리 주체   | AWS 완전 관리형 (Managed)             | Confluent (상용) 또는 Open Source (직접 관리)    |
| 확장 단위   | <b>Shard</b> (샤드 수에 따라 비용/성능 결정) | <b>Partition</b> (파티션 단위로 병렬 처리)         |
| 데이터 분배  | Partition Key 사용                 | Round-robin 또는 Key-Value 기반 Partitioning |

**Table 2:** *Kinesis*와 *Kafka* 비교

#### 3.2 Slowly Changing Dimensions (SCD)

- **Type 1:** 과거 데이터를 덮어씀(Overwrite). 이력 관리 안 됨.
- **Type 2:** 새로운 행을 추가하고 유효 기간(Start/End Date)이나 플래그(Current)를 두어 이력을 관리함.
- **Delta Merge:** ‘MERGE INTO’ 구문을 사용하여 변경된 컬럼(예: City)만 감지하고 업데이트/삽입 로직을 구현합니다.

#### 3.3 Spark Streaming Logic

- **Trigger 옵션:**
  - ‘trigger(once=True)’ : **Deprecated**.
  - ‘trigger(availableNow=True)’ : 권장됨. 데이터를 마이크로 배치로 나누어 처리하므로 클러스터 과부하를 방지합니다.
- **Checkpointing:** 스트리밍의 핵심. 시스템 중단 후 재시작 시 중단된 지점부터 정확히 다시 처리(Exactly-once)할 수 있게 해줍니다.
- **Image Processing:**
  - Spark Serverless 환경에서는 ‘display()’로 이미지를 직접 렌더링하지 못할 수 있습니다.
  - ‘pillow’ 라이브러리 등을 사용하여 바이너리 데이터를 이미지로 변환하거나 처리(Invert 등)하는 UDF를 작성해야 합니다.

### 4 Next Steps & Action Items

- **Assignment 4:** 다음 수업 전까지 최종 과제(Assignment 4)를 확인하고 준비할 것.
- **Guest Lecture:** 다음 수업에는 업계 전문가 초청 강연이 예정되어 있음.