

MIT 6.86x: 가장 안전한 경계선

Unit 3: Maximum Margin & SVM

Contents

1	Unit 3. 마진 최대화와 SVM (Maximum Margin & SVM)	2
1.1	1. 힙지 손실 (Hinge Loss)	2
1.2	2. SVM의 목적 함수 (Primal Formulation)	3
1.3	3. 정규화 (Regularization)와 Soft Margin	3
2	실전 시나리오: 자율주행 차선 인식	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 2: Linear Classifiers (틀리지만 않으면 됨)
- **Unit 3: Support Vector Machines (현재 단위: 가장 완벽하게 나누기)**
 - 3.1 Hinge Loss (확신을 갖는 학습)
 - 3.2 Margin Maximization (도로 폭 넓히기)
 - 3.3 Regularization (λ 의 역할)
- Unit 4: Feature Engineering (비선형 데이터 다루기)

1 Unit 3. 마진 최대화와 SVM (Maximum Margin & SVM)

*Unit 2*의 퍼셉트론은 훌륭했지만, "아무 선이나" 긋는다는 치명적인 단점이 있었습니다. 절벽 끝에 서 있어도 떨어지지만 않으면 안전하다고 판단했죠. *SVM*은 다릅니다. "절벽에서 적어도 $1m$ 는 떨어져 있어야 안전하다"라고 주장합니다. 이것이 바로 마진(Margin)입니다.

□ 개요 (Overview)

이 단원에서는 분류 경계면과 데이터 사이의 거리를 최대화하는 SVM(Support Vector Machine)을 배웁니다. 이를 위해 단순한 오분류(0/1 Loss) 대신 힙지 손실(Hinge Loss)을 도입하여 "여유 있는 정답"을 유도하고, 정칙화(Regularization)를 통해 이상치(Outlier)에 대처하는 유연한(Soft) 경계면을 만드는 법을 익힙니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Margin (마진)	결정 경계와 가장 가까운 데이터 사이의 거리 (도로 폭).
Support Vectors	도로의 경계선에 딱 붙어있는 데이터들 (결정적인 기준점).
Hinge Loss	"틀리면 혼나고, 아슬아슬하게 맞춰도 혼나는" 손실 함수.
Regularization (λ)	"마진을 넓힐래, 아니면 문제를 다 맞출래?" 사이의 조절 나사.

1.1 1. 힙지 손실 (Hinge Loss)

□ 개념 1: 턱걸이는 인정하지 않는다

한 줄 요약: 정답을 맞췄더라도, 경계선에서 충분히 멀리 떨어져 있지 않으면(확신이 없으면) 벌점을 부과합니다.

1) 직관적 비유: 낭떠러지 운전

- Perceptron (0/1 Loss): 바퀴가 낭떠러지에 걸치지만 않으면 OK. (위험천만)
- SVM (Hinge Loss): 낭떠러지에서 최소 $1m$ 이상 떨어져야 OK. $50cm$ 떨어져서 운전하면, 비록 떨어지진 않았지만 "위험했다"며 벌점을 줍니다.

2) 수식과 해석

$$Loss(y, z) = \max(0, 1 - yz), \quad (z = \theta \cdot x)$$

- $yz \geq 1$ (안전): 정답을 맞췄고 여유 공간(Margin)도 1 이상임. $\rightarrow Loss = 0$.

- $0 < yz < 1$ (불안): 정답은 맞췄지만 경계선에 너무 붙어있음. → **Loss 발생** ($0 \sim 1$).
- $yz < 0$ (오답): 틀렸음. → **Loss 큼** (1 이상).

그래프 모양이 문의 경첩(Hinge)처럼 꺾여 있어서 힌지 손실이라 부릅니다.

1.2 2. SVM의 목적 함수 (Primal Formulation)

□ 개념 2: 도로 확장 공사

한 줄 요약: 도로의 폭(Margin)을 넓히는 것은 수학적으로 법선 벡터의 길이 $\|\theta\|$ 를 줄이는 것과 같습니다.

1) 기하학적 원리

점 x 에서 초평면 $\theta \cdot x = 0$ 까지의 거리는 $\frac{|\theta \cdot x|}{\|\theta\|}$ 입니다. 우리가 "안전 기준"을 1로 잡았으므로($|\theta \cdot x| \geq 1$), 마진 거리는 최소 $\frac{1}{\|\theta\|}$ 가 됩니다.

- 마진 최대화 ($\max \frac{1}{\|\theta\|}$) $\iff$ 벡터 길이 최소화 ($\min \|\theta\|^2$)

2) 최적화 문제 (Hard Margin)

$$\min_{\theta} \frac{1}{2} \|\theta\|^2$$

$$\text{subject to } y^{(i)}(\theta \cdot x^{(i)} + \theta_0) \geq 1 \quad (\forall i)$$

이 식은 2차 함수(Quadratic)이므로, 오목/볼록이 확실하여 **유일한 해(Global Optimum)**가 존재합니다.

1.3 3. 정칙화 (Regularization)와 Soft Margin

□ 개념 3: 융통성 있는 보안관

한 줄 요약: 완벽한 분리가 불가능할 때, "도로를 침범하는 것"을 일부 허용하되 벌금을 물려서 균형을 맞춥니다.

1) 현실의 문제 (Noise)

데이터에 노이즈가 섞여 있다면, 완벽하게 두 그룹을 나누는 직선은 존재하지 않거나 아주 구불구불한 억지스러운 선이 됩니다(과적합).

2) 해결책: Soft Margin SVM

$$J(\theta) = \underbrace{\frac{\lambda}{2} \|\theta\|^2}_{\text{마진 최대화}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \max(0, 1 - y^{(i)}(\theta \cdot x^{(i)}))}_{\text{에러 최소화 (힌지 손실)}}$$

3) λ 의 역할 (Trade-off 조절)

λ 는 "마진(안전)"을 얼마나 중요하게 생각하는지 나타내는 파라미터입니다.

- λ 가 큼 (Regularization 중시): "에러가 좀 나더라도 도로를 넓게 써라." → 단순한 모델, 과소적합(Underfitting) 주의.
- λ 가 작음 (Error 최소화 중시): "도로가 좁아져도 좋으니 데이터 하나하나 다 맞춰라." → 복잡한 모델, 과적합(Overfitting) 주의.

2 실전 시나리오: 자율주행 차선 인식

□ Scenario: 넥슨 카트라이더 자율주행 모드

당신은 카트라이더의 AI 주행 보조 시스템을 개발합니다. 트랙 위에서 "주행 가능 구역(Positive)"과 "벽/장애물(Negative)"을 구분해야 합니다.

1. **Perceptron 적용 시:** 경계선을 벽에 딱 붙어서 굽습니다. 조금만 미끄러지면 바로 충돌 사고가 납니다. (불안정)
2. **SVM 적용 시:** 벽에서 최대한 멀리 떨어진 중앙선(Margin 최대화)을 찾습니다. 약간 미끄러져도(Noise) 충돌하지 않습니다. (안정적)
3. **Soft Margin 상황:** 트랙 중간에 바나나 껍질(Outlier)이 하나 떨어져 있습니다.
 - **Hard Margin:** 바나나를 피하려고 핸들을 급격히 꺾다가 오히려 사고가 납니다.
 - **Soft Margin:** "저건 그냥 이상치야"라고 무시하고(Loss 함수), 부드럽게 밟고 지나가면서 전체적인 주행 라인을 유지합니다.

3 자주 묻는 질문 (FAQ)

- Q1. 왜 마진을 최대화하는데 $\|\theta\|$ 를 최소화하나요? A.** 마진 공식이 $\frac{1}{\|\theta\|}$ 이기 때문입니다. 분모가 작아져야 전체 값이 커집니다. 기하학적으로는 θ 벡터의 길이가 짧아질수록, 결정 경계면($\theta \cdot x = 1$)이 원점에서 멀어지기 때문입니다.
- Q2. 힌지 손실의 미분은 어떻게 하나요? 꺾인 점이 있잖아요. A.** 맞습니다. $z = 1$ 인 지점에서는 미분 불가능합니다. 그래서 '서브그라디언트(Subgradient)'라는 개념을 사용합니다. 꺾인 점에서는 미분값을 0과 -1 사이의 임의의 값(보통 둘 중 하나)으로 정의해서 넘어갑니다.

Next Step: SVM은 직선(초평면)으로 데이터를 나누는 최강의 도구입니다. 하지만 데이터가 도넛 모양이나 소용돌이 모양이라면요? 직선으로는 절대 못 나눕니다. 다음 **Unit 4**에서는 데이터를 고차원으로 보내서 휘어진 경계면을 만드는 마법, 커널(Kernel) 기법과 특징 공학(Feature Engineering)을 배웁니다.

Unit 3 핵심 요약

- **목표:** 단순 분류가 아니라, 가장 안전한 분류(Max Margin)를 한다.
- **Hinge Loss:** $\max(0, 1 - yz)$. 1 이상의 여유를 갖고 맞추도록 강제한다.
- **Primal Objective:** $\min \frac{\lambda}{2} \|\theta\|^2 + \text{Loss}$. 마진과 에러의 균형을 찾는다.
- λ : 모델의 단순함(마진)과 정확함(에러) 사이의 트레이드오프를 조절한다.