

MIT 6.86x: 가장 낮은 곳을 향하여

Unit 4: Optimization (최적화)

Contents

1	Unit 4. 최적화 방법론 (Optimization)	2
1.1	1. 경사 하강법 (Gradient Descent, GD)	2
1.2	2. 확률적 경사 하강법 (Stochastic Gradient Descent, SGD)	3
1.3	3. SGD의 수렴성과 학습률 스케줄링	3
2	실전 시나리오: 넷플릭스 추천 시스템 학습	4
3	자주 묻는 질문 (FAQ)	4

Course Structure & Current Focus

- Unit 2, 3: Modeling (목적 함수 $J(\theta)$ 정의)
- **Unit 4: Optimization (현재 단원: $J(\theta)$ 를 최소화하는 θ^* 찾기)**
 - 4.1 Gradient Descent (안개 낀 산 내려오기)
 - 4.2 Stochastic Gradient Descent (빠르고 거친 이동)
 - 4.3 Convergence & Learning Rate (멈추는 기술)
- Unit 5: Non-linear Classification (Neural Nets)

1 Unit 4. 최적화 방법론 (Optimization)

*Unit 3*에서 우리는 "마진을 최대화하라"는 멋진 목표(목적 함수)를 세웠습니다. 하지만 목표만 있다고 문제가 풀리지는 않습니다. 서울(현재 파라미터)에서 부산(최적 파라미터)을 가야 하는데, 지도도 없고 나침반(기울기)만 하나 덜렁 있는 상황입니다. 이번 단원에서는 이 나침반 하나에 의지해 가장 낮은 계곡을 찾아가는 알고리즘을 배웁니다.

□ 개요 (Overview)

이 단원에서는 손실 함수 $J(\theta)$ 의 최솟값을 찾기 위한 두 가지 핵심 알고리즘, **경사 하강법 (GD)**과 **확률적 경사 하강법 (SGD)**을 다룹니다. 특히 딥러닝의 표준인 SGD가 왜 수학적으로 정당한지 (Unbiased Estimator), 그리고 진동하는 SGD를 어떻게 수렴시킬 것인지 (Learning Rate Decay)에 대한 이론적 배경을 학습합니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Gradient (∇J)	현재 위치에서 가장 가파르게 올라가는 방향. (우리는 반대로 감)
Learning Rate (η)	한 걸음의 보폭. 너무 크면 발산하고 너무 작으면 느리다.
Batch GD	한 걸음 갈 때마다 모든 데이터를 다 읽고 신중하게 가는 방법.
SGD	데이터 하나만 보고 "이쪽인 것 같아!" 하고 뛰어가는 방법.
Epoch	전체 데이터를 한 번 훑어보는 단위.

1.1 1. 경사 하강법 (Gradient Descent, GD)

□ 개념 1: 안개 낀 산에서 내려오기

한 줄 요약: 현재 위치에서 발밑을 더듬어 경사가 가장 급한 쪽으로 한 걸음씩 내려 갑니다.

1) 알고리즘

전체 데이터셋 S_n 에 대한 평균 손실 함수의 기울기를 계산합니다.

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} J(\theta_t)$$

- **마이너스(-)의 의미:** 기울기는 '올라가는' 방향이므로, 내려가기 위해 반대로 이동합니다.
- **수학적 원리:** 테일러 급수 1차 근사(선형 근사)에 의해, η 가 충분히 작다면 함수값 감소가 보장됩니다.

2) 치명적인 단점 (Computational Bottleneck)

한 걸음($t \rightarrow t+1$)을 떼기 위해 n 개의 데이터를 모두 미분해야 합니다.

- $n = 1,000,000$ 이면, 1보 전진을 위해 100만 번 계산해야 합니다. ($O(n)$ Cost)
- 너무 느려서 빅데이터 학습에는 사용할 수 없습니다.

1.2 2. 확률적 경사 하강법 (Stochastic Gradient Descent, SGD)

□ 개념 2: 술 취한 사람의 귀가

한 줄 요약: 전체의 의견을 듣지 않고, 지나가는 사람(데이터) 한 명 붙잡고 길을 물어서 갑니다. 비틀거리지만(Noisy), 결국 집(최적해)으로 갑니다.

1) 아이디어

”기울기의 평균을 구하나, 샘플 하나만 뽑아서 구하나, 기댓값은 같지 않을까?”

2) 업데이트 규칙

랜덤하게 데이터 i 를 하나 뽑아서 업데이트합니다.

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \text{Loss}(x^{(i)}, y^{(i)}; \theta_t)$$

- **비용:** $O(n) \rightarrow O(1)$ 로 획기적 감소.
- **속도:** GD가 1 걸음 갈 때, SGD는 n 걸음을 갈 수 있습니다.

3) 수학적 정당성 (Unbiased Estimator)

개별 데이터의 기울기는 전체 기울기의 **비편향 추정량(Unbiased Estimator)**입니다.

$$\mathbb{E}[\nabla \text{Loss}(x^{(i)})] = \nabla J(\theta)$$

즉, 한 번 한 번은 엉뚱한 방향일 수 있어도(High Variance), 평균적으로는 올바른 방향을 가리킵니다.

1.3 3. SGD의 수렴성과 학습률 스케줄링

□ 개념 3: 멈추는 법을 배워라

한 줄 요약: GD는 바닥에 오면 알아서 멈추지만, SGD는 바닥에서도 계속 진동합니다. 따라서 갈수록 보폭(η)을 줄여야 합니다.

1) GD vs SGD의 경로 비교

- **GD:** 등고선의 수직 방향으로 부드러운 곡선을 그리며 최솟값에 안착.
- **SGD:** 지그재그로 요동치며 (Fluctuation) 이동. 최솟값 근처에서도 멈추지 않고 주변을 맴돌.

2) 로빈스-몬로 조건 (Robbins-Monro Conditions)

SGD가 수학적으로 수렴하기 위한 학습률 η_t 의 조건입니다.

1. $\sum \eta_t = \infty$: (도달 가능성) 보폭의 합은 무한대여야 합니다. (시작점이 아무리 멀어도 갈 수 있어야 함).
2. $\sum \eta_t^2 < \infty$: (수렴 가능성) 보폭 제곱의 합은 유한해야 합니다. (점점 줄어들어 진동이 멈춰야 함).

대표적인 스케줄: $\eta_t = \frac{1}{t}$ 또는 $\eta_t = \frac{C}{t+\text{offset}}$.

2 실전 시나리오: 넷플릭스 추천 시스템 학습

□ Scenario: 수억 명의 시청 기록 학습

당신은 전 세계 2억 명의 유저 데이터를 이용해 추천 알고리즘을 학습시킵니다.

1. **Batch GD 시도:** 파라미터를 한 번 업데이트하려면 2억 개의 로그를 다 읽어야 합니다. → 1 Epoch 도는데 일주일 걸림. 학습 불가.
2. **SGD 적용:** 유저가 영상을 클릭할 때마다 즉시 그 데이터 하나로 파라미터를 미세 조정합니다. → 실시간으로 모델이 학습되며, 1시간 만에 괜찮은 성능에 도달.
3. **문제 발생 (진동):** 학습 후반부에 정확도가 오르락내리락하며 불안정합니다.
4. **해결 (Learning Rate Decay):** 학습률을 처음엔 0.1로 하다가, 에폭마다 0.1배씩 줄여나갑니다 (Annealing). → 진동이 잦아들며 최고 성능 (Global Minima 근처)에 안착.

3 자주 묻는 질문 (FAQ)

- Q1. SGD가 GD보다 정확도는 떨어지나요?** A. 이론적으로는 GD가 더 정밀하게 최솟값을 찾을 수 있습니다. 하지만 SGD의 '노이즈'가 오히려 장점이 되기도 합니다. GD는 얕은 함정 (Local Minima)에 빠지면 못 나오지만, SGD는 비틀거리는 특성 덕분에 함정을 탈출하여 더 좋은 해 (Global Minima)를 찾을 확률이 높습니다.

Q2. Mini-batch는 뭔가요? A. GD(전체)와 SGD(1개)의 절충안입니다. 데이터 32개나 64개씩 묶어서 업데이트하는 방식입니다.

- SGD보다 노이즈가 적어 안정적이고,
- 행렬 연산(GPU)을 활용해 속도도 빠릅니다.
- 현대 딥러닝은 99% 이 **Mini-batch SGD**를 사용합니다.

Next Step: 최적화라는 엔진을 달았으니, 이제 더 복잡한 모델을 만들어볼까요? 직선(선형 분류기)으로는 XOR 문제를 풀 수 없습니다. 다음 **Unit 5**에서는 선형 분류기를 여러 층 쌓아서 곡선 경계를 만드는 **신경망(Neural Networks)**과 딥러닝의 기초를 배웁니다.

Unit 4 핵심 요약

- **Gradient Descent (GD):** 전체 데이터 사용. 안정적이지만 $O(n)$ 으로 느리다.
- **Stochastic GD (SGD):** 데이터 1개 사용. $O(1)$ 로 빠르지만 불안정(Noisy)하다.
- **Unbiased Estimator:** SGD의 기댓값은 GD와 같다. (평균적으로는 바른 방향).
- **Step Size Schedule:** SGD의 진동을 잡기 위해 학습률 η_t 를 점점 줄여야 한다 (Decay).