

MIT 6.86x: 차원의 저주를 피하는 지름길

Unit 6: Kernel Methods (커널 방법)

Contents

1	Unit 6. 커널 방법 (Kernel Methods)	2
1.1	1. 듀얼 문제 (Dual Problem)와 내적의 발견	2
1.2	2. 커널 트릭 (Kernel Trick)	3
1.3	3. 대표적인 커널: 가우시안 (RBF) 커널	3
1.4	4. 커널 SVM (Kernel SVM)	4
2	실전 시나리오: 넥슨 게임 봇(Bot) 탐지	5
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 3: SVM (최적의 직선 찾기)
- Unit 5: Feature Engineering (고차원 변환 $\phi(x)$)
- **Unit 6: Kernel Methods (현재 단원: 계산 비용 없이 고차원 효과 내기)**
 - 6.1 Dual Problem (내적의 발견)
 - 6.2 The Kernel Trick (지름길)
 - 6.3 RBF Kernel (무한 차원의 마법)
 - 6.4 Kernel SVM (비선형 분류의 완성)
- Unit 7: Neural Networks (딥러닝)

1 Unit 6. 커널 방법 (Kernel Methods)

*Unit 5*에서 우리는 데이터를 고차원으로 매핑($\phi(x)$)하면 선형 분리가 가능해진다는 것을 배웠습니다. 하지만 100차원의 데이터를 2차 다항식으로만 확장해도 특징이 수천 개로 늘어나고, 계산 속도는 거북이가 됩니다. "고차원의 혜택은 누리면서, 계산은 저차원에서 빠르게 할 수는 없을까?" 이 말도 안 되는 욕심을 수학적으로 실현한 것이 바로 커널 트릭입니다.

□ 개요 (Overview)

커널 방법은 SVM의 최적화 문제를 **듀얼(Dual)** 형태로 변형하여, 데이터가 오직 **내적(Dot Product)** 형태로만 등장한다는 점을 이용합니다. 이를 통해 데이터를 실제로 고차원으로 변환하지 않고도 고차원 공간에서의 내적값을 계산해주는 **커널 함수(Kernel Function)**를 도입, 계산 비용을 획기적으로 줄이면서도 복잡한 비선형 경계면을 만들어 냅니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Primal Problem	원래 문제. w, b 를 찾자. 데이터 좌표 x 가 직접 쓰임.
Dual Problem	쌍대 문제. α (가중치)를 찾자. 데이터 간 유사도(내적)만 쓰임.
Kernel Trick	고차원 계산 결과를 저차원에서 즉시 알아내는 마법의 함수.
RBF Kernel	두 점 사이의 거리를 이용해 유사도를 측정하는 커널 (가우시안).
Feature Space	실제로 가진 않지만, 수학적으로 존재하는 가상의 고차원 공간.

1.1 1. 듀얼 문제 (Dual Problem)와 내적의 발견

□ 개념 1: 관점의 전환

한 줄 요약: "데이터의 절대적 위치(좌표)"는 중요하지 않습니다. "데이터끼리 얼마나 닮았나(내적)"가 중요합니다.

1) Primal vs Dual

SVM의 목적식을 라그랑주 승수법을 이용해 변형하면 다음과 같은 듀얼 문제가 됩니다.

$$\max_{\alpha} \sum \alpha_i - \frac{1}{2} \sum_{i,j} y^{(i)} y^{(j)} \alpha_i \alpha_j (\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)})$$

2) 핵심 발견

위 식을 자세히 보세요. 데이터 x 가 단독으로 쓰이지 않고, 반드시 두 데이터의 내적 ($\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}$) 형태로만 등장합니다.

- 내적(Dot Product)은 기하학적으로 유사도(Similarity)를 의미합니다.
- 즉, 분류 경계선을 찾기 위해 필요한 것은 좌표가 아니라 유사도 정보뿐입니다.

1.2 2. 커널 트릭 (Kernel Trick)

□ 개념 2: 웜홀(Wormhole) 타기

한 줄 요약: $\phi(x)$ 를 계산해서 고차원으로 날아간 뒤 내적하고 다시 돌아오는 대신, 그냥 땅바닥에서 $K(x, z)$ 만 계산하면 똑같은 결과가 나옵니다.

1) 문제 상황 (The Hard Way)

데이터 x, z 를 고차원으로 보낸 뒤 내적하려면:

1. 변환: $x \rightarrow \phi(x), z \rightarrow \phi(z)$ (엄청난 연산 비용)
2. 내적: $\phi(x) \cdot \phi(z)$ (엄청난 연산 비용)

2) 해결책 (The Smart Way)

다음 성질을 만족하는 함수 K 를 찾습니다.

$$K(x, z) = \phi(x) \cdot \phi(z)$$

이제 우리는 ϕ 를 몰라도, K 만 계산하면 됩니다.

- 예: 다항식 커널 $K(x, z) = (x \cdot z + 1)^2$
- 이걸 전개해보면 실제로 2차 다항식 특징들의 내적과 수학적으로 동일함이 증명됩니다. 하지만 계산은 단순히 숫자 곱셈 한 번이면 끝납니다.

1.3 3. 대표적인 커널: 가우시안 (RBF) 커널

□ 개념 3: 무한 차원의 마법

한 줄 요약: 데이터 주변에 산봉우리(유사도)를 세워서 지형을 만듭니다. 이는 수학적으로 데이터를 무한대 차원으로 보낸 것과 같습니다.

1) 수식

$$K(x, z) = \exp(-\gamma \|x - z\|^2)$$

- **의미:** 두 점 x, z 사이의 유클리드 거리가 가까우면 1, 멀면 0에 수렴. (유사도 측정)
- **γ (Gamma):** 산봉우리의 뾰족한 정도. γ 가 크면 아주 뾰족한 산(Overfitting 위험), 작으면 완만한 언덕.

2) 왜 무한 차원인가?

지수 함수 e^x 를 테일러 급수(Taylor Series)로 전개하면 $1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots$ 처럼 무한한 다항식의 합이 됩니다. 즉, RBF 커널을 쓴다는 것은 모든 차수의 다항식 특징을 다 고려한다는 뜻과 같습니다.

1.4 4. 커널 SVM (Kernel SVM)

□ 개념 4: 휘어지는 경계선

한 줄 요약: 고차원에서는 평면으로 잘랐지만, 이를 다시 원래 차원으로 투영해보면 꼬불꼬불한 곡선이 되어 있습니다.

작동 원리

1. 데이터는 선형 분리 불가능한 복잡한 형태입니다.
2. 커널 함수 K 를 사용하여 듀얼 문제를 푹니다. (실제 변환 없이 고차원 내적 값만 사용)
3. 최적의 α (가중치)를 찾습니다.
4. 새로운 데이터 u 가 들어오면 판별 함수는 다음과 같습니다:

$$h(u) = \text{sign} \left(\sum_{i \in SV} \alpha_i y^{(i)} K(x^{(i)}, u) + b \right)$$

5. **해석:** 새로운 데이터 u 가 기존의 중요한 데이터들(Support Vectors)과 얼마나 유사한지(K)를 측정하고, 가중치 투표를 통해 분류합니다.

2 실전 시나리오: 넥슨 게임 봇(Bot) 탐지

□ Scenario: 인간과 봇의 움직임 구분

당신은 '던전앤파이터'의 보안팀입니다. 봇들의 마우스 이동 경로를 분석하여 차단하려 합니다.

1. 데이터: 마우스의 (x, y) 좌표 이동 궤적.
2. 특징:
 - 봇: 기계적으로 정확하게 움직이지만, 가끔 랜덤 노이즈를 섞어서 선형적으로 구분이 안 됨.
 - 인간: 불규칙하지만 자연스러운 곡선을 그림.
3. 선형 SVM 실패: 직선으로는 복잡한 궤적 패턴을 나눌 수 없음.
4. 다항식 특징 시도: $x^2, y^2, xy \dots$ 몇 차까지 늘려야 할지 모르겠고 계산이 너무 느림.
5. RBF 커널 SVM 적용:
 - "특정 봇 패턴($x^{(i)}$)과 거리가 가까우면(유사하면) 봇이다"라는 논리로 접근.
 - 무한 차원의 특징을 고려하므로 아주 미세하고 복잡한 '봇만의 영역'을 곡선으로 도려내듯 찾아냄.
6. 결과: 봇 탐지율 99% 달성. (단, γ 튜닝이 중요했음).

3 자주 묻는 질문 (FAQ)

- Q1. 어떤 커널을 써야 할지 어떻게 아나요?** A. 정답은 없지만, RBF 커널이 가장 무난하고 강력해서 기본값(Default)으로 쓰입니다. 텍스트 데이터처럼 희소(Sparse)한 경우에는 선형 커널(Linear Kernel)이 더 좋을 때도 있습니다. 결국 교차 검증(Cross Validation)으로 찾아야 합니다.
- Q2. RBF 커널은 무한 차원이라는데 과적합 안 되나요?** A. 될 수 있습니다! 그래서 규제 파라미터 C (Cost)와 커널 파라미터 γ (Gamma)를 잘 조절해야 합니다.
- γ 가 크면: 내 주변 데이터만 신경 씀 $\rightarrow$ 섬세한 경계 $\rightarrow$ 과적합.
 - γ 가 작으면: 멀리 있는 데이터까지 신경 씀 $\rightarrow$ 뭉뚱그린 경계 $\rightarrow$ 과소적합.

Next Step: 커널 SVM은 강력하지만, 데이터가 많아지면 ($n > 100,000$) 내적 계산량이 많아져서 느려집니다. 이 한계를 극복하고, 빅데이터에서도 복잡한 패턴을 스스로 학습하는 끝판왕 모델, **Unit 7: 신경망(Neural Networks)** 과 딥러닝으로 넘어갑니다.

Unit 6 핵심 요약

- **Dual Problem:** SVM은 데이터의 좌표가 아니라 '내적(유사도)'만 있으면 풀 수 있다.
- **Kernel Trick:** $K(x, z) = \phi(x) \cdot \phi(z)$. 고차원 변환 없이 고차원 내적값을 계산하는 지름길.
- **RBF Kernel:** 거리 기반 유사도 측정. 무한 차원으로 매핑하는 효과를 낸다.
- **장점:** 저차원의 계산 비용으로 고차원의 분류 성능을 얻는다.