

MIT 6.86x: 정답 없는 세계의 질서

Unit 4: Unsupervised Learning - Clustering

Contents

1	Unit 4. 군집화 (Clustering)	2
1.1	1. K-Means 알고리즘과 좌표 하강법	2
1.2	2. K-Medoids 알고리즘	3
2	실전 시나리오: 넥슨 유저 세분화 (User Segmentation)	3
3	자주 묻는 질문 (FAQ)	4

Course Structure & Current Focus

- Unit 1 3: Supervised Learning (정답 y 가 있는 학습)
- **Unit 4: Unsupervised Learning (현재 단원: 정답 y 가 없는 학습)**
 - 11.1 K-Means Algorithm (좌표 하강법 관점)
 - 11.2 K-Medoids (이상치에 강건한 방법)
 - 11.3 Hierarchy Clustering (계층적 군집화)
- Unit 5: Generative Models (데이터 생성)

1 Unit 4. 군집화 (Clustering)

지금까지 우리는 선생님이 채점해주는 (*Label*이 있는) 문제를 풀었습니다. 하지만 현실 세계 데이터의 90%는 정답지가 없습니다. 넥슨의 로그 데이터도 "이 유저는 하드코어 유저다"라고 써붙여져 있지 않죠. 이제 우리는 아무도 가르쳐주지 않은 상태에서, 데이터끼리 뭉쳐있는 구조 (*Structure*)를 스스로 찾아내는 방법을 배웁니다.

□ 개요 (Overview)

군집화는 유사한 데이터끼리 그룹을 묶는 기술입니다. 가장 대표적인 **K-Means** 알고리즘을 단순한 반복 절차가 아닌 **좌표 하강법 (Coordinate Descent)**이라는 최적화 이론으로 해석하고, 평균 (Mean)의 한계를 극복하기 위한 **K-Medoids** 알고리즘을 비교 학습합니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Centroid (μ)	클러스터의 중심점. (무게 중심)
Assignment (r)	"너는 A 팀, 재는 B 팀"이라고 배정하는 변수.
Inertia (Cost J)	각 팀원들이 중심점으로부터 떨어진 거리의 제곱 합. (응집도)
Coordinate Descent	x, y 를 동시에 못 찾으니까, x 고정하고 y 찾고, y 고정하고 x 찾는 전략.
Medoid	클러스터를 대표하는 실제 데이터 포인트. (반장)

1.1 1. K-Means 알고리즘과 좌표 하강법

□ 개념 1: 깃발 꽂기 게임

한 줄 요약: 깃발(중심)을 꽂고 사람들이 가장 가까운 깃발로 모입니다. 사람이 모인 곳의 한가운데로 깃발을 다시 옮깁니다. 이를 반복합니다.

1) 작동 원리 (The Iterative Process)

1. **초기화:** K 개의 중심점 (μ)을 랜덤하게 찍습니다.
2. **할당 (Assignment):** 모든 데이터는 가장 가까운 중심점 소속이 됩니다.
3. **업데이트 (Update):** 각 그룹의 무게중심(평균)으로 중심점을 이동시킵니다.
4. **반복:** 중심이 안 움직일 때까지 2 3번을 반복합니다.

2) 수학적 해석: 좌표 하강법 (Coordinate Descent)

이 직관적인 과정은 사실 엄밀한 수학적 최적화입니다.

$$J(r, \mu) = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|x_n - \mu_k\|^2$$

이 함수 J 를 최소화해야 하는데, 변수 r (소속)과 μ (위치)가 서로 얽혀 있어서 미분이 불가능합니다. 그래서 하나를 고정(Freeze)하고 나머지를 최적화하는 전략을 씁니다.

- **Step 1 (r 최적화):** μ 를 고정.

$$\min_r J \implies \text{각 데이터를 가장 가까운 } \mu_k \text{에 할당.}$$

- **Step 2 (μ 최적화):** r 을 고정.

$$\min_{\mu} J \implies \mu_k \text{를 해당 그룹 데이터들의 평균(Mean)으로 이동.}$$

이 과정은 J 값을 계단식으로 계속 낮추며, 더 이상 낮아지지 않는 지역 최적해(Local Minimum)에 반드시 수렴합니다.

1.2 2. K-Medoids 알고리즘

□ 개념 2: 평균의 함정과 실제 대표 선출

한 줄 요약: K-Means는 허공에 있는 평균을 중심으로 잡지만, K-Medoids는 실제 데이터 중 하나를 대장(Representative)으로 뽑습니다.

1) K-Means의 치명적 약점 (Outliers)

데이터가 (1, 1), (2, 2), (3, 3) 그리고 저 멀리 (100, 100)에 하나 있다고 합시다.

- **K-Means (μ):** 평균은 약 (26, 26)이 됩니다. 중심점이 데이터가 모인 곳을 떠나 엉뚱한 곳에 위치하게 됩니다. (이상치에 민감)
- **K-Medoids:** 중간값인 (2, 2) 혹은 (3, 3)을 대표로 삼습니다. (100, 100)은 무시됩니다. (강건함)

2) 비교 분석

2 실전 시나리오: 넥슨 유저 세분화 (User Segmentation)

□ Scenario: 고래(Whale) 유저와 일반 유저 분류

당신은 게임 내 유저들을 '과금러', '즐거러', '폐인' 등으로 자동 분류하고 싶습니다.

특징	K-Means	K-Medoids (PAM)
중심점	평균 (가상의 좌표)	Medoid (실제 데이터)
계산 속도	매우 빠름 ($O(N)$)	느림 ($O(N^2)$)
이상치	매우 민감함 (취약)	강건함 (Robust)
적용	일반적인 대용량 데이터	노이즈가 많은 데이터

1. 데이터: [플레이 시간, 결제 금액]

2. K-Means 적용 시도:

- 한 명의 '슈퍼 과금러(10억 원 결제)'가 데이터에 포함되어 있습니다.
- K-Means의 중심점(평균)이 이 사람 쪽으로 쭉욱 끌려갑니다.
- 결과: 일반 과금 유저(10만 원)들이 '무과금 그룹'으로 잘못 분류되고, '고래 그룹'은 범위가 너무 넓어집니다.

3. K-Medoids 전환:

- 중심점을 실제 유저 중에서 뽑습니다.
- 슈퍼 과금러는 그냥 하나의 점일 뿐, 중심(대표 유저)을 바꾸지 못합니다.
- 결과: 대다수의 일반 유저 패턴을 반영한 합리적인 그룹핑이 완성됩니다.

3 자주 묻는 질문 (FAQ)

Q1. K(그룹 개수)는 어떻게 정하나요? A. 가장 어려운 문제입니다. 보통 **Elbow Method**를 씁니다. K 를 1부터 늘려가며 J (거리 제곱 합)를 그려봅니다. K 가 늘면 J 는 무조건 줄어드는데, 줄어드는 폭이 급격히 둔화되어 팔꿈치처럼 꺾이는 지점을 선택합니다.

Q2. K-Means는 항상 정답을 찾나요? A. 아닙니다. 초기값을 어디에 찍느냐에 따라 결과가 달라집니다(Local Optima 문제). 그래서 보통 'K-Means++' 같은 초기화 기법을 쓰거나, 랜덤 초기화로 여러 번 돌려서 가장 좋은 결과를 선택합니다.

Next Step: K-Means는 데이터를 "너는 A팀, 너는 B팀"식으로 딱 잘라 말합니다(Hard Clustering). 하지만 "이 유저는 A팀 성향 70%, B팀 성향 30%야"라고 확률적으로 말할 순 없을까요? 다음 시간에는 통계적 군집화 방법인 **GMM (Gaussian Mixture Models)**과 이를 푸는 **EM 알고리즘**을 배웁니다.

Unit 4 핵심 요약

- **Clustering:** 정답 없이 데이터의 구조를 찾는 비지도 학습.
- **K-Means:** 중심 할당 $\leftrightarrow$ 중심 이동을 반복하는 좌표 하강법 알고리즘.
- **Coordinate Descent:** 변수들을 한 번에 최적화하기 어려울 때, 하나씩 번갈아 가며 최적화하는 기법.
- **K-Medoids:** 평균 대신 실제 데이터를 대표로 사용하여 이상치에 강하다.