

MIT 6.86x: 경험으로 완성하는 지능

Unit 5 (Part B): Q-Learning & Deep Q-Networks

Contents

1	Unit 5 (Part B). Q-러닝 (Q-Learning)	2
1.1	1. Q-러닝의 핵심: Q-테이블과 업데이트	2
1.2	2. 탐험 (Exploration) vs 활용 (Exploitation)	3
1.3	3. 딥 Q-네트워크 (DQN, Deep Q-Network)	4
2	실전 시나리오: 넥슨 카트라이더 AI	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 5 (Part A): RL Basics (MDP, Bellman Eq - 룰을 알 때)
- **Unit 5 (Part B): Q-Learning (현재 단위: 룰을 모를 때)**
 - 14.1 Q-Function & Q-Table (컨닝 페이퍼 만들기)
 - 14.2 Exploration vs Exploitation (모험과 안주)
 - 14.3 Deep Q-Network (테이블을 뇌로 교체하다)
- Unit 6: Unsupervised Learning (군집화)

1 Unit 5 (Part B). Q-러닝 (Q-Learning)

지난 파트(MDP)에서는 "확률 P 를 아니, 계산만 하면 답이 나온다"고 했습니다. 하지만 여러분이 '카트라이더'를 처음 할 때, 드리프트 마찰 계수 공식을 알고 게임을 하나요? 아닙니다. 일단 박아보고 (Fail), 완주해보며 (Success) 몸으로 배웁니다. 이번 단원에서는 환경의 규칙을 모르는 상태에서 오직 경험 (Experience)만으로 최적의 전략을 학습하는 Q-러닝을 배웁니다.

□ 개요 (Overview)

Q-러닝은 "Model-free(환경 모델 없음)" 강화 학습의 대표 주자입니다. 에이전트는 Q-함수(행동 가치 함수)를 정의하고, 시행착오를 통해 이 값을 갱신해 나갑니다. 이 과정에서 필연적으로 발생하는 탐험(Exploration)과 활용(Exploitation)의 딜레마를 해결하는 전략과, 테이블 방식의 한계를 딥러닝으로 극복한 DQN까지 다룹니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Q-Function $Q(s, a)$	"상태 s 에서 a 를 하면, 나중에 총 몇 점 받을까?" (예상 점수)
Model-free	게임의 룰(물리 법칙 등)을 몰라도 학습 가능함.
Temporal Difference (TD)	"직접 해보니 내 예상이랑 이만큼 다르네?" (예측 오차)
Exploration	아는 길 말고 새로운 길 가보기. (도전)
Exploitation	아는 길 중 제일 좋은 길 가기. (안주)
DQN	Q값 적는 표(Table)가 너무 커져서, 신경망(Brain)으로 대체한 것.

1.1 1. Q-러닝의 핵심: Q-테이블과 업데이트

□ 개념 1: 나만의 맛집 리스트 작성

한 줄 요약: 빈 노트(Table)를 들고 다니면서, 행동을 해보고 점수(Reward)가 좋으면 노트에 적힌 점수를 높이고, 나쁘면 깎습니다.

1) Q-Table (커닝 페이지)

엑셀 표를 상상하세요.

- **행(Row):** 모든 가능한 상태 (내 위치).
- **열(Column):** 모든 가능한 행동 (상, 하, 좌, 우).
- **값(Cell):** 그 행동의 가치(점수). 처음엔 모두 0입니다.

2) 학습 식 (Update Rule)

행동 a 를 해서 보상 R 을 받고 다음 상태 s' 이 되었습니다. 내 생각(Q_{old})을 현실($Target$)에 맞춰 수정합니다.

$$Q(s, a) \leftarrow \underbrace{Q(s, a)}_{\text{기존 예상}} + \alpha \left[\underbrace{(R + \gamma \max_{a'} Q(s', a'))}_{\text{현실 (Target)}} - \underbrace{Q(s, a)}_{\text{기존 예상}} \right]$$

- **Target:** "방금 받은 보상(R) + 거기서 낼 수 있는 최고의 미래 가치($\max Q$)"
- **Error:** 현실(Target)과 내 예상(Q)의 차이.
- α (학습률): 새로운 경험을 얼마나 반영할 것인가? (보통 0.1)

1.2 2. 탐험(Exploration) vs 활용(Exploitation)

□ 개념 2: 단골집 vs 신상 맛집

한 줄 요약: 아는 것만 하면 발전이 없고 (Local Optima), 모험만 하면 실속이 없습니다. 둘의 균형을 잡아야 합니다.

1) 딜레마 (Dilemma)

- **활용 (Exploitation):** Q값이 제일 높은 행동만 함. → 우물 안 개구리가 됨.
- **탐험 (Exploration):** 아무거나 막 해봄. → 위험하고 비효율적임.
- **문제:** 처음엔 Q값이 다 0이라서, 아무것도 안 해보면 어디가 좋은지 영원히 모름.

2) 해결책: ϵ -Greedy (엡실론 그리디)

동전을 던져서 행동을 결정합니다.

- 확률 ϵ (예: 10%): **탐험**. 미친 척하고 랜덤 행동을 합니다. "오늘은 새로운 메뉴 도전!"
- 확률 $1 - \epsilon$ (예: 90%): **활용**. Q값이 가장 높은 행동을 합니다. "늘 먹던 길로."
- **Decay:** 학습 초기엔 $\epsilon = 1.0$ (완전 탐험)으로 시작해, 점점 줄여서 나중엔 $\epsilon = 0.01$ (고수의 플레이)로 수렴시킵니다.

1.3 3. 딥 Q-네트워크 (DQN, Deep Q-Network)

□ 개념 3: 노트를 뇌로 바꾸다

한 줄 요약: 상태가 너무 많아서 표(Table)를 그릴 수 없으니, 상태를 입력하면 Q 값을 계산해주는 '함수(신경망)'를 만듭니다.

1) Q-Learning의 한계 (차원의 저주)

미로 찾기는 표를 그릴 수 있습니다. 하지만 화면 픽셀이나 바둑판 같은 경우, 상태의 개수가 우주의 원자 수보다 많습니다. 표를 만들 메모리가 부족합니다.

2) 해결책: Function Approximation

표 대신 신경망(Neural Network)을 사용합니다.

$$Q(s, a) \approx f_w(s, a)$$

우리가 Unit 3에서 배운 FNN(Fully Connected Neural Network)이 여기서 다시 등장합니다.

- **입력:** 현재 게임 화면 (픽셀) or 상태 벡터.
- **네트워크:** 위 그림과 같은 신경망이 복잡한 패턴을 분석합니다.
- **출력:** 각 행동(버튼) 별 예상 Q값.

이것이 딥마인드가 아타리(Atari) 게임을 정복하고 알파고를 만든 핵심 원리입니다.

2 실전 시나리오: 넥슨 카트라이더 AI

□ Scenario: 드리프트 장인 AI 만들기

당신은 카트라이더 AI 개발자입니다. AI에게 "최적의 드리프트 타이밍"을 가르치고 싶습니다.

1. **상태(S):** 트랙의 커브 각도, 현재 속도, 벽과의 거리.
2. **행동(A):** [직진, 좌회전, 우회전, 드리프트, 부스터]
3. **보상(R):**
 - 벽 충돌: -10점
 - 속도 유지: +1점
 - 게이지 충전: +5점

4. 학습 과정 (ϵ -Greedy):

- 초반 ($\epsilon = 1.0$): AI가 벽에 계속 박힙니다. (탐험)
- 중반: "드리프트를 했더니 게이지가 차고 부스터를 쓰니 빨라지더라"는 사실을 Q-Table(혹은 DQN)에 기록합니다.
- 후반 ($\epsilon = 0.05$): 이제 AI는 칼같이 코너를 공략하며(활용), 가끔 새로운 라인을 시도해봅니다.

5. 결과: 사람이 짠 'if-else' 로직보다 훨씬 자연스럽고 빠른 주행을 선보입니다.

3 자주 묻는 질문 (FAQ)

Q1. Q-러닝은 항상 최적의 해를 찾나요? A. 이론적으로는 충분한 시간과 탐험이 주어지면 Q-Table 방식은 최적해에 수렴함이 증명되었습니다. 하지만 DQN(신경망)을 쓸 때는 근사(Approximation)를 하기 때문에, 완벽한 최적해보다는 "꽤 훌륭한 해"를 찾는 것에 만족하는 경우가 많습니다.

Q2. 알파고도 Q-러닝인가요? A. 네, 알파고의 핵심 부품 중 하나가 DQN과 유사한 가치 네트워크(Value Network)입니다. 여기에 몬테카를로 트리 탐색(MCTS)이라는 계획 알고리즘을 섞어서 완성했습니다.

Next Step: 강화 학습은 에이전트가 환경과 상호작용하며 데이터를 스스로 만들어냅니다. 지금까지 우리는 정해진 데이터셋이 있거나(지도/비지도), 상호작용하는 데이터(강화학습)를 다뤘습니다. 그렇다면 데이터가 거의 없는 상황에서 어떻게 학습할까요? 다음 시간에는 전이 학습(Transfer Learning)과 소량의 데이터 학습법을 다룹니다.

Unit 5 (Part B) 핵심 요약

- **Model-free:** 룰을 몰라도 경험(S, A, R, S')만으로 학습한다.
- **Q-Function:** 행동의 가치를 평가하는 함수. $Target - Current$ 오차를 줄이며 학습한다.
- **Exploration-Exploitation:** ϵ -Greedy 전략으로 모험과 안주의 균형을 잡는다.
- **DQN:** Q-Table 대신 신경망을 사용하여 무한한 상태 공간을 커버한다.