

MIT 6.419x: 연결과 계층의 발견

Module 1 (Part B): Spectral & Hierarchical Clustering

Contents

1	Module 1 (Part B). 고급 군집화 (Advanced Clustering)	2
1.1	1. K-Means의 한계 (The Convexity Assumption)	2
1.2	2. 스펙트럴 클러스터링 (Spectral Clustering)	3
1.3	3. 계층적 군집화 (Hierarchical Clustering)	3
2	실전 시나리오: 넥슨 게임 길드(Guild) 분석	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Module 1 (Part A): Dimensionality Reduction (시각화)
- **Module 1 (Part B): Advanced Clustering (현재 단위: 구조적 군집화)**
 - 1.5 Limits of K-Means (구형 가정의 한계)
 - 1.6 Spectral Clustering (그래프 컷과 라플라시안)
 - 1.7 Hierarchical Clustering (덴드로그램과 연결법)
- Module 2: Analysis of Networks (네트워크 과학)

1 Module 1 (Part B). 고급 군집화 (Advanced Clustering)

지난 시간 $t\text{-SNE}$ 를 통해 복잡하게 꼬인 데이터를 눈으로 확인했습니다. 그런데 $K\text{-Means}$ 알고리즘을 돌려보니, 눈으로 보기엔 분명히 다른 그룹인데 하나로 묶어버리는 실수를 범합니다. 왜 그럴까요? $K\text{-Means}$ 는 단순한 '거리'만 보기 때문입니다. 이제 우리는 "친구의 친구는 친구다"라는 연결성 (*Connectivity*)을 이용해 복잡한 구조를 풀어내는 방법을 배웁니다.

□ 개요 (Overview)

이 단원에서는 $K\text{-Means}$ 의 기하학적 한계(볼록성 가정)를 극복하기 위해, 데이터를 그래프 관점에서 해석하는 스펙트럴 클러스터링(Spectral Clustering)과 데이터의 계층적 구조를 파악하는 계층적 군집화(Hierarchical Clustering)를 다룹니다. 특히 스펙트럴 클러스터링의 핵심인 라플라시안 행렬과 고유값 분해의 연결고리를 이해하는 것이 핵심입니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Convex Cluster	공처럼 둥글고 짝 찬 형태의 군집. ($K\text{-Means}$ 가 좋아하는 것)
Adjacency Matrix (W)	누가 누구랑 연결되었는지(유사한지) 나타내는 친구 관계 표.
Laplacian Matrix (L)	$D - W$. 그래프의 구조적 성질을 담고 있는 핵심 행렬.
Graph Cut	그래프를 가위로 잘라서 그룹을 나누는 행위.
Dendrogram	데이터가 합쳐지는 순서를 기록한 족보(Tree) 그림.

1.1 1. $K\text{-Means}$ 의 한계 (The Convexity Assumption)

□ 개념 1: 둥근 구멍에 네모난 못

한 줄 요약: $K\text{-Means}$ 는 "모든 클러스터는 둥근 공 모양이다"라고 가정합니다. 초승달 모양이나 도넛 모양 데이터는 절대 구분하지 못합니다.

한계 상황

- **Two Moons:** 두 개의 초승달이 서로 맞물려 있는 경우. $K\text{-Means}$ 는 가운데를 수직으로 똑 잘라서 반반씩 섞어버립니다.
- **Concentric Circles:** 계란 노른자와 흰자처럼 안팎으로 감싸는 경우. $K\text{-Means}$ 는 파이 조각처럼 잘라버립니다.

- **이유:** 유클리드 거리상으로는 흰자 끝과 끝보다, 흰자와 노른자가 더 가깝기 때문입니다. 연결성을 무시한 결과입니다.

1.2 2. 스펙트럴 클러스터링 (Spectral Clustering)

□ 개념 2: 다리 끊기 (Graph Cut)

한 줄 요약: 데이터를 공간상의 점이 아니라 '노드와 엣지로 이루어진 그래프'로 봅니다. 그룹 간의 연결 다리를 끊어서 (Cut) 섬을 만드는 것이 목표입니다.

1) 알고리즘 단계 (The Recipe)

1. 유사도 그래프 생성 (W): 거리(d)가 가까우면 1, 멀면 0인 인접 행렬을 만듭니다. (또는 가우시안 커널 사용)
2. 라플라시안 행렬 계산 (L): 그래프의 성질을 요약합니다.

$$L = D - W$$

(D : 차수 행렬, 각 노드가 친구가 몇 명인지 대각선에 적음)

3. 고유값 분해 (Spectral Embedding): L 의 고유벡터를 구합니다.
4. K-Means 적용: 고유벡터로 변환된 공간(Spectral Domain)에서는 초승달 모양이 둥근 공 모양으로 퍼집니다. 여기서 K-Means를 돌립니다.

2) 왜 라플라시안(L)인가?

우리의 목표는 "그룹 간 연결은 끊고 (Min Cut), 그룹 내부는 뭉치게 하는" 것입니다. 수학적으로 이 최적화 문제(Normalized Cut)를 풀면, 그 해답이 놀랍게도 L 행렬의 두 번째로 작은 고유벡터(Fiedler Vector)와 같다는 것이 증명되어 있습니다.

- 즉, 복잡한 그래프 자르기 문제를 선형대수(행렬 분해) 문제로 바꿔서 푸는 것입니다.

1.3 3. 계층적 군집화 (Hierarchical Clustering)

□ 개념 3: 족보 만들기 (Family Tree)

한 줄 요약: 처음엔 모두가 남남이었다가, 가장 친한 사람끼리 짝을 짓고, 그 커플끼리 또 합치면서 거대한 가족(트리)을 만듭니다.

1) 병합형 (Agglomerative) 방식

- 시작: 데이터 N 개가 각각 1 개의 클러스터.
- 반복: 가장 가까운 두 클러스터를 합침 ($N \rightarrow N - 1 \rightarrow \dots \rightarrow 1$).
- 결과: 덴드로그램 (Dendrogram) 이라는 트리 구조가 나옵니다. 원하는 높이에서 자르면 (K) 클러스터가 나뉩니다.

2) 연결법 (Linkage Methods): 거리의 정의

”점과 점 사이의 거리는 아는데, 그룹과 그룹 사이의 거리는 어떻게 재나요?”

방법	정의 (Distance between clusters)	특징
Single	가장 가까운 멤버끼리의 거리 (최단)	길게 늘어진 뱀 모양 잘 찾음. 노이즈에 약함.
Complete	가장 먼 멤버끼리의 거리 (최장)	둥글고 컴팩트한 군집 형성.
Average	모든 멤버 간 거리의 평균	무난하고 안정적임.
Ward	합쳤을 때 분산의 증가량	가장 널리 쓰임. 크기가 고른 군집 선호.

2 실전 시나리오: 넥슨 게임 길드(Guild) 분석

□ Scenario: 적대 길드와 동맹 길드 파악

당신은 '리니지'와 같은 MMORPG의 데이터 분석가입니다. 수천 개의 길드가 서로 전쟁하거나 동맹을 맺고 있습니다. 이 복잡한 정치 지형도를 그려야 합니다.

1. 데이터: 길드 간 PK 횟수, 파티 사냥 횟수, 채팅 빈도.
2. 문제: 단순히 "전투력이 비슷한 길드"끼리 묶는 것(K-Means)은 의미가 없습니다. 전투력이 달라도 서로 친하면 같은 편입니다. "관계(Relation)"가 중요합니다.
3. 스펙트럴 클러스터링 적용:
 - 노드: 각 길드.
 - 엣지(W): 파티 사냥이 많으면 가중치 높음(친함), PK가 많으면 가중치 낮음(적대).
 - 라플라시안(L): 그래프 구조 계산.
 - 결과: 2차원 평면에 투영하니, 거대한 두 세력(공성측 vs 수성측)이 양극단으로 뚜렷하게 나뉩니다.
4. 인사이트: "전투력은 낮지만 인맥으로 연결된 '제3세력'이 존재함"을 발견합니다.

3 자주 묻는 질문 (FAQ)

- Q1. 스펙트럴 클러스터링은 만능인가요?** **A.** 성능은 강력하지만 계산 비용이 비쌉니다. $N \times N$ 크기의 행렬을 만들고 고유값 분해를 해야 하므로, 데이터가 수만 개를 넘어가면 ($N > 10,000$) 매우 느려집니다. 이때는 Nyström 근사 같은 기법을 써야 합니다.
- Q2. 덴드로그램은 어떻게 읽나요?** **A.** 아래 (Leaf)는 개별 데이터, 위 (Root)는 전체 데이터입니다. 세로축은 "합쳐질 때의 거리(비용)"를 의미합니다. 세로선이 길다는 것은, 두 그룹이 아주 멀리 떨어져 있는데 억지로 합쳤다는 뜻입니다. 보통 이 긴 선을 자르는 (Cut) 위치가 최적의 K 가 됩니다.

Next Step: 우리는 데이터를 점 (Point)이 아닌 연결된 구조 (Graph)로 보기 시작했습니다. 그렇다면 이 '네트워크' 자체를 본격적으로 분석할 수는 없을까요? 누가 중심 인물 (Hub)이고, 정보는 어떻게 전파될까요? 다음 **Module 2: 네트워크 분석 (Analysis of Networks)**에서 그래프 이론의 심화를 다룹니다.

Module 1 (Part B) 핵심 요약

- **한계:** K-Means는 볼록 (Convex)한 형태만 찾을 수 있다.
- **Spectral Clustering:** 데이터를 그래프로 보고, 라플라시안 행렬의 고유벡터를 이용해 비볼록 구조를 분리한다. (Graph Cut)
- **Hierarchical Clustering:** 데이터를 계층적 트리 (Dendrogram)로 시각화한다.
- **Linkage:** 클러스터 간 거리를 정의하는 방법 (Ward, Single, Complete)에 따라 결과가 달라진다.