

MIT 6.419x: 우연을 걸러내는 기술

Module 1 (Part C): Multiple Hypothesis Testing

Contents

1	Module 1 (Part C). 다중 가설 검정 (Multiple Hypothesis Testing)	2
1.1	1. 문제의 배경: 왜 $P < 0.05$ 로는 부족한가?	2
1.2	2. 해결책 1: FWER 제어 (Bonferroni 교정)	3
1.3	3. 해결책 2: FDR 제어 (Benjamini-Hochberg)	4
2	실전 시나리오: 신약 후보 물질 발굴	5
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Module 1 (Part A): Dimensionality Reduction (시각화)
- Module 1 (Part B): Clustering (구조 파악)
- **Module 1 (Part C): Multiple Hypothesis Testing (현재 단원: 가짜 발견 제어)**
 - 1.8 The Multiple Testing Problem (p -hacking의 위험)
 - 1.9 FWER & Bonferroni Correction (보수적 접근)
 - 1.10 FDR & Benjamini-Hochberg (실용적 접근)
- Module 2: Analysis of Networks (네트워크 과학)

1 Module 1 (Part C). 다중 가설 검정 (Multiple Hypothesis Testing)

앞서 우리는 수만 개의 유전자 데이터나 고객 행동 로그를 군집화하여 의미 있는 그룹을 찾았습니다. 그런데 누군가 묻습니다. "이 그룹들이 진짜 의미가 있는 거야, 아니면 그냥 우연히 뭉친 거야?" 이 질문에 답하기 위해 우리는 $P < 0.05$ 라는 전통적인 기준을 넘어, 빅데이터 시대에 맞는 새로운 검증 기준을 세워야 합니다.

□ 개요 (Overview)

이 단원에서는 변수가 많은 고차원 데이터에서 통계적 검정을 수행할 때 발생하는 다중 검정의 문제(False Positive 폭증)를 다룹니다. 이를 해결하기 위한 두 가지 주요 전략인 FWER(본페로니 교정)과 FDR(벤자미니-호크버그 절차)의 원리를 배우고, 연구 목적에 따라 어떤 방법을 선택해야 하는지 학습합니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Type I Error (α)	늑대가 없는데 "늑대다!"라고 외치는 실수. (거짓 양성)
Multiple Testing Problem	주사위를 수만 번 던지면, 6이 연속 10번 나오는 '기적'도 우연히 발생한다는 문제.
FWER (Family-Wise Error Rate)	"전체 실험 중 단 하나의 실수도 용납하지 않겠다."
Bonferroni Correction	유의 수준을 $1/N$ 로 나눠버리는 아주 엄격한 기준.
FDR (False Discovery Rate)	"건져 올린 물고기 중 쓰레기가 5% 정도 섞여 있어도 괜찮다."

1.1 1. 문제의 배경: 왜 $P < 0.05$ 로는 부족한가?

□ 개념 1: 로또 당첨의 함정

한 줄 요약: 한 번 시도해서 성공할 확률이 희박하더라도, 수만 번 시도하면 누군가는 반드시 성공합니다. 그걸 '실력'이라고 착각하면 안 됩니다.

1) 직관적 비유: 동전 던지기 대회

- 1명이 동전을 10번 던져서 전부 앞면이 나올 확률은 약 0.001 (0.1%)입니다. 매우 희박하죠.
- 하지만 10,000명이 동시에 동전을 던진다면?

- 확률적으로 약 **10명**은 동전 10개 모두 앞면이 나옵니다.
- **오류**: 연구자는 이 10명을 보고 "초능력자다!"라고 결론 내립니다. 하지만 이들은 그냥 운 좋은 일반인(**False Positive**)입니다.

2) 실제 문제 (유전체 분석)

- 유전자 20,000개를 검사합니다 ($m = 20,000$).
- 유의 수준 $\alpha = 0.05$ 를 적용합니다.
- 아무런 효과가 없어도(귀무가설 참), $20,000 \times 0.05 = 1,000$ 개의 유전자가 '유의미하다'고 나옵니다.
- 결과: 1,000개의 가짜 암 유전자 후보가 발견됩니다. 연구비 낭비의 시작입니다.

1.2 2. 해결책 1: FWER 제어 (본페로니 교정)

□ 개념 2: 철통 보안 검색대

한 줄 요약: 단 하나의 위험물도 비행기에 태우지 않겠다며, 모든 승객을 현미경으로 검사하는 방식입니다. 안전하지만, 비행기를 탈 수 있는 사람이 거의 없습니다.

1) 본페로니 교정 (Bonferroni Correction)

전체 가설 중 하나라도 틀릴 확률(FWER)을 0.05로 맞추려면, 개별 가설의 기준을 N 배 엄격하게 해야 합니다.

$$\alpha_{new} = \frac{\alpha}{m}$$

2) 계산 예시

유전자 20,000개를 검사할 때 ($\alpha = 0.05$):

$$P_{threshold} = \frac{0.05}{20,000} = 0.0000025$$

- **장점**: 가짜(False Positive)가 나올 확률이 거의 0에 가깝습니다. (확실한 것만 잡음)
- **단점**: 기준이 너무 높아서, 진짜 중요한 유전자(True Positive)까지 다 탈락시킵니다. (검정력 Power 급락)

1.3 3. 해결책 2: FDR 제어 (벤자미니-호크버그)

□ 개념 3: 섞어도 괜찮아, 비율만 맞춰

한 줄 요약: 금을 켤 때 돌맹이가 좀 섞여 있어도, 금이 훨씬 많으면 성공입니다. "내가 찾았다고 주장한 것 중 가짜의 비율(FDR)"을 5%로 유지합니다.

1) 벤자미니-호크버그 (BH) 절차

매우 우아하고 실용적인 알고리즘입니다. P 값들을 줄 세워서 동적으로 커트라인을 정합니다.

알고리즘 순서:

1. 모든 가설의 P 값을 오름차순으로 정렬합니다: $P_{(1)} \leq P_{(2)} \leq \dots \leq P_{(m)}$.
2. 각 k 번째 P 값에 대해, 다음 기준선 (Line) 아래에 있는지 확인합니다.

$$P_{(k)} \leq \frac{k}{m} \times \alpha$$

(순위 k 가 커질수록, 즉 뒤로 갈수록 기준을 널널하게 봐줍니다.)

3. 위 조건을 만족하는 가장 큰 k 를 찾습니다.
4. 1 등부터 k 등까지 모든 가설을 "유의미하다"고 선언합니다.

2) 숫자 대입 계산 예시

총 5개의 가설을 검정했고 ($m = 5$), 목표 FDR $\alpha = 0.05$ 입니다. P 값 결과: $[0.001, 0.009, 0.04, 0.045, 0.6]$

순위 (k)	P 값 ($P_{(k)}$)	기준선 ($\frac{k}{5} \times 0.05$)	통과 여부 ($P \leq$ 기준)
1	0.001	0.01	Pass (✓)
2	0.009	0.02	Pass (✓)
3	0.040	0.03	Fail (×)
4	0.045	0.04	Fail (×) - 잠깐!

(수정: 예시 수치를 BH 절차의 극적인 효과를 위해 재조정합니다)

재조정된 예시: $P = [0.001, 0.015, 0.025, 0.05, 0.6]$, $\alpha = 0.05$.

- $k = 1$: $0.001 \leq 0.01$ (Pass)
- $k = 2$: $0.015 \leq 0.02$ (Pass)
- $k = 3$: $0.025 \leq 0.03$ (Pass) → **여기까지가 최대!**
- $k = 4$: $0.05 > 0.04$ (Fail)

결론: 3번째 가설까지 모두 유의미하다고 인정합니다. (본페로니였다면 0.01 기준이라 $k = 1$ 만 통과했을 것입니다. BH 덕분에 2, 3번도 구제받았습니다.)

2 실전 시나리오: 신약 후보 물질 발굴

□ Scenario: 수만 개의 화합물 스크리닝

당신은 제약회사의 데이터 과학자입니다. 10,000개의 화합물 중 암세포를 죽이는 효과가 있는 후보를 추려야 합니다.

1. **상황:** 10,000번의 실험을 통해 각각 P 값을 얻었습니다.
2. **본페로니 적용 시:**
 - 기준: $0.05/10,000 = 0.000005$.
 - 결과: 후보 물질이 **2개** 나옵니다.
 - 평가: 너무 적습니다. 놓친 후보 중에 진짜 대박 신약이 있을 수 있습니다.
3. **FDR (BH) 적용 시:**
 - 목표: "후보 중 5% 정도는 짱이어도 된다."
 - 결과: 후보 물질이 **150개** 나옵니다.
 - 평가: 이 150개를 가지고 2차 정밀 실험을 진행합니다. 가짜가 78개 섞여 있겠지만, 나머지 142개의 진짜 후보를 건졌으니 훨씬 이득입니다.

3 자주 묻는 질문 (FAQ)

Q1. 언제 FWER을 쓰고 언제 FDR을 쓰나요? A. 목적에 따라 다릅니다.

- **FWER (본페로니):** 최종 임상 시험처럼 "단 하나의 실수도 치명적일 때" 씁니다. (보수적)
- **FDR (BH):** 초기 탐색 단계, 유전체 분석, 추천 시스템 A/B 테스트처럼 "많은 후보를 발굴하고 싶을 때" 씁니다. (현대 데이터 과학의 표준)

Q2. P 값을 정렬하는 것만으로 어떻게 오류가 제어되나요? A. 수학적으로 증명되어 있습니다. $y = x$ 그래프를 그렸을 때, P 값들이 대각선 아래에 위치한다는 것은 "우연히 발생할 확률보다 더 드물게 발생했다"는 증거가 됩니다. BH 절차는 이 경계선을 동적으로 조정하여 가짜의 비율(Area)을 제어합니다.

Next Step: 우리는 고차원 데이터의 '시각화(Part A)', '군집화(Part B)', 그리고 '가설 검정(Part C)'까지 마쳤습니다. 이제 데이터 포인트들이 서로 독립적이지 않고 복잡하게 얽혀 있다면 어떨까요? 다음 **Module 2: 네트워크 분석 (Analysis of Networks)**에서는 그래프 이론을 통해 데이터 간의 관계를 분석합니다.

Module 1 (Part C) 핵심 요약

- **다중 검정 문제:** 가설 검정을 많이 할수록 우연에 의한 가짜 발견 (False Positive) 이 폭증한다.
- **FWER (본페로니):** α/m . 매우 엄격하다. 진짜도 놓칠 위험이 크다.
- **FDR (벤자미니-호크버그):** 발견된 것 중 가짜의 비율을 제어한다. $P_{(k)} \leq \frac{k}{m} \alpha$.
- **트렌드:** 빅데이터 분석에서는 너무 보수적인 FWER보다 실용적인 **FDR**을 주로 사용한다.