

MIT 6.419x: 지도의 빈칸을 채우다

Module 3 (Part B): Spatial Statistics (GP & Kriging)

Contents

1	Module 3 (Part B). 공간 통계 (Spatial Statistics)	2
1.1	1. 가우시안 프로세스 (Gaussian Processes, GP)	2
1.2	2. 크리깅 (Kriging)	3
1.3	3. 커널 방법론 (The Kernel Connection)	3
2	실전 시나리오: 넥슨 글로벌 서버 렉(Lag) 지도	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Module 3 (Part A): Time Series Analysis (시간의 흐름)
- **Module 3 (Part B): Spatial Statistics (현재 단위: 공간의 분포)**
 - 3.5 Gaussian Processes (함수의 확률 분포)
 - 3.6 Kriging & Variograms (지구통계학적 보간)
 - 3.7 Kernel Methods (공간적 유사도 정의)

1 Module 3 (Part B). 공간 통계 (Spatial Statistics)

지난 시간(*Part A*)에는 "오늘의 나는 어제의 나"라는 시간적 자기상관(*Autocorrelation*)을 다뤘습니다. 이번에는 "모든 것은 다른 모든 것과 관련이 있지만, 가까운 것이 더 관련이 있다(*Tobler's First Law*)"는 지리학의 제1법칙을 바탕으로, 공간적 자기상관을 다룹니다.

□ 개요 (Overview)

이 단원에서는 등성등성한 관측 데이터(예: 기상청 관측소)를 바탕으로 전체 공간(예: 대한민국 전체 미세먼지 지도)을 추정하는 방법을 배웁니다. 특히 가우시안 프로세스(GP)를 통해 예측의 불확실성을 정량화하고, 이를 지구통계학에 적용한 크리깅(Kriging) 기법을 마스터합니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Interpolation (보간)	점들 사이의 빈 공간을 부드럽게 채워 넣는 기술.
Uncertainty	"이 지역 값은 내가 확실히 아는데, 저기는 데이터가 없어서 잘 몰라(분산이 커)."
Variogram	거리가 멀어질수록 데이터 간의 차이(분산)가 어떻게 커지는지 나타내는 그래프.
Kernel (k)	두 지점이 '가깝다'는 것을 수학적으로 정의하는 함수.

1.1 1. 가우시안 프로세스 (Gaussian Processes, GP)

□ 개념 1: 함수의 확률 분포

한 줄 요약: 점 하나하나를 예측하는 게 아니라, "데이터를 설명할 수 있는 모든 가능한 곡선(함수)들의 모임"을 그립니다.

1) 핵심 아이디어

일반적인 회귀분석($y = wx + b$)은 파라미터 w 를 찾지만, GP는 함수 $f(x)$ 자체를 확률 변수로 봅니다.

- **관측된 곳:** 오차가 거의 없이 점을 지나가야 하므로 불확실성(분산)이 0에 가깝습니다.
- **관측 안 된 곳:** 어떤 값이든 될 수 있으므로 불확실성(분산)이 풍선처럼 부풀어 오릅니다.

2) 구성 요소

$$f(x) \sim GP(m(x), k(x, x'))$$

- 평균 함수 (m): 데이터의 전반적인 추세.
- 커널 함수 (k): x 와 x' 가 가까우면 $f(x)$ 와 $f(x')$ 도 비슷한 값을 가질 확률이 높다는 '상관관계'를 정의합니다.

1.2 2. 크리깅 (Kriging)

□ 개념 2: 지능적인 가중 평균

한 줄 요약: 단순히 가까운 점을 평균 내는 게 아니라, 공간의 특성(배리오그램)을 분석해서 가장 오차가 적은 황금 비율(가중치)로 섞습니다.

1) 작동 원리 (BLUE)

미지의 지점 x_0 의 값은 주변 데이터 $Z(x_i)$ 들의 선형 결합입니다.

$$\hat{Z}(x_0) = \sum_{i=1}^n \lambda_i Z(x_i)$$

여기서 가중치 λ_i 를 구하는 것이 핵심인데, 배리오그램(Variogram)을 이용해 오차 분산을 최소화하는 최적의 λ 를 찾아냅니다.

2) 배리오그램 (Variogram)

"거리가 h 만큼 떨어져 있으면, 값은 얼마나 차이가 날까?"를 나타내는 함수입니다.

- 가까운 거리: 차이가 적음 (상관관계 높음).
- 먼 거리: 차이가 큼 (상관관계 낮음).
- 크리깅은 이 구조를 파악해서, 멀리 있어도 상관관계가 유지되는 방향이라면 가중치를 더 줍니다.

1.3 3. 커널 방법론 (The Kernel Connection)

□ 개념 3: 공간의 질감(Texture) 정의하기

한 줄 요약: "이 지역은 부드러운 언덕인가(RBF), 아니면 거친 자갈밭인가(Matern)?"를 수학적(커널)으로 결정합니다.

주요 커널 종류

1. RBF (Squared Exponential):

- 아주 매끄러운(Smooth) 곡선을 만듭니다.
- 현실 세계의 거친 지형이나 급격한 변화를 설명하기엔 너무 이상적일 수 있습니다.

2. Matern Kernel:

- 거칠기(Roughness)를 조절하는 파라미터가 있습니다.
- 공간 통계에서 가장 널리 쓰이며, 현실적인 물리 현상을 잘 반영합니다.

3. Periodic Kernel:

- 일정한 패턴이 반복될 때 사용합니다 (예: 계절에 따른 온도 변화).

2 실전 시나리오: 넥슨 글로벌 서버 랙(Lag) 지도

□ Scenario: 전 세계 유저들의 네트워크 품질 추정

당신은 넥슨 글로벌 서비스 본부장입니다. 전 세계 곳곳에 흩어진 유저들의 핑(Ping) 데이터를 이용해, 어느 지역에 서버를 증설해야 할지 결정해야 합니다.

1. **데이터:** 일부 유저($n = 10,000$)에게서 수집된 [위도, 경도, Ping] 데이터. 대부분의 지역은 데이터가 없는 공백지입니다.

2. Kriging 적용:

- 단순히 근처 유저 값을 평균 내는 게 아니라, 대륙별 인터넷망의 특성(Variogram)을 고려해 보간합니다.
- 결과: 데이터가 없던 '동남아 시골 마을'의 핑도 주변 도시 데이터를 기반으로 정밀하게 추정해냅니다.

3. Gaussian Process 활용 (핵심):

- GP는 불확실성(Variance) 지도를 함께 줍니다.
- "아프리카 지역은 핑이 200ms로 예상되지만, 불확실성이 매우 높다(± 100)."
- 의사결정: 불확실성이 높은 지역은 선불리 서버를 짓기보다, 먼저 테스트 서버를 열어 데이터를 더 수집하기로 결정합니다.

3 자주 묻는 질문 (FAQ)

- Q1. 단순 평균(Nearest Neighbor)과 크리깅의 결정적 차이는?** A. 불확실성(Uncertainty)과 구조(Structure)입니다. 단순 평균은 "값"만 채우지만, 크리깅은 "이 값이 얼마나 믿을만한지(Variance)"를 알려줍니다. 또한, 크리깅은 데이터가 한쪽에 쏠려 있으면(Clustered), 그쪽 데이터들의 가중치를 낮춰서(De-clustering) 전체적인 균형을 맞춥니다.
- Q2. 커널은 어떻게 고르나요?** A. 데이터에 대한 도메인 지식이 필요합니다. "현상은 부드럽게 변하는가, 급격히 변하는가?", "주기적인가?"를 고민해야 합니다. 보통은 Matern 커널로 시작해서 Cross-Validation으로 최적의 커널을 찾습니다.

Next Step: 지금까지 정형 데이터(행렬, 그래프, 시계열, 공간)를 다뤘습니다. 이제 마지막 모듈에서는 비정형 데이터의 끝판왕인 **이미지와 텍스트**를 다루기 위해 다시 딥러닝(CNN, NLP)의 심화 주제로 돌아가거나, 강화학습의 응용을 다루게 됩니다. (MIT 커리큘럼에 따라 유동적)

Module 3 (Part B) 핵심 요약

- **Gaussian Processes:** 함수를 확률적으로 추정하여 예측값과 불확실성(범위)을 동시에 제공한다.
- **Kriging:** 공간적 상관관계(Variogram)를 분석하여 미관측 지점을 정밀하게 보간하는 지구통계학 기법.
- **Kernel:** 공간적 유사도를 정의하는 핵심 엔진. (RBF = Smooth, Matern = Realistic).