

MIT 6.419x: 실험 없이 원인을 찾다

Module 4 (Part B): Causal Inference in Observational Studies

Contents

1	Unit 10. 관찰 연구에서의 인과 추론	2
1.1	1. 교란 변수와 심슨의 역설	2
1.2	2. 성향 점수 매칭 (Propensity Score Matching, PSM)	3
1.3	3. 도구 변수 (Instrumental Variables, IV)	3
1.4	4. 회귀 불연속 (Regression Discontinuity, RD)	4
2	실전 시나리오: 넥슨 PC방 혜택 분석	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Module 4 (Part A): Causal Basics (ATE, Selection Bias)
- **Module 4 (Part B): Observational Studies (현재 단원: 관찰 연구 기법)**
 - 10.1 Confounders & Simpson's Paradox (함정 피하기)
 - 10.2 Matching & Propensity Score (비슷한 것끼리 묶기)
 - 10.3 Instrumental Variables (도구 변수 활용)
 - 10.4 Regression Discontinuity (경계선 활용)
- Module 5: Deep Learning & Applications (심화 응용)

1 Unit 10. 관찰 연구에서의 인과 추론

*Part A*에서 우리는 " A/B 테스트(RCT)가 최고다"라고 배웠습니다. 하지만 현실에서는 담배의 해로움을 알기 위해 강제로 담배를 피우게 할 수 없고, 넥슨의 모든 유저에게 강제로 캐시를 지급할 수도 없습니다. 실험이 불가능한 상황에서, 이미 쌓여있는 로그 데이터(Observational Data)만으로 인과관계를 밝혀내는 고급 기술들을 배웁니다.

□ 개요 (Overview)

이 단원에서는 관찰 데이터에 숨어있는 교란 변수(Confounder)의 위험성을 심슨의 역설을 통해 이해하고, 이를 통제하기 위한 3대장 기법을 배웁니다. 1. 성향 점수 매칭 (PSM): 비슷한 사람끼리 비교하기. 2. 도구 변수 (IV): 외부 충격을 이용하기. 3. 회귀 불연속 (RD): 컷오프 경계선의 마법 활용하기.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Observational Study	연구자가 개입하지 않고, 자연 발생한 데이터를 관찰하는 연구.
Confounder (교란 요인)	원인과 결과 뒤에서 둘 다 조종하는 흑막. ($Z \rightarrow X, Z \rightarrow Y$)
Simpson's Paradox	쪼개서 볼 때와 합쳐서 볼 때 결과가 정반대가 되는 기이한 현상.
Propensity Score	"이 사람이 처치(약/쿠폰)를 받을 확률". 복잡한 특성을 점수 하나로 요약.
Instrumental Variable	원인(X)에만 영향을 주고 결과(Y)에는 직접 영향을 안 주는 제3의 변수.

1.1 1. 교란 변수와 심슨의 역설

□ 개념 1: 통계의 착시 현상

한 줄 요약: 데이터를 뭉뚱그려 (Aggregation) 보면 진실이 가려집니다. 쪼개서 (Stratification) 봐야 합니다.

심슨의 역설 (Simpson's Paradox)

- 상황: 신약 A의 완치율이 B보다 높습니다. (전체 통계)
- 진실: 남성 그룹에서도 B가 높고, 여성 그룹에서도 B가 높습니다. (???)

- **원인:** A 약은 주로 병이 가벼운 사람들에게 투여되었고, B 약은 중환자들에게 투여되었기 때문입니다. '환자의 중증도'라는 교란 변수를 무시하고 합쳤기 때문에 발생한 착시입니다.
- **교훈:** 인과 추론의 제1원칙은 "비교 가능한 것끼리 비교하라(Ceteris Paribus)"입니다.

1.2 2. 성향 점수 매칭 (Propensity Score Matching, PSM)

□ 개념 2: 도플갱어 찾기

한 줄 요약: 약을 먹은 사람과, 안 먹었지만 먹을 뻔했던(성향이 비슷한) 사람을 짝지어서 비교합니다.

1) 원리

변수가 많으면(나이, 성별, 소득, 지역...) 완벽하게 똑같은 짝을 찾기 힘듭니다. 그래서 모든 특성을 '처치 받을 확률(Propensity Score)'이라는 하나의 숫자로 압축합니다.

$$e(x) = P(T = 1 | X = x)$$

2) 매칭 (Matching)

1. 각 유저가 쿠폰을 받을 확률(성향 점수)을 계산합니다.
2. 실제 쿠폰 받은 사람($T=1$, 점수 0.7)과 안 받은 사람($T=0$, 점수 0.7)을 매칭합니다.
3. 이 둘의 구매액 차이를 계산하면 순수한 쿠폰 효과를 알 수 있습니다.

1.3 3. 도구 변수 (Instrumental Variables, IV)

□ 개념 3: 자연 실험(Natural Experiment) 이용하기

한 줄 요약: 우리가 직접 실험할 수 없을 때, 우연히 발생한 외부 충격(도구)을 이용해 인과관계를 알아냅니다.

1) 도구 변수의 조건

도구 변수 Z 는 X (원인)는 건드리지만, Y (결과)는 직접 건드리지 않아야 합니다. ($Z \rightarrow X \rightarrow Y$)

- **예시:** "군 복무(X)가 평생 소득(Y)에 미치는 영향"

- **문제:** 애국심이나 건강 상태 같은 교란 변수가 섞여 있습니다.
- **도구(Z):** 생일 추첨(징병제 복권). 생일은 랜덤이므로 개인 특성과 무관하며, 오직 군대 가는 여부(X)에만 영향을 줍니다.

2) 2단계 최소자승법 (2SLS)

- **Stage 1:** Z 로 X 를 예측합니다. ($\hat{X}$ 생성) $\rightarrow X$ 에서 교란 변수의 때를 벗겨냄.
- **Stage 2:** 깨끗해진 $\hat{X}$ 로 Y 를 설명합니다.

1.4 4. 회귀 불연속 (Regression Discontinuity, RD)

□ 개념 4: 갇힌 장 차이

한 줄 요약: 커트라인(90점) 바로 위(90점)와 바로 아래(89점) 사람은 실력 차이가 거의 없습니다. 운명만 달렸을 뿐이죠. 이들을 비교합니다.

1) 원리

임의의 컷오프(Threshold) 주변에서는 마치 무작위 할당(Random Assignment)이 일어난 것과 같다고 가정합니다.

- **예:** 장학금 기준이 토익 800점.
- 799점(탈락)과 800점(수혜) 학생을 비교하면 장학금의 인과 효과를 측정할 수 있습니다.

2) 시각적 확인

X 축(점수)에 따른 Y 축(결과) 그래프를 그렸을 때, 컷오프 지점에서 그래프가 '점프(Jump)' 한다면 그것이 바로 인과 효과입니다.

2 실전 시나리오: 넥슨 PC방 혜택 분석

□ Scenario: PC방 혜택이 진짜 접속 시간을 늘릴까?

당신은 넥슨의 사업 PM입니다. "PC방에서 접속하면 경험치 +20%" 혜택을 줍니다. PC방 유저의 플레이 시간이 집 유저보다 2배 깁니다. 이게 혜택 덕분일까요?

1. **문제 (Selection Bias):** 원래 게임을 오래 하는 '하드코어 유저'들이 PC방을 더 많이 갑니다. (단순 비교 불가)

2. **해결책 1 (PSM):** 집 유저 중에서도 하드코어한 성향(레벨, 장비 수준 등)이 PC방 유저와 비슷한 사람들을 찾아 매칭하여 비교합니다.
3. **해결책 2 (IV - 도구 변수):** "비 오는 날(Z)"을 도구로 씁니다.
 - 비가 오면 귀찮아서 PC방을 덜 갑니다 ($Z \rightarrow X$).
 - 비 자체가 게임 실력(Y)에 영향을 주진 않습니다.
 - 비 때문에 '강제로' 집에서 하게 된 유저들의 플레이 시간 변화를 분석하여 순수한 PC방 효과를 추정합니다.

3 자주 묻는 질문 (FAQ)

Q1. 셋 중 뭐가 제일 좋나요? A. 상황에 따라 다릅니다.

- **RD (회귀 불연속):** 가장 신뢰도가 높지만(거의 RCT급), 컷오프 규칙이 있는 경우에만 쓸 수 있습니다.
- **IV (도구 변수):** 강력하지만, 완벽한 도구 변수(Z)를 찾는 것이 하늘의 별 따기입니다. (대부분 논문감)
- **PSM (매칭):** 가장 범용적이고 쉽지만, "우리가 관찰하지 못한 변수(Unobserved Confounder)"는 통제 못 한다는 약점이 있습니다.

Q2. 머신러닝이랑 인과 추론을 섞어 쓸 수 있나요? A. 네, 최신 트렌드인 **Causal ML**입니다. 'Double Machine Learning' 같은 기법은 성향 점수나 결과 예측 모델에 딥러닝(XGBoost 등)을 사용하여 추정의 정확도를 높입니다. (주로 Moloco 같은 애드테크에서 많이 씁니다.)

Next Step: 드디어 MIT 6.419x의 긴 여정이 마무리되었습니다. 고차원 데이터 시각화부터, 네트워크 분석, 시공간 통계, 그리고 인과 추론까지. 이제 이 모든 지식을 종합하여 넥슨의 데이터를 바라보면, 전에는 보이지 않던 '구조'와 '원인'이 보이기 시작할 것입니다. 고생 많으셨습니다!

Module 4 (Part B) 핵심 요약

- **심슨의 역설:** 데이터를 뭉뚱그려 보면 인과관계가 뒤집힐 수 있다. 쪼개 봐야 한다.
- **PSM:** 성향이 비슷한 사람끼리 짝지어(Matching) 비교한다.
- **IV:** 외부 충격(도구)을 이용해 자연 실험 상황을 만든다.
- **RD:** 컷오프 경계선에서의 불연속 점프를 인과 효과로 간주한다.