

Contents

0.1	필수 용어 사전	2
0.2	핵심 개념 1: 분포를 모를 때의 생존법 (부등식)	3
0.2.1	1. 마르코프 부등식 (Markov Inequality)	3
0.2.2	2. 체비셰프 부등식 (Chebyshev Inequality)	3
0.3	핵심 개념 2: 대수의 법칙 (Laws of Large Numbers)	3
0.3.1	분산의 축소 (Variance Shrinking)	4
0.4	핵심 개념 3: 중심 극한 정리 (Central Limit Theorem)	4
0.4.1	CLT 문제 해결 3단계 레시피	4
0.5	실전 응용: 게임 서버 용량 설계 (Capacity Planning)	5
0.6	초심자가 자주 묻는 질문 (FAQ)	5
0.7	요약 및 다음 단계	6

□ 이 교재의 전체 구조 (Roadmap)

- Unit 1: 확률의 기초와 이산 확률 변수 (완료)
- Unit 2: 일반 확률 변수 (완료)
- Unit 3: 확률 과정과 극한 정리 (Random Processes & Limit Theorems)
 - Chapter 7: 극한 정리와 통계적 추론 (Limit Theorems) ← 현재 위치
 - Chapter 8: 베르누이 프로세스와 포아송 프로세스
 - Chapter 9: 마르코프 체인 (Markov Chains)

Unit 3 - Chapter 7: 극한 정리: 무한(∞)이 주는 선물

Intro: 정확한 계산에서 '근사(Approximation)'로

[이전 단계와의 연결]

지금까지는 확률 변수의 분포(PMF/PDF)를 정확히 알고 있다고 가정하고, $P(X \leq 3)$ 같은 값을 '정확하게' 계산했습니다. 하지만 현실 세계(빅데이터)에서는 데이터가 너무 많거나 분포를 모르는 경우가 대부분입니다. 이제 우리는 "데이터가 무한히 많아지면($n \rightarrow \infty$), 분포를 몰라도 결과를 예측할 수 있다"는 강력한 도구를 배웁니다.

□ 이 단원의 핵심 개요 (Overview)

1. **부등식 (Bounds):** 분포를 몰라도 평균과 분산만 알면 '최악의 시나리오'를 막을 수 있다. (마르코프, 체비셰프)
2. **대수의 법칙 (LLN):** 데이터가 많아지면 통계치(평균)는 결국 진실(True Mean)로 수렴한다.
3. **중심 극한 정리 (CLT):** 데이터가 많아지면 합과 평균의 분포는 무조건 정규 분포(Bell Curve)가 된다.

0.1 필수 용어 사전

mainblue!20 기호	용어	직관적 의미
Bounds	한계(부등식)	정확한 값은 모르지만, "적어도 이 선은 넘지 않는다"는 상한선
M_n	표본 평균	데이터 n 개를 모아서 낸 평균 ($\frac{X_1 + \dots + X_n}{n}$)
Converge	수렴 ($\rightarrow$)	n 이 커질수록 특정 값이나 분포에 가까워지는 현상
LLN	대수의 법칙	"많이 던지면 결국 확률대로 나온다." (진실의 발견)
CLT	중심 극한 정리	"많이 합치면 종 모양(정규 분포)이 된다." (형태의 발견)

0.2 핵심 개념 1: 분포를 모를 때의 생존법 (부등식)

분포의 모양(PDF)을 몰라도, 평균(μ)과 분산(σ^2)만 안다면 확률의 한계(Limit)를 설정할 수 있습니다. 이것은 리스크 관리(Risk Management)의 기초입니다.

0.2.1 1. 마르코프 부등식 (Markov Inequality)

□ 평균의 시소 원리

- 조건: 데이터가 음수가 아닐 때 ($X \geq 0$).
- 직관: 평균(무게중심)이 정해져 있다면, 아주 큰 값이 나올 확률은 작아야만 합니다. 그래야 시소가 균형을 잡으니까요.
- 공식:

$$P(X \geq a) \leq \frac{E[X]}{a}$$

□ 예시: 연봉 분포 미스터리

어떤 회사의 평균 연봉이 5,000만 원이라는 것만 알고 있습니다. 이 회사에서 5억 원 (평균의 10배) 이상 받는 사람은 최대 몇 명일까요?

- 정확한 분포는 모릅니다. 하지만 마르코프 부등식에 의해:

$$P(X \geq 5\text{억}) \leq \frac{5\text{천만}}{5\text{억}} = \frac{1}{10} = 10\%$$

- 결론: 고액 연봉자는 아무리 많아봤자 전 직원의 10%를 넘을 수 없습니다. (절대적 상한선)

0.2.2 2. 체비셰프 부등식 (Chebyshev Inequality)

□ 분산이 알려주는 거리의 제약

- 조건: 모든 분포에 적용 가능. (분산 σ^2 을 알 때)
- 직관: 분산(퍼짐)이 작다면, 데이터는 평균 근처에 모여 있어야 합니다. 평균에서 멀리 떨어진 꼬리(Tail) 확률은 급격히 줄어듭니다.
- 공식:

$$P(|X - \mu| \geq c) \leq \frac{\text{var}(X)}{c^2}$$

(거리 c 가 멀어질수록 확률은 제곱(c^2)으로 줄어듭니다.)

0.3 핵심 개념 2: 대수의 법칙 (Laws of Large Numbers)

”데이터가 깡패다.” 데이터(n)가 많아지면 표본 평균(M_n)은 흔들림을 멈추고 진실(μ)로 수렴합니다.

0.3.1 분산의 축소 (Variance Shrinking)

왜 수렴할까요? 수학적 엔진은 바로 분산이 줄어들기 때문입니다.

$$M_n = \frac{X_1 + \dots + X_n}{n} \implies \text{var}(M_n) = \frac{\sigma^2}{n}$$

- $n \rightarrow \infty$ 이면 분산 $\rightarrow 0$ 이 됩니다.
- 분산이 0이라는 뜻은, 분포가 평균 μ 한 점에 뽕족하게 모인다는 뜻입니다. (불확실성 소멸)

잠깐! 오해하기 쉬워요: 약법칙(Weak) vs 강법칙(Strong)

- **약법칙 (WLLN):** "오차가 발생할 확률이 0이 된다." (가끔 튀는 놈이 나올 수는 있지만, 그 가능성이 희박해짐)
- **강법칙 (SLLN):** "결과값 자체가 100% 확률로 진실에 쏠린다." (시뮬레이션 그래프가 진동하다가 결국 일직선이 됨)
- **실무적 결론:** 엔지니어링에서는 둘 다 "데이터 많으면 평균 믿어도 된다"로 해석해도 무방합니다.

0.4 핵심 개념 3: 중심 극한 정리 (Central Limit Theorem)

이 챕터의 하이라이트입니다. LLN이 "평균으로 간다"는 위치를 알려줬다면, CLT는 "어떤 모양으로 가는가?"를 알려줍니다.

□ 모든 길은 정규 분포로 통한다

원래 데이터가 이항 분포든, 균등 분포든, 지수 분포든 상관없습니다. "독립적인 확률 변수들을 많이 더하면(S_n) 그 합이 분포는 정규 분포(N)에 가까워진다."

0.4.1 CLT 문제 해결 3단계 레시피

복잡한 합의 확률을 구해야 할 때, 다음 절차를 따르세요.

□ CLT 해결 레시피: 표준화(Standardization) 후 근사

상황: $S_n = X_1 + \dots + X_n$ (합계)의 확률을 구하고 싶다.

1단계: 평균과 분산 계산

- 합의 평균: $E[S_n] = n\mu$
- 합의 분산: $\text{var}(S_n) = n\sigma^2$ (표준편차는 $\sigma\sqrt{n}$)

2단계: 표준화 (Z-score 변환) 정규 분포표를 쓰기 위해 Z 로 바꿉니다.

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}}$$

3단계: 근사 (Approximation) 이제 Z_n 을 표준 정규 분포 $N(0, 1)$ 로 취급하여 표에서 확률 $\Phi(z)$ 를 찾습니다.

0.5 실전 응용: 게임 서버 용량 설계 (Capacity Planning)

□ 실전 시나리오: 넥슨 서버 개발자의 고민

신규 게임 출시를 앞두고 있습니다.

- 유저 1명의 접속 트래픽 (X_i)은 평균 10MB(μ), 표준편차 5MB(σ)입니다. (분포는 모름, 아마도 지수 분포?)
- 동시 접속자가 10,000명 (n) 일 때, 총 트래픽 (S_n)이 서버 용량인 100,500MB를 초과하여 서버가 터질 확률은?

해결 과정 (CLT 적용):

1. 기초값: $n = 10000$, $\mu = 10$, $\sigma = 5$.

2. 합의 통계량:

- 평균 $E[S_n] = 10000 \times 10 = 100,000$ MB
- 분산 $\text{var}(S_n) = 10000 \times 25 \implies$ 표준편차 $\sqrt{250000} = 500$ MB

3. 표준화: 우리가 궁금한 임계값 100,500을 Z 로 변환.

$$Z = \frac{100,500 - 100,000}{500} = \frac{500}{500} = 1$$

4. 결론: $P(Z > 1)$ 을 구하면 됩니다. 정규 분포표에서 $P(Z \leq 1) \approx 0.84$.

$$P(S_n > 100500) \approx 1 - 0.84 = 0.16$$

해석: 서버가 터질 확률이 16%나 됩니다! (위험함). 용량을 늘려야 합니다.

0.6 초심자가 자주 묻는 질문 (FAQ)

Q1. n 이 얼마나 커야 정규 분포라고 볼 수 있나요?

보통 통계학 교과서에서는 $n \geq 30$ 이면 충분하다고 봅니다. 하지만 분포가 심하게 치우친 (Skewed) 경우라면 데이터가 더 많이 필요할 수 있습니다.

Q2. 왜 $\sqrt{n}$ 으로 나누나요?

이게 핵심입니다! 합(S_n)은 n 에 비례해서 커지지만, 변동성(표준편차)은 $\sqrt{n}$ 에 비례해서 커집니다. 즉, 신호 (Signal, n)가 소음 (Noise, $\sqrt{n}$)보다 더 빨리 커지기 때문에, 데이터가 많을수록 비율적으로 안정되는 것입니다.

Q3. 마르코프와 체비셰프 중 뭘 써야 하나요?

정보가 많을수록 더 강력한(Tight) 부등식을 쓸 수 있습니다.

- 평균만 안다 $\rightarrow$ 마르코프 (범위가 넓음)
- 분산까지 안다 $\rightarrow$ 체비셰프 (범위가 좁혀짐)
- 분포 모양(종 모양)까지 안다 $\rightarrow$ 정규 분포 계산 (정확함)

0.7 요약 및 다음 단계

□ Unit 3-1 핵심 요약

1. **부등식**: 분포를 몰라도 평균(μ)과 분산(σ^2)만 있으면 리스크의 상한선을 그을 수 있다.
2. **LLN**: 데이터가 많으면 표본 평균 $\approx$ 진짜 평균이다. (믿어라!)
3. **CLT**: 데이터 합계의 분포는 결국 정규 분포(Z)로 수렴한다.
4. **공학적 의미**: 복잡한 세상의 현상을 정규 분포라는 단순한 모델로 근사(Approximation)하여 해석할 수 있게 해준다.

[다음 단원 예고]

지금까지는 $n \rightarrow \infty$ 로 갈 때의 '분포'를 봤습니다. 이제 시간 t 가 흐르면서 사건이 발생하는 '**과정 (Process)**'을 다룹니다.

다음 장 **Chapter 8: 베르누이와 포아송 프로세스**에서는 "동전을 영원히 던지는 상황"과 "콜센터 전화가 계속 오는 상황"을 모델링합니다.