

MIT 18.6501: 통계학의 수학적 기초

Fundamentals of Statistics Notes

Contents

1	Unit 1. 통계적 모델링과 우도 (Modeling, Identifiability, Likelihood)	2
1.1	1. 통계적 모델 (Statistical Model)	2
1.2	2. 식별 가능성 (Identifiability)	3
1.3	3. 우도 (Likelihood)	4
2	로그 우도 (Log-Likelihood)와 실전 적용	5
3	자주 묻는 질문 (FAQ)	6

Course Structure & Current Focus

- Unit 0: Probability Review (Prerequisites)
- **Unit 1: Modeling, Identifiability, Likelihood (현재 단위)**
 - 1.1 Statistical Model
 - 1.2 Identifiability
 - 1.3 Likelihood Function
- Unit 2: Maximum Likelihood Estimation (MLE)
- Unit 3: Method of Moments
- Unit 4: Hypothesis Testing

1 Unit 1. 통계적 모델링과 우도 (Modeling, Identifiability, Likelihood)

지난 시간(*Unit 0*)까지 우리는 확률론의 기초와 큰 수의 법칙(LLN), 중심극한 정리(CLT)라는 무기를 손에 넣었습니다. 이제 이 무기를 가지고 현실 세계의 데이터를 분석하기 위해, 가장 먼저 해야 할 일은 '데이터를 담은 수학적 그릇(모델)'을 만드는 것입니다.

□ 개요 (Overview)

통계학을 제대로 하기 위해서는 현실의 불확실한 데이터를 수학적으로 엄밀하게 정의해야 합니다. 이 단원에서는 데이터를 수학적 집합으로 변환하는 통계적 모델(Statistical Model)의 정의, 모델의 파라미터가 유일한지 확인하는 식별 가능성(Identifiability), 그리고 데이터를 통해 파라미터를 추정하기 위한 도구인 우도(Likelihood)의 개념을 배웁니다. 이는 추후 배울 '최대우도추정(MLE)'을 위한 필수적인 기초 작업입니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Sample Space (E)	데이터가 나올 수 있는 모든 후보들의 집합 (무대)
Parameter Space (Θ)	우리가 찾고 싶은 정답(θ)이 숨어있는 범위
Statistical Model	데이터가 발생할 수 있는 확률 규칙들의 모음집
Identifiability	범인의 지문이 유일한가? (파라미터 구별 가능 여부)
Likelihood (L_n)	이 데이터가 관측되었을 때, 범인이 θ 일 가능성

1.1 1. 통계적 모델 (Statistical Model)

□ 개념 1: 통계적 모델이란 무엇인가?

한 줄 요약: 현실의 막연한 데이터를 엄밀한 수학적 집합(Set)과 확률(Probability)로 번역하는 과정입니다.

1) 직관적 비유: 맞춤 정장 만들기

현실의 데이터는 '사람의 몸'과 같습니다. 통계적 모델은 이 몸에 딱 맞는 '정장(수트)'을 만드는 과정입니다.

- **표본 공간 (E):** 옷감이 될 수 있는 재료들입니다. (면인가? 실크인가?)
- **파라미터 공간 (Θ):** 옷의 치수 조절 범위입니다. (허리 20 40인치 사이)
- **확률 분포 족 ($\{P_\theta\}$):** 치수(θ)에 따라 만들어지는 다양한 옷 디자인들입니다.

우리는 이 중에서 '내 몸(데이터)'에 가장 잘 맞는 옷(θ)을 찾고 싶은 것입니다.

2) 기술적 정의 및 수학적 구조

통계적 모델은 쌍(Pair) $(E, \{P_\theta\}_{\theta \in \Theta})$ 으로 정의됩니다.

1. **Sample Space (E):** 관측 데이터 X 가 취할 수 있는 값들의 집합.
2. **Parameter Space (Θ):** 미지수 θ 가 속한 집합. $\Theta \subseteq \mathbb{R}^k$.
3. **Probability Family (P_θ):** θ 값 하나가 정해지면, 그에 대응하는 확률 분포 하나가 결정됩니다.

3) 구체적 예시: 동전 던지기 (베르누이 모델)

우리가 앞면(1), 뒷면(0) 이 나오는 동전을 던진다고 합시다.

- $E = \{0, 1\}$ (동전은 0 아니면 1 만 나옵니다.)
- $\Theta = [0, 1]$ (앞면이 나올 확률 p 는 0 과 1 사이입니다.)
- $\{P_\theta\} =$ 베르누이 분포 $\text{Ber}(p)$ 들의 집합.

오해 방지: 잘 정의된 모델 (Well-specified) 이란?

”모델을 세운다”는 것은 가정을 한다는 뜻입니다. 만약 실제 데이터는 '주사위 (1 6)' 인데, 모델을 '동전 (0,1)' 으로 세우면 어떻게 될까요?

- 실제 데이터 생성 원리 P 가 우리 모델 집합 $\{P_\theta\}$ 안에 없을 때, 이를 **Misspecified Model** 이라고 합니다.
- 반대로, 실제 자연의 법칙 P 가 우리 모델 안에 포함되어 있다면 **Well-specified Model** 이라고 합니다.

1.2 2. 식별 가능성 (Identifiability)

□ 개념 2: 이 모델로 정답을 찾을 수 있는가?

한 줄 요약: 서로 다른 원인(파라미터)이 서로 다른 결과(분포)를 만들어야만, 결과를 보고 원인을 역추적할 수 있습니다.

1) 직관적 비유: 범인의 지문

범죄 현장에서 지문을 채취했습니다(데이터).

- **식별 가능:** 모든 사람의 지문이 다르다면, 지문을 보고 범인을 특정할 수 있습니다.
- **식별 불가능:** 만약 철수와 영희의 지문이 똑같이 생겼다면? 지문을 확보해도 둘 중 누가 범인인지 알 수 없습니다.

2) 기술적 정의

함수 $\theta \mapsto P_\theta$ 가 단사함수(Injective)여야 합니다. 즉,

$$\theta \neq \theta' \implies P_\theta \neq P_{\theta'}$$

만약 서로 다른 θ 가 같은 P_θ 를 만든다면, 데이터가 무한히 많아도 θ 를 추정할 수 없습니다.

3) 숫자 예시: 식별 불가능한 경우 (Non-identifiable)

어떤 데이터 X 가 평균이 $\mu_1 + \mu_2$ 인 정규분포를 따른다고 가정해 봅시다.

$$X \sim \mathcal{N}(\mu_1 + \mu_2, 1)$$

우리가 데이터에서 평균이 5라는 사실을 알아냈습니다.

- 경우 A: $\mu_1 = 2, \mu_2 = 3 \rightarrow$ 합 5
- 경우 B: $\mu_1 = 1, \mu_2 = 4 \rightarrow$ 합 5

μ_1 과 μ_2 의 조합은 무수히 많습니다. 데이터만으로는 절대 진짜 (μ_1, μ_2) 를 찾을 수 없습니다. 이것이 식별 불가능입니다.

1.3 3. 우도 (Likelihood)

□ 개념 3: 관점의 대전환

한 줄 요약: "데이터가 주어졌을 때, 이 파라미터가 정답일 점수는 몇 점인가?"를 계산하는 함수입니다.

1) 직관적 비유: 명탐정 코난

- **확률(PDF):** 범인(θ)이 정해져 있을 때, 어떤 증거(x)를 남길지 예측하는 것. (미래 예측)
- **우도(Likelihood):** 증거(x)가 이미 확보되었을 때, 누가 범인(θ)일지 추리하는 것. (과거 추론)

2) 기술적 정의: i.i.d와 결합 확률

데이터 $X_1, \dots, X_n$ 이 서로 독립(Independent)이고 같은 분포(Identically Distributed)를 따른다고 가정합니다. 우도 함수 $L_n(\theta)$ 는 결합 확률 밀도 함수(Joint PDF)와 식은 같지만, 주인공(변수)이 다릅니다.

$$L_n(\theta) = \prod_{i=1}^n f(X_i; \theta)$$

여기서 X_i 는 이미 관측된 고정값(상수)이고, θ 가 변수입니다.

3) 계산 예시: 불량품 찾기

공장에서 부품을 3개 뽑았는데 (양품, 양품, 불량)이 나왔습니다. 양품확률을 p 라고 합시다. (1=양품, 0=불량) 데이터: $X_1 = 1, X_2 = 1, X_3 = 0$.

- 가설 A ($p = 0.5$): 공장이 반반 확률로 만듦.

$$L_3(0.5) = 0.5 \times 0.5 \times (1 - 0.5) = 0.125$$

- 가설 B ($p = 0.9$): 공장이 90% 확률로 잘 만듦.

$$L_3(0.9) = 0.9 \times 0.9 \times (1 - 0.9) = 0.081$$

결과: 이 데이터(양, 양, 불) 기준으로는 가설 A($p = 0.5$)의 우도(0.125)가 더 높습니다. 즉, $p = 0.5$ 일 가능성이 더 높다고 추론할 수 있습니다.

2 로그 우도 (Log-Likelihood)와 실전 적용

왜 로그를 취하는가?

우도 L_n 은 확률의 곱셈($\prod$)입니다. n 이 커지면 값이 0에 너무 가깝게 작아져서 컴퓨터가 계산하지 못합니다(Underflow). 따라서 로그를 취해 덧셈($\sum$)으로 바꿉니다. 로그는 단조증가 함수이므로 최대값의 위치는 변하지 않습니다.

$$\ell_n(\theta) = \sum_{i=1}^n \log f(X_i; \theta)$$

실전 시나리오: 사용자 체류 시간 분석

당신이 앱 서비스 기획자라고 가정합니다. 사용자의 체류 시간(T)이 지수 분포 $f(t; \lambda) = \lambda e^{-\lambda t}$ 를 따른다고 모델링했습니다.

1. 데이터 수집: 3명의 유저가 각각 2분, 3분, 5분을 머물렀습니다. ($x_1 = 2, x_2 = 3, x_3 = 5$)

2. 우도 함수 구성:

$$L(\lambda) = (\lambda e^{-2\lambda}) \times (\lambda e^{-3\lambda}) \times (\lambda e^{-5\lambda}) = \lambda^3 e^{-10\lambda}$$

3. 로그 우도:

$$\ell(\lambda) = \log(\lambda^3 e^{-10\lambda}) = 3 \log \lambda - 10\lambda$$

4. 최적화: 이것을 미분해서 0이 되는 λ 를 찾으면, 그것이 바로 가장 그럴듯한(Likely) 파라미터입니다.

3 자주 묻는 질문 (FAQ)

Q1. 확률(Probability)과 우도(Likelihood)는 같은 거 아닌가요? A. 아니요, 정반대입니다!

- 확률: θ 가 고정 $\rightarrow$ 데이터 x 가 변수. (적분하면 1)
- 우도: 데이터 x 가 고정 $\rightarrow$ 파라미터 θ 가 변수. (적분해도 1이 아님)

Q2. 왜 식별 가능성(Identifiability)을 먼저 확인하나요? A. 식별 불가능한 모델을 가지고 우도 계산을 하는 것은, 답이 없는 문제를 열심히 푸는 것과 같습니다. 열심히 계산해서 우도가 최대인 지점을 찾아도, 그 θ 가 유일한 정답이라고 확신할 수 없기 때문입니다.

Next Step: 우리는 이제 '우도 함수'라는 강력한 점수판을 만들었습니다. 다음 단원인 **Unit 2**에서는 미분(Calculus)을 사용하여 이 우도 함수를 **최대화(Maximum)** 시키는 θ , 즉 **MLE(Maximum Likelihood Estimator)**를 구하는 법을 본격적으로 배웁니다.

Unit 1 핵심 요약

- **통계적 모델:** 데이터를 설명하기 위한 수학적 가정 $(E, \{P_\theta\})$.
- **식별 가능성:** 파라미터가 다르면 분포도 달라야 한다 $(\theta \neq \theta' \implies P_\theta \neq P_{\theta'})$. 이것이 보장되어야 추정이 가능하다.
- **우도(Likelihood):** 관측된 데이터 X 를 고정하고, 파라미터 θ 를 변화시키며 '가능성'을 측정하는 함수.
- **로그 우도:** 계산의 편의성과 미분을 위해 우도에 로그를 취한 형태 $(\sum \log f)$.