

MIT 18.6501: 통계적 추론의 핵심

Unit 2: Point Estimation (점 추정)

Contents

1	Unit 2. 점 추정 (Point Estimation)	2
1.1	1. 추정량(Estimator)의 정의와 본질	2
1.2	2. 최대우도추정 (MLE, Maximum Likelihood Estimation)	3
1.3	3. 적률법 (MoM, Method of Moments)	4
1.4	4. 추정량의 성질 (Properties): 성적표 매기기	4
2	실전 시나리오: 모바일 게임 가차 확률 검증	5
3	자주 묻는 질문 (FAQ)	6

Course Structure & Current Focus

- Unit 1: Modeling, Identifiability, Likelihood (완료)
- **Unit 2: Point Estimation (현재 단위)**
 - 2.1 Estimator: Definition & Intuition
 - 2.2 Maximum Likelihood Estimation (MLE)
 - 2.3 Method of Moments (MoM)
 - 2.4 Properties: Bias, Variance, MSE
- Unit 3: Confidence Intervals (구간 추정)
- Unit 4: Hypothesis Testing (가설 검정)

1 Unit 2. 점 추정 (Point Estimation)

*Unit 1*에서 우리는 '우도 (Likelihood)'라는 강력한 도구를 만들었습니다. 이제 질문을 던질 차례입니다. "그래서 그 우도를 가장 높게 만드는 범인(θ)은 정확히 누구인가?" 이번 단원에서는 미지의 파라미터를 하나의 숫자(Point)로 찍어 맞추는 방법과, 그 방법의 성적을 매기는 기준을 배웁니다.

□ 개요 (Overview)

점 추정은 데이터를 함수에 넣어 미지의 파라미터 θ 에 대한 최적의 추측값 $\hat{\theta}$ 를 계산하는 과정입니다. 우리는 두 가지 주요 방법론인 MLE(최적화 접근)와 MoM(대수의 법칙 접근)을 배우고, 추정량이 좋은지 나쁜지를 판별하는 MSE(Bias-Variance Trade-off) 프레임워크를 익힙니다. 이것은 머신러닝의 손실 함수(Loss Function) 개념의 기초가 됩니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Estimator ($\hat{\theta}_n$)	데이터를 입력받아 추정값을 뱉어내는 '함수' (공식 그 자체)
Estimate	실제 데이터를 넣어 계산된 구체적인 '숫자'
Bias (편향)	영점 조절 상태. 평균적으로 정답을 맞히는가?
Variance (분산)	정밀도. 데이터가 조금 바뀔 때 추정값이 얼마나 흔들리는가?
MSE	종합 점수. 편향의 제곱과 분산을 합친 총 에러.

1.1 1. 추정량(Estimator)의 정의와 본질

□ 개념 1: 추정량은 숫자가 아니라 '함수'이자 '확률변수'다

한 줄 요약: 추정량은 데이터가 들어오면 정답을 내놓는 '기계'이며, 들어오는 데이터가 랜덤하므로 기계가 내놓는 답도 랜덤하게 변합니다.

1) 직관적 비유: 여론조사 기관

대통령 지지율(θ)을 알고 싶습니다.

- 추정량($\hat{\theta}$): "지나가는 사람 100명에게 물어보고 찬성 비율을 계산한다"라는 규칙입니다.
- 확률변수로서의 성격: 오늘 100명을 조사했을 때와, 내일 100명을 조사했을 때 결과는 다를 것입니다. 즉, $\hat{\theta}$ 는 고정된 값이 아니라 분포(Distribution)를 가집니다.

2) 기술적 정의

추정량 $\hat{\theta}_n$ 은 표본 $X_1, \dots, X_n$ 의 함수입니다.

$$\hat{\theta}_n = g(X_1, \dots, X_n)$$

중요 조건: 이 함수 g 안에는 미지의 파라미터 θ 가 들어 있으면 안 됩니다. (우리가 모르는 값을 이용해 계산할 수는 없으니까요.)

1.2 2. 최대우도추정 (MLE, Maximum Likelihood Estimation)

□ 개념 2: 가장 그럴듯한 범인 찾기

한 줄 요약: "현재의 데이터가 관찰될 확률을 수학적으로 가장 높여주는 θ 값을 정답으로 채택하자."

1) 직관적 비유: 등산하기

안개 낀 산(로그 우도 함수)에서 가장 높은 봉우리(최대값)를 찾아가는 과정입니다.

- 산의 높이: $\ell_n(\theta)$ (로그 우도)
- 전략: 기울기(미분값)가 0이 되는 지점을 찾는다.

2) 수학적 절차 (Algorithm)

1. **Log-Likelihood:** $\ell_n(\theta) = \sum_{i=1}^n \log f(X_i; \theta)$ 를 구합니다.
2. **Differentiate:** θ 에 대해 미분합니다. $\frac{\partial}{\partial \theta} \ell_n(\theta)$.
3. **Solve:** 미분값이 0이 되는 방정식(Estimating Equation)을 푹니다.
4. **Check:** 두 번 미분하여 음수인지(위로 볼록, Concave) 확인하여 최대값임을 보장합니다.

3) 계산 예시: 포아송 분포 (웹사이트 방문자 수)

하루 방문자 수 X 가 포아송 분포 $\text{Pois}(\lambda)$ 를 따른다고 가정합니다. ($\theta = \lambda$)

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

데이터: $X_1, \dots, X_n$

- 로그 우도: $\ell_n(\lambda) = \sum (-\lambda + X_i \ln \lambda - \ln X_i!) = -n\lambda + (\sum X_i) \ln \lambda - C$
- 미분: $\frac{\partial}{\partial \lambda} \ell_n(\lambda) = -n + \frac{\sum X_i}{\lambda}$
- 0으로 놓기: $-n + \frac{\sum X_i}{\lambda} = 0 \implies \hat{\lambda}_{MLE} = \frac{1}{n} \sum X_i = \bar{X}$

결론: 포아송 분포의 MLE는 직관적이게도 표본 평균입니다.

1.3 3. 적률법 (MoM, Method of Moments)

□ 개념 3: 평균을 평균에 맞춘다

한 줄 요약: "이론적인 평균(Population Mean)이 실제 데이터의 평균(Sample Mean)과 같아야 한다"는 단순한 믿음에서 출발합니다.

1) 직관적 비유: 요리 간 맞추기

국물 맛(데이터)을 봅니다.

- 이론: 소금(θ)을 1스푼 넣으면 짠맛 농도($E[X]$)가 10이 되어야 한다.
- 실제: 국물을 떠서 맛보니 짠맛 농도($\bar{X}$)가 20이다.
- 추론: "아, 소금이 2스푼 들어갔겠구나($\hat{\theta} = 2$)."

2) 수학적 정의

k 번째 이론적 적률(Moment) $m_k(\theta) = E[X^k]$ 을 구하고, 이를 표본 적률 $\frac{1}{n} \sum X_i^k$ 과 같다고 둡니다.

$$E[X] = \bar{X} \quad (1 \text{ 차 모멘트 매칭})$$

미지수가 2개면 2차 모멘트($E[X^2]$)까지 사용합니다.

MLE vs MoM: 누가 더 좋은가?

일반적으로 MLE가 더 정밀(Efficient)합니다. 하지만 MLE는 계산이 복잡하거나 미분이 불가능할 수 있습니다. 이때 계산이 쉬운 MoM을 먼저 구해서 MLE를 찾기 위한 초기값(Initial Guess)으로 사용하는 경우가 많습니다.

1.4 4. 추정량의 성질 (Properties): 성적표 매기기

□ 개념 4: Bias-Variance Trade-off

한 줄 요약: 좋은 추정량은 영점이 잘 잡혀있어야 하고(Low Bias), 쏠 때마다 탄착군이 좁게 모여야 합니다(Low Variance).

1) 편향 (Bias): 영점 조절

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

추정량을 무한히 반복했을 때, 그 평균이 과연 정답(θ)과 일치하는가?

- $\text{Bias} = 0$: 비편향 추정량 (Unbiased). 영점이 정확함.
- $\text{Bias} \neq 0$: 편향 추정량 (Biased). 영점이 틀어짐.

2) 분산 (Variance): 탄착군 크기

$$\text{Var}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2]$$

데이터가 바뀔 때마다 추정값이 얼마나 들쭉날쭉한가? (안정성)

3) MSE (Mean Squared Error): 최종 점수

우리의 목표는 에러의 총합을 줄이는 것입니다.

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \underbrace{\text{Bias}(\hat{\theta})^2}_{\text{영점 오차}} + \underbrace{\text{Var}(\hat{\theta})}_{\text{흔들림}}$$

인사이트: 때로는 영점이 조금 틀어지더라도 (Bias 존재), 탄착군을 획기적으로 좁힐 수 있다면 (Variance 감소), 그게 더 좋은 추정량일 수 있습니다. (이것이 현대 머신러닝의 핵심 철학입니다.)

2 실전 시나리오: 모바일 게임 가차 확률 검증

□ Scenario: 유저들의 불만

당신은 게임 회사 넥슨의 PM입니다. "전설 아이템 획득 확률(p)이 1%라고 했는데, 너무 안 나온다!"라는 유저 불만이 폭주합니다. 데이터를 확인해보니, 100명의 유저가 가차를 돌렸고 그중 딱 1명만 성공했습니다. ($n = 100, \sum x_i = 1$)

1. **모델링:** 성공/실패이므로 베르누이 분포 $X \sim \text{Ber}(p)$ 입니다.
2. **MLE 적용:** 베르누이의 MLE는 표본 평균입니다.

$$\hat{p}_{MLE} = \frac{1}{100} = 0.01 (1\%)$$

회사 측 입장: "데이터로 추정해 보니 1%가 맞습니다. 시스템은 정상입니다."

3. **Bayesian 관점 (심화 예고):** 하지만 만약 유저가 3명만 돌려서 0명이 나왔다면? $\hat{p} = 0\%$. 확률이 0이라고 단정할 수 있을까요? 이때는 "과거의 경험 (Prior)"을 섞는 베이지안 방식이 필요할 수 있습니다.

3 자주 묻는 질문 (FAQ)

- Q1. 비편향(Unbiased) 추정량이 무조건 좋은 건가요?** A. 아닙니다! 비편향이지만 분산이 태평양만큼 넓다면 쓸모가 없습니다. 약간의 편향을 감수하더라도 분산이 매우 작은 추정량(예: Ridge Regression)을 선택하는 경우가 많습니다. 결국 **MSE(총에러)**가 작은 것이 장땡입니다.
- Q2. MLE는 항상 정답을 주나요?** A. 데이터가 무한히 많다면($n \rightarrow \infty$) MLE는 참값으로 수렴합니다(Consistency). 하지만 데이터가 적을 때(n 이 작을 때)는 MLE도 틀릴 수 있고, 심지어 편향(Biased)되어 있을 수도 있습니다. (예: 정규분포 분산의 MLE는 편향되어 있음).

Next Step: 우리는 점 추정을 통해 $\hat{\theta} = 0.01$ 이라는 숫자를 얻었습니다. 하지만 이 숫자가 얼마나 확실한지는 아직 모릅니다. 0.01이라곤 했지만, 실제로는 0.005일 수도 있고 0.015일 수도 있지 않을까요? 다음 **Unit 3**에서는 이 불확실성을 감안하여 정답이 있을 만한 구간(**Interval**)을 구하는 법을 배웁니다.

Unit 2 핵심 요약

- **추정량(Estimator):** 데이터의 함수이자 확률변수. 분포를 가진다.
- **MLE:** 우도(Likelihood)를 최대화하는 값을 찾는다. (미분 $\nabla \ell = 0$)
- **MoM:** 표본 평균을 이론적 평균과 같다고 둔다. (계산이 쉬움)
- **Bias-Variance Trade-off:** $MSE = Bias^2 + Var$. 편향과 분산의 균형을 맞춰 전체 에러를 줄이는 것이 목표다.