

MIT 18.6501: 무한한 데이터의 힘

Unit 3: Asymptotic Properties (점근적 성질)

Contents

1	Unit 3. 점근적 성질 (Asymptotic Properties)	2
1.1	1. 일치성 (Consistency)	2
1.2	2. 점근적 정규성 (Asymptotic Normality)	3
1.3	3. 피셔 정보와 크래머-라오 하한 (CRLB)	3
1.4	4. 델타 방법 (Delta Method)	4
2	실전 시나리오: 모바일 게임 리텐션(재접속률) 예측	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 1: Modeling (무대 세팅)
- Unit 2: Point Estimation (범인 지목)
- **Unit 3: Asymptotic Properties (현재 단위: 무한대로 확장)**
 - 3.1 Consistency (일치성)
 - 3.2 Asymptotic Normality (점근적 정규성)
 - 3.3 Fisher Information & CRLB (추정의 한계)
 - 3.4 Delta Method (함수의 추정)
- Unit 4: Hypothesis Testing (가설 검정)

1 Unit 3. 점근적 성질 (Asymptotic Properties)

Unit 2에서 우리는 $\hat{\theta}$ 라는 '추정량'을 만들었습니다. 하지만 데이터 개수(n)가 적을 때는 이 추정량이 얼마나 정확한지 계산하기 어렵습니다(분산 공식이 복잡함). 그래서 우리는 질문을 바꿉니다. "만약 데이터가 무한히 많아진다면($n \rightarrow \infty$), 이 추정량은 결국 정답을 맞히게 될까?" 이것이 통계적 추론의 이론적 보증수표가 됩니다.

□ 개요 (Overview)

이 단원에서는 데이터의 크기 n 이 커질 때 추정량이 가지는 극한의 성질을 다룹니다. 추정량이 참값으로 수렴하는지(Consistency), 오차의 분포가 정규분포를 따르는지(Asymptotic Normality) 확인하고, 추정 정밀도의 절대적 한계선(CRLB)을 수학적으로 규명합니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Consistency (일치성)	데이터를 많이 모으면, 결국 정답을 찾아내는가?
Asymptotic Normality	오차의 모양이 종 모양(정규분포)으로 예쁘게 모이는가?
Fisher Information (I)	데이터 하나가 파라미터에 대해 주는 힌트의 양 (곡률).
CRLB	신(God)도 이보다 더 정확하게 추정할 순 없다 (분산의 하한선).
Delta Method	$\hat{\theta}$ 의 분포를 알 때, $f(\hat{\theta})$ 의 분포를 근사하는 기술.

1.1 1. 일치성 (Consistency)

□ 개념 1: 좋은 추정량의 최소 자격 요건

한 줄 요약: 데이터가 쌓일수록 추정값의 오차가 0으로 줄어들어, 결국 참값과 같아져야 합니다.

1) 직관적 비유: 디지털 사진의 해상도

- n 이 작을 때: 저화질 픽셀 사진. 무엇인지 흐릿하게 보입니다.
- $n \rightarrow \infty$: 고화질 4K 사진. 실제 피사체(참값 θ^*)와 완전히 똑같이 보입니다.
- 만약 데이터를 무한히 모았는데도 사진이 흐릿하다면? 그 카메라는 고장난 것입니다(Inconsistent).

2) 기술적 정의: 확률적 수렴

추정량 $\hat{\theta}_n$ 이 참값 θ^* 로 **확률 수렴 (Converge in Probability)** 해야 합니다.

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta^*| > \epsilon) = 0$$

의미: 오차가 ϵ 보다 클 가능성이, 데이터가 늘어날수록 0이 된다. (주로 **대수의 법칙 (LLN)**에 의해 보장됩니다.)

1.2 2. 점근적 정규성 (Asymptotic Normality)

□ 개념 2: 모든 길은 정규분포로 통한다

한 줄 요약: 원래 데이터 분포가 무엇이든 상관없이, "추정 오차"의 분포는 종 모양 (Bell Curve)을 따릅니다.

1) 직관적 비유: 돋보기로 확대하기

n 이 커지면 $\hat{\theta}_n$ 은 θ^* 라는 한 점으로 뭉칩니다(분산 $\rightarrow 0$). 분포를 보려면 이 오차를 **확대**해야 합니다.

- 그냥 오차: $\hat{\theta}_n - \theta^* \rightarrow 0$ (너무 작아서 안 보임)
- $\sqrt{n}$ 배 확대: $\sqrt{n}(\hat{\theta}_n - \theta^*)$ (이제 모양이 보임 $\rightarrow$ 정규분포!)

2) 기술적 정의

$$\sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{d} \mathcal{N}(0, \sigma_{asymp}^2)$$

여기서 σ_{asymp}^2 를 점근 분산(Asymptotic Variance)이라고 합니다. 이것을 알아야 신뢰 구간을 만들 수 있습니다.

1.3 3. 피셔 정보와 크래머-라오 하한 (CRLB)

□ 개념 3: 추정 정밀도의 물리적 한계선

한 줄 요약: 정보가 많을수록(곡선이 뽀족할수록) 분산은 작아지며, 그 한계는 피셔 정보의 역수입니다.

1) 직관적 비유: 산봉우리의 뽀족함

로그 우도 함수(Likelihood)를 산이라고 생각합시다.

- **뽀족한 산 (High Curvature):** 정상(최대값)의 위치가 아주 명확합니다. $\rightarrow$ 정보 많음, 분산 작음.
- **평평한 산 (Low Curvature):** 어디가 정상인지 헷갈립니다. $\rightarrow$ 정보 적음, 분산 큼.

2) 공식 및 계산 예시 (동전 던지기)

파라미터 θ 에 대해 우도 함수의 '불록한 정도(2계 도함수)'가 정보량입니다.

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right]$$

예시: 베르누이 분포 ($f(x; p) = p^x(1-p)^{1-x}$)

1. 로그 우도: $\log f = x \log p + (1-x) \log(1-p)$
2. 1차 미분: $\frac{x}{p} - \frac{1-x}{1-p}$
3. 2차 미분: $-\frac{x}{p^2} - \frac{1-x}{(1-p)^2}$
4. 기댓값 ($E[X] = p$): $I(p) = \frac{p}{p^2} + \frac{1-p}{(1-p)^2} = \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}$

결과 (CRLB): 어떤 비편향 추정량도 분산이 $\frac{1}{nI(p)} = \frac{p(1-p)}{n}$ 보다 작을 순 없습니다. (참고: 표본평균 $\bar{X}$ 의 분산이 정확히 이 값입니다. 즉, $\bar{X}$ 는 가장 효율적인 추정량입니다!)

1.4 4. 델타 방법 (Delta Method)

□ 개념 4: 함수를 통과한 추정량의 분포

한 줄 요약: $\hat{\theta}$ 가 정규분포라면, $g(\hat{\theta})$ 도 (근사적으로) 정규분포이며, 분산은 '기울기 제공'만큼 변합니다.

1) 직관적 비유: 지구는 둥글지만 운동장은 평평하다

지구($g(\theta)$ 곡선)는 둥글지만, 우리가 서 있는 좁은 공간에서는 평평한 직선처럼 보입니다. 이 성질(선형 근사)을 이용해 분산을 예측합니다.

2) 공식

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta)]^2 \cdot \sigma^2)$$

원래 분산 σ^2 에 변환 함수의 미분값의 제곱($[g'(\theta)]^2$)을 곱해주면 됩니다.

2 실전 시나리오: 모바일 게임 리텐션(재접속률) 예측

□ Scenario: 대규모 업데이트의 성과

넥슨에서 대규모 업데이트를 진행했습니다. 전체 유저의 재접속률 p 를 추정하려 합니다.

1. **데이터 수집:** $n = 10,000$ 명의 유저 로그를 분석했더니 $\hat{p} = 0.6$ (60%) 이 나왔습니다.
2. **목표:** 우리는 단순히 p 가 아니라, **오즈(Odds)** $\frac{p}{1-p}$ (접속할 확률이 접속 안 할 확률의 몇 배인가?)에 관심이 있습니다.
3. **문제:** $\hat{p}$ 의 분산은 알겠는데, 오즈 $\frac{\hat{p}}{1-\hat{p}}$ 의 신뢰구간은 어떻게 구하죠?
4. **해결 (델타 방법):**
 - 변환 함수: $g(p) = \frac{p}{1-p}$
 - 미분: $g'(p) = \frac{1}{(1-p)^2}$
 - 새로운 분산: 원래 분산 $\frac{p(1-p)}{n}$ 에 $[g'(p)]^2$ 를 곱함.
 - 결론: 복잡한 시뮬레이션 없이도, 미분 한 번으로 오즈 값의 오차 범위를 즉시 계산할 수 있습니다.

3 자주 묻는 질문 (FAQ)

Q1. 데이터가 적으면(n 이 작으면) 이 이론들은 쓸모 없나요? **A.** 완전히 쓸모없는 건 아닙니다. 통계학에서는 보통 $n \geq 30$ 정도면 중심극한정리가 작동한다고 봅니다. 하지만 n 이 작을 때는 정규분포 근사가 부정확할 수 있으므로, t-분포를 쓰거나 부트스트랩(Bootstrap) 같은 시뮬레이션 방법을 쓰는 것이 안전합니다.

Q2. 왜 하필 $\sqrt{n}$ 을 곱하나요? 그냥 n 을 곱하면 안 되나요? **A.** 좋은 질문입니다!

- 오차($\hat{\theta} - \theta$)는 대략 $\frac{1}{\sqrt{n}}$ 의 속도로 줄어듭니다.
- 그냥 두면 0이 되고, n 을 곱하면 발산(∞)해 버립니다.
- 딱 균형을 맞춰서 안정적인 분포(정규분포)를 만들기 위해 역수인 $\sqrt{n}$ 을 곱하는 것입니다.

Next Step: 이제 우리는 추정량 $\hat{\theta}$ 가 정규분포를 따른다는 강력한 무기를 얻었습니다. 그렇다면 "이 추정값이 0.5라고 주장하는 것이 타당한가?"를 판단할 수 있겠죠? 다음 Unit 4에서는 이 분포를 이용해 가설을 검증하는 가설 검정(Hypothesis Testing)으로 넘어갑니다.

Unit 3 핵심 요약

- **Consistency:** $n \rightarrow \infty$ 이면 추정량은 참값이 된다.
- **Asymptotic Normality:** 추정 오차는 $\sqrt{n}$ 스케일에서 정규분포 $\mathcal{N}(0, I(\theta)^{-1})$ 를 따른다.
- **Fisher Info & CRLB:** 분산의 하한선은 정보량의 역수다. MLE는 이 한계에 도달하는 최적의 추정량(Efficient Estimator)이다.
- **Delta Method:** 변환된 추정량 $g(\hat{\theta})$ 의 분산은 $g'(\theta)^2 \times \text{Var}(\hat{\theta})$ 이다.