

MIT 18.6501: 최적의 검정 레시피

Unit 6: Testing Methodology (검정 방법론)

Contents

1	Unit 6. 검정 방법론 (Testing Methodology)	2
1.1	1. 네이만-피어슨 보조정리 (Neyman-Pearson Lemma)	2
1.2	2. 우도비 검정 (LRT)과 윌크스 정리	3
1.3	3. 통계적 검정의 삼위일체 (The Holy Trinity)	3
1.4	4. t-test: 데이터가 적을 때의 현실	4
2	실전 계산: 불공정 동전 판별 (Wald Test)	5
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 4: Confidence Intervals (범위 추정)
- Unit 5: Hypothesis Testing Basics (검정의 철학: α, β)
- **Unit 6: Testing Methodology (현재 단원: 구체적인 계산법)**
 - 6.1 Neyman-Pearson Lemma (검정의 황금률)
 - 6.2 Likelihood Ratio Test (LRT) & Wilks' Theorem
 - 6.3 The Holy Trinity (LRT, Wald, Score)
 - 6.4 t-test (소표본 검정)
- Unit 7: Goodness of Fit (적합도 검정)

1 Unit 6. 검정 방법론 (Testing Methodology)

Unit 5에서 우리는 가설 검정이 "1종 오류(α)를 묶어두고 검정력(Power)을 최대화하는 최적화 문제"라는 것을 배웠습니다. 하지만 "그래서 구체적으로 어떤 식을 계산해야 검정력이 최대가 되는데?"라는 질문에는 아직 답하지 않았습니다. 이번 단원에서는 우도(Likelihood)를 이용해 그 '최강의 공식'을 만들어냅니다.

□ 개요 (Overview)

이 단원에서는 검정력을 수학적으로 최대화하는 네이만-피어슨 보조정리를 시작으로, 이를 일반화한 LRT(우도비 검정)를 배웁니다. 특히 우도 함수(Likelihood Function)의 기하학적 형태를 분석하는 3가지 방법(LRT, Wald, Score)의 관계를 이해하고, 데이터가 적을 때 사용하는 t-test까지 다룹니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Neyman-Pearson Lemma	"단순 vs 단순" 가설에서 우도비(Ratio)가 짱이다.
Likelihood Ratio (λ)	$(H_0 \text{ 설명력}) / (H_1 \text{ 설명력})$. 작을수록 H_0 기각.
Wilks' Theorem	LRT 통계량은 데이터가 많으면 카이제곱 분포(χ^2)가 된다.
Wald Test	MLE와 H_0 사이의 수평 거리를 잰다.
Score Test	H_0 지점에서의 기울기(Slope)를 잰다.

1.1 1. 네이만-피어슨 보조정리 (Neyman-Pearson Lemma)

□ 개념 1: 가장 강력한 검정(UMP)을 만드는 레시피

한 줄 요약: 두 개의 점(θ_0 vs θ_1)을 비교할 때, 직관이나 감이 아니라 "우도의 비율"을 기준으로 삼는 것이 수학적으로 가장 정확하다.

1) 직관적 비유: 비밀번호 매칭

두 사람이 각자 자신이 진짜 계정 주인이라고 주장합니다.

- 철수(H_0): "비밀번호는 1234야."
- 영희(H_1): "비밀번호는 5678이야."

우리가 가진 데이터(입력된 키로그)가 1234와 얼마나 비슷한지($L(\theta_0)$), 5678과 얼마나 비슷한지($L(\theta_1)$) 확률을 계산해서 비율을 봅니다. 이 비율만큼 확실한 증거는 없습니다.

2) 수학적 결론

기각역(Rejection Region)을 다음과 같이 설정할 때 검정력(Power)이 최대가 됩니다.

$$\frac{L(\theta_1)}{L(\theta_0)} > k \quad (\text{즉, } H_1 \text{의 우도가 압도적으로 높을 때})$$

이것을 최강력 검정(UMP: Uniformly Most Powerful test)이라고 합니다.

1.2 2. 우도비 검정 (LRT)과 윌크스 정리

□ 개념 2: 만능열쇠 (Universal Key)

한 줄 요약: 복잡한 모델이라도 "제약 있는 우도"와 "제약 없는 우도"의 비율만 계산하면, 카이제곱 분포를 이용해 바로 검정할 수 있습니다.

1) 검정 통계량의 구성

$$\lambda = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} = \frac{L(\hat{\theta}_{H_0})}{L(\hat{\theta}_{MLE})}$$

- 분자: H_0 라는 족쇄를 차고 낼 수 있는 최대 점수.
- 분모: 족쇄를 풀고(전체 공간) 낼 수 있는 최대 점수.
- 해석: 비율 λ 가 1에 가까우면 족쇄(H_0)가 별로 방해가 안 된 것이니 H_0 채택. 0에 가까우면 기각.

2) Wilks' Theorem (핵심 정리)

$n \rightarrow \infty$ 일 때, 다음 통계량은 카이제곱 분포를 따릅니다.

$$-2 \log \lambda \xrightarrow{d} \chi_d^2$$

(d : 파라미터 개수의 차이. 예: H_0 는 고정값, H_1 은 자유면 $d = 1$) 이 정리 덕분에 우리는 복잡한 시뮬레이션 없이도 p-value를 구할 수 있습니다.

1.3 3. 통계적 검정의 삼위일체 (The Holy Trinity)

□ 개념 3: 우도 산(Mountain) 등반하기

한 줄 요약: H_0 가 틀렸다는 것을 입증하기 위해 산의 높이(LRT), 너비(Wald), 기울기(Score) 중 하나를 짭니다.

우도 함수(Likelihood Function)를 하나의 산봉우리라고 상상해 봅시다.

- **정상(Peak):** $\hat{\theta}_{MLE}$ (데이터가 가장 잘 설명되는 지점)
- **현재 위치:** θ_0 (귀무가설이 주장하는 지점)

A. LRT (Likelihood Ratio Test) - "높이 차이"

- **질문:** "정상의 고도($L(\hat{\theta})$)와 현재 위치의 고도($L(\theta_0)$) 차이가 많이 나는가?"
- **특징:** 가장 정확하지만, 두 지점의 우도를 모두 계산해야 합니다.
- **수식:** $2[\ell(\hat{\theta}) - \ell(\theta_0)]$ (로그 우도의 차이)

B. Wald Test - "수평 거리"

- **질문:** "정상($\hat{\theta}$)까지 수평으로 얼마나 걸어가야 하는가?" ($\hat{\theta} - \theta_0$)
- **특징:** 직관적입니다. 하지만 θ 를 제공하거나 로그를 취하면 거리가 변하는 단점이 있습니다.
- **수식:** $\frac{(\hat{\theta} - \theta_0)^2}{\text{Var}(\hat{\theta})}$ (거리를 표준오차로 나눈 것의 제곱)

C. Score Test (LM Test) - "경사도(Slope)"

- **질문:** "지금 서 있는 곳(θ_0)의 경사가 가파른가?"
- **특징:** 정상을 밟아볼 필요가 없습니다! (MLE 계산 불필요). 경사가 평평하면 (≈ 0) 여기가 정상이니 H_0 유지, 가파르면 정상이 저 위에 있다는 뜻이니 H_0 기각.
- **수식:** H_0 지점에서의 미분값(Score)의 제곱을 정보량(Information)으로 나눈 것.

1.4 4. t-test: 데이터가 적을 때의 현실

□ 개념 4: 모르는 게 있으면 꼬리가 두꺼워진다

한 줄 요약: 분산 σ^2 을 몰라서 표본분산 S^2 을 대충 써야 할 때, 그 불안감만큼 기각 기준을 엄격하게(꼬리를 두껍게) 만듭니다.

상황

데이터 $X_i \sim \mathcal{N}(\mu, \sigma^2)$ 인데, μ 를 검정하고 싶지만 σ 도 모릅니다.

- **Z-test (이상적):** $\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ (분산을 앎 $\rightarrow$ 정규분포)
- **t-test (현실적):** $\frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ (분산을 추정함 $\rightarrow$ t-분포)

$n \rightarrow \infty$ 가 되면 $S \rightarrow \sigma$ 가 되므로 t-분포는 정규분포와 같아집니다. 즉, t-test는 LRT의 유한 표본(Finite Sample) 버전입니다.

2 실전 계산: 불공정 동전 판별 (Wald Test)

□ Scenario: 카지노의 의심

카지노에서 어떤 동전이 앞면(p)이 너무 많이 나온다는 제보가 들어왔습니다. $H_0 : p = 0.5$ vs $H_1 : p \neq 0.5$. 데이터: $n = 100$ 번 던져서 앞면이 60 번 나옴 ($\hat{p} = 0.6$).

1. 도구 선택: 계산이 편한 Wald Test를 사용합시다.
2. 거리 측정: $|\hat{p} - p_0| = |0.6 - 0.5| = 0.1$.
3. 불확실성(표준오차) 계산: H_0 하에서의 표준오차는 $\sqrt{\frac{p_0(1-p_0)}{n}} = \sqrt{\frac{0.5 \times 0.5}{100}} = 0.05$.
4. Wald 통계량 (Z-score):

$$W = \frac{\text{거리}}{\text{표준오차}} = \frac{0.1}{0.05} = 2.0$$

5. 판정: $|W| = 2.0 > 1.96$ (유의수준 5% 기준값).
6. 결론: "2표준편차만큼 벗어났으므로 통계적으로 유의미하다. H_0 기각. 이 동전은 불공정하다."

3 자주 묻는 질문 (FAQ)

Q1. LRT, Wald, Score 중에 뭘 써야 하나요? A. 데이터가 무한히 많다면($n \rightarrow \infty$) 셋의 결과는 같습니다.

- 정확도: $\text{LRT} > \text{Wald} \approx \text{Score}$. (LRT가 분포 근사가 제일 좋습니다.)
- 편의성: Wald가 제일 쉽습니다 (신뢰구간 구할 때 좋음).
- 계산 비용: 모델이 너무 복잡해서 MLE를 구하기 힘들 땐 Score가 짱입니다.

Q2. 윌크스 정리는 왜 -2를 곱하나요? A. 수학적 유도 과정에서 정규분포의 지수승($e^{-x^2/2}$)에 로그를 취하면 $-x^2/2$ 가 나옵니다. 여기서 x^2 (카이제곱) 모양을 맞추기 위해 -2를 곱해서 계수를 없애주는 것입니다.

Next Step: 지금까지는 "파라미터 θ 가 0이냐 아니냐"를 검정했습니다(Parametric Test). 그런데 만약 "데이터가 정규분포를 따르긴 하는가?" 처럼 분포의 모양 자체를 의심해야 한다면 어떻게 할까요? 다음 **Unit 7**에서는 모델의 가정 자체를 검증하는 적합도 검정(Goodness of Fit)을 배웁니다.

Unit 6 핵심 요약

- **Neyman-Pearson:** 단순 가설 대립 시 우도비(Likelihood Ratio)가 검정력 최강(UMP)이다.
- **Wilks' Theorem:** $-2 \log(\text{우도비}) \sim \chi^2$. 복잡한 모델 검정의 만능열쇠.
- **The Holy Trinity:**
 - LRT: 높이 차이 (정확함)
 - Wald: 수평 거리 (직관적, $\hat{\theta}$ 필요)
 - Score: 기울기 (계산 빠름, $\hat{\theta}$ 불필요)
- **t-test:** 분산을 모를 때 사용하는 LRT의 엄밀한 버전.