

MIT 18.6501: 모델 자체에 대한 의심

Unit 7: Goodness of Fit (적합도 검정)

Contents

1	Unit 7. 적합도 검정 (Goodness of Fit)	2
1.1	1. 이산 데이터와 다항 분포 (The Setup)	2
1.2	2. 피어슨의 카이제곱 검정 (Pearson's χ^2 Test)	3
1.3	3. 복합 가설 검정 (Composite Goodness of Fit)	3
2	실전 시나리오: 확률형 아이템(가챠) 조작 의혹 검증	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 5, 6: Parametric Hypothesis Testing (모델을 믿고 θ 검정)
- **Unit 7: Goodness of Fit (현재 단원: 모델 $\mathcal{P}$ 자체를 검증)**
 - 7.1 Discrete Setting & Multinomial Distribution
 - 7.2 Pearson's χ^2 Test (핵심 공식)
 - 7.3 Composite Hypothesis (파라미터를 모를 때)
 - 7.4 CDF-based Test (KS Test)
- Unit 8: General Linear Models (회귀 분석의 확장)

1 Unit 7. 적합도 검정 (Goodness of Fit)

Unit 6까지 우리는 "이 데이터는 정규분포를 따른다"는 가정하에 평균이 θ 인지 아닌지를 싸웠습니다(LRT, Wald, Score). 하지만 누군가 근본적인 질문을 던집니다. "애초에 데이터가 정규분포가 아니면 어떻게 할 건데?" 이번 단원에서는 특정 파라미터가 아니라, 데이터의 분포 모양 자체가 이론과 맞는지 확인하는 법을 배웁니다.

□ 개요 (Overview)

적합도 검정은 "관측된 데이터(Reality)"와 "모델이 예측한 데이터(Theory)" 사이의 거리를 측정하는 과정입니다. 데이터를 범주(Bin)로 나누어 다항 분포 문제로 치환하고, 피어슨 카이제곱 통계량을 사용해 오차를 분석합니다. 이때 파라미터를 추정해서 검정할 경우 자유도가 감소하는 원리까지 다룹니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Multinomial Dist.	주사위 던지기. 데이터가 여러 칸(Bin) 중 하나에 들어감.
Observed (O_j)	실제 데이터가 각 칸에 들어간 횟수 (N_j).
Expected (E_j)	이론적으로 들어갔어야 할 횟수 (np_j).
χ^2 Statistic	$\sum \frac{(O-E)^2}{E}$. 현실과 이론의 괴리감 점수.
Degrees of Freedom (df)	자유롭게 움직일 수 있는 데이터의 개수 ($K - 1 - d$).

1.1 1. 이산 데이터와 다항 분포 (The Setup)

□ 개념 1: 연속을 이산으로 (Discretization)

한 줄 요약: 모양을 비교하기 가장 쉬운 방법은, 구간(Bin)을 나누어 각 구간에 몇 개가 들어갔는지 세는 것입니다. (히스토그램 만들기)

1) 설정 (Setup)

데이터가 K 개의 범주(Category) 중 하나에 떨어집니다.

- 예: 혈액형 (A, B, O, AB $\rightarrow K = 4$)
- 예: 키 (160 이하, 160-170, 170-180, 180 이상 $\rightarrow K = 4$)

각 범주에 관측된 횟수를 $N_1, \dots, N_K$ 라고 하면, 이 벡터는 다항 분포(Multinomial Distribution)를 따릅니다.

1.2 2. 피어슨의 카이제곱 검정 (Pearson's χ^2 Test)

□ 개념 2: 현실(Observed)과 이론(Expected)의 거리

한 줄 요약: 단순히 차이를 제공해서 더하는 게 아니라, "기대값이 큰 곳은 오차도 크다"는 점을 감안하여 표준화한 거리입니다.

1) 직관적 비유: 시험 점수 보정

- 수학(평균 50 점)에서 10점 차이 나는 것과,
- 체육(평균 90 점)에서 10점 차이 나는 것은 무게감이 다릅니다.
- 오차의 절대적인 크기 $((O - E)^2)$ 가 아니라, 그 동네의 규모(E) 대비 얼마나 큰지를 봐야 합니다.

2) 핵심 공식 (T_n)

$$T_n = \sum_{j=1}^K \frac{(N_j - np_j^0)^2}{np_j^0} = \sum_{j=1}^K \frac{(\text{Obs} - \text{Exp})^2}{\text{Exp}}$$

- 분자 $(O - E)^2$: 오차의 크기.
- 분모 E : 분산(Variance) 역할. (포아송/다항분포에서 분산은 평균과 비례함).
- 의미: $\frac{\text{오차}}{\text{표준편차}} \approx Z$ (표준정규분포)가 되므로, 이것의 제곱 합은 χ^2 가 됩니다.

3) 점근적 성질 (Asymptotic Property)

$n \rightarrow \infty$ 일 때,

$$T_n \xrightarrow{d} \chi_{K-1}^2$$

왜 K 가 아니라 $K-1$ 인가? 데이터의 총합은 반드시 n 이어야 합니다 ($\sum N_j = n$). 마지막 칸(N_K)은 앞의 $K-1$ 개 값이 정해지면 자동으로 결정되므로 자유가 없습니다.

1.3 3. 복합 가설 검정 (Composite Goodness of Fit)

□ 개념 3: 옷을 몸에 맞았다면, 심사 기준을 높여라

한 줄 요약: 파라미터를 몰라서 데이터로 추정($\hat{\theta}$)한 뒤 검정할 때는, 이미 데이터를 한 번 훑쳐본 셈이므로 자유도(df)를 깎아서 패널티를 줍니다.

1) 문제 상황

”이 데이터가 포아송 분포를 따르는가?”라고 묻지만, λ 가 3인지 5인지 모릅니다.

- 해결: 데이터에서 먼저 MLE $\hat{\lambda}$ 를 구합니다.
- 적용: 그 $\hat{\lambda}$ 를 이용해 기대 확률 $p_j(\hat{\lambda})$ 를 계산합니다.

2) 자유도의 변화 (핵심 이론)

$$T_n = \sum \frac{(N_j - np_j(\hat{\theta}))^2}{np_j(\hat{\theta})} \xrightarrow{d} \chi_{K-1-d}^2$$

- d : 추정된 파라미터의 개수.
- 직관: 파라미터를 추정하는 과정에서 데이터의 정보(자유도)를 d 만큼 소모했습니다. 모델을 데이터에 ”끼워 맞추기(Fitting)” 때문에, 오차($O - E$)가 자연 상태보다 인위적으로 줄어듭니다. 이를 보정하기 위해 분포의 기준을 더 뻣뻣하게(df 감소) 잡는 것입니다.

2 실전 시나리오: 확률형 아이템(가차) 조작 의혹 검증

□ Scenario: 유저들의 봉기

당신은 넥슨의 게임 운영자입니다. 유저들이 ”전설/영웅/일반 아이템 확률이 공지된 것과 다르다!”고 소송을 제기했습니다. 공지 확률: 전설(10%), 영웅(30%), 일반(60%). ($K = 3$)

1. 데이터 수집: 100회 뽑기 결과 ($n = 100$)

- 관측(O): 전설 5개, 영웅 25개, 일반 70개.

2. 기대값 계산 (E):

- 전설: $100 \times 0.1 = 10$
- 영웅: $100 \times 0.3 = 30$
- 일반: $100 \times 0.6 = 60$

3. 카이제곱 통계량 계산:

$$\begin{aligned} \chi^2 &= \frac{(5 - 10)^2}{10} + \frac{(25 - 30)^2}{30} + \frac{(70 - 60)^2}{60} \\ &= \frac{25}{10} + \frac{25}{30} + \frac{100}{60} = 2.5 + 0.83 + 1.67 = 5.0 \end{aligned}$$

4. 판정 (자유도 $K - 1 = 2$): 유의수준 5%에서 χ^2_2 의 임계값은 **5.99**입니다.

$$5.0 < 5.99 \quad (\text{각각 실패})$$

5. 결론: "관측된 차이가 다소 있긴 하지만(전설이 적게 나옴), 통계적으로 '조작'이라 단정할 만큼 극단적이진 않습니다. 우연의 범위 내입니다." (유저들의 분노는 가라앉지 않겠지만, 수학적으로는 무죄입니다.)

3 자주 묻는 질문 (FAQ)

- Q1. 데이터가 적어도 이 방법을 쓸 수 있나요? A. 위험합니다. 보통 각 칸(Bin)의 기대 빈도(E_j)가 최소 5 이상은 되어야 카이제곱 분포 근사가 잘 맞습니다. 만약 기대 빈도가 너무 작으면, 인접한 칸들을 합쳐서(Merge) $E \geq 5$ 를 만들어야 합니다.
- Q2. 그냥 $(O - E)$ 만 보면 안 되나요? 왜 제곱하고 나누나요? A. $(O - E)$ 를 그냥 더하면 양수와 음수가 상쇄되어 항상 0이 됩니다. 그래서 제곱을 합니다. 그리고 E 로 나누는 것은 "가중치" 때문입니다. 1000개 중 10개 차이 나는 것과, 20개 중 10개 차이 나는 것은 다르기 때문입니다.
- Q3. 연속형 데이터는 어떻게 하나요? A. 카이제곱 검정을 쓰려면 강제로 구간(Bin)을 나눠야 합니다(정보 손실 발생). 그게 싫다면 구간을 나누지 않고 누적 분포 함수(CDF) 자체를 비교하는 콜모고로프-스미르노프(KS) 검정을 사용하면 됩니다.

Next Step: 우리는 이제 θ 를 찾는 것(Unit 2 6)을 넘어 모델 전체를 검증(Unit 7)했습니다. 통계학의 기초는 끝났습니다. 이제 통계학의 꽃이자 머신러닝의 시초인 **Unit 8: 선형 회귀 분석 (Linear Regression)**으로 넘어가, 변수와 변수 사이의 관계($X \rightarrow Y$)를 모델링합니다.

Unit 7 핵심 요약

- **관점 전환:** 파라미터 값이 아니라 분포의 모양(Shape)을 검정한다.
- **카이제곱 통계량:** $\sum \frac{(O-E)^2}{E}$. 관측값과 기대값의 표준화된 거리.
- **자유도(df):** 기본적으로 $K - 1$. 단, 파라미터를 데이터로 추정했다면 $K - 1 -$ (추정 파라미터 수)로 줄어든다.
- **주의점:** 각 칸의 기대 빈도가 너무 작으면(5 미만) 신뢰할 수 없다.