

MIT 18.6501: 설명에서 예측으로

Unit 3: Linear Regression (선형 회귀)

Contents

1	Unit 3. 선형 회귀 (Linear Regression)	2
1.1	1. 선형 회귀 모델의 구조 (The Setup)	2
1.2	2. 최소자승법 (Least Squares Estimation, LSE)	3
1.3	3. 기하학적 해석: 직교 투영 (Projection)	3
1.4	4. 가우스-마르코프 정리 (Gauss-Markov Theorem)	4
1.5	5. 추론 (Inference): 가설 검정	4
2	실전 시나리오: 넷플릭스 시청 시간 예측	5
3	자주 묻는 질문 (FAQ)	6

Course Structure & Current Focus

- Unit 1, 2: Estimation (현재 상태 파악)
- **Unit 3: Linear Regression (현재 단위: 미래 예측과 관계 규명)**
 - 3.1 The Setup: Matrix Formulation
 - 3.2 Least Squares Estimation (LSE)
 - 3.3 Geometric Interpretation (Projection)
 - 3.4 Gauss-Markov Theorem (BLUE)
 - 3.5 Inference (t-test, F-test)
- Unit 4: Hypothesis Testing (심화)

1 Unit 3. 선형 회귀 (Linear Regression)

지금까지 우리는 하나의 변수(예: 동전 앞면 확률 p , 평균 키 μ)를 추정하는 데 집중했습니다. 하지만 현실 세계는 여러 변수가 얽혀 있습니다. 키는 유전, 영양, 운동량에 영향을 받죠. 이제 우리는 "변수 X 가 변할 때 결과 Y 는 어떻게 변하는가?"를 수학적으로 모델링하고, 이를 통해 보이지 않는 미래를 예측 (*Prediction*)하는 단계로 나아갑니다.

□ 개요 (Overview)

선형 회귀는 입력(X)과 출력(Y)의 관계를 선형 방정식($Y = X\beta$)으로 설명하는 기법입니다. 이 단원에서는 최소자승법(LSE)이 기하학적으로는 직교 투영(Orthogonal Projection)임을 이해하고, 데이터가 정규분포를 따르지 않아도 LSE가 최적의 추정량(BLUE)이 됨을 증명하는 가우스-마르코프 정리를 배웁니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Design Matrix (X)	요리 재료들의 목록표 ($n \times p$ 행렬).
Coefficient Vector (β)	각 재료가 맛에 미치는 영향력 (우리가 구해야 할 레시피).
Residual (e or $\hat{e}$)	실제 맛(Y)과 레시피대로 만든 맛($\hat{Y}$)의 차이.
Projection Matrix (P)	Y 를 X 의 공간 위로 수직으로 내리쬐는 그림자 생성기.
BLUE	Best Linear Unbiased Estimator. (가장 믿을만한 선형 추정량).

1.1 1. 선형 회귀 모델의 구조 (The Setup)

□ 개념 1: 행렬로 세상을 표현하다

한 줄 요약: 복잡한 연립방정식 문제를 $\mathbf{Y} = \mathbf{X}\beta + \epsilon$ 이라는 우아한 행렬식 하나로 압축합니다.

1) 직관적 비유: 아파트 가격 맞추기

- $\mathbf{Y}$ (결과): 아파트 가격들 (10억, 15억, ...)
- $\mathbf{X}$ (재료): [평수, 역까지 거리, 학군 점수]
- β (영향력): [평당 가격, 1km 당 감가액, 학군 프리미엄]
- ϵ (잡음): 옆집이 시세보다 싸게 내놓은 급매물 같은 예측 불가능한 요인.

2) 수학적 정의

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

여기서 $\mathbf{X}$ 는 $n \times p$ 행렬입니다 (n : 데이터 개수, p : 변수 개수). 주요 가정:

1. $\mathbb{E}[\epsilon] = 0$ (잡음의 평균은 0이다.)
2. $\text{Var}(\epsilon) = \sigma^2 I_n$ (모든 데이터의 잡음 수준은 일정하고 독립적이다.)

1.2 2. 최소자승법 (Least Squares Estimation, LSE)

□ 개념 2: 오차의 제곱을 최소화하라

한 줄 요약: 모든 데이터 점들과 직선 사이의 거리(잔차) 제곱합을 최소로 만드는 β 를 찾습니다.

1) 최적화 문제

우리의 목표는 잔차 벡터의 길이($\|\mathbf{Y} - \mathbf{X}\beta\|^2$)를 최소화하는 $\hat{\beta}$ 를 찾는 것입니다.

$$\hat{\beta} = \operatorname{argmin}_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2$$

2) 해 구하기 (Normal Equations)

위 식을 β 로 미분하여 0이 되는 지점을 찾으면 다음과 같은 정규 방정식(Normal Equations)이 나옵니다.

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{Y}$$

만약 $(\mathbf{X}^T \mathbf{X})$ 의 역행렬이 존재한다면, 우리는 단 한 번의 행렬 연산으로 정답을 얻습니다.

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

1.3 3. 기하학적 해석: 직교 투영 (Projection)

□ 개념 3: 그림자 놀이

한 줄 요약: 우리의 예측값 $\hat{Y}$ 는 실제 데이터 Y 를 $\mathbf{X}$ 가 만드는 평면(공간) 위로 수직으로 내리놓은 그림자입니다.

1) 공간의 이해

- 데이터 $\mathbf{Y}$ 는 n 차원 공간에 떠 있는 하나의 점입니다.
- 우리가 가진 재료 $\mathbf{X}$ 들로 만들 수 있는 모든 예측값들의 집합을 열 공간(Column Space, $\mathcal{C}(\mathbf{X})$)이라고 합니다. 이는 n 차원 공간 속의 작은 평면입니다.

2) 직교성 (Orthogonality)

점 Y 에서 평면 $\mathcal{C}(\mathbf{X})$ 까지 거리가 가장 짧으려면? 당연히 수직(Orthogonal)으로 내려야 합니다. 즉, 잔차 벡터 $e = Y - \hat{Y}$ 는 평면 $\mathcal{C}(\mathbf{X})$ 와 직교합니다.

$$\mathbf{X}^T e = 0 \implies \mathbf{X}^T (Y - \mathbf{X}\hat{\beta}) = 0$$

이 식을 풀면 앞서 본 정규 방정식 $\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{Y}$ 가 바로 유도됩니다!

3) 투영 행렬 (Hat Matrix)

예측값 $\hat{Y}$ 는 Y 에 투영 행렬 P 를 곱한 것입니다.

$$\hat{Y} = PY, \quad \text{where } P = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

(P 를 Hat Matrix 라고 부르는 이유는 Y 머리 위에 모자 $\hat{Y}$ 를 씌워주기 때문입니다.)

1.4 4. 가우스-마르코프 정리 (Gauss-Markov Theorem)

□ 개념 4: 왜 하필 LSE 인가?

한 줄 요약: 데이터가 정규분포가 아니더라도, 오차의 평균이 0이고 분산이 일정하다면 LSE가 "가장 분산이 작은(정밀한) 선형 추정량"임이 수학적으로 보장됩니다.

BLUE (Best Linear Unbiased Estimator)

LSE 추정량 $\hat{\beta}$ 는 다음 조건을 만족하는 챔피언입니다.

- **Linear:** 데이터 Y 의 선형 결합으로 계산됨.
- **Unbiased:** 평균적으로 참값 β 를 맞춘 ($\mathbb{E}[\hat{\beta}] = \beta$).
- **Best:** 위의 두 조건을 만족하는 애들 중에서 분산이 가장 작음 (Minimum Variance).

즉, 다른 방법을 쓰면 영점이 흔들리거나(Biased), 탄착군이 넓어집니다(High Variance).

1.5 5. 추론 (Inference): 가설 검정

이제 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ 라는 정규분포 가정을 추가합니다. 그래야 신뢰 구간과 p-value를 구할 수 있습니다.

1) 추정량의 분포

$\hat{\beta}$ 는 정규분포 따르는 Y 의 선형 변환이므로, 역시 정규분포를 따릅니다.

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$$

2) t-test (변수의 유의성 검정)

”학군(β_3)이 집값에 진짜 영향이 있나?” ($H_0 : \beta_3 = 0$)

$$T = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \sim t_{n-p}$$

여기서 $\text{SE}(\hat{\beta}_j)$ 는 $\hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}$ 입니다.

코크란의 정리 (Cochran's Theorem)

우리가 t-분포를 쓸 수 있는 이유는 ”추정된 계수($\hat{\beta}$)와 잔차($\hat{\epsilon}$)가 서로 독립”이라는 수학적 성질 덕분입니다. 이는 기하학적으로 투영된 그림자($\hat{Y}$)와 수직선(e)이 직교하기 때문에 성립합니다.

2 실전 시나리오: 넷플릭스 시청 시간 예측**□ Scenario: 새로운 드라마의 성공 예측**

당신은 넷플릭스의 데이터 과학자입니다. 신규 드라마의 '첫 달 시청 시간(Y)'을 예측하려 합니다.

1. 변수 설정 (X):

- X_1 : 제작비 (억 원)
- X_2 : 주연 배우의 인스타 팔로워 수 (만 명)
- X_3 : 에피소드 수

2. 모델링: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ **3. LSE 결과:** $\hat{\beta} = [100, 2.5, 0.1, 50]^T$

- 해석: 제작비 1억 늘면 시청 시간 2.5만 시간 증가.
- 해석: 팔로워 1만 명당 시청 시간 0.1만 시간 증가. (생각보다 적음)

4. t-test: X_2 (팔로워 수)의 p-value가 0.35가 나옴.

- 결론: ”주연 배우의 팔로워 수는 시청 시간에 통계적으로 유의미한 영향이 없습니다.” → 마케팅 팀에 ”인플루언서 섭외보다 제작비 증액이 낫습니다”라고 제안.

3 자주 묻는 질문 (FAQ)

- Q1. $(\mathbf{X}^T \mathbf{X})$ 의 역행렬이 없으면 어떡하죠? A.** 이를 다중공선성 (Multicollinearity) 문제라고 합니다. 예를 들어 '키(cm)'와 '키(m)'를 동시에 변수로 넣으면, 두 변수가 완벽하게 겹쳐서 수학적으로 해를 구할 수 없습니다. 이때는 변수를 하나 제거하거나, Ridge Regression 같은 기법을 써야 합니다.
- Q2. 왜 잔차 제곱의 합을 쓰나요? 절댓값의 합을 쓰면 안 되나요? A.** 써도 됩니다(LAD 회귀). 하지만 절댓값은 미분이 불가능한 점(뾰족한 점)이 있어서 수학적으로 다루기 어렵습니다. 반면 제곱(L^2)은 미분이 깔끔하고, 기하학적으로 '직교 투영'이라는 완벽한 해석이 가능하기 때문에 통계학의 표준이 되었습니다.

Next Step: 우리는 연속형 숫자(Y)를 예측하는 선형 회귀를 배웠습니다. 그런데 만약 결과가 숫자가 아니라 "합격/불합격", "암/정상" 같은 범주라면 어떡할까요? 선형 회귀로는 0과 1 사이의 확률을 표현하기 어렵습니다. 다음 시간에는 이를 해결하는 로지스틱 회귀(Logistic Regression)와 일반화 선형 모형(GLM)을 배웁니다.

Unit 3 핵심 요약

- **모델:** $Y = \mathbf{X}\beta + \epsilon$. 현실을 선형 결합으로 근사한다.
- **LSE:** 잔차 제곱합을 최소화하는 방법. $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T Y$.
- **기하학:** 예측값 $\hat{Y}$ 는 데이터 Y 를 열 공간 $\mathcal{C}(\mathbf{X})$ 에 수직 투영(Orthogonal Projection)한 것이다.
- **Gauss-Markov:** 정규성 가정이 없어도 LSE는 분산이 가장 작은 최적의 추정량(BLUE)이다.