

MIT 18.6501: 모든 데이터를 위한 통계

Unit 9: Generalized Linear Models (GLM)

Contents

1	Unit 9. 일반화 선형 모형 (GLM)	2
1.1	1. 지수족 분포 (Exponential Family)	2
1.2	2. 연결 함수 (Link Function)	3
1.3	3. 추정 알고리즘: IRLS	4
2	실전 시나리오: 대학원 합격 예측 (로지스틱)	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 3: Linear Regression (연속형 데이터 예측)
- Unit 7: Goodness of Fit (모델 검증)
- **Unit 9: Generalized Linear Models (현재 단위: 확장팩 설치)**
 - 9.1 Exponential Family (공통의 조상)
 - 9.2 Link Function (데이터 범위 해결)
 - 9.3 Logistic Regression (이진 분류)
 - 9.4 Poisson Regression (카운트 데이터)
 - 9.5 IRLS Algorithm (해를 구하는 법)
- Unit 10: Classification (머신러닝으로의 연결)

1 Unit 9. 일반화 선형 모형 (GLM)

Unit 3에서 배운 선형 회귀($Y = X\beta$)는 강력하지만 치명적인 약점이 있습니다. Y 가 정규분포를 따라야 한다는 점이지요. 만약 "내일 비가 올까(0/1)?"를 선형 회귀로 예측했더니 "확률이 120%"라거나 "-30%"라는 황당한 답이 나온다면 어떡할까요? GLM은 이 문제를 해결하기 위해 선형 회귀에 '유연한 연결고리(Link)'를 달아주는 과정입니다.

□ 개요 (Overview)

GLM은 정규분포, 베르누이 분포, 포아송 분포 등을 **지수족(Exponential Family)**이라는 하나의 수학적 틀로 묶고, **연결 함수(Link Function)**를 통해 선형 예측($X\beta$)을 데이터의 특성에 맞는 범위(예: 0 1)로 매핑하는 기법입니다. 이를 통해 분류(Classification)와 회귀(Regression)를 통합적으로 다룹니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Exponential Family	"다르게 생겼지만 사실은 한 가족". 미분과 계산이 편한 분포들의 모임.
Link Function (g)	$X\beta$ (무한대 범위)를 μ (제한된 범위)로 통역해주는 번역기.
Logit Link	확률(0 1)을 $\pm\infty$ 로 퍼주는 함수. (로지스틱 회귀용)
Log Link	양수(0 ∞)를 전체 실수로 퍼주는 함수. (포아송 회귀용)
IRLS	GLM은 공식 한 방에 안 풀리므로, 조금씩 정답을 찾아가는 반복 알고리즘.

1.1 1. 지수족 분포 (Exponential Family)

□ 개념 1: 통계학의 만능 플랫폼

한 줄 요약: 정규분포, 베르누이, 포아송 등은 겉보기엔 다르지만, 사실 $f(y) = h(y)e^{\eta^T(y) - A(\eta)}$ 라는 공통 DNA를 가진 가족입니다.

1) 왜 배우는가?

서로 다른 분포들을 매번 따로 연구할 필요가 없습니다. 이 "가족"에 속하기만 하면 다음과 같은 강력한 성질(VIP 혜택)을 공유하기 때문입니다.

- **Convexity:** 로그 우도 함수가 항상 위로 볼록(Concave)합니다. 즉, 최적화할 때 '가짜 봉우리(Local Optima)'가 없어서 안심하고 답을 찾을 수 있습니다.
- **Automatic Moments:** 복잡한 적분 없이 미분만으로 평균과 분산을 구할 수 있습니다. ($A'(\eta) = \text{평균}, A''(\eta) = \text{분산}$)

2) 수학적 구조

$$f(y; \theta) = h(y) \exp(\eta(\theta) \cdot T(y) - A(\theta))$$

- η : 자연 파라미터 (Natural Parameter). 분포의 모양을 결정하는 핵심.
- $T(y)$: 충분 통계량.
- $A(\theta)$: 로그 분배 함수 (정규화 상수). 확률의 합이 1이 되게 맞추는 역할.

1.2 2. 연결 함수 (Link Function)

□ 개념 2: 무한의 세계와 유한의 세계를 잇다

한 줄 요약: 선형 회귀 결과값 $X\beta$ 는 $-\infty \sim \infty$ 범위를 가지지만, 우리가 원하는 평균 μ 는 범위가 제한적입니다(확률은 0 1). 이 둘을 이어주는 다리입니다.

1) 로지스틱 회귀 (Logistic Regression)

- 상황: 합격(1) vs 불합격(0). $Y \sim \text{Bernoulli}(p)$.
- 문제: $X\beta = 100$ 이 나오면 확률이 1을 넘어버림.
- 해결 (Logit Link): 확률(p) 대신 로그 오즈(Log-Odds)를 예측합니다.

$$g(p) = \log\left(\frac{p}{1-p}\right) = X\beta$$

- 복원: 역함수를 취하면 그 유명한 시그모이드(Sigmoid) 함수가 됩니다.

$$p = \frac{e^{X\beta}}{1 + e^{X\beta}} = \frac{1}{1 + e^{-X\beta}}$$

2) 포아송 회귀 (Poisson Regression)

- 상황: 하루 교통사고 건수. $Y \in \{0, 1, 2, \dots\}$. (음수 불가능)
- 문제: 선형 회귀는 음수 값을 예측할 수도 있음.
- 해결 (Log Link): 평균(λ)에 로그를 씌워서 예측합니다.

$$g(\lambda) = \log(\lambda) = X\beta \implies \lambda = e^{X\beta}$$

- 의미: X 가 증가하면 Y 는 기하급수적(Multiplicative)으로 증가합니다.

1.3 3. 추정 알고리즘: IRLS

□ 개념 3: 산을 오르는 반복적인 걸음

한 줄 요약: 선형 회귀처럼 한 번에 답(β)이 나오지 않습니다. 직선을 긋고(Linear), 가중치를 조절하고(Reweight), 다시 긋는 과정을 반복(Iterative) 합니다.

1) 문제점

GLM의 로그 우도 함수를 미분하면, β 가 지수함수($e^{X\beta}$) 안에 갇혀 있어서 깔끔하게 정리가 안 됩니다 (No closed-form solution).

2) 해결책: 뉴턴-랩슨 & IRLS

근사적으로 해를 구하는 수치해석 기법을 씁니다.

- **Iteratively Reweighted Least Squares (IRLS):** 매 단계마다 분산이 다른 것을 고려하여 가중치(Weight)를 둔 선형 회귀(WLS)를 푸는 문제로 바뀌서 풀립니다. 컴퓨터가 아주 빠르게 반복해서 최적의 β 를 찾아냅니다.

2 실전 시나리오: 대학원 합격 예측 (로지스틱)

□ Scenario: GPA와 합격률의 관계

학생들의 GPA(X)에 따른 합격 여부($Y \in \{0, 1\}$)를 분석합니다.

1. 데이터: GPA 3.0은 불합격, 3.5는 합격... 이런 데이터 100개.
2. 모델링: $Y \sim \text{Bernoulli}(p)$, $\log(\frac{p}{1-p}) = \beta_0 + \beta_1 X$.
3. 결과: $\hat{\beta}_0 = -10, \hat{\beta}_1 = 3$.
4. 예측 계산 (GPA 3.8인 학생):
 - 선형 예측값: $\eta = -10 + 3(3.8) = -10 + 11.4 = 1.4$.
 - 이것은 확률이 아니라 로그 오즈입니다.
 - 확률 변환: $p = \frac{1}{1+e^{-1.4}} \approx \frac{1}{1+0.246} \approx 0.80$.
5. 해석: GPA가 3.8인 학생은 합격 확률이 약 80%입니다.
6. 계수 해석: $\beta_1 = 3$ 은 양수이므로, GPA가 높을수록 합격 오즈가 $e^3 \approx 20$ 배 증가합니다 (매우 강력한 영향).

3 자주 묻는 질문 (FAQ)

Q1. 왜 확률을 바로 $X\beta$ 로 두지 않고 굳이 '오즈'에 로그를 씌우나요? A. 만약 $P(Y = 1) = \beta_0 + \beta_1 X$ 로 두면, X 가 아주 커졌을 때 확률이 1.5가 되거나 -0.2가 되는 모순이 발생합니다. 로그 오즈는 범위가 $(-\infty, \infty)$ 이므로, $X\beta$ 와 매칭시키기에 수학적으로 가장 안전하고 자연스럽습니다.

Q2. 정준 연결 함수(Canonical Link)가 뭔가요? A. '순정 부품' 같은 겁니다. 수학적으로 가장 깔끔하게 떨어지는 연결 함수 조합입니다.

- Normal $\rightarrow$ Identity ($Y = X\beta$)
- Bernoulli $\rightarrow$ Logit
- Poisson $\rightarrow$ Log

다른 걸 써도 되지만(예: Probit), 정준 링크를 쓰면 계산이 편하고 해석이 명확합니다.

Next Step: 우리는 GLM을 통해 Y 가 0/1인 경우(로지스틱)까지 다루었습니다. 하지만 만약 Y 가 0/1이 아니라 "개, 고양이, 사자"처럼 3개 이상의 범주라면 어떻게 할까요? 다음 **Unit 10**에서는 이를 해결하는 다중 분류(Multiclass Classification)와 현대적 분류 기법들을 배웁니다.

Unit 9 핵심 요약

- **지수족(Exponential Family):** GLM의 수학적 기반. 로그 우도가 오목(Convex)하여 최적화가 쉽다.
- **연결 함수(Link Function):** $g(\mu) = X\beta$. 선형 예측값을 데이터 범위에 맞게 변환한다.
- **로지스틱 회귀:** $g = \text{logit}$. 이진 분류에 사용. 결과는 로그 오즈.
- **포아송 회귀:** $g = \text{log}$. 카운트 데이터에 사용.
- **IRLS:** GLM의 해를 구하는 반복적 알고리즘.