

MIT 18.6501: 가정을 버리고 데이터 그대로

Unit 4: Density Estimation (밀도 추정)

Contents

1	Unit 4. 밀도 추정 (Density Estimation)	2
1.1	1. 히스토그램 (Histogram)	2
1.2	2. 커널 밀도 추정 (KDE, Kernel Density Estimation)	3
1.3	3. 편향-분산 트레이드오프 (Bias-Variance Trade-off)	3
1.4	4. 최적의 대역폭 선택 (Optimal Bandwidth)	4
2	실전 시나리오: 게임 유저 플레이 타임 분석	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 1 3: Parametric Statistics (정규분포 가정 하의 추정)
- **Unit 4: Non-parametric Statistics (현재 단원: 가정 없는 추정)**
 - 10.1 Histograms (가장 기초적인 방법)
 - 10.2 Kernel Density Estimation (KDE, 스무딩)
 - 10.3 Bias-Variance Trade-off (핵심 딜레마)
 - 10.4 Optimal Bandwidth Selection
- Unit 5: PCA (차원 축소)

1 Unit 4. 밀도 추정 (Density Estimation)

Unit 3까지는 "키는 정규분포를 따른다"고 가정하고 평균(μ)만 찾았습니다. 하지만 만약 분포가 낙타 등처럼 봉우리가 두 개 (*Bimodal*) 라면요? 평균만으로는 데이터의 진짜 모습을 설명할 수 없습니다. 이제 우리는 파라미터 몇 개를 찾는 게 아니라, 분포의 모양(함수 f) 자체를 그려내는 방법을 배웁니다.

□ 개요 (Overview)

밀도 추정은 관측된 데이터로부터 미지의 확률 밀도 함수 f 를 복원하는 기술입니다. 가장 단순한 히스토그램의 한계를 극복하기 위해 커널 밀도 추정(KDE)을 도입하며, 이때 발생하는 편향(Bias)과 분산(Variance)의 트레이드오프를 조절하여 최적의 스무딩 파라미터(대역폭 h)를 찾는 것이 핵심입니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Density Estimation	데이터 점들을 보고 원래 어떻게 분포해 있었는지 지도를 그리는 것.
Histogram	데이터를 구간(Bin) 별로 나눠 벽돌 쌓기. (각지고 거침)
KDE (Kernel Density Estimation)	데이터를 벽돌 대신 부드러운 모래무덤으로 쌓기. (부드러움)
Bandwidth (h)	모래무덤의 퍼짐 정도. 작으면 뽀족, 크면 평퍼짐.
Bias-Variance Trade-off	디테일을 살릴 것인가(Low Bias), 노이즈를 없앨 것인가(Low Variance)?

1.1 1. 히스토그램 (Histogram)

□ 개념 1: 디지털 모자이크

한 줄 요약: 데이터 공간을 격자(Bin)로 나누고, 각 칸에 떨어진 데이터 개수만큼 높이를 올리는 계단 함수입니다.

1) 한계점

- 불연속성: 현실의 확률은 부드러운 곡선인데, 히스토그램은 각진 계단 모양입니다.
- 시작점 의존성: 구간을 0부터 시작하느냐, 0.5부터 시작하느냐에 따라 모양이 완전히 달라집니다.

1.2 2. 커널 밀도 추정 (KDE, Kernel Density Estimation)

□ 개념 2: 벽돌 대신 모래를 쌓자

한 줄 요약: 각 데이터 포인트 위치에 '커널(Kernel)'이라는 작은 확률의 언덕을 쌓고, 이 언덕들을 모두 더해서 전체 지형을 만듭니다.

1) 직관적 비유: 모래무덤 쌓기

데이터 점이 하나(X_i) 찍힐 때마다, 그 위에 모래 한 줌(K)을 붓습니다.

- 데이터가 몰려 있는 곳: 모래가 많이 쌓여 높은 산이 됩니다.
- 데이터가 없는 곳: 모래가 없어 평지가 됩니다.
- 결과적으로 아주 부드러운 곡선(Smooth Curve)이 완성됩니다.

2) 수학적 정의 (The Estimator)

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

- $K(\cdot)$: 커널 함수. 보통 정규분포(Gaussian) 모양을 씁니다. ($\int K = 1$)
- h : 대역폭(Bandwidth). 커널의 폭을 결정하는 가장 중요한 변수입니다.
- 수학적 의미: 경험적 분포와 커널 함수의 합성곱(Convolution)입니다.

1.3 3. 편향-분산 트레이드오프 (Bias-Variance Trade-off)

□ 개념 3: 너무 섬세해도, 너무 둔감해도 안 된다

한 줄 요약: 대역폭 h 가 작으면 노이즈까지 따라그리고(과적합), h 가 크면 중요 특징을 뭉개버립니다(과소적합).

우리의 목표는 추정함수 $\hat{f}$ 와 실제함수 f 사이의 차이(MSE)를 줄이는 것입니다.

$$\text{MSE} = \text{Bias}^2 + \text{Variance}$$

1) 대역폭 h 가 작을 때 (Narrow Bandwidth)

- **현상:** 그래프가 자글자글하고 뽀족합니다 (Spiky).
- **Bias (낮음):** 데이터가 있는 위치를 아주 정확히 찌릅니다.
- **Variance (높음):** 데이터 하나만 바뀌어도 그래프 모양이 요동칩니다. (Overfitting)

2) 대역폭 h 가 클 때 (Wide Bandwidth)

- **현상:** 그래프가 평퍼짐하고 밋밋합니다 (Smooth).
- **Bias (높음):** 뽕족한 봉우리(Peak)를 깎아먹고 평탄화시킵니다. (Underfitting)
- **Variance (낮음):** 데이터가 좀 바뀌어도 둔감하게 반응합니다.

1.4 4. 최적의 대역폭 선택 (Optimal Bandwidth)

□ 개념 4: 중용(Golden Mean)을 찾아서

한 줄 요약: Bias와 Variance의 합이 최소가 되는 지점을 미분으로 찾습니다.

수학적 결론

MISE(Mean Integrated Squared Error)를 최소화하는 최적의 h 는 데이터 개수 n 과 다음과 같은 관계를 가집니다.

$$h_{opt} \propto n^{-1/5}$$

- 의미: 데이터 n 이 많아지면 h 를 천천히 줄여서 디테일을 살려야 합니다.
- 주의: 모수적 방법($1/\sqrt{n}$)보다 수렴 속도($n^{-2/5}$)가 느립니다. 즉, 함수 전체를 추정하려면 훨씬 더 많은 데이터가 필요합니다.

2 실전 시나리오: 게임 유저 플레이 타임 분석

□ Scenario: 평균의 함정 탈출

당신은 MMORPG 게임의 PM입니다. "유저들의 평균 플레이 타임은 2시간입니다"라는 보고를 받았습니다. 그래서 2시간짜리 콘텐츠를 만들었는데 망했습니다. 왜일까요?

1. 데이터 시각화 (KDE 적용): 단순 평균(μ) 대신 KDE로 분포를 그려보았습니다.
2. 발견 (Bimodal Distribution): 분포가 낙타 등처럼 봉우리가 두 개였습니다.
 - 그룹 A (라이트 유저): 30분 플레이 (숙제만 하고 끄)
 - 그룹 B (헤비 유저): 5시간 플레이 (레이드 땀)

평균인 '2시간'에 해당하는 유저는 사실 아무도 없었습니다!

3. h 파라미터 튜닝:

- h 를 너무 크게 잡으면: 두 봉우리가 뭉개져서 하나로 보임 (평균 2시간의 함정 재현).
 - h 를 적절히 잡으면: 30분과 5시간의 두 봉우리가 명확히 분리됨.
4. 전략 수정: 2시간짜리 콘텐츠 대신, "30분짜리 일일 퀘스트"와 "4시간짜리 레이드"로 콘텐츠를 이원화하여 대성공을 거둡니다.

3 자주 묻는 질문 (FAQ)

- Q1. 커널 함수 K 의 모양(정규분포, 삼각형 등)이 중요한가요? A. 별로 안 중요합니다. 커널의 모양보다는 대역폭 h 의 크기가 결과에 100배는 더 큰 영향을 미칩니다. 그냥 미분하기 편한 가우시안 커널을 쓰면 됩니다.
- Q2. 왜 비모수적 방법은 데이터가 많이 필요한가요? A. 모수적 방법은 "종 모양이다"라는 강력한 힌트(가정)를 가지고 시작하므로, 중심(μ)과 폭(σ)만 맞추면 됩니다. 하지만 비모수적 방법은 아무런 힌트 없이 백지상태에서 지도를 그려야 하므로, 빈 공간을 채우기 위해 훨씬 많은 정보(데이터)가 필요합니다.

Next Step: 우리는 데이터의 분포(밀도)를 알아냈습니다. 이제 이 고차원 데이터를 다루기 쉽게 압축할 수는 없을까요? 다음 시간에는 비모수 통계의 또 다른 축인 **Unit 5: 주성분 분석 (PCA, Principal Component Analysis)**을 통해 데이터의 차원을 축소하고 숨겨진 구조를 시각화하는 법을 배웁니다.

Unit 4 핵심 요약

- 비모수 통계: 특정 분포($\mathcal{N}$)를 가정하지 않고 함수 f 자체를 추정한다.
- 히스토그램: 쉽지만 각지고, 구간 설정에 민감하다.
- KDE: 커널(K)과 대역폭(h)을 이용해 스무딩하는 기법.
- Bias-Variance Trade-off: h 가 작으면 과적합(Variance $\uparrow$), 크면 과소적합(Bias $\uparrow$).
- 최적의 h : $n^{-1/5}$ 에 비례하여 설정한다.