

MIT 18.6501: 데이터의 본질을 찾아서

Unit 5: Principal Component Analysis (PCA)

Contents

1	Unit 5. 주성분 분석 (PCA)	2
1.1	1. 차원 축소의 철학: 분산은 정보다	2
1.2	2. 기하학적 해석: 최적의 좌표축 찾기	3
1.3	3. 수학적 엔진: 공분산 행렬과 고유값 분해	3
1.4	4. 차원 축소의 실행 (Dimension Reduction)	4
2	실전 시나리오: 벡스 유저 세분화 (User Segmentation)	4
3	자주 묻는 질문 (FAQ)	5

Course Structure & Current Focus

- Unit 3: Linear Regression (정답 Y 를 맞추는 지도 학습)
- Unit 4: Density Estimation (데이터의 분포 모양 추정)
- **Unit 5: Principal Component Analysis (현재 단원: 데이터 구조 파악 및 압축)**
 - 5.1 Philosophy: Variance is Information
 - 5.2 Geometric Interpretation
 - 5.3 Covariance Matrix & Eigen-decomposition
 - 5.4 Dimension Reduction Process
- Unit 6: Clustering (K-means, Hierarchical)

1 Unit 5. 주성분 분석 (PCA)

Unit 4에서 우리는 데이터의 밀도(*Density*)를 추정했습니다. 하지만 데이터의 차원(p)이 커지면 밀도 추정은 급격히 어려워집니다(차원의 저주). "변수가 100개나 되는데, 이것 다 써야 하나? 중요한 것 몇 개만 추릴 순 없을까?" 이 질문에 답하기 위해, 우리는 데이터의 핵심 정보만 남기고 껍데기를 버리는 차원 축소(*Dimensionality Reduction*)의 세계로 들어갑니다.

□ 개요 (Overview)

PCA는 고차원 데이터의 정보를 최대한 보존하면서 저차원으로 압축하는 기법입니다. "분산(Variance)이 곧 정보(Information)"라는 철학을 바탕으로, 데이터의 분산을 최대화하는 새로운 축(주성분)을 찾습니다. 이 과정은 수학적으로 공분산 행렬의 고유값 분해(Eigenvalue Decomposition) 문제로 귀결됩니다.

□ 핵심 용어 사전

용어 (Term)	직관적 의미 (Meaning)
Variance (분산)	데이터가 퍼진 정도. PCA에서는 이를 '정보량'으로 해석함.
Principal Component (PC)	데이터를 가장 잘 설명하는 새로운 좌표축 (방향).
Orthogonality (직교성)	PC1과 PC2는 수직이다. 즉, 서로 겹치는 정보가 없다.
Eigenvector (v)	새로운 축의 '방향'.
Eigenvalue (λ)	그 축이 설명하는 정보의 '크기' (분산의 양).

1.1 1. 차원 축소의 철학: 분산은 정보다

□ 개념 1: 심장 박동기 모니터

한 줄 요약: 변화가 없는(분산 0) 데이터는 죽은 데이터입니다. 요동치는(분산 큰) 데이터가 살아있는 정보입니다.

1) 직관적 비유

병원 모니터의 심전도 그래프를 상상해 보세요.

- 일직선 ($Var = 0$): 환자가 사망했습니다. 정보가 없습니다.
- 위아래로 뒹 ($Var > 0$): 환자가 살아있습니다. 분석할 정보가 있습니다.
- 결론: 데이터가 넓게 퍼져 있을수록, 서로를 구별할 수 있는 정보가 많습니다. 따라서 우리는 분산이 가장 큰 방향을 찾고 싶습니다.

2) 차원의 저주 탈출

변수(차원)가 많으면 계산도 힘들고 시각화도 불가능합니다. 정보량이 적은(분산이 작은) 변수는 과감히 버려서, 핵심만 남기는 것이 목표입니다.

1.2 2. 기하학적 해석: 최적의 좌표축 찾기

□ 개념 2: 럭비공 돌리기

한 줄 요약: 데이터 구름(Cloud)의 모양에 맞춰서 좌표축을 회전시킵니다. 가장 길쭉한 쪽이 x 축(PC1), 그 다음 넓은 쪽이 y 축(PC2)이 되도록요.

1) 첫 번째 주성분 (PC1)

데이터 점들을 가장 길게 통과하는 직선입니다.

- 기하학적으로는, 데이터 점들을 직선에 투영(Projection)했을 때 그 그림자들이 가장 넓게 퍼지는 선입니다.
- 동시에, 데이터 점들과 직선 사이의 수직 거리(Reconstruction Error)를 최소화하는 선입니다.

2) 두 번째 주성분 (PC2)

PC1과 반드시 수직(Orthogonal) 이면서, 남은 분산을 가장 잘 설명하는 방향입니다.

- **Why Orthogonal?** PC1이 이미 설명한 정보와 겹치지 않는, 완전히 새로운 정보(Independent Information)만 담기 위해서입니다. 이를 통해 변수 간의 상관관계를 제거(Decorrelation) 합니다.

1.3 3. 수학적 엔진: 공분산 행렬과 고유값 분해

□ 개념 3: 모든 것은 고유값 문제로 통한다

한 줄 요약: "분산을 최대화하는 축을 찾아라"라는 복잡한 미적분 문제가, 놀랍게도 선형대수의 $Av = \lambda v$ 를 푸는 문제로 바뀝니다.

Step 1: 표본 공분산 행렬 (S)

데이터 $\mathbf{X}$ (중심화됨, Mean=0)에 대해:

$$S = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$$

이 행렬은 변수들끼리 얼마나 같이 움직이는지(Correlation)를 담고 있습니다. 우리의 목표는 이 상관성을 없애는(대각화하는) 것입니다.

Step 2: 스펙트럼 정리 (Spectral Theorem)

S 는 대칭 행렬(Symmetric Matrix)입니다. 선형대수학의 스펙트럼 정리에 의해, 대칭 행렬은 반드시 실수 고유값을 가지며, 그 고유벡터들은 서로 직교합니다.

- 즉, 우리가 억지로 직교하는 축을 찾을 필요가 없습니다. 수학적으로 이미 직교하는 축(고유벡터)이 존재함이 보장됩니다.

Step 3: 고유값 분해 (The Solution)

$$Sv_j = \lambda_j v_j$$

- 고유벡터 (v_j): 우리가 찾던 새로운 축의 방향 (Principal Component).
- 고유값 (λ_j): 그 축 방향으로의 분산의 크기 (정보량).

1.4 4. 차원 축소의 실행 (Dimension Reduction)**□ 개념 4: 정보의 압축**

한 줄 요약: 중요도가 낮은(고유값이 작은) 축은 과감히 버립니다.

절차

1. 고유값들을 크기순으로 나열합니다: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$.
2. **Scree Plot**을 그려보거나, 누적 기여율(Cumulative Variance Ratio)을 확인합니다.

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^p \lambda_j} \geq 0.95 \quad (95\% \text{ 정보 보존})$$

3. 상위 k 개의 고유벡터만 남기고 나머지는 버립니다.
4. 데이터를 이 k 개의 축으로 투영(Projection)하여 차원을 $p \rightarrow k$ 로 줄입니다.

2 실전 시나리오: 넥슨 유저 세분화 (User Segmentation)**□ Scenario: 너무 많은 게임 지표들**

당신은 넥슨의 데이터 분석가입니다. 유저들의 플레이 패턴을 분석하려고 보니 지표가 너무 많습니다. (변수 20개: 총 킬 수, 데스 수, 어시스트, 가한 피해량, 받은 피해량, 힐량, 타워 철거 수, CS, 골드 획득량...) 변수가 20개라 시각화도 안 되고, 군집화(Clustering)를 돌려도 결과가 엉망입니다.

1. **문제:** 변수 간 상관관계가 너무 높습니다. (킬 많이 하면 골드도 많고 피해량도 높음).
2. **PCA 적용:** 20차원 데이터를 입력하여 주성분 분석을 수행합니다.
3. **결과 해석:**
 - **PC1 (설명력 60%):** 킬, 딜량, 골드 등 '전투/성장' 관련 변수들이 모두 양의 가중치를 가짐. → 해석: "실력(Skill) 지표"
 - **PC2 (설명력 20%):** 받은 피해량, 힐량은 높고 킬은 낮음. → 해석: "탱킹/서포팅 성향"
4. **활용:** 20개의 변수 대신, (Skill, Style)이라는 단 2개의 변수로 유저를 2차원 평면에 찍어봅니다. 유저 그룹이 명확하게 보이기 시작합니다.

3 자주 묻는 질문 (FAQ)

- Q1. 축을 돌리면 데이터의 의미가 변하지 않나요?** **A.** 네, 변합니다. 원래 변수는 "키", "몸무게"처럼 물리적 의미가 명확했지만, PCA로 만들어진 PC1은 " $0.7 \times \text{키} + 0.3 \times \text{몸무게}$ " 같은 섞인 값이 됩니다. 이를 "크기(Size)"라고 해석할지는 분석가의 몫입니다. 해석력(Interpretability)을 잃는 대신, 요약력(Summarization)을 얻는 것입니다.
- Q2. 데이터 스케일링(Scaling)을 꼭 해야 하나요?** **A.** 필수입니다! 만약 키는 cm(170), 몸무게는 kg(60) 단위인데, 연봉을 원(50,000,000) 단위로 넣으면, 연봉의 분산이 압도적으로 커서 PC1이 그냥 "연봉" 축이 되어버립니다. 반드시 모든 변수를 표준화(Standardization, 평균 0 분산 1)한 뒤 PCA를 돌려야 공평한 비교가 됩니다.

Next Step: 우리는 PCA를 통해 데이터를 압축하고 시각화했습니다. 이제 이 잘 정리된 데이터들을 끼리끼리 묶어볼 수 없을까요? 다음 **Unit 6**에서는 비지도 학습의 또 다른 핵심인 **군집화 (Clustering: K-means, Hierarchical)**를 통해 데이터 속에 숨어있는 그룹을 찾아냅니다.

Unit 5 핵심 요약

- **철학:** 분산(Variance)이 클수록 정보가 많다.
- **목표:** 정보를 최대한 보존하면서 변수의 개수(차원)를 줄이자.
- **방법:** 공분산 행렬 S 의 고유벡터(Eigenvector)를 찾는다.
- **PC의 성질:** 서로 직교(Orthogonal)하며, 상관관계가 제거된다.
- **주의:** 해석이 어려워질 수 있으며, 스케일링(정규화)이 필수적이다.