

# MIT 18.6501: 빅데이터의 딜레마와 돌파구

## Unit 12: High-dimensional Regression & Sparsity

### Contents

|     |                                                               |   |
|-----|---------------------------------------------------------------|---|
| 1   | Unit 12. 고차원 회귀와 희소성 (High-dimensional Regression & Sparsity) | 2 |
| 1.1 | 1. 문제의 본질: $p > n$ 일 때 발생하는 일                                 | 2 |
| 1.2 | 2. 희소성 가정 (Sparsity Assumption)                               | 3 |
| 1.3 | 3. 규제화 (Regularization): Ridge vs LASSO                       | 3 |
| 1.4 | 4. LASSO의 기하학적 해석 (The Geometry of Sparsity)                  | 4 |
| 1.5 | 5. 이론적 보장 (Theoretical Guarantees)                            | 4 |
| 2   | 실전 시나리오: 넥슨 게임 로그 분석                                          | 5 |
| 3   | 자주 묻는 질문 (FAQ)                                                | 6 |

---

### Course Structure & Current Focus

- Unit 8: Linear Regression (변수  $p$  가 작고 고정됨)
- Unit 11: PCA (변수를 합쳐서 줄임)
- **Unit 12: High-dimensional Regression (현재 단원: 변수가 너무 많음  $p \gg n$ )**
  - 12.1 The Curse of Dimensionality ( $p > n$ )
  - 12.2 Sparsity Assumption (Occam's Razor)
  - 12.3 Regularization: Ridge vs LASSO
  - 12.4 Geometry of LASSO (왜 0이 되는가?)
- Unit 13: Robustness (이상치 대응)

# 1 Unit 12. 고차원 회귀와 희소성 (High-dimensional Regression & Sparsity)

Unit 8에서 우리는  $Y = X\beta + \epsilon$ 을 풀기 위해 최소자승법(OLS)을 배웠습니다. 그때는 데이터( $n$ )가 변수( $p$ )보다 충분히 많았습니다. 하지만 현대의 유전체 학이나 텍스트 분석 데이터는 변수는 수만 개인데 샘플은 수십 개뿐입니다. "미지수가 식보다 많은 연립방정식", 과연 풀 수 있을까요? 이 불가능해 보이는 문제를 풀기 위해 우리는 '희소성(Sparsity)'이라는 강력한 믿음을 도입합니다.

## □ 개요 (Overview)

이 단원에서는 변수의 수( $p$ )가 데이터의 수( $n$ )보다 큰 고차원 상황( $p \gg n$ )에서 발생하는 문제점(Singularity, Overfitting)을 진단합니다. 이를 해결하기 위해 "진짜 중요한 변수는 소수일 것이다"라는 희소성 가정을 도입하고, LASSO(L1 Regularization)를 통해 변수 선택(Variable Selection)과 추정(Estimation)을 동시에 수행하는 기하학적 원리를 배웁니다.

## □ 핵심 용어 사전

| 용어 (Term)                      | 직관적 의미 (Meaning)                             |
|--------------------------------|----------------------------------------------|
| High-dimensional ( $p \gg n$ ) | 방정식보다 미지수가 더 많은 난감한 상황.                      |
| Sparsity (희소성)                 | "진짜 범인은 이 수만 명 중에 딱 한두 명이다."                 |
| Regularization (규제)            | 정답을 맞추는 것뿐만 아니라, 답안지(계수)가 깔끔해야 점수를 주는 채점 방식. |
| Ridge (L2)                     | 계수들을 0에 가깝게 작게 만들 (Shrinkage).               |
| LASSO (L1)                     | 중요하지 않은 계수를 아예 0으로 만들 (Selection).           |

## 1.1 1. 문제의 본질: $p > n$ 일 때 발생하는 일

### □ 개념 1: 식보다 미지수가 많다

**한 줄 요약:** 해가 하나로 정해지지 않고 무수히 많으며, 컴퓨터는 그중에서 "노이즈까지 외워버린" 최악의 해를 선택하게 됩니다.

### 1) 수학적 불능 (Singularity)

OLS 해  $\hat{\beta} = (X^T X)^{-1} X^T Y$ 를 구하려면 역행렬이 존재해야 합니다. 하지만  $p > n$ 이면  $X^T X$ 는 비가역 행렬(Singular Matrix)이 되어 역행렬이 없습니다.

- 예:  $x + y + z = 10$ . 미지수는 3개, 식은 1개.  $(1, 1, 8), (2, 3, 5)...$  해가 무한함.

## 2) 완벽한 과적합 (Perfect Overfitting)

변수가 많으면 모델은 모든 데이터 포인트를 완벽하게 지나가는 구불구불한 곡선을 만들 수 있습니다. (Training Error = 0). 하지만 새로운 데이터가 들어오면 예측력이 0에 수렴합니다.

## 1.2 2. 희소성 가정 (Sparsity Assumption)

### □ 개념 2: 오컴의 면도날 (Occam's Razor)

**한 줄 요약:** "현상은 복잡해 보이지만, 실제로 결과( $Y$ )를 조종하는 핵심 변수( $\beta_j \neq 0$ )는 극소수( $s$ )일 것이다."

### 수학적 정의

참값 벡터  $\beta^*$ 는  $p$ 차원이지만, 그중 0이 아닌 성분의 개수  $s$ 는  $n$ 보다 훨씬 작다고 가정합니다 ( $s \ll n$ ).

$$\|\beta^*\|_0 := \sum_{j=1}^p \mathbb{I}(\beta_j^* \neq 0) = s \ll n$$

이 믿음이 있어야만 우리는  $p$ 차원이라는 거대한 우주에서  $s$ 개의 별을 찾을 수 있습니다.

## 1.3 3. 규제화 (Regularization): Ridge vs LASSO

### □ 개념 3: 벌점 (Penalty) 시스템

**한 줄 요약:** "문제를 잘 푸는 것 (RSS 최소화)"도 중요하지만, "답안지가 복잡하면 (계수가 크면)" 감점을 시키는 새로운 채점 기준을 도입합니다.

### 최적화 문제의 변화

$$\hat{\beta} = \operatorname{argmin}_{\beta} (\|Y - X\beta\|^2 + \lambda \cdot \text{Penalty}(\beta))$$

$\lambda$ 는 규제의 강도입니다.  $\lambda$ 가 클수록 계수를 더 강하게 억누릅니다.

### 1) Ridge 회귀 (L2 Norm)

$$\text{Penalty} = \sum \beta_j^2$$

- 효과: 모든 계수를 균일하게 줄여줍니다 (Shrinkage).
- 한계: 0이 되지는 않습니다. (0.0001 같은 작은 값으로 살아남음). 변수 선택 기능이 없습니다.

## 2) LASSO 회귀 (L1 Norm)

$$\text{Penalty} = \sum |\beta_j|$$

- 효과: 덜 중요한 변수의 계수를 정확히 0으로 만듭니다 (Selection).
- 의의: 모델 해석이 용이해지고, 희소성 가정을 구현할 수 있습니다.

## 1.4 4. LASSO의 기하학적 해석 (The Geometry of Sparsity)

### □ 개념 4: 등근 원과 뾰족한 마름모

**한 줄 요약:** L1 페널티 영역(마름모)은 모서리가 뾰족해서, 최적해가 축(Axis) 위에서 형성될 확률이 매우 높습니다. 축 위에 있다는 것은 해당 좌표값이 0이라는 뜻입니다.

이 그림은 Unit 12의 하이라이트입니다.

- 등고선 (RSS): 타원형으로 퍼져나가는 "데이터가 원하는 답".
- 제약 영역 (Penalty): 원점 주변의 "우리가 허용하는 답의 범위". ( $\lambda$ 에 의해 결정됨).

### 상황 비교

1. Ridge (원형):  $\beta_1^2 + \beta_2^2 \leq C$ . 타원이 등근 원과 만납니다. 접점은 주로 1사분면 어딘가( $\beta_1 \neq 0, \beta_2 \neq 0$ )에서 생깁니다. 0이 되지 않습니다.
2. LASSO (마름모):  $|\beta_1| + |\beta_2| \leq C$ . 타원이 퍼져나가다가 뾰족한 모서리(Corner)에 먼저 닿습니다. 이 모서리는 축 위에 존재합니다 (예:  $\beta_1 = C, \beta_2 = 0$ ). 즉, 자연스럽게  $\beta_2$ 가 0이 됩니다. 이것이 LASSO가 변수를 제거하는 수학적/기하학적 원리입니다.

## 1.5 5. 이론적 보장 (Theoretical Guarantees)

### □ 개념 5: 신(Oracle)과의 대결

**한 줄 요약:** LASSO는 우리가 "진짜 중요한 변수가 무엇인지 미리 알고 있을 때 (Oracle)" 수행하는 추정만큼이나 훌륭한 성능을 냅니다.

## 오라클 부등식 (Oracle Inequalities)

LASSO의 오차는 다음을 만족합니다 (확률적으로).

$$\|\hat{\beta}_{LASSO} - \beta^*\|^2 \leq C \frac{s \log p}{n}$$

- 오차는 전체 변수  $p$ 가 아니라, **중요 변수 개수  $s$** 에 비례합니다.
- $\log p$ 는  $p$ 가 아주 커져도 매우 천천히 증가하므로,  $p \gg n$  상황에서도 오차가 작게 유지됩니다.

## 2 실전 시나리오: 넥슨 게임 로그 분석

### □ Scenario: 이탈 유저를 찾아라

당신은 넥슨의 데이터 분석가입니다. '메이플스토리' 유저 중 누가 다음 달에 게임을 접을지(Churn) 예측하고 싶습니다.

#### 1. 데이터 상황:

- $n = 500$  (최근 이탈한 유저 샘플 수)
- $p = 10,000$  (수집된 행동 로그 종류: 점프 횟수, 채팅 수, 물약 사용, 특정 맵 방문 등 무수히 많음)

2. **문제:**  $p \gg n$  이므로 일반 회귀분석을 돌리면 모든 변수가 중요하다고 나오거나 에러가 납니다.

3. **LASSO 적용:** L1 규제를 걸고 회귀분석을 수행합니다.

4. **결과:** 10,000개의 변수 중 9,995개의 계수가 0이 되었습니다.

- 살아남은 변수 5개: [길드 탈퇴 여부], [친구 목록 삭제 수], [고가 아이템 판매], [접속 시간 급감], [고객센터 불만 접수]

5. **인사이트:** "수만 가지 행동 중, 이 5개지만 모니터링하면 이탈을 90% 예측할 수 있구나!" → 해당 유저들에게 쿠폰 발송(Action Item).

### 3 자주 묻는 질문 (FAQ)

- Q1. 중요한 변수가 0이 되어버리면 어떡하나요?** **A.** 그럴 위험이 있습니다. 만약 변수들끼리 상관관계가 높다면(예: 왼발 움직임 vs 오른발 움직임), LASSO는 둘 중 하나만 남기고 하나는 0으로 죽여버립니다. 이를 방지하기 위해 Ridge와 LASSO를 섞은 **Elastic Net**을 사용하기도 합니다.
- Q2.  $\lambda$ (규제 강도)는 어떻게 정하나요?** **A.**  $\lambda$ 가 너무 크면 다 0이 되고(Underfitting), 너무 작으면 OLS랑 같아집니다(Overfitting). 보통 **교차 검증(Cross-Validation)**을 통해 예측 에러가 가장 작은 최적의  $\lambda$ 를 찾습니다.

**Next Step:** 우리는 고차원 데이터에서 희소성을 이용해 '중요한 변수'를 찾아냈습니다. 그런데 만약 데이터에 단순히 변수가 많은 게 아니라, **악의적인 노이즈(Outlier)**가 섞여 있다면 어떡할까요? 다음 **Unit 13**에서는 데이터가 오염되어도 흔들리지 않는 **로버스트 통계(Robust Statistics)**를 배웁니다.

#### Unit 12 핵심 요약

- **문제:**  $p \gg n$  이면 OLS는 불가능하거나 과적합된다.
- **가정:** 희소성(Sparsity). 중요한 변수는 소수( $s$ )다.
- **LASSO (L1):** 절댓값 페널티를 사용하여 변수 선택과 추정을 동시에 한다.
- **기하학:** L1의 뾰족한 모서리(Corner)가 최적해를 0으로 유도한다.
- **이론:**  $s \log p/n$  속도로 수렴하여 고차원에서도 작동한다.