

[CS230] Improving Deep Neural Networks: Data Setup Strategy

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-4. Neural Networks Basics - *Completed*

Chapter 5. Practical Aspects of Deep Learning (Current Unit)

- 5.1 Train / Dev / Test Sets Strategy
 - * The Purpose of Splitting
 - * Big Data Era Ratio (98/1/1)
 - * Distribution Mismatch & Data Leakage
 - * Bias-Variance Diagnosis
- 5.2 Regularization (L2, Dropout)
- 5.3 Optimization Algorithms (Adam, RMSProp)

지난 시간 복습 및 연결

지금까지 우리는 신경망이라는 '최고급 엔진'을 조립했습니다. 하지만 페라리 엔진을 트랙터에 달거나, 불순물이 섞인 연료를 넣으면 아무 소용이 없습니다. 이제부터는 엔진을 '어떻게 운용해야(Strategy)' 최고의 성능을 낼 수 있는지 배웁니다. 그 첫걸음은 데이터를 올바르게 나누는 것입니다. 많은 초심자가 데이터를 몽땅 털어 넣고 학습부터 시키지만, 이는 "채점 기준도 모른 채 시험 공부를 하는 것"과 같습니다.

1 Unit Overview

□ 핵심 목표

이 단원은 성공적인 머신러닝 프로젝트의 나침반인 '데이터 분할 전략'을 다룹니다.

- **정의:** Train(학습), Dev(튜닝), Test(평가) 세트의 명확한 역할 차이를 이해합니다.
- **비율:** 빅데이터 시대(100만 개 이상)에 왜 **98:1:1** 비율을 사용하는지 통계적으로 설명합니다.
- **원칙:** Dev와 Test 세트가 반드시 **동일한 분포(Same Distribution)**여야 하는 이유를 배웁니다.
- **진단:** 데이터 분할 결과를 통해 모델의 과소적합/과대적합을 진단하는 표를 해석합니다.

2 Essential Terminology

데이터셋	역할	비유 (수험생)
Train Set	모델의 파라미터(W, b) 학습	교과서 (평소 공부)
Dev Set	하이퍼파라미터 튜닝 & 모델 선택	모의고사 (실력 점검 및 공부법 수정)
Test Set	최종 성능 평가 (학습/튜닝 관여 X)	수능/본고사 (결과 반복 불가)

* Note: 과거에는 'Validation Set' 이라고 불렀으나, Andrew Ng 교수는 'Dev Set' 이라는 용어를 선호합니다.

3 Core Concepts: 전략적 분할

3.1 1. The Era Shift: 60/20/20 vs 98/1/1

데이터의 양(Size)에 따라 황금 비율은 달라집니다.

- **Traditional ML (Small Data):** 데이터가 1만 개 미만일 때.
 - 비율: 60% : 20% : 20%
 - 이유: 평가용 데이터가 너무 적으면 통계적으로 신뢰할 수 없어서 20%나 떼어놔야 했습니다.
- **Deep Learning Era (Big Data):** 데이터가 100만 개 이상일 때.
 - 비율: 98% : 1% : 1%
 - 이유: 100만 개의 1%면 1만 개입니다. 이 정도면 평가하기에 충분합니다. 나머지 98%를 학습(Train)에 몰아주어 성능을 극대화하는 것이 유리합니다.

3.2 2. The Golden Rule: Same Distribution

”Dev Set과 Test Set은 반드시 같은 과녁을 겨냥해야 한다.”

나쁜 예시 (Bad Example) (오해 방지 가이드)

- **Train:** 웹에서 크롤링한 고화질 고양이 사진 (20만 장)
- **Dev/Test:** 사용자가 폰으로 찍은 흐릿한 고양이 사진 (1만 장)

결과: 훈련 때는 99점(고화질 마스터)이지만, 실전에서는 0점입니다. **해결:** 모든 데이터를 섞어서(Shuffle) 나누거나, Dev/Test를 실제 목표(모바일 사진)로만 구성해야 합니다.

4 Deep Dive: 모델 진단 (Bias vs Variance)

데이터를 나누는 진짜 이유는 모델의 상태를 진단하기 위해서입니다.

□ 성능 진단표 (Human Error $\approx$ 0% 가정) (모델 진단)

Train Error	Dev Error	진단 (Diagnosis)	처방 (Action)
1%	11%	High Variance (과대적합)	데이터 추가, 정규화(Dropout), 모델 축소
15%	16%	High Bias (과소적합)	더 큰 모델(층 추가), 학습 시간 연장
15%	30%	High Bias & Variance	모델 구조 변경, 데이터 정제
0.5%	1%	Low Bias & Low Variance	Ideal (성공!)

- **Bias(편향) 문제:** Train Set조차 제대로 못 맞춤. (공부를 안 함)
- **Variance(분산) 문제:** Train은 잘 맞추는데 Dev는 못 맞춤. (교과서만 달달 외움, 응용 불가)

5 Implementation: Data Leakage 방지

가장 중요한 것은 **Data Leakage**(데이터 누수)를 막는 것입니다. 정규화(Normalization)를 할 때, 전체 데이터의 평균을 쓰면 안 됩니다. 오직 **Train Set**의 통계량만 사용해야 합니다.

```

1 import numpy as np
2 from sklearn.model_selection import train_test_split
3
4 def prepare_data(X, y):
5     """
6     X: (m, n_x) features
7     y: (m,) labels
8     """
9     # 1. Stratified Split 클래스(비율 유지하며 분할)
10    # Train(98%) vs Temp(2%)
11    X_train, X_temp, y_train, y_temp = train_test_split(
12        X, y, test_size=0.02, random_state=42, stratify=y
13    )
14
15    # Temp 다시 반반 나누어 Dev(1%) vs Test(1%)
16    X_dev, X_test, y_dev, y_test = train_test_split(
17        X_temp, y_temp, test_size=0.5, random_state=42, stratify=y_temp
18    )
19
20    # 2. Data Leakage 방지 전처리 핵심(!)
21    # 전체 가X 아니라, 오직 X_train 만으로 평균표준편차/ 계산
22    mean = np.mean(X_train, axis=0)
23    std = np.std(X_train, axis=0)
24
25    # 계산된 통계량으로 Train, Dev, Test 모두 변환
26    X_train_norm = (X_train - mean) / (std + 1e-8)
27    X_dev_norm = (X_dev - mean) / (std + 1e-8)
28    X_test_norm = (X_test - mean) / (std + 1e-8)
29
30    return X_train_norm, X_dev_norm, X_test_norm, y_train, y_dev, y_test

```

Listing 1: Stratified Split & Safe Normalization

6 FAQ & Pitfalls

Q1. Test Set 없이 Train/Dev만 쓰면 안 되나요?

A. 가능은 하지만, 위험합니다. Dev Set을 보고 모델을 계속 수정하다 보면, 모델이 Dev Set에 과적합(Overfitting)됩니다. 마치 모의고사 답을 외워버린 것과 같습니다. 객관적인 최종 평가를 위해 Test Set은 한 번도 보지 않은 상태로 남겨둬야 합니다.

Q2. 시계열 데이터(주식)도 랜덤 셔플(Shuffle)해도 되나요?

A. 절대 안 됩니다. 미래 정보가 과거 학습 데이터에 섞여 들어가게 됩니다(Look-ahead Bias). 시계열 데이터는 시간 순서대로 잘라야 합니다. (예: 1 9월 Train, 10월 Dev, 11월 Test)

다음 단계 (Next Step)

데이터 세팅이 끝났습니다. 이제 여러분은 모델이 **High Variance(과대적합)** 상태인지, **High Bias(과소적합)** 상태인지 진단할 수 있습니다.

만약 진단 결과 모델이 **High Variance(과대적합)**라면 어떻게 해야 할까요? 데이터를 더 모으는 것이 좋겠지만, 돈과 시간이 듭니다. 다음 시간에는 데이터를 늘리지 않고도 과대적합을 해결하는 마법 같은 기법, **[Regularization] (L2 Regularization & Dropout)**을 배우겠습니다.

□ 단원 요약 (Cheat Sheet)

1. **Split:** 빅데이터 시대에는 **98/1/1** 비율이 대세다. Train에 집중하라.
2. **Distribution:** Dev와 Test는 반드시 **같은 분포**여야 한다.
3. **Leakage:** 정규화 시 평균(μ)과 분산(σ)은 오직 **Train Set**에서만 구한다.
4. **Diagnosis:** Train Error와 Dev Error의 차이가 크면 **Variance(과대적합)** 문제다.