

[CS230] Optimization Algorithms: Batch Normalization

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-4. Neural Networks Basics - *Completed*

Chapter 5. Practical Aspects of Deep Learning (Current Unit)

- 5.1-5.5 Regularization & Data Setup - *Completed*
- 5.6-5.10 Optimization (Adam, Tuning) - *Completed*
- **5.11 Batch Normalization**
 - * Concept: Internal Covariate Shift
 - * The Algorithm: Norm, Scale, Shift
 - * Train Mode vs Test Mode (Running Average)
 - * Implementation
- 5.12 Softmax Regression - *Upcoming*

지난 시간 복습 및 연결

우리는 가중치 초기화와 하이퍼파라미터 튜닝을 통해 모델 성능을 높였습니다. 하지만 층이 깊어질수록 여전히 학습이 불안정하고, 학습률을 조금만 높여도 발산해버리는 문제가 발생합니다. 이유는 앞단 층의 파라미터가 바뀌면, 뒷단 층으로 넘어오는 데이터의 분포가 계속 바뀌기 때문입니다. 뒷단 층 입장에서는 계속 흔들리는 땅 위에서 균형을 잡으려는 것과 같습니다. 이를 해결하기 위해 2015년, "데이터 분포를 강제로 고정시키자"는 혁명적인 아이디어가 등장합니다. 바로 배치 정규화(Batch Normalization)입니다.

1 Unit Overview

□ 핵심 목표

이 단원은 딥러닝 역사상 가장 위대한 발명 중 하나인 배치 정규화의 원리와 구현을 다룹니다.

- **원인:** 학습을 방해하는 내부 공변량 변화(Internal Covariate Shift) 현상을 이해합니다.
- **알고리즘:** 미니 배치 단위로 평균/분산을 정규화하고, $\text{Scale}(\gamma)$ & $\text{Shift}(\beta)$ 파라미터로 복원하는 과정을 유도합니다.
- **차이:** 학습(Train) 때는 배치 통계량을, 추론(Test) 때는 이동 평균(Running Average)을 써야 함을 배웁니다.
- **구현:** 두 가지 모드를 지원하는 BN 클래스를 Python으로 구현합니다.

2 Essential Terminology

용어/기호	의미	역할
Batch Norm	배치 정규화	은닉층의 활성화 값을 정규 분포로 만듦.
Gamma (γ)	스케일 파라미터	정규화된 값의 분산을 조절 (학습 가능).
Beta (β)	시프트 파라미터	정규화된 값의 평균을 조절 (학습 가능).
Running Stats	이동 평균 통계량	테스트 시 사용하기 위해 학습 중 누적해둔 평균/분산.

3 Core Concepts: 흔들리는 땅 고정하기

3.1 1. Internal Covariate Shift (내부 공변량 변화)

□ 흔들리는 다리 위에서 걷기 (직관적 비유)

- **Without BN:** 앞사람(Layer 1)이 발을 구를 때마다 다리가 흔들립니다. 뒷사람(Layer 2)은 중심 잡느라 앞으로 나아갈 수가 없습니다. (학습 속도 저하)
- **With BN:** 각 층마다 "발판을 수평으로 고정(Normalize)"해줍니다. 뒷사람은 앞사람의 움직임에 상관없이 안정적으로 달릴 수 있습니다. (학습 속도 비약적 향상)

3.2 2. The Algorithm: Norm, Scale, Shift

은닉층의 값 Z 에 대해 미니 배치 단위로 4단계를 수행합니다.

1. **Mean:** $\mu = \frac{1}{m} \sum z^{(i)}$
2. **Variance:** $\sigma^2 = \frac{1}{m} \sum (z^{(i)} - \mu)^2$
3. **Normalize:** $z_{norm} = \frac{z - \mu}{\sqrt{\sigma^2 + \epsilon}}$ (ϵ : 0 나누기 방지)
4. **Scale & Shift (핵심):** $\tilde{z} = \gamma z_{norm} + \beta$

왜 다시 γ

무조건 평균 0, 분산 1로 고정하면, 데이터가 Sigmoid의 선형 구간(가운데)에만 몰리게 되어 비선형성(표현력)을 잃게 됩니다. γ 와 β 를 학습 가능하게 두어, "필요하다면 원래 분포로 되돌릴 수 있는 자유"를 모델에게 주는 것입니다.

4 Deep Dive: Train vs Test Mode

배치 정규화 구현에서 가장 중요한 포인트입니다.

- **Training Mode:** 현재 들어온 미니 배치의 평균/분산을 계산해서 씁니다. 동시에 이 값들을 `'running_mean'`, `'running_var'` () .
- **Test Mode:** 테스트 때는 데이터가 1개만 들어올 수도 있습니다(분산 계산 불가). 따라서 학습 때 미리 저장해둔 `'running_mean'`, `'running_var'` .

5 Implementation: Batch Norm Class

```
1 import numpy as np
2
3 class BatchNorm:
4     def __init__(self, n_features, momentum=0.9):
5         self.gamma = np.ones((n_features, 1)) # 초기값 1 변화(없음)
6         self.beta = np.zeros((n_features, 1)) # 초기값 0 변화(없음)
7
8         # 테스트 단계를 위한 메모리 (Running Stats)
9         self.running_mean = np.zeros((n_features, 1))
10        self.running_var = np.ones((n_features, 1))
11        self.momentum = momentum
12        self.epsilon = 1e-8
13
14        def forward(self, Z, mode='train'):
15            if mode == 'train':
16                # 1. 미니 배치 통계량 계산
17                mu = np.mean(Z, axis=1, keepdims=True)
18                var = np.var(Z, axis=1, keepdims=True)
19
20                # 2. 정규화
21                Z_norm = (Z - mu) / np.sqrt(var + self.epsilon)
22
23                # 3. Running Stats 업데이트 지수(가중 평균)
24                # 역전파와 무관하게 별도로 기록해둠
25                self.running_mean = self.momentum * self.running_mean + (1 - self.
momentum) * mu
26                self.running_var = self.momentum * self.running_var + (1 - self.momentum
) * var
27
28                elif mode == 'test':
29                    # 테스트 시에는 저장해둔 통계량 사용
30                    Z_norm = (Z - self.running_mean) / np.sqrt(self.running_var + self.
epsilon)
31
32                # 4. Scale and Shift 공통()
33                out = self.gamma * Z_norm + self.beta
```

Listing 1: Batch Normalization Implementation

6 FAQ & Pitfalls

Q. BN을 쓰면 왜 b (Bias)를 없애도 되나요?

A. $Z = WX + b$ 에서 평균 μ 를 빼는 과정($Z - \mu$) 때문에 상수 b 는 어차피 상쇄되어 사라집니다. 대신 BN의 β 가 편향 역할을 대신합니다.

Q. BN은 어디에 넣나요? Activation 전? 후?

A. 원래 논문(Andrew Ng 스타일)은 **Activation 전**($Z \rightarrow BN \rightarrow A$)을 권장합니다. 하지만 최근에는 후($Z \rightarrow A \rightarrow BN$)에 넣는 경우도 많습니다. 둘 다 잘 동작합니다.

다음 단계 (Next Step)

이제 우리는 딥러닝 모델의 성능을 극한으로 끌어올리는 모든 도구(초기화, 정규화, 최적화, 배치 정규화)를 손에 넣었습니다.

지금까지는 '고양이 vs 개'처럼 답이 두 개인 이진 분류만 다뤘습니다. 하지만 세상에는 답이 여러 개인 문제가 더 많습니다. (숫자 0-9, 옷 종류 등) 다음 시간에는 여러 개의 클래스를 동시에 분류하는 [Softmax Regression]에 대해 다루겠습니다.

□ 단원 요약 (Cheat Sheet)

1. **Batch Norm:** 각 층의 입력을 정규화하여 학습을 안정화하고 가속한다.
2. **Gamma/Beta:** 정규화로 잃어버린 표현력을 복구하기 위한 학습 파라미터.
3. **Train/Test:** 학습 시엔 배치 통계량, 테스트 시엔 이동 평균(Running Avg)을 쓴다.
4. **Effect:** 초기화에 덜 민감해지고, 높은 학습률을 쓸 수 있다.