

[CS230] Structuring Machine Learning Projects: Single Number Evaluation Metric (F1 Score)

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-5. Deep Learning Fundamentals - *Completed*

Chapter 6. Structuring ML Projects (Current Unit)

- 6.1 Orthogonalization Strategy - *Completed*
- **6.2 Single Number Evaluation Metric**
 - * Confusion Matrix (TP, TN, FP, FN)
 - * Precision vs Recall Trade-off
 - * Why Harmonic Mean? (F1 Score)
 - * Implementation
- 6.3 Satisficing and Optimizing Metrics - *Upcoming*

지난 시간 복습 및 연결

지난 시간에 우리는 프로젝트의 방향을 잡는 '직교화' 전략을 배웠습니다. 하지만 방향을 잡았다고 끝이 아닙니다. 팀원이 두 개의 모델을 들고 왔습니다. "A는 정밀도가 높는데 재현율이 낮고, B는 정밀도는 낮는데 재현율이 높습니다. 뭘 쓸까요?" 여기서 머뭇거리면 프로젝트가 멈춥니다. 앤드류 응 교수는 "평가 지표는 하나여야 한다(Single Number Metric)"고 강조합니다. 그래야 수많은 실험 결과를 한 줄로 세우고, 1등을 바로 뽑을 수 있기 때문입니다.

1 Unit Overview

□ 핵심 목표

이 단원은 불균형 데이터에서 모델 성능을 정확히 평가하는 **F1 Score**를 다룹니다.

- **정의:** 정밀도(Precision)와 재현율(Recall)의 개념을 오차 행렬을 통해 익힙니다.
- **이유:** 왜 단순 평균이 아닌 조화 평균(Harmonic Mean)을 써야 하는지 증명합니다.
- **관계:** 임계값 변화에 따라 두 지표가 반대로 움직이는 **Trade-off** 관계를 파악합니다.
- **구현:** Python으로 직접 지표를 계산하고 분석합니다.

2 Essential Terminology: Confusion Matrix

구분	예측: Positive (1)	예측: Negative (0)
실제: Positive (1)	TP (정답)	FN (놓침/미검출)
실제: Negative (0)	FP (오해/거짓 알람)	TN (정답)

3 Core Concepts: 두 마리 토끼 잡기

3.1 1. Precision (정밀도)

질문: "모델이 찾은 것 중에 진짜는 얼마나 되는가?"

$$P = \frac{TP}{TP + FP}$$

□ 칸칸한 미식가 (직관적 비유)

"나는 맛있는 건 절대 안 먹어." (FP 싫어함) 맛있는 것 (TP)을 좀 놓치더라도, 내 입에 들어오는 건 무조건 맛있어야 합니다. **활용:** 스팸 메일 분류 (정상 메일을 스팸통에 넣으면 치명적임).

3.2 2. Recall (재현율)

질문: "실제 존재하는 것 중에 모델이 얼마나 찾았는가?"

$$R = \frac{TP}{TP + FN}$$

□ 그물망 어선 (직관적 비유)

"쓰레기가 좀 섞여도 좋으니, 물고기는 다 잡아라." (FN 싫어함) 잡동사니 (FP)가 걸려도 괜찮지만, 물고기 (TP)를 놓치면 안 됩니다. **활용:** 암 진단 (암 환자를 정상이라 하면 생명이 위험함), 도둑 탐지.

4 Deep Dive: Why Harmonic Mean? (F1 Score)

왜 두 지표를 그냥 더해서 2로 나누면 (산술 평균) 안 될까요?

□ 바보 모델의 함정 (수학적 증명)

암 환자가 1%인 데이터가 있습니다. 어떤 모델이 "무조건 암이다(1)"라고 예측한다고 합시다. (Recall = 1.0, Precision ≈ 0.01)

1. 산술 평균 (Arithmetic Mean):

$$\frac{P + R}{2} = \frac{0.01 + 1.0}{2} \approx 0.5$$

→ 말도 안 되는 모델에게 50점이나 줍니다. 과대평가입니다.

2. 조화 평균 (Harmonic Mean, F1 Score):

$$F1 = \frac{2}{\frac{1}{P} + \frac{1}{R}} = 2 \frac{P \times R}{P + R}$$

$$2 \frac{0.01 \times 1.0}{0.01 + 1.0} \approx 0.019$$

→ 둘 중 하나라도 낮으면 점수를 확 깎아버립니다. 이것이 우리가 원하는 평가 방식입니다.

5 Implementation: Metric Calculation

‘scikit-learn’을 쓰면 쉽지만, 원리 이해를 위해 ‘numpy’로 직접 구현해 봅시다.

```
1 import numpy as np
2
3 def calculate_metrics(y_true, y_pred):
4     """
5     y_true: 실제값 (0 or 1)
6     y_pred: 예측값 (0 or 1)
7     """
8     # 불리언 인덱싱으로 TP, FP, FN 계산 (Vectorized)
9     TP = np.sum((y_true == 1) & (y_pred == 1))
10    FP = np.sum((y_true == 0) & (y_pred == 1))
11    FN = np.sum((y_true == 1) & (y_pred == 0))
12
13    # 으로0 나누기 방지용 엡실론
14    epsilon = 1e-7
15
16    # Precision & Recall
17    precision = TP / (TP + FP + epsilon)
18    recall = TP / (TP + FN + epsilon)
19
20    # F1 Score (Harmonic Mean)
21    f1 = 2 * (precision * recall) / (precision + recall + epsilon)
22
23    return precision, recall, f1
24
25 # --- 실행 ---
26 if __name__ == "__main__":
27     # 암환자(1) 명2, 정상(0) 명8
28     y_true = np.array([0, 1, 0, 0, 1, 0, 0, 0, 0, 0])
29
30     # 모델 예측: 명은1 맞췄지만, 정상인 명을1 오진함
31     y_pred = np.array([0, 1, 0, 0, 0, 1, 0, 0, 0, 0])
32
33     p, r, f1 = calculate_metrics(y_true, y_pred)
34
35     print(f"Precision: {p:.2f}") # 0.50 번(2 예측해서 번1 맞음)
36     print(f"Recall: {r:.2f}") # 0.50 실제( 명2 중 명1 찾음)
```

```
print(f"F1 Score: {f1:.2f}") # 0.50
```

Listing 1: Precision

6 FAQ & Pitfalls

Q. Accuracy(정확도)는 언제 쓰나요?

A. 데이터 클래스 비율이 50:50으로 균형 잡혀 있을 때만 씁니다. 불균형 데이터(99:1)에서는 무조건 0으로 찍어도 정확도가 99%가 나오므로 무의미합니다.

Q. Recall이 Precision보다 훨씬 중요한 경우는요?

A. F1 Score는 두 지표를 1:1로 봅니다. Recall을 더 중요하게 보고 싶다면 **F2 Score**(Recall에 가중치)를 쓰면 됩니다. 반대는 F0.5 Score입니다.

다음 단계 (Next Step)

이제 우리는 성능을 평가하는 단일 숫자(F1 Score)를 얻었습니다. 그런데 현실에서는 성능뿐만 아니라 제약 조건도 있습니다. "정확도는 높아야 하지만, 실행 시간은 10ms 이내여야 한다."

이런 복잡한 요구사항을 어떻게 단일 지표로 정리할까요? 다음 시간에는 [Satisficing and Optimizing Metrics]를 통해, '최적화해야 할 것'과 '만족시켜야 할 것'을 구분하는 전략을 배웁니다.

□ 단원 요약 (Cheat Sheet)

1. **Need:** 불균형 데이터에서는 정확도 대신 Precision/Recall을 봐야 한다.
2. **Trade-off:** Precision과 Recall은 반비례 관계다. 둘 다 높은 게 최고다.
3. **F1 Score:** 조화 평균이다. 극단적인 값(하나만 높은 경우)에 페널티를 주어 균형을 잡는다.
4. **Single Number:** 지표를 하나로 합쳐야 빠른 의사결정이 가능하다.