

[CS230] Structuring Machine Learning Projects: End-to-End Deep Learning

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-7. ML Strategy & Advanced Learning - *Completed*

Chapter 8. End-to-End Deep Learning (Current Unit)

- **8.1 Concept: Pipeline vs E2E**
 - * Definition: Direct Highway
 - * Pros: Let the Data Speak
 - * Cons: Data Hungry & Black Box
 - * Decision Checklist
- 8.2 Application Examples (Speech, Vision)

Chapter 9. Convolutional Neural Networks (CNN) - *Next Part*

지난 시간 복습 및 연결

지난 시간까지 우리는 전이 학습과 다중 작업 학습을 통해 기존 지식을 활용하는 법을 배웠습니다. 이제 딥러닝이 가져온 가장 거대한 패러다임의 변화, **엔드투엔드(End-to-End)** 딥러닝에 대해 이야기할 시간입니다. 과거에는 음성 인식을 위해 음향학, 음성학 등 수많은 파이프라인을 조립했습니다. 하지만 딥러닝은 이 모든 단계를 건너뛰고, "입력에서 출력으로 직행하는 고속도로"를 뚫어버렸습니다. 이것이 언제나 정답일까요?

1 Unit Overview

□ 핵심 목표

이 단원은 중간 단계를 생략하고 데이터만으로 학습하는 E2E 딥러닝의 장단점을 분석합니다.

- **정의:** 전통적인 파이프라인(Pipeline) 방식과 **E2E** 방식의 구조적 차이를 구분합니다.
- **장점:** 인간의 편향(Hand-designed components)을 제거하여 최적의 성능을 내는 원리를 이해합니다.
- **단점:** 왜 막대한 양의 데이터가 필요한지(Data Hungry), 왜 디버깅이 어려운지 파악합니다.
- **결정:** 언제 E2E를 쓰고, 언제 파이프라인을 써야 하는지 결정 기준을 세웁니다.

2 Essential Terminology

용어	의미	비유
End-to-End (E2E)	입력 → 출력으로 직행하는 단일 모델	직항 비행기 (중간 경유지 없음)
Pipeline	여러 모듈을 순차적으로 연결한 시스템	경유 비행기 (A → B → C → D)
Hand-engineered	사람이 직접 설계한 특징/규칙	수제작 부품 (장인의 손길)

3 Core Concepts: 직행 고속도로

3.1 1. Pipeline vs End-to-End

예시: 음성 인식 (Speech Recognition)

- **Traditional Pipeline:**

Audio → MFCC(특징 추출) → Phoneme(음소) → Word → Text

각 단계마다 전문가의 지식(음성학 등)이 필요합니다.

- **End-to-End Deep Learning:**

Audio → [Deep Neural Network] → Text

중간 단계(음소 등)를 명시적으로 가르치지 않습니다. 데이터만 충분하면 신경망이 알아서 최적의 내부 표현을 찾아냅니다.

3.2 2. The Key Idea: Let the Data Speak

전통적 방식에는 "음소를 먼저 찾아야 해"라는 인간의 가정(Bias)이 들어갑니다. 하지만 데이터가 충분하다면, 신경망은 음소보다 더 효율적인 자신만의 방식을 찾아낼 수 있습니다. E2E는 데이터가 스스로 최적의 처리 과정을 설계하도록 허용하는 것입니다.

4 Deep Dive: Pros & Cons

무조건 E2E가 좋은 것은 아닙니다. 명확한 트레이드오프가 존재합니다.

□ End-to-End 장단점 분석 (전략 가이드)

장점 (Pros):

- **Data-driven:** 인간의 선입견에 갇히지 않고 데이터 패턴 자체를 학습하므로, 데이터가 많을수록 성능 상한선이 높습니다.
- **Simplicity:** 복잡한 파이프라인을 설계하고 유지보수할 필요가 없습니다. 신경망 하나만 관리하면 됩니다.

단점 (Cons):

- **Data Hungry:** (x, y) 쌍 데이터가 엄청나게 많이 필요합니다. (파이프라인은 각 모듈별로 적은 데이터로 학습 가능).
- **Black Box:** 왜 틀렸는지 설명하기 어렵습니다. (파이프라인은 "음소 인식에서 틀렸군" 하고 알 수 있음).

5 Example: Date Formatting

날짜 형식을 변환하는 간단한 예제로 E2E의 철학을 봅니다. Input: "20th Jan. 2023" → Output: "2023-01-20"

```
1 # Traditional Approach (Rule-based)
2 def parse_date(date_str):
3     # 수많은 규칙(Regex) 작성 필요
4     # "Jan" -> 01, "February" -> 02 ...
5     # 오타 처리, 예외 처리 등 복잡함
6     pass
7
8 # End-to-End Approach
9 # 규칙을 짜는 게 아니라, 데이터(x, y)를 들이붓는다.
10 x_data = ["25th Dec 2022", "December 25, 2022", "12/25/22"]
11 y_data = ["2022-12-25", "2022-12-25", "2022-12-25"]
12
13 # 데이터가 만10 개쯤 있다면,
14 # 모델(Seq2Seq 등)은 "Dec"가 라는"12" 것을 스스로 깨우칩니다.
15 # 코드는 모델 아키텍처 정의뿐, 비즈니스 로직은 없습니다.
16 model.fit(x_data, y_data)
```

Listing 1: E2E Logic Overview

6 FAQ & Pitfalls

Q. 자율주행도 E2E로 하나요?

A. 초기에는 시도했지만(NVIDIA 등), 현재는 안전 때문에 파이프라인을 선호합니다. "이미지 → 핸들 조향"으로 바로 가면, 사고가 났을 때 왜 핸들을 꺾었는지 알 수 없어 디버깅과 책임 소재 파악이 불가능하기 때문입니다. (최근엔 다시 E2E 비중이 늘어나는 추세이긴 합니다.)

Q. 데이터가 적을 때 E2E를 쓰면 안 되나요?

A. 네, 성능이 처참할 수 있습니다. 데이터가 적을 때는 인간의 지식(Hand-engineered features)을 주입해주는 파이프라인 방식이 훨씬 효율적입니다.

다음 단계 (Next Step)

이것으로 앤드류 응 교수의 '머신러닝 프로젝트 구조화 전략(Structuring ML Projects)' 파트 (Part 3)를 모두 마칩니다. 이제 여러분은 딥러닝의 기초 이론부터 성능 향상 기법, 그리고 프로젝트를 지휘하는 전략까지 모두 갖췄습니다.

다음 시간부터는 딥러닝의 꽃이자 가장 널리 쓰이는 분야인 [Part 4. Convolutional Neural Networks (CNN)]의 세계로 들어갑니다. 이미지를 처리하는 컴퓨터의 시각을 정복해보겠습니다. 기대하십시오.

□ 단원 요약 (Cheat Sheet)

1. **E2E:** 중간 단계 없이 입력에서 출력으로 바로 매핑하는 딥러닝 방식.
2. **Pros:** 데이터가 충분하면 인간보다 더 효율적인 특징을 찾아낸다.
3. **Cons:** 막대한 양의 라벨링 데이터가 필요하다. 설명력이 부족하다.
4. **Decision:** 데이터 양이 적거나 안전/설명이 중요한 분야는 파이프라인을 쓴다.