

[CS230] Convolutional Neural Networks: CNN Foundations

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-8. Deep Learning Strategy & Architecture - *Completed*

Chapter 9. Convolutional Neural Networks (Current Part)

- **9.1 CNN Foundations: Convolution, Padding, Strides**
 - * The Convolution Operation (*)
 - * Padding (Valid vs Same)
 - * Strides (Downsampling)
 - * **The Golden Formula** (Dimension Calculation)
- 9.2 Pooling Layers (Max/Average) - *Upcoming*
- 9.3 CNN Example: LeNet-5 - *Upcoming*

지난 시간 복습 및 연결

우리는 지금까지 딥러닝 프로젝트를 전략적으로 지휘하는 법(Part 3)을 배웠습니다. 이제 딥러닝이 가장 눈부신 성과를 낸 **컴퓨터 비전(Part 4)**의 세계로 들어갑니다. 만약 고화질 이미지를 기존의 FC(Fully Connected) Layer에 넣으면 어떻게 될까요? 파라미터가 수십억 개로 폭발하여 계산이 불가능해집니다. 우리에게엔 이미지의 지역적 특징을 효율적으로 추출하는 새로운 도구가 필요합니다. 바로 **합성곱(Convolution)**입니다.

1 Unit Overview

□ 핵심 목표

이 단원은 CNN을 구성하는 가장 기초적인 '레고 블록' 세 가지를 마스터합니다.

- **Convolution:** 필터를 슬라이딩하며 특징을 추출하는 기본 연산.
- **Padding:** 이미지 가장자리 정보 손실을 막고 크기를 유지하는 기법.
- **Strides:** 필터 이동 간격을 조절하여 출력 크기를 줄이는 기법.
- **Formula:** 입력 크기, 필터, 패딩, 스트라이드가 주어졌을 때 출력 크기를 계산하는 공식을 암기합니다.

2 Essential Terminology

용어	기호	설명
Filter / Kernel	$f \times f$	이미지를 훑는 작은 윈도우. 학습 대상 파라미터(W).
Padding	p	입력 이미지 테두리에 덧대는 가짜 픽셀(0).
Stride	s	필터가 한 번에 이동하는 칸 수(보폭).
Feature Map	-	합성곱 연산의 결과물(출력 이미지).

3 Core Concepts: CNN의 레고 블록

3.1 1. The Convolution Operation (*)

FC Layer가 이미지 전체를 한 번에 본다면, 합성곱은 작은 '손전등'으로 이미지를 훑는 것과 같습니다.

- **과정:** 3×3 필터를 이미지 좌측 상단에 겹쳐 놓고, 겹치는 숫자끼리 곱해서 더합니다(내적). 그 결과값 하나가 출력의 픽셀 하나가 됩니다. 옆으로 한 칸씩 이동하며 반복합니다.
- **의미:** 필터의 값에 따라 수직선, 수평선 같은 특정 패턴이 있는 위치를 찾아냅니다.

3.2 2. Padding (p)

합성곱을 하면 이미지가 점점 작아집니다 ($6 \times 6 \rightarrow 4 \times 4 \rightarrow \dots$). 또한 가장자리 픽셀은 필터가 덜 지나가서 정보가 소실됩니다. 이를 막기 위해 테두리에 0을 채웁니다.

- **Valid Padding** ($p = 0$): 패딩 없음. 크기가 줄어듦.
- **Same Padding:** 입력과 출력의 크기가 같아지도록 p 를 설정함.

$$p = \frac{f - 1}{2} \quad (\text{단, } s = 1)$$

3.3 3. Strides (s)

필터를 한 칸씩($s = 1$)이 아니라 두 칸씩($s = 2$) 듬성듬성 이동합니다.

- **효과:** 출력 크기가 대략 $1/s$ 배로 줄어듭니다 (**Downsampling**).
- **용도:** 계산량을 줄이거나 넓은 영역을 요약해서 볼 때 씁니다.

4 Deep Dive: The Golden Formula (만능 공식)

이 공식은 CNN 아키텍처를 설계하거나 논문을 읽을 때 필수입니다. 무조건 암기하십시오.

□ 출력 크기 계산 공식 (만능 공식)

입력 크기가 $n \times n$ 일 때, 출력 크기는 다음과 같습니다.

$$n_{out} = \left\lfloor \frac{n + 2p - f}{s} + 1 \right\rfloor$$

- n : 입력 크기
- p : 패딩 크기
- f : 필터 크기
- s : 스트라이드
- $\lfloor \cdot \rfloor$: 바닥 함수 (소수점 내림)

계산 예제 상황: 입력 7×7 ($n = 7$), 필터 3×3 ($f = 3$), 패딩 없음 ($p = 0$), 스트라이드 2 ($s = 2$).
계산:

$$n_{out} = \left\lfloor \frac{7 + 2(0) - 3}{2} + 1 \right\rfloor = \left\lfloor \frac{4}{2} + 1 \right\rfloor = \lfloor 3 \rfloor = 3$$

결과: 출력은 3×3 크기가 됩니다.

5 Implementation Perspective: 3D Volume

실제 이미지는 컬러(RGB)이므로 3차원($H \times W \times C$)입니다.

- **Rule:** 필터의 채널 수(깊이)는 입력의 채널 수와 항상 같아야 합니다.
- **예시:** 입력이 $6 \times 6 \times 3$ 이면, 필터는 $3 \times 3 \times 3$ 이어야 합니다.
- **다중 필터:** 만약 이런 필터를 10개 쓴다면? 출력은 $4 \times 4 \times 10$ 이 됩니다.

필터 개수

CNN 층을 지난 뒤 데이터의 깊이(Depth)는 입력의 깊이가 아니라 필터의 개수에 의해 결정됩니다. 이것이 채널 수를 조절하는 핵심 메커니즘입니다.

다음 단계 (Next Step)

우리는 CNN의 기초 연산(Conv, Padding, Stride)을 마스터했습니다. 하지만 이것만으로는 부족합니다. 이미지의 크기를 더 과감하게 줄이면서도 중요한 정보(최대값)만 남기는 풀링(Pooling) 계층이 필요합니다.

다음 시간에는 Max Pooling과 Average Pooling에 대해 배우고, 드디어 이 모든 블록을 조립하여 첫 번째 완전한 CNN 모델(LeNet-5)을 만들어보겠습니다.

□ 단원 요약 (Cheat Sheet)

1. **Convolution:** 필터를 슬라이딩하며 지역적 특징을 추출한다.
2. **Padding:** 가장자리 손실을 막고 크기를 유지한다 (Same Padding).
3. **Stride:** 이동 간격을 넓혀 크기를 줄인다.
4. **Formula:** $n_{out} = \lfloor \frac{n+2p-f}{s} + 1 \rfloor$.