

[CS230] Sequence Models: Word Representation (Embedding)

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-9. Deep Learning Fundamentals & CNNs - *Completed*

Chapter 10. Sequence Models (Current Part)

- 10.1-10.4 RNN, GRU, LSTM - *Completed*
- **10.5 Word Representation**
 - * One-hot Encoding (The Old Way)
 - * Word Embedding (The New Way)
 - * Analogy Reasoning (King - Man + Woman)
 - * Embedding Matrix & Lookup Table
- 10.6 Word2Vec & GloVe - *Upcoming*

지난 시간 복습 및 연결

지난 시간 우리는 시퀀스 데이터를 처리하는 강력한 엔진인 **LSTM**을 만들었습니다. 이제 이 엔진에 연료를 넣을 차례입니다. 컴퓨터는 '사과'나 '왕'이라는 글자를 이해하지 못합니다. 오직 숫자만 이해하죠. 그렇다면 단어를 어떻게 숫자로 바꿔야 할까요? 단순히 번호를 매기면(1번 사과, 2번 배) 엉뚱한 수학적 관계가 생깁니다. 우리는 단어의 **의미(Meaning)**를 숫자 속에 담고 싶습니다. 오늘은 NLP의 혁명, **단어 임베딩(Word Embedding)**을 배웁니다.

1 Unit Overview

□ 핵심 목표

이 단원은 컴퓨터가 인간의 언어를 이해하는 척하게 만든 핵심 기술을 다룹니다.

- **One-hot:** 전통적인 방식의 희소성(Sparsity)과 의미 부재 문제를 이해합니다.
- **Embedding:** 단어를 실수 벡터(Dense Vector)로 표현하여 의미를 담는 원리를 파악합니다.
- **Analogy:** 벡터 연산을 통해 "남자 - 여자 = 왕 - 여왕" 관계를 도출해봅니다.
- **Matrix:** 임베딩 층이 실제로는 거대한 룩업 테이블(Lookup Table)임을 이해합니다.

2 Essential Terminology

용어	형태	특징
One-hot Encoding	$[0, 0, 1, 0, \dots]$	희소함. 단어 간 거리가 모두 같음 (관계 없음).
Word Embedding	$[0.1, -0.5, 0.9, \dots]$	밀집함. 비슷한 단어끼리 거리가 가까움.
Embedding Matrix	$E \in \mathbb{R}^{V \times D}$	모든 단어의 벡터를 담고 있는 행렬.

3 Core Concepts: 숫자에 의미를 담다

3.1 1. The Old Way: One-hot Encoding

단어 사전 크기가 10,000개라면 10,000차원 벡터를 만듭니다.

- **Man (5391번):** $[0, \dots, 1(5391 \text{ 번째}), \dots, 0]$
- **Woman (9853번):** $[0, \dots, 1(9853 \text{ 번째}), \dots, 0]$
- **문제점:** 두 벡터의 내적(Dot Product)은 0입니다. 컴퓨터 입장에서 Man은 Woman과도 다르고 Apple과도 다릅니다. 유사성을 알 수 없습니다.

3.2 2. The New Way: Word Embedding

단어를 훨씬 작은 차원(예: 300차원)의 실수 벡터(Real-valued Vector)로 표현합니다. 각 차원은 우리가 알 수 없는(혹은 추상적인) '특징(Feature)'을 나타냅니다.

□ 가상의 특징표 (Featurized Representation) (직관적 비유)

Feature	Man	Woman	King	Queen
Gender	-1	1	-0.95	0.97
Royal	0.01	0.02	0.93	0.95
Age	0.03	0.02	0.70	0.60

이제 "Man"과 "Woman" 벡터를 비교하면, Gender를 제외한 나머지 수치들이 매우 비슷합니다. 내적을 하면 값이 크게 나옵니다. 유사성을 계산할 수 있습니다.

3.3 3. Analogy Reasoning (유추 추론)

단어 임베딩의 가장 유명한 예시입니다.

$$e_{Man} - e_{Woman} \approx \begin{bmatrix} -2 \\ 0 \\ 0 \end{bmatrix} \quad (\text{Gender 차이만 남음})$$

$$e_{King} - e_{Queen} \approx \begin{bmatrix} -2 \\ 0 \\ 0 \end{bmatrix} \quad (\text{Gender 차이만 남음})$$

따라서 다음 등식이 성립합니다.

$$e_{Man} - e_{Woman} \approx e_{King} - e_{Queen}$$

$$e_{King} - e_{Man} + e_{Woman} \approx e_{Queen}$$

컴퓨터에게 "왕 - 남자 + 여자"를 계산하라면, 놀랍게도 "여왕"에 해당하는 벡터를 찾아냅니다.

4 Deep Dive: Implementation Details

4.1 Embedding Layer as a Lookup Table

수학적으로는 원-핫 벡터 O_j 와 임베딩 행렬 E 를 곱하는 것($E \cdot O_j$)입니다. 하지만 O_j 는 하나만 1이고 나머지가 0이므로, 이는 결국 행렬 E 의 j 번째 열(Column)을 꺼내오는 것과 같습니다. 딥러닝 프레임워크는 이를 행렬 곱셈이 아닌, 인덱스 접근(Lookup)으로 구현하여 속도를 높입니다.

5 Implementation: Keras Embedding

```
1 import tensorflow as tf
2 from tensorflow.keras.layers import Embedding
3
4 # 설정
5 vocab_size = 10000 # 단어 사전 크기 (V)
6 embedding_dim = 300 # 임베딩 차원 (D)
7 input_length = 10 # 입력 문장 길이 (T)
8
9 # 모델 정의
10 model = tf.keras.Sequential()
11
12 # Embedding Layer
13 # 이 층은 (10000, 300) 크기의 행렬 E 가집니다.
14 # 학습 초반에는 랜덤 값이지만, 역전파를 통해 의미를 ' ' 학습해갑니다.
15 model.add(Embedding(input_dim=vocab_size,
16                     output_dim=embedding_dim,
17                     input_length=input_length))
18
19 # 모델 요약
20 model.summary()
21
22 # --- 입력 데이터 예시 ---
23 # "I love you" -> [1, 539, 23, 0, 0...] 정수(인덱스로 변환)
24 # 입력 shape: (Batch, 10)
25 # 출력 shape: (Batch, 10, 300) -> 각 단어가 차원 300 벡터로 변환
```

Listing 1: Embedding Layer Usage

6 FAQ & Pitfalls

Q. 임베딩 값은 어떻게 학습하나요?

A. 두 가지 방법이 있습니다. 1. **End-to-End:** 내 문제(예: 감성 분석)를 풀면서 임베딩 층도 같이 학습시킵니다. 데이터가 많아야 합니다. 2. **Pre-trained: Word2Vec**이나 **GloVe**처럼 위키피디아 같은 방대한 텍스트로 미리 학습된 임베딩 행렬을 가져와서 씁니다. (전이 학습, 추천!)

Q. 임베딩 차원(300 등)은 어떻게 정하나요?

A. 하이퍼파라미터입니다. 보통 50, 100, 300 등을 많이 씁니다. 차원이 클수록 더 정교한 의미를 담을 수 있지만, 메모리와 계산량이 늘어납니다.

다음 단계 (Next Step)

이제 우리는 단어를 벡터로 바꾸는 '개념'을 알았습니다. 그렇다면 이 벡터 값(숫자들)은 도대체 어떻게 구하는 걸까요? 사람이 일일이 입력할 수는 없습니다.

컴퓨터가 방대한 텍스트를 읽으면서 "단어의 의미는 그 주변 단어들에 의해 결정된다"는 원리를 이용해 스스로 학습하게 해야 합니다. 다음 시간에는 임베딩 학습 알고리즘의 양대 산맥, [Word2Vec (Skip-gram, CBOW)]과 [GloVe]에 대해 알아보겠습니다.

□ 단원 요약 (Cheat Sheet)

1. **One-hot:** 단어 간 유사성을 표현하지 못하는 희소 벡터.
2. **Embedding:** 단어 간 유사성을 내적(거리)으로 계산할 수 있는 밀집 벡터.
3. **Analogy:** 벡터 연산으로 단어 관계(성별, 시제 등)를 추론 가능함.
4. **Layer:** 임베딩 층은 거대한 룩업 테이블(Lookup Table)이다.