

[CS230] Sequence Models: Debiasing Word Embeddings

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-9. Deep Learning Fundamentals & CNNs - *Completed*

Chapter 10. Sequence Models (Current Part)

- 10.1-10.6 RNN, LSTM, Word2Vec, GloVe - *Completed*
- **10.7 Debiasing Word Embeddings**
 - * The Problem: "Man is to Computer Programmer..."
 - * Geometry of Bias: Identifying the Bias Axis
 - * Neutralize Algorithm (Projection)
 - * Equalize Algorithm (Equidistance)

Chapter 11. Attention Mechanism - *Next Part*

지난 시간 복습 및 연결

지난 시간에 배운 Word2Vec은 놀라웠습니다. 하지만 2016년, 연구자들은 충격적인 사실을 발견했습니다. "남자에게 프로그래머가 있다면, 여자에게는 누가 있는가?" 모델의 대답은 "가정주부(Homemaker)"였습니다. 이는 모델의 잘못이 아닙니다. 모델은 인간이 쓴 텍스트의 편향(Gender Bias)을 그대로 학습했을 뿐입니다. 오늘은 AI 윤리의 핵심, **임베딩 편향 제거**를 배웁니다.

1 Unit Overview

□ 핵심 목표

이 단원은 학습된 임베딩 벡터에서 사회적 편향을 수학적으로 제거하는 알고리즘을 다룹니다.

- **식별:** 편향 방향(Gender Axis)을 벡터 공간에서 찾아냅니다.
- **중화(Neutralize):** 의사, 간호사 등 중립 단어에서 편향 성분을 제거합니다 (투영).
- **균형화(Equalize):** 할머니, 할아버지 등 성별 단어가 중립 단어와 같은 거리를 갖도록 조정합니다.

2 Essential Terminology

용어	의미	예시
Bias Axis	성별을 나타내는 벡터 방향.	$\vec{he} - \vec{she}$ 의 평균.
Neutral Words	성별과 무관해야 하는 단어.	Doctor, Nurse, Teacher.
Gender Specific	성별이 정의상 필요한 단어.	Grandfather, Queen, Girl.

3 Core Concepts: 편향의 기하학

3.1 1. Identifying Bias (편향 식별)

임베딩 공간에서 성별 편향은 다음과 같이 나타납니다.

$Man : Woman :: King : Queen$ (적절함)

$Man : Woman :: Doctor : Nurse$ (부적절함 - 고정관념)

3.2 2. The Debiasing Algorithm (3단계)

3.2.1 Step 1: Identify Bias Direction (축 찾기)

성별을 나타내는 단어 쌍들의 차이를 평균 내어 성별 축(Gender Axis) g 를 정의합니다.

$$g \approx \text{Average}(\vec{he} - \vec{she}, \vec{male} - \vec{female}, \dots)$$

3.2.2 Step 2: Neutralize (중화)

"Doctor" 같은 중립 단어는 성별 축 성분을 가져서는 안 됩니다. **Action:** 단어 벡터 w 를 성별 축 g 에 투영(Project)하여 편향 성분을 뺍니다.

□ 중화 공식 (Projection) (핵심 수식)

$$w_{\text{debiased}} = w - \frac{w \cdot g}{\|g\|^2} g$$

벡터 w 에서 성별 축 방향의 그림자(성분)를 제거하여, 성별 축과 수직이 되게 만듭니다.

3.2.3 Step 3: Equalize (균형화)

"Grandmother"와 "Grandfather"는 성별 정보를 가져야 하므로 중화하면 안 됩니다. 하지만 "Babysitter"와의 거리는 공평해야 합니다. **Action:** 두 단어가 중립 축에서 등거리(Equidistant)에 위치하도록 미세 조정합니다.

4 Implementation: Neutralize Function

벡터 투영을 통해 편향을 제거하는 함수입니다.

```
1 import numpy as np
2
3 def neutralize(curr_embedding, g):
4     """
5     curr_embedding: 중화할 단어 벡터 예(: doctor)
6     g: 편향 방향 벡터 (bias axis)
```

```

7      """
8      # 1. 편향 성분 계산 (Projection)
9      # (w · g / ||g||^2) * g
10     norm_sq = np.linalg.norm(g) ** 2
11     projection = (np.dot(curr_embedding, g) / norm_sq) * g
12
13     # 2. 원본에서 편향 제거
14     debiased_embedding = curr_embedding - projection
15
16     return debiased_embedding
17
18 # --- 검증 ---
19 if __name__ == "__main__":
20     g = np.array([1.0, 0.0]) # 축이 x 성별 축이라고 가정
21     doctor = np.array([2.0, 4.0]) # 성별 성분(2.0)이 포함됨
22
23     # 중화
24     doctor_debiased = neutralize(doctor, g)
25
26     print(f"Original: {doctor}")
27     print(f"Debiased: {doctor_debiased}")
28     # 예상: [0.0, 4.0] 성별(성분이 0) 됨

```

Listing 1: Neutralize Implementation

5 FAQ & Pitfalls

모든 단어를 중화하면 안 됩니다! (오해 방지 가이드)

"King", "Queen", "Actor", "Actress" 같은 단어는 성별 정보가 그 단어의 핵심 의미입니다. 이런 단어들을 중화해버리면 "King"과 "Queen"이 똑같은 단어가 되어버립니다. 따라서 성별 정의 단어(Gender Definition Words)를 분류하는 작업이 선행되어야 합니다.

Q. 이 방법으로 모든 편향이 사라지나요?

A. 완벽하진 않습니다. 'Hard Debiasing'은 벡터의 방향만 수정하지만, 단어들이 뭉쳐 있는 클러스터링 구조 등 간접적인 편향은 남을 수 있습니다. 하지만 매우 효과적인 첫걸음입니다.

다음 단계 (Next Step)

이제 우리는 단어를 윤리적으로 올바른 벡터로 표현하는 법까지 배웠습니다. 준비는 끝났습니다.

이제 단어들을 조합해 문장을 통째로 번역하거나 요약하는 거대한 모델을 만들어 봅시다. 다음 시간에는 입력 시퀀스를 압축했다가 다시 풀어내는 [Seq2Seq Model]과, 긴 문장 처리에 필수적인 [Beam Search] 알고리즘에 대해 다루겠습니다.

□ 단원 요약 (Cheat Sheet)

1. **Bias:** 학습 데이터의 사회적 편향이 임베딩 벡터에 반영된다.
2. **Neutralize:** 중립 단어(직업 등)를 성별 축에 수직이 되도록 투영한다.
3. **Equalize:** 성별 단어(할머니/할아버지)가 중립 단어와 등거리에 있게 한다.
4. **Ethics:** AI 모델 배포 전 편향 제거는 필수적인 전처리 과정이다.