

[CS230] Sequence Models: BLEU Score (Evaluation Metric)

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-9. Deep Learning Fundamentals & CNNs - *Completed*

Chapter 10. Sequence Models (Current Part)

- 10.1-10.9 RNN, Seq2Seq, Beam Search - *Completed*
- **10.10 BLEU Score**
 - * The Multiple Reference Problem
 - * Modified Precision (Clipping)
 - * N-grams (Unigram, Bigram, Trigram)
 - * Brevity Penalty (Length Normalization)

Chapter 11. Attention Mechanism - *Next Part*

지난 시간 복습 및 연결

지난 시간에 빔 서치로 최적의 문장을 생성하는 법을 배웠습니다. 그런데 근본적인 질문이 남습니다. "번역이 잘 됐는지 컴퓨터가 어떻게 채점할까?" 이미지 분류는 정답이 하나(고양이)지만, 번역은 정답이 여러 개입니다. ("나는 학교에 간다", "학교에 가는 중이다" 등) 사람이 일일이 채점하기엔 너무 비쌉니다. 이를 해결하기 위해 IBM이 제안한 자동화된 점수, **BLEU Score**를 배웁니다.

1 Unit Overview

□ 핵심 목표

이 단원은 기계 번역 평가의 표준인 BLEU Score의 원리를 다룹니다.

- **다중 정답:** 여러 개의 참고 문장(Reference)을 기준으로 평가합니다.
- **정밀도:** 단순 일치가 아닌 클리핑된 정밀도(Clipped Precision)를 사용해 "the the the" 문제를 해결합니다.
- **N-gram:** 단어 묶음을 비교하여 문맥과 어순의 정확성을 평가합니다.
- **페널티:** 너무 짧은 문장에 페널티(BP)를 주어 꼼수를 방지합니다.

2 Essential Terminology

용어	의미	역할
Reference	정답 문장(들).	채점 기준. (사람이 번역한 것)
Candidate	모델이 생성한 문장.	채점 대상.
Modified Precision	빈도수 제한 정밀도.	중복 단어 남발 방지.
Brevity Penalty	길이 불이익.	정보 누락(짧은 문장) 방지.

3 Core Concepts: 정밀도의 함정

3.1 1. The Problem with Standard Precision

Candidate: "the the the the the" (5단어) **Reference:** "The cat is on the mat."

- 단순 정밀도: 5개 모두 정답에 있음("the"). $\rightarrow 5/5 = 100$ 점? (말도 안 됨)
- 해결책 (Clipping): 정답 문장에 "the"가 최대 몇 번 나오는지 셉니다. (2번). 분자를 2로 제한합니다. $\rightarrow 2/5 = 40$ 점.

3.2 2. N-gram Analysis (어순 평가)

단어만 다 있다고 문장이 아닙니다. "The cat the mat on is" (단어는 맞지만 엉터리) 이를 잡기 위해 N-gram(단어 묶음)을 봅니다.

- Unigram (1-gram): 단어 존재 여부 (내용 충실도).
- Bigram (2-gram): "The cat", "cat is" ... (어순/유창성).

3.3 3. Brevity Penalty (BP)

정밀도 기반 평가는 "짧게 말하면 유리하다"는 약점이 있습니다. **Cand:** "The cat" (2단어 다 맞음. 정밀도 100하지만 정보가 누락되었습니다. 예측 문장이 정답보다 짧으면 점수를 깎습니다.

4 Deep Dive: The Formula

□ BLEU Formula (핵심 수식)

$$\text{BLEU} = BP \times \exp \left(\frac{1}{4} \sum_{n=1}^4 p_n \right)$$

- p_n : n-gram의 보정된 정밀도.
- BP : Brevity Penalty (길이 페널티).
- $\exp(\dots)$: 기하 평균(Geometric Mean)을 구하는 방식.

5 Implementation: NLTK Library

파이썬 NLTK 라이브러리로 쉽게 계산할 수 있습니다.

```

1 from nltk.translate.bleu_score import sentence_bleu
2
3 # 1. 데이터 준비
4 # 는Reference 여러 개일 수 있음 리스트의( 리스트)
5 references = [
6     ['the', 'cat', 'is', 'on', 'the', 'mat'],          # Ref 1
7     ['there', 'is', 'a', 'cat', 'on', 'the', 'mat'] # Ref 2
8 ]
9
10 # 는Candidate 하나의 리스트
11 candidate = ['the', 'cat', 'is', 'on', 'the', 'mat']
12
13 # 2. BLEU 계산
14 # weights: 1-gram ~ 4-gram 가중치 보통( 균등하게 0.25)
15 score = sentence_bleu(references, candidate, weights=(0.25, 0.25, 0.25, 0.25))
16
17 print(f"BLEU Score: {score:.4f}")

```

Listing 1: BLEU Score Calculation

6 FAQ & Pitfalls

Q. BLEU 점수가 높으면 완벽한 번역인가요?

A. 아니요. BLEU는 단어 일치도만 봅니다. 의미는 통하는데 단어가 다른 의역(Paraphrasing)이나, 미묘한 뉘앙스 차이는 잡아내지 못합니다. 하지만 "최소한 이 정도는 한다"는 지표로는 가장 훌륭합니다.

Q. 만약 4-gram이 하나도 안 맞으면요?

A. $p_4 = 0$ 이 되면 기하 평균 특성상 전체 점수가 0이 되어버립니다. 이를 막기 위해 아주 작은 값(ϵ)을 더해주는 **Smoothing** 기법을 씁니다.

다음 단계 (Next Step)

우리는 빔 서치로 문장을 만들고, BLEU로 평가까지 했습니다. 하지만 Seq2Seq에는 여전히 "긴 문장의 병목 현상"이라는 거대한 벽이 남아 있습니다. 인코더가 100단어를 벡터 하나에 압축하는 것은 무리입니다.

"번역할 때 문장 전체를 외우지 않고, 필요한 단어만 그때그때 다시 보면서(Attend) 번역할 수는 없을까?" 다음 시간, 딥러닝 역사상 가장 위대한 발명 중 하나인 [Attention Mechanism]을 통해 이 벽을 부수겠습니다. 이것이 바로 Transformer와 GPT로 가는 마지막 열쇠입니다.

□ 단원 요약 (Cheat Sheet)

1. **Modified Precision:** 정답에 등장하는 횟수만큼만 인정하여 중복 곱수를 막는다.
2. **N-gram:** 1 4단어 묶음을 비교하여 문맥과 유창성을 평가한다.
3. **BP:** 문장이 짧으면 점수를 깎아 정보 누락을 방지한다.
4. **Standard:** 기계 번역 성능 평가의 업계 표준이다.