

[CS230] Sequence Models: Transformers & Self-Attention

Lecturer: Gemini (Integrated Editor)

□ Course Table of Contents

Chapter 1-9. Deep Learning Fundamentals & CNNs - *Completed*

Chapter 10. Sequence Models (Current Part)

- 10.1-10.11 RNN, LSTM, Attention Mechanism - *Completed*
- **10.12 Transformers & Modern Attention**
 - * Self-Attention: Understanding Relationships
 - * The Q, K, V Framework (Query, Key, Value)
 - * Multi-Head Attention: Parallel Perspectives
 - * Beyond Transformers: LLM and ViT

지난 시간 복습 및 연결

지난 시간에 배운 '어텐션'이 RNN이라는 엔진의 성능을 높여주는 보조 장치였다면, 오늘 배울 트랜스포머(Transformer)는 그 엔진 자체를 통째로 갈아치운 혁명입니다. 구글의 2017년 논문 "**Attention Is All You Need**"는 순차적 처리(RNN)를 버리고 오직 어텐션만으로 문장을 이해할 수 있음을 증명했습니다. 이것이 바로 ChatGPT와 모든 거대 언어 모델(LLM)의 탄생 지점입니다.

1 Unit Overview

□ 핵심 목표

이 단원은 현대 AI 시스템의 중추인 트랜스포머 아키텍처의 핵심 원리를 다룹니다.

- **Self-Attention:** 문장 내 단어들이 서로 어떤 관계를 맺고 있는지 스스로 학습하는 원리를 배웁니다.
- **Q, K, V:** 정보 검색의 관점에서 어텐션을 계산하는 세 가지 구성 요소(Query, Key, Value)를 파악합니다.
- **Multi-Head:** 여러 개의 어텐션을 병렬로 수행하여 다각적인 문맥을 추출하는 이유를 학습합니다.
- **병렬성:** RNN과 달리 문장 전체를 동시에 처리함으로써 얻는 계산 효율성을 이해합니다.

2 Essential Terminology: The QKV Framework

용어	의미	역할
Query (Q)	질문	"지금 내가 찾고 싶은 정보는 무엇인가?"
Key (K)	인덱스/색인	"내가 가진 정보의 키워드는 무엇인가?"
Value (V)	내용	"키워드에 해당하는 실제 값은 무엇인가?"
Scaled Dot-Product	유사도 계산	Q와 K를 곱해 점수를 내고 루트 차원으로 나눔.

3 Core Concepts: 자기 자신을 돌아보기

3.1 1. Self-Attention: 대명사 해결

RNN은 단어를 순서대로 읽었지만, 트랜스포머는 문장 안의 모든 단어 쌍 사이의 관계를 한 번에 계산합니다.

□ "it"은 누구인가? (직관적 비유)

"The animal didn't cross the street because it was too tired."

Self-Attention은 "it"이라는 단어를 처리할 때 문장의 모든 단어를 훑습니다. 모델은 "animal"과의 어텐션 점수를 가장 높게 주어, "it = animal"임을 스스로 깨닫게 됩니다.

3.2 2. Multi-Head Attention

하나의 어텐션만으로는 복잡한 문맥을 다 담기 어렵습니다. 트랜스포머는 여러 개의 '헤드'를 병렬로 운영합니다.

- **Head 1:** 주어와 동사의 관계에 집중
- **Head 2:** 형용사와 명사의 관계에 집중
- **Head 3:** 대명사와 선행사의 관계에 집중

이 다양한 관점들을 나중에 하나로 합쳐(Concatenate) 풍부한 이해력을 갖게 됩니다.

4 Deep Dive: The Attention Math

트랜스포머의 심장인 Scaled Dot-Product Attention의 수식입니다.

□ Scaled Dot-Product Attention (핵심 메커니즘)

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- QK^T : Query와 Key 사이의 유사도 점수.
- $\sqrt{d_k}$: 차원이 커질 때 점수가 너무 커져 Softmax 기울기가 소실되는 것을 방지하는 Scaling 계수.
- V : 최종적으로 가중치를 곱해 정보를 취합할 실제 값.

5 Implementation: Conceptual Logic

TensorFlow를 이용한 어텐션의 핵심 로직입니다.

```
1 import tensorflow as tf
2
3 def scaled_dot_product_attention(q, k, v, mask=None):
4     # 1. 유사도 Score 계산
5     matmul_qk = tf.matmul(q, k, transpose_b=True)
6
7     # 2. Scaling 루트( 차원만큼 나누기)
8     dk = tf.cast(tf.shape(k)[-1], tf.float32)
9     scaled_logits = matmul_qk / tf.math.sqrt(dk)
10
11     # 3. Softmax 통해 가중치 결정
12     attention_weights = tf.nn.softmax(scaled_logits, axis=-1)
13
14     # 4. Value 가중 합하여 최종 출력
15     output = tf.matmul(attention_weights, v)
16
17     return output, attention_weights
```

Listing 1: Scaled Dot-Product Attention

6 Modern Trends: Beyond Transformers

트랜스포머 이후 AI의 패러다임은 크게 확장되었습니다.

- **LLM (거대 언어 모델):** GPT, Llama 등 트랜스포머 블록을 수백 개 쌓아 인간 수준의 추론을 수행합니다.
- **ViT (Vision Transformer):** 이미지도 패치로 나누어 어텐션을 적용합니다. 이제 컴퓨터 비전에서도 트랜스포머가 대세입니다.
- **Efficiency:** 문장이 길어질 때 계산량이 N^2 으로 폭발하는 문제를 해결하기 위한 FlashAttention 등이 활발히 연구됩니다.

□ Course Conclusion

□ 최종 요약

1. **Self-Attention:** 단어 간의 유기적 관계를 한 번에 파악하는 혁신적 방식.
2. **No More RNN:** 병렬 처리가 가능해져 모델의 거대화가 가능해짐.
3. **Versatility:** 텍스트를 넘어 이미지, 오디오 등 모든 도메인으로 확장 중.

축하합니다! Seq2Seq에서 시작해 어텐션을 거쳐, 세상을 바꾸고 있는 트랜스포머의 원리까지 모두 마스터하셨습니다. 여러분은 이제 현대 딥러닝의 정점에서 있습니다.