

BADM572: Data-Driven Decision Making

통합 강의 노트

Contents

1 용어 정리	15
1.1 용어 정리	15
1.2 1. 서문 (Preface)	15
1.3 2. 모듈 1: 비즈니스 의사결정을 위한 데이터 탐색 및 생성 (Module 1 Exploring and Producing Data for Business Decision Making)	17
1.3.1 2.1. 모듈 소개 (Welcome to Exploring and Producing Data for Business Decision Making!)	17
1.3.2 2.2. 레슨 1-1: 비즈니스 통계학 개론 (Lesson 1-1 Introduction to Business Statistics)	19
1.3.3 2.3. 레슨 1-2: 기술 통계학: 빈도표 (Lesson 1-2 Descriptive Statistics: Frequency Tables)	22
1.4 용어 정리	33
1.5 핵심 개념 및 원리	33
1.5.1 1. 빈도표 (Frequency Tables)	33
1.5.2 2. 막대 그래프 (Bar Graphs)	34
1.5.3 3. 히스토그램 (Histograms)	34
1.5.4 4. 파이 차트 (Pie Charts)	35
1.6 절차/방법: Excel을 활용한 데이터 요약 및 시각화	36
1.6.1 1. Excel에서 질적 데이터 빈도표 생성하기 (Lesson 1-2.3)	36
1.6.2 2. Excel에서 빈도표를 막대 그래프로 표현하기 (Lesson 1-2.4)	39
1.6.3 3. Excel에서 히스토그램 생성하기 (Lesson 1-3.2)	40
1.6.4 4. Excel에서 파이 차트 생성하기 (Lesson 1-4.2)	42
1.7 체크리스트	45
1.8 FAQ (자주 묻는 질문)	45
1.9 빠르게 훑어보기 (1페이지 요약)	47
1.10 용어 정리	48
1.11 핵심 개념 및 원리	48
1.11.1 파이 차트 (Pie Charts)	48

1.11.2 산점도 (Scatter Plots)	49
1.12 절차/방법: 엑셀을 이용한 데이터 시각화	51
1.12.1 파이 차트 생성 및 서식 지정 (Excel)	51
1.12.2 산점도 생성 및 서식 지정 (Excel)	53
1.13 체크리스트: 데이터 시각화 학습 및 활용	55
1.13.1 학습 점검	55
1.13.2 엑셀 실습 점검	56
1.13.3 데이터 분석 및 커뮤니케이션 점검	56
1.14 FAQ: 초심자를 위한 질문과 답변	56
1.15 빠르게 훑어보기: 1페이지 요약	57
2 용어 정리	59
2.1 용어 정리	59
2.2 Module 2: 비즈니스 의사결정을 위한 데이터 탐색 및 생성	60
2.2.1 Lesson 2-1: 중심 경향성 측정	60
2.2.2 Lesson 2-2: 산포도 측정	69
2.3 개요: 데이터 탐색 및 생산 모듈 2 (파트 2/5)	81
2.4 용어 정리	81
2.5 핵심 개념 및 원리	81
2.5.1 백분위수 (Percentiles)	81
2.5.2 Z-점수 (Z-score)	84
2.5.3 경험적 규칙 (Empirical Rule)	85
2.6 절차/방법: Z-점수 및 백분위수 Excel 계산	87
2.6.1 Z-점수 예시: 연봉 제안 (Excel 활용)	87
2.7 이산 및 연속 확률 변수 (Discrete and Continuous Random Variables)	89
2.7.1 확률 변수 (Random Variables)	89
2.7.2 확률 변수의 종류	89
2.7.3 확률 분포 (Probability Distributions)	90
2.7.4 누적 분포 함수 (Cumulative Distribution Function, CDF)	91
2.7.5 기댓값 (Expected Value) 및 표준편차 (Standard Deviation)	92
2.7.6 확률 분포의 목적	95
2.8 빠르게 훑어보기 (핵심 요약)	95
2.9 FAQ: 초심자를 위한 질문과 답변	96
2.10 개요	96

2.11 용어 정리	97
2.12 핵심 개념 및 원리	97
2.12.1 이산 확률 변수의 기댓값과 표준 편차	97
2.12.2 연속 확률 분포와 정규 분포	97
2.13 절차 및 방법: Excel을 활용한 통계 계산	100
2.13.1 이산 확률 변수의 기댓값 및 표준 편차 계산 (Excel)	100
2.13.2 정규 분포 확률 계산 (Excel)	103
2.14 실습: 표준 편차 근사치 추정	104
2.15 정규 분포의 모델로서의 활용	105
2.16 개요	106
2.17 용어 정리	106
2.18 핵심 개념 및 원리	106
2.18.1 표준화 (Z-점수)	106
2.18.2 누적 확률 (Cumulative Probability)	107
2.19 Lesson 2-5.3: Excel을 이용한 표준 정규 분포	107
2.19.1 문제 정의 및 Z-점수 계산	107
2.19.2 Excel의 NORM.S.DIST 함수 사용	108
2.19.3 NORM.S.DIST와 NORM.DIST의 비교	108
2.20 Lesson 2-5.4: Excel에서 '미만' 확률 계산	109
2.20.1 문제 정의	109
2.20.2 Excel의 NORM.DIST 함수 사용	109
2.21 Lesson 2-5.5: Excel에서 '초과' 확률 계산	110
2.21.1 문제 정의	110
2.21.2 계산 원리: 전체 확률에서 '미만' 확률 빼기	110
2.22 Lesson 2-5.6: Excel에서 '두 값 사이' 확률 계산	111
2.22.1 문제 정의	111
2.22.2 계산 원리: 상한 누적 확률에서 하한 누적 확률 빼기	111
2.23 Lesson 2-5.7: Excel에서 주어진 확률에 대한 Z-값 찾기 (INV 함수)	112
2.23.1 문제 정의	112
2.23.2 Excel의 NORM.INV 함수 사용	112
2.23.3 Excel의 NORM.S.INV 함수 사용	113
2.23.4 두 INV 함수의 비교	113
2.24 Lesson 2-6: 표준 정규 분포표	114

2.25	빠르게 훑어보기 (1페이지 요약)	114
2.26	FAQ	115
2.26.1	표준정규분포의 이해	115
2.26.2	Z-점수 계산 및 의미	116
2.26.3	Z-테이블의 구성	117
2.26.4	표준정규분포표 (Z-Table)	118
2.26.5	1. 특정 값보다 작을 확률 ($P(X \leq x)$)	119
2.26.6	2. 특정 값보다 클 확률 ($P(X \geq x)$)	119
2.26.7	3. 음수 Z-점수 처리	120
2.26.8	4. 두 값 사이의 확률 ($P(x_1 \leq X \leq x_2)$)	121
2.26.9	1. 백분위수(확률)로 Z-값 찾기	122
2.26.10	2. Z-값으로 원본 데이터 값 (X) 찾기	122
3	Lecture 3	127
3.1	개요	127
	개요	127
3.2	용어 정리	127
	용어 정리	127
3.3	Preface	128
	Preface	128
3.4	Module 3: Exploring and Producing Data for Business Decision Making	129
	Module 3: Exploring and Producing Data for Business Decision Making	129
3.4.1	Lesson 3-1: Producing Data	129
	Lesson 3-1: Producing Data	129
3.4.2	Lesson 3-2: Sampling	133
	Lesson 3-2: Sampling	133
3.5	개요	141
3.6	용어 정리	141
3.7	핵심 개념 및 원리	141
3.7.1	3-3.1 중심 극한 정리와 표본 평균 (Central Limit Theorem and Sampling Means)	141
3.7.2	3-3.2 중심 극한 정리 시각화 (Animating the Central Limit Theorem)	145
3.7.3	3-3.3 표본 분포와 경험적 규칙 (Sampling Distribution and Empirical Rule in Excel)	146
3.7.4	3-4.1 중심 극한 정리와 표본 비율 (Central Limit Theorem – Sampling Proportion)	149
3.8	빠르게 훑어보기 (1페이지 요약)	151

3.9	FAQ	151
4	신뢰 수준이 신뢰 구간에 미치는 영향 (Excel 활용)	153
4.1	신뢰 수준이 신뢰 구간에 미치는 영향 (Excel 활용)	153
4.1.1	신뢰 수준에 따른 임계값 변화	153
	신뢰 수준에 따른 임계값 변화	153
4.1.2	신뢰 수준에 따른 오차 한계 변화	154
	신뢰 수준에 따른 오차 한계 변화	154
4.1.3	신뢰 수준에 따른 신뢰 구간 변화	155
	신뢰 수준에 따른 신뢰 구간 변화	155
4.1.4	신뢰 수준에 따른 신뢰 구간 변화	156
	신뢰 수준에 따른 신뢰 구간 변화	156
4.2	신뢰 구간: 모집단 비율	157
	신뢰 구간: 모집단 비율	157
4.2.1	모집단 비율에 대한 추론의 필요성	157
	모집단 비율에 대한 추론의 필요성	157
4.2.2	모집단 비율에 대한 신뢰 구간 공식	158
	모집단 비율에 대한 신뢰 구간 공식	158
4.2.3	예시: 지역 고용 시장 조건 (Gallup 설문)	158
	예시: 지역 고용 시장 조건 (Gallup 설문)	158
4.2.4	95% "신뢰"의 진정한 의미	159
	95% "신뢰"의 진정한 의미	159
4.2.5	승수(Multiplier)와 신뢰 수준	160
	승수(Multiplier)와 신뢰 수준	160
4.2.6	연습: 99% 신뢰 구간 계산	161
	연습: 99% 신뢰 구간 계산	161
4.2.7	신뢰 수준과 신뢰 구간 폭의 관계	162
	신뢰 수준과 신뢰 구간 폭의 관계	162
4.2.8	표본 크기의 영향	163
	표본 크기의 영향	163
4.3	빠르게 훑어보기: 핵심 요약	163
	빠르게 훑어보기: 핵심 요약	163
4.4	FAQ: 자주 묻는 질문	164
	FAQ: 자주 묻는 질문	164

4.5 개요	165
개요	165
4.6 용어 정리	165
용어 정리	165
4.7 모집단 비율에 대한 신뢰 구간 (Excel 활용)	165
모집단 비율에 대한 신뢰 구간 (Excel 활용)	165
4.7.1 데이터 준비 및 초기 분석	165
데이터 준비 및 초기 분석	165
4.7.2 표본 데이터 분석 및 신뢰 구간 계산	166
표본 데이터 분석 및 신뢰 구간 계산	166
4.8 신뢰 구간 애니메이션을 통한 이해	167
신뢰 구간 애니메이션을 통한 이해	167
4.8.1 신뢰 구간의 개념 시각화	168
신뢰 구간의 개념 시각화	168
4.8.2 표본 크기의 영향	168
표본 크기의 영향	168
4.8.3 신뢰 수준의 영향	169
신뢰 수준의 영향	169
4.8.4 정확도와 정밀도 향상	170
정확도와 정밀도 향상 전략	170
4.9 시작 급여 예시 (Excel 활용)	170
시작 급여 예시 (Excel 활용)	170
4.9.1 문제 정의 및 평균 급여 신뢰 구간 계산	170
문제 정의 및 평균 급여 신뢰 구간 계산	170
4.9.2 특정 급여 이상을 받는 졸업생 비율 신뢰 구간 계산	171
특정 급여 이상을 받는 졸업생 비율 신뢰 구간 계산	171
4.10 핵심 요약 및 학습 가이드	172
핵심 요약 및 학습 가이드	172
4.11 개요	173
개요	173
4.12 용어 정리	173
용어 정리	173
4.13 핵심 개념 및 원리	173

4.13.1 신뢰 구간과 오차 한계의 이해	173
4.13.2 오차 한계의 구성 요소	174
4.13.3 표본 크기 결정의 필요성	174
4.13.4 평균 추정을 위한 표본 크기 결정	175
4.13.5 비율 추정을 위한 표본 크기 결정	175
4.13.6 오차 한계를 결정하는 요인	176
4.14 절차 및 방법: 표본 크기 계산 예시	176
4.14.1 평균 추정을 위한 표본 크기 계산 예시	176
4.14.2 비율 추정을 위한 표본 크기 계산 예시	178
4.15 실습: Excel을 활용한 표본 크기 결정	180
4.15.1 비율 추정 시 표본 크기 결정 (Excel)	180
4.15.2 평균 추정 시 표본 크기 결정 (Excel)	181
4.15.3 표본 크기가 신뢰 구간에 미치는 영향 (Excel)	182
4.16 체크리스트	184
4.17 FAQ	184
4.18 빠르게 훑어보기 (1페이지 요약)	185
5 Lecture 5	187
5.1 모듈 1: 비즈니스를 위한 추론 및 예측 통계	188
5.1.1 강의 소개	188
5.1.2 Lesson 1-1: 가설 설정	190
5.1.3 Lesson 1-2: 결과 분석	194
5.1.4 Lesson 1-3: 평균에 대한 양측 검정	197
5.1.5 Lesson 1-4: 평균에 대한 단측 검정	200
6 용어 정리	219
6.1 용어 정리	219
용어 정리	219
6.2 1. 서문 (Preface)	220
1. 서문 (Preface)	220
6.3 2. 모듈 2: 비즈니스를 위한 추론 및 예측 통계	220
2. 모듈 2: 비즈니스를 위한 추론 및 예측 통계	220
6.3.1 2.1. 레슨 2-1: 평균 차이 없음 검정 (Testing for No Difference in Means)	221
2.1. 레슨 2-1: 평균 차이 없음 검정	221

6.3.2	2.2. 레슨 2-2: 평균에 대한 단측 검정 (One-Tail Test of the Means)	235
	2.2. 레슨 2-2: 평균에 대한 단측 검정	235
6.4	개요	241
6.5	용어 정리	241
6.6	Lesson 2-2.2: Excel을 이용한 평균의 단측 검정	241
6.6.1	개념: 단측 검정의 필요성	241
6.6.2	가설 설정	241
6.6.3	Excel을 이용한 분석 절차	242
6.6.4	결과 해석	242
6.6.5	신뢰 구간 계산	243
6.7	Lesson 2-3.1: 평균의 특정 값 검정	243
6.7.1	개념: 특정 값과의 차이 검정	243
6.7.2	가설 설정 (단계 1)	244
6.7.3	유의 수준 설정 (단계 2)	244
6.7.4	데이터 수집 (단계 3 준비)	244
6.7.5	P-값 계산 (단계 3)	244
6.7.6	Excel 결과 및 해석	245
6.7.7	결정 (단계 4)	245
6.8	Lesson 2-4.1: 짝지은 표본 검정	246
6.8.1	개념: 짝지은 표본 실험의 이해	246
6.8.2	짝지은 표본 검정의 가설	246
6.8.3	제품 디자인 평가: 가설 설정	247
6.8.4	Excel 결과 및 해석	247
6.8.5	어떤 제품이 더 우수한가?	247
6.8.6	얼마나 더 우수한가? (신뢰 구간 계산)	248
6.8.7	연습 문제: 교육 프로그램 효과 검정	249
6.8.8	연습 문제: Excel 결과 및 결론	249
6.9	Lesson 2-4.2: Excel을 이용한 짝지은 표본 검정	250
6.9.1	Excel을 이용한 짝지은 표본 검정 절차	250
6.9.2	가설 설정	250
6.9.3	Excel 분석 단계	250
6.9.4	Excel 결과 해석	251
6.9.5	신뢰 구간 계산 (평균 차이)	252

6.10 Lesson 2-5.1: 비율 검정	253
6.10.1 개념: 두 모집단 비율 비교	253
6.10.2 비율 검정의 가설	253
6.10.3 예시 1: 남학생과 여학생의 수학 성적 비교	254
6.10.4 P-값 계산 (Z-검정)	254
6.10.5 Excel 출력 및 결론 (예시 1)	254
6.10.6 예시 2: 패스트푸드 워크플로우 재설계	255
6.10.7 Excel 출력 및 결론 (예시 2)	255
6.10.8 95% 신뢰 구간 계산 (비율 차이)	256
6.10.9 표본 크기의 중요성	256
6.10.10 연습 문제: UI 입학 허가 수락률 감소 주장 검정	256
6.10.11 연습 문제: Excel 출력 및 결론	257
6.11 개요: 두 표본 비율 검정	258
6.12 용어 정리	259
6.13 Lesson 2-5.2: 두 표본 비율에 대한 단측 검정 (엑셀 활용)	259
6.13.1 핵심 개념 및 원리	259
6.13.2 패스트푸드 체인점 워크플로우 개선 예시	260
6.13.3 엑셀을 이용한 검정 절차	260
6.13.4 신뢰구간 계산 및 활용	261
6.13.5 최종 결론	263
6.14 Lesson 2-5.3: 두 표본 비율에 대한 양측 검정 (엑셀 활용)	263
6.14.1 핵심 개념 및 원리	263
6.14.2 남학생과 여학생의 수학 시험 성적 예시	263
6.14.3 엑셀을 이용한 검정 절차	264
6.14.4 최종 결론	265
6.15 빠르게 훑어보기: 두 표본 비율 검정 요약	265
7 Lecture 7	267
7.1 개요	267
7.2 용어 정리	267
7.3 Module 3: 비즈니스를 위한 추론 및 예측 통계	268
7.3.1 Lesson 3-1: 서론	268
7.3.2 Lesson 3-2: 최소 제공법	273
7.3.3 Lesson 3-3: 회귀 모델 평가	280

7.4	모델 활용 (Using the Model)	287
7.4.1	예시: 양의 상관관계 (Positive Correlation)	287
7.4.2	예시: 음의 상관관계 (Negative Correlation)	289
7.4.3	연습 문제: GPA와 시작 급여	291
7.5	단순 선형 회귀: Excel 출력 분석 (Simple Linear Regression: Excel Output Analysis)	292
7.5.1	Excel을 이용한 회귀 분석 절차: 가동 중단 시간 예시	293
7.6	모델 가정 및 한계 (Model Assumptions and Limitations)	295
7.6.1	모델 가정 (Model Assumptions)	295
7.6.2	모델의 한계 (Limitations)	298
7.6.3	요약 및 주의 사항	298
7.7	Excel을 이용한 잔차 분석 (Residual Analysis in Excel)	299
7.7.1	Excel에서 잔차 플롯 생성 및 해석: GPA-시작 급여 예시	299
7.8	체크리스트: 회귀 모델 가정 검토	301
7.9	FAQ: 초심자를 위한 질문과 답변	303
7.10	빠르게 훑어보기: 핵심 요약	303
8	Lecture 8	305
8.1	개요	305
	개요	305
8.2	용어 정리	306
	용어 정리	306
8.3	모듈 4: 추론 및 예측 통계	307
8.3.1	Lesson 4-1: 모델 소개	307
8.3.2	예시 1: 제약 회사 영업 사원 성과 평가	309
8.4	FAQ: 초심자를 위한 질문과 답변	322
	FAQ: 초심자를 위한 질문과 답변	322
8.5	빠르게 훑어보기 (1페이지 요약)	322
	빠르게 훑어보기 (1페이지 요약)	322
8.6	핵심 개념 및 원리: 질적 데이터와 더미 변수	323
8.6.1	1. 질적 데이터의 회귀 모델 포함 필요성	323
8.6.2	2. 범주형 변수의 직접 입력 불가 및 더미 변수 도입	324
8.6.3	3. 두 가지 범주를 가진 질적 데이터 처리	324
8.7	절차/방법: Excel에서 더미 변수 사용하기 (두 가지 범주)	329
8.7.1	1. 데이터 준비: 원본 데이터 확인	329

8.7.2	2. 데이터 코딩: 더미 변수 생성	329
8.7.3	3. Excel에서 회귀 분석 실행	330
8.7.4	4. 회귀 분석 결과 해석	331
8.8	핵심 개념 및 원리: 여러 범주를 가진 질적 데이터 처리	332
8.8.1	1. 여러 범주를 가진 질적 데이터의 필요성	332
8.8.2	2. 여러 범주에 대한 더미 변수 생성	333
8.8.3	3. 회귀 분석 결과 해석 (Excel 출력)	334
8.8.4	4. 예측 및 추가 분석 연습	336
8.9	빠르게 훑어보기 (1페이지 요약)	337
	빠르게 훑어보기 (1페이지 요약)	337
8.10	핵심 개념 및 원리: 여러 범주를 가진 질적 데이터 처리	338
8.10.1	1. 다중 범주 질적 데이터와 더미 변수	338
8.10.2	2. N-1 규칙: 왜 하나를 제외하는가?	338
8.10.3	3. 회귀 모델의 해석: R-제곱, p-값, 계수	339
8.11	절차 및 방법: 엑셀을 이용한 다중 범주 더미 변수 회귀 분석	340
8.11.1	1. 데이터 준비: 더미 변수 생성	340
8.11.2	2. 엑셀에서 회귀 분석 실행	340
8.12	실습 및 결과 해석	341
8.12.1	1. 회귀 통계량 해석	341
8.12.2	2. ANOVA 테이블 해석	342
8.12.3	3. 계수 테이블 해석	342
8.12.4	4. 회귀 모델을 이용한 예측	343
8.13	체크리스트	344
8.14	FAQ (자주 묻는 질문)	345
8.15	빠르게 훑어보기 (1페이지 요약)	346

Chapter 1

용어 정리

강의명: BADM-572: Data-Driven Decision Making

주차: Module 1 (Part 1/3)

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 이 문서는 'Exploring and Producing Data Module 1'의 핵심 내용을 담고 있습니다. 데이터 기반 의사결정을 위한 통계학의 기본 개념부터 실제 데이터 요약 기법까지 다룹니다. 특히, 데이터의 종류를 이해하고, 빈도표를 활용하여 데이터를 효과적으로 시각화하고 해석하는 방법을 학습합니다. Excel을 이용한 실습 과정을 포함하여, 비전공자도 통계적 사고와 데이터 활용 능력을 키울 수 있도록 구성되었습니다.

1.1 용어 정리

용어	쉬운 설명	원어	비고
데이터	결론을 도출할 수 있는 사실과 수치	Data	소득, 나이, 교육 수준 등
변수	요소의 특정 특성	Variable	성별, 나이, 직업 등
데이터 세트	특정 연구를 위해 수집된 데이터 모음	Data Set	연구 대상에 대한 정보 제공
양적 변수	수량적 의미를 가지는 숫자 값	Quantitative Variable	연봉, 나이, 온도 (단위가 있음)
질적 변수 (범주형)	범주를 나타내는 데이터	Qualitative (Categorical) Variable	성별, 민족, 만족도 수준 (단위 없음)
명목 변수	순서나 순위가 없는 질적 변수	Nominative Variable	성별, 거주 주, 머리색, 우편번호
순서 변수	의미 있는 순서나 순위가 있는 질적 변수	Ordinal Variable	만족도 수준 (매우 불만족 < 불만족), 학위
모집단	결론을 도출하고자 하는 모든 요소의 집합	Population	일리노이 주 모든 사람의 고용 상태
표본	모집단의 부분 집합	Sample	선거 예측을 위한 유권자 일부
모수	모집단 데이터에서 계산된 요약 측정값	Population Parameter	모집단 평균
통계량	표본 데이터에서 계산된 요약 측정값	Sample Statistic	표본 평균 (모수를 추정하는 데 사용)
빈도표	데이터를 범주별로 정리하여 빈도를 보여주는 표	Frequency Table	특정 항목의 발생 횟수
상대 빈도	전체 관측치 중 특정 값의 비율	Relative Frequency	(관측 횟수) ÷ (총 관측 횟수)

1.2 1. 서문 (Preface)

Gies eBook을 선택해 주셔서 감사합니다. 이 Gies eBook은 Coursera에서 제공되는 Fataneh Taghaboni-Dutta 교수의 'Exploring and Producing Data for Business Decision Making' 모듈 1의 확장된 비디오 강의 스크립트를 기반으로 합니다. 이 eBook은 MOOC 비디오의 모든 정보를 완전히 접근 가능한 형식의

로 제공하여 독서 경험을 향상시킵니다. ePUB 3.0 형식을 지원하는 모든 표준 기반 e-리딩 소프트웨어와 함께 사용할 수 있습니다.

핵심 요약

Gies eBook의 특징:

- Coursera 강의 스크립트 기반: 비디오 강의 내용을 텍스트로 제공합니다.
- 완전한 정보 제공: MOOC 비디오의 모든 정보를 담고 있습니다.
- 접근성: 모든 표준 기반 e-리딩 소프트웨어(ePUB 3.0)에서 사용 가능합니다.

각 Gies eBook은 레슨별로 나뉘어 있으며, e-리더의 목차 기능을 사용하여 탐색할 수 있습니다. 각 레슨 내에서는 다음 순서의 콘텐츠가 항상 나타납니다:

- 레슨 제목 (Lesson title)
- 웹 기반 비디오 링크 (A link to the web-based videos for each lesson): 비디오를 시청하려면 온라인 상태여야 합니다.

레슨 내에서 슬라이드가 변경되거나 다음 정보 비디오 장면으로 전환될 때마다 다음 내용이 제공됩니다:

- 현재 슬라이드 또는 비디오 장면의 썸네일 이미지 (Thumbnail image)
- 슬라이드에 있는 텍스트 (Any text present on the slide): 검색 가능하고 스크린 리더가 읽을 수 있는 형식으로 썸네일 아래에 재현됩니다.
- 중요한 시각 자료에 대한 확장된 텍스트 설명 (Extended text description of the important visuals): 그래프 및 차트와 같은 시각 자료에 대한 상세 설명입니다.
- 비디오의 표 형식 데이터 (Any tabular data from the video): 스크린 리더 탐색 및 읽기를 위해 재현되고 적절하게 레이블이 지정됩니다.
- 모든 수학 방정식 (All math equations): 화면에 표시될 경우 내용과 표현을 모두 제공하는 MathML로 제공됩니다.
- 강의록 (Transcript): 말하는 사람별로 레이블이 지정된 비디오의 모든 원본 음성을 캡처합니다.

모든 Gies eBook은 접근성과 사용성을 최우선으로 설계되었습니다. 이 디자인은 독자들이 어떤 디지털 독서 도구를 선택하든 유연하게 모든 독자에게 서비스를 제공하기 위함입니다.

이 Gies eBook에 대한 질문이나 개선 제안이 있으시면 Giesbooks@illinois.edu로 문의하십시오.

저작권 (Copyright) Copyright © 2019 by Fataneh Taghaboni-Dutta. All rights reserved. Published by the Gies College of Business at the University of Illinois at Urbana-Champaign, and the Board of Trustees of the University of Illinois.

1.3 2. 모듈 1: 비즈니스 의사결정을 위한 데이터 탐색 및 생성 (Module 1 Exploring and Producing Data for Business Decision Making)

1.3.1 2.1. 모듈 소개 (Welcome to Exploring and Producing Data for Business Decision Making!)

2.1.1. 강의 소개 (Course Introduction)

예제

왜 통계학을 공부해야 할까요? (Why Study Statistics?)

- 데이터는 우리 주변에 있습니다: GDP, 인플레이션을, 실업률과 같은 경제 지표부터 스포츠 선수의 성과, 복권 당첨 확률까지, 우리는 매일 수많은 숫자를 접합니다.
- 더 나은 의사결정을 위해: 이 숫자들은 우리에게 정보를 제공하여 더 나은 의사결정을 돕기 위함입니다. 하지만 우리는 이 숫자들을 어떻게 활용해야 할까요?

데이터 분석의 중요성

데이터 분석은 모든 분야에서 중요합니다.

- 농업 비즈니스 (Agro business)
- 헬스케어 (Health care)
- 금융 기관 (Financial institutions)
- 숙박 산업 (Hospitality industries)
- 소매업 (Retail)
- 제조업 (Manufacturing)
- 교육 (Education)
- 기타 등등 (Etc., etc.)

통계학은 의학, 농업, 날씨, 경제, 스포츠, 사회 행동 등 모든 것을 설명하는 데 사용될 수 있습니다. 통계학은 결과에 영향을 미치는 요인을 식별하고, 이러한 요인이 결과에 어떻게 영향을 미치는지 학습하여 결과를 형성하는 데 도움을 줍니다.

핵심 요약

통계학의 가치:

- 데이터 이해: 통계학은 데이터를 이해하는 데 도움을 줍니다.
- 핵심 역량: 고용주들이 신입 사원에게 가장 중요하게 여기는 기술 중 하나입니다.
- 미래 직업: LinkedIn에서 '가장 인기 있는 기술' 1위로 선정되었으며, Google의 수석 경제학자 Hal Varian은 "향후 10년 동안 가장 섹시한 직업은 통계학자"라고 언급했습니다. 모든 조직은 데이터 과학자를 찾고 있습니다.

그렇다면 통계학이란 무엇일까요? (So What is Statistics?)

올바른 통계학 (Done the Right Way): 통계학은 데이터에 수학적 방법을 사용하는 것을 포함합니다. 하지만 이는 실제로 유용한 데이터를 얻는 방법과 최종적으로 결과를 해석하는 방법을 아는 것을 의미하기도 합니다.

무엇이 잘못될 수 있을까요? (What can go wrong?)

- 우리가 가진 데이터가 좋지 않다 (Data that we have is not good)
- 사용된 방법이 부적절하다 (Method used is inappropriate)
- 해석이 부정확하다 (The interpretation is incorrect)

통계학은 의도적으로 비윤리적이거나, 의도치 않게 무지한 사람에 의해 쉽게 오용될 수 있는 분야입니다. 데이터가 올바른 방식으로 수집되고, 분석이 올바른 방식으로 수행되며, 최종적으로 결과가 올바른 방식으로 제시될 때, 통계학은 우리 주변의 세상을 이해하고 더 나은 의사결정을 통해 이점을 얻을 수 있는 훌륭한 도구가 될 수 있습니다. 반대로, 잘못된 데이터로 시작하거나, 잘못된 방법론을 사용하거나, 결과를 잘못 해석하면 실제로 해를 끼칠 수 있습니다.

핵심 요약

무엇을 배우게 될까요? (What Will You Learn? - Macro Objectives) 이 과정은 여러분을 데이터 과학자나 통계학자로 만들지는 않습니다. 하지만 통계학의 기본을 이해하고, 데이터를 활용하여 더 나은 비즈니스 의사결정을 내릴 수 있는 능력을 키우는 데 초점을 맞춥니다.

- 통계적 소양 (Statistically literate)을 갖추게 됩니다.
- 데이터를 요약하는 방법 (how to summarize data)을 배웁니다.
- 요약된 데이터에서 통찰력을 얻는 방법 (how to gain insight from the summaries)을 배웁니다.
- 표본 추출 (sampling)과 표본 통계량 (sample statistics)의 중요성을 이해합니다.
- 표본 통계량을 사용하여 모집단 (population)에 대한 추론 (inferences)을 하는 방법을 배웁니다.

어떻게 배우게 될까요? (How Will You Learn?)

다양한 활동을 통해 주제를 더 잘 이해하게 될 것입니다.

- **비디오 강의 (Video lectures):** 이론적 개념을 가르치고, 다양한 문제와 설정에 적용하는 방법을 제공합니다.
- **Excel 시연 (Excel illustrations):** 대규모 데이터 세트에 방법론을 적용하고 결과를 해석하는 방법을 보여줍니다. 단순히 결과를 생성하는 것이 아니라, 결과가 실제로 무엇을 의미하는지 이해하여 더 나은 의사결정을 내리는 것이 목표입니다.
- **채점 퀴즈 (Graded quizzes):** 자료를 숙달했는지 확인합니다. 통계 개념은 서로 연결되어 있으므로, 다음 주제로 넘어가기 전에 각 주제를 잘 이해하는 것이 중요합니다. 자가 평가는 다음 단계로 넘어갈 준비가 되었는지, 아니면 개념을 더 자세히 검토해야 하는지 알려줄 것입니다.
- **동료 평가 과제 (Peer reviewed assignments):** 덜 양적인 질문이나 시나리오에 대해 설명하거나 비평하도록 요청받습니다. 응답을 게시하고 다른 학생들의 응답을 읽고 품질에 대한 의견을 게시해야 합니다. 이 활동은 데이터 분석 기반 보고서에 반응하는 기술을 연마하고, 의사결정자에게 필요한 많은 기술을 통합하는 데 도움이 됩니다.

이 과정은 쉬운 주제가 아니지만, 배우는 도구를 적용하는 데 집중할 것입니다. 때로는 지루하게 분류될 수 있는 개념들도 결과를 이해하는 데 필요한 만큼만 다룰 것입니다. 이 과정을 통해 통계학의 아름다움과 힘을 발견하게 될 것입니다.

1.3.2 2.2. 레슨 1-1: 비즈니스 통계학 개론 (Lesson 1-1 Introduction to Business Statistics)

2.2.1. 레슨 1-1.1: 기본 용어 (Lesson 1-1.1 Basic Terminology)

비즈니스 통계학 (Business Statistics)

불확실성에 직면한 "좋은" 의사결정을 위한 과학

우리는 종종 좋은 의사결정을 내리기 위해 많은 정보 조각들을 맞춰야 합니다. 이는 마치 퍼즐을 푸는 것과 같습니다. 통계학은 이 퍼즐을 푸는 데 도움을 줄 수 있습니다.

통계적 의사결정 과정의 퍼즐 비유

이 과정을 위해 우리는 세 가지 주요 단계를 거칩니다:

1. **데이터 설명 (Describing Data):** 우리가 알고 싶은 것을 명확하고 간결하며 구체적으로 요약하려고 노력합니다.
2. **데이터 생성 (Producing Data):** 더 구체적인 질문을 공식화하고, 질문에 정확히 맞춰진 정보를 수집하기 시작합니다.
3. **데이터로부터 결론 도출 (Conclusion from Data):** 수집한 데이터와 정보로부터 결론을 도출하고, 그 결론이 얼마나 확실한지 결정합니다.

핵심 요약

중요 용어 (Important Terminology) 통계학을 배우는 것은 외국어를 배우는 것과 같습니다. 먼저 어휘를 배워야 합니다.

- **데이터 (Data):** 결론을 도출할 수 있는 사실과 수치입니다.

- 예시: 여러분의 소득, 나이, 교육 수준 등은 모두 데이터의 예시입니다.
- **변수 (Variable):** 요소의 어떤 특성입니다.
 - 예시: 이 강의에 누가 관심이 있는지 알고 싶다면, 성별, 나이, 직업, 교육 수준, 지리적 위치 등이 변수가 될 수 있습니다.
- **데이터 세트 (Data set):** 특정 연구를 위해 수집된 데이터입니다.
 - 설명: 각 연구 요소에 대해 관심 있는 변수에 대한 데이터 항목을 수집한 결과입니다. 데이터 세트는 연구 대상(사람, 사건, 객체 등)에 대한 정보를 제공합니다.

변수의 종류 (Types of Variables)

변수에는 크게 두 가지 종류가 있습니다: 양적 변수와 질적 변수입니다.

1. 양적 변수 (Quantitative Variables)

- **한 줄 핵심 요약:** 수량(quantity)을 나타내는 숫자 값입니다.
- **직관적 예시/비유:** 키, 몸무게, 연봉, 나이, 온도 등 측정 가능한 숫자들입니다.
- **기술적 정확한 설명:** 항상 숫자 값을 가지며, 어떤 종류의 수량을 나타냅니다. 고정되거나 표준화된 측정 단위를 가집니다. 예를 들어, 소득은 달러 단위, 온도는 섭씨 또는 화씨 단위로 측정됩니다.

2. 질적 변수 (Qualitative (Categorical) Variables)

- **한 줄 핵심 요약:** 범주(category)를 나타내는 데이터입니다.
- **직관적 예시/비유:** 성별(남/여), 머리색(검정/갈색), 만족도(매우 만족/만족/보통) 등 분류 가능한 항목들입니다.
- **기술적 정확한 설명:** 범주형 데이터라고도 합니다.
 - 비수치형 또는 수치형일 수 있습니다:
 - * **비수치형 (Non-numeric):** 예를 들어, 사람의 성별은 단순히 '남성' 또는 '여성'으로 기록될 수 있습니다.
 - * **수치형 (Numeric):** 예를 들어, 서비스 만족도를 1부터 5까지의 척도로 평가하도록 요청할 수 있습니다 (1은 '매우 불만족', 5는 '매우 만족'). 이 경우 숫자는 수량이 아니라 만족도 수준이라는 범주를 나타냅니다. 중요한 점은 이 숫자들은 측정 단위가 없다는 것입니다.
 - **명목 변수 (Nominative) 또는 순서 변수 (Ordinal)일 수 있습니다:**
 - * **명목 변수 (Nominative):** 범주들 사이에 의미 있는 순서나 순위가 없는 질적 변수입니다.
 - 예시: 사람의 성별, 거주 주, 머리색, 우편번호 등.
 - * **순서 변수 (Ordinal):** 범주들 사이에 의미 있는 순서나 순위가 있는 질적 변수입니다. 데이터가 수치적으로 기록되었든 비수치적으로 기록되었든 상관없습니다.
 - 예시: 고객 만족도 수준을 '탁월', ' 좋음', '보통', '나쁨', '불만족'으로 평가하는 경우. 여기서 한 범주는 다음 범주보다 높으므로 순서 변수입니다. 만약 이들을 숫자 4, 3, 2, 1, 0으로 대체하더라도 여전히 순서 변수입니다.

예제

연습해 봅시다: 변수의 종류 분류하기 (Let's Practice) 다음 변수들이 양적 변수인지 질적 변수인지, 그리고 질적 변수라면 명목 변수인지 순서 변수인지 판단해 보세요.

- 우편번호 (Postal zip code)

- 형제자매 수 (Number of siblings)
- 최종 학위 (Highest degree earned)
- 연봉 (Annual salary)
- 머리색 (Hair color)

정답 (Follow Up):

- 머리색 (Hair color): 범주형 (Categorical), 명목 (Nominative). 자연적인 순서가 존재하지 않습니다.
- 형제자매 수 (Number of siblings): 양적 (Quantitative). 숫자로 세어지는 수량입니다.
- 최종 학위 (Highest degree earned): 범주형 (Categorical), 순서 (Ordinal). 고등학교 학위, 학사, 석사 등 의미 있는 순서가 있습니다.
- 연봉 (Annual salary): 양적 (Quantitative). 숫자로 측정되는 수량입니다.
- 우편번호 (Postal zip code): 범주형 (Categorical), 명목 (Nominative). 숫자이지만 값을 나타내지 않으며 (예: UIUC의 61820 우편번호는 수량이 아님), 자연적인 순서가 없습니다.

데이터 세트의 구성 요소 (What Is In The Data Set?)

모집단 (Population)과 표본 (Sample)

모집단과 표본의 개념

- 모집단 (Population): 우리가 결론을 도출하고자 하는 모든 요소의 집합입니다.
 - 예시: 일리노이 주에 거주하는 모든 사람의 고용 상태를 알고 싶다면, 일리노이 주에 거주하는 모든 사람을 조사해야 합니다. 미국 정부는 10년마다 인구 조사를 실시하여 당시 미국에 거주하는 모든 사람에 대한 데이터를 수집합니다.
 - 주의: 모집단에 대한 연구는 대부분 너무 비싸고 시간이 많이 소요됩니다.
- 표본 (Sample): 모집단 단위의 부분 집합입니다.
 - 설명: 모집단 전체를 조사하는 대신, 모집단의 일부를 선택하여 데이터를 수집합니다.
 - 예시: 선거 결과를 예측하는 정치 여론 조사는 유권자 표본으로부터 데이터를 수집하여 수행됩니다.

핵심 요약

모수 (Parameters)와 통계량 (Statistics)

- 모집단 모수 (A population parameter): 모집단 데이터(예: 인구 조사)를 사용하여 계산된, 데이터 세트의 어떤 측면을 설명하는 요약 측정값입니다.
 - 예시: 모집단 평균은 모집단 내 모든 값의 평균입니다.
- 표본 통계량 (A sample statistic): 표본 정보로부터 계산된 값입니다.
 - 설명: 우리는 표본 통계량을 사용하여 모집단에 대한 값을 추정합니다.

우리는 방금 매우 기본적인 그러나 중요한 용어들을 배웠습니다. 이 용어들은 이 과정 내내, 그리고 더 중요하게는 통계학이 사용되는 모든 분야에서 사용될 것입니다. 따라서 이 용어들이 정확히 무엇을 의미하는지 아는 것이 중요합니다. 과정이 진행되고 이 주제에 대한 지식이 증가함에 따라 다른 용어들도 배우게 될 것입니다.

1.3.3 2.3. 레슨 1-2: 기술 통계학: 빈도표 (Lesson 1-2 Descriptive Statistics: Frequency Tables)

2.3.1. 레슨 1-2.1: 데이터 요약: 빈도표 (Lesson 1-2.1 Summarizing Data: Frequency Tables)

데이터 요약 (Summarizing Data)

우리는 더 나은 의사결정을 내리기 위해 데이터를 수집합니다. 예를 들어, 마케팅 프로모션이 판매에 미치는 영향을 파악하거나, 인력의 생산성에 대한 데이터를 수집할 수 있습니다. 그러나 단순히 쌓여 있는 데이터를 보는 것만으로는 그다지 유용하지 않습니다. 우리는 데이터를 이해해야 하며, 데이터를 더 잘 이해하는 가장 좋은 방법 중 하나는 시각적인 수단을 통해 데이터를 정리하고 요약하는 것입니다.

이 모듈에서는 양적 변수와 범주형 변수 모두에 대한 시각적 요약 기법에 초점을 맞출 것입니다. 구체적으로는 빈도표 (Frequency tables), 히스토그램 (Histograms), 원형 차트 (Pie charts), 그리고 산점도 (Scatter plots)를 다룹니다.

예제

미국에서 가장 많이 팔린 픽업트럭 (Best-Selling Pickup Trucks In The US)

미국에서 가장 많이 팔린 픽업트럭 (2015년 8월 기준)

순위 % 변화 2	베스트셀러 트럭	2015년 8월	2014년 8월	% 변화 1	2015년 YTD	2014년 YTD
#1 -0.5%	Ford F-Series	71,332	68,109	4.7%	494,800	497,174
#2 16.6%	Chevrolet Silverado	54,977	49,201	11.7%	387,179	331,977
#3 3.8%	Ram P/U	45,310	43,775	3.5%	294,045	283,256
#4 8.7%	GMC Sierra	21,241	19,847	7.0%	141,799	130,526
#5 18.8%	Toyota Tacoma	16,230	14,338	13.2%	122,064	102,736
#6 1.8%	Toyota Tundra	10,057	11,834	-15.0%	81,582	80,133
#7 -	Chevrolet Colorado	7,114	55,898	73.0%	-	-
#8 -12.1%	Nissan Frontier	3,645	6,770	-46.2%	42,644	48,510
#9 -	GMC Canyon	2,423	20,094	5.0%	-	-
#10 -3.2%	Nissan Titan	1,268	1,231	3.0%	8,443	8,719
#11 -95.2%	Honda Ridgeline	4	1,347	-99.7%	513	10,593
#12 -90.8%	Chevrolet Avalanche	0	5	-100.0%	8	87
#13 -96.0%	Cadillac Escalade EXT	0	1	-100.0%	2	50
총계 10.4%		233,601	216,458	7.9%	1,649,071	1,493,839

이러한 표는 미디어 또는 비즈니스 회의에서 자주 볼 수 있습니다. 이 표는 2015년 8월까지 미국에서 가장 많이 팔린 픽업트럭 상위 13개를 한눈에 보여줍니다. 이 유형의 표를 **빈도표 (frequency table)**라고 하며, **범주형 데이터 (categorical data)**를 요약하는 데 매우 유용합니다 (이 경우 트럭 모델 이름).

이 표를 보면, 2015년 첫 8개월 동안 미국에서 233,601대의 트럭이 판매되었다는 것을 알 수 있습니다. 만약 실제 233,601개의 기록을 본다면, 어떤 트럭이 1위 판매자이고 어떤 트럭이 2위 판매자인지 즉시 알기 어려울 것입니다. 이와 같은 표로 데이터를 요약하면 어떤 모델이 얼마나 팔렸는지, 그리고 모델들이 서로 어떻게 비교되는지 정확히 알 수 있습니다.

트럭 판매량 빈도 막대 그래프

이 정보는 막대 그래프로도 나타낼 수 있습니다. 각 막대의 높이는 각 특정 트럭의 판매 대수를 나타내며, 원시 데이터를 빠르게 개괄적으로 보여주는 또 다른 방법입니다. 이는 데이터에 대해 더 효과적으로 소통하는 데 도움이 됩니다.

각 모델의 판매 대수 대신, 각 범주를 **상대 빈도 (relative frequency)**로 요약할 수도 있습니다. 예를 들어, Ford F-Series가 가장 많이 팔린 트럭이라는 것은 알지만, 이 트럭의 시장 점유율은 얼마 일까요? 이러한 유형의 질문은 상대 빈도를 찾아 답할 수 있습니다.

상대 빈도 분포 (Relative Frequency Distribution)

상대 빈도 (Relative Frequency)는 특정 값이 관측된 횟수를 총 관측 횟수로 나눈 값입니다.

$$\text{상대 빈도} = \frac{\text{값이 관측된 횟수}}{\text{총 관측 횟수}}$$

예제

Ford F-Series의 상대 빈도 계산: Ford F-Series는 71,332대 판매되었고, 총 판매 대수는 233,601대입니다.

$$\text{Ford F-Series 상대 빈도} = \frac{71,332}{233,601} \approx 0.3054$$

따라서 Ford F-Series가 가장 많이 팔린 트럭일 뿐만 아니라, 시장의 약 30.5%를 차지한다는 것을 알 수 있습니다. 데이터를 요약하는 것만으로도 데이터에 대한 통찰력을 얻기 시작합니다.

미국에서 가장 많이 팔린 픽업트럭 (상대 빈도 포함)

순위	트럭 모델	2015년 8월	상대 빈도
#1	Ford F-Series	71,332	30.54%
#2	Chevrolet Silverado	54,977	23.53%
#3	Ram P/U	45,310	19.40%
#4	GMC Sierra	21,241	9.09%
#5	Toyota Tacoma	16,230	6.95%
#6	Toyota Tundra	10,057	4.31%
#7	Chevrolet Colorado	7,114	3.05%
#8	Nissan Frontier	3,645	1.56%
#9	GMC Canyon	2,423	1.04%
#10	Nissan Titan	1,268	0.54%
#11	Honda Ridgeline	4	0.00%
#12	Chevrolet Avalanche	0	0.00%
#13	Cadillac Escalade EXT	0	0.00%
총계		233,601	100%

모든 모델에 대한 상대 빈도를 생성할 수 있으며, 이제 상위 3개 베스트셀러가 전체 시장의 약 73%를 차지한다는 것을 알 수 있습니다.

양적 데이터에 대한 빈도표 (Frequency Table for Quantitative Data)

고객 대기 시간에 대해 무엇을 알 수 있을까요? (What do we know about customers' waiting times?)

콜센터를 상상해 보세요. 고객 경험의 중요한 부분은 상담원에게 빠르게 연결되는 것입니다. 고객이 무엇을 경험하고 있는지 이해하려면 대기 시간에 대한 정보를 수집할 수 있습니다. 각 고객은 다른 고객과 약간 다른 경험을 할 수 있습니다.

고객 대기 시간(초)				
51	95	68	243	167
288	108	83	48	251

이 표는 10명의 고객에 대한 대기 시간을 초 단위로 보여줍니다. 하지만 500개의 관측치가 있다고 가정해 봅시다. 500개의 항목을 보는 것만으로는 무슨 일이 일어나고 있는지 빠르게 이해할 수 없습니다. 따라서 데이터를 요약하여 더 잘 이해하기 위해 빈도표를 사용할 수 있습니다.

여기에 있는 것과 유사한 양적 데이터에 대한 빈도표를 만들려면, **범위 (ranges)**를 만들고 각 범위에 해당하는 고객 수를 세어야 합니다. 예를 들어, 고객을 0 0.5분(30초 이하) 범위에 배치할 수 있습니다. 그런 다음 31초에서 60초 사이에 대기한 고객을 두 번째 구간(bin)에 배치하는 식으로 계속할 수 있습니다.

양적 데이터에 대한 빈도표 (500개 관측치)

범위 (Range)	빈도 (Frequency)	상대 빈도 (Relative Frequency)
30	30	0.06
60	49	0.10
90	40	0.08
120	40	0.08
150	37	0.07
180	45	0.09
210	66	0.13
240	62	0.12
270	71	0.14
300	60	0.12

여기서 500개 관측치의 요약을 볼 수 있습니다. 빈도 열의 값은 다양한 대기 시간을 경험한 고객 수를 나타냅니다. 예를 들어, 66명의 고객은 상담원과 통화하기 전에 181초에서 210초 사이를 기다렸습니다. 상대 빈도 열은 다양한 대기 시간을 경험한 고객의 비율을 보여줍니다. 이 경우, 고객의 13%가 181초에서 210초 사이(3분에서 3.5분 사이)를 기다렸습니다. 많은 보고서에서 데이터를 요약하는 다양한 방법을 사용하므로, 숫자가 어떻게 요약되었는지 면밀히 살펴봐야 합니다.

예제

예시: 연령별 치명적인 충돌 사고 운전자 (Drivers Involved in Fatal Crashes by Age, 2011)

2011년 연령별 치명적인 충돌 사고 운전자

연령대	총 운전자		주의 산만 운전자			휴대폰 사용 운전자		
	#	총 %	#	총 운전자 %	주의 산만 운전자 %	#	총 %	휴대폰 운전자 %
15-19	3,212	7	344	11	11	72	21	20
20-29	10,160	23	790	8	26	117	15	32
30-39	7,401	17	505	7	16	79	16	21
40-49	7,376	17	464	6	15	49	11	13
50-59	6,783	16	434	6	14	34	8	9
60-69	4,144	9	251	6	8	12	5	3
+70	3,815	9	270	9	9	5	2	1
총계	43,658	100	3,085	7	100	368	12	100

Source: NCSA, FARS 2011 (ARF); Note: Total includes 60 drivers aged 14 and under, 4 of whom were noted as distracted.

이 표는 미국 교통부 보고서에서 가져온 것입니다. 이 표를 사용하여 몇 가지 질문에 답해 봅시다.

질문 1: 어떤 연령대가 주의 산만으로 인한 치명적인 충돌 사고 수준이 가장 높았습니까?

- **답변:** 15-19세 연령대입니다. 이 연령대의 운전자 3,212명 중 344명이 주의 산만으로 인해 치명적인 충돌 사고를 냈습니다. (표의 '주의 산만 운전자' 열에서 15-19세의 344명, '총 운전자 %'에서 11%를 확인)

질문 2: 어떤 연령대가 휴대폰 사용으로 인한 치명적인 충돌 사고 수준이 가장 높았습니까?

- **답변:** 다시 15-19세 연령대입니다. (표의 '휴대폰 사용 운전자' 열에서 15-19세의 72명, '총 %'에서 21%를 확인)
- **추가 분석:** 15-19세 연령대의 주의 산만 운전자 344명 중 72명이 휴대폰을 사용했기 때문에 주의가 산만해졌습니다. 이는 이 연령대에서 주의 산만 운전으로 인한 치명적인 충돌 사고의 21%가 휴대폰 사용 때문에 발생했다는 의미입니다.

연습해 봅시다 (Let's Practice): 20-29세 운전자 중 치명적인 충돌 사고를 냈을 때 휴대폰을 사용하고 있던 비율은 몇 퍼센트입니까?

정답 (Follow Up):

- **답변:** 15%입니다. 20-29세 연령대의 주의 산만 운전자 790명 중 117명이 휴대폰을 사용했습니다. ($117 \div 790 \approx 0.1481$, 즉 약 15%)

빈도표를 사용하면 많은 양의 데이터를 이해하기 쉽고 소통에 매우 유용한 요약으로 만들 수 있습니다. 또한, 무슨 일이 일어나고 있는지에 대한 이해를 높이는 질문을 하는 데 도움이 됩니다 (예: 치명적인 충돌 사고 수를 줄이는 방법).

이 강의에서는 데이터를 요약하는 두 가지 그래픽 방법을 배웠습니다. 데이터를 요약하는 것은 무슨 일이 일어나고 있는지 빠르게 이해하고, 더 정교한 통계적 방법으로 데이터를 탐색하기 시작할 수 있게 해줍니다.

2.3.2. 레슨 1-2.2: Excel에서 빈도표 만들기: 양적 데이터 (Lesson 1-2.2 Frequency Tables in Excel: Quantitative Data)

Excel에서 고객 대기 시간 빈도표 만들기

여기 고객들이 전화로 상담원과 통화하기까지 기다린 시간을 초 단위로 기록한 데이터 파일이 있습니다. 이 파일에는 500개의 관측치가 있습니다. 만약 제가 관리자이고 고객이 상담원과 통화하기까지 일반적으로 얼마나 기다리는지 알고 싶다면, 원시 데이터만 봐서는 알 수 없을 것입니다. 따라서 데이터를 요약하기 위해 빈도표를 사용할 것입니다. 하지만 양적 데이터를 다루고 있기 때문에 각 숫자를 개별적으로 나타낼 수는 없습니다.

고객 대기 시간 Excel 원시 데이터

최소값, 최대값, 개수 찾기 (Finding Min, Max, Count)

범위를 만들기 위해서는 데이터의 최소 관측치, 최대 관측치, 그리고 총 관측치 수를 아는 것이 매우 유용합니다.

최소, 최대, 개수 계산을 위한 Excel 설정

1. 최소값 (Minimum) 찾기:

- MIN 함수를 사용합니다. 이 함수는 주어진 범위에서 가장 작은 숫자를 반환합니다.
- 단계:
 1. 최소값을 표시할 셀을 선택합니다.
 2. =MIN(을 입력합니다.
 3. 데이터 범위(예: A2 셀부터 시작)를 선택합니다. Ctrl + Shift + 아래쪽 화살표를 눌러 전체 데이터를 한 번에 선택할 수 있습니다.
 4.)를 입력하고 Enter를 누릅니다.
- 결과: 최소값은 0입니다. 이는 적어도 한 명의 고객이 기다리지 않고 즉시 상담원과 통화할 수 있었다는 의미입니다.

```
1 =MIN(A2:A501)
```

Listing 1.1: Excel MIN 함수 사용 예시

2. 최대값 (Maximum) 찾기:

- MAX 함수를 사용합니다. MIN 함수와 동일한 방식으로 작동합니다.
- 단계:
 1. 최대값을 표시할 셀을 선택합니다.
 2. =MAX(을 입력합니다.
 3. 데이터 범위(예: A2:A501)를 선택합니다.
 4.)를 입력하고 Enter를 누릅니다.
- 결과: 최대 대기 시간은 300초입니다. 즉, 5분입니다. 적어도 한 명의 고객이 5분까지 기다렸습니다.

```
1 =MAX(A2:A501)
```

Listing 1.2: Excel MAX 함수 사용 예시

3. 개수 (Count) 찾기:

- COUNT 함수를 사용합니다.
- 단계:
 1. 개수를 표시할 셀을 선택합니다.
 2. =COUNT(을 입력합니다.
 3. 데이터 범위(예: A2:A501)를 선택합니다.
 4.)를 입력하고 Enter를 누릅니다.
- 결과: 총 500개의 관측치가 있습니다.

```
1 =COUNT(A2:A501)
```

Listing 1.3: Excel COUNT 함수 사용 예시

구간 (Bin) 생성

이제 데이터를 30초 간격으로 정리할 구간(bin)을 만들 것입니다.

- **단계:**

1. 'Bin'이라는 새 열을 만듭니다.
2. 첫 번째 셀에 30을 입력합니다. 이 구간에는 0초부터 30초까지 기다린 모든 고객이 포함됩니다.
3. 다음 셀에 60을 입력합니다. 이 구간에는 30초를 약간 넘는 시간부터 60초까지 기다린 고객이 포함됩니다.
4. 90을 입력하는 식으로 300까지 30 간격으로 숫자를 채웁니다. 첫 두 개의 숫자를 입력한 후, 두 셀을 선택하고 오른쪽 아래 모서리를 드래그하여 자동으로 채울 수 있습니다.

Excel에서 구간(Bin) 생성

빈도 계산 (Calculating Frequency)

빈도를 찾기 위해 Excel의 배열 함수인 FREQUENCY를 사용할 것입니다. 배열 함수는 단일 숫자가 아닌 배열(여러 값)을 반환하므로, 모든 값을 기록할 공간이 필요합니다.

• 단계:

1. 빈도 값을 받을 셀 범위를 선택합니다. 구간(bin) 옆 옆에 있는 셀들을 선택하고, 혹시 모를 추가 관측치를 위해 마지막 구간 아래에 한 셀을 더 포함하는 것이 좋습니다.
2. 선택된 범위의 첫 번째 셀에 =FREQUENCY(를 입력합니다.
3. 데이터 배열 (data_array): 원본 데이터가 있는 범위(예: A2:A501)를 선택합니다.
4. 쉼표(,)를 입력합니다.
5. 구간 배열 (bins_array): 방금 만든 구간(bin) 범위(예: B2:B11)를 선택합니다.
6.)를 입력합니다.
7. 매우 중요: Ctrl + Shift + Enter를 동시에 눌러 배열 함수를 완료합니다. 이렇게 해야 모든 빈도 값이 올바르게 채워집니다.

1 {=FREQUENCY(A2:A501,B2:B11)} % 중괄호는 Ctrl+Shift+로Enter 자동 생성됨

Listing 1.4: Excel FREQUENCY 함수 사용 예시

Excel에서 계산된 빈도표	
구간 (Bin)	빈도 (Frequency)
30	30
60	49
90	40
120	40
150	37
180	45
210	66
240	62
270	71
300	60

이제 각 구간에 해당하는 고객 수를 알 수 있습니다. 예를 들어, 30명의 고객은 0초에서 30초 사이를 기다렸고, 66명의 고객은 180초에서 210초 사이를 기다렸습니다.

상대 빈도 계산 (Calculating Relative Frequency)

상대 빈도는 각 범주에 속하는 고객의 비율을 알려줍니다. 예를 들어, 30명의 고객이 0초에서 30초 사이를 기다렸는데, 이는 총 500명의 고객 중 30명입니다. 이 비율을 계산해야 합니다.

• 단계:

1. 'Relative Frequency'라는 새 열을 만듭니다.
2. 첫 번째 상대 빈도 셀에 $=C2/E4$ (예시: 빈도 셀이 C2이고 총 개수 셀이 E4인 경우)와 같이 입력합니다.
3. **총 개수 셀 고정:** 총 개수(500)는 모든 계산에서 동일하게 사용되어야 하므로, 해당 셀(예: E4)을 선택한 후 F4 키를 눌러 절대 참조(\$E\$4)로 만듭니다. 이렇게 하면 수식을 아래로 끌어 복사해도 총 개수 셀의 위치가 고정됩니다.
4. 수식을 입력한 후 **Enter**를 누릅니다.
5. 첫 번째 상대 빈도 셀을 선택하고, 셀의 오른쪽 아래 모서리를 두 번 클릭하거나 아래로 끌어 나머지 셀을 자동으로 채웁니다.
6. 필요하다면, 상대 빈도 열의 셀들을 선택하고 Excel의 서식 옵션에서 '백분율 (Percentage)'로 변경하여 비율을 퍼센트로 표시할 수 있습니다.

1 $=C2/ \$E\4 % 는 C2 빈도, 는 E4 총 개수 셀

Listing 1.5: Excel 상대 빈도 계산 예시

Excel에서 계산된 빈도 및 상대 빈도표		
구간 (Bin)	빈도 (Frequency)	상대 빈도 (Relative Frequency)
30	30	0.06 (6%)
60	49	0.098 (9.8%)
90	40	0.08 (8%)
120	40	0.08 (8%)
150	37	0.074 (7.4%)
180	45	0.09 (9%)
210	66	0.132 (13.2%)
240	62	0.124 (12.4%)
270	71	0.142 (14.2%)
300	60	0.12 (12%)

이제 고객 대기 시간에 대한 상대 빈도를 얻었습니다. 이 표를 보면 많은 고객이 대기 시간의 상위 구간에 집중되어 있음을 알 수 있습니다. 만약 대기 시간이 부정적인 고객 경험 지표라면, 이는 어떤 비즈니스 관리자에게도 좋은 소식이 아닐 것입니다.

강의명: BADM-572: Data-Driven Decision Making

주차: Module 1 (Part 2/3)

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 이 문서는 'Exploring and Producing Data Module 1'의 두 번째 파트(2/3)로, 데이터 요약 및 시각화의 핵심 도구들을 다룹니다. 특히 질적 데이터(Qualitative Data)와 양적 데이터(Quantitative Data)를 효과적으로 분석하고 표현하는 방법을 학습합니다. Excel을 활용하여 빈도표(Frequency Tables)를 생성하고, 이를 막대 그래프(Bar Graphs), 히스토그램(Histograms), 파이 차트(Pie Charts)로 시각화하는 구체적인 절차를 상세히 설명합니다. 각 시각화 도구의 특징과 적절한 사용 시점을 이해하여, 데이터를 통해 더 나은 의사결정을 내릴 수 있는 기반을 마련하는 것이 목표입니다.

1.4 용어 정리

용어 (Term)	쉬운 설명	원어 (Original Term)	비고
빈도표	특정 범주나 값의 출현 횟수를 정리한 표	Frequency Table	질적/양적 데이터 요약
범주형 데이터	분류나 그룹으로 나눌 수 있는 데이터	Categorical Data (Qualitative Data)	트럭 모델, 성별 등
수치형 데이터	숫자 형태로 측정되는 데이터	Quantitative Data	판매량, 대기 시간 등
상대 빈도	전체 데이터 중 특정 범주나 값이 차지하는 비율	Relative Frequency	백분율로 표현 가능
막대 그래프	범주형 데이터의 빈도를 막대 길이로 표현한 그래프	Bar Graph	각 범주 간 비교에 용이
히스토그램	수치형 데이터의 분포를 구간별 빈도로 표현한 그래프	Histogram	막대 사이 간격 없음
빈 (계급 구간)	히스토그램에서 데이터를 나누는 구간	Bin (Class Interval)	적절한 크기 선택이 중요
파이 차트	전체에 대한 각 범주의 비율을 부채꼴 크기로 표현한 그래프	Pie Chart	전체 대비 비율 비교에 용이
데이터 분석 도구	Excel에서 통계 분석 기능을 제공하는 추가 기능	Data Analysis Toolpak	히스토그램 생성 시 필요

1.5 핵심 개념 및 원리

데이터를 효과적으로 이해하고 의사결정에 활용하기 위해서는 원시(Raw) 데이터를 단순히 보는 것만으로는 부족합니다. 데이터를 요약하고 시각화하는 다양한 도구들을 활용해야 합니다. 이 섹션에서는 질적 데이터와 양적 데이터를 요약하고 시각화하는 주요 방법들을 소개합니다.

1.5.1 1. 빈도표 (Frequency Tables)

빈도표는 데이터에 포함된 특정 값이나 범주가 얼마나 자주 나타나는지(빈도)를 정리한 표입니다. 이는 대량의 원시 데이터를 한눈에 파악하기 쉽게 요약하는 강력한 도구입니다.

핵심 요약

한 줄 핵심 요약: 빈도표는 데이터의 각 항목이 얼마나 자주 나타나는지(빈도)를 정리하여 데이터를 요약하는 표입니다.

직관적 예시/비유: 만약 당신이 한 해 동안 팔린 모든 트럭 모델의 목록을 가지고 있다면, 이 목록은 수십만 개의 항목으로 이루어져 있을 것입니다. 이 원시 데이터를 보면서 "어떤 트럭이 가장 많이 팔렸지?"라는

질문에 답하기는 매우 어렵습니다. 하지만 빈도표를 만들면, 각 트럭 모델별로 몇 대가 팔렸는지(빈도)를 쉽게 알 수 있어, 시장의 흐름을 빠르게 파악할 수 있습니다.

기술적 정확한 설명: 빈도표는 주로 범주형 데이터(Qualitative Data)를 요약하는 데 사용되지만, 수치형 데이터(Quantitative Data)도 특정 구간(Bin)으로 묶어 빈도를 계산할 수 있습니다. 빈도표는 다음과 같은 정보를 포함할 수 있습니다:

- **범주 (Category):** 데이터의 각 고유한 값 또는 그룹.
- **빈도 (Frequency):** 각 범주가 데이터 세트에서 나타나는 횟수.
- **상대 빈도 (Relative Frequency):** 각 범주의 빈도를 전체 데이터 수로 나눈 값으로, 보통 백분율로 표현됩니다. 이는 전체에서 각 범주가 차지하는 비율을 보여줍니다.

빈도표를 통해 데이터의 분포를 파악하고, 가장 흔한 항목이나 가장 드문 항목을 식별할 수 있습니다.

1.5.2 2. 막대 그래프 (Bar Graphs)

막대 그래프는 빈도표의 정보를 시각적으로 표현하는 가장 일반적인 방법 중 하나입니다. 주로 범주형 데이터의 빈도나 상대 빈도를 비교할 때 사용됩니다.

핵심 요약

한 줄 핵심 요약: 막대 그래프는 범주형 데이터의 빈도나 상대 빈도를 막대의 길이로 시각화하여 각 범주 간의 크기를 비교하는 데 유용합니다.

직관적 예시/비유: 트럭 판매량 빈도표를 만들었다면, 이 표를 보고 어떤 트럭이 가장 많이 팔렸는지 숫자로 알 수 있습니다. 하지만 막대 그래프로 그리면, 가장 긴 막대가 가장 많이 팔린 트럭을 나타내므로, 시각적으로 훨씬 빠르게 판매 순위를 파악할 수 있습니다. 마치 키를 비교할 때 숫자로 말하는 것보다 나란히 서 있는 모습을 보는 것이 더 직관적인 것과 같습니다.

기술적 정확한 설명: 막대 그래프는 다음과 같은 특징을 가집니다:

- **축 (Axes):** 일반적으로 가로축(x-축)은 범주(예: 트럭 모델)를 나타내고, 세로축(y-축)은 빈도 또는 상대 빈도를 나타냅니다.
- **막대 (Bars):** 각 범주에 해당하는 막대는 서로 떨어져 있습니다. 이는 각 범주가 독립적임을 시각적으로 보여줍니다. 막대의 길이는 해당 범주의 빈도 또는 상대 빈도에 비례합니다.
- **비교 용이성:** 막대의 길이를 통해 여러 범주 간의 크기를 쉽게 비교할 수 있습니다.

막대 그래프는 데이터의 순위나 특정 범주의 중요도를 강조할 때 효과적입니다.

1.5.3 3. 히스토그램 (Histograms)

히스토그램은 막대 그래프와 유사해 보이지만, 수치형 데이터의 분포를 시각화하는 데 특화된 도구입니다. 데이터를 특정 구간(빈)으로 나누고, 각 구간에 속하는 데이터의 빈도를 막대로 표현합니다.

핵심 요약

한 줄 핵심 요약: 히스토그램은 수치형 데이터의 분포를 보여주기 위해 데이터를 구간(빈)으로 나누고, 각 구간의 빈도를 막대로 표현하는 특별한 형태의 막대 그래프입니다.

직관적 예시/비유: 고객 대기 시간 데이터를 가지고 있다고 가정해 봅시다. 1초, 5초, 10초, 30초 등 다양한 대기 시간이 있을 것입니다. 이 모든 시간을 개별적으로 막대 그래프로 그리면 너무 많은 막대가 생겨 복잡해집니다. 히스토그램은 "0 30초", "31 60초"와 같이 대기 시간을 구간으로 묶어, 각 구간에 몇 명의 고객이 속하는지를 보여줍니다. 이를 통해 "대부분의 고객이 30초 이내로 기다리는구나" 또는 "1분 이상 기다리는 고객도 꽤 많네"와 같은 전체적인 대기 시간 패턴을 파악할 수 있습니다.

기술적 정확한 설명: 히스토그램은 다음과 같은 특징을 가집니다:

- **연속성:** 막대 그래프와 달리 히스토그램의 막대들은 서로 붙어 있습니다. 이는 데이터가 연속적인 수치형 데이터임을 나타냅니다.
- **빈 (Bins):** 가로축은 데이터의 값 범위를 여러 개의 구간(빈 또는 계급 구간)으로 나눕니다. 각 빈은 특정 값 범위를 나타내며, 빈의 크기(간격)는 히스토그램의 모양에 큰 영향을 미칩니다.
- **빈도 (Frequency):** 세로축은 각 빈에 속하는 데이터의 빈도(또는 상대 빈도)를 나타냅니다.
- **분포 파악:** 히스토그램을 통해 데이터의 중심 경향, 퍼짐 정도, 왜도(skewness), 이상치(outliers) 등 전반적인 분포 형태를 파악할 수 있습니다.

빈 크기의 중요성: 빈의 크기를 너무 크게 설정하면 중요한 세부 정보를 놓칠 수 있고, 너무 작게 설정하면 데이터가 효과적으로 요약되지 않아 패턴을 파악하기 어려워집니다. 적절한 빈 크기를 선택하는 것이 중요합니다.

1.5.4 4. 파이 차트 (Pie Charts)

파이 차트는 전체에 대한 각 범주의 비율을 시각적으로 비교하는 데 사용되는 원형 그래프입니다. 주로 범주형 데이터의 상대 빈도를 표현할 때 유용합니다.

핵심 요약

한 줄 핵심 요약: 파이 차트는 전체 데이터에서 각 범주가 차지하는 비율을 원형의 부채꼴 형태로 시각화하여, 각 부분의 상대적 크기를 쉽게 비교할 수 있게 합니다.

직관적 예시/비유: 미국인들이 가장 좋아하는 디저트 종류를 조사했다고 가정해 봅시다. 파이(Pie)가 29%, 케이크(Cake)가 17%, 쿠키(Cookies)가 15% 등 다양한 비율이 나올 것입니다. 이 정보를 파이 차트로 그리면, 전체 원(100%)에서 파이가 가장 큰 조각을 차지하고 있음을 한눈에 알 수 있습니다. 마치 피자를 여러 조각으로 나눈 것처럼, 각 조각의 크기가 전체에서 차지하는 비율을 직관적으로 보여줍니다.

기술적 정확한 설명: 파이 차트는 다음과 같은 특징을 가집니다:

- **전체 비율:** 파이 차트의 전체 원은 100%를 나타내며, 각 부채꼴(slice)은 특정 범주가 전체에서 차지하는 비율을 나타냅니다.
- **범주형 데이터:** 주로 범주형 데이터에 사용되며, 각 범주는 서로 배타적이어야 합니다.
- **제한된 범주 수:** 너무 많은 범주를 파이 차트에 포함하면 각 부채꼴이 너무 작아져 구분이 어려워지고 가독성이 떨어집니다. 일반적으로 5 7개 이하의 범주에 사용하는 것이 좋습니다.
- **상대적 비교:** 각 범주의 절대적인 값보다는 전체에 대한 상대적인 비율을 비교하는 데 효과적입니다.

파이 차트는 전체 대비 각 부분의 중요도를 강조하거나, 여러 범주가 전체를 어떻게 구성하는지 보여줄 때 유용합니다.

1.6 절차/방법: Excel을 활용한 데이터 요약 및 시각화

이 섹션에서는 Excel을 사용하여 빈도표를 만들고, 이를 바탕으로 막대 그래프, 히스토그램, 파이 차트를 생성하는 구체적인 단계를 설명합니다.

1.6.1 1. Excel에서 질적 데이터 빈도표 생성하기 (Lesson 1-2.3)

질적 데이터(예: 트럭 모델 이름)의 빈도표를 만드는 과정은 다음과 같습니다. 이 과정은 어떤 항목이 얼마나 많이 팔렸는지, 즉 각 항목의 빈도를 파악하는 데 사용됩니다.

시나리오: 베스트셀러 트럭 모델 분석, colback=lightblue, colframe=darkblue

미국에서 한 해 동안 판매된 23만 3천 대 이상의 트럭 모델 데이터를 가지고 있습니다. 이 원시 데이터만으로는 어떤 트럭이 잘 팔렸는지 파악하기 어렵습니다. 빈도표를 만들어 데이터를 요약하고 시장 동향을 이해하고자 합니다.

단계 1: 고유한 트럭 모델 목록 추출하기

수십만 개의 데이터에서 중복을 제거하고 고유한 트럭 모델 이름만 추출하는 과정입니다.

1. **데이터 선택:** 트럭 모델 이름이 있는 열(예: A 열)을 선택합니다.
2. **전체 데이터 범위 선택:** A1 셀을 클릭한 후, **Ctrl + Shift + 아래쪽 화살표** 키를 눌러 A 열의 모든 데이터를 한 번에 선택합니다. (233,602개의 행이 선택될 것입니다.)
3. **고급 필터 열기:** Excel 리본 메뉴에서 **데이터(Data)** 탭으로 이동한 후, **정렬 및 필터(Sort & Filter)** 그룹에서 **고급(Advanced)**을 클릭합니다.
4. **고급 필터 설정:**
 - 팝업 창에서 **다른 장소에 복사(Copy to another location)**를 선택합니다.
 - **목록 범위(List range)**는 이미 선택된 A 열 데이터 범위로 자동 입력됩니다.
 - **복사 위치(Copy to)** 입력란을 클릭한 후, 고유한 목록을 표시할 새 셀(예: E1)을 선택합니다.
 - **고유한 레코드만(Unique records only)** 확인란을 선택합니다.
 - **확인(OK)**을 클릭합니다.
5. **결과 확인:** E열에 판매된 고유한 트럭 모델 목록이 자동으로 생성됩니다.

단계 2: 각 트럭 모델의 판매 빈도 계산하기

추출된 고유 모델별로 원시 데이터에서 몇 번 나타나는지 세는 과정입니다.

1. **COUNTIF 함수 사용:** 고유 트럭 모델 목록 옆 셀(예: F2)에 다음 수식을 입력합니다:

```
1 =COUNTIF(range, criteria)
2
```

Listing 1.6: COUNTIF 함수 예시

2. **범위(Range) 지정:**

- COUNTIF(다음, 원시 데이터가 있는 A 열의 실제 데이터 범위(A2부터 시작)를 선택합니다. A1은 열 이름이므로 제외합니다.
- A2 셀을 클릭한 후, Ctrl + Shift + 아래쪽 화살표 키를 눌러 A 열의 모든 트럭 모델 데이터를 선택합니다.
- 선택된 범위 고정: F4 키를 눌러 선택된 범위(예: \$A\$2:\$A\$233602)를 절대 참조로 고정합니다. 이렇게 하면 수식을 다른 셀로 복사해도 범위가 변하지 않습니다.

3. 조건(Criteria) 지정:

- 범위 지정 후 쉼표(,)를 입력합니다.
- 고유 트럭 모델 목록의 첫 번째 항목(예: E2, 'Toyota Tacoma')을 클릭합니다.
- 괄호를 닫고 Enter 키를 누릅니다.

4. 결과 확인: F2 셀에 'Toyota Tacoma'의 판매 빈도(예: 16,230)가 표시됩니다.

5. 수식 자동 채우기: F2 셀의 오른쪽 아래 모서리에 마우스를 가져가면 십자(+) 모양이 나타납니다. 이 상태에서 더블 클릭하면 나머지 모든 고유 트럭 모델에 대한 판매 빈도가 자동으로 계산됩니다.

단계 3: 빈도표 정렬하기

판매 빈도를 기준으로 트럭 모델을 정렬하여 순위를 쉽게 파악할 수 있습니다.

1. 데이터 선택: 고유 트럭 모델 목록(E 열)과 해당 빈도(F 열)를 모두 선택합니다.
2. 사용자 지정 정렬: Excel 리본 메뉴에서 **홈(Home)** 탭으로 이동한 후, **편집(Editing)** 그룹에서 **정렬 및 필터(Sort & Filter)**를 클릭하고 **사용자 지정 정렬(Custom Sort)**을 선택합니다.
3. 정렬 기준 설정:
 - 정렬 기준(Sort by) 드롭다운 메뉴에서 'Count' (빈도 열의 이름)를 선택합니다.
 - 정렬 순서(Order) 드롭다운 메뉴에서 **내림차순(Largest to Smallest)**을 선택합니다.
 - **확인(OK)**을 클릭합니다.
4. 결과 확인: 트럭 모델이 판매량(빈도)이 가장 많은 순서대로 정렬됩니다.

예제

트럭 모델 (Truck Model) 판매 대수

정렬된 트럭 모델 판매 빈도표 예시:

Ford F-Series
 Chevrolet Silverado
 Ram P/U
 GMC Sierra
 Toyota Tacoma
 Toyota Tundra
 Chevrolet Colorado
 Nissan Frontier
 GMC Canyon
 Nissan Titan
 Honda Ridgeline

베스트셀러 트럭 모델 판매 빈도 (정렬됨)

단계 4: 상대 빈도 (Relative Frequency) 계산하기

각 트럭 모델이 전체 판매량에서 차지하는 비율을 계산합니다.

1. **총 판매 대수 계산:** 빈도표 아래 빈 셀(예: F13)에 `=SUM(F2:F12)`와 같이 빈도 열의 모든 값을 더하는 수식을 입력하여 총 판매 대수를 계산합니다. (결과: 233,601)
2. **상대 빈도 열 추가:** 빈도 열 옆에 '상대 빈도(Relative Frequency)'라는 새 열(예: G 열)을 추가합니다.
3. **상대 빈도 수식 입력:** 첫 번째 트럭 모델의 상대 빈도를 계산할 셀(예: G2)에 다음 수식을 입력합니다:

```
1 =F2 / $F$13
```

```
2
```

Listing 1.7: 상대 빈도 계산 수식

- F2는 해당 트럭 모델의 빈도입니다.
- \$F\$13는 총 판매 대수 셀을 절대 참조로 고정한 것입니다. F4 키를 눌러 고정할 수 있습니다. 이렇게

해야 수식을 복사할 때 총 판매 대수 셀이 변하지 않습니다.

4. **결과 확인 및 서식 지정:** G2 셀에 'Ford F-Series'의 상대 빈도(예: 0.305)가 표시됩니다.
 - 이 값을 백분율로 표시하려면, 셀을 선택하고 **홈(Home)** 탭의 **표시 형식(Number)** 그룹에서 **백분율 스타일(%)** 버튼을 클릭합니다. (예: 31%)
 - 소수점 자릿수를 조정하려면, 같은 그룹에서 **소수 자릿수 늘림/줄임** 버튼을 사용합니다.
5. **수식 자동 채우기:** G2 셀의 오른쪽 아래 모서리를 더블 클릭하여 나머지 모든 트럭 모델의 상대 빈도를 계산합니다.

예제			
		트럭 모델 (Truck Model)	판매 대수 (Count)
상대 빈도가 포함된 트럭 모델 판매 빈도표 예시:		Ford F-Series	71332
		Chevrolet Silverado	54977
		Ram P/U	45310
		GMC Sierra	21241
		Toyota Tacoma	16230
		Toyota Tundra	10057
		Chevrolet Colorado	7114
		Nissan Frontier	3645
		GMC Canyon	2423
		Nissan Titan	1268
베스트셀러 트럭 모델 판매 빈도 및 상대 빈도		Honda Ridgeline	4

이 빈도표를 통해 Ford F-Series가 전체 판매량의 30.5%를 차지하며 가장 많이 팔린 트럭임을 한눈에 알 수 있습니다.

1.6.2 2. Excel에서 빈도표를 막대 그래프로 표현하기 (Lesson 1-2.4)

빈도표를 시각적으로 표현하는 가장 효과적인 방법 중 하나는 막대 그래프를 사용하는 것입니다. 이는 각 범주 간의 비교를 직관적으로 보여줍니다.

단계 1: 판매 대수 막대 그래프 생성하기

트럭 모델별 판매 대수(Count)를 막대 그래프로 시각화합니다.

1. **데이터 선택:** 트럭 모델 이름 열(예: E열)과 판매 대수(Count) 열(예: F열)을 모두 선택합니다.
2. **차트 삽입:** Excel 리본 메뉴에서 **삽입(Insert)** 탭으로 이동한 후, **차트(Charts)** 그룹에서 **막대(Bar)** 차트 아이콘을 클릭하고 **2차원 세로 막대형(2-D Column)**을 선택합니다.
3. **차트 생성:** 선택한 데이터에 대한 막대 그래프가 자동으로 생성됩니다.
4. **차트 서식 지정 (선택 사항):**

- **차트 스타일 변경:** 차트가 선택된 상태에서 리본 메뉴의 **차트 디자인(Chart Design)** 탭에서 다양한 차트 스타일을 선택하여 디자인을 변경할 수 있습니다.
- **눈금선 제거:** 차트의 가로 눈금선(Gridlines)을 클릭하여 선택한 후 **Delete** 키를 눌러 제거할 수 있습니다.
- **축 서식 변경:** x-축(트럭 모델 이름)을 더블 클릭하여 **축 서식(Format Axis)** 창을 엽니다. **선(Line)** 옵션에서 선 색상을 '검정(Black)'으로, 너비를 조절하여 더 선명하게 만들 수 있습니다.

단계 2: 상대 빈도 막대 그래프 생성하기

트럭 모델별 상대 빈도(Relative Frequency)를 막대 그래프로 시각화합니다.

1. 데이터 선택 (비연속 열):

- 먼저 트럭 모델 이름 열(예: E 열)을 선택합니다.
- **Ctrl** 키를 누른 상태에서 상대 빈도(Relative Frequency) 열(예: G 열)을 선택합니다. 이렇게 하면 서로 떨어져 있는 두 개의 열을 동시에 선택할 수 있습니다.

2. 차트 삽입: Excel 리본 메뉴에서 삽입(Insert) 탭으로 이동한 후, 차트(Charts) 그룹에서 막대(Bar) 차트 아이콘을 클릭하고 **2차원 세로 막대형(2-D Column)**을 선택합니다.

3. 차트 생성: 상대 빈도를 나타내는 막대 그래프가 생성됩니다. 이 그래프의 y-축은 백분을 또는 소수점 형태로 상대 빈도를 나타냅니다.

4. 결과 확인: 이 그래프를 통해 각 트럭 모델이 전체 판매량에서 차지하는 비율을 시각적으로 비교할 수 있습니다. 예를 들어, Ford F-Series의 막대는 30%를 약간 넘는 높이를 가질 것입니다.

팁

막대 그래프와 히스토그램의 차이:

- **막대 그래프 (Bar Graph):** 주로 범주형 데이터에 사용되며, 각 막대 사이에 간격이 있습니다. 각 막대는 독립적인 범주를 나타냅니다.
 - **히스토그램 (Histogram):** 주로 수치형 데이터에 사용되며, 막대들이 서로 붙어 있습니다. 각 막대는 연속적인 데이터의 특정 구간(빈)을 나타냅니다.
- 이러한 시각적 차이는 데이터의 종류와 특성을 반영합니다.

1.6.3 3. Excel에서 히스토그램 생성하기 (Lesson 1-3.2)

히스토그램은 수치형 데이터의 분포를 시각적으로 파악하는 데 매우 유용합니다. Excel의 '데이터 분석(Data Analysis)' 도구를 사용하여 히스토그램을 생성할 수 있습니다.

주의

사전 준비: 데이터 분석 도구 추가 기능 활성화 Excel에서 히스토그램 기능을 사용하려면 '데이터 분석(Data Analysis)' 추가 기능이 활성화되어 있어야 합니다.

1. **파일(File)** 탭 → **옵션(Options)** → **추가 기능(Add-ins)**으로 이동합니다.
2. **관리(Manage)** 드롭다운 메뉴에서 **Excel 추가 기능(Excel Add-ins)**을 선택하고 **이동(Go...)**을 클릭합니다.
3. **분석 도구(Analysis ToolPak)** 확인란을 선택하고 **확인(OK)**을 클릭합니다.

4. 이제 데이터(Data) 탭에 데이터 분석(Data Analysis) 버튼이 나타날 것입니다.

시나리오: 고객 대기 시간 분석,colback=lightblue,colframe=darkblue

고객 서비스 센터의 고객 대기 시간 데이터를 가지고 있습니다. 이 데이터의 분포를 파악하여 고객들이 얼마나 오래 기다리는지, 그리고 대기 시간 패턴이 어떤지 이해하고자 합니다.

단계 1: Excel의 자동 빈(Bin) 설정을 사용하여 히스토그램 생성하기

Excel이 데이터에 적합하다고 판단하는 빈(구간)을 자동으로 설정하여 히스토그램을 생성합니다.

1. **데이터 준비:** 고객 대기 시간 데이터가 있는 열(예: A 열)을 준비합니다. (A1 셀에 'Customer Waiting Time'과 같은 레이블이 있다고 가정합니다.)
2. **데이터 분석 도구 실행:** Excel 리본 메뉴에서 데이터(Data) 탭으로 이동한 후, 분석(Analyze) 그룹에서 데이터 분석(Data Analysis)을 클릭합니다.
3. **히스토그램 선택:** 팝업 창에서 히스토그램(Histogram)을 선택하고 확인(OK)을 클릭합니다.
4. **히스토그램 대화 상자 설정:**
 - **입력 범위(Input Range):** 고객 대기 시간 데이터가 있는 열을 선택합니다. A1 셀을 클릭한 후 Ctrl + Shift + 아래쪽 화살표 키를 눌러 전체 데이터를 선택합니다.
 - **빈 범위(Bin Range):** 이 단계에서는 Excel이 자동으로 빈을 설정하도록 비워둡니다.
 - **레이블(Labels):** 입력 범위에 열 이름(예: A1)이 포함되어 있다면 이 확인란을 선택합니다.
 - **출력 옵션(Output Options):**
 - **출력 범위(Output Range):** 결과를 표시할 워크시트의 빈 셀(예: C1)을 클릭합니다. (기본값인 '새 워크시트'를 선택할 수도 있습니다.)
 - **차트 출력(Chart Output):** 히스토그램 그래프를 함께 생성하려면 이 확인란을 반드시 선택합니다.
 - **확인(OK)**을 클릭합니다.
5. **결과 확인:** 선택한 출력 범위에 빈(Bin)과 빈도(Frequency) 표, 그리고 히스토그램 그래프가 생성됩니다. Excel이 자동으로 설정한 빈은 데이터의 최소값부터 시작하여 일정한 간격(예: 13.63초)으로 증가하는 것을 볼 수 있습니다.

단계 2: 사용자 지정 빈(Bin) 설정을 사용하여 히스토그램 생성하기

분석 목적에 따라 특정 빈(구간)을 직접 정의하여 히스토그램을 생성할 수 있습니다. 예를 들어, 고객 대기 시간을 30초 간격으로 보고 싶을 때 유용합니다.

1. **빈 범위 준비:** 새 열(예: D 열)에 원하는 빈의 상한값을 입력합니다. 예를 들어, 30초 간격으로 빈을 만들려면 '30', '60', '90', ... 과 같이 입력합니다. (D1 셀에 'Range'와 같은 레이블이 있다고 가정합니다.)
2. **데이터 분석 도구 실행:** 데이터(Data) 탭 → 데이터 분석(Data Analysis) → 히스토그램(Histogram) → 확인(OK)을 클릭합니다.
3. **히스토그램 대화 상자 설정:**
 - **입력 범위(Input Range):** 고객 대기 시간 데이터 열(예: A 열)을 선택합니다. (레이블 포함)
 - **빈 범위(Bin Range):** 새로 준비한 사용자 지정 빈 범위(예: D1:D10)를 선택합니다. (레이블 포함)

2. **데이터 선택:** 디저트 종류 열과 선호도(비율) 열을 모두 선택합니다.
3. **차트 삽입:** Excel 리본 메뉴에서 **삽입(Insert)** 탭으로 이동한 후, **차트(Charts)** 그룹에서 **파이(Pie)** 차트 아이콘을 클릭하고 **2차원 원형(2-D Pie)**을 선택합니다.
4. **차트 생성:** 선택한 데이터에 대한 파이 차트가 자동으로 생성됩니다.
5. **차트 서식 지정 (선택 사항):**
 - **데이터 레이블 추가:** 차트를 선택한 후, 차트 옆에 나타나는 '+' 버튼을 클릭하고 **데이터 레이블(Data Labels)**을 선택합니다. 레이블 옵션에서 **백분율(Percentage)** 및 **항목 이름(Category Name)**을 표시하도록 설정할 수 있습니다.
 - **차트 제목 변경:** 차트 제목을 클릭하여 원하는 제목으로 변경합니다 (예: "미국인 디저트 선호도").

파이 차트와 막대 그래프의 비교 (Lesson 1-4.1)

데이터를 시각화할 때 파이 차트와 막대 그래프 중 어떤 것을 선택할지는 전달하고자 하는 메시지에 따라 달라집니다.

파이 차트 (Pie Chart)	막대 그래프 (Bar Graph)
장점: • 전체에 대한 각 부분의 상대적 비율을 시각적으로 쉽게 비교할 수 있습니다. • 각 범주가 전체를 어떻게 구성하는지 직관적으로 보여줍니다. • 범주 수가 적을 때 가독성이 높습니다. • 여러 범주 간의 정확한 비교와 순위 파악에 용이합니다. • 범주 수가 많아도 가독성을 유지하기 쉽습니다. 단점: • 범주 수가 많으면 각 부채꼴이 너무 작아져 비교가 어렵습니다. • 각 범주의 절대적인 값을 파악하기 어렵습니다. • 비슷한 비율의 범주들을 구분하기 어렵습니다. • 모든 범주를 포함하여 전체를 구성하는 관계를 보여주기에 덜 효과적입니다. 주요 사용 시점: • 전체 대비 각 부분의 비율 관계를 강조할 때. • 범주 수가 적고, 각 범주가 전체의 상당 부분을 차지할 때. • 여러 범주 간의 순위나 크기 차이를 명확히 비교하고 싶을 때. • 범주 수가 많거나, '기타'와 같은 추가 범주를 포함할 때.	장점: • 각 범주의 절대적인 값을 명확하게 보여줍니다. 단점: • 전체에 대한 각 부분의 상대적 비율을 직관적으로 파악하기 어렵습니다. 주요 사용 시점: • 각 범주의 정확한 값을 보여주고 싶을 때.
파이 차트와 막대 그래프의 비교	

예제

미국-중국 수출 데이터 예시: 2015년 미국에서 중국으로의 10대 수출 품목 데이터를 막대 그래프와 파이 차트로 시각화할 수 있습니다.

- **막대 그래프:** 항공우주 부문이 약 140억 달러로 1위임을 명확히 보여주며, 각 품목의 정확한 수출액을 비교하기 좋습니다.
- **파이 차트:** 상위 5개 수출 품목(항공우주, 전기 기계, 핵, 차량, 씨앗 및 씨앗 오일)이 전체 수출액의 4분의 3을 차지한다는 관계를 빠르게 파악할 수 있습니다.

여기에 '기타 모든 수출 품목'이라는 11번째 범주를 추가하면, 파이 차트가 상위 10개 품목과 기타

품목 간의 전체적인 비율 관계를 더 효과적으로 보여줄 수 있습니다. 반면 막대 그래프는 '기타' 항목이 추가되면 전체적인 순위 비교가 다소 복잡해질 수 있습니다.

1.7 체크리스트

이 섹션의 내용을 학습하고 실습하면서 다음 항목들을 확인해 보세요.

- **빈도표 이해 및 생성:**
 - 질적 데이터의 빈도표를 만드는 목적을 이해했는가?
 - Excel의 '고급 필터'를 사용하여 고유한 레코드를 추출할 수 있는가?
 - COUNTIF 함수를 사용하여 각 항목의 빈도를 정확히 계산할 수 있는가?
 - F4 키를 사용하여 셀 참조를 절대 참조로 고정하는 방법을 이해하고 활용할 수 있는가?
 - 상대 빈도를 계산하고 백분율로 서식 지정할 수 있는가?
 - 빈도표를 특정 기준(예: 빈도)으로 정렬할 수 있는가?
- **막대 그래프 이해 및 생성:**
 - 막대 그래프가 범주형 데이터 시각화에 적합한 이유를 설명할 수 있는가?
 - Excel에서 판매 대수 및 상대 빈도 막대 그래프를 생성할 수 있는가?
 - 비연속적인 열을 선택하여 차트를 만드는 방법을 알고 있는가? (Ctrl 키 활용)
 - 차트의 기본 서식(제목, 축, 눈금선 등)을 변경할 수 있는가?
- **히스토그램 이해 및 생성:**
 - 히스토그램이 수치형 데이터 시각화에 적합한 이유를 설명할 수 있는가?
 - Excel의 '데이터 분석' 추가 기능을 활성화할 수 있는가?
 - Excel의 자동 빈 설정을 사용하여 히스토그램을 생성할 수 있는가?
 - 사용자 지정 빈을 정의하여 히스토그램을 생성할 수 있는가?
 - 빈 크기 선택이 히스토그램의 해석에 미치는 영향을 이해하고 설명할 수 있는가?
- **파이 차트 이해 및 생성:**
 - 파이 차트가 전체 대비 각 부분의 비율을 시각화하는 데 적합한 이유를 설명할 수 있는가?
 - Excel에서 파이 차트를 생성하고 데이터 레이블을 추가할 수 있는가?
 - 파이 차트와 막대 그래프의 장단점 및 적절한 사용 시점을 비교 설명할 수 있는가?
- **전반적인 데이터 시각화 능력:**
 - 주어진 데이터의 종류(질적/양적)에 따라 적절한 요약 및 시각화 도구를 선택할 수 있는가?
 - 시각화된 데이터를 통해 데이터의 패턴이나 주요 특징을 파악하고 설명할 수 있는가?

1.8 FAQ (자주 묻는 질문)

- **Q:** 빈도표를 만들 때 왜 '고유한 레코드만'을 선택해야 하나요? **A:** 원시 데이터에는 수십만 개의 중복된 항목(예: 같은 트럭 모델 이름)이 있을 수 있습니다. 빈도표를 만들려면 각 고유한 항목이 무엇인지 먼저 알아야 합니다. '고유한 레코드만'을 선택하면 중복 없이 각 항목의 목록을 얻을 수 있어, 이 목록을 기준으로 각 항목의 빈도를 계산할 수 있습니다.

- **Q: COUNTIF 함수에서 범위를 고정하기 위해 F4 키를 누르는 것이 왜 중요한가요? A:** F4 키를 눌러 범위를 절대 참조(예: \$A\$2:\$A\$233602)로 고정하지 않으면, 수식을 아래 셀로 복사할 때 범위도 함께 이동(상대 참조)하게 됩니다. 이렇게 되면 잘못된 범위에서 빈도를 계산하게 되어 결과가 틀어지게 됩니다. 범위를 고정하면 모든 계산이 동일한 원시 데이터 범위를 참조하게 됩니다.
- **Q: 막대 그래프와 히스토그램은 둘 다 막대를 사용하는데, 어떤 차이가 있나요? A:** 가장 큰 차이는 데이터의 종류와 막대 사이의 간격입니다. 막대 그래프는 '범주형 데이터'(예: 트럭 모델)에 사용되며, 각 막대 사이에 간격이 있습니다. 반면 히스토그램은 '수치형 데이터'(예: 대기 시간)에 사용되며, 막대들이 서로 붙어 있습니다. 히스토그램의 막대는 연속적인 데이터의 특정 '구간(빈)'을 나타냅니다.
- **Q: 히스토그램에서 빈(Bin) 크기를 어떻게 결정해야 하나요? A:** 빈 크기 결정은 중요하면서도 어려운 부분입니다. 너무 크면 데이터의 중요한 세부 정보를 놓치고, 너무 작으면 데이터가 효과적으로 요약되지 않아 패턴을 파악하기 어렵습니다. Excel의 '데이터 분석' 도구는 자동으로 빈을 설정해주므로, 먼저 이를 활용해 보고, 그 다음 분석 목적에 따라 30초, 60초 등 의미 있는 간격으로 직접 빈을 설정하여 여러 히스토그램을 비교해 보는 것이 좋습니다.
- **Q: 파이 차트는 언제 사용하고, 막대 그래프는 언제 사용하는 것이 좋은가요? A:** 파이 차트는 각 부분이 '전체에서 차지하는 비율'을 강조하고 싶을 때, 특히 범주 수가 적을 때 좋습니다. 반면 막대 그래프는 각 범주의 '절대적인 값'을 비교하거나, 여러 범주 간의 '순위'를 명확히 보여주고 싶을 때, 또는 범주 수가 많을 때 더 효과적입니다. 전달하고자 하는 메시지에 따라 적절한 차트를 선택해야 합니다.

1.9 빠르게 훑어보기 (1페이지 요약)

데이터 요약 및 시각화 핵심 도구

1. 빈도표 (Frequency Tables)

- 목적: 질적/양적 데이터의 출현 횟수(빈도)를 정리하여 요약.
- Excel 활용:
 - 고유 목록 추출: '데이터' → '고급 필터' → '다른 장소에 복사' → '고유한 레코드만'.
 - 빈도 계산: =COUNTIF(원시 데이터 범위, 고유 항목) (범위는 F4로 절대 참조 고정).
 - 상대 빈도: =빈도 / 총합 (총합은 F4로 절대 참조 고정).
 - 정렬: '홈' → '정렬 및 필터' → '사용자 지정 정렬'.

2. 막대 그래프 (Bar Graphs)

- 목적: 범주형 데이터의 빈도/상대 빈도를 막대 길이로 시각화하여 각 범주 간 크기 비교.
- Excel 활용:
 - 데이터 선택: 범주 열과 빈도/상대 빈도 열 선택 (Ctrl로 비연속 열 선택 가능).
 - 차트 삽입: '삽입' → '막대' → '2차원 세로 막대형'.
 - 특징: 막대 사이에 간격 있음.

3. 히스토그램 (Histograms)

- 목적: 수치형 데이터의 분포를 구간(빈)별 빈도로 시각화.
- Excel 활용:
 - 사전 준비: '데이터 분석' 추가 기능 활성화.
 - 생성: '데이터' → '데이터 분석' → '히스토그램'.
 - 설정: 입력 범위, (선택적) 빈 범위, 레이블, 출력 범위, 차트 출력. **빈 크기:** Excel 자동 설정 또는 사용자 지정 (분석 목적에 따라 조절).
 - 특징: 막대들이 서로 붙어 있음.

4. 파이 차트 (Pie Charts)

- 목적: 전체에 대한 각 범주의 비율을 부채꼴 크기로 시각화.
- Excel 활용:
 - 데이터 선택: 범주 열과 비율 열 선택.
 - 차트 삽입: '삽입' → '파이' → '2차원 원형'.
 - 특징: 범주 수가 적을 때 효과적, 전체 대비 비율 강조.

시각화 도구 선택 가이드:

- 파이 차트: 전체 대비 각 부분의 비율 관계 강조 (범주 소수).
- 막대 그래프: 각 범주의 정확한 값 비교, 순위 파악 (범주 다수 가능).
- 히스토그램: 수치형 데이터의 전반적인 분포, 패턴 파악.

강의명: BADM-572: Data-Driven Decision Making

주차: Module 1 (Part 3/3)

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 이 문서는 BADM-572: Data-Driven Decision Making 과목의 'Exploring and Producing Data Module 1' 중 마지막 파트(3/3)를 다룹니다. 주요 목표는 데이터를 시각적으로 요약하고 관계를 탐색하는 방법을 학습하는 것입니다. 특히, 파이 차트(Pie Charts)를 활용하여 범주형 데이터의 비율을 시각화하고, 산점도(Scatter Plots)를 통해 두 변수 간의 관계를 파악하는 기술에 중점을 둡니다. 엑셀(Excel)을 활용한 실제 데이터 시각화 절차와 함께, 각 차트 유형의 목적, 장단점, 그리고 효과적인 활용 전략을 상세히 설명합니다. 이 문서를 통해 데이터 시각화의 기본 원리를 이해하고, 실제 비즈니스 의사결정에 필요한 통찰력을 얻을 수 있습니다.

1.10 용어 정리

용어 (Term)	쉬운 설명 (Easy Explanation)	원어 (Original Term)	비고 (Notes)
파이 차트	전체에 대한 각 부분의 비율을 부채꼴 모양으로 나타낸 그래프	Pie Chart	범주형 데이터에 유용
범주형 데이터	이름이나 라벨로 구분되는 데이터 (예: 트럭 모델)	Categorical Data	
상대 빈도	전체 데이터 중 특정 범주가 차지하는 비율	Relative Frequency	백분율로 표현 가능
파이 오브 파이	작은 비율의 범주들을 묶어 별도의 파이 차트로 보여주는 방식	Pie of Pie	복잡한 파이 차트 가독성 향상
산점도	두 변수 간의 관계를 점으로 표시하여 시각화한 그래프	Scatter Plot	두 변수 간의 상관관계 파악
독립 변수	다른 변수에 영향을 주는 변수 (X축에 배치)	Independent Variable	원인 또는 예측 변수
종속 변수	독립 변수의 영향을 받는 변수 (Y축에 배치)	Dependent Variable	결과 또는 반응 변수
시계열	X축이 시간의 흐름을 나타내는 산점도	Time Series	시간 경과에 따른 변화 추세 분석
상관관계	두 변수가 함께 변화하는 경향성	Correlation	관계의 방향과 강도
데이터 레이블	차트의 각 요소에 표시되는 실제 값이나 백분율	Data Labels	정보의 정확한 전달
범례	차트의 색상이나 패턴이 무엇을 의미하는지 설명하는 요소	Legend	차트 해석에 필수적

1.11 핵심 개념 및 원리

1.11.1 파이 차트 (Pie Charts)

개념

한 줄 핵심 요약: 파이 차트는 전체에 대한 각 부분의 비율을 시각적으로 보여주는 원형 그래프입니다. **직관적 예시/비유:** 피자 한 판을 여러 조각으로 나누어 각 조각이 전체 피자에서 차지하는 비율을 보여주는 것과 같습니다. 각 조각의 크기는 해당 범주의 비율을 나타냅니다. **기술적 정확성 설명:** 파이 차트는 범주형 데이터(Categorical Data)의 분포를 시각화하는 데 특히 유용합니다. 각 범주(예: 트럭 모델)가 전체 시장(Total Market)에서 차지하는 비례적인 시장 점유율(Proportion of the Market)을 한눈에 파악할 수 있도록 돕습니다. 각 슬라이스(slice)는 전체의 백분율을 나타내며, 모든 슬라이스의 합은 100%가 됩니다.

파이 차트의 활용 목적

파이 차트는 주로 다음과 같은 상황에서 사용됩니다:

- **시장 점유율 분석:** 특정 제품이나 서비스가 전체 시장에서 차지하는 비율을 보여줄 때.
- **예산 분배:** 전체 예산이 각 항목에 어떻게 배분되었는지 시각화할 때.
- **인구 통계:** 특정 그룹이 전체 인구에서 차지하는 비율을 나타낼 때.

파이 차트는 범주의 수가 적을 때 가장 효과적이며, 각 범주의 비율 차이가 명확할수록 시각적 효과가 좋습니다.

파이 차트의 한계와 '파이 오브 파이' (Pie of Pie)

주의

파이 차트의 한계: 범주의 수가 너무 많거나, 각 범주의 비율이 매우 작아서 슬라이스가 너무 얇아지면 차트가 복잡해지고 가독성이 떨어집니다. 특히, 작은 비율의 범주들이 많을 때 이러한 문제가 두드러집니다.

개념

파이 오브 파이 (Pie of Pie): 이러한 한계를 극복하기 위해 '파이 오브 파이' 차트가 사용됩니다. 이는 원래 파이 차트에서 작은 비율을 차지하는 여러 범주들을 하나로 묶어 '기타(Other)'와 같은 단일 슬라이스로 만든 다음, 이 '기타' 슬라이스를 다시 별도의 작은 파이 차트로 분할하여 상세하게 보여주는 방식입니다.

파이 오브 파이의 장점:

- **가독성 향상:** 메인 파이 차트의 복잡성을 줄여 주요 범주에 집중할 수 있게 합니다.
- **세부 정보 제공:** 작은 비율의 범주들도 놓치지 않고 상세하게 분석할 수 있는 기회를 제공합니다.
- **효과적인 커뮤니케이션:** 데이터의 핵심 메시지를 명확하게 전달하면서도 필요한 세부 정보를 제공할 수 있습니다.

이 차트를 효과적으로 사용하려면 데이터가 내림차순으로 정렬되어 있는 것이 좋습니다. 엑셀은 기본적으로 하위 몇 개 항목을 자동으로 분리하여 보조 차트를 생성합니다.

1.11.2 산점도 (Scatter Plots)

개념

한 줄 핵심 요약: 산점도는 두 변수 간의 관계를 시각적으로 탐색하기 위해 사용되는 그래프입니다. **직관적 예시/비유:** 키와 몸무게의 관계를 알아보기 위해 사람들의 키와 몸무게를 각각 X축과 Y축에 점으로 찍어보는 것과 같습니다. 점들이 특정 패턴을 보이면 두 변수 사이에 관계가 있다고 추측할 수 있습니다. **기술적 정확한 설명:** 산점도는 두 개의 양적 변수(Quantitative Variables)가 서로 어떻게 관련되어 있는지를 보여줍니다. 각 데이터 포인트는 두 변수의 특정 값을 나타내는 (X, Y) 좌표로 표시됩니다. 이를 통해 변수 간의 상관관계(Correlation) 유무, 관계의 방향(양의 상관관계, 음의 상관관계), 그리고 관계의 강도(강한 관계, 약한 관계)를 시각적으로 파악할 수 있습니다.

독립 변수와 종속 변수

산점도를 그릴 때 가장 중요한 것은 어떤 변수를 X축에, 어떤 변수를 Y축에 놓을지 결정하는 것입니다.

- **독립 변수 (Independent Variable):** 다른 변수에 영향을 미친다고 가정하는 변수입니다. 보통 원인 (Cause)이 되거나 예측(Predictor)하는 역할을 합니다. 산점도에서는 **X**축에 배치됩니다.
- **종속 변수 (Dependent Variable):** 독립 변수의 영향을 받는다고 가정하는 변수입니다. 보통 결과 (Effect)가 되거나 반응(Response)하는 역할을 합니다. 산점도에서는 **Y**축에 배치됩니다.

예제

예시: 광고비 지출과 판매량

- **질문:** 광고비 지출이 판매량에 영향을 미치는가?
 - **독립 변수 (X축):** 광고 예산 (Advertising Budget) – 우리가 통제하거나 결정할 수 있는 변수입니다.
 - **종속 변수 (Y축):** 판매량 (Sales) – 광고 예산에 의해 영향을 받는다고 생각하는 변수입니다.
- 이처럼 변수 간의 인과 관계(Causal Relationship)를 가정할 때, 원인 변수를 X축에, 결과 변수를 Y축에 놓는 것이 일반적입니다.

시계열 (Time Series)

개념

시계열 (Time Series): 특별한 형태의 산점도로, X축이 시간의 흐름(예: 연도, 월, 일)을 나타낼 때 사용됩니다. 시계열 그래프는 시간 경과에 따른 데이터의 변화 추세, 계절성, 주기성 등을 파악하는데 유용합니다.

예제

예시: 미국-중국 수출액 시계열 1992년부터 2014년까지 미국에서 중국으로의 총 수출액을 연도별로 산점도로 나타내면 시계열 그래프가 됩니다. 이 그래프를 통해 수출액이 시간이 지남에 따라 어떻게 변화했는지, 특정 시점에 급격한 변화가 있었는지 등을 파악할 수 있습니다. 예를 들어, 1992년에서 1999년까지는 완만한 성장세를 보이다가 2000년부터는 상당히 꾸준하고 선형적인 성장을 보였다는 것을 시각적으로 확인할 수 있습니다.

산점도 해석의 중요성

산점도를 통해 두 변수 간의 관계를 시각적으로 파악하는 것은 데이터 분석의 첫 단계입니다.

- 점들이 오른쪽 위로 향하는 경향을 보이면 **양의 상관관계** (Positive Correlation)가 있다고 할 수 있습니다 (예: 광고비 증가 → 판매량 증가).
- 점들이 오른쪽 아래로 향하는 경향을 보이면 **음의 상관관계** (Negative Correlation)가 있다고 할 수 있습니다.
- 점들이 특별한 패턴 없이 흩어져 있으면 **상관관계가 없거나 약하다고** 볼 수 있습니다.

이러한 시각적 분석은 나중에 회귀 분석(Regression Analysis)과 같은 통계적 분석을 수행하기 위한 중요한 기반이 됩니다.

1.12 절차/방법: 엑셀을 이용한 데이터 시각화

1.12.1 파이 차트 생성 및 서식 지정 (Excel)

이 섹션에서는 엑셀을 사용하여 파이 차트를 만들고, 가독성을 높이기 위해 다양한 서식 옵션을 적용하는 방법을 단계별로 설명합니다.

다운로드

자료 다운로드: 파이 차트 실습을 위한 엑셀 파일: Best-selling Trucks Pie chart excel file
(첫 번째 워크시트: Best_Selling_Trucks_Table 참조)

1단계: 데이터 준비 및 선택

- **데이터 확인:** 트럭 모델 판매 데이터 (Truck Model Sold Data)를 사용합니다. 이 데이터는 이전에 빈도표(Frequency Table)와 막대 차트(Bar Chart)를 만드는 데 사용되었습니다.
- **데이터 선택:** 파이 차트를 그릴 데이터를 선택합니다. 일반적으로 '트럭 모델 판매(Truck Model Sold)', '판매 대수(Counts)', '상대 빈도(Relative Frequency)' 열을 선택합니다.
- **핵심:** 엑셀은 '트럭 모델 판매'를 범주로, '판매 대수'를 각 슬라이스의 크기를 결정하는 값으로 사용합니다. '상대 빈도'를 선택하더라도 엑셀은 기본적으로 '판매 대수'를 기반으로 비율을 계산하여 보여주므로 큰 차이는 없습니다. 각 슬라이스는 시장 점유율의 백분율을 나타냅니다.

슬라이드 125 설명: E열 (Truck Model Sold), F열 (counts), G열 (Relative Frequency)이 선택된 모습.

2단계: 파이 차트 삽입

1. 엑셀 상단 메뉴에서 **삽입(Insert)** 탭을 클릭합니다.
2. **차트(Charts)** 그룹에서 **파이 또는 도넛형 차트 삽입(Insert Pie or Doughnut Chart)** 아이콘을 클릭합니다.
3. **2차원 파이(2-D Pie)** 차트를 선택합니다.

슬라이드 126 설명: 삽입 탭에서 2차원 파이 차트가 선택된 모습.

슬라이드 127 설명: 각 트럭 모델의 판매 대수를 나타내는 파이 차트가 나타난 모습.

3단계: 차트 서식 지정 및 가독성 향상

파이 차트가 생성되면, 정보를 더 명확하게 전달하기 위해 서식을 지정해야 합니다.

1. 데이터 레이블 추가:

- 차트를 클릭하면 오른쪽에 나타나는 **차트 요소(Chart Elements)** 아이콘(+)을 클릭합니다.
- **데이터 레이블(Data Labels)**을 선택합니다. 이렇게 하면 각 슬라이스에 판매 대수가 표시됩니다.

슬라이드 127 설명: 데이터 레이블이 추가되어 각 범주별 판매 대수가 표시된 모습.

2. 범례(Legend) 및 차트 제목(Chart Title) 설정:

- 차트 요소 아이콘에서 **차트 제목(Chart Title)**과 **범례(Legend)**가 선택되어 있는지 확인합니다.
- 범례는 각 색상이 어떤 트럭 모델을 나타내는지 보여줍니다 (예: 파란색은 Ford F-Series).

슬라이드 128 설명: 차트 요소가 강조되어 있고 차트 제목과 범례가 선택된 모습. 슬라이드 129 설명: 데이터 레이블이 추가된 모습. 파란색이 *Ford F-Series*를 나타낸다고 설명.

3. 데이터 레이블에 범주 이름 포함 (고급):

- 차트 요소에서 데이터 레이블 옆의 화살표를 클릭한 후 **기타 옵션(More Options)**을 선택합니다.
- 데이터 레이블 서식(**Format Data Labels**) 작업 창이 나타나면 **레이블 옵션(Label Options)**에서 **범주 이름(Category Name)**을 선택합니다.
- 이렇게 하면 각 슬라이스에 트럭 모델 이름과 판매 대수가 함께 표시됩니다.

슬라이드 130 설명: 차트 요소가 강조되어 있고 차트 제목, 데이터 레이블, 범례가 선택된 모습. 데이터 레이블을 클릭하여 기타 옵션을 선택하는 과정 설명. 슬라이드 131 설명: 데이터 레이블이 강조되어 있고 레이블 옵션이 선택된 모습. 슬라이드 132 설명: 데이터 레이블이 트럭 모델 이름과 판매 대수를 포함하도록 업데이트된 모습.

주의

주의: 범주 이름까지 데이터 레이블에 포함하면 차트가 매우 복잡해지고 가독성이 떨어질 수 있습니다. 특히 범주의 수가 많거나 이름이 길 때 더욱 그렇습니다.

다운로드

자료 다운로드: 파이 차트 실습 엑셀 파일 (두 번째 워크시트: `Table_and_Pie_Chart` 참조)

4단계: '파이 오브 파이' 차트 활용 (복잡한 데이터에 대한 해결책)

데이터에 작은 시장 점유율을 가진 모델이 많아 파이 차트가 복잡해 보일 때, '파이 오브 파이' 차트를 사용하면 가독성을 크게 높일 수 있습니다.

1. 데이터 선택: '트럭 모델 판매', '판매 대수', '상대 빈도' 열을 다시 선택합니다.

슬라이드 133 설명: 트럭 모델 판매, 판매 대수, 상대 빈도 열이 선택된 모습.

2. 차트 유형 변경:

- 기존 파이 차트를 클릭하고 **차트 디자인(Chart Design)** 탭으로 이동합니다.

- **차트 종류 변경(Change Chart Type)**을 클릭합니다.
- **파이(Pie)** 섹션에서 **파이 오브 파이(Pie of Pie)**를 선택하고 **확인(OK)**을 클릭합니다.

슬라이드 134 설명: 파이 차트가 강조된 모습. 슬라이드 135 설명: 파이 오브 파이 차트가 강조된 모습. 특정 섹션을 분리하여 하위 섹션을 만드는 기능 설명. 슬라이드 136 설명: 첫 번째 파이 차트에서 두 번째 파이 차트가 추가되어 덜 복잡해진 모습.

3. '파이 오브 파이' 서식 지정:

- '파이 오브 파이' 차트를 더블 클릭하여 **데이터 계열 서식(Format Data Series)** 작업 창을 엽니다.
- **계열 옵션(Series Options)** 섹션에서 보조 차트에 포함될 항목을 조정할 수 있습니다.
- 두 번째 그림에 있는 **값(Values in second plot)**: 기본값은 '하위 4개' 항목을 분리합니다. 이 값을 변경하여 더 많은 항목을 보조 차트로 옮길 수 있습니다 (예: 5, 6 등으로 증가).
- 두 번째 그림에 있는 **백분율(Percentage values in second plot)**: 특정 백분율(예: 10%) 미만의 모든 항목을 보조 차트로 옮길 수 있습니다.

슬라이드 138 설명: 계열 옵션이 선택된 모습. 기본적으로 하위 4개 항목을 분리하며, 데이터가 내림차순으로 정렬되어 있어야 함을 강조. 보조 차트 항목 수를 변경하는 방법 설명. 슬라이드 139 설명: 계열 옵션 창에서 항목 수를 변경하여 파이 차트가 변화하는 모습. 슬라이드 140 설명: 10% 미만의 모든 값이 두 번째 차트에 포함되도록 변경된 모습. 슬라이드 141 설명: 두 번째 파이 차트를 가리키는 화살표. 이 차트의 모든 모델이 시장의 10% 미만을 차지함을 설명.

4. 데이터 레이블을 백분율로 표시:

- 차트 요소에서 데이터 레이블을 선택한 후 **기타 옵션**으로 이동합니다.
- **레이블 옵션**에서 **백분율(Percentage)**을 선택하고 **값(Values)**은 선택 해제합니다.

슬라이드 142 설명: 파이 차트의 데이터 레이블이 선택된 모습. 슬라이드 143 설명: 파이 차트의 데이터 레이블이 백분율로 변경된 모습. 각 항목이 시장의 10% 미만을 차지함을 보여줌.

다운로드

자료 다운로드: 파이 차트 실습 엑셀 파일 (세 번째 워크시트: Pie_of_Pie 참조)

핵심 요약

파이 차트의 목적: 데이터를 가장 효과적인 방식으로 요약하여 더 나은 의사소통을 가능하게 하고, 데이터에서 통찰력을 얻어 향후 분석에 활용하는 것입니다. '파이 오브 파이'는 복잡한 데이터를 명확하게 보여주는 좋은 예시입니다.

1.12.2 산점도 생성 및 서식 지정 (Excel)

이 섹션에서는 엑셀을 사용하여 두 변수 간의 관계를 시각적으로 탐색하는 산점도를 만들고 서식을 지정하는 방법을 단계별로 설명합니다.

다운로드

자료 다운로드: 산점도 실습을 위한 엑셀 파일: Scatter Plot excel file (첫 번째 워크시트: Advertising_and_Sales_Table 참조)

1단계: 데이터 준비 및 선택

- **데이터 확인:** 광고비(Advertising)와 판매량(Sales) 데이터가 준비되어 있습니다.
- **변수 식별:**
 - 독립 변수(X축): 광고비(Advertising) – 판매량에 영향을 미친다고 가정하는 변수입니다.
 - 종속 변수(Y축): 판매량(Sales) – 광고비에 의해 영향을 받는다고 가정하는 변수입니다.
- **데이터 선택:** X값과 Y값이 연속된 열에 있어야 합니다. 열 레이블(헤더)을 포함하여 모든 데이터를 선택합니다.
- **팁:** Control + Shift + 아래쪽 화살표 키를 사용하여 한 번에 모든 데이터를 선택할 수 있습니다.

슬라이드 150 설명: A열(Advertising)과 B열(Sales) 두 개의 열로 구성된 스프레드시트. 광고비가 판매량에 영향을 미친다는 가설을 바탕으로 광고비를 독립 변수(X축), 판매량을 종속 변수(Y축)로 설정하는 과정 설명. X축이 시간일 경우 시계열이라고 언급. 슬라이드 151 설명: 모든 데이터 요소를 한 번에 선택하기 위해 Control + Shift + 아래쪽 화살표를 사용하는 방법 설명. 레이블을 포함하여 선택해도 무방하다고 언급.

2단계: 산점도 삽입

1. 엑셀 상단 메뉴에서 삽입(Insert) 탭을 클릭합니다.
2. 차트(Charts) 그룹에서 산점도(X, Y) 또는 거품형 차트 삽입(Insert Scatter (X, Y) or Bubble Chart) 아이콘을 클릭합니다.
3. 산점도(Scatter) (점만 표시되는 첫 번째 옵션)를 선택합니다. 선이 연결된 차트는 선택하지 않습니다.

슬라이드 152 설명: 삽입 탭에서 산점도가 선택된 모습. 슬라이드 153 설명: 판매량과 광고비에 대한 산점도가 나타난 모습. 차트 서식 지정의 필요성 언급.

3단계: 차트 서식 지정 및 가독성 향상

산점도가 생성되면, 축 제목 등을 추가하여 차트의 의미를 명확하게 전달해야 합니다.

1. **축 제목 추가:**
 - 차트를 클릭하면 오른쪽에 나타나는 차트 요소(Chart Elements) 아이콘(+)을 클릭합니다.
 - 축 제목(Axis Titles)을 선택합니다. 그러면 X축과 Y축에 '축 제목' 텍스트 상자가 나타납니다.

슬라이드 154 설명: 차트 요소가 강조되어 있고 축, 차트 제목, 눈금선이 선택된 모습. 축 제목을 추가하는 방법 설명. 슬라이드 155 설명: X축 레이블이 선택된 모습.

2. **축 제목 편집:**
 - X축의 '축 제목' 텍스트 상자를 클릭하고 Advertising \$로 변경합니다.
 - Y축의 '축 제목' 텍스트 상자를 클릭하고 Sales \$로 변경합니다.

슬라이드 156 설명: 산점도의 X축 레이블이 'Advertising \$'로, Y축 레이블이 'Sales \$'로 변경된 모습.

3. **눈금선(Gridlines) 제거 (선택 사항):**
 - 차트 요소 아이콘에서 눈금선(Gridlines)을 선택 해제합니다. 이렇게 하면 차트 배경의 격자선이 사라져 데이터 포인트에 더 집중할 수 있습니다.

슬라이드 157 설명: 차트 요소가 강조되어 있고 눈금선이 선택 해제된 모습.

4. 추세선(Trendline) 추가 (현재는 제외):

- 차트 요소 아이콘에서 추세선(Trendline)을 선택하면 데이터 포인트에 가장 잘 맞는 선이 추가됩니다.
- 현재 단계에서는 추세선을 추가하지 않습니다. 추세선은 나중에 회귀 분석과 같은 고급 분석에 사용됩니다.

슬라이드 158 설명: 차트 요소가 강조되어 있고 추세선이 선택 해제된 모습. 추세선은 나중에 다른 분석에 사용될 것이라고 설명.

5. 데이터 레이블 추가 (선택 사항):

- 차트 요소 아이콘에서 데이터 레이블(Data Labels)을 선택하면 각 데이터 포인트의 정확한 값을 표시할 수 있습니다.

슬라이드 159 설명: 차트 요소가 강조되어 있고 데이터 레이블이 선택된 모습.

6. 차트 스타일 변경 (선택 사항):

- 차트를 클릭하면 오른쪽에 나타나는 차트 스타일(Chart Styles) 아이콘(붓 모양)을 클릭하여 다양한 시각적 스타일을 적용할 수 있습니다. 이는 개인적인 선호도에 따라 선택합니다.

슬라이드 160 설명: 차트 스타일이 선택된 모습. 다양한 스타일을 선택할 수 있으며, 이는 개인적인 선호도에 따른다고 설명.

다운로드

자료 다운로드: 산점도 실습 엑셀 파일 (두 번째 워크시트: Scatter_Plot 참조)

핵심 요약

산점도 해석: 완성된 산점도를 통해 광고비가 증가함에 따라 판매량도 증가하는 경향이 있음을 시각적으로 확인할 수 있습니다. 이는 두 변수 사이에 양의 상관관계가 존재할 가능성을 시사하며, 이러한 시각적 증거는 더 심층적인 통계적 검증의 필요성을 알려줍니다.

1.13 체크리스트: 데이터 시각화 학습 및 활용

이 체크리스트는 파이 차트와 산점도 학습 및 실제 적용 시 중요한 사항들을 점검하는 데 도움이 됩니다.

1.13.1 학습 점검

파이 차트의 목적과 적절한 사용 시점을 이해했는가? (범주형 데이터의 비율)

파이 차트가 복잡해질 때 '파이 오브 파이' 차트를 사용하는 이유와 방법을 이해했는가?

산점도의 목적과 적절한 사용 시점을 이해했는가? (두 변수 간의 관계)

독립 변수와 종속 변수의 개념을 명확히 구분하고, 각각 X축과 Y축에 올바르게 배치할 수 있는가?

시계열 그래프가 산점도의 한 종류임을 이해하고 있는가?

각 차트 유형의 시각적 패턴을 통해 데이터에서 어떤 통찰력을 얻을 수 있는지 설명할 수 있는가?

1.13.2 엑셀 실습 점검

엑셀에서 파이 차트를 성공적으로 생성할 수 있는가?

파이 차트에 데이터 레이블, 범주 이름, 백분율을 추가하고 서식을 지정할 수 있는가?

'파이 오브 파이' 차트를 생성하고, 보조 차트에 포함될 항목의 기준(개수 또는 백분율)을 조정할 수 있는가?

엑셀에서 산점도를 성공적으로 생성할 수 있는가?

산점도에 축 제목을 추가하고, X축과 Y축에 올바른 변수 이름을 지정할 수 있는가?

산점도에서 불필요한 눈금선을 제거하거나 데이터 레이블을 추가하는 등 서식을 지정할 수 있는가?

1.13.3 데이터 분석 및 커뮤니케이션 점검

생성된 차트가 데이터의 핵심 메시지를 명확하고 효과적으로 전달하는가?

차트의 시각적 요소를 통해 얻은 통찰력을 바탕으로 추가적인 질문이나 분석 방향을 제시할 수 있는가?

차트가 비전공자나 처음 보는 사람도 쉽게 이해할 수 있도록 구성되었는가?

데이터 시각화가 단순한 그림 그리기가 아니라, 데이터 요약 및 의사결정 지원 도구임을 인지하고 있는가?

1.14 FAQ: 초심자를 위한 질문과 답변

- Q: 파이 차트와 막대 차트는 언제 사용해야 하나요? A:** 파이 차트는 전체에 대한 각 부분의 **비율**을 보여줄 때 가장 적합합니다. 예를 들어, 시장 점유율이나 예산 분배와 같이 합계가 100%가 되는 경우에 유용합니다. 반면, 막대 차트는 여러 범주 간의 **크기 비교**나 시간 경과에 따른 변화를 보여줄 때 더 효과적입니다. 범주의 수가 많거나 비율 차이가 미미할 때는 막대 차트가 파이 차트보다 가독성이 좋습니다.
- Q: '파이 오브 파이' 차트를 사용하면 항상 좋은가요? A:** '파이 오브 파이'는 메인 파이 차트가 너무 복잡해질 때, 즉 작은 비율의 범주가 너무 많을 때 매우 유용합니다. 하지만 범주의 수가 적거나 모든 범주의 비율이 충분히 클 때는 일반 파이 차트만으로도 충분하며, '파이 오브 파이'는 오히려 차트를 불필요하게 복잡하게 만들 수 있습니다. 데이터의 특성과 전달하고자 하는 메시지에 따라 적절한 차트 유형을 선택하는 것이 중요합니다.
- Q: 산점도에서 점들이 아무런 패턴 없이 흩어져 있으면 어떻게 해석해야 하나요? A:** 점들이 무작위로 흩어져 있고 특정 방향성이나 군집을 보이지 않는다면, 이는 두 변수 사이에 **선형적인 관계가 없거나 매우 약하다**는 것을 시사합니다. 즉, 한 변수의 변화가 다른 변수의 변화를 예측하는 데 큰 도움이 되지 않는다는 의미입니다. 하지만 비선형적인 관계가 존재할 가능성도 있으므로, 추가적인 분석이 필요할 수 있습니다.
- Q: 독립 변수와 종속 변수를 잘못 설정하면 어떤 문제가 발생하나요? A:** 독립 변수와 종속 변수를 잘못 설정하면 차트의 해석이 왜곡될 수 있습니다. 예를 들어, 판매량을 X축에, 광고비를 Y축에 놓으면 광고비가 판매량에 의해 영향을 받는 것처럼 보일 수 있습니다. 이는 우리가 일반적으로 가정하는 인과 관계(광고비가 판매량에 영향을 미침)와 반대이므로, 잘못된 결론을 도출할 위험이 있습니다. 항상 원인으로 생각되는 변수를 X축에, 결과로 생각되는 변수를 Y축에 배치해야 합니다.
- Q: 엑셀에서 차트를 만들 때 어떤 서식 옵션이 가장 중요한가요? A:** 가장 중요한 서식 옵션은 **축 제목** (Axis Titles)과 **차트 제목** (Chart Title), 그리고 **데이터 레이블** (Data Labels)입니다. 축 제목은

각 축이 무엇을 나타내는지 명확히 하여 차트의 의미를 이해하는 데 필수적입니다. 차트 제목은 차트 전체의 주제를 요약합니다. 데이터 레이블은 각 데이터 포인트의 정확한 값을 제공하여 오해를 줄이고 정확한 정보를 전달합니다. 불필요한 눈금선 제거 등은 가독성을 높이는 보조적인 역할을 합니다.

1.15 빠르게 훑어보기: 1 페이지 요약

데이터 시각화 핵심 요약

1. 파이 차트 (Pie Charts)

- 목적: 전체에 대한 각 부분의 **비율** 시각화 (범주형 데이터).
- 장점: 시장 점유율, 예산 분배 등 비율 관계를 직관적으로 파악.
- 한계: 범주가 많거나 비율이 작으면 복잡해짐.
- 해결책: **파이 오브 파이 (Pie of Pie)**: 작은 범주들을 묶어 별도 차트로 상세화하여 가독성 향상.
- 엑셀: 삽입 탭 → 파이 차트 → 차트 요소에서 데이터 레이블, 범례, 범주 이름 등 서식 지정.

2. 산점도 (Scatter Plots)

- 목적: 두 변수 간의 관계 시각화 (양적 데이터).
- 변수:
 - 독립 변수 (Independent Variable): 원인, 예측 변수 → **X**축.
 - 종속 변수 (Dependent Variable): 결과, 반응 변수 → **Y**축.
- 해석: 점들의 패턴으로 상관관계(양의, 음의, 없음) 파악.
- 시계열 (Time Series): X축이 시간일 경우.
- 엑셀: 삽입 탭 → 산점도 → 차트 요소에서 축 제목, 차트 제목, 눈금선, 데이터 레이블 등 서식 지정.

3. 공통 시각화 원칙

- 명확성: 차트 제목, 축 제목, 범례, 데이터 레이블은 필수.
- 가독성: 불필요한 요소 제거 (예: 눈금선), 적절한 차트 유형 선택.
- 목적성: 데이터의 핵심 메시지를 효과적으로 전달하고, 향후 분석을 위한 통찰력 제공.

Chapter 2

용어 정리

강의명: 데이터 기반 의사결정

주차: Module 2 (Part 1)

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 데이터 탐색 및 분석을 위한 중심 경향성 및 산포도 이해

강의 개요

이 문서는 'Exploring and Producing Data Module 2'의 첫 번째 파트 내용을 담고 있습니다. 데이터를 효과적으로 요약하고 분석하기 위한 핵심 통계 개념인 중심 경향성(평균, 중앙값)과 산포도(범위, 분산, 표준 편차)에 대해 다룹니다. 각 개념의 정의, 계산 방법, 그리고 실제 비즈니스 의사결정에서 어떻게 활용되는지 상세히 설명합니다. 특히, Excel을 사용하여 이러한 통계량을 계산하는 실용적인 방법도 함께 제시하여, 비전공자나 초심자도 쉽게 이해하고 적용할 수 있도록 구성되었습니다.

2.1 용어 정리

용어	쉬운 설명	원어	비고
중심 경향성	데이터가 어디에 집중되어 있는지 나타내는 값	Central Tendency	평균, 중앙값 등이 있음
평균	모든 값을 더한 후 개수로 나눈 값	Mean (Average)	데이터의 '기대값'을 나타냄
중앙값	데이터를 크기 순으로 정렬했을 때 가운데 위치하는 값	Median	극단값(아웃라이어)에 덜 민감함
모집단	연구 대상이 되는 전체 집단	Population	모든 가능한 관측값의 집합
표본	모집단에서 추출한 일부 데이터	Sample	모집단의 특성을 추정하는 데 사용
모수	모집단의 특성을 나타내는 수치	Parameter	모집단 평균(μ), 모집단 표준 편차(σ) 등
통계량	표본의 특성을 나타내는 수치	Statistics	표본 평균($\bar{x}$), 표본 표준 편차(s) 등
산포도	데이터가 얼마나 퍼져 있는지 나타내는 정도	Dispersion (Variation)	데이터의 '변동성'을 나타냄
범위	데이터의 최댓값에서 최솟값을 뺀 값	Range	데이터의 퍼진 정도를 가장 간단하게 나타냄
분산	각 데이터가 평균으로부터 얼마나 떨어져 있는지 제곱하여 평균한 값	Variance	표준 편차의 제곱
표준 편차	분산의 양의 제곱근	Standard Deviation	데이터가 평균으로부터 평균적으로 얼마나 떨어져 있는지 나타냄
아웃라이어	다른 데이터와 동떨어진 극단적인 값	Outlier	평균에 큰 영향을 미칠 수 있음
왜도	데이터 분포의 비대칭 정도	Skewness	평균과 중앙값의 위치 관계에 영향을 줌

2.2 Module 2: 비즈니스 의사결정을 위한 데이터 탐색 및 생성

2.2.1 Lesson 2-1: 중심 경향성 측정

Lesson 2-1.1: 중심 경향성 측정

중심 경향성 (Central Tendency)

중심 경향성 측정은 데이터의 '중앙' 또는 '중심'이 어디에 위치하는지를 나타내는 값입니다. 이는 데이터의 대표적인 값을 찾는 데 사용됩니다.

- **정의:** 데이터의 중심 또는 중간을 나타내는 측정값입니다.
- **특징:** 항상 데이터의 '전형적인' 값이라고 할 수는 없습니다.
- **주요 측정값:** 평균(Mean)과 중앙값(Median)에 대해 자세히 알아봅니다.

평균 (Mean)

평균은 데이터의 '산술 평균' 또는 '기대값'을 나타내는 가장 일반적인 중심 경향성 측정값입니다.

- **정의:** 모든 관측값을 더한 후 관측값의 총 개수로 나눈 값입니다.
- **표기법:** 통계학에서는 모집단(Population)과 표본(Sample)에 따라 다른 기호를 사용합니다.
 - **모집단 평균 (μ - Mu):** 모집단의 모든 요소를 사용하여 계산된 평균입니다. 이는 '모수 (Parameter)'라고 불리며, 그리스 문자로 표기됩니다.
 - **표본 평균 ($\bar{x}$ - x-bar):** 모집단에서 추출한 표본의 요소를 사용하여 계산된 평균입니다. 이는 '통계량 (Statistics)'이라고 불리며, 영어 소문자로 표기됩니다. 표본 평균은 모집단 평균을 추정하는 데 사용됩니다.

평균 계산 방법 수동으로 계산할 필요는 없지만, 소프트웨어가 어떻게 값을 생성하는지 이해하는 것이 중요합니다.

- **모집단 평균 (μ):**

$$\mu = \frac{\sum_{i=1}^N X_i}{N}$$

여기서,

- X_i : 모집단의 각 요소의 변수 값
- N : 모집단의 크기 (총 요소 수)
- $\sum$: 합계 기호

- **표본 평균 ($\bar{x}$):**

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

여기서,

- x_i : 표본의 각 요소의 변수 값
- n : 표본의 크기 (총 요소 수)

예시: 고객 평균 지출액

웹사이트 방문 고객 7명으로부터 수집된 지출 데이터를 사용하여 평균 지출액을 계산해 봅시다.

고객 지출액 (x)

1	\$85.68
2	\$67.21
3	\$98.08
4	\$34.78
5	\$56.98
6	\$27.93
7	\$40.72

고객별 지출액 데이터

계산: 표본 평균($\bar{x}$)은 모든 고객의 지출액을 더한 후 고객 수(7명)로 나눕니다.

$$\begin{aligned}
 \bar{x} &= \frac{x_1 + x_2 + x_3 + x_4 + x_5 + x_6 + x_7}{7} \\
 &= \frac{85.68 + 67.21 + 98.08 + 34.78 + 56.93 + 27.93 + 40.72}{7} \\
 &= \frac{411.38}{7} \\
 &= \$58.77
 \end{aligned}$$

이 표본의 평균 지출액은 \$58.77입니다.

중앙값 (Median)

중앙값(M_d)은 데이터를 크기 순으로 정렬했을 때 정확히 가운데에 위치하는 값입니다. 데이터의 50%는 중앙값보다 크거나 같고, 50%는 중앙값보다 작거나 같습니다.

- 정의: 데이터를 오름차순 또는 내림차순으로 정렬했을 때 중간에 위치하는 값입니다.
- 표기법: 모집단과 표본 간에 별도의 기호 차이는 없습니다.
- 계산 방법:
 - 측정값의 개수가 홀수인 경우: 중앙값은 정렬된 데이터에서 정확히 가운데에 있는 값입니다.
 - 측정값의 개수가 짝수인 경우: 중앙값은 정렬된 데이터에서 가운데에 있는 두 값의 평균입니다.

다.

예시: 고객 지출액의 중앙값

위에서 사용한 고객 지출액 데이터를 사용하여 중앙값을 계산해 봅시다.

고객 지출액 (x)

1	\$85.68
2	\$67.21
3	\$98.08
4	\$34.78
5	\$56.98
6	\$27.93
7	\$40.72

고객별 지출액 데이터
계산:

1. 데이터를 오름차순으로 정렬합니다.

정렬된 목록	지출액
1	\$27.93
2	\$34.78
3	\$40.72
4	\$56.98
5	\$67.21
6	\$85.68
7	\$98.08

정렬된 고객 지출액 데이터

2. 데이터 포인트의 개수가 7개(홀수)이므로, 가운데 위치한 4번째 값이 중앙값입니다.
따라서 중앙값은 \$56.98 입니다. 이는 고객의 50%가 \$56.98보다 많이 지출했고, 50%가 그보다 적게

지출했음을 의미합니다.

어떤 중심 경향성 측도를 사용할 것인가? (평균 vs. 중앙값)

평균과 중앙값은 모두 데이터의 중심을 나타내지만, 데이터의 특성, 특히 '아웃라이어(Outlier)'의 존재 여부에 따라 어떤 측도가 더 적절한지 달라집니다.

예시 1: 일반적인 연봉 데이터 친구 9명과 당신(총 10명)이 비슷한 연봉을 받는 상황을 가정해 봅시

연봉

\$57,000

\$58,000

\$59,000

\$62,000

다.

\$64,000

\$65,000

\$66,000

\$68,000

\$71,000

\$80,000

친구 10명의 연봉 데이터

- **평균:** \$65,000
- **중앙값:** 데이터가 짝수(10개)이므로, 가운데 두 값(\$64,000, \$65,000)의 평균인 \$64,500
이 경우 평균과 중앙값이 매우 유사하며, 둘 다 그룹의 '전형적인' 연봉을 잘 나타냅니다.

예시 2: 아웃라이어에 있는 연봉 데이터 이제 프로 농구 선수로 성공한 옛 동창 한 명이 그룹에 합류하여 총 11 명이 되었다고 가정해 봅시다. 이 동창의 연봉은 \$8,000,000입니다.

연봉

\$57,000

\$58,000

\$59,000

\$62,000

\$64,000

\$65,000

\$66,000

\$68,000

\$71,000

\$80,000

\$8,000,000

아웃라이어가 포함된 연봉 데이터

- 평균: \$786,363.64

- **중앙값:** 데이터가 홀수(11개)이므로, 가운데(6번째) 값인 \$65,000

결론:

- 아웃라이어(극단적인 값)가 존재할 때, 평균은 아웃라이어에 매우 민감하게 반응하여 크게 변동합니다. 이 경우 \$786,363.64는 그룹의 '전형적인' 연봉이라고 보기 어렵습니다.
- 반면, 중앙값은 아웃라이어에 덜 민감하며, 데이터의 실제 중심을 더 잘 대표합니다. \$65,000는 여전히 대부분의 그룹 구성원에게 더 전형적인 값입니다.
- **실제 적용:** 주택 가격을 보고할 때 종종 '중앙값'이 사용됩니다. 이는 몇몇 값비싼 저택이나 낡은 주택 때문에 평균이 왜곡되는 것을 방지하여, 구매자들이 시장의 실제 가격대를 더 정확하게 파악할 수 있도록 돕습니다.

연습 문제: 신규 사업장 연간 임대료

신규 사업장 후보지 5곳의 연간 임대료 데이터가 주어졌습니다. 이 데이터 세트의 평균과 중앙값을 계산해 봅시다.

위치	연간 임대료
A	\$84,000
B	\$78,000
C	\$114,000
D	\$103,200
E	\$93,600

신규 사업장 연간 임대료 데이터

풀이:

1. **평균 계산:** 모든 임대료를 더한 후 5로 나눕니다.

$$\begin{aligned}
 \bar{x} &= \frac{84000 + 78000 + 114000 + 103200 + 93600}{5} \\
 &= \frac{472800}{5} \\
 &= \$94,560
 \end{aligned}$$

평균 임대료는 \$94,560입니다.

2. 중앙값 계산: 데이터를 오름차순으로 정렬합니다.

위치	연간 임대
B	\$78,000
A	\$84,000
E	\$93,600
D	\$103,200
C	\$114,000

정렬된 연간 임대료 데이터 데이터 포인트가 5개(홀수)이므로, 가운데(3번째) 값인 \$93,600이 중앙값입니다.

Lesson 2-1.2: Excel에서 평균 및 중앙값 계산

Excel에서 평균 계산하기 (AVERAGE 함수)

뉴욕시의 일일 기온 데이터(26,000개 이상의 기록)를 사용하여 평균을 계산해 봅시다.

단계:

1. Excel 시트에서 평균을 계산할 셀을 선택합니다. (예: 데이터 옆의 빈 셀)
2. 해당 셀에 `=AVERAGE(`를 입력합니다. Excel은 입력하는 동안 관련 함수 목록을 자동으로 표시합니다.
3. 평균을 계산할 데이터 범위를 선택합니다.
 - 첫 번째 데이터 셀을 클릭합니다 (예: C7).
 - `Ctrl + Shift + 아래쪽 화살표` 키를 동시에 눌러 해당 열의 모든 데이터를 자동으로 선택합니다. (예: C7:C26776)
4. 괄호를 닫고 `) Enter` 키를 누릅니다.
5. 결과가 선택한 셀에 표시됩니다. (예: 뉴욕시 평균 기온 55.2도)

```
1 =AVERAGE(C7:C26776)
```

Listing 2.1: Excel AVERAGE 함수 사용 예시

Excel에서 중앙값 계산하기 (MEDIAN 함수)

동일한 뉴욕시 일일 기온 데이터를 사용하여 중앙값을 계산해 봅시다.

단계:

1. Excel 시트에서 중앙값을 계산할 셀을 선택합니다. (예: 평균 셀 아래의 빈 셀)
2. 해당 셀에 `=MEDIAN(`를 입력합니다.
3. 중앙값을 계산할 데이터 범위를 선택합니다.

- 첫 번째 데이터 셀을 클릭합니다 (예: C7).
 - Ctrl + Shift + 아래쪽 화살표 키를 동시에 눌러 해당 열의 모든 데이터를 자동으로 선택합니다. (예: C7:C26776)
4. 괄호를 닫고) Enter 키를 누릅니다.
5. 결과가 선택한 셀에 표시됩니다. (예: 뉴욕시 중앙값 기온 55.9도)

```
1 =MEDIAN(C7:C26776)
```

Listing 2.2: Excel MEDIAN 함수 사용 예시

평균과 중앙값 비교: 뉴욕시 기온 데이터의 평균은 55.2도, 중앙값은 55.9도입니다. 이 두 값이 매우 가깝다는 것은 뉴욕시의 일일 기온 분포가 비교적 대칭적이라는 것을 시사합니다.

2.2.2 Lesson 2-2: 산포도 측정

Lesson 2-2.1: 산포도 측정

산포도 (Variation / Dispersion) 측정의 필요성

중심 경향성(평균 또는 중앙값)은 데이터의 '중심'을 알려주지만, 이 중심값이 얼마나 '대표적인지'는 알려주지 않습니다. 데이터가 얼마나 퍼져 있는지, 즉 '변동성'을 이해하는 것이 중요합니다.

- **목표:** 데이터가 얼마나 넓게 퍼져 있거나 밀집되어 있는지를 파악합니다.
- **비유:** 자동차 오일 교환 시간이 평균 30분이라고 할 때, 20분 만에 끝날지 40분 걸릴지 예측하려면 변동성 정보가 필요합니다.
- **주요 측정값:**
 1. 범위 (Range)
 2. 분산 (Variance)
 3. 표준 편차 (Standard Deviation)

범위 (Range)

범위는 데이터의 퍼진 정도를 가장 간단하게 나타내는 측정값입니다.

- **정의:** 데이터 세트의 가장 큰 관측값에서 가장 작은 관측값을 뺀 값입니다.
- **장점:** 계산이 매우 간단하여 데이터의 대략적인 확산 정도를 빠르게 파악할 수 있습니다.
- **단점:** 극단값(아웃라이어)에 매우 민감하며, 데이터 세트가 커질수록 정확도가 떨어집니다. 전체 데이터의 변동성을 충분히 반영하지 못할 수 있습니다.

예시: 응급실 (ER) 대기 시간 비교

두 응급실(ER A, ER B)의 환자 처리 시간 효율성을 비교해 봅시다. 두 ER 모두 평균 대기 시간은 5분으로 동일합니다. 하지만 어떤 ER이 환자들이 평균에 더 가까운 대기 시간을 경험할까요?

ER A의 대기 시간분포:

대기 시간 (분)	빈도
4	8
5	14
6	6

ER A 대기 시간 데이터

- 최소 대기 시간: 4분
- 최대 대기 시간: 6분
- 범위: 6분 - 4분 = 2분

ER B의 대기 시간분포:

대기 시간 (분)	빈도
2	2
3	3
4	5
5	11
6	5
7	3
8	2

ER B 대기 시간 데이터

- 최소 대기 시간: 2분
- 최대 대기 시간: 8분
- 범위: 8분 - 2분 = 6분

결론:

- 두 ER 모두 평균 대기 시간은 5분으로 같지만, ER A의 범위는 2분이고 ER B의 범위는 6분입니다.
- 이는 ER B의 환자들이 ER A보다 훨씬 더 다양한(변동성이 큰) 대기 시간을 경험한다는 것을 의미합니다.
- 따라서 ER A의 평균 대기 시간은 환자 경험을 더 잘 대표하는 반면, ER B의 평균은 덜 전형적입니다.

범위는 간단하지만, 데이터 세트가 커질수록 정확도가 떨어지므로, 더 일반적으로 사용되고 의미 있는 산포도 측정값은 표준 편차와 분산입니다.

표준 편차 (Standard Deviation) 및 분산 (Variance)

표준 편차와 분산은 데이터가 평균으로부터 얼마나 퍼져 있는지를 정량적으로 나타내는 가장 중요한 산포도 측정값입니다.

- **표준 편차 (Standard Deviation):**

- **정의:** 데이터의 산포도를 측정하는 값입니다. 표준 편차 값이 작으면 데이터 포인트들이 평균에 가깝게 밀집되어 있음을 의미합니다.
- **계산:** 분산의 양의 제곱근을 취하여 계산됩니다.
- **활용:** 데이터의 변동성을 표현할 뿐만 아니라, 통계학의 고급 주제(예: 가설 검정, 신뢰 구간)에서도 광범위하게 사용됩니다.

- **분산 (Variance):**

- **정의:** 각 관측값이 평균으로부터 얼마나 떨어져 있는지(편차)를 제곱하여 평균한 값입니다. 편차를 제곱하는 이유는 양수와 음수의 편차가 서로 상쇄되는 것을 방지하기 위함입니다.
- **계산:** 모집단 데이터와 표본 데이터에 따라 계산 방식이 다릅니다.

분산 계산 방법

- **모집단 분산 (σ^2 - Sigma squared):**

$$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \mu)^2}{N}$$

여기서,

- X_i : 모집단의 각 요소의 변수 값
- μ : 모집단 평균
- N : 모집단의 크기

각 관측값에서 모집단 평균을 뺀 후 제곱하고, 이 값들을 모두 더한 다음 모집단 크기 N 으로 나눕니다.

- **표본 분산 (s^2 - s squared):**

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

여기서,

- x_i : 표본의 각 요소의 변수 값
- $\bar{x}$: 표본 평균
- n : 표본의 크기

각 관측값에서 표본 평균을 뺀 후 제곱하고, 이 값들을 모두 더한 다음 **표본 크기 n 이 아닌 $n - 1$ 로 나눕니다.** $n - 1$ 로 나누는 이유는 표본 분산이 모집단 분산을 더 정확하게 추정하도록 하기 위함입니다 (자유도 보정).

표준 편차 계산 방법 분산이 어떻게 계산되었든, 표준 편차는 항상 분산의 양의 제곱근입니다.

- **모집단 표준 편차 (σ):**

$$\sigma = \sqrt{\sigma^2}$$

- **표본 표준 편차 (s):**

$$s = \sqrt{s^2}$$

표기법 주의: 모집단 모수는 그리스 문자(대문자)로, 표본 통계량은 영어 소문자로 표기됩니다.

예시: 연봉 데이터로 분산 및 표준 편차 계산

이전의 연봉 데이터를 사용하여 분산과 표준 편차를 계산해 봅시다. 이 그룹의 친구들을 대학 졸업생 모집단의 '표본'으로 간주합니다.

연봉

\$57,000

\$58,000

\$59,000

\$62,000

첫 번째 그룹 (10명):

\$64,000

\$65,000

\$66,000

\$68,000

\$71,000

\$80,000

친구 10명의 연봉 데이터

- 표본 크기 (n) = 10
- 표본 평균 ($\bar{x}$) = \$65,000

계산:

$$\begin{aligned}s^2 &= \frac{\sum_{i=1}^{10} (x_i - 65000)^2}{10 - 1} \\&= \frac{(57000 - 65000)^2 + (58000 - 65000)^2 + \cdots + (80000 - 65000)^2}{9} \\&= \frac{430,000,000}{9} \\&\approx 47,777,778\end{aligned}$$

표본 분산 (s^2) $\approx 47,777,778$

표본 표준 편차 (s) $= \sqrt{47,777,778} \approx \$6,912.147$

연봉

\$57,000

\$58,000

\$59,000

\$62,000

\$64,000

\$65,000

\$66,000

\$68,000

\$71,000

\$80,000

\$8,000,000

두 번째 그룹 (아웃라이어 포함, 11명):

아웃라이어가 포함된 연봉 데이터

- 표본 크기 (n) = 11

- 표본 평균 ($\bar{x}$) = \$786,363.64

계산:

$$\begin{aligned}s^2 &= \frac{\sum_{i=1}^{11} (x_i - 786363.64)^2}{11 - 1} \\&= \frac{(57000 - 786363.64)^2 + \cdots + (8000000 - 786363.64)^2}{10} \\&\approx 5,724,063,454,545.46\end{aligned}$$

표본 분산 (s^2) $\approx 5,724,063,454,545.46$

표본 표준 편차 (s) $= \sqrt{5,724,063,454,545.46} \approx \$2,392,501.51$

결론: 아웃라이어(8백만 달러 연봉)가 추가되자 표준 편차가 \$6,912에서 \$2,392,501로 크게 증가했습니다. 이는 평균 연봉(\$786,363)이 이 그룹의 '전형적인' 값을 전혀 대표하지 못한다는 것을 명확히 보여줍니다. 데이터를 요약할 때는 항상 중심 경향성(평균 또는 중앙값)과 함께 산포도(표준 편차)를 함께 고려해야 합니다.

연습 문제: 히스토그램을 통한 평균의 대표성 판단

두 히스토그램 A와 B가 주어졌습니다. 어떤 표본의 평균이 무작위로 선택된 관측값을 더 잘 대표 할까요? 그 이유는 무엇일까요?

히스토그램 A 데이터:

값	빈도
---	----

0	1
---	---

1	3
---	---

2	5
---	---

3	7
---	---

4	9
---	---

5	11
---	----

6	10
---	----

7	8
---	---

8	6
---	---

9	4
---	---

10	2
----	---

히스토그램 A 데이터

히스토그램 B 데이터:

값	빈도
---	----

0	2
---	---

1	3
---	---

2	4
---	---

3	5
---	---

4	6
---	---

5	7
---	---

6	6
---	---

7	5
---	---

8	4
---	---

9	3
---	---

10	2
----	---

히스토그램 B 데이터

풀이:

- 정답: A
- 이유:
 - 두 히스토그램 모두 중심 경향성은 5 근처에 있으며, 값의 범위는 0에서 10 사이입니다.
 - 하지만 히스토그램 A는 데이터가 중심(5) 주변에 더 밀집되어 있습니다. 즉, A는 B보다 '슬림한' 형태를 가집니다.
 - 이는 표본 A의 데이터 분포가 표본 B보다 표준 편차가 더 작다는 것을 의미합니다.
 - 표준 편차가 작다는 것은 데이터가 평균에 더 가깝게 모여 있다는 뜻이므로, 평균이 데이터 세트를 더 잘 대표합니다.

핵심: 데이터 세트에 대한 정보를 전달할 때 평균과 같은 단일 요약 지점만으로는 불완전합니다. 평균이 데이터의 좋은 대표값이 되려면, 데이터 내의 변동성(표준 편차로 표현됨)도 함께 고려해야 합니다.

Lesson 2-2.2: Excel에서 표준 편차 계산

Excel에서 표준 편차 계산하기 (STDEV.S 함수)

뉴욕시의 일일 기온 데이터(26,000개 이상의 기록)를 사용하여 표준 편차를 계산해 봅시다. 이전 계산에서 평균은 55.2도, 중앙값은 55.9도였습니다.

단계:

1. Excel 시트에서 표준 편차를 계산할 셀을 선택합니다. (예: 평균 및 중앙값 셀 아래의 빈 셀)
2. 해당 셀에 =ST를 입력합니다. Excel은 관련 함수 목록을 표시합니다.
3. **중요:** 모집단 표준 편차(STDEV.P)와 표본 표준 편차(STDEV.S)를 구분해야 합니다.
 - STDEV.P: 전체 모집단을 기반으로 표준 편차를 계산합니다. (분모 N)
 - STDEV.S: 표본 데이터를 기반으로 모집단 표준 편차를 추정합니다. (분모 $n - 1$)
 우리는 뉴욕시의 모든 기온 데이터를 가지고 있지만, 이는 '모집단'이 아닌 '표본'으로 간주되므로 STDEV.S를 선택합니다.
4. STDEV.S를 선택하고 Tab 키를 누릅니다.
5. 표준 편차를 계산할 데이터 범위를 선택합니다.
 - 첫 번째 데이터 셀을 클릭합니다 (예: C7).
 - Ctrl + Shift + 아래쪽 화살표 키를 동시에 눌러 해당 열의 모든 데이터를 자동으로 선택합니다. (예: C7:C26776)
6. 괄호를 닫고) Enter 키를 누릅니다.
7. 결과가 선택한 셀에 표시됩니다. (예: 뉴욕시 기온의 표준 편차 17.37도)

```
=STDEV.S(C7:C26776)
```

Listing 2.3: Excel STDEV.S 함수 사용 예시

결과 해석: 뉴욕시 기온의 표준 편차는 약 17.37도입니다.

- 만약 뉴욕시 기온이 정규 분포를 따른다고 가정하면,
 - 약 68%의 시간 동안 기온은 평균(≈ 55 도) ± 1 표준 편차(≈ 17 도) 범위 내에 있을 것입니다.

(즉, 38도에서 72도 사이)

- 약 95%의 시간 동안 기온은 평균(≈ 55 도) ± 2 표준 편차(≈ 34 도) 범위 내에 있을 것입니다.

(즉, 21도에서 89도 사이)

이처럼 표준 편차는 데이터의 변동성을 이해하고, 특정 값이 평균으로부터 얼마나 떨어져 있는지, 그리고 데이터가 얼마나 퍼져 있는지를 파악하는 데 중요한 역할을 합니다.

2.3 개요: 데이터 탐색 및 생산 모듈 2 (파트 2/5)

강의 개요

이 문서는 BADM-572: 데이터 기반 의사결정 과목의 '데이터 탐색 및 생산 모듈 2' 중 두 번째 파트에 해당하는 핵심 내용을 다룹니다. 우리는 데이터 내에서 특정 값의 상대적 위치를 이해하는데 필수적인 **백분위수(Percentiles)**와 **Z-점수(Z-score)** 개념을 학습합니다. 또한, 데이터의 분포 특성을 파악하는 **경험적 규칙(Empirical Rule)**을 살펴보고, 이들을 **Excel**에서 어떻게 계산하고 활용하는지 실습합니다. 마지막으로, **이산(Discrete)** 및 **연속(Continuous)** 확률 변수의 정의와 그 확률 분포, 그리고 **기댓값(Expected Value)**과 **표준편차(Standard Deviation)** 계산 방법을 다룹니다. 이 문서는 시험 대비를 위해 모든 개념을 비전공자도 이해할 수 있도록 상세하고 친절하게 설명하며, 실제 비즈니스 상황에서의 적용 사례를 풍부하게 제시합니다.

2.4 용어 정리

다음 표는 이 문서에서 다루는 주요 통계 용어들을 쉽게 설명하고 원어를 병기하여 이해를 돕습니다.

용어	쉬운 설명	원어	비고
백분위수	데이터에서 특정 값보다 작은 값들이 차지하는 비율	Percentile	상대적 위치 파악
Z-점수	특정 데이터가 평균으로부터 표준편차의 몇 배만큼 떨어져 있는지 나타내는 값	Z-score	표준화된 거리
경험적 규칙	종 모양 분포에서 평균으로부터 표준편차 거리에 따른 데이터 비율	Empirical Rule	정규 분포의 특성
이산 확률 변수	셀 수 있는 유한한 값을 가지는 변수	Discrete Random Variable	정수형 값
연속 확률 변수	특정 구간 내에서 무한히 많은 값을 가질 수 있는 변수	Continuous Random Variable	실수형 값
확률 분포	확률 변수가 가질 수 있는 각 값과 그 확률을 나열한 것	Probability Distribution	데이터의 패턴
누적 분포 함수	확률 변수가 특정 값보다 작거나 같을 확률	Cumulative Distribution Function (CDF)	확률의 합
기댓값	확률 변수의 평균적인 값 (장기적으로 기대되는 값)	Expected Value	평균과 동일한 의미

2.5 핵심 개념 및 원리

2.5.1 백분위수 (Percentiles)

백분위수 핵심 요약

백분위수는 데이터 세트 내에서 특정 값보다 작은 값들이 차지하는 '대략적인 비율'을 나타냅니다. 이는 데이터의 상대적인 위치를 파악하는 데 매우 유용합니다.

우리는 종종 어떤 값이 다른 값들과 비교했을 때 상대적으로 어느 위치에 있는지 궁금해합니다. 예를 들어, 새로운 직업 제안으로 10만 달러의 연봉을 받았다면, 이 제안이 좋은 것인지 어떻게 알 수 있을까요? 이때 백분위수가 유용하게 사용됩니다.

백분위수 예시: 연봉 제안

만약 당신의 10만 달러 연봉이 '95번째 백분위수'에 해당한다면, 이는 유사 직종의 다른 사람들의 95%보다 더 많은 급여를 받는다는 의미입니다. 반대로 '25번째 백분위수'라면, 75%의 사람들이 당신보다 더 많은 급여를 받는다는 뜻이므로, 그리 만족스럽지 않을 수 있습니다. 이처럼 백분위수는 당신이 연구하는 값의 위치를 빠르게 알려줍니다.

백분위수 계산 방법

백분위수를 계산하는 방법은 여러 가지가 있지만, 모든 방법은 유사한 결과를 제공합니다. 핵심은 데이터를 순서대로 정렬하는 것입니다.

1. **데이터 정렬:** 모든 데이터 포인트를 오름차순(가장 작은 값부터 가장 큰 값까지)으로 정렬합니다.
2. **위치 파악:** 특정 백분위수(Pth percentile)를 찾으려면, 전체 관측치의 P%가 그 값보다 작거나 같고, (100-P)%가 그 값보다 크거나 같게 되는 지점을 찾습니다.

중앙값 (Median) 과 백분위수

우리는 이미 '중앙값(Median)'에 대해 배웠습니다. 중앙값은 데이터의 50%가 그 값보다 높고, 50%가 그 값보다 낮은 값입니다. 따라서 중앙값은 '50번째 백분위수'와 같습니다. 중앙값을 찾을 때 데이터를 정렬하고 중간 지점을 찾는 것과 마찬가지로, 다른 백분위수도 같은 방식으로 찾습니다.

백분위수 계산 예시: 연봉 데이터

다음은 유사 직종 10명의 연봉 데이터가 내림차순으로 정렬된 표입니다.

순서	연봉
1	\$115,472
2	\$105,845
3	\$105,582
4	\$102,551
5	\$98,188
6	\$94,220
7	\$91,380
8	\$89,828
9	\$89,697
10	\$89,519

이 데이터를 오름차순으로 다시 생각해보면:

- **10번째 백분위수:** 가장 낮은 값인 \$89,519와 그 다음 값인 \$89,697 사이에 위치합니다. 이는 10%의 값이 이보다 작고, 90%의 값이 이보다 크다는 의미입니다.
- **50번째 백분위수 (중앙값):** \$94,220와 \$98,188 사이에 위치합니다.
- **60번째 백분위수:** \$98,188와 \$102,551 사이에 위치합니다.

만약 당신의 연봉이 \$100,000라면, 이 데이터에서는 대략 60번째 백분위수에 가깝게 위치할 것입니다.

2.5.2 Z-점수 (Z-score)

Z-점수 핵심 요약

Z-점수는 특정 관측치가 평균으로부터 '표준편차의 몇 배'만큼 떨어져 있는지를 나타내는 값입니다. 이는 대규모 데이터 세트에서 특정 값의 상대적 위치를 파악하는 또 다른 강력한 방법입니다.

Z-점수를 사용하면 특정 값보다 작은 데이터 포인트의 비율을 찾을 수 있습니다. 이는 백분위수와 유사하게 상대적 위치를 알려주지만, 표준화된 방식으로 더 정밀한 정보를 제공합니다.

Z-점수 공식

Z-점수는 다음 공식을 사용하여 계산됩니다:

$$Z = \frac{x - \mu}{\sigma}$$

여기서:

- x : 관심 변수 (우리가 알고 싶은 특정 값)
- μ : 모집단의 평균 (데이터 세트의 평균)
- σ : 모집단의 표준편차 (데이터 세트의 변동성)

Z-점수 예시: 연봉 비교

대학을 졸업하고 비즈니스 학위로 취업 제안을 받았다고 가정해 봅시다. 당신의 제안이 다른 모든 대학 졸업생들의 유사 직종 제안과 비교하여 어느 정도인지 알고 싶습니다. 만약 중앙값만 안다면 상위 50%인지 하위 50%인지만 알 수 있습니다. 하지만 51%인지 95%인지는 알 수 없습니다. 이때 Z-점수를 계산하여 당신의 제안 위치를 파악할 수 있습니다.

Salary.com 데이터에 따르면, 비즈니스 데이터 분석가의 평균 연봉(중앙값)은 \$54,030 이고 표준편차는 약 \$8,900 (또는 예시에서 \$8,600) 입니다. 당신이 \$65,000의 제안을 받았다면, 이는 평균보다 높지만 다른 사람들과 비교했을 때 어느 정도일까요?

Z-점수를 계산해 봅시다:

$$\begin{aligned} Z &= \frac{x - \mu}{\sigma} \\ &= \frac{65,000 - 54,030}{8,600} \\ &= \frac{10,970}{8,600} \\ &\approx 1.27 \end{aligned}$$

이 Z-점수 1.27은 당신이 받은 연봉 \$65,000가 평균(\$54,030)보다 '1.27 표준편차만큼 더 높다'는 것을 의미합니다.

2.5.3 경험적 규칙 (Empirical Rule)

경험적 규칙 핵심 요약

경험적 규칙은 종 모양(bell-shaped)의 대규모 데이터 분포(정규 분포)에서 데이터가 평균으로부터 표준편차의 몇 배만큼 떨어져 있는지에 따라 데이터의 특정 비율이 포함된다는 규칙입니다. 이는 Z-점수를 통해 대략적인 백분위수를 추정하는 데 유용합니다.

대규모 데이터 세트에서는 많은 값들이 평균(또는 중앙값) 주변에 밀집되어 있는 경향이 있습니다. 이러한 데이터를 히스토그램으로 그리면 대칭적인 종 모양 곡선(정규 분포)을 형성하는 경우가 많습니다. 이럴 때 '경험적 규칙'이 적용됩니다.

경험적 규칙의 내용

종 모양 분포에서:

- 전체 관측치의 **68%**는 평균으로부터 **1 표준편차** 이내에 분포합니다.
- 전체 관측치의 **95%**는 평균으로부터 **2 표준편차** 이내에 분포합니다.
- 전체 관측치의 **99.7%**는 평균으로부터 **3 표준편차** 이내에 분포합니다.

Figure 2.1: 종 모양 곡선과 경험적 규칙 (가상의 이미지)

가상의 이미지 설명: 종 모양 곡선과 경험적 규칙

슬라이드 46의 이미지는 평균이 2000인 대칭적인 종 모양 곡선을 보여줍니다.

- **1 표준편차 이내 (빨간색):** 평균으로부터 1 표준편차 범위 내에 68%의 데이터가 포함됩니다.
 - **2 표준편차 이내 (녹색):** 평균으로부터 2 표준편차 범위 내에 95%의 데이터가 포함됩니다.
 - **3 표준편차 이내 (파란색):** 평균으로부터 3 표준편차 범위 내에 99.7%의 데이터가 포함됩니다.
- 이 규칙을 알면 특정 관측치가 평균과 비교하여 어느 위치에 있는지 빠르게 파악할 수 있습니다.

경험적 규칙 적용: Z-점수 1.27

앞서 계산한 연봉 제안의 Z-점수가 1.27이었습니다.

- Z-점수 1은 평균으로부터 1 표준편차 위에 있다는 뜻이며, 이는 대략 68%의 데이터가 평균 $\pm$ 1 표준편차 안에 있으므로, 1 표준편차 위는 대략 $50\% + (68\%/2) = 84\%$ 백분위수에 해당합니다.
- Z-점수 2는 평균으로부터 2 표준편차 위에 있다는 뜻이며, 이는 대략 95%의 데이터가 평균 $\pm$ 2 표준편차 안에 있으므로, 2 표준편차 위는 대략 $50\% + (95\%/2) = 97.5\%$ 백분위수에 해당합니다.

당신의 Z-점수 1.27은 1과 2 표준편차 사이에 있으므로, 당신의 연봉은 대략 84%와 97.5% 백분위수 사이, 즉 70번째에서 95번째 백분위수 어딘가에 있을 것이라고 추정할 수 있습니다. 이는 꽤 좋은 제안임을 시사합니다.

정확한 값은 나중에 배우겠지만, 경험적 규칙은 컴퓨터나 계산기 없이도 빠르고 직관적인 추정치를 제공하여 의사결정에 도움을 줍니다.

실제 비즈니스에서의 Z-점수 및 백분위수 활용

자동차 가격 비교 (TrueCar)

TrueCar와 같은 서비스는 소비자가 자동차 구매 시 공정한 가격을 지불하는지 판단하는 데 도움을 줍니다. 이들은 특정 지역에서 동일한 자동차 모델에 대해 사람들이 지불한 가격 범위를 시각적으로 보여줍니다.

- **평균:** '적정 시장 가격(Good price)'에 해당합니다.
- **곡선의 왼쪽 꼬리:** '좋은 가격(Great price)' 또는 '매우 좋은 가격(Exceptional price)'을 나타냅니다. **곡선의 오른쪽 꼬리:** '시장 가격 이상(Above market)'을 나타냅니다.

당신이 구매한 가격이 평균보다 낮고 곡선의 왼쪽에 위치할수록 더 좋은 거래를 했다고 생각할 것입니다.

예를 들어, Camry XLE V6 모델의 가격 데이터를 보면, 평균 지불 가격은 약 \$29,000입니다. 만약 당신이 평균보다 2 표준편차 낮은 가격에 구매했다면, 이는 '매우 좋은 가격(Exceptional bargain)'에 해당합니다. 이처럼 절대적인 가격 자체보다 다른 사람들이 지불한 가격과 비교한 상대적 위치가 훨씬 더 중요합니다.

자동차 연비 비교

새 차를 구매할 때 연비 라벨을 보게 됩니다. 이 라벨은 차량의 MPG(갤런당 마일) 추정치를 보여 주어 소비자가 차량을 비교하고 선택하는 데 도움을 줍니다.

- 소형 SUV 카테고리의 연비 범위는 16 MPG에서 32 MPG입니다.
- 이 카테고리에서 가장 좋은 연비인 32 MPG는 99번째 백분위수에 해당하고, 가장 나쁜 연비인 16 MPG는 1번째 백분위수에 해당한다고 가정할 수 있습니다.
- 당신이 고려하는 차의 연비가 26 MPG라면, 이 차는 동급 차량들과 비교했을 때 어느 정도일까요?

문제 해결:

1. **평균 추정:** 범위의 중간 지점을 평균으로 추정할 수 있습니다.

$$\text{평균}(\mu) = \frac{16 + 32}{2} = 24 \text{ MPG}$$

2. **표준편차 추정:** 경험적 규칙에 따르면, 99.7%의 관측치는 평균으로부터 ± 3 표준편차 이내에 있습니다. 즉, 전체 범위는 약 6 표준편차에 해당합니다.

$$\text{표준편차}(\sigma) = \frac{\text{최대값} - \text{최소값}}{6} = \frac{32 - 16}{6} = \frac{16}{6} \approx 2.67 \text{ MPG}$$

3. **Z-점수 계산:** 당신이 고려하는 차의 연비(x)는 26 MPG입니다.

$$Z = \frac{x - \mu}{\sigma} = \frac{26 - 24}{2.67} = \frac{2}{2.67} \approx 0.75$$

이 차는 평균보다 0.75 표준편차만큼 높은 연비를 가집니다. 경험적 규칙을 다시 적용하면, 68%의 관측치가 ± 1 표준편차 이내에 있으므로, 평균보다 1 표준편차 높은 지점은 대략 84번째 백분위수 ($50\% + 68\%/2$)에 해당합니다. 0.75 표준편차는 1 표준편차보다 약간 낮으므로, 이 차는 대략 80번째 백분위수에 가까울 것으로 추정할 수 있습니다. 즉, 동급 차량의 80%보다 연비가 좋다는 의미입니다.

이처럼 Z-점수를 알면 특정 관측치가 전체 모집단 내에서 어느 위치에 있는지 파악하는 데 큰 도움이

됩니다. 실제 값(예: 26 MPG) 자체보다 그 상대적 위치(예: 80번째 백분위수)가 의사결정에 더 의미 있는 정보를 제공하는 경우가 많습니다.

2.6 절차/방법: Z-점수 및 백분위수 Excel 계산

Excel은 Z-점수와 백분위수를 정확하게 계산하는 데 유용한 함수들을 제공합니다. 특히 정규 분포를 따르는 데이터에 대해 특정 값의 백분위수를 찾거나, 특정 백분위수에 해당하는 값을 찾는 데 사용됩니다.

2.6.1 Z-점수 예시: 연봉 제안 (Excel 활용)

앞서 다룬 연봉 제안 예시를 다시 살펴봅시다.

- 당신의 연봉 제안: \$65,000 (x)
- 평균 연봉: \$54,030 (μ)
- 표준편차: \$8,600 (σ)

Z-점수는 1.27로 계산되었습니다. 이제 Excel을 사용하여 이 Z-점수에 해당하는 정확한 백분위수를 찾아 봅시다.

1단계: NORM.DIST 함수로 백분위수 계산

NORM.DIST 함수는 지정된 평균과 표준편차를 가진 정규 분포에서 특정 값(x)보다 작거나 같은 확률(누적 분포 함수)을 반환합니다. 이 확률이 바로 백분위수입니다.

```
1 =NORM.DIST(x, mean, standard_dev, cumulative)
```

Listing 2.4: NORM.DIST 함수 사용법

여기서 `cumulative` 인수는 TRUE (또는 1)로 설정하여 누적 분포 함수를 사용해야 합니다. FALSE (또는 0)는 확률 질량 함수(Probability Mass Function)를 반환하며, 이 수업에서는 사용하지 않습니다.

NORM.DIST 함수 적용

Excel에서 다음을 입력합니다:

```
1 =NORM.DIST(65000, 54030, 8600, TRUE)
2 % 또는
3 =NORM.DIST(65000, 54030, 8600, 1)
```

Listing 2.5: NORM.DIST 함수를 이용한 백분위수 계산

결과: 약 0.898948

이 결과는 당신의 연봉 \$65,000가 약 89.9번째 백분위수에 해당한다는 것을 의미합니다. 즉, 유사 직종의 다른 사람들의 약 89.9%가 당신보다 적은 연봉을 받는다는 뜻입니다. 이는 경험적 규칙을 통해 추정된 70%-95% 범위 내에 있으며, 훨씬 더 정확한 값입니다.

가상의 이미지 설명: NORM.DIST 함수 결과

슬라이드 62의 이미지는 NORM.DIST 함수의 결과인 0.898948을 보여줍니다. 또한, 평균이 \$54,030인 종 모양 곡선에서 약 90%에 해당하는 영역이 음영 처리되어 있습니다. 이는 계산된 백분위수가 시각적으로 어떤 의미를 가지는지 보여줍니다.

2단계: NORM.S.INV 함수로 Z-점수 확인

NORM.S.INV 함수는 표준 정규 분포(평균이 0이고 표준편차가 1인 분포)에서 주어진 누적 확률에 해당하는 Z-점수를 반환합니다. 이는 우리가 계산한 백분위수(확률)를 다시 Z-점수로 변환하여 확인할 때 유용합니다.

```
1 =NORM.S.INV(probability)
```

Listing 2.6: NORM.S.INV 함수 사용법

NORM.S.INV 함수 적용

앞서 NORM.DIST 함수로 얻은 백분위수(0.898948)를 사용하여 Z-점수를 확인해 봅시다. Excel에서 다음을 입력합니다:

```
1 =NORM.S.INV(0.898948)
```

Listing 2.7: NORM.S.INV 함수를 이용한 Z-점수 확인

결과: 약 1.275581

이 결과는 우리가 수동으로 계산했던 Z-점수 1.27과 거의 일치합니다. 이처럼 Excel 함수를 사용하면 Z-점수와 백분위수 사이를 쉽게 오가며 정확한 값을 얻을 수 있습니다.

NORM.S.DIST와 NORM.S.INV의 'S' 의미

함수 이름에 '.S'가 붙은 NORM.S.DIST나 NORM.S.INV는 'Standard Normal Distribution'을 의미합니다. 즉, 평균이 0이고 표준편차가 1인 표준 정규 분포를 사용한다는 뜻입니다. 일반 NORM.DIST나 NORM.INV는 사용자가 지정한 평균과 표준편차를 사용합니다.

평균과 중앙값의 관계: 분포의 왜도 (Skewness)

강의명: BADM-572

주차: Lecture 2-3/5 & 2-4/5

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 이산 및 연속 확률 변수, 정규 분포 및 Excel 활용

2.7 이산 및 연속 확률 변수 (Discrete and Continuous Random Variables)

2.7.1 확률 변수 (Random Variables)

확률 변수 핵심 요약

확률 변수(X)는 무작위 과정의 수치적 결과를 나타내는 변수입니다. 이는 우리가 던지는 질문에 대한 답이 무작위성을 띠는 경우에 사용됩니다.

통계학에서 '확률 변수'라는 용어를 자주 듣게 됩니다. 이는 기본적으로 우리가 묻는 질문에 대한 답을 나타냅니다. 예를 들어, "내 주식 가치가 1년 안에 얼마나 변할까?"라는 질문에 대한 답이 바로 확률 변수입니다. 왜 '무작위(Random)'일까요? 주식 가격이 오르거나 내리는 정확한 이유를 완전히 이해하기 어렵기 때문에, 그 결과는 무작위적이라고 간주됩니다. 통계에서는 확률 변수를 대문자 X 로 표기합니다.

2.7.2 확률 변수의 종류

확률 변수는 크게 두 가지 유형으로 나뉩니다: 이산 확률 변수와 연속 확률 변수.

1. 이산 확률 변수 (Discrete Random Variable)

이산 확률 변수 핵심 요약

이산 확률 변수는 '유한한 수의 구별되는 값'만을 가질 수 있는 변수입니다. 즉, 셀 수 있는 값들로 이루어져 있습니다.

이산 확률 변수는 특정 값을 '점프'하여 가질 수 있으며, 그 사이의 모든 값을 가질 수는 없습니다. 주로 정수 형태의 값을 가집니다.

이산 확률 변수 예시

- 가족 내 자녀 수 (0명, 1명, 2명 등)
 - 이 강의를 수강하는 학생 수
 - 서비스에 만족한다고 평가한 고객 수
 - 주사위를 던졌을 때 나오는 눈의 수 (1, 2, 3, 4, 5, 6)
- 이들은 모두 셀 수 있는 명확한 값들로 표현됩니다.

2. 연속 확률 변수 (Continuous Random Variable)

연속 확률 변수 핵심 요약

연속 확률 변수는 '정의된 구간 내에서 무한히 많은 가능한 값'을 가질 수 있는 변수입니다. 특정 값으로 정의되기보다는 '구간'으로 정의됩니다.

연속 확률 변수는 셀 수 없을 정도로 무한히 많은 값을 가질 수 있으며, 매우 높은 정밀도로 측정될 수 있습니다.

연속 확률 변수 예시

- 탄산음료 캔의 무게 (예: 11.5온스에서 12.5온스 사이의 모든 실수 값)
- 전구의 수명 (예: 100시간에서 1,000시간 사이의 모든 실수 값)
- 주식의 일일 수익률
- 고객 서비스 상담원과 통화하기 위해 기다린 시간

실제로 각 탄산음료 캔의 무게를 정확히 측정하면 항상 미세하게 다른 숫자가 나올 것입니다. 이는 특정 값으로 딱 떨어지지 않고, 어떤 구간 내에서 무한한 가능성을 가지기 때문입니다.

이산 vs. 연속 확률 변수 비교

특징	이산 확률 변수	연속 확률 변수
값의 종류	셀 수 있는 유한한 값	특정 구간 내 무한한 값
측정 방식	주로 세는 방식 (정수)	주로 측정하는 방식 (실수)
예시	자녀 수, 고객 수, 주사위 눈	무게, 시간, 온도, 수익률

연습 문제: 이산 또는 연속 확률 변수 식별

다음 확률 변수들을 이산 또는 연속으로 식별해 보세요.

- 주식의 일일 수익률: **연속** (수익률은 소수점 이하 무한한 값을 가질 수 있습니다.)
- 줄 서서 기다리는 고객 수: **이산** (고객 수는 0, 1, 2...와 같이 셀 수 있는 정수입니다.)
- 고객 서비스 상담원과 통화하기 위해 기다린 시간: **연속** (시간은 초, 밀리초 등 무한히 세분화될 수 있습니다.)
- 초콜릿 바의 칼로리 수: **연속** (칼로리도 이론적으로는 무한히 세분화될 수 있는 연속적인 값입니다. 하지만 실제로는 편의상 정수나 소수점 한 자리로 '기록'될 수 있어 이산처럼 보일 수 있습니다.)

2.7.3 확률 분포 (Probability Distributions)

확률 분포 핵심 요약

확률 분포는 이산 확률 변수가 가질 수 있는 각 값과 그 값이 발생할 확률을 나열한 것입니다. 이는 데이터의 패턴을 이해하는 데 사용됩니다.

이산 확률 변수의 경우, 확률 분포는 가능한 각 값과 그에 해당하는 확률을 목록으로 보여줍니다. 이는 우리가 히스토그램과 상대 빈도를 배울 때 이미 다루었던 개념과 유사합니다.

확률 분포 예시: 형제자매 수

20명에게 형제자매가 몇 명인지 물어본 설문조사 결과를 가정해 봅시다. 여기서 확률 변수 X 는 '형제자매 수'입니다.

형제자매 수 (X)	응답자 수
0	3
1	6
2	5
3	4
4	2
총계	20

각 형제자매 수에 대한 상대 빈도(확률)를 계산하여 확률 분포를 만들 수 있습니다.

형제자매 수 (X)	응답자 수	확률 $P(X=x)$
0	3	$3 \div 20 = 0.15$
1	6	$6 \div 20 = 0.30$
2	5	$5 \div 20 = 0.25$
3	4	$4 \div 20 = 0.20$
4	2	$2 \div 20 = 0.10$
총계	20	1.00

이 표는 이산 확률 변수의 확률 분포를 보여줍니다. 예를 들어, 무작위로 한 명을 선택했을 때 형제자매가 0명일 확률은 15%이고, 3명일 확률은 20%입니다.

확률 분포의 속성

이산 확률 분포는 다음 두 가지 중요한 속성을 가집니다:

1. 각 확률은 0보다 크거나 같아야 합니다: $P(X = x) \geq 0$
2. 모든 가능한 결과의 확률 합은 1이어야 합니다: $\sum_{\text{all } x} P(X = x) = 1$

2.7.4 누적 분포 함수 (Cumulative Distribution Function, CDF)

누적 분포 함수 핵심 요약

누적 분포 함수(CDF)는 확률 변수 X 가 특정 값 x 보다 '작거나 같을' 확률을 나타냅니다. 즉, $P(X \leq x)$ 를 계산합니다.

모든 확률 변수(이산 및 연속)는 누적 분포 함수를 가집니다. 이산 확률 변수의 경우, CDF는 해당 값까지의 모든 개별 확률을 합산하여 계산됩니다.

누적 분포 함수 예시: 형제자매 수

형제자매 수 예시에서 $P(X \leq 2)$ 를 계산해 봅시다. 이는 형제자매가 2명 이하일 확률을 의미합니다.

$$P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$P(X \leq 2) = 0.15 + 0.30 + 0.25 = 0.70$$

즉, 무작위로 한 명을 선택했을 때 형제자매가 2명 이하일 확률은 70%입니다.

다음 표는 각 형제자매 수에 대한 누적 확률을 보여줍니다.

형제자매 수 (X)	확률 $P(X=x)$	누적 확률 $P(X \leq x)$
0	0.15	0.15
1	0.30	$0.15 + 0.30 = 0.45$
2	0.25	$0.45 + 0.25 = 0.70$
3	0.20	$0.70 + 0.20 = 0.90$
4	0.10	$0.90 + 0.10 = 1.00$

가상의 이미지 설명: 누적 확률 분포 그래프

슬라이드 75의 이미지는 계단형으로 증가하는 누적 확률 분포 그래프를 보여줍니다. 형제자매 수가 증가함에 따라 누적 확률도 증가하며, 4명 이하일 확률은 100%에 도달합니다.

2.7.5 기댓값 (Expected Value) 및 표준편차 (Standard Deviation)

기댓값 (Expected Value) 또는 평균 (μ)

기댓값 핵심 요약

이산 확률 변수 X 의 기댓값($E(X)$) 또는 평균(μ)은 각 가능한 값에 해당 확률을 곱한 후 모두 더한 값입니다. 이는 장기적으로 기대되는 평균적인 결과입니다.

기댓값은 데이터 분포의 '중심 경향'을 나타냅니다.

기댓값 공식

$$E(X) = \mu = \sum_{\text{all } x} x \cdot P(X = x)$$

기댓값 계산 예시: 형제자매 수

형제자매 수 예시에서 기댓값을 계산해 봅시다.

$$\begin{aligned} E(X) &= (0 \times 0.15) + (1 \times 0.30) + (2 \times 0.25) + (3 \times 0.20) + (4 \times 0.10) \\ &= 0 + 0.30 + 0.50 + 0.60 + 0.40 \\ &= 1.8 \end{aligned}$$

따라서 이 모집단에서 평균적으로 1.8명의 형제자매를 가질 것으로 기대됩니다. 이는 이 데이터의

중심 경향을 잘 나타냅니다.

표준편차 (Standard Deviation, σ)

표준편차 핵심 요약

이산 확률 변수의 표준편차(σ)는 기댓값(평균)으로부터 데이터가 얼마나 퍼져 있는지를 나타내는 척도입니다. 각 값과 평균의 차이를 제곱하고 확률을 곱한 후 모두 더한 값의 제곱근입니다.

기댓값이 분포의 중심을 알려준다면, 표준편차는 그 중심으로부터 데이터가 얼마나 '변동'하는지를 알려줍니다.

표준편차 공식

$$\sigma = \sqrt{\sum_{\text{all } x} (x - \mu)^2 \cdot P(X = x)}$$

표준편차 계산 예시: 형제자매 수

형제자매 수 예시에서 평균 $\mu = 1.8$ 을 사용하여 표준편차를 계산해 봅시다.

$$\begin{aligned} \sigma^2 &= (0 - 1.8)^2 \times 0.15 \\ &\quad + (1 - 1.8)^2 \times 0.30 \\ &\quad + (2 - 1.8)^2 \times 0.25 \\ &\quad + (3 - 1.8)^2 \times 0.20 \\ &\quad + (4 - 1.8)^2 \times 0.10 \\ &= (-1.8)^2 \times 0.15 + (-0.8)^2 \times 0.30 + (0.2)^2 \times 0.25 + (1.2)^2 \times 0.20 + (2.2)^2 \times 0.10 \\ &= (3.24 \times 0.15) + (0.64 \times 0.30) + (0.04 \times 0.25) + (1.44 \times 0.20) + (4.84 \times 0.10) \\ &= 0.486 + 0.192 + 0.01 + 0.288 + 0.484 \\ &= 1.46 \end{aligned}$$

따라서 분산은 1.46이고, 표준편차는:

$$\sigma = \sqrt{1.46} \approx 1.21$$

이 모집단에서 형제자매 수의 표준편차는 약 1.21명입니다. 이는 평균 1.8명으로부터 데이터가 평균적으로 1.21명 정도 퍼져 있음을 의미합니다.

연습 문제: 은행 대기 고객 수

은행 지점장이 고객 대기열에 몇 명이 기다리는지 파악하기 위해 연구를 수행하여 다음 패턴을 발견했습니다.

대기 고객 수 (X)	관측 횟수
0	3
1	10
2	8
3	5
4	3
5	2
6	1
총 관측 횟수	32

0	3
1	10
2	8
3	5
4	3
5	2
6	1

총 관측 횟수	32
----------------	-----------

질문:

1. 기대되는 대기 고객 수는 몇 명입니까? (기댓값 $E(X)$)
2. 4명 이상의 고객이 줄 서 있는 것을 발견할 확률은 얼마입니까? ($P(X \geq 4)$)

문제 해결: 먼저 각 대기 고객 수에 대한 확률을 계산해야 합니다. 총 관측 횟수는 32회입니다.

대기 고객 수 (X)	관측 횟수	확률 $P(X=x)$
0	3	$3 \div 32 \approx 0.094$
1	10	$10 \div 32 \approx 0.313$
2	8	$8 \div 32 = 0.250$
3	5	$5 \div 32 \approx 0.156$
4	3	$3 \div 32 \approx 0.094$
5	2	$2 \div 32 \approx 0.063$
6	1	$1 \div 32 \approx 0.031$
총계	32	1.001 (반올림 오차)

1. 기대되는 대기 고객 수 (기댓값 $E(X)$) 계산:

$$\begin{aligned}
 E(X) &= (0 \times 0.094) + (1 \times 0.313) + (2 \times 0.250) + (3 \times 0.156) + (4 \times 0.094) + (5 \times 0.063) + (6 \times 0.031) \\
 &= 0 + 0.313 + 0.500 + 0.468 + 0.376 + 0.315 + 0.186 \\
 &\approx 2.158
 \end{aligned}$$

따라서 기대되는 대기 고객 수는 평균적으로 약 2.16명입니다.

2. 4명 이상의 고객이 줄 서 있는 것을 발견할 확률 $P(X \geq 4)$ 계산: 이는 $P(X = 4) + P(X =$

5) + $P(X = 6)$ 의 합과 같습니다.

$$\begin{aligned} P(X \geq 4) &= P(X = 4) + P(X = 5) + P(X = 6) \\ &= 0.094 + 0.063 + 0.031 \\ &= 0.188 \end{aligned}$$

따라서 4명 이상의 고객이 줄 서 있는 것을 발견할 확률은 약 18.8%입니다.

2.7.6 확률 분포의 목적

확률 분포는 이산 확률 변수의 각 결과와 그 발생 확률을 연결하는 표입니다. 가능한 결과가 매우 많은 경우에는 이 표를 일일이 만드는 것이 비효율적일 수 있습니다. 다행히도, 많은 잘 알려진 확률 분포들이 존재하며, 우리의 특정 연구나 실험이 이러한 분포 중 하나에 속한다는 것을 알게 되면, 적절한 공식을 사용하여 특정 결과의 확률을 계산할 수 있습니다.

이 과정에서는 이러한 특정 분포들을 깊이 다루지는 않지만, 대규모 데이터 세트와 표본 추출에 중점을 두기 때문에, 확률 계산을 위한 '정규 분포(Normal Distribution)'에 대해 학습할 것입니다. 정규 분포는 이산 변수와 연속 변수 모두에 사용될 수 있습니다.

2.8 빠르게 훑어보기 (핵심 요약)

모듈 2 파트 2/5 핵심 요약

- **백분위수 (Percentiles):** 데이터 내 값의 상대적 위치를 나타냅니다. 특정 값보다 작은 데이터의 비율을 의미하며, 중앙값은 50번째 백분위수입니다.
- **Z-점수 (Z-score):** 데이터가 평균으로부터 표준편차의 몇 배만큼 떨어져 있는지를 나타내는 표준화된 값입니다.

$$Z = \frac{x - \mu}{\sigma}$$

- **경험적 규칙 (Empirical Rule):** 종 모양 분포에서 1, 2, 3 표준편차 이내에 각각 68%, 95%, 99.7%의 데이터가 분포한다는 규칙입니다. Z-점수를 통해 대략적인 백분위수를 추정하는 데 사용됩니다.
- **Excel 활용:**
 - **NORM.DIST(x, mean, standard_dev, TRUE):** 특정 값(x)의 백분위수(누적 확률)를 계산합니다.
 - **NORM.S.INV(probability):** 표준 정규 분포에서 주어진 확률에 해당하는 Z-점수를 반환합니다.
- **확률 변수 (Random Variables):** 무작위 과정의 수치적 결과입니다.
 - **이산 확률 변수 (Discrete RV):** 셀 수 있는 유한한 값을 가집니다 (예: 고객 수).
 - **연속 확률 변수 (Continuous RV):** 특정 구간 내에서 무한히 많은 값을 가집니다 (예: 시간, 무게).
- **확률 분포 (Probability Distribution):** 이산 확률 변수의 각 값과 그 확률을 나열한 것입니다.

- **누적 분포 함수 (CDF):** 확률 변수가 특정 값보다 작거나 같을 확률 $P(X \leq x)$ 입니다.
- **기댓값 (Expected Value, $E(X)$ 또는 μ):** 이산 확률 변수의 평균적인 값입니다.

$$E(X) = \sum_{\text{all } x} x \cdot P(X = x)$$

- **표준편차 (Standard Deviation, σ):** 이산 확률 변수의 변동성을 나타냅니다.

$$\sigma = \sqrt{\sum_{\text{all } x} (x - \mu)^2 \cdot P(X = x)}$$

2.9 FAQ: 초심자를 위한 질문과 답변

1. **Q: 백분위수와 Z-점수는 모두 상대적 위치를 나타내는데, 어떤 차이가 있나요? A:** 백분위수는 특정 값보다 작은 데이터의 '비율'을 직접적으로 보여줍니다 (예: 95%보다 높다). 반면 Z-점수는 평균으로부터 '표준편차 단위로 얼마나 떨어져 있는지'를 나타냅니다. Z-점수는 정규 분포의 특성을 활용하여 더 정밀한 확률 계산이나 다른 분포와의 비교에 유용합니다.
2. **Q: 경험적 규칙은 언제 사용할 수 있나요? 항상 정확한가요? A:** 경험적 규칙은 데이터 분포가 '종 모양'이고 '대칭적'일 때 (즉, 정규 분포를 따를 때) 가장 잘 적용됩니다. 이는 대략적인 추정치를 빠르게 얻는데 유용하지만, 정확한 백분위수를 얻기 위해서는 Excel의 NORM.DIST 함수와 같은 도구를 사용하는 것이 좋습니다.
3. **Q: 이산 확률 변수와 연속 확률 변수를 구분하는 것이 왜 중요한가요? A:** 두 변수의 유형에 따라 확률을 계산하는 방법과 사용하는 통계 모델이 달라지기 때문입니다. 이산 변수는 각 점에서의 확률을, 연속 변수는 특정 구간에서의 확률을 다룹니다. 올바른 유형을 식별해야 적절한 분석 기법을 적용할 수 있습니다.
4. **Q: 초콜릿 바의 칼로리 수는 연속 변수라고 했는데, 왜 이산처럼 기록될 수 있다고 하나요? A:** 칼로리는 이론적으로 소수점 이하 무한한 값을 가질 수 있는 연속적인 양입니다. 하지만 실제 제품 라벨에서는 편의상 200kcal, 205kcal 등과 같이 정수나 특정 소수점 자리로 반올림하여 '표시'합니다. 이처럼 연속적인 데이터를 이산적으로 '기록'하는 경우가 있을 수 있습니다.
5. **Q: 기댓값은 항상 데이터 세트 내에 실제로 존재하는 값인가요? A:** 아닙니다. 기댓값은 '장기적으로 평균적으로 기대되는 값'을 의미하며, 실제 데이터 세트에 존재하지 않을 수도 있습니다. 예를 들어, 형제자매 수의 기댓값이 1.8명이었지만, 실제로는 1명이나 2명은 있어도 1.8명의 형제자매를 가진 사람은 없습니다.

2.10 개요

이 문서는 BADM-572 과목의 'Exploring and Producing Data Module 2' 중 파트 3/5에 해당하는 내용을 다룹니다. 주요 내용은 이산 확률 변수의 기댓값과 표준 편차를 Excel로 계산하는 방법, 그리고 연속 확률 분포의 핵심인 정규 분포의 개념과 특성, 마지막으로 Excel을 활용하여 정규 분포 확률을 계산하는 실습입니다. 데이터 기반 의사 결정을 위한 통계적 도구의 실제 적용 방법을 이해하고, 특히 Excel 함수 사용법을 익히는 데 중점을 둡니다.

2.11 용어 정리

용어	쉬운 설명	원어	비고
기댓값	확률 변수가 가질 수 있는 값들의 평균	Expected Value (Mean, μ)	장기적으로 기대되는 평균
표준 편차	데이터가 평균으로부터 얼마나 퍼져있는지 나타내는 척도	Standard Deviation (σ)	변동성 측정
이산 확률 변수	셀 수 있는 유한하거나 가산 무한한 값을 가지는 변수	Discrete Random Variable	주사위 눈금, 수요량 등
연속 확률 변수	특정 구간 내의 모든 실숫값을 가질 수 있는 변수	Continuous Random Variable	온도, 시간, 키 등
정규 분포	종 모양의 대칭적인 확률 분포	Normal Distribution	자연 현상에서 흔히 관찰됨
표준 정규 분포	평균이 0이고 표준 편차가 1인 정규 분포	Standard Normal Distribution	Z-분포라고도 함
Z-점수	특정 값이 평균으로부터 몇 표준 편차 떨어져 있는지 나타내는 값	Z-score	데이터를 표준화하는 방법
누적 분포 함수	특정 값 이하의 확률을 나타내는 함수	Cumulative Distribution Function (CDF)	Excel의 NORM.DIST 함수에서 cumulative=TRUE
SUM 함수	지정된 범위의 숫자들을 모두 더하는 Excel 함수	SUM	합계 계산
SUMPRODUCT 함수	여러 배열의 해당 요소들을 곱한 후 그 합계를 반환하는 Excel 함수	SUMPRODUCT	기댓값, 분산 계산에 유용
SQRT 함수	숫자의 양의 제곱근을 반환하는 Excel 함수	SQRT	표준 편차 계산 시 사용
NORM.DIST 함수	정규 분포의 확률을 계산하는 Excel 함수	NORM.DIST	누적 확률 계산

2.12 핵심 개념 및 원리

2.12.1 이산 확률 변수의 기댓값과 표준 편차

이산 확률 변수는 주사위 눈금이나 특정 제품의 일일 수요량처럼 셀 수 있는 값을 가지는 변수입니다. 이러한 변수의 기댓값(평균)과 표준 편차는 데이터의 중심 경향과 변동성을 이해하는 데 필수적입니다.

기댓값 (Expected Value, μ)

기댓값은 이산 확률 변수가 가질 수 있는 각 값에 해당 확률을 곱한 후 모두 더한 값입니다. 이는 장기적으로 해당 변수가 취할 것으로 예상되는 평균적인 값입니다.

$$E(X) = \mu = \sum_{i=1}^k x_i p(x_i) = x_1 p(x_1) + x_2 p(x_2) + \cdots + x_k p(x_k)$$

여기서 x_i 는 확률 변수가 가질 수 있는 각 값이고, $p(x_i)$ 는 해당 값을 가질 확률입니다.

표준 편차 (Standard Deviation, σ)

표준 편차는 데이터가 기댓값(평균)으로부터 얼마나 퍼져 있는지를 나타내는 척도입니다. 표준 편차가 클수록 데이터의 변동성이 크고, 작을수록 데이터가 평균에 밀집되어 있습니다. 분산(σ^2)은 각 값에서 평균을 뺀 후 제곱하고 해당 확률을 곱한 값들을 모두 더한 것입니다. 표준 편차는 분산의 양의 제곱근입니다.

$$\sigma = \sqrt{\sum_{i=1}^k (x_i - \mu)^2 p(x_i)} = \sqrt{(x_1 - \mu)^2 p(x_1) + (x_2 - \mu)^2 p(x_2) + \cdots + (x_k - \mu)^2 p(x_k)}$$

2.12.2 연속 확률 분포와 정규 분포

연속 확률 변수는 온도, 키, 시간과 같이 특정 구간 내의 모든 실숫값을 가질 수 있는 변수입니다. 이 변수들은 특정 값에서 정의되지 않고, 값의 구간에 걸쳐 정의되며, 곡선 아래의 면적으로 확률을 나타냅니다.

연속 확률 변수의 특징

- 특정 값에서 정의되지 않고, 값의 구간에 걸쳐 정의됩니다.
- 확률은 곡선 아래의 면적으로 표현됩니다 (고급 수학에서는 적분으로 계산).
- 특정 단일 값을 관측할 확률은 0입니다. 왜냐하면 변수가 취할 수 있는 값의 수가 무한하기 때문입니다.

연속 확률 분포의 속성

확률 함수 $p(x)$ 는 다음을 만족해야 합니다:

- 모든 x 에 대해 $P(x) \geq 0$: 어떤 값도 음의 확률을 가질 수 없습니다.
- 곡선 아래의 총 면적은 1: 모든 가능한 확률을 합하면 1(100%)이 됩니다.

정규 분포 (Normal Distribution)

정규 분포는 연속 확률 변수에 사용되는 가장 잘 알려진 분포 중 하나이며, 종 모양(bell-shaped)의 곡선 형태를 가집니다. 특정 조건 하에서는 이산 변수의 분포를 근사하는 데도 사용될 수 있어 매우 중요합니다.

정규 분포의 정의

정규 분포는 다음 두 가지 매개변수에 의해 정의됩니다:

1. 평균 (μ): 분포의 중심을 나타내며, 곡선은 평균을 중심으로 대칭입니다.
2. 표준 편차 (σ): 분포의 모양(퍼짐 정도)을 결정합니다. 표준 편차가 클수록 곡선은 더 넓고 낮아지며, 작을수록 더 좁고 높아집니다.

정규 분포 곡선 예시 (시각적 설명)

평균과 표준 편차에 따른 정규 분포의 모양 변화:

- **평균의 영향 (슬라이드 99):**
 - 평균 500, 표준 편차 15인 곡선은 500에서 가장 높습니다.
 - 평균 300, 표준 편차 15인 곡선은 300에서 가장 높습니다.
 - 표준 편차가 같으면 곡선의 모양(폭과 높이)은 같고, 평균에 따라 중심 위치만 달라집니다.
- **표준 편차의 영향 (슬라이드 100):**
 - 평균 500, 표준 편차 15인 곡선은 넓게 퍼져 있습니다.
 - 평균 500, 표준 편차 5인 곡선은 평균 500에서 더 높고 날씬합니다.
 - 표준 편차가 클수록 값들이 더 넓게 퍼져 있고, 작을수록 값들이 평균에 더 밀집되어 있습니다. 즉, 평균이 더 나은 대표성을 가집니다.

Figure 2.4: 평균과 표준 편차에 따른 정규 분포의 모양 변화 예시

그림 2.4 설명: 정규 분포는 평균에 따라 중심이 이동하고, 표준 편차에 따라 퍼짐 정도(폭)가 달라지는 종 모양의 곡선입니다. 표준 편차가 클수록 곡선은 낮고 넓게 퍼지며, 작을수록 높고 좁게 집중됩니다.

정규 분포의 주요 속성

- **대칭성:** 곡선은 평균(μ)을 중심으로 완벽하게 대칭입니다. 평균은 동시에 중앙값(median)이기도 합니다.

- **꼬리의 무한 확장:** 분포의 양쪽 꼬리는 수평축에 점점 가까워지지만, 결코 닿지 않고 무한히 뻗어 나갑니다. 왼쪽은 음의 무한대, 오른쪽은 양의 무한대로 향합니다.
- **총 면적:** 곡선 아래의 총 면적은 항상 1(100%)입니다.
- **면적의 분할:** 평균의 오른쪽 면적은 0.5이고, 왼쪽 면적도 0.5입니다. 이 둘을 합하면 1(100%)입니다.

표준 정규 곡선 (Standard Normal Curve) 및 Z-점수

서로 다른 평균과 표준 편차를 가진 여러 정규 분포를 비교하거나 특정 확률을 계산할 때, 각 분포에 대해 개별적으로 계산하는 것은 비효율적입니다. 이를 위해 모든 정규 분포를 하나의 표준화된 형태로 변환하는 방법이 있는데, 이것이 바로 표준 정규 분포(Standard Normal Distribution)입니다.

표준 정규 분포의 특징

- **평균 (μ):** 0
- **표준 편차 (σ):** 1
- 표준 정규 분포의 확률 변수를 **표준 점수(standard score)** 또는 **Z-점수(z-score)**라고 부릅니다.

Z-점수 (Z-score)

Z-점수는 특정 데이터 값(X)이 평균(μ)으로부터 몇 표준 편차(σ) 떨어져 있는지를 나타냅니다.

$$z = \frac{\text{관심 값} - \text{모든 값의 평균}}{\text{모든 값의 표준 편차}} = \frac{X - \mu}{\sigma}$$

Z-점수를 사용하면 어떤 정규 분포든 표준 정규 분포로 변환하여, 표준화된 표나 소프트웨어(예: Excel의 NORM.DIST 함수)를 통해 쉽게 확률을 계산할 수 있습니다.

정규 분포를 표준 정규 분포로 표준화하는 과정

문제: 평균(μ) 1000, 표준 편차(σ) 10인 정규 분포에서 $P(995 \leq X \leq 1005)$ 는 얼마인가?

- **원래 분포 (슬라이드 103):** 평균 1000, 표준 편차 10인 종 모양 곡선에서 995와 1005 사이의 면적을 구합니다.
- **Z-점수 변환 (표준화):**
 - $X = 995$ 일 때, $z = (995 - 1000) \div 10 = -0.5$
 - $X = 1005$ 일 때, $z = (1005 - 1000) \div 10 = 0.5$
- **표준 정규 분포 (슬라이드 104):** 평균 0, 표준 편차 1인 종 모양 곡선에서 -0.5와 0.5 사이의 면적을 구합니다.

결론: $P(995 \leq X \leq 1005)$ 는 $P(-0.5 \leq Z \leq 0.5)$ 와 동일하며, 이 값은 0.3829입니다.

Figure 2.5: 정규 분포를 표준 정규 분포로 표준화하는 과정

그림 2.5 설명: Z-점수를 통해 어떤 정규 분포든 평균 0, 표준 편차 1인 표준 정규 분포로 변환할 수 있습니다. 이렇게 변환된 Z-점수를 사용하면 표준화된 표나 Excel 함수를 통해 확률을 쉽게 계산할 수 있습니다.

표준 편차와 경험적 규칙 (Empirical Rule)

표준 편차는 데이터의 변동성을 측정하는 가장 일반적인 척도입니다. 정규 분포에서는 평균으로부터의 표준 편차 거리에 따라 데이터가 분포하는 비율이 예측 가능합니다.

경험적 규칙 (Empirical Rule)

정규 분포를 따르는 대부분의 데이터 세트에서:

- 약 **68%**의 관측치가 평균으로부터 **1 표준 편차** 이내에 있습니다 ($\mu \pm 1\sigma$).
- 약 **95.45%**의 관측치가 평균으로부터 **2 표준 편차** 이내에 있습니다 ($\mu \pm 2\sigma$).
- 약 **99.73%**의 관측치가 평균으로부터 **3 표준 편차** 이내에 있습니다 ($\mu \pm 3\sigma$).

3 표준 편차를 벗어나는 관측치는 드물게 발생하며, 이를 **이상치(outliers)**로 간주할 수 있습니다.

표준 편차에 따른 정규 분포의 데이터 포함 비율

경험적 규칙 시각화:

- **1 표준 편차 이내 ($\mu \pm 1\sigma$):** 표준 정규 분포에서 $Z=-1$ 부터 $Z=1$ 까지의 면적은 약 68%입니다.
 - **2 표준 편차 이내 ($\mu \pm 2\sigma$):** 표준 정규 분포에서 $Z=-2$ 부터 $Z=2$ 까지의 면적은 약 95.45%입니다.
 - **3 표준 편차 이내 ($\mu \pm 3\sigma$):** 표준 정규 분포에서 $Z=-3$ 부터 $Z=3$ 까지의 면적은 약 99.73%입니다.
- 이 규칙은 데이터의 변동성을 이해하고 이상치를 식별하는 데 유용합니다.

Figure 2.6: 표준 편차에 따른 정규 분포의 데이터 포함 비율 (경험적 규칙)

그림 3.4 설명: 정규 분포에서 평균을 중심으로 1, 2, 3 표준 편차 이내에 포함되는 데이터의 비율을 보여주는 경험적 규칙은 데이터의 분포 특성을 직관적으로 이해하는 데 도움을 줍니다.

2.13 절차 및 방법: Excel을 활용한 통계 계산

2.13.1 이산 확률 변수의 기댓값 및 표준 편차 계산 (Excel)

편의점 관리자의 제품 수요 데이터를 예시로 들어, Excel에서 기댓값과 표준 편차를 계산하는 과정을 단계별로 설명합니다.

문제 상황

편의점 관리자는 판매하는 제품 중 하나의 수요를 이해하여 매일 재고량을 더 잘 결정하고자 합니다. 그녀는 몇 주 동안 다음 데이터를 수집했습니다. 이 데이터를 기반으로 예상 수요(기댓값)와 그 표준 편차는 얼마입니까?

일일 수요 (Daily Demand)	발생 횟수 (Occurrence of Demand)
1	3
2	10
...	...
20	12

예상 수요 데이터 세트 (일부)

단계 1: 총 발생 횟수 계산

각 일일 수요가 발생한 총 횟수를 알아야 각 수요의 확률을 계산할 수 있습니다.

1. Excel 시트에서 '발생 횟수' 열 옆에 '합계 (Sum)' 셀을 만듭니다.
2. '합계' 셀 옆에 =SUM(을 입력합니다.
3. '발생 횟수' 열의 모든 값을 선택합니다 (첫 번째 셀을 선택한 후 Ctrl + Shift + 아래쪽 화살표를 누르면 편리합니다).
4. 괄호를 닫고 Enter를 누릅니다.

결과

총 발생 횟수는 140입니다.

단계 2: 각 수요의 확률 계산

각 일일 수요가 발생할 확률은 해당 수요의 발생 횟수를 총 발생 횟수로 나눈 값입니다.

1. '발생 횟수' 열 옆에 '확률 (Probability)'이라는 새 열을 만듭니다.
2. 첫 번째 확률 값을 계산합니다: 첫 번째 '발생 횟수' 셀을 선택하고 총 발생 횟수 셀로 나눕니다. 예를 들어, =B2/I1 (여기서 B2는 첫 번째 발생 횟수 값, I1은 총 합계 값).
3. **중요:** 총 발생 횟수 셀(예: I1)을 절대 참조로 만듭니다. 셀을 선택한 상태에서 F4 키를 누르면 \$I\$1과 같이 달러 기호가 붙습니다. 이렇게 하면 수식을 아래로 복사할 때 이 셀이 고정됩니다.
4. 수식을 입력한 후 Enter를 누릅니다.
5. 첫 번째 확률 셀을 선택하고, 셀의 오른쪽 아래 모서리에 있는 채우기 핸들('+' 모양)을 두 번 클릭하거나 아래로 드래그하여 나머지 확률 값을 자동으로 채웁니다.

확률 합계 확인

모든 확률 값의 합계는 1이 되어야 합니다. '확률' 열의 끝에 =SUM() 함수를 사용하여 합계를 확인합니다. 합계가 1이 아니면 계산에 오류가 있을 수 있습니다.

단계 3: 기댓값 (평균 수요) 계산

기댓값은 각 일일 수요 값에 해당 확률을 곱한 값들을 모두 더한 것입니다. Excel의 SUMPRODUCT 함수를 사용하면 이 과정을 한 번에 처리할 수 있습니다.

1. '확률' 열의 오른쪽에 '기댓값 (Expected value (mean))'이라는 셀을 만듭니다.
2. 이 셀에 =SUMPRODUCT(을 입력합니다.
3. 첫 번째 배열로 '일일 수요' 열 전체를 선택합니다 (예: A2:A21).
4. 쉼표(,)를 입력합니다.
5. 두 번째 배열로 '확률' 열 전체를 선택합니다 (예: C2:C21).
6. 괄호를 닫고 Enter를 누릅니다.

결과

계산된 기댓값(평균 수요)은 11.49입니다.

단계 4: 표준 편차 계산을 위한 중간 값 계산 $((x - \mu)^2)$

표준 편차를 계산하기 위해 각 일일 수요 값에서 평균(기댓값)을 뺀 후 제곱한 값을 계산하는 중간 열을 만듭니다.

1. '확률' 열 옆에 '(x-mu)^2'라는 새 열을 만듭니다.
2. 첫 번째 셀에 =(A2-\$I\$4)^2와 같이 수식을 입력합니다. (여기서 A2는 첫 번째 일일 수요 값, \$I\$4는 기댓값 셀이며, F4를 눌러 절대 참조로 만듭니다).
3. Enter를 누른 후, 채우기 핸들을 사용하여 나머지 셀을 자동으로 채웁니다.

단계 5: 표준 편차 계산

이제 표준 편차를 계산할 준비가 되었습니다. 분산(σ^2)은 $(x - \mu)^2$ 값에 해당 확률을 곱한 값들을 모두 더한 것이고, 표준 편차는 이 분산의 제곱근입니다.

1. '기댓값' 셀 아래에 '표준 편차 (Standard deviation)' 셀을 만듭니다.
2. 이 셀에 =SQRT(SUMPRODUCT(을 입력합니다.
3. 첫 번째 배열로 '(x-mu)^2' 열 전체를 선택합니다 (예: D2:D21).
4. 쉼표(,)를 입력합니다.
5. 두 번째 배열로 '확률' 열 전체를 선택합니다 (예: C2:C21).
6. 괄호를 닫고 Enter를 누릅니다.

결과

계산된 표준 편차는 6.205입니다. 이는 수요의 변동성이 약 6.205 정도임을 의미합니다. 평균 수요 11.49를 기준으로 1 표준 편차 범위는 약 5.28 (11.49 - 6.205)에서 17.69 (11.49 + 6.205) 사이입니다.

2.13.2 정규 분포 확률 계산 (Excel)

Excel의 NORM.DIST 함수를 사용하여 정규 분포의 확률을 계산하는 방법을 알아봅니다. 이 함수는 특정 값 이하의 누적 확률을 반환합니다.

문제 상황

평균이 1000이고 표준 편차가 10인 정규 분포가 있습니다. 확률 변수 X 가 995와 1005 사이에 있을 확률, 즉 $P(995 \leq X \leq 1005)$ 는 얼마입니까?

단계 1: 문제 시각화

정규 분포 곡선을 그리고, 995와 1005 사이의 면적을 색칠하여 구하고자 하는 확률을 시각적으로 이해합니다. Excel의 NORM.DIST 함수는 항상 특정 값 이하의 누적 확률을 반환합니다. 따라서 $P(995 \leq X \leq 1005)$ 를 구하려면, $P(X \leq 1005)$ 에서 $P(X \leq 995)$ 를 빼야 합니다.

정규 분포에서 특정 구간 확률 계산 시각화

시각적 이해:

- 평균 1000인 종 모양의 정규 분포 곡선을 그립니다.
- 우리가 찾고자 하는 $P(995 \leq X \leq 1005)$ 는 995와 1005 사이의 면적입니다.
- Excel의 NORM.DIST 함수는 항상 왼쪽 꼬리부터 특정 값까지의 누적 확률을 계산합니다.
- 따라서 $P(X \leq 1005)$ 는 1005 왼쪽의 모든 면적을 나타냅니다 (큰 영역).
- $P(X \leq 995)$ 는 995 왼쪽의 모든 면적을 나타냅니다 (작은 영역).
- 우리가 원하는 $P(995 \leq X \leq 1005)$ 는 $P(X \leq 1005) - P(X \leq 995)$ 로 계산할 수 있습니다.

Figure 2.7: 정규 분포에서 특정 구간 확률 계산 시각화

그림 2.7 설명: 전체 노란색 영역은 $P(X \leq 1005)$ 를 나타내고, 녹색 영역은 $P(X \leq 995)$ 를 나타냅니다. 우리가 구하고자 하는 파란색 영역($P(995 \leq X \leq 1005)$)은 노란색 영역에서 녹색 영역을 뺀 값과 같습니다.

단계 2: $P(X \leq 1005)$ 계산

1. Excel 시트에서 평균(1000)과 표준 편차(10)를 입력할 셀을 준비합니다.
2. 'p($x \leq 1005$)'와 같은 레이블을 가진 셀을 만듭니다.
3. 해당 셀에 =NORM.DIST(를 입력합니다.
4. 함수 인수를 채웁니다:
 - x: 1005 (관심 있는 값)
 - mean: 1000 (평균)
 - standard_dev: 10 (표준 편차)
 - cumulative: TRUE 또는 1 (누적 분포 함수를 사용하겠다는 의미)
5. 완성된 수식은 =NORM.DIST(1005, 1000, 10, TRUE) 또는 =NORM.DIST(1005, 1000, 10, 1)입니다.
6. Enter를 누릅니다.

결과

$P(X \leq 1005)$ 는 약 0.6915입니다.

단계 3: $P(X \leq 995)$ 계산

1. 'p(x ≤ 995)'와 같은 레이블을 가진 셀을 만듭니다.
2. 해당 셀에 =NORM.DIST(를 입력합니다.
3. 함수 인수를 채웁니다:
 - x: 995
 - mean: 1000
 - standard_dev: 10
 - cumulative: TRUE 또는 1
4. 완성된 수식은 =NORM.DIST(995, 1000, 10, TRUE) 또는 =NORM.DIST(995, 1000, 10, 1)입니다.
5. Enter를 누릅니다.

결과

$P(X \leq 995)$ 는 약 0.3085입니다.

단계 4: $P(995 \leq X \leq 1005)$ 계산

단계 2에서 얻은 값에서 단계 3에서 얻은 값을 뺍니다.

1. 'p(995 ≤ x ≤ 1005)'와 같은 레이블을 가진 셀을 만듭니다.
2. 이 셀에 이전 단계에서 계산된 두 셀을 참조하는 수식을 입력합니다. 예를 들어, $P(X \leq 1005)$ 가 B7 셀에 있고 $P(X \leq 995)$ 가 B8 셀에 있다면, =B7 - B8을 입력합니다.
3. Enter를 누릅니다.

최종 결과

$P(995 \leq X \leq 1005)$ 는 약 0.38292입니다. 이는 평균이 1000이고 표준 편차가 10인 정규 분포에서 값이 995에서 1005 사이에 있을 확률이 38.29%임을 의미합니다.

2.14 실습: 표준 편차 근사치 추정**문제**

평균 50을 중심으로 하는 두 개의 정규 분포 곡선 A와 B가 있습니다. 각 곡선의 표준 편차를 근사해 보세요.

그림 2.8 설명: 두 곡선 모두 평균이 50입니다. 곡선 A는 10에서 90까지 넓게 퍼져 있고, 곡선 B는 25에서 75까지 좁고 높게 퍼져 있습니다.

두 정규 분포 곡선의 표준 편차 추정 연습

곡선 A: 평균 50, x축 범위 약 10에서 90. 최고점 y축 0.025. 곡선 B: 평균 50, x축 범위 약 25에서 75. 최고점 y축 0.05 (더 높고 날씬함).

Figure 2.8: 두 정규 분포 곡선의 표준 편차 추정 연습

해답

경험적 규칙에 따르면, 대부분의 데이터(약 99.7%)는 평균으로부터 3 표준 편차 이내에 분포합니다. 이 점을 활용하여 표준 편차를 근사할 수 있습니다.

1. 곡선 A:

- 곡선 A는 평균 50에서 약 95까지 꼬리가 매우 얇아지는 것으로 보입니다.
- 이는 95가 대략 평균으로부터 3 표준 편차 떨어진 값이라고 가정할 수 있습니다.
- 평균에서 95까지의 거리는 $95 - 50 = 45$ 입니다.
- 이 거리가 3 표준 편차에 해당하므로, 표준 편차는 $45 \div 3 = 15$ 로 근사할 수 있습니다.

2. 곡선 B:

- 곡선 B는 평균 50에서 약 75까지 꼬리가 얇아지는 것으로 보입니다.
- 이는 75가 대략 평균으로부터 3 표준 편차 떨어진 값이라고 가정할 수 있습니다.
- 평균에서 75까지의 거리는 $75 - 50 = 25$ 입니다.
- 이 거리가 3 표준 편차에 해당하므로, 표준 편차는 $25 \div 3 \approx 8.33$ 으로 근사할 수 있습니다 (강의에서는 약 8로 언급).

결론

곡선 A의 표준 편차는 약 15이고, 곡선 B의 표준 편차는 약 8입니다. 표준 편차가 작을수록 곡선이 더 높고 날씬하며, 값이 평균에 더 밀집되어 있음을 시각적으로 확인할 수 있습니다.

2.15 정규 분포의 모델로서의 활용

완벽하게 대칭적인 곡선은 현실 세계에서 드물지만, 많은 실제 현상들이 거의 정규 분포를 따릅니다. 이러한 특성 덕분에 정규 분포는 다양한 분야에서 중요한 통계 모델로 활용됩니다.

정규 분포의 활용

- **확률 평가:** 특정 결과에 대한 확률을 평가하는 모델로 사용됩니다.
- **표본 정보 활용:** 표본 정보를 사용하여 모집단에 대한 이해를 얻는 데 도움을 줍니다.
- **이산 확률 변수 근사:** 특정 조건 하에서 이산 확률 변수 및 분포를 근사하는 데 유용하게 사용될 수 있습니다.

이러한 이유로 정규 분포는 통계학 분야에서 가장 중요한 확률 분포 중 하나로 간주됩니다.

2.16 개요

이 문서는 **BADM-572: Data-Driven Decision Making** 과목의 **Exploring and Producing Data Module 2** 중 파트 4/5에 해당하는 내용을 다룹니다. 주요 목표는 Excel을 활용하여 정규 분포(Normal Distribution)와 표준 정규 분포(Standard Normal Distribution)와 관련된 다양한 확률을 계산하는 방법을 학습하는 것입니다. 특히, **NORM.DIST**, **NORM.S.DIST**, **NORM.INV**, **NORM.S.INV**와 같은 핵심 Excel 함수들의 사용법과 그 차이점을 상세히 설명합니다. 이 문서를 통해 비전공자나 처음 배우는 사람도 정규 분포의 개념을 이해하고, 실제 데이터 분석에 Excel 함수를 효과적으로 적용할 수 있도록 돕습니다.

2.17 용어 정리

Table 2.1: 주요 용어 설명

용어	쉬운 설명	원어	비고
정규 분포	종 모양의 대칭적인 확률 분포로, 자연 현상에서 흔히 관찰됩니다.	Normal Distribution	평균과 표준 편차로 정의됩니다.
표준 정규 분포	평균이 0이고 표준 편차가 1인 특별한 정규 분포입니다.	Standard Normal Distribution	모든 정규 분포는 표준 정규 분포로 변환될 수 있습니다.
Z-점수	특정 데이터 포인트가 평균에서 표준 편차의 몇 배만큼 떨어져 있는지를 나타내는 값입니다.	Z-score	데이터를 표준화하여 비교할 때 사용됩니다.
누적 분포 함수	특정 값보다 작거나 같은 확률을 나타내는 함수입니다.	Cumulative Distribution Function (CDF)	Excel 함수에서 'cumulative=TRUE'로 설정할 때 계산됩니다.
확률 질량 함수	이산 확률 변수에서 특정 값이 나타날 확률을 나타내는 함수입니다.	Probability Mass Function (PMF)	연속 분포에서는 특정 점의 확률이 0이므로 거의 사용되지 않습니다.
백분위수	전체 데이터 중 특정 값보다 작거나 같은 데이터의 비율을 나타냅니다.	Percentile	예를 들어, 95백분위수는 95%의 데이터가 그 값보다 작거나 같음을 의미합니다.
평균	데이터 세트의 중심 경향을 나타내는 값입니다.	Mean (μ)	모든 값을 더한 후 개수로 나눈 값입니다.
표준 편차	데이터가 평균으로부터 얼마나 퍼져 있는지를 나타내는 척도입니다.	Standard Deviation (σ)	값이 클수록 데이터의 산포도가 큼니다.
NORM.DIST	일반 정규 분포의 확률을 계산하는 Excel 함수입니다.	NORM.DIST	X, 평균, 표준 편차, 누적 여부를 인수로 받습니다.
NORM.S.DIST	표준 정규 분포의 확률을 계산하는 Excel 함수입니다.	NORM.S.DIST	Z-점수와 누적 여부를 인수로 받습니다.
NORM.INV	일반 정규 분포에서 주어진 확률에 해당하는 X 값을 찾는 Excel 함수입니다.	NORM.INV	확률, 평균, 표준 편차를 인수로 받습니다.
NORM.S.INV	표준 정규 분포에서 주어진 확률에 해당하는 Z-점수를 찾는 Excel 함수입니다.	NORM.S.INV	확률만을 인수로 받습니다.

2.18 핵심 개념 및 원리

정규 분포는 통계학에서 가장 중요하고 널리 사용되는 확률 분포 중 하나입니다. 많은 자연 현상, 사회 현상, 측정 오차 등이 정규 분포를 따르는 경향이 있습니다. 정규 분포는 종 모양(bell-shaped)의 대칭적인 곡선으로 나타나며, 평균(μ)과 표준 편차(σ)라는 두 가지 매개변수에 의해 완전히 정의됩니다.

- **평균 (μ):** 분포의 중심을 나타냅니다. 곡선의 가장 높은 지점입니다.
- **표준 편차 (σ):** 데이터가 평균으로부터 얼마나 퍼져 있는지를 나타냅니다. 표준 편차가 작으면 데이터가 평균 주변에 밀집되어 있고, 크면 넓게 퍼져 있습니다.

2.18.1 표준화 (Z-점수)

서로 다른 평균과 표준 편차를 가진 여러 정규 분포를 비교하거나 분석할 때, 이들을 하나의 공통된 형태로 변환하는 것이 유용합니다. 이것이 바로 **표준화(Standardization)** 과정이며, 그 결과로 얻어지는 값이 **Z-점수(Z-score)**입니다.

- **Z-점수란?**
 1. **한 줄 핵심 요약:** 특정 데이터 포인트가 평균으로부터 표준 편차의 몇 배만큼 떨어져 있는지를 나타내는 값입니다.
 2. **직관적 예시/비유:** 당신이 시험에서 80점을 받았는데, 평균이 70점이고 표준 편차가 10점이라면, 당신은 평균보다 10점 높게 받은 것이고, 이는 표준 편차 1개만큼 높은 것입니다. 이때 Z-점수는 +1이 됩니다. 만약 60점을 받았다면, 평균보다 10점 낮으므로 Z-점수는 -1이 됩니다.
 3. **기술적 정확한 설명:** 원시 데이터 값(X)을 평균(μ)을 빼고 표준 편차(σ)로 나누어 계산합니다.

$$Z = \frac{X - \mu}{\sigma}$$

Z-점수를 통해 모든 정규 분포는 **표준 정규 분포(Standard Normal Distribution)**로 변환될 수 있습니다. 표준 정규 분포는 항상 평균이 0이고 표준 편차가 1인 특성을 가집니다. 이러한 표준화를 통해 우리는 어떤 정규 분포에서든 특정 값의 상대적인 위치와 확률을 쉽게 비교하고 계산할 수 있습니다.

2.18.2 누적 확률 (Cumulative Probability)

정규 분포에서 특정 값에 대한 확률을 계산할 때, 우리는 주로 **누적 확률(Cumulative Probability)**을 사용합니다. 누적 확률은 특정 값(x)보다 작거나 같은 모든 값의 확률을 의미하며, 이는 정규 분포 곡선 아래의 왼쪽 면적에 해당합니다.

• 누적 확률이란?

1. **한 줄 핵심 요약:** 특정 지점까지의 모든 확률을 합산한 값으로, 곡선 아래의 왼쪽 면적을 나타냅니다.
2. **직관적 예시/비유:** 당신이 시험에서 80점을 받았고, 이 점수가 상위 10%에 해당한다고 가정해 봅시다. 이는 90%의 학생들이 80점보다 낮거나 같은 점수를 받았다는 의미입니다. 이때 80점까지의 누적 확률은 0.90 (90%)이 됩니다.
3. **기술적 정확한 설명:** 확률 변수 X 가 특정 값 x 보다 작거나 같은 확률 $P(X \leq x)$ 를 의미합니다. Excel의 정규 분포 함수들은 기본적으로 이 누적 확률을 계산합니다.

주의

확률 질량 함수(Probability Mass Function, PMF)와 누적 분포 함수(Cumulative Distribution Function, CDF)의 차이: 연속 확률 분포(정규 분포와 같이)에서는 특정 한 점의 확률은 0입니다. 예를 들어, 키가 정확히 170.000...cm일 확률은 0입니다. 따라서 연속 분포에서는 PMF 대신 CDF를 사용하여 특정 구간의 확률이나 특정 값보다 작거나 같은 확률을 계산합니다. Excel 함수에서 `cumulative` 인수를 TRUE (또는 1)로 설정하면 CDF를 계산하고, FALSE (또는 0)로 설정하면 확률 밀도 함수(Probability Density Function, PDF)의 값을 반환합니다. PDF 값은 확률이 아니며, 곡선의 높이를 나타냅니다. 일반적으로 확률 계산에는 CDF를 사용합니다.

2.19 Lesson 2-5.3: Excel을 이용한 표준 정규 분포

이 섹션에서는 Excel의 `NORM.S.DIST` 함수를 사용하여 표준 정규 분포의 확률을 계산하는 방법을 배웁니다. `NORM.S.DIST`는 표준 정규 분포(평균 0, 표준 편차 1)에 특화된 함수입니다.

2.19.1 문제 정의 및 Z-점수 계산

우리는 평균이 1,000이고 표준 편차가 10인 정규 분포에서, 무작위로 관찰된 값이 995와 1,005 사이에 있을 확률을 알고 싶습니다. 즉, $P(995 \leq X \leq 1005)$ 를 계산하는 것이 목표입니다.

이 문제를 해결하기 위해 먼저 원시 값(X)을 Z-점수로 표준화합니다. Z-점수 공식은 $Z = (X - \mu) \div \sigma$ 입니다.

- $X = 995$ 일 때: $z = (995 - 1000) \div 10 = -0.5$

- $X = 1005$ 일 때: $z = (1005 - 1000) \div 10 = 0.5$

따라서 우리는 $P(-0.5 \leq Z \leq 0.5)$ 를 계산해야 합니다.

Figure 2.9: 표준 정규 곡선 (Z-점수 -0.5에서 0.5 사이 면적)

슬라이드에는 평균이 0이고 x 축이 -3에서 3까지, y 축이 0.0에서 0.4까지 퍼져 있는 종 모양의 대칭적인 표준 정규 분포 곡선이 표시됩니다. 곡선 아래 -0.5에서 0.5까지의 면적이 파란색으로 채워져 있습니다. 이는 $P(-0.5 \leq Z \leq 0.5)$ 를 시각적으로 나타냅니다. 슬라이드 하단에는 *NORM.S.DIST* 함수가 강조되어 있습니다.

2.19.2 Excel의 NORM.S.DIST 함수 사용

NORM.S.DIST 함수는 표준 정규 분포의 누적 확률을 계산합니다. 이 함수는 Z-점수와 누적 여부를 인수로 받습니다. 평균과 표준 편차는 표준 정규 분포의 정의에 따라 0과 1로 고정되어 있기 때문에 별도로 입력할 필요가 없습니다.

- 함수 구문: `=NORM.S.DIST(z, cumulative)`
- 인수 설명:
 - **z**: 확률을 계산하려는 Z-점수입니다.
 - **cumulative**: 누적 분포 함수를 계산할지 여부를 지정합니다. — **TRUE** (또는 1): 누적 분포 함수를 반환합니다 ($P(Z \leq z)$). — **FALSE** (또는 0): 확률 밀도 함수 값을 반환합니다. (일반적으로 확률 계산에는 **TRUE**를 사용합니다.)

예제

단계별 계산: 우리는 $P(-0.5 \leq Z \leq 0.5)$ 를 찾고 있습니다. 이는 $P(Z \leq 0.5) - P(Z \leq -0.5)$ 로 계산할 수 있습니다.

1. **$P(Z \leq 0.5)$ 계산:** Excel에서 `=NORM.S.DIST(0.5, TRUE)`를 입력합니다. 결과는 약 0.6914입니다. 이는 Z-점수가 0.5보다 작거나 같은 확률이 69.14%임을 의미합니다.
2. **$P(Z \leq -0.5)$ 계산:** Excel에서 `=NORM.S.DIST(-0.5, TRUE)`를 입력합니다. 결과는 약 0.3085입니다. 이는 Z-점수가 -0.5보다 작거나 같은 확률이 30.85%임을 의미합니다.
3. **두 값 사이의 확률 계산:** 두 결과를 빼면 됩니다: $0.6914 - 0.3085 = 0.3829$. 따라서 $P(-0.5 \leq Z \leq 0.5)$ 는 0.3829입니다. 이는 원시 값으로 $P(995 \leq X \leq 1005)$ 가 38.29%임을 의미합니다.

2.19.3 NORM.S.DIST와 NORM.DIST의 비교

Excel에는 일반 정규 분포의 확률을 계산하는 *NORM.DIST* 함수도 있습니다. 두 함수의 주요 차이점은 다음과 같습니다.

Table 2.2: NORM.S.DIST와 NORM.DIST 함수 비교

특징	NORM.S.DIST	NORM.DIST
대상 분포	표준 정규 분포 (평균=0, 표준 편차=1)	일반 정규 분포 (사용자가 지정한 평균, 표준 편차)
필요 인수	Z-점수, 누적 여부	X 값, 평균, 표준 편차, 누적 여부
사용 시점	데이터를 Z-점수로 표준화한 후 확률을 계산할 때	원시 데이터(X)와 분포의 매개변수를 직접 사용하여 확률을 계산할 때
효율성	Z-점수를 수동으로 계산해야 하므로 한 단계 더 필요할 수 있음	평균과 표준 편차를 직접 입력하여 한 번에 계산 가능

예제

NORM.DIST를 사용한 동일한 계산: $P(995 \leq X \leq 1005)$ 를 NORM.DIST로 직접 계산할 수도 있습니다. $=\text{NORM.DIST}(1005, 1000, 10, \text{TRUE}) - \text{NORM.DIST}(995, 1000, 10, \text{TRUE})$ 이 결과 역시 0.3829가 나옵니다. NORM.DIST는 내부적으로 X 값을 Z-점수로 변환하여 계산하므로, 사용자가 직접 Z-점수를 계산할 필요가 없어 더 효율적일 수 있습니다.

팁

언제 어떤 함수를 사용할까? NORM.DIST는 대부분의 경우에 더 편리합니다. 그러나 Z-점수 자체의 의미를 분석하거나, 표준 정규 분포표를 사용하는 경우처럼 Z-점수를 명시적으로 다루어야 할 때는 NORM.S.DIST가 유용합니다. 두 함수의 차이점을 이해하는 것이 중요합니다.

2.20 Lesson 2-5.4: Excel에서 '미만' 확률 계산

이 섹션에서는 Excel의 NORM.DIST 함수를 사용하여 특정 값보다 작거나 같은 확률($P(X \leq x)$)을 계산하는 방법을 배웁니다. 이는 어떤 점수가 전체 모집단에서 몇 백분위수에 해당하는지 알아볼 때 유용합니다.

2.20.1 문제 정의

SAT 시험 점수를 예로 들어 보겠습니다. SAT 점수는 평균이 500점이고 표준 편차가 100점인 정규 분포를 따른다고 가정합니다. 어떤 학생이 458점을 받았을 때, 이 학생보다 낮은 점수를 받은 사람들의 비율(즉, 458점의 백분위수)은 얼마일까요? 우리는 $P(X \leq 458)$ 를 계산해야 합니다.

Figure 2.10: SAT 점수 458점 미만 확률 곡선

슬라이드에는 평균이 500인 종 모양의 정규 분포 곡선이 표시됩니다. 458점 지점부터 곡선의 왼쪽 끝까지의 면적이 음영 처리되어 있습니다. 이는 $P(X \leq 458)$ 를 시각적으로 나타냅니다. Excel 시트에는 X, Mean, Standard deviation 값이 각각 458, 500, 100으로 입력되어 있습니다. $p(x \leq 458)$ 셀 옆에서 NORM.DIST 함수가 선택되는 모습이 보입니다.

2.20.2 Excel의 NORM.DIST 함수 사용

NORM.DIST 함수는 일반 정규 분포의 누적 확률을 계산합니다.

- 함수 구문: `=NORM.DIST(x, mean, standard_dev, cumulative)`
- 인수 설명:
 - x: 확률을 계산하려는 특정 값입니다.
 - mean: 분포의 평균입니다.
 - standard_dev: 분포의 표준 편차입니다.
 - cumulative: 누적 분포 함수를 계산할지 여부를 지정합니다. (확률 계산에는 TRUE 또는 1을 사용합니다.)

예제

SAT 점수 458점 미만 확률 계산: Excel에서 `=NORM.DIST(458, 500, 100, 1)`를 입력합니다.

```
1 =NORM.DIST(458, 500, 100, 1)
2
```

Listing 2.8: Excel에서 '미만' 확률 계산 예시

결과는 약 0.337243입니다.

결과 해석: 이는 SAT 점수가 458점보다 작거나 같은 확률이 33.72%임을 의미합니다. 즉, 이 학생은 약 33.72 백분위수에 해당하며, 전체 응시자의 약 33.72%가 이 학생보다 낮은 점수를 받았습니다. 평균(500점)보다 낮은 점수이므로 50 백분위수보다 낮을 것이라는 직관과 일치합니다.

2.21 Lesson 2-5.5: Excel에서 '초과' 확률 계산

이 섹션에서는 Excel을 사용하여 특정 값보다 크거나 같은 확률($P(X \geq x)$)을 계산하는 방법을 배웁니다. Excel의 `NORM.DIST` 함수는 기본적으로 '미만' 확률(누적 확률)을 제공하므로, '초과' 확률을 계산하려면 약간의 변형이 필요합니다.

2.21.1 문제 정의

SAT 시험 점수 예시를 계속 사용하겠습니다. 평균 500점, 표준 편차 100점인 정규 분포를 따릅니다. 어떤 학생이 635점보다 높은 점수를 받을 확률은 얼마일까요? 즉, $P(X \geq 635)$ 를 계산해야 합니다.

Figure 2.11: SAT 점수 635점 초과 확률 곡선

슬라이드에는 평균이 500인 종 모양의 정규 분포 곡선이 표시됩니다. 635점 지점부터 곡선의 오른쪽 끝까지의 면적이 음영 처리되어 있습니다. 이는 $P(X \geq 635)$ 를 시각적으로 나타냅니다. Excel 시트에는 *Mean*과 *Standard deviation* 값이 각각 500, 100으로 입력되어 있으며, $p(x \geq 635)$ 셀이 보입니다.

2.21.2 계산 원리: 전체 확률에서 '미만' 확률 빼기

정규 분포 곡선 아래의 전체 면적(총 확률)은 항상 1입니다. 따라서 특정 값(x)보다 크거나 같은 확률은 전체 확률(1)에서 그 값보다 작거나 같은 확률($P(X \leq x)$)을 뺀 것과 같습니다.

$$P(X \geq x) = 1 - P(X \leq x)$$

예제

SAT 점수 635점 초과 확률 계산:

1. $P(X \leq 635)$ 계산: 먼저 635점보다 작거나 같은 확률을 `NORM.DIST` 함수로 계산합니다. Excel에서 `=NORM.DIST(635, 500, 100, 1)`를 입력합니다. 결과는 약 0.91149입니다. 이는 635점보다 작거나 같은 확률이 91.15%임을 의미합니다.
2. $P(X \geq 635)$ 계산: 이제 전체 확률 1에서 위에서 구한 값을 뺍니다. Excel에서 `=1 - NORM.DIST(635, 500, 100, 1)`를 입력합니다.

```

1 =1 - NORM.DIST(635, 500, 100, 1)
2

```

Listing 2.9: Excel에서 '초과' 확률 계산 예시

결과는 약 0.088508입니다.

결과 해석: SAT 점수가 635점보다 높을 확률은 약 8.85%입니다. 이는 635점 이상을 받는 학생이 전체의 약 8.85%라는 의미입니다.

2.22 Lesson 2-5.6: Excel에서 '두 값 사이' 확률 계산

이 섹션에서는 Excel을 사용하여 두 특정 값 사이에 있을 확률($P(\text{lower} \leq X \leq \text{upper})$)을 계산하는 방법을 배웁니다. 이 역시 NORM.DIST 함수를 활용하며, '미만' 확률의 개념을 응용합니다.

2.22.1 문제 정의

SAT 시험 점수 예시를 다시 사용합니다. 평균 500점, 표준 편차 100점인 정규 분포를 따릅니다. 무작위로 선택된 학생의 SAT 점수가 490점과 550점 사이에 있을 확률은 얼마일까요? 즉, $P(490 \leq X \leq 550)$ 를 계산해야 합니다.

Figure 2.12: SAT 점수 490점과 550점 사이 확률 곡선

슬라이드에는 평균이 500인 종 모양의 정규 분포 곡선이 표시됩니다. 490점과 550점 사이의 면적이 음영 처리되어 있습니다. 이는 $P(490 \leq X \leq 550)$ 를 시각적으로 나타냅니다. Excel 시트에는 Mean과 Standard deviation 값이 각각 500, 100으로 입력되어 있으며, $P(490 \leq x \leq 550)$ 셀이 보입니다.

2.22.2 계산 원리: 상한 누적 확률에서 하한 누적 확률 빼기

두 값(lower와 upper) 사이에 있을 확률은, upper 값보다 작거나 같은 확률($P(X \leq \text{upper})$)에서 lower 값보다 작거나 같은 확률($P(X \leq \text{lower})$)을 뺀 것과 같습니다.

$$P(\text{lower} \leq X \leq \text{upper}) = P(X \leq \text{upper}) - P(X \leq \text{lower})$$

예제

SAT 점수 490점과 550점 사이 확률 계산:

1. $P(X \leq 550)$ 계산: 먼저 상한 값인 550점보다 작거나 같은 확률을 NORM.DIST 함수로 계산합니다. Excel에서 =NORM.DIST(550, 500, 100, 1)를 입력합니다. 결과는 약 0.69146입니다.
2. $P(X \leq 490)$ 계산: 다음으로 하한 값인 490점보다 작거나 같은 확률을 NORM.DIST 함수로 계산합니다. Excel에서 =NORM.DIST(490, 500, 100, 1)를 입력합니다. 결과는 약 0.46017입니다.
3. 두 값 사이의 확률 계산: 두 결과를 빼면 됩니다. Excel에서 다음과 같이 입력합니다.

```

1 =NORM.DIST(550, 500, 100, 1) - NORM.DIST(490, 500, 100, 1)
2

```

Listing 2.10: Excel에서 '두 값 사이' 확률 계산 예시

결과는 약 0.23129입니다.

결과 해석: SAT 점수가 490점과 550점 사이에 있을 확률은 약 23.13%입니다. 이는 무작위로 선택된 학생 중 약 23.13%가 이 범위 내의 점수를 받는다는 의미입니다.

2.23 Lesson 2-5.7: Excel에서 주어진 확률에 대한 Z-값 찾기 (INV 함수)

이 섹션에서는 정규 분포에서 특정 확률(백분위수)에 해당하는 원시 값(X) 또는 Z-점수를 찾는 방법을 배웁니다. 이는 앞서 배운 확률 계산의 역방향 과정이며, Excel의 `NORM.INV` 및 `NORM.S.INV` 함수를 사용합니다.

2.23.1 문제 정의

SAT 시험 점수 예시를 다시 사용합니다. 평균 500점, 표준 편차 100점인 정규 분포를 따릅니다. 만약 어떤 학교가 상위 95%의 학생들만 입학시킨다고 할 때, 이 95백분위수에 해당하는 SAT 점수는 몇 점일까요? 즉, $P(X \leq X_{target}) = 0.95$ 를 만족하는 X_{target} 값을 찾아야 합니다.

Figure 2.13: 95백분위수에 해당하는 SAT 점수 찾기

슬라이드에는 평균이 500인 종 모양의 정규 분포 곡선이 표시됩니다. 곡선의 오른쪽 상단에 'score'라는 값과 함께 0.95의 비율이 음영 처리되어 있습니다. 이는 95백분위수에 해당하는 점수를 찾는 상황을 시각적으로 나타냅니다. Excel 시트에는 'Score at 95%' 셀 옆에서 `NORM.INV` 함수가 사용되는 모습이 보입니다.

2.23.2 Excel의 NORM.INV 함수 사용

`NORM.INV` 함수는 주어진 누적 확률에 해당하는 원시 값(X)을 직접 반환합니다.

- **함수 구문:** `=NORM.INV(probability, mean, standard_dev)`
- **인수 설명:**
 - **probability:** 찾고자 하는 누적 확률입니다 (0과 1 사이의 값).
 - **mean:** 분포의 평균입니다.
 - **standard_dev:** 분포의 표준 편차입니다.

예제

95백분위수에 해당하는 SAT 점수 계산 (NORM.INV): Excel에서 `=NORM.INV(0.95, 500, 100)`를 입력합니다.

```
1 =NORM.INV(0.95, 500, 100)
2
```

Listing 2.11: Excel에서 NORM.INV 함수 사용 예시

결과는 약 664.4854입니다.

결과 해석: SAT 점수가 664.4854점 이상이면 상위 5%에 해당합니다. SAT 점수는 보통 정수이므로, 665점 이상을 받아야 95백분위수 이상에 해당한다고 볼 수 있습니다.

2.23.3 Excel의 NORM.S.INV 함수 사용

NORM.S.INV 함수는 주어진 누적 확률에 해당하는 Z-점수를 반환합니다. 이 함수는 표준 정규 분포(평균 0, 표준 편차 1)를 가정하므로, 평균과 표준 편차를 인수로 받지 않습니다.

- 함수 구문: =NORM.S.INV(probability)
- 인수 설명:
 - probability: 찾고자 하는 누적 확률입니다 (0과 1 사이의 값).

예제

95백분위수에 해당하는 Z-점수 계산 (NORM.S.INV): Excel에서 =NORM.S.INV(0.95)를 입력합니다.

```
1 =NORM.S.INV(0.95)
2
```

Listing 2.12: Excel에서 NORM.S.INV 함수 사용 예시

결과는 약 1.644854입니다.

Z-점수를 원시 점수로 변환: 이 Z-점수를 사용하여 원래 분포의 점수(X)를 계산할 수 있습니다.

$$X = \mu + Z \times \sigma \quad X = 500 + 1.644854 \times 100 = 500 + 164.4854 = 664.4854$$

```
1 =500 + (H6 * 100) % H6 셀에 NORM.S.INV 결과가 있다고 가정
2
```

Listing 2.13: Z-점수를 원시 점수로 변환하는 Excel 수식

결과는 NORM.INV를 사용했을 때와 동일한 664.4854입니다.

2.23.4 두 INV 함수의 비교

NORM.INV와 NORM.S.INV는 동일한 최종 결과를 얻을 수 있지만, 과정에서 차이가 있습니다.

Table 2.3: NORM.INV와 NORM.S.INV 함수 비교

특징	NORM.INV	NORM.S.INV
반환 값	원시 값 (X)	Z-점수
필요 인수	확률, 평균, 표준 편차	확률
사용 시점	특정 백분위수에 해당하는 원시 값을 바로 알고 싶을 때	Z-점수 자체를 분석하거나, Z-점수를 통해 원시 값을 수동으로 계산할 때
효율성	한 번의 함수 호출로 최종 결과 획득	Z-점수를 얻은 후 원시 값으로 변환하는 추가 계산 필요

핵심 정보

어떤 함수를 선택할까? 대부분의 경우, 특정 백분위수에 해당하는 원시 값을 직접 알고 싶다면 NORM.INV가 더 효율적입니다. 그러나 Z-점수의 의미를 이해하고 그 값을 활용해야 하는 상황이라면 NORM.S.INV를 사용하는 것이 좋습니다. 두 함수 모두 유용하며, 상황에 따라 적절한 함수를

선택하는 것이 중요합니다.

2.24 Lesson 2-6: 표준 정규 분포표

핵심 요약

참고: 제공된 자료에는 이 섹션에 대한 구체적인 내용이 없으며, Lesson 2-6.1의 내용이 Lesson 2-5.7과 동일하게 "Finding Z for a Given Probability (INV) in Excel"로 명시되어 있습니다. 따라서 표준 정규 분포표를 직접 읽는 방법에 대한 설명은 포함되지 않으며, Excel의 INV 함수를 사용하는 방법은 Lesson 2-5.7에서 상세히 다루었습니다. 전통적으로 표준 정규 분포표는 Z-점수에 해당하는 누적 확률을 찾거나, 누적 확률에 해당하는 Z-점수를 찾는 데 사용되었습니다. Excel과 같은 도구를 사용하면 이러한 표를 수동으로 찾아볼 필요 없이 함수를 통해 빠르고 정확하게 값을 얻을 수 있습니다.

2.25 빠르게 훑어보기 (1페이지 요약)

Excel을 활용한 정규 분포 분석 핵심 요약

정규 분포의 이해:

- 종 모양의 대칭 곡선으로, 평균(μ)과 표준 편차(σ)로 정의됩니다.
- Z-점수($Z = (X - \mu)/\sigma$)를 통해 모든 정규 분포를 표준 정규 분포(평균 0, 표준 편차 1)로 변환할 수 있습니다.
- Excel 함수는 기본적으로 누적 확률($P(X \leq x)$)을 계산합니다.

확률 계산 (NORM.DIST / NORM.S.DIST):

- 특정 값 미만 ($P(X \leq x)$): =NORM.DIST(x, mean, standard_dev, TRUE)
- 특정 값 초과 ($P(X \geq x)$): =1 - NORM.DIST(x, mean, standard_dev, TRUE)
- 두 값 사이 ($P(\text{lower} \leq X \leq \text{upper})$): =NORM.DIST(upper, mean, standard_dev, TRUE) - NORM.DIST(lower, mean, standard_dev, TRUE)
- 표준 정규 분포의 확률 ($P(Z \leq z)$): =NORM.S.DIST(z, TRUE)

역방향 계산 (NORM.INV / NORM.S.INV):

- 주어진 확률에 해당하는 X 값 찾기: =NORM.INV(probability, mean, standard_dev)
- 주어진 확률에 해당하는 Z-점수 찾기: =NORM.S.INV(probability)
- Z-점수를 X 값으로 변환: $X = \mu + Z \times \sigma$

핵심 비교:

- NORM.DIST vs NORM.S.DIST: 전자는 일반 분포, 후자는 표준 분포.
- NORM.INV vs NORM.S.INV: 전자는 X 값 반환, 후자는 Z-점수 반환.

2.26 FAQ

- **Q: NORM.DIST와 NORM.S.DIST의 주요 차이점은 무엇인가요?** **A:** NORM.DIST는 일반 정규 분포(사용자가 평균과 표준 편차를 지정)의 확률을 계산하는 반면, NORM.S.DIST는 표준 정규 분포(평균 0, 표준 편차 1로 고정)의 확률을 계산합니다. 따라서 NORM.S.DIST는 Z-점수만을 인수로 받습니다.
- **Q: NORM.INV와 NORM.S.INV의 차이점은 무엇인가요?** **A:** 두 함수 모두 주어진 누적 확률에 해당하는 값을 찾지만, NORM.INV는 원래 분포의 X 값(원시 점수)을 직접 반환하고, NORM.S.INV는 표준 정규 분포의 Z-점수를 반환합니다. NORM.S.INV를 사용한 후에는 Z-점수를 X 값으로 변환하는 추가 계산이 필요합니다.
- **Q: Excel에서 '보다 큼' 확률($P(X \geq x)$)을 어떻게 계산하나요?** **A:** Excel의 정규 분포 함수는 기본적으로 '보다 작거나 같음' 확률(누적 확률)을 반환합니다. 따라서 '보다 큼' 확률을 계산하려면 전체 확률(1)에서 '보다 작거나 같음' 확률을 빼야 합니다. 예: $=1 - \text{NORM.DIST}(x, \text{mean}, \text{standard_dev}, \text{TRUE})$.
- **Q: Excel 정규 분포 함수에서 '누적(cumulative)' 인수는 항상 1로 설정해야 하나요?** **A:** 대부분의 경우, 특정 값보다 작거나 같은 확률(누적 확률)을 계산할 때는 'TRUE' 또는 1로 설정해야 합니다. 'FALSE' 또는 0으로 설정하면 확률 밀도 함수(PDF)의 값을 반환하는데, 이는 특정 한 점의 확률이 아니라 곡선의 높이를 나타내므로 일반적으로 확률 계산에는 사용되지 않습니다.

개요

이 문서는 'Exploring and Producing Data Module 2'의 핵심 내용 중 하나인 표준정규분포와 Z-테이블 활용법을 다룹니다. 표준정규분포의 기본 개념부터 Z-점수를 이용한 확률 계산, 그리고 주어진 확률로부터 Z-점수와 원본 값을 역으로 찾아내는 방법까지 상세히 설명합니다. 비전공자도 쉽게 이해할 수 있도록 풍부한 예시와 직관적인 설명을 제공하며, 시험 대비를 위한 필수적인 지식을 완벽하게 정리합니다.

용어 정리

데이터 분석에서 표준정규분포와 Z-점수는 매우 중요한 개념입니다. 다음 표는 이 문서에서 사용되는 주요 용어들을 쉽게 설명합니다.

용어	쉬운 설명	원어	비고
표준정규분포	평균이 0이고 표준편차가 1인 특별한 정규분포.	Standard Normal Distribution	모든 정규분포를 비교하기 위한 기준
Z-점수	어떤 데이터 값이 평균으로부터 몇 표준편차 떨어져 있는지를 나타내는 값.	Z-Score	데이터의 상대적 위치를 파악
확률 밀도 함수	연속형 확률 변수가 특정 값을 가질 확률의 상대적 밀도를 나타내는 함수.	Probability Density Function (PDF)	종 모양 곡선의 높이를 결정
누적 확률	특정 값보다 작거나 같은 확률.	Cumulative Probability	Z-테이블에서 제공하는 기본 값
백분위수	전체 데이터 중 특정 값보다 작거나 같은 데이터의 비율을 100분율로 나타낸 것.	Percentile	데이터의 상대적 순위
표준정규분포표	Z-점수에 해당하는 누적 확률 값을 정리해 놓은 표.	Z-Table	확률 계산을 위한 필수 도구

핵심 개념 및 원리

2.26.1 표준정규분포의 이해

표준정규분포(Standard Normal Distribution)는 통계학에서 매우 중요한 개념입니다. 이는 모든 정규분포를 비교하고 분석하기 위한 표준화된 형태를 제공합니다.

정의

표준정규분포의 정의 표준정규분포는 평균(μ)이 0이고 표준편차(σ)가 1인 특별한 정규분포입니다.

표준정규분포의 특징

- **종 모양(Bell-shaped Curve):** 데이터가 평균 주변에 집중되어 있고, 평균에서 멀어질수록 빈도가 줄어드는 대칭적인 종 모양을 가집니다.
- **대칭성(Symmetry):** 평균(0)을 중심으로 좌우가 완벽하게 대칭입니다. 이는 음수 Z-점수의 확률을 양수 Z-점수를 통해 유추할 수 있게 합니다.
- **전체 면적 1:** 곡선 아래의 총 면적은 항상 1입니다. 이는 모든 가능한 확률의 합이 100%임을 의미합니다.
- **확률 밀도 함수:** 표준정규분포의 확률 밀도 함수 $p(x)$ 는 다음과 같습니다.

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

표준정규분포의 경우 $\mu = 0, \sigma = 1$ 이므로, 이 식은 다음과 같이 간소화됩니다.

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

여기서 $e \approx 2.71828$ (자연로그의 밑), $\pi \approx 3.14159$ (원주율)입니다. 이 함수는 곡선의 높이, 즉 특정 지점에서의 확률 밀도를 나타냅니다.

왜 표준정규분포가 필요한가?, colback=lightgray, colframe=black!75

세상에는 다양한 평균과 표준편차를 가진 수많은 정규분포가 존재합니다. 예를 들어, 어떤 시험의 평균은 500점이고 표준편차는 100점일 수 있고, 다른 시험의 평균은 70점이고 표준편차는 10점일 수 있습니다. 이처럼 서로 다른 분포를 직접 비교하기는 어렵습니다.

표준정규분포는 이러한 다양한 정규분포들을 하나의 공통된 척도(평균 0, 표준편차 1)로 변환하여 비교할 수 있게 해줍니다. 이를 통해 어떤 데이터가 해당 분포 내에서 상대적으로 어느 위치에 있는지 쉽게 파악하고, 복잡한 적분 계산 없이도 Z-테이블을 통해 확률을 구할 수 있습니다.

2.26.2 Z-점수 계산 및 의미

Z-점수(Z-Score)는 개별 데이터 포인트가 평균으로부터 얼마나 떨어져 있는지를 표준편차 단위로 나타내는 값입니다.

정의

Z-점수 공식 Z-점수는 다음 공식으로 계산됩니다.

$$z = \frac{\text{관심 값} - \text{모든 값의 평균}}{\text{모든 값의 표준편차}}$$

수학적 기호로는 다음과 같습니다.

$$z = \frac{x - \mu}{\sigma}$$

여기서:

- x : 우리가 알고 싶은 특정 데이터 값 (관심 값)
- μ : 모집단의 평균 (average of all values)
- σ : 모집단의 표준편차 (standard deviation of all values)

Z-점수의 의미

- **상대적 위치**: Z-점수는 특정 데이터가 평균보다 높은지 낮은지, 그리고 얼마나 높은지 낮은지를 표준편차 단위로 알려줍니다.
 - Z-점수가 양수이면 평균보다 높은 값입니다.
 - Z-점수가 음수이면 평균보다 낮은 값입니다.
 - Z-점수가 0이면 평균과 같은 값입니다.
- **비교 가능성**: 서로 다른 단위나 분포를 가진 데이터라도 Z-점수로 변환하면 동일한 표준 척도 위에서 비교할 수 있습니다. 예를 들어, 수학 시험 점수와 영어 시험 점수를 Z-점수로 변환하여 어떤 과목에서 더 잘했는지 객관적으로 판단할 수 있습니다.

예제

Z-점수 계산 예시: SAT 점수 이전 SAT 시험은 각 섹션(예: 수학)의 평균이 500점이고 표준편차가 100점으로 설계되었습니다. 어떤 학생이 635점을 받았다면, 이 학생은 얼마나 잘한 것일까요?

- 관심 값 (x) = 635
- 평균 (μ) = 500
- 표준편차 (σ) = 100

Z-점수를 계산해 봅시다:

$$z = \frac{635 - 500}{100} = \frac{135}{100} = 1.35$$

이 학생의 Z-점수는 1.35입니다. 이는 학생의 점수가 평균보다 1.35 표준편차만큼 높다는 것을 의미합니다. 이제 이 Z-점수를 사용하여 학생의 백분위수를 찾아볼 수 있습니다.

표준정규분포표 (Z-Table) 활용법

표준정규분포표, 또는 Z-테이블은 Z-점수에 해당하는 누적 확률을 제공하는 도구입니다. 이 테이블을 통해 복잡한 적분 계산 없이도 특정 Z-점수 이하의 확률을 쉽게 찾을 수 있습니다.

2.26.3 Z-테이블의 구성

제공된 Z-테이블은 Z-점수와 그에 해당하는 누적 확률(cumulative probability)을 보여줍니다.

- **Z-값**: 테이블의 가장 왼쪽 열은 Z-점수의 소수점 첫째 자리까지를 나타냅니다 (예: 0.0, 0.1, 0.2, ...).

- **소수점 둘째 자리:** 테이블의 가장 위쪽 행은 Z-점수의 소수점 둘째 자리를 나타냅니다 (예: 0.00, 0.01, 0.02, ...).
- **확률 값:** 테이블 내부의 값들은 해당 Z-점수보다 작거나 같은 확률 $P(Z \leq z)$ 을 나타냅니다. 즉, Z-점수 왼쪽 영역의 면적을 의미합니다.

Z-테이블 사용 시 주의사항

Z-테이블은 여러 종류가 있을 수 있습니다. 어떤 테이블은 $P(Z \leq z)$ 를, 어떤 테이블은 $P(Z \geq z)$ 를, 또 어떤 테이블은 평균(0)과 Z-점수 사이의 면적을 제공하기도 합니다. 이 문서에서 사용하는 테이블은 $P(Z \leq z)$, 즉 **Z-점수 왼쪽 영역의 누적 확률**을 제공합니다. 테이블을 사용하기 전에 반드시 해당 테이블의 범례(legend)를 확인하여 어떤 확률을 나타내는지 이해해야 합니다.

2.26.4 표준정규분포표 (Z-Table)

다음은 표준정규분포표의 일부입니다. 이 표를 사용하여 다양한 확률을 계산할 수 있습니다.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.50399	0.50798	0.51197	0.51595	0.51994	0.52392	0.52790	0.53188	0.53586
0.1	0.53983	0.54380	0.54776	0.55172	0.55567	0.55966	0.56360	0.56749	0.57142	0.57535
0.2	0.57926	0.58317	0.58706	0.59095	0.59483	0.59871	0.60257	0.60642	0.61026	0.61409
0.3	0.61791	0.62172	0.62552	0.62930	0.63307	0.63683	0.64058	0.64431	0.64803	0.65173
0.4	0.65542	0.65910	0.66276	0.66640	0.67003	0.67364	0.67724	0.68082	0.68439	0.68793
0.5	0.69146	0.69497	0.69847	0.70194	0.70540	0.70884	0.71226	0.71566	0.71904	0.72240
0.6	0.72575	0.72907	0.73237	0.73565	0.73891	0.74215	0.74537	0.74857	0.75175	0.75490
0.7	0.75804	0.76115	0.76424	0.76730	0.77035	0.77337	0.77637	0.77935	0.78230	0.78524
0.8	0.78814	0.79103	0.79389	0.79673	0.79955	0.80234	0.80511	0.80785	0.81057	0.81327
0.9	0.81594	0.81859	0.82121	0.82381	0.82639	0.82894	0.83147	0.83398	0.83646	0.83891
1.0	0.84134	0.84375	0.84614	0.84849	0.85083	0.85314	0.85543	0.85769	0.85993	0.86214
1.1	0.86433	0.86650	0.86864	0.87076	0.87286	0.87493	0.87698	0.87900	0.88100	0.88298
1.2	0.88493	0.88686	0.88877	0.89065	0.89251	0.89435	0.89617	0.89796	0.89973	0.90147
1.3	0.90320	0.90490	0.90658	0.90824	0.90988	0.91149	0.91308	0.91466	0.91621	0.91774
1.4	0.91924	0.92073	0.92220	0.92364	0.92507	0.92647	0.92785	0.92922	0.93056	0.93189
1.5	0.93319	0.93448	0.93574	0.93699	0.93822	0.93943	0.94062	0.94179	0.94295	0.94408
1.6	0.94520	0.94630	0.94738	0.94845	0.94950	0.95053	0.95154	0.95254	0.95352	0.95449
1.7	0.95543	0.95637	0.95728	0.95818	0.95907	0.95994	0.96080	0.96164	0.96246	0.96327
1.8	0.96407	0.96485	0.96562	0.96638	0.96712	0.96784	0.96856	0.96926	0.96995	0.97062
1.9	0.97128	0.97193	0.97257	0.97320	0.97381	0.97441	0.97500	0.97558	0.97615	0.97670
2.0	0.97725	0.97778	0.97831	0.97882	0.97932	0.97982	0.98030	0.98077	0.98124	0.98169
2.1	0.98214	0.98257	0.98300	0.98341	0.98382	0.98422	0.98461	0.98500	0.98537	0.98574
2.2	0.98610	0.98645	0.98679	0.98713	0.98745	0.98778	0.98809	0.98840	0.98870	0.98899
2.3	0.98928	0.98956	0.98983	0.99010	0.99036	0.99061	0.99086	0.99111	0.99134	0.99158
2.4	0.99180	0.99202	0.99224	0.99245	0.99266	0.99286	0.99305	0.99324	0.99343	0.99361
2.5	0.99379	0.99396	0.99413	0.99430	0.99446	0.99461	0.99477	0.99492	0.99506	0.99520
2.6	0.99534	0.99547	0.99560	0.99573	0.99585	0.99598	0.99609	0.99621	0.99632	0.99643
2.7	0.99653	0.99664	0.99674	0.99683	0.99693	0.99702	0.99711	0.99720	0.99728	0.99736
2.8	0.99744	0.99752	0.99760	0.99767	0.99774	0.99781	0.99788	0.99795	0.99801	0.99807
2.9	0.99813	0.99819	0.99825	0.99831	0.99836	0.99841	0.99846	0.99851	0.99856	0.99861
3.0	0.99865	0.99869	0.99874	0.99878	0.99882	0.99886	0.99889	0.99893	0.99896	0.99900

표준정규분포표 (Z-Table): Z-점수보다 작거나 같은 누적 확률 $P(Z \leq z)$

확률 계산 절차

Z-테이블을 사용하여 다양한 유형의 확률을 계산하는 방법을 단계별로 살펴보겠습니다. 모든 예시는 SAT 시험 점수(평균 $\mu = 500$, 표준편차 $\sigma = 100$)를 기반으로 합니다.

2.26.5 1. 특정 값보다 작을 확률 ($P(X \leq x)$)

가장 기본적인 형태로, Z-테이블이 직접 제공하는 확률입니다.

예제

예시: SAT 점수 635점 이하일 확률 ($P(X \leq 635)$) 어떤 학생이 SAT에서 635점을 받았습니다. 이 학생보다 점수가 낮거나 같은 사람들의 비율(백분위수)은 얼마일까요?

단계:

1. **Z-점수 계산:** 먼저 635점에 해당하는 Z-점수를 계산합니다.

$$z = \frac{635 - 500}{100} = 1.35$$

2. **Z-테이블에서 값 찾기:** Z-테이블에서 Z-점수 1.35에 해당하는 확률을 찾습니다.

- 왼쪽 열에서 '1.3'을 찾습니다.
- 위쪽 행에서 '0.05'를 찾습니다.
- '1.3' 행과 '0.05' 열이 교차하는 지점의 값을 확인합니다.

Z	...	0.05	...
⋮	⋮	⋮	⋮
1.3	...	0.91149	...
⋮	⋮	⋮	⋮

테이블에서 찾은 값은 **0.91149**입니다.

결론: $P(Z \leq 1.35) = 0.9115$ (반올림). 이는 SAT 시험 응시자 중 약 91.15%가 635점보다 낮거나 같은 점수를 받았다는 의미입니다. 이 학생은 약 91백분위수에 해당합니다.

시각적 이해, colback=lightblue!50!white, colframe=darkblue

표준정규분포 곡선에서 $Z=1.35$ 지점의 왼쪽에 해당하는 모든 면적을 파란색으로 칠한 그림을 상상해 보세요. 이 파란색 면적이 바로 0.9115의 확률을 나타냅니다. 곡선은 X축 -3에서 3까지 퍼져 있고, Y축 0에서 0.4까지 밀도를 나타내며, $X=0$, $Y=0.4$ 에서 정점을 이룹니다.

2.26.6 2. 특정 값보다 클 확률 ($P(X \geq x)$)

Z-테이블은 $P(Z \leq z)$ 를 제공하므로, $P(Z \geq z)$ 는 전체 확률(1)에서 $P(Z \leq z)$ 를 빼서 구합니다.

예제

예시: SAT 점수 635점 이상일 확률 ($P(X \geq 635)$) SAT에서 635점을 받은 학생보다 점수가 높거나 같은 사람들의 비율은 얼마일까요?

단계:

1. **Z-점수 계산:** 635점에 해당하는 Z-점수는 이전 예시와 동일하게 1.35입니다.
2. **$P(Z \leq z)$ 찾기:** Z-테이블에서 $P(Z \leq 1.35)$ 는 0.9115입니다.
3. **1에서 빼기:** 전체 확률은 1이므로, $P(Z \geq 1.35)$ 는 다음과 같습니다.

$$P(Z \geq 1.35) = 1 - P(Z \leq 1.35) = 1 - 0.9115 = 0.0885$$

결론: $P(Z \geq 1.35) = 0.0885$. 이는 SAT 시험 응시자 중 약 8.85%가 635점보다 높거나 같은 점수를 받았다는 의미입니다.

시각적 이해, colback=lightblue!50!white, colframe=darkblue

표준정규분포 곡선에서 $Z=1.35$ 지점의 왼쪽에 해당하는 면적(파란색, $P(Z \leq 1.35)$)과 오른쪽에 해당하는 면적(흰색, $P(Z \geq 1.35)$)을 상상해 보세요. 이 두 면적의 합은 1입니다. 따라서 오른쪽 면적은 1에서 왼쪽 면적을 뺀 값입니다.

2.26.7 3. 음수 Z-점수 처리

Z-테이블은 보통 양수 Z-점수만 제공하지만, 표준정규분포의 대칭성을 이용하여 음수 Z-점수의 확률도 계산할 수 있습니다.

예제

예시: SAT 점수 458점 이하일 확률 ($P(X \leq 458)$) 어떤 학생이 SAT에서 458점을 받았습니다. 이 학생보다 점수가 낮거나 같은 사람들의 비율은 얼마일까요?

단계:

1. **Z-점수 계산:** 458점에 해당하는 Z-점수를 계산합니다.

$$z = \frac{458 - 500}{100} = \frac{-42}{100} = -0.42$$

Z-점수가 음수이므로, 이 학생은 평균보다 낮은 점수를 받았습니다.

2. **대칭성 활용:** 표준정규분포는 평균(0)을 중심으로 대칭입니다. 따라서 $P(Z \leq -0.42)$ 는 $P(Z \geq 0.42)$ 와 같습니다. 즉, $Z=-0.42$ 의 왼쪽 면적은 $Z=0.42$ 의 오른쪽 면적과 동일합니다.

시각적 이해: 대칭성, colback=lightblue!50!white, colframe=darkblue

두 개의 표준정규분포 곡선을 상상해 보세요.

- 왼쪽 곡선: $Z=-0.42$ 지점의 왼쪽 영역이 파란색으로 칠해져 있습니다 ($P(Z \leq -0.42)$).
- 오른쪽 곡선: $Z=0.42$ 지점의 오른쪽 영역이 파란색으로 칠해져 있습니다 ($P(Z \geq 0.42)$).

이 두 파란색 영역의 면적은 정확히 같습니다.

3. **$P(Z \leq \text{양수 } Z)$ 찾기:** $P(Z \geq 0.42)$ 를 구하기 위해 먼저 Z-테이블에서 $P(Z \leq 0.42)$ 를 찾습니다.
 - 왼쪽 열에서 '0.4'를 찾습니다.
 - 위쪽 행에서 '0.02'를 찾습니다.

- '0.4' 행과 '0.02' 열이 교차하는 지점의 값을 확인합니다.

테이블에서 찾은 값은 **0.66276**입니다. (반올림하여 0.6628) 이는 $P(Z \leq 0.42) = 0.6628$ 을 의미합니다. 이 값은 $Z=0.42$ 의 왼쪽 면적(흰색 영역)입니다.

4. 1에서 빼기: 우리가 찾는 $P(Z \geq 0.42)$ 는 $1 - P(Z \leq 0.42)$ 입니다.

$$P(Z \geq 0.42) = 1 - 0.6628 = 0.3372$$

결론: $P(Z \leq -0.42) = 0.3372$. 이는 SAT 시험 응시자 중 약 33.72%가 458점보다 낮거나 같은 점수를 받았다는 의미입니다. 이 학생은 약 33.72백분위수에 해당합니다.

2.26.8 4. 두 값 사이의 확률 ($P(x_1 \leq X \leq x_2)$)

두 Z-점수 사이의 확률은 더 큰 Z-점수까지의 누적 확률에서 더 작은 Z-점수까지의 누적 확률을 빼서 구합니다.

예제

예시: SAT 점수 490점과 550점 사이일 확률 ($P(490 \leq X \leq 550)$) SAT 시험에서 490점과 550점 사이의 점수를 받을 확률은 얼마일까요?

단계:

1. 두 Z-점수 계산:

- $x_1 = 490$: $z_1 = \frac{490-500}{100} = \frac{-10}{100} = -0.1$

- $x_2 = 550$: $z_2 = \frac{550-500}{100} = \frac{50}{100} = 0.5$

이제 $P(-0.1 \leq Z \leq 0.5)$ 를 찾아야 합니다.

2. 원리 적용: $P(z_1 \leq Z \leq z_2) = P(Z \leq z_2) - P(Z \leq z_1)$

3. $P(Z \leq 0.5)$ 찾기: Z-테이블에서 $P(Z \leq 0.5)$ 를 찾습니다.

- 왼쪽 열 '0.5', 위쪽 행 '0.00'

- 값: **0.69146** (반올림하여 0.6915)

4. $P(Z \leq -0.1)$ 찾기: 음수 Z-점수이므로 대칭성을 이용합니다.

- $P(Z \leq -0.1)$ 는 $P(Z \geq 0.1)$ 와 같습니다.

- 먼저 $P(Z \leq 0.1)$ 를 Z-테이블에서 찾습니다. — 왼쪽 열 '0.1', 위쪽 행 '0.00' — 값: **0.53983** (반올림하여 0.5398)

- $P(Z \geq 0.1) = 1 - P(Z \leq 0.1) = 1 - 0.5398 = 0.4602$

- 따라서 $P(Z \leq -0.1) = 0.4602$

5. 최종 계산:

$$P(-0.1 \leq Z \leq 0.5) = P(Z \leq 0.5) - P(Z \leq -0.1) = 0.6915 - 0.4602 = 0.2313$$

결론: $P(490 \leq X \leq 550) = 0.2313$. 이는 SAT 시험 응시자 중 약 23.13%가 490점과 550점 사이의 점수를 받을 확률을 의미합니다.

시각적 이해, colback=lightblue!50!white, colframe=darkblue

세 개의 표준정규분포 곡선을 상상해 보세요.

- 첫 번째 곡선: $Z=0.5$ 왼쪽 전체 면적 ($P(Z \leq 0.5)$)
 - 두 번째 곡선: $Z=-0.1$ 왼쪽 전체 면적 ($P(Z \leq -0.1)$)
 - 세 번째 곡선: $Z=-0.1$ 과 $Z=0.5$ 사이의 면적 ($P(-0.1 \leq Z \leq 0.5)$)
- 첫 번째 곡선의 면적에서 두 번째 곡선의 면적을 빼면 세 번째 곡선의 면적이 됩니다.

주어진 확률로 Z-값 찾기 (역방향 문제: INV)

때로는 특정 확률(예: 백분위수)에 해당하는 Z-점수를 찾고, 그 Z-점수를 이용하여 원본 데이터 값을 역으로 계산해야 할 때가 있습니다. 이는 Z-테이블을 거꾸로 읽는 과정입니다.

2.26.9 1. 백분위수(확률)로 Z-값 찾기

주어진 확률에 해당하는 Z-점수를 찾으려면, Z-테이블 내부의 확률 값들 중에서 가장 가까운 값을 찾습니다.

예제

예시: 상위 95백분위수에 해당하는 Z-값 찾기 SAT 시험에서 상위 95백분위수에 들려면 Z-점수가 얼마여야 할까요? 즉, $P(Z \leq z) = 0.95$ 를 만족하는 Z-값을 찾습니다.

단계:

1. **Z-테이블에서 0.95에 가장 가까운 값 찾기:** Z-테이블 내부에서 0.95에 가장 가까운 확률 값을 찾습니다.

- 0.94950 ($Z=1.64$)
- 0.95053 ($Z=1.65$)

우리가 찾는 0.95는 0.94950과 0.95053의 정확히 중간에 있습니다.

2. **Z-값 보간 (Interpolation):** 0.95가 두 값의 중간이므로, 해당 Z-점수도 두 Z-점수(1.64와 1.65)의 중간값을 사용합니다.

$$Z = \frac{1.64 + 1.65}{2} = 1.645$$

결론: 상위 95백분위수에 해당하는 Z-점수는 약 **1.645**입니다.

2.26.10 2. Z-값으로 원본 데이터 값 (X) 찾기

Z-점수를 알면, Z-점수 공식을 역으로 사용하여 원본 데이터 값(x)을 계산할 수 있습니다.

정의

원본 데이터 값 (X) 계산 공식

$$x = \mu + z \times \sigma$$

여기서:

- x : 우리가 찾고자 하는 원본 데이터 값
- μ : 모집단의 평균
- z : 해당 확률에 대한 Z-점수
- σ : 모집단의 표준편차

예제

예시: 상위 95백분위수에 해당하는 SAT 점수 찾기 SAT 시험에서 상위 95백분위수에 들려면 몇 점을 받아야 할까요? (평균 $\mu = 500$, 표준편차 $\sigma = 100$)

단계:

1. **Z-값 확인:** 이전 예시에서 상위 95백분위수에 해당하는 Z-점수는 1.645임을 확인했습니다.
2. **원본 값 계산:** Z-점수 공식을 역으로 사용하여 x 를 계산합니다.

$$x = 500 + (1.645 \times 100) = 500 + 164.5 = 664.5$$

결론: SAT 시험에서 664.5점 이상을 받으면 상위 95백분위수에 해당합니다.

시각적 이해, colback=lightblue!50!white, colframe=darkblue

표준정규분포 곡선에서 $Z=1.645$ 지점의 왼쪽 면적이 0.95가 되도록 파란색으로 칠한 그림을 상상해 보세요. 이 Z-점수 1.645는 평균으로부터 1.645 표준편차만큼 떨어져 있다는 것을 의미하며, 이를 실제 점수로 환산한 것이 664.5점입니다.

실습 문제 및 풀이

이제 배운 내용을 바탕으로 실습 문제를 풀어봅시다.

예제

실습 문제: SAT 점수 600점과 650점 사이일 확률 SAT 시험 (평균 $\mu = 500$, 표준편차 $\sigma = 100$)에서 무작위로 선택된 응시자가 600점과 650점 사이의 점수를 받을 확률은 얼마일까요? ($P(600 \leq X \leq 650)$)

예제

실습 문제 풀이 단계:

1. **두 Z-점수 계산:**

- $x_1 = 600$: $z_1 = \frac{600-500}{100} = \frac{100}{100} = 1.0$

- $x_2 = 650$: $z_2 = \frac{650-500}{100} = \frac{150}{100} = 1.5$

이제 $P(1.0 \leq Z \leq 1.5)$ 를 찾아야 합니다.

2. **원리 적용:** $P(z_1 \leq Z \leq z_2) = P(Z \leq z_2) - P(Z \leq z_1)$

3. **$P(Z \leq 1.5)$ 찾기:** Z-테이블에서 $P(Z \leq 1.5)$ 를 찾습니다.

- 왼쪽 열 '1.5', 위쪽 행 '0.00'

- 값: **0.93319** (반올림하여 0.9332)
4. $P(Z \leq 1.0)$ 찾기: Z-테이블에서 $P(Z \leq 1.0)$ 를 찾습니다.
- 왼쪽 열 '1.0', 위쪽 행 '0.00'
 - 값: **0.84134** (반올림하여 0.8413)
5. 최종 계산:

$$P(1.0 \leq Z \leq 1.5) = P(Z \leq 1.5) - P(Z \leq 1.0) = 0.9332 - 0.8413 = 0.0919$$

결론: $P(600 \leq X \leq 650) = 0.0919$. 이는 SAT 시험 응시자 중 약 9.19%가 600점과 650점 사이의 점수를 받을 확률을 의미합니다.

빠르게 훑어보기 (1 페이지 요약)

다음은 표준정규분포와 Z-테이블 활용의 핵심 내용을 한눈에 볼 수 있도록 요약한 것입니다.

핵심 요약

핵심 요약: 표준정규분포와 Z-테이블

- **표준정규분포:** 평균 $\mu = 0$, 표준편차 $\sigma = 1$ 인 정규분포. 모든 정규분포를 표준화하여 비교 가능하게 합니다.
- **Z-점수:** $z = \frac{x - \mu}{\sigma}$
데이터가 평균으로부터 몇 표준편차 떨어져 있는지 나타냅니다.
- **Z-테이블:** Z-점수 왼쪽의 누적 확률 $P(Z \leq z)$ 를 제공합니다.

확률 계산 유형:

- $P(X \leq x)$ (특정 값 이하):
 1. x 를 z 로 변환: $z = (x - \mu)/\sigma$
 2. Z-테이블에서 $P(Z \leq z)$ 직접 찾기
- $P(X \geq x)$ (특정 값 이상):
 1. x 를 z 로 변환
 2. Z-테이블에서 $P(Z \leq z)$ 찾기
 3. $1 - P(Z \leq z)$ 계산
- $P(X \leq x)$ (음수 Z-점수):
 1. x 를 음수 z 로 변환
 2. 대칭성 이용: $P(Z \leq -z) = P(Z \geq +z)$
 3. $P(Z \geq +z) = 1 - P(Z \leq +z)$ 계산
- $P(x_1 \leq X \leq x_2)$ (두 값 사이):
 1. x_1, x_2 를 각각 z_1, z_2 로 변환
 2. $P(Z \leq z_2)$ 와 $P(Z \leq z_1)$ 찾기 (음수 Z-점수 주의)
 3. $P(Z \leq z_2) - P(Z \leq z_1)$ 계산

역방향 문제 (주어진 확률로 Z-값 찾기):

- **확률 $\rightarrow$ Z-값:**
 1. Z-테이블 내부에서 주어진 확률에 가장 가까운 값 찾기
 2. 해당 Z-점수 확인 (필요시 보간)
- **Z-값 $\rightarrow$ 원본 값 (X):**
 1. $X = \mu + z \times \sigma$ 공식 사용

FAQ (자주 묻는 질문)

- **Q: Z-테이블이 $P(Z \leq z)$ 만 제공하는 이유는 무엇인가요? A:** Z-테이블이 누적 확률($P(Z \leq z)$)을 제공하는 것은 통계 계산의 효율성 때문입니다. 이 하나의 값만 알면 대칭성과 전체 면적 1의 성질을 이용하여 $P(Z \geq z)$, $P(Z \leq -z)$, $P(z_1 \leq Z \leq z_2)$ 등 모든 유형의 확률을 쉽게 유도할 수 있기 때문입니다. 가장 기본적인 정보를 제공하여 다른 모든 정보를 파생시킬 수 있도록 설계된 것입니다.
- **Q: 음수 Z-값을 직접 찾을 수 있는 Z-테이블도 있나요? A:** 네, 있습니다. 일부 Z-테이블은 음수 Z-점수에 대한 확률 값도 직접 제공합니다. 하지만 표준정규분포의 대칭성 덕분에 양수 Z-점수 테이블만으로도 모든 계산이 가능하므로, 많은 교재나 자료에서는 양수 Z-점수 테이블만 제공하는 경우가 많습니다. 두 가지 유형의 테이블 모두 같은 결과를 도출합니다.
- **Q: Z-테이블 대신 Excel이나 다른 통계 소프트웨어를 사용하면 좋은 점은 무엇인가요? A:** Excel이나 R, Python 같은 통계 소프트웨어는 Z-테이블을 수동으로 찾아보는 것보다 훨씬 빠르고 정확하게 확률을 계산해 줍니다. 특히 소수점 이하 자리가 많거나 Z-테이블에 없는 정밀한 Z-값을 다룰 때 유용합니다. 또한, 주어진 확률에 대한 Z-값을 역으로 찾아주는 함수(예: Excel의 NORM.S.INV)도 제공하여 계산 시간을 크게 단축시켜 줍니다. 이 수업에서도 Excel 사용법을 익히는 것이 중요하다고 강조하고 있습니다.

체크리스트

이 문서를 통해 학습한 내용을 점검하고, 시험 및 과제 준비에 활용하세요.

- **개념 이해**
 - 표준정규분포의 정의와 특징을 정확히 이해하고 있는가? ($\mu = 0, \sigma = 1$, 종 모양, 대칭성)
 - Z-점수의 의미와 계산 공식을 정확히 알고 있는가? ($z = (x - \mu)/\sigma$)
 - Z-테이블이 어떤 확률을 나타내는지 (누적 확률 $P(Z \leq z)$) 이해하고 있는가?
- **확률 계산 능력**
 - 특정 값보다 작을 확률 ($P(X \leq x)$)을 Z-테이블로 계산할 수 있는가?
 - 특정 값보다 클 확률 ($P(X \geq x)$)을 Z-테이블로 계산할 수 있는가?
 - 음수 Z-점수가 포함된 확률을 대칭성을 이용하여 계산할 수 있는가?
 - 두 값 사이의 확률 ($P(x_1 \leq X \leq x_2)$)을 Z-테이블로 계산할 수 있는가?
- **역방향 문제 해결 능력**
 - 주어진 확률(백분위수)에 해당하는 Z-점수를 Z-테이블에서 찾을 수 있는가? (보간 포함)
 - 찾은 Z-점수를 이용하여 원본 데이터 값 ($X = \mu + z \times \sigma$)을 계산할 수 있는가?
- **실습 및 응용**

- 제공된 예시들을 스스로 다시 풀어보고 정답을 맞출 수 있는가?
 - 새로운 문제에 Z-테이블 활용법을 적용하여 해결할 수 있는가?
 - Excel과 같은 도구를 사용하여 Z-점수 및 확률을 계산하는 방법을 알고 있는가? (이 문서에서는 개념 설명에 집중했으나, 실제 활용 시 중요)
-

Chapter 3

Lecture 3

강의명: BADM-572: Data-Driven Decision Making (데이터 탐색 및 생성)

주차: Module 3 - 파트 1/2

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 데이터 수집, 연구 유형, 샘플링 기법 등 비즈니스 의사 결정을 위한 데이터 탐색 및 생성 방법을 학습하고, 편향 없는 데이터의 중요성과 Excel 샘플링 실습을 다룹니다.

3.1 개요

이 문서는 BADM-572 과목의 'Exploring and Producing Data Module 3' 중 파트 1/2에 해당하는 내용을 다룹니다. 데이터를 비즈니스 의사 결정에 활용하기 위한 핵심적인 개념과 절차를 학습합니다. 주요 목표는 데이터 수집 방법, 다양한 연구 유형, 그리고 대표성 있는 샘플을 생성하는 다양한 샘플링 기법을 이해하는 것입니다. 특히, 편향되지 않은 데이터를 얻는 것의 중요성과 Excel을 활용한 샘플링 실습 방법을 상세히 설명합니다. 이 문서는 비전공자나 처음 배우는 사람도 완벽히 이해할 수 있도록 쉬운 설명, 풍부한 예시, 그리고 실용적인 절차를 제공하여 시험 대비 및 실무 적용에 필요한 모든 정보를 담고 있습니다.

3.2 용어 정리

데이터 분석 및 통계 학습에 필수적인 주요 용어들을 정리했습니다. 각 용어의 쉬운 설명과 원어를 함께 제공하여 이해를 돕습니다.

용어	쉬운 설명	원어	비고
반응 변수	우리가 알고 싶어 하는, 다른 요인에 의해 영향을 받는 변수	Response Variable	종속 변수라고도 함
독립 변수	반응 변수에 영향을 미칠 수 있다고 생각되는 변수	Independent Variable	설명 변수라고도 함
실험 연구	연구자가 독립 변수를 직접 조작하여 결과를 관찰하는 연구	Experimental Study	원인-결과 관계 파악에 유리
관찰 연구	연구자가 독립 변수를 조작하지 않고 자연 상태를 관찰하는 연구	Observational Study	윤리적, 현실적 제약이 있을 때 사용
횡단면 데이터	특정 시점에 여러 대상으로부터 수집된 데이터	Cross-Sectional Data	스냅샷과 같음
시계열 데이터	일정 기간 동안 동일 대상으로부터 반복적으로 수집된 데이터	Time-Series Data	시간의 흐름에 따른 변화 분석
빅 데이터	매우 방대하고 다양한 형태의 데이터 집합	Big Data	구조화/비구조화 데이터 모두 포함
샘플링	전체 모집단에서 일부를 선택하여 표본을 추출하는 과정	Sampling	모집단 특성 추론의 기초
비확률 샘플링	각 개체가 선택될 확률이 알려져 있지 않거나 동일하지 않은 샘플링	Non-Probability Sampling	편향될 가능성이 높음
자발적 샘플링	개체 스스로 연구 참여를 선택하는 샘플링	Volunteer Sampling	강한 의견을 가진 사람 위주로 편향
편의 샘플링	접근하기 쉬운 개체를 선택하는 샘플링	Convenience Sampling	시간/비용 절약, 편향 가능성 높음
편향	샘플이 모집단을 정확하게 대표하지 못하여 발생하는 오차	Bias	잘못된 결론으로 이어질 수 있음
확률 샘플링	각 개체가 선택될 확률이 알려져 있고 무작위로 선택되는 샘플링	Probability Sampling	모집단에 대한 일반화 가능
단순 무작위 샘플링	모집단의 모든 개체가 동일한 확률로 선택되는 샘플링	Simple Random Sampling	가장 기본적인 확률 샘플링
층화 샘플링	모집단을 특정 기준으로 층(strata)으로 나눈 후, 각 층에서 무작위 샘플링	Stratified Sampling	각 하위 그룹의 대표성 보장
군집 샘플링	모집단을 군집(clusters)으로 나눈 후, 일부 군집을 무작위로 선택하여 전체 또는 일부 조사	Cluster Sampling	지리적으로 넓은 지역에 유용

3.3 Preface

Gies eBook을 선택해 주셔서 감사합니다.

이 Gies eBook은 Coursera의 Fataneh Taghaboni-Dutta 교수님의 'Exploring and Producing Data for Business Decision Making' Module 3의 확장된 비디오 강의 스크립트를 기반으로 합니다. Gies eBook은 MOOC 비디오의 모든 정보를 완전히 접근 가능한 형식으로 제공하여 독서 경험을 제공합니다. 이 Gies eBook은 ePUB 3.0 형식을 지원하는 모든 표준 기반 e-리딩 소프트웨어와 함께 사용할 수 있습니다.

각 Gies eBook은 e-리더의 목차 기능을 사용하여 탐색할 수 있는 레슨(lessons)으로 나뉘어 있습니다. 각 레슨 내에서는 다음 콘텐츠 순서가 항상 나타납니다:

- 레슨 제목 (Lesson title)
- 각 레슨의 웹 기반 비디오 링크 (온라인 상태여야 시청 가능)

레슨 내에서 슬라이드가 변경되거나 다음 정보 비디오 장면으로 전환될 때마다 다음이 제공됩니다:

- 현재 슬라이드 또는 비디오 장면의 **썸네일 이미지**
- 비디오 슬라이드에 있는 모든 텍스트는 썸네일 아래에 검색 가능하고 스크린 리더 친화적인 형식으로 재구성됩니다.
- 슬라이드에 제시된 그래프 및 차트와 같은 중요한 시각 자료에 대한 **확장된 텍스트 설명**
- 비디오의 모든 표 형식 데이터는 스크린 리더 탐색 및 읽기를 위해 **재구성되고 적절하게 레이블됩니다.**
- 모든 수학 방정식은 화면에 표시될 경우 내용과 표현을 모두 제공하는 **MathML**로 제시됩니다.
- 말하는 사람별로 레이블이 지정된 비디오의 모든 원본 음성을 캡처한 **스크립트 (Transcript)**

모든 Gies eBook은 접근성과 유용성을 최우선으로 설계되었습니다. 이 디자인은 독자들이 어떤 디지털 독서 도구를 선택하든 유연한 방식으로 모든 독자에게 서비스를 제공하기 위한 것입니다.

이 Gies eBook에 대한 질문이나 개선 제안이 있으시면 Giesbooks@illinois.edu로 문의하십시오.

3.4 Module 3: Exploring and Producing Data for Business Decision Making

이 모듈에서는 비즈니스 의사 결정을 위한 데이터를 탐색하고 생성하는 방법에 대해 학습합니다. 데이터는 모든 분석의 출발점이며, 올바른 데이터를 올바른 방식으로 얻는 것이 중요합니다.

3.4.1 Lesson 3-1: Producing Data

Lesson 3-1.1: Producing Data

데이터를 생산하는 것은 우리가 알고자 하는 바를 명확히 정의하고, 그에 맞는 데이터를 수집하는 일련의 과정을 의미합니다. 이 과정은 크게 기존 데이터를 활용하거나, 직접 연구를 수행하여 새로운 데이터를 생성하는 두 가지 방식으로 나눌 수 있습니다.

데이터는 어디에서 오는가? (Where Does the Data Come From?)

우리가 무엇을 알고 싶은지 결정한 후에는 데이터가 필요합니다. 예를 들어, 미국인이 오락에 지출하는 평균 금액이나 온라인 교육을 추구하는 사람의 평균 연령과 같은 무작위 변수(random variables)를 정의했다면, 다음 단계는 데이터를 찾는 것입니다.

핵심 요약

데이터 출처: 데이터는 크게 기존 출처(Existing Sources)에서 찾거나, 직접 연구(Conducting a Study)를 통해 생성할 수 있습니다.

1. 기존 출처 (Existing Sources) 이미 공공 또는 민간 기관에서 수집해 놓은 방대한 양의 데이터가 존재합니다. 이러한 데이터는 시간과 비용을 절약할 수 있다는 장점이 있습니다.

- **정부 및 국제 기구:** 미국 정부 간행물, 세계 기구 보고서 등 전자 버전으로 제공되는 자료가 많습니다.
- **인터넷:** 다양한 웹사이트와 데이터베이스에서 정보를 얻을 수 있습니다. **예시:** 온라인 백과사전, 공개 데이터 포털, 기업 웹사이트 등.
- **도서관:** 좋은 도서관의 참고 자료 섹션이나 카운티 법원 기록에도 풍부한 정보가 있습니다. **예시:** 역사적 기록, 인구 통계 자료, 법률 문서 등.
- **데이터 수집 기관:** Bloomberg, Dow Jones and Company, Travel Industry of America, Graduate Management Admission Council, Educational Testing Services와 같은 전문 기관에서 구독료를 내거나 개별 보고서를 구매하여 데이터를 얻을 수 있습니다. **예시:** 금융 시장 데이터, 산업 보고서, 시험 성적 데이터 등.

이러한 기존 데이터는 이미 수집되어 있으므로, 연구를 시작하기 전에 먼저 필요한 데이터가 이미 존재하는지 확인하는 것이 효율적입니다.

2. 직접 연구 수행 (Conducting a Study) 때로는 우리가 필요로 하는 데이터가 기존에 존재하지 않을 수 있습니다. 이런 경우에는 직접 연구를 수행하여 데이터를 수집해야 합니다. 연구를 시작하는 단계는 다음과 같습니다.

연구 시작의 첫 번째 단계: 반응 변수 정의 (Step One in Initiating a Study)

반응 변수 (Response Variable): 우리가 관심을 가지고 이해하고자 하는 변수를 정의합니다. 이 변수는 다른 요인에 의해 영향을 받는다고 가정합니다. 통계학에서는 이 용어를 자주 사용하므로 익숙해지는 것이 중요합니다.

- **예시:** 작업자 생산성 (Worker productivity)

예제

예시: 작업자 생산성 직원들이 업무를 얼마나 효율적으로 수행하는지 알고 싶다고 가정해 봅시다. 이 경우, 우리의 관심 변수는 '작업자 생산성'이 됩니다. 이를 '시간당 서비스하는 고객 수'로 측정할 수 있습니다. 우리는 작업자 생산성이 여러 요인에 반응한다고 믿기 때문에, 이것이 반응 변수가 됩니다. 즉, 생산성은 다른 요인에 의해 영향을 받는 결과 변수입니다.

연구 시작의 두 번째 단계: 독립 변수 정의 (Step Two in Initiating a Study)

독립 변수 (Independent Variables): 관심 변수(반응 변수)와 관련이 있을 수 있으며 측정될 다른 변수들을 정의합니다. 이 변수들은 반응 변수에 영향을 미친다고 가정합니다.

- **예시:** 훈련량 (Amount of training), 장비 신뢰성 (Reliability of equipment), 해당 직무 경력 (Number of years at this job)

예제

예시: 작업자 생산성에 영향을 미치는 요인 작업자 생산성(반응 변수)에 영향을 미칠 수 있는 요인들(독립 변수)은 다음과 같습니다:

- 작업자가 받은 훈련량
- 사용하는 장비의 신뢰성
- 해당 직무에서의 경력

이러한 요인들은 작업자 생산성이라는 반응 변수에 영향을 미치는 독립 변수가 됩니다. 즉, 이 변수들은 생산성에 영향을 주는 원인 변수들입니다.

연습

연습 문제: 학습 시간이 성적에 미치는 영향 신입생 그룹에게 주당 학습 시간을 기록하도록 요청하고, 4년 동안의 GPA를 추적합니다. 이 연구에서 관심 변수(반응 변수)는 무엇이며, 독립 변수는 무엇입니까?

풀이

풀이: 학습 시간이 성적에 미치는 영향

- **관심 변수 (반응 변수):** 학생들의 GPA (학습 시간에 반응하여 변동한다고 가정)
- **독립 변수:** 주당 학습 시간 (GPA에 영향을 미친다고 가정)

연구의 유형 (Type of Study) 연구를 수행할 때는 독립 변수를 조작할 수 있는지 여부에 따라 연구 유형이 달라집니다.

연구의 유형 (1/2): 실험 연구 (Experimental Study)

실험 연구 (Experimental Study): 독립 변수를 조작(manipulated)할 수 있는 연구입니다. 연구자가 의도적으로 독립 변수의 조건을 변경하고 그에 따른 반응 변수의 변화를 관찰합니다. 이는 원인과 결과 관계를 명확히 파악하는 데 유리합니다.

- **예시:** 비료가 식물 수확량에 미치는 영향
 - **반응 변수:** 식물 수확량 (Plant yield)
 - **독립 변수:** 사용된 비료의 양 (Amount of fertilizer used)

예제

예시: 비료와 식물 수확량 특정 비료가 식물 수확량에 미치는 영향을 측정하고 싶다고 가정해 봅시다.

- 우리는 여러 구획의 땅에 **다른 양의 비료**를 주고 (독립 변수 조작)
- 수확 시점에 **수확량**을 측정합니다 (반응 변수 관찰).

이 경우, 비료의 양을 조작할 수 있으므로 실험 연구에 해당합니다. 물론, 토양조건, 물 공급 등 다른 모든 요인은 동일하게 유지된다고 가정합니다. 연구의 질을 결정하는 주요 문제 중 하나는 연구자들이 독립 변수들을 얼마나 잘, 그리고 완벽하게 식별했는지입니다. 이를 실패하면 잘못된거나 불완전한 이해로 이어질 수 있습니다.

연구의 유형 (2/2): 관찰 연구 (Observational Study)

관찰 연구 (Observational Study): 독립 변수를 통제(control)할 수 없거나 통제하는 것이 비윤리적인 연구입니다. 연구자는 자연적으로 발생하는 현상을 관찰하고 데이터를 수집합니다. 이 연구는 변수들 간의 관계를 파악하는 데 유용하지만, 인과 관계를 직접적으로 증명하기는 어렵습니다.

- **예시:** 아이들이 언어 능력을 어떻게 발달시키는가?
 - **반응 변수:** 한 살 때 아는 단어 수 (Number of words by age one)
 - **독립 변수:** 아이에게 말해준 단어 수 (Number words spoken to the child)

예제

예시: 아이들의 언어 발달 아이들이 언어 능력을 어떻게 발달시키는지에 대한 연구를 생각해 봅시다.

- 관심 변수는 '한 살 때 아기가 아는 단어 수'일 수 있습니다.
- 만약 '아기에게 말해준 단어 수'가 언어 발달에 영향을 미친다고 믿는다면, 일부 부모에게 1년 동안 아이에게 전혀 말을 걸지 못하게 하거나, 다른 부모에게 하루 18시간씩 말을 걸도록 지시하는 것은 **비윤리적**입니다.

이러한 연구는 참가자들이 스스로 아기에게 얼마나 말을 걸었는지, 아기가 한 살 때 몇 단어를 말할 수 있었는지 **자율적으로 보고(self-report)**하는 관찰 연구로만 수행될 수 있습니다.

데이터 수집 기간 (Data Collection Time Frame) 데이터를 수집하는 시점에 따라 데이터의 유형이 달라집니다.

데이터 수집 기간 (1/2): 횡단면 데이터 (Cross-Sectional Data)

횡단면 데이터 (Cross-Sectional Data): 동일하거나 거의 동일한 시점에 수집된 데이터입니다. 여러 개체(사람, 회사, 지역 등)에 대한 정보를 한 시점에서 수집합니다. 마치 특정 순간의 '스냅샷'과 같습니다.

예제

예시: 은행 직원의 휴대폰 요금 분석
직원들의 휴대폰 사용 요금을 지불하는 은행이 지난달(예: 5월) 직원들의 휴대폰 요금 청구서를 분석하고자 합니다.

- 5월 한 달 동안의 여러 직원들의 청구서를 살펴보는 것은 횡단면 데이터를 제공합니다. 이는 특정 시점(5월)에 여러 개체(직원)에 대한 데이터를 수집하는 방식입니다.

데이터 수집 기간 (2/2): 시계열 데이터 (Time-Series Data)

시계열 데이터 (Time-Series Data): 서로 다른 시간 기간에 걸쳐 수집된 데이터입니다. 동일한 개체(사람, 회사, 주식 등)에 대한 정보를 여러 시점에서 반복적으로 수집합니다. 시간의 흐름에 따른 변화와 추세를 분석하는 데 적합합니다.

예제

예시: 간호사 연구 (Nurses Study)
1976년에 시작되어 1989년에 확장된 유명한 '간호사 연구'는 시계열 데이터의 훌륭한 예시입니다.

- 이 연구는 여성 건강을 연구하기 위해 **20만 명 이상의 간호사들로부터 오랜 기간 동안 건강 관련** 데이터를 수집했습니다.
- 이는 간호사들이 연구자들의 개입 없이 생활하며 주기적으로 건강에 대한 질문에 답하고 의료 검사를 받은 **관찰 연구**였습니다.

이처럼 여러 해에 걸쳐 데이터를 수집하는 것은 시계열 데이터에 해당합니다.

연습

연습 문제: 학습 시간이 성적에 미치는 영향 (재검토)
신입생 그룹에게 주당 학습 시간을 기록하도록 요청하고, 4년 동안의 GPA를 추적합니다. 이 연구는 관찰 연구입니까, 실험 연구입니까? 데이터는 시계열입니까, 횡단면입니까?

풀이

풀이: 학습 시간이 성적에 미치는 영향 (재검토)

- **연구 유형:** 학생들에게 학습 습관을 기록하도록 요청했지만, 이를 조작하지 않았으므로 **관찰 연구 (Observational Study)**입니다.
- **데이터 유형:** 데이터가 4년이라는 기간에 걸쳐 수집되므로 **시계열 데이터 (Time-Series Data)**입니다.

연습

연습 문제: 맥주가 비만에 미치는 영향
맥주 섭취와 허리-엉덩이 비율(WHR), 체질량 지수(BMI) 간의 관계를 조사하기 위해, 연구자들은 25~64세 남성 1,141명과 여성 1,212명의 무작위 표본을 대상으로 연구를 수행했습니다. 피험자들은 설문지를 작성하고 클리닉에서 간단한 검사를 받았

습니다. 일반적인 주간 맥주, 와인, 증류주 섭취량, 음주 빈도 및 기타 여러 요인들이 설문지를 통해 측정되었습니다. 이것은 어떤 종류의 연구입니까? 데이터는 어떻게 수집되었습니까?

풀이

풀이: 맥주가 비만에 미치는 영향

- **연구 유형:** 연구자들이 맥주 섭취량을 조작하지 않고 설문지와 검사를 통해 데이터를 수집했으므로 **관찰 연구 (Observational Study)**입니다.
- **데이터 유형:** 모든 피험자로부터 동일한 시점(특정 주간, 특정 검사 시점)에 데이터가 수집되었으므로 **횡단면 데이터 (Cross-Sectional Data)**입니다.

빅 데이터 (Big Data) 오늘날 비즈니스 세계에서 중요한 개념인 빅 데이터는 통계 분석에 많은 기회를 제공합니다.

빅 데이터 (Big Data)

빅 데이터 (Big Data): 구조화된(structured) 데이터와 비구조화된(unstructured) 데이터 모두의 방대한 양을 의미합니다.

- **데이터 출처:** GPS 장치, 스마트폰, 신용카드, 건강 추적 장치, 게임 콘솔 등 다양한 수단을 통해 기업들은 데이터를 수집하고 있습니다. 이러한 장치들은 끊임없이 데이터를 생성하며, 이 데이터는 기업의 의사 결정에 활용될 수 있습니다.
- **기회:** 빅 데이터의 가용성은 다음과 같은 흥미로운 질문에 답할 수 있는 추가적인 기회를 제공합니다:
 - 누군가 심장마비 증상을 보이기 전에 심장마비가 올 것을 예측할 수 있는가? (예: 웨어러블 기기 데이터 분석)
 - 누군가 대출을 받기 전에 대출 불이행 가능성을 예측할 수 있는가? (예: 신용 기록, 거래 패턴, 소셜 미디어 데이터 분석)

이러한 방대한 데이터를 이해하는 능력은 우리가 관심 있는 변수에 대한 이해를 얻기 위해 데이터를 찾는 또 다른 방법입니다. 통계에서 수행되는 모든 분석은 관심 모집단의 부분 집합인 **표본(sample)**으로 시작합니다. 따라서 어떤 데이터가 필요한지 알게 되면, 표본을 생성해야 합니다. 다음 레슨에서는 이러한 표본을 생성하는 방법을 논의할 것입니다.

학술 인용 (Academic Citation)

Bobak, M., Skodove, Z., and Marmot, M. (2003). Beer and obesity: A cross-sectional study. European Journal of Clinical Nutrition, 57(10). Retrieved from <https://www.ncbi.nlm.nih.gov/pubmed/14506485>.

3.4.2 Lesson 3-2: Sampling

Lesson 3-2.1: Sampling

지금까지 데이터를 요약하고 분포에 대해 배웠습니다. 또한 표본에서 데이터를 얻는 것에 대해서도 이야기했습니다. 이제 데이터를 생성하는 방법, 즉 **샘플링(Sampling)**에 대해 이야기할 시간입니다. 뉴스 프로그램이나 기사를 읽을 때 '과학적 연구(scientific study)' 또는 '과학적 여론조사(scientific poll)'와

같은 용어를 들어본 적이 있을 것입니다. 이는 비과학적인 방식으로 데이터가 생성될 수도 있다는 것을 의미합니다.

핵심 요약

샘플링 방법: 표본을 추출할 때는 크게 두 가지 방법 중 하나를 사용합니다.

1. **비확률 방법 (Non-Probability Methods):** 각 개체가 선택될 확률이 알려져 있지 않거나 동일하지 않습니다.
2. **확률 방법 (Probability Methods):** 각 개체가 선택될 확률이 알려져 있고 무작위로 선택됩니다.

이러한 방법들을 자세히 살펴보겠습니다.

비확률 방법 (Non-Probability Method) 비확률 샘플링은 모집단의 각 개체가 표본으로 선택될 확률이 알려져 있지 않거나 동일하지 않은 방법입니다. 이 방법은 편리하고 비용 효율적일 수 있지만, 표본이 모집단을 대표하지 못하여 **편향(bias)**이 발생할 위험이 높습니다. 따라서 이 방법으로 얻은 결과는 모집단에 대해 일반화하기 어렵습니다.

비확률 방법 (1/2): 자발적 샘플링 (Volunteer Sampling)

자발적 샘플링 (Volunteer Sampling): 개인이 스스로 연구 참여를 선택하여 표본에 포함되기를 선택하는 방식입니다.

- **문제점:**
 - **편향 (Bias):** 특정 문제에 대해 강한 의견을 가진 사람들이 주로 참여하므로, 표본이 모집단을 대표하지 못합니다.
 - **결과 일반화 불가 (Results are not generalizable):** 표본에서 얻은 결과를 더 큰 모집단에 적용하기 어렵습니다.

예제

예시: 제품 리뷰 구매한 제품에 대한 리뷰를 남기는 것은 자발적 샘플링의 예시입니다. 리뷰를 남기는 고객은 특정 의견(매우 만족 또는 매우 불만족)을 가지고 있을 가능성이 높습니다.

- **문제점:** 이러한 데이터는 통계적으로 '비과학적'으로 간주됩니다. 왜냐하면 대부분의 경우 특정 문제에 대해 강한 의견을 가진 개인의 데이터만 포함되어 **편향될** 가능성이 높기 때문입니다.
- **일반화의 한계:** 자발적 응답 표본에서 얻은 데이터는 표본으로 추출된 개인이 자신에 대한 정보만 제공하므로, 더 큰 그룹에 대해 일반화하기 어렵습니다.

예외: 그러나 의료 치료를 위한 임상 시험과 같이, 개인이 의료 연구에 참여하도록 강요하는 것이 비윤리적인 경우에는 자발적 샘플링이 유일한 방법일 수 있습니다. 이 경우, 여러 치료법을 비교할 때는 자발적 샘플링이 덜 문제가 됩니다. (이 시리즈의 두 번째 과정에서 더 자세히 논의될 예정입니다.)

비확률 방법 (2/2): 편의 샘플링 (Convenience Sampling)

편의 샘플링 (Convenience Sampling): 연구자가 접근하기 편리하다는 이유로 대상을 선택하는 방식입니다.

예제

예시: 투표소 앞 여론조사 뉴스 매체에서 투표소 밖에 서서 투표를 마치고 나오는 유권자들에게 누구에게 투표했는지 묻는 경우가 편의 샘플링의 예시입니다.

- **문제점:** 각 개인이 응답을 거부하거나 응답하기로 선택할 수 있으므로, 자발적 샘플링의 요소도 포함되어 **편향**이 발생할 수 있습니다.
- **상황에 따른 유용성:** 그러나 수집되는 변수에 따라서는 이 유형의 표본이 상당히 대표적인 그룹을 제공할 수도 있습니다. 하지만 일반적으로 편향은 표본에서 가장 문제가 되는 문제입니다.

비대표성 표본 사용의 문제점: 편향 (The Problem With Using a Non-Representative Sample - Bias) 편향된 표본은 잘못된 결론으로 이어질 수 있습니다. 역사적인 사례를 통해 이를 이해해 봅시다.

1936년 미국 대통령 선거 (1936 Presidential Election)

- **후보:** 프랭클린 D. 루즈벨트 (Franklin D. Roosevelt) vs. 알프레드 랜던 (Alfred Landon)
- **배경:** 대공황 직후로, 실업률과 정부 지출과 같은 경제 문제가 주요 쟁점이었습니다. 루즈벨트는 정부 지출을 통한 고용 증대를 지지했고, 랜던은 이를 제한하는 것을 선호했습니다. 랜던은 주로 부유층 유권자들에게 선호되었습니다.
- **예측:** 당시 가장 존경받는 잡지 중 하나인 *The Literary Digest*는 루즈벨트의 패배를 예측했습니다.
- **결과:** 루즈벨트가 압도적인 승리를 거두었습니다. *The Literary Digest*의 예측은 틀렸습니다. (랜던은 단 두 개 주에서만 승리했습니다.)

예제

무엇이 잘못되었는가? *The Literary Digest*는 전화번호부에서 표본을 추출했습니다.

- **문제점:** 1930년대에는 전화가 부유층만이 가질 수 있는 사치품이었습니다.
 - **결과:** 따라서 그들의 표본은 **편향**되었고, 유권자 모집단을 정확하게 대표하지 못했습니다. 여론조사에 참여한 사람들이 부유층이었기 때문에 랜던이 당선될 것이라는 인상을 주었지만, 실제로는 정반대였습니다.
- 이 사례는 대표성 없는 표본이 얼마나 심각한 오류를 초래할 수 있는지를 보여줍니다.

대표성 있는 표본 (Representative Sample) 데이터 분석을 올바르게 수행하려면, 편향되지 않고 모집단을 잘 대표하는 표본으로 시작해야 합니다.

대표성 있는 표본 (Representative Sample)

무작위로 선택된 표본 (A Randomly Selected Sample)은 다음과 같은 특징을 가집니다:

- **모집단 대표성:** 전체 모집단을 대표합니다.
- **편향 방지:** 표본의 평균이 모집단의 평균과 유사하게 만들어 편향을 피합니다.
- **모집단 특성 추론 가능:** 표본으로부터 모집단의 특성을 추론할 수 있게 합니다.
- **표본 크기와 모집단 크기:** 더 큰 모집단이라고 해서 더 큰 표본이 필요한 것은 아닙니다.

예제

표본 크기에 대한 오해 해소 ”더 큰 모집단이라고 해서 더 큰 표본이 필요한 것은 아닙니다.” 이 말은 매우 중요합니다.

- 예를 들어, 중국 소비자에 대해 알고 싶다고 해서 미국 소비자에 대한 연구보다 더 큰 표본을 취할 필요는 없습니다.
- 중요한 것은 **표본이 얼마나 잘 무작위로 추출되어 모집단을 대표하는가**이지, 모집단의 절대적인 크기가 아닙니다.

이러한 방식으로 표본을 올바르게 선택하면, '과학적 여론조사' 또는 '과학적 연구'라고 불릴 수 있는 결과를 얻을 수 있습니다.

확률 샘플링 기법 (Probability Sampling Techniques) 과학적인 여론조사나 연구를 위해서는 확률 샘플링 방법을 사용해야 합니다. 이 방법들은 표본에서 얻은 결과를 모집단에 일반화할 수 있게 해줍니다.

확률 샘플링 기법 (1/3): 단순 무작위 샘플링 (Simple Random Sampling)

단순 무작위 샘플링 (Simple Random Sampling): 모집단의 모든 개체가 다른 개체와 동일한 확률로 선택될 기회를 가집니다. 이는 가장 기본적인 확률 샘플링 계획입니다.

예제

예시: 제비뽑기 이름이 적힌 모자에서 이름을 뽑는 것과 같습니다. 각 개인이 선택될 확률이 동일합니다.

- **장점:** 선택 과정에서 편향이 발생하지 않도록 보장하는 한 가지 방법입니다.
- **주의점:** 그러나 선택된 구성원들의 **무응답(non-response)**과 관련된 편향이 발생할 수 있습니다. 예를 들어, 전화나 우편으로 설문 요청을 받았을 때 응답하지 않으면 무응답으로 분류됩니다. 연구자들은 편향을 줄이기 위해 응답률을 높이는 데 많은 노력을 기울입니다.

확률 샘플링 기법 (2/3): 층화 샘플링 (Stratified Sampling)

층화 샘플링 (Stratified Sampling): 모집단이 **자연적으로 하위 모집단(층, strata)**으로 나눌 수 있을 때 사용됩니다. 각 층에서 단순 무작위 샘플을 추출하여 전체 표본을 구성합니다. 이 방법은 각 하위 그룹의 대표성을 보장하는 데 효과적입니다.

- **예시:** 여성 (200명) + 남성 (200명) = 총 400명

예제

예시: 성별 대표성 보장 여론조사를 실시할 때, 남성과 여성 모두가 표본에 공정하게 대표되도록 하고 싶다고 가정해 봅시다. 이 경우, 성별을 기준으로 두 개의 층(strata)을 만듭니다.

- 여성 층에서 200명의 여성을 단순 무작위로 선택하고,
 - 남성 층에서 200명의 남성을 단순 무작위로 선택합니다.
 - 이렇게 선택된 총 400명이 우리의 최종 표본이 됩니다.
- 층화 샘플링은 각 하위 그룹의 대표성을 보장하는 데 효과적입니다.

확률 샘플링 기법 (3/3): 군집 샘플링 (Cluster Sampling)

군집 샘플링 (Cluster Sampling): 모집단이 자연적으로 그룹(군집, clusters)으로 나뉘어 있을 때 사용됩니다. 각 군집은 모집단의 축소판처럼 행동할 것으로 예상됩니다.

• **절차:**

1. 무작위로 일부 군집을 선택합니다.
2. 선택된 군집의 모든 구성원을 표본에 포함하거나, 선택된 군집 내에서 일부 구성원을 무작위로 선택합니다.

예제

예시: 지역별 소득 조사 넓은 지리적 영역에 퍼져 있는 모집단이나, 지역별로 관심 변수에 차이가 있는 경우(예: 동네별 소득 조사)에 군집 샘플링이 적합합니다.

- 큰 도시를 15개의 군집(예: 동네)으로 나눈 후, 이 중 8개의 군집을 무작위로 선택하여 표본을 추출할 수 있습니다.

층화 샘플링과의 차이점:

- **층화 샘플링:** 모든 층에서 무작위 표본을 추출합니다. 각 층은 동질적이지만 층 간에는 이질적입니다.
- **군집 샘플링:** 일부 군집에서만 표본을 추출합니다. 각 군집은 이질적이지만 군집 간에는 동질적입니다.

두 방법 모두 무작위 표본을 추출하기 전에 모집단을 나누는 작업이 필요하지만, 군집 샘플링은 더 작은 표본으로도 좋은 대표성 있는 표본을 얻을 수 있습니다.

연습

연습 문제: 패스트푸드점 고객 만족도 조사 총 10개의 패스트푸드점 네트워크를 운영하고 있으며, 고객들이 음식과 서비스 품질에 만족하는지 알고 싶습니다. 다음 샘플링 기법들을 분류하십시오:

1. 모든 고객은 계산서와 함께 전화번호를 받고 의견을 제시하도록 권장됩니다.
2. 3개의 식당을 선택하고, 지난주에 이 3개 지점을 방문한 모든 고객에게 연락하여 설문조사를 실시합니다.
3. 각 식당에서 무작위로 50명의 고객을 선택하여 설문조사를 실시합니다.
4. 과거 고객 데이터베이스에서 무작위로 500명의 고객을 선택하여 설문조사를 실시합니다.

풀이

풀이: 패스트푸드점 고객 만족도 조사 (1/4)

1. 모든 고객은 계산서와 함께 전화번호를 받고 의견을 제시하도록 권장됩니다.

- **유형:** 자발적 샘플링 (Volunteer Sampling)

- **설명:** 이는 비확률 방법입니다. 매우 만족하거나 매우 불만족한 고객의 비율이 불균형하게 나타나 잘못된 인상을 줄 수 있습니다. 불만족한 고객은 연락하지 않고 단순히 재방문하지 않을 수 있어, 개선에 필요한 피드백을 놓칠 수 있습니다.

폴이

폴이: 패스트푸드점 고객 만족도 조사 (2/4)

2. 3개의 식당을 선택하고, 지난주에 이 3개 지점을 방문한 모든 고객에게 연락하여 설문조사를 실시합니다.

- **유형: 군집 샘플링 (Cluster Sampling)**
- **설명:** 전체 고객 기반이 방문한 식당(군집)으로 나뉩니다. 우리는 3개의 군집을 선택했고, 이 3개 식당을 지난주에 방문한 모든 고객에게 설문조사를 실시했습니다.

폴이

폴이: 패스트푸드점 고객 만족도 조사 (3/4)

각 식당에서 무작위로 50명의 고객을 선택하여 설문조사를 실시합니다.

- **유형: 층화 샘플링 (Stratified Sampling)**
- **설명:** 10개의 식당이 있으므로 10개의 층(strata)이 있습니다. 각 식당에서 고객을 조사함으로써, 최악의 서비스 기록이나 최고의 서비스 기록을 가진 식당을 놓치지 않고 모든 10개 지점의 대표성을 확보할 수 있습니다.

폴이

폴이: 패스트푸드점 고객 만족도 조사 (4/4)

과거 고객 데이터베이스에서 무작위로 500명의 고객을 선택하여 설문조사를 실시합니다.

- **유형: 단순 무작위 샘플링 (Simple Random Sample)**
- **설명:** 고객이 어떤 식당을 방문했는지와 관계없이 무작위로 선택되었으므로 단순 무작위 샘플링의 예시입니다.

표본 크기 (Sample Size) 지금까지 표본 크기에 대해서는 언급하지 않았습니다. 가장 중요한 우선순위는 확률 샘플링 계획을 사용하여 모집단을 대표하는 표본을 확보하는 것입니다.

핵심 요약

표본 크기 고려 사항:

- **대표성 우선:** 가장 먼저 해야 할 일은 확률 샘플링 계획을 사용하여 모집단을 대표하는 표본을 확보하는 것입니다. 편향되지 않은 표본이 좋은 분석의 기초입니다.
- **정확도 향상:** 표본이 클수록 모집단에 대해 더 정확한 아이디어를 얻을 수 있습니다. 즉, 표본 크기가 클수록 추정치의 정밀도가 높아집니다.
- **비용 문제:** 더 큰 표본을 수집하는 데는 항상 시간과 비용이 수반됩니다. 따라서 연구의 목적과 예산에 맞춰 적절한 표본 크기를 결정해야 합니다.
- **필요에 따른 계산:** 우리의 요구 사항(예: 원하는 오차 범위, 신뢰 수준)에 따라 필요한 표본의 크기를 계산할 수 있습니다.

이 레슨에서는 모집단에서 개인 또는 데이터 포인트를 선택하는 다양한 기술을 배웠습니다. 이는 겉보기에는 간단한 단계이지만, 실제로는 매우 중요한 단계입니다. 좋은 표본 없이는 좋은 분석이 불가능합니다. 일반적으로 확률 샘플링 방법은 편향되지 않은 표본을 생성하며, 이를 통해 우리의 발견을 안전하게 일반화할 수 있습니다. 그러나 비확률 샘플링 기술을 사용하는 것이 유일한 선택인 경우도 있습니다. 이러한 기술이 사용될 때는 그들이 도입하는 편향의 유형과 그 결과로 얻은 표본에서 도출할 수 있는 결론의

한계를 인식하는 것이 중요합니다.

Lesson 3-2.2: Sampling Function in Excel

이 섹션에서는 Excel의 데이터 분석 기능을 사용하여 모집단에서 표본을 추출하는 방법을 실습합니다.

주의

사전 준비: 이 실습을 위해서는 'Daily Temperature' Excel 파일이 필요합니다. 이 파일은 일반적으로 강의 자료에서 제공되며, 첫 번째 워크시트에 데이터가 포함되어 있습니다.

Excel에서 샘플링 기능 사용하기 우리는 샴페인, 시카고, 뉴욕 세 도시의 일일 기온 데이터를 가지고 있습니다. 여기서는 뉴욕의 기온 데이터를 사용하여 샘플링을 진행합니다.

일일 기온 Excel 시트 (Daily Temperature Excel Sheet)

데이터 설명: Excel 워크시트에는 일련번호(day #), 날짜(date), 그리고 샴페인, 시카고, 뉴욕 공항의 기온 데이터가 다섯 개의 열로 구성되어 있습니다. 이 데이터는 수만 개의 관측치를 포함할 수 있습니다.

1. 데이터 선택:

- 뉴욕 기온 데이터가 있는 열(예: E열)을 선택합니다.
- 첫 번째 데이터 셀(예: E2)을 클릭한 후, **Ctrl + Shift + 아래쪽 화살표**를 눌러 해당 열의 모든 데이터를 빠르게 선택합니다. 이 예시에서는 26,000개가 넘는 일일 기온 데이터가 있습니다 (예: E1부터 E26771까지).

2. 데이터 분석 도구 열기:

- Excel 리본 메뉴에서 데이터 (Data) 탭을 클릭합니다.
- 데이터 분석 (Data Analysis)을 클릭합니다 (일반적으로 리본 메뉴의 오른쪽 끝에 위치). 만약 이 옵션이 보이지 않는다면, Excel 추가 기능에서 '분석 도구(Analysis ToolPak)'를 활성화해야 합니다.

3. 샘플링 기능 선택:

- '데이터 분석' 팝업 창에서 목록을 아래로 스크롤하여 **샘플링 (Sampling)**을 선택한 후 **확인 (OK)**을 클릭합니다.

4. 샘플링 설정: '샘플링' 팝업 창이 나타나면 다음을 설정합니다.

- **입력 범위 (Input Range):** 뉴욕 기온 데이터가 있는 전체 범위를 입력합니다 (예: \$E\$1:\$E\$26771). 이 범위는 첫 번째 셀(E1)에 열 이름('New York')이 포함되어야 합니다.
- **레이블 (Labels):** 첫 번째 셀(E1)에 'New York'과 같은 레이블이 포함되어 있다면, 레이블 확인란을 선택합니다. 이렇게 하면 Excel이 첫 번째 셀을 데이터가 아닌 레이블로 인식하여 샘플링에서 제외합니다.
- **샘플링 방법 (Sampling Method):**
 - **주기적 (Periodic):** 특정 간격(예: 4)을 지정하면 원본 데이터에서 매 4번째 데이터를 선택합니다. 이는 무작위성이 낮아 편향될 수 있습니다.
 - **무작위 (Random):** 무작위로 데이터를 선택합니다. 여기서는 무작위를 선택하여 대표성 있는 샘플을 얻습니다.

- **샘플 수 (Number of Samples):** 이 필드는 통계학에서 말하는 '샘플의 수'가 아니라, 하나의 샘플에 포함될 관측치의 수(샘플 크기)를 의미합니다. 예를 들어, 130을 입력하여 130개의 관측치를 가진 샘플을 추출합니다.
 - **출력 옵션 (Output Options):**
 - 출력 범위 (Output range): 특정 셀을 지정하여 결과를 출력합니다.
 - 새 워크시트 (New Worksheet Ply): 새 워크시트에 결과를 출력합니다 (기본적으로 선택).
 - 새 통합 문서 (New Workbook): 새 통합 문서에 결과를 출력합니다.
- 여기서는 새 워크시트를 선택하고 확인 (OK)을 클릭합니다.

5. 첫 번째 샘플 확인:

- 새로운 워크시트가 생성되고, A 열에 130개의 무작위로 선택된 뉴욕 기온 데이터가 나타납니다. 첫 번째 데이터는 레이블로 인식되어 제외됩니다.
- A1 셀에 'Sample 1'과 같이 이름을 지정합니다.

6. 여러 샘플 추출 (선택 사항): 중심 극한 정리(Central Limit Theorem)를 이해하기 위해 여러 개의 샘플을 추출하는 것이 유용합니다.

- 새 워크시트의 B1 셀에 'Sample 2'를 입력하고, C1, D1, E1에 각각 'Sample 3', 'Sample 4', 'Sample 5'를 입력합니다.
- 원본 데이터 시트(Sheet 1)로 돌아가서 2 4단계를 반복합니다.
- 이때, 출력 옵션에서 출력 범위를 선택하고, 새 워크시트(Sheet 2)의 B2 셀을 지정하여 두 번째 샘플이 첫 번째 샘플 옆에 위치하도록 합니다. 주의: 출력 범위를 지정할 때, 이전에 입력 범위가 자동으로 다시 강조 표시될 수 있습니다. 출력 범위 셀을 클릭한 후 다른 곳을 클릭하기 전에 반드시 출력 범위 입력 상자가 활성화되어 있는지 확인해야 합니다.
- 이 과정을 5번 반복하여 5개의 다른 샘플을 추출합니다. 각 샘플은 130개의 관측치를 가집니다. (샘플 크기는 매번 동일할 필요는 없지만, 이 예시에서는 130으로 고정했습니다.)

7. 샘플 평균 계산: 각 샘플의 평균을 계산하여 샘플 평균이 어떻게 다른지 확인합니다.

- 예를 들어, G 열에 'Sample 1 average', 'Sample 2 average' 등을 입력합니다.
- H 열에 다음 수식을 사용하여 각 샘플의 평균을 계산합니다:

```

1 =AVERAGE(A2:A131) % Sample 의1 평균 (부터A2 까지A131 개130 데이터)
2 =AVERAGE(B2:B131) % Sample 의2 평균
3 =AVERAGE(C2:C131) % Sample 의3 평균
4 =AVERAGE(D2:D131) % Sample 의4 평균
5 =AVERAGE(E2:E131) % Sample 의5 평균
6

```

Listing 3.1: 샘플 평균 계산 예시

- 결과는 다음과 같을 수 있습니다 (예시 값):
 - Sample 1 평균: 55.97807693
 - Sample 2 평균: 54.91192308
 - Sample 3 평균: 58.03353846
 - Sample 4 평균: 57.76907692
 - Sample 5 평균: 55.77107692

핵심 요약

샘플링 결과 분석: 동일한 대규모 데이터 세트에서 추출된 5개의 샘플(각 130개 관측치)은 서로 다른 평균값을 가집니다. 예를 들어, 샘플 3이 가장 높은 평균을, 샘플 2가 가장 낮은 평균을 보였습니다.

이러한 샘플 평균의 차이를 이해하는 것이 **중심 극한 정리 (Central Limit Theorem)**의 핵심입니다. 나중에 샘플 평균의 분포를 살펴보고 중심 극한 정리가 어떻게 작동하는지 이해하게 될 것입니다. 이 실습은 중심 극한 정리의 개념을 시각적으로 이해하는 데 중요한 기초를 제공합니다.

3.5 개요

문서 핵심 요약

이 문서는 'Exploring and Producing Data Module 3'의 후반부 내용을 다루며, 통계학의 핵심 개념인 **중심 극한 정리(Central Limit Theorem, CLT)**를 심층적으로 탐구합니다. 표본 평균과 표본 비율의 분포가 모집단의 형태와 관계없이 충분히 큰 표본 크기에서 정규 분포를 따른다는 원리를 이해하고, 이를 통해 단일 표본으로 모집단에 대한 신뢰성 있는 추론을 수행하는 방법을 학습합니다. 실제 데이터와 시뮬레이션, Excel 실습을 통해 CLT의 강력한 힘과 경험적 규칙(Empirical Rule)의 적용을 시각적으로 확인하며, 데이터 기반 의사결정의 기초를 다집니다.

3.6 용어 정리

Table 3.1: 주요 통계 용어 정리

용어	쉬운 설명	원어	비고
중심 극한 정리	표본 평균의 분포가 모집단 형태와 무관하게 정규 분포를 따르는 현상	Central Limit Theorem (CLT)	통계적 추론의 기반
표본 평균	여러 표본에서 계산된 평균들의 분포	Sampling Distribution of Sample Means	표본 크기가 커질수록 정규 분포에 가까워짐
표본 비율	여러 표본에서 계산된 비율들의 분포	Sampling Distribution of Sample Proportions	표본 크기가 커질수록 정규 분포에 가까워짐
표준 오차	표본 평균 또는 표본 비율 분포의 표준 편차	Standard Error (SE)	표본 크기가 클수록 작아짐 (정확도 증가)
모집단	연구 대상이 되는 전체 집단	Population	모든 개체의 특성
표본	모집단에서 추출된 일부 집단	Sample	모집단을 대표하도록 무작위 추출
점 추정량	모집단 모수를 추정하기 위해 표본에서 계산된 값	Point Estimator	표본 평균($\bar{x}$), 표본 비율($\hat{p}$) 등
경험적 규칙	정규 분포에서 평균으로부터 표준 편차의 배수 내에 데이터가 포함되는 비율	Empirical Rule (68-95-99.7 Rule)	표본 평균 분포에 적용 가능
모집단 평균	모집단 전체의 평균	Population Mean (μ)	미지의 값인 경우가 많음
표본 평균	표본에서 계산된 평균	Sample Mean ($\bar{x}$)	모집단 평균의 추정치
모집단 표준 편차	모집단 전체의 표준 편차	Population Standard Deviation (σ)	모집단 데이터의 퍼짐 정도
표본 표준 편차	표본에서 계산된 표준 편차	Sample Standard Deviation (s)	표본 데이터의 퍼짐 정도
모집단 비율	모집단 전체에서 특정 범주에 속하는 비율	Population Proportion (p)	미지의 값인 경우가 많음
표본 비율	표본에서 특정 범주에 속하는 비율	Sample Proportion ($\hat{p}$)	모집단 비율의 추정치

3.7 핵심 개념 및 원리

3.7.1 3-3.1 중심 극한 정리와 표본 평균 (Central Limit Theorem and Sampling Means)

중심 극한 정리(CLT)의 중요성

대부분의 사람들은 작은 표본으로 얻은 결과에 대해 의심을 품습니다. 하지만 통계학의 '슈퍼히어로'인 **중심 극한 정리(CLT)** 덕분에, 우리는 편향되지 않고 대표성 있는 표본만 있다면, 그 크기가 상대적으로 작더라도 모집단에 대한 정확한 결론을 내릴 수 있습니다. 이 정리는 표본 평균의 분포가 특정 조건을 만족할 때 정규 분포를 따른다는 강력한 통찰을 제공합니다.

CLT의 기본 원리: 표본 평균의 분포

우리는 모집단 전체를 연구할 시간이나 수단이 없는 경우가 많습니다. 그래서 표본 연구에 의존하게 되는데, 이때 중심 극한 정리가 큰 역할을 합니다. 이 정리는 다음과 같은 핵심 아이디어를 제공합니다:

- **작은 표본으로 큰 결론:** 소수의 사람들에게 신약을 테스트하고 전 세계에 안전하고 효과적이라고 결정하는 것과 같이, 작은 표본으로도 광범위한 결론을 도출할 수 있는 근거가 됩니다.
- **통계학의 슈퍼히어로:** 통계학에서 가장 강력한 정리 중 하나로, 표본을 통해 모집단을 이해하는 데 필수적인 도구입니다.

이 정리를 이해하기 위해 구체적인 예시를 살펴보겠습니다.

예시: 침대들의 영화 관람 지출

영화 스튜디오는 수익을 위해 영화를 제작하며, 침대(13 19세)는 중요한 고객층입니다. 스튜디오는 어떤 유형의 영화를 우선 제작할지 결정하기 위해 침대들이 영화 관람에 얼마나 돈을 쓰는지 알고 싶어 합니다.

- **모집단 질문:** 전국의 모든 침대들이 영화 관람에 얼마나 돈을 쓸까요?
- **이상적인 시나리오:** 모든 침대에 대해 물어본다면, 대부분의 지출액은 평균 근처에 모여 있을 것이고, 평균에서 멀어질수록 해당 금액을 지출하는 침대는 줄어들 것입니다.
- **현실적인 제약:** 모든 침대에 대해 물어볼 수는 없습니다. 따라서 우리는 무작위 표본을 추출하여 조사합니다.

첫 번째 연구: 25명의 침대 그룹에게 연간 영화 관람 지출액을 물어봅니다.

- **표본 크기:** $n = 25$
- **개별 응답 분포:** 히스토그램은 3,000달러에서 10,500달러까지 넓은 범위의 지출액을 보여줍니다.
- **그룹 평균:** 이 25명의 평균 지출액은 약 **\$728**입니다.

이 한 그룹의 평균이 전체 모집단을 대표하지 않을 수 있으므로, 우리는 이러한 표본을 여러 번 추출하여 그 평균들을 살펴봅니다. 이 연구에서는 25명의 침대로 구성된 그룹 99개를 더 추출하여 각 그룹의 평균 지출액을 기록할 것입니다. 최종적으로 총 100개의 평균 지출액을 얻게 됩니다.

표본 크기 변화에 따른 표본 평균 분포의 변화

100개의 표본 평균(각 표본 크기 $n = 25$)을 히스토그램으로 그리면, 그 분포는 다소 종 모양(bell-shaped)을 띠는 것을 확인할 수 있습니다.

Figure 3.1: 표본 크기 $n = 25$ 일 때 100개 표본 평균의 분포 (가상 이미지)

설명: 이 히스토그램은 6,000달러에서 7,500달러 사이에 집중되어 있으며, 대략적인 종 모양을 보여줍니다.

이제 표본 크기를 늘려가면서 표본 평균의 분포가 어떻게 변하는지 관찰해 봅시다.

- **표본 크기 $n = 50$:** 각 그룹의 표본 크기를 50으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,000달러에서 7,000달러 사이에 더 밀집된 형태를 보입니다.
- **표본 크기 $n = 100$:** 각 그룹의 표본 크기를 100으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,000달러에서 6,800달러 사이에 더욱 밀집됩니다.

- **표본 크기 $n = 250$:** 각 그룹의 표본 크기를 250으로 늘리고 100개의 그룹을 조사합니다. 히스토그램은 6,200달러에서 6,600달러 사이에 훨씬 더 밀집된 형태를 보입니다.

Figure 3.2: 표본 크기 증가에 따른 표본 평균 분포의 변화 (가상 이미지)

설명: 5개의 히스토그램이 나란히 표시되어 있으며, 표본 크기가 증가할수록 분포가 더욱 정규 분포에 가까워지고 평균 주변에 밀집되는 것을 시각적으로 보여줍니다.

CLT의 핵심 관찰 결과

표본 크기가 증가함에 따라, 표본 평균의 분포는 다음과 같이 변합니다:

- **분포의 퍼짐 감소:** 분포의 폭(spread)이 줄어듭니다.
- **정규 분포에 수렴:** 분포가 평균을 중심으로 더욱 고르게 퍼지면서 전형적인 정규 분포(normal distribution) 형태에 가까워집니다.
- **좁아지는 분포:** 분포가 좁아진다는 것은 표준 편차가 작아진다는 의미이며, 이는 표본 평균이 모집단 평균을 훨씬 더 잘 대표하게 됨을 뜻합니다.

비정규 모집단에도 적용되는 CLT

그렇다면 모집단 자체가 정규 분포를 따르지 않는 경우에도 이러한 현상이 나타날까요? 중심 극한 정리의 진정한 힘은 바로 여기에 있습니다.

예시: 시카고 일일 평균 기온 분포

시카고의 수년간 일일 평균 기온 분포를 살펴보면, 이는 정규 분포가 아닌 **이봉 분포(bimodal distribution)**를 보입니다. 두 개의 봉우리는 추운 달과 따뜻한 달에 가장 자주 관측되는 기온을 나타냅니다.

이러한 비정규 모집단에서 표본 평균의 표본 분포는 어떻게 나타날까요? 우리는 시카고의 평균 기온을 추정하기 위해 다음과 같이 여러 표본을 추출해 보겠습니다.

- **표본 크기 $n = 5$:** 100개의 표본을 추출하고 각 표본에서 5개의 관측치를 선택합니다. 표본 평균의 분포는 36도에서 60도 사이에 집중되며, 48.71도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 25$:** 표본 크기를 25로 늘립니다. 표본 평균의 분포는 38.9680도에서 59도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 50$:** 표본 크기를 50으로 늘립니다. 표본 평균의 분포는 41도에서 57도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.
- **표본 크기 $n = 100$:** 표본 크기를 100으로 늘립니다. 표본 평균의 분포는 42도에서 56.5도 사이에 집중되며, 56도 근처에 봉우리가 있습니다.

비정규 모집단에 대한 CLT의 결론

비정규 모집단에서도 표본 크기가 증가함에 따라, 표본 평균의 분포는 다음과 같이 변합니다:

- **정규 분포에 수렴:** 표본 평균의 분포는 더욱 정규 분포에 가까워집니다.
- **좁아지는 분포:** 분포가 더욱 좁아집니다.

이는 모집단의 실제 분포가 무엇이든 상관없이, 표본 크기가 충분히 크다면 표본 평균의 분포는 항상 대략적으로 정규 분포를 따른다는 것을 의미합니다. 이 특별한 현상 덕분에 우리는 실제 모집단이 정규 분포를 따르든 아니든 상관없이 정규 분포의 속성을 활용할 수 있습니다.

표본 평균 분포의 특성: 표준 오차

표본 평균의 분포를 설명할 때, 우리는 중심 경향성(central tendency)과 변동성(variability)을 사용합니다.

- **중심 경향성:** 표본 평균 분포의 중심은 **표본 평균($\bar{x}$)**으로 나타냅니다. 이는 모집단 평균(μ)에 대한 점 추정량(point estimator)이 됩니다.
- **변동성:** 표본 평균 분포의 변동성은 **표준 오차(Standard Error, SE)**라고 부릅니다. 표준 오차는 다음 공식으로 계산됩니다:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

여기서 σ 는 모집단 표준 편차이고, n 은 표본 크기입니다. 만약 모집단 표준 편차 σ 를 모른다면, 표본 표준 편차 s 를 대신 사용하여 추정할 수 있습니다.

표준 오차의 의미와 표본 크기의 중요성

수학적으로 이 공식을 보면, **표본 크기(n)**가 증가할수록 분모가 커지므로 표준 오차($\sigma_{\bar{x}}$)는 **감소**합니다. 이는 표본 평균 분포의 변동성이 줄어든다는 것을 의미합니다.

- **신뢰성 증가:** 표본 크기가 클수록 표준 오차가 작아지므로, 더 큰 표본 크기에서 얻은 결과는 더 신뢰할 수 있습니다.
- **대표성 증가:** 표본 평균 분포가 좁아질수록, 표본 평균이 모집단의 참 평균에 더 가까워집니다. 이것이 바로 모든 통계 분석에서 **표본 크기가 매우 중요한 이유**입니다. 다음 모듈에서는 적절한 표본 크기를 결정하는 방법에 대해 더 자세히 배울 것입니다.

중심 극한 정리의 궁극적인 활용: 경험적 규칙

중심 극한 정리 덕분에 표본 평균이 정규 분포를 따른다는 것을 알게 되었으므로, 우리는 정규 곡선의 강력한 속성인 **경험적 규칙(Empirical Rule)**을 활용할 수 있습니다.

Figure 3.4: 정규 분포와 경험적 규칙 (가상 이미지)

설명: 평균을 중심으로 종 모양의 곡선이 그려져 있으며, ± 1 표준 편차 내에 68

- **68% 규칙:** 모든 표본 평균의 약 **68%**는 모집단 평균으로부터 **1 표준 오차** 이내에 놓일 것으로 예상됩니다.
- **95% 규칙:** 모든 표본 평균의 약 **95%**는 모집단 평균으로부터 **2 표준 오차** 이내에 놓일 것으로 예상됩니다.
- **99.7% 규칙:** 모든 표본 평균의 약 **99.7%**는 모집단 평균으로부터 **3 표준 오차** 이내에 놓일 것으로 예상됩니다.

이러한 지식을 바탕으로 우리는 단 하나의 표본만 추출하더라도, 그 표본 평균이 분포의 중심(모집단 평균에 가까운 값)에 있는지 아니면 꼬리 부분(이상치)에 가까운지에 대해 평가할 수 있습니다. 이러한 평가 능력은 우리가 수행한 표본 연구 결과에 대해 **얼마나 확신할 수 있는지**를 알려주며, 이는 다음 모듈에서 다룰 주제인 신뢰 구간(confidence interval)의 기초가 됩니다.

3.7.2 3-3.2 중심 극한 정리 시각화 (Animating the Central Limit Theorem)

이 섹션에서는 애니메이션을 통해 중심 극한 정리가 실제로 어떻게 작동하는지 시각적으로 보여줍니다.

애니메이션 설정: 모집단 분포 변경

- 초기 상태: 먼저 정규 분포를 따르는 모집단을 가정합니다. 이 모집단에서 표본을 반복적으로 추출하면, 표본 평균 또한 정규 분포를 따를 것이라는 것은 놀라운 일이 아닙니다.
- 모집단 사용자 정의: 애니메이션에서는 모집단 분포를 임의로 클릭하여 비정규 분포로 변경합니다. 예를 들어, 여러 지점에 데이터를 집중시켜 비대칭적이거나 다봉형의 분포를 만듭니다.

Figure 3.5: 사용자 정의된 비정규 모집단 분포 (가상 이미지)

설명: 히스토그램에서 여러 무작위 지점을 클릭하여 생성된 비정규 분포를 보여줍니다. 이 분포는 평균 14.80, 중앙값 11.00, 표준 편차 9.45, 왜도 0.28, 첨도 -1.35를 가집니다. 평균과 중앙값이 크게 다르므로 종 모양이 아님을 알 수 있습니다.

표본 추출 및 평균 분포 관찰

애니메이션은 다음과 같은 과정을 반복합니다.

1. 첫 번째 클릭:
 - 모집단에서 5개의 무작위 관측치를 추출하여 'Sample Data' 그래프에 표시합니다.
 - 이 5개 관측치의 평균을 계산하여 'Distribution of Means N=5' 그래프에 점으로 표시합니다.
 - 모집단에서 25개의 무작위 관측치를 추출하여 'Sample Data' 그래프에 표시합니다.
 - 이 25개 관측치의 평균을 계산하여 'Distribution of Means N=25' 그래프에 점으로 표시합니다.
2. 반복: 이 과정을 여러 번 반복하여 각 표본 크기(N=5, N=25)에 대한 표본 평균 분포가 어떻게 형성되는지 시각적으로 보여줍니다.
3. 관찰: 초기에는 N=5의 분포가 왼쪽으로 치우치는 등 비대칭적일 수 있지만, N=25의 분포는 상대적으로 중앙에 더 가깝게 위치하는 경향을 보입니다.

Figure 3.6: 애니메이션을 통한 표본 추출 및 평균 분포 형성 (가상 이미지)

설명: 상단에 사용자 정의된 모집단 히스토그램이 있고, 그 아래에 'Sample Data', 'Distribution of Means N=5', 'Distribution of Means N=25' 그래프가 있습니다. 애니메이션 버튼을 클릭하면 데이터 블록이 'Sample Data'로 떨어지고, 그 평균이 아래 두 그래프에 점으로 추가됩니다. N=25의 평균이 N=5의 평균보다 그래프 중앙에 더 가깝게 위치하는 경향을 보여줍니다.

대규모 반복을 통한 정규 분포 수렴

- 소규모 반복: 5회 반복 시에는 여전히 정규 분포와 거리가 멀어 보일 수 있습니다.
- 대규모 반복 (10,000회): 10,000번 반복하면, 표본 평균의 분포는 훨씬 더 정규 분포에 가까워집니다. 특히 N=25의 분포는 N=5의 분포보다 훨씬 더 좁고 종 모양을 띠게 됩니다.
- 초대규모 반복 (100,000회): 100,000번 반복하면, 두 분포 모두 거의 완벽한 정규 분포를 보이며, N=25의 분포는 N=5의 분포보다 훨씬 더 밀집되어 있습니다.

CLT 시각화의 핵심 메시지

중심 극한 정리의 아름다움은 여기에 있습니다: 어떤 모집단 분포를 가지고 있든 상관없이, 충분히 큰 표본 크기(일반적으로 30 이상)만 있다면, 표본 평균의 표본 분포는 정규 분포를 따르기 시작합니다. 이 덕분에 우리는 단 하나의 표본을 추출하더라도 그 표본 평균이 모집단 평균으로부터 얼마나 변동할지 예측할 수 있습니다.

표준 오차의 시각적 이해와 계산

애니메이션은 표준 오차의 개념을 시각적으로도 보여줍니다.

- **표준 오차의 형태:** 표본 평균 분포의 퍼짐 정도를 나타내는 것이 표준 오차입니다.
- **공식:** 표준 오차는 모집단 표준 편차를 표본 크기의 제곱근으로 나눈 값입니다.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

- **계산 예시:**
 - 모집단 표준 편차가 9.45라고 가정할 때:
 - **N=5일 때:** $\sigma_{\bar{x}} = \frac{9.45}{\sqrt{5}} \approx 4.22$
 - **N=25일 때:** $\sigma_{\bar{x}} = \frac{9.45}{\sqrt{25}} = \frac{9.45}{5} \approx 1.89$

표준 오차와 표본 크기의 관계

이 계산 결과는 표본 크기가 커질수록 표준 오차가 크게 감소한다는 것을 명확히 보여줍니다. 즉, 표본 크기가 클수록 표본 평균들이 하나의 중심점(모집단 평균) 주위에 훨씬 더 밀집되어 분포하게 됩니다. 이는 표본이 모집단을 더 정확하게 대표한다는 의미입니다.

표본 평균을 통한 모집단 평균 추정

애니메이션의 최종 결과는 표본 평균의 분포 평균이 모집단 평균에 매우 가깝다는 것을 보여줍니다.

- **모집단 평균:** 14.80
- **N=5일 때 표본 평균 분포의 평균:** 14.78 (모집단 평균에 매우 근접)
- **N=25일 때 표본 평균 분포의 평균:** 14.79 (모집단 평균에 더욱 근접)

CLT의 궁극적인 장점

중심 극한 정리의 아름다움과 강점은 바로 여기에 있습니다. 만약 표본 추출을 올바르게 수행한다면, 추출된 표본은 모집단을 잘 대표하게 됩니다. 따라서 표본 정보를 사용하여 얻은 통계량(예: 표본 평균)은 모집단 모수(예: 모집단 평균)에 대한 훌륭한 점 추정량(point estimator)이 됩니다.

3.7.3 3-3.3 표본 분포와 경험적 규칙 (Sampling Distribution and Empirical Rule in Excel)

이 섹션에서는 Excel을 사용하여 중심 극한 정리와 경험적 규칙의 개념을 실제 데이터로 시연합니다.

데이터 준비: 뉴욕 일일 기온 데이터

- 데이터셋: 뉴욕시의 지난 25년간 26,000개 이상의 일일 평균 기온 데이터 포인트를 사용합니다.
- 모집단 특성:
 - 최소 일일 평균 기온: **2.6도** (화씨)
 - 최대 일일 평균 기온: **94.5도** (화씨)
 - 평균 일일 기온 (모집단 평균): **55.2도** (화씨)
 - 표준 편차 (모집단 표준 편차): 약 **17.38**

표본 추출 및 표본 평균 계산

- 표본 크기: 각 표본은 72개의 관측치(무작위로 선택된 72일)를 가집니다. ($n = 72$)
- 반복 횟수: 이 과정을 총 **100,000**번 반복하여 100,000개의 표본 평균을 얻습니다.
- 예시: 첫 번째 표본의 평균은 54.7도였습니다.

Figure 3.7: Excel에서 100,000개의 표본 평균 데이터 (가상 이미지)

설명: 'Sample Number'와 'Sample Average' 두 열로 구성된 Excel 시트의 일부를 보여줍니다. 각 행은 하나의 표본과 그 평균을 나타냅니다.

표본 평균 분포의 특성 분석

100,000개의 표본 평균 데이터를 사용하여 그 분포의 특성을 분석합니다.

- 표본 평균의 최소/최대:
 - 최소 표본 평균: **47.2도**
 - 최대 표본 평균: **64.2도**
 이는 모집단 평균 55.2도에서 상당히 벗어난 표본 평균도 존재함을 보여줍니다.
- 표본 평균들의 평균: 100,000개 표본 평균들의 평균을 계산하면 **55.2도**가 나옵니다. 이는 모집단 평균과 정확히 일치합니다.
- 표본 평균들의 표준 편차 (실제 계산): 100,000개 표본 평균들의 표준 편차를 Excel의 STDEV.S 함수로 계산하면 약 **2.05**가 나옵니다.
- 표준 오차 (이론적 계산): 표준 오차 공식($\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$)을 사용하여 이론적인 표준 오차를 계산합니다.

$$\sigma_{\bar{x}} = \frac{17.38}{\sqrt{72}} \approx 2.048$$

실제와 이론의 일치

Excel에서 직접 계산한 표본 평균들의 표준 편차(2.05)와 이론적인 표준 오차(2.048)가 거의 일치하는 것을 확인할 수 있습니다. 이는 중심 극한 정리와 표준 오차 공식이 실제 데이터에서도 정확하게 작동함을 보여줍니다.

모집단 분포와 표본 평균 분포의 비교

- **모집단 히스토그램 (뉴욕 기온):** 26,000개 이상의 기온 기록에 대한 히스토그램은 40도와 76도 부근에 두 개의 봉우리가 있는 **이봉 분포**를 보이며, 이는 정규 분포가 아닙니다.
- **표본 평균 히스토그램:** 100,000개 표본 평균에 대한 히스토그램을 생성합니다.
 - **빈(Bin) 설정:** 표본 평균의 최소(47.2)와 최대(64.2) 값을 고려하여 45도에서 66도까지 0.5도 간격으로 빈을 설정합니다.
 - **결과:** 생성된 히스토그램은 **종 모양의 정규 분포**와 매우 유사한 형태를 보입니다. 중심은 55.2도에 위치하며, 분포의 퍼짐은 표준 오차인 2.048에 해당합니다.

Figure 3.8: 뉴욕 기온 모집단 분포와 표본 평균 분포 히스토그램 비교 (가상 이미지)

설명: 왼쪽에는 이봉 분포를 보이는 뉴욕 기온 모집단 히스토그램이, 오른쪽에는 종 모양의 정규 분포를 보이는 표본 평균 히스토그램이 나란히 배치되어 있습니다. 표본 평균 히스토그램은 55도 근처에 중앙값이 위치하며, 모집단 분포보다 훨씬 좁고 대칭적입니다.

CLT의 시각적 증명

이 시각적 비교는 중심 극한 정리의 핵심을 명확히 보여줍니다. 모집단 분포가 정규 분포가 아니더라도, 충분히 큰 표본 크기(여기서는 $n = 72$)로 추출된 표본 평균들의 분포는 정규 분포를 따르게 됩니다. 또한, 이 분포는 모집단 분포보다 훨씬 더 **밀집되어(좁게)** 있습니다.

표본 평균 분포에 경험적 규칙 적용

표본 평균 분포가 정규 분포를 따르므로, 우리는 여기에 경험적 규칙을 적용할 수 있습니다. 우리의 표본 평균 분포의 평균은 55.2도이고, 표준 오차는 약 2.05도입니다.

- **1 표준 오차 이내 (68%):**
 - 범위: $55.2 \pm 1 \times 2.05 = [53.15, 57.25]$
 - 의미: 약 68%의 표본들이 53.15도에서 57.25도 사이의 평균을 가질 것입니다.
- **2 표준 오차 이내 (95.5%):**
 - 범위: $55.2 \pm 2 \times 2.05 = [51.1, 59.3]$
 - 의미: 약 95.5%의 표본들이 51.1도에서 59.3도 사이의 평균을 가질 것입니다.
- **3 표준 오차 이내 (99.7%):**
 - 범위: $55.2 \pm 3 \times 2.05 = [49.05, 61.35]$
 - 의미: 약 99.7%의 표본들이 49.05도에서 61.35도 사이의 평균을 가질 것입니다.

Figure 3.9: 표본 평균 히스토그램에 적용된 경험적 규칙 (가상 이미지)

설명: 표본 평균 히스토그램 위에 68

경험적 규칙의 보편성

이 예시에서 보듯이, 우리의 데이터에서도 경험적 규칙이 완벽하게 적용됩니다. 이는 중심 극한 정리가 '정리(theorem)'인 이유입니다. 모집단의 근본적인 분포가 정규 분포이든 아니든 상관없이, **충분히 큰 표본 크기**를 가진다면 표본 평균의 분포는 정규 분포를 따를 것이고, 따라서 경험적 규칙도 항상 성립합니다.

3.7.4 3-4.1 중심 극한 정리와 표본 비율 (Central Limit Theorem – Sampling Proportion)

중심 극한 정리는 표본 평균에만 적용되는 것이 아닙니다. 표본 비율(sample proportion)의 경우에도 정규 분포 현상이 나타납니다.

표본 비율의 개념

- **비율의 정의:** 비율은 특정 범주에 속하는 그룹의 백분율(percentage)을 의미합니다.
- **예시:**
 - 온라인 बैं킹을 선호하는 인구의 비율
 - 특정 후보에게 투표할 유권자의 비율
- **추론의 필요성:** 이러한 질문에 답하기 위해 우리는 다시 표본 연구에 의존하며, 표본에서 관찰된 비율을 바탕으로 모집단에 대해 일반화합니다.

Table 3.2: 모집단 비율과 표본 비율 표기

개념	표기
모집단 비율	p
표본 비율	$\hat{p}$ (p-hat)

표본 비율의 계산

표본 비율($\hat{p}$)은 관심 있는 범주에 속하는 관측치 수를 전체 표본 크기로 나눈 값입니다.

$$\hat{p} = \frac{\text{관심 범주에 속하는 관측치 수}}{\text{총 표본 크기}}$$

예시: 온라인 쇼핑 광고 효과

우리는 온라인 쇼핑 사이트를 운영하며 다양한 온라인 광고를 통해 고객을 유치합니다. 어떤 광고가 실제로 구매로 이어지는 고객을 데려오는지 알고 싶습니다.

- **고객 유형:**
 1. 구매하는 고객
 2. 구매하지 않는 고객
- **데이터 분석:** 마케팅 부서에서 특정 광고를 호스팅하는 웹사이트의 데이터를 분석합니다.
- **관찰된 표본:** 특정 기간 동안 400명의 고객이 광고 링크를 클릭했고, 그중 118명이 구매했습니다.
- **표본 비율 계산:**

$$\hat{p} = \frac{118}{400} = 0.295$$

이는 이 링크를 통해 들어온 고객의 29.5%가 구매자임을 추정할 수 있습니다.

하지만 다른 날에는 어떤 결과가 나올까요? 여기서 중심 극한 정리가 다시 한번 도움을 줍니다.

표본 크기 변화에 따른 표본 비율 분포의 변화

모집단 비율 p 를 알고 있다고 가정하고, 표본 크기를 변화시키면서 표본 비율의 분포를 살펴봅시다.

예시: 온라인 광고 구매율 시뮬레이션

가정: 실제 모집단 구매 비율은 $p = 0.3$ (30%)입니다.

1. 표본 크기 $n = 50$, 10회 반복:

- 50명의 고객으로 구성된 표본을 10번 무작위로 추출합니다.
- 각 표본에서 구매자 수를 세어 표본 비율을 계산합니다.
- **결과:** 표본 비율은 0.2에서 0.48까지 넓게 분포합니다. 단 하나의 표본만 추출한다면 실제 비율에서 상당히 벗어난 값을 얻을 수도 있습니다.

2. 표본 크기 $n = 100$, 10회 반복:

- 표본 크기를 100으로 늘립니다.
- **결과:** 표본 비율의 범위는 0.24에서 0.39로 줄어들며, 분포의 퍼짐이 감소하기 시작합니다.

3. 표본 크기 $n = 1000$, 10회 반복:

- 표본 크기를 1,000으로 늘립니다.
- **결과:** 표본 비율의 히스토그램은 훨씬 더 좁아지고 대략적인 종 모양을 띠기 시작합니다. 범위는 0.26에서 0.34로 크게 줄어듭니다.

표본 비율에 대한 CLT의 결론

표본 크기가 충분히 크다면, 표본 비율의 분포는 다음과 같은 특성을 보입니다:

- **정규 분포에 수렴:** 대략적으로 정규 분포를 따릅니다.
- **중심:** 분포의 중심은 실제 모집단 비율(p) 주변에 위치합니다.
- **퍼짐 감소:** 표본 크기가 커질수록 분포가 좁아집니다.

이는 중심 극한 정리의 핵심 원리인 "적절하게 추출된 큰 표본은 그 표본이 추출된 모집단을 닮는다"는 것을 다시 한번 보여줍니다. 물론 표본마다 변동은 있겠지만, 모집단에서 크게 벗어나는 표본이 나올 확률은 매우 낮습니다.

표본 비율 분포의 표준 오차

표본 비율 분포의 퍼짐 정도는 **표준 오차(Standard Error)**로 알려져 있으며, 다음 공식으로 계산됩니다.

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

여기서 p 는 모집단 비율(또는 그 추정치)이고, n 은 표본 크기입니다.

CLT의 강력한 활용

중심 극한 정리의 강력함은 바로 여기에 있습니다. 모집단의 근본적인 분포가 정규 분포이든 아니든 상관없이, **충분히 큰 표본 크기**만 있다면 단 하나의 표본으로도 모집단에 대한 추론을 할 수 있는 능력을 제공합니다. 다음 모듈에서는 이 표본 정보를 사용하여 모집단에 대한 추론을 수행하는 방법을 더 자세히 배울 것입니다.

3.8 빠르게 훑어보기 (1페이지 요약)

중심 극한 정리 (CLT) 핵심 요약

- **정의:** 표본 크기가 충분히 크다면, 모집단 분포의 형태와 관계없이 표본 평균(또는 표본 비율)의 표본 분포는 정규 분포에 가까워집니다.
- **왜 중요한가?:** 모집단 전체를 조사하기 어려울 때, 작은 표본으로도 모집단에 대한 신뢰성 있는 추론을 가능하게 합니다. 통계적 추론의 근간이 됩니다.
- **표본 평균의 분포:**
 - 표본 크기(n)가 커질수록 표본 평균 분포는 더욱 정규 분포에 가까워지고, 평균 주변에 더 밀집됩니다.
 - 분포의 중심은 모집단 평균(μ)에 가까워집니다.
 - 분포의 퍼짐은 **표준 오차**($\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$)로 측정되며, n 이 커질수록 표준 오차는 작아집니다.
- **비정규 모집단:** 모집단 자체가 정규 분포를 따르지 않아도, CLT는 여전히 유효합니다. (예: 시카고 기온 데이터)
- **표본 비율의 분포:**
 - 표본 크기(n)가 커질수록 표본 비율 분포도 정규 분포에 가까워지고, 모집단 비율(p) 주변에 밀집됩니다.
 - 분포의 퍼짐은 **표준 오차**($\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$)로 측정됩니다.
- **경험적 규칙 적용:** 표본 평균/비율 분포가 정규 분포를 따르므로, 경험적 규칙(68-95-99.7 규칙)을 적용하여 표본 평균/비율이 모집단 모수로부터 얼마나 떨어져 있을지 확률적으로 예측할 수 있습니다.
- **결론:** CLT는 단일 표본을 통해 모집단에 대한 신뢰성 있는 추론을 가능하게 하는 통계학의 핵심 원리입니다.

3.9 FAQ

- **Q: 중심 극한 정리(CLT)가 왜 '슈퍼히어로'라고 불리나요? A:** CLT는 통계학에서 가장 강력하고 광범위하게 적용되는 정리 중 하나이기 때문입니다. 이 정리 덕분에 우리는 모집단의 실제 분포를 모르거나 비정규 분포를 따르더라도, 충분히 큰 표본만 있다면 표본 평균(또는 비율)의 분포가 정규 분포를 따른다는 것을 확신할 수 있습니다. 이는 제한된 정보로도 모집단에 대한 신뢰성 있는 추론을 가능하게 하여, 데이터 기반 의사결정의 핵심 기반이 됩니다.
- **Q: 표본 크기가 '충분히 크다'는 것은 대략 어느 정도를 의미하나요? A:** 일반적으로 표본 크기가 30 이상이면 중심 극한 정리가 잘 적용된다고 봅니다. 하지만 모집단 분포의 형태에 따라 필요한 표본 크기는 달라질 수 있습니다. 모집단 분포가 매우 비대칭적이거나 이상치가 많다면 더 큰 표본 크기가 필요할 수 있습니다. 표본 비율의 경우, $np \geq 10$ 이고 $n(1-p) \geq 10$ 이라는 조건을 만족하는 것이 좋습니다.
- **Q: 표준 편차와 표준 오차는 무엇이 다른가요? A:** **표준 편차(Standard Deviation)**는 단일 데이터셋 (예: 모집단 데이터 또는 단일 표본 데이터) 내의 개별 관측치들이 평균으로부터 얼마나 퍼져 있는지를 나타내는 척도입니다. 반면, **표준 오차(Standard Error)**는 여러 표본에서 얻은 표본 통계량(예: 표본 평균 또는 표본 비율)들이 모집단 모수로부터 얼마나 퍼져 있는지를 나타내는 척도입니다. 즉, 표준 오차는 표본 통계량의 분포(표본 분포)의 표준 편차입니다.

- **Q:** 모집단이 정규 분포를 따르지 않아도 CLT가 적용된다는 것이 정말인가요? **A:** 네, 그렇습니다. 이것이 CLT의 가장 놀라운 점 중 하나입니다. 시카고 기온 예시에서 보았듯이, 모집단 분포가 이봉 분포와 같이 정규 분포가 아니더라도, 충분히 큰 표본 크기로 표본을 반복적으로 추출하여 그 평균들을 모으면, 이 표본 평균들의 분포는 정규 분포를 따르게 됩니다. 이 덕분에 우리는 정규 분포의 속성을 활용하여 추론을 할 수 있습니다.
- **Q:** CLT를 통해 얻은 지식이 실제 의사결정에 어떻게 활용될 수 있나요? **A:** CLT는 단일 표본 연구 결과를 바탕으로 모집단 전체에 대한 결론을 내릴 수 있는 과학적 근거를 제공합니다. 예를 들어, 신제품의 시장 반응을 예측하기 위해 소수의 소비자 표본을 조사하거나, 선거 결과를 예측하기 위해 소수의 유권자 표본을 조사할 때, CLT는 표본 결과가 모집단을 얼마나 잘 대표하는지, 그리고 그 결과에 대해 얼마나 확신할 수 있는지 평가하는 데 사용됩니다. 이는 다음 모듈에서 다룰 신뢰 구간 및 가설 검정의 기초가 됩니다.

Chapter 4

신뢰 수준이 신뢰 구간에 미치는 영향 (Excel 활용)

강의명: BADM-572: Data-Driven Decision Making

주차: Module 4: 추론 통계

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 신뢰 수준과 신뢰 구간, 가설 검정의 기본 개념을 학습하고 Excel을 활용한 통계적 추론 방법을 다룹니다.

4.1 신뢰 수준이 신뢰 구간에 미치는 영향 (Excel 활용)

이 섹션에서는 신뢰 수준(Confidence Level)이 신뢰 구간의 폭에 어떻게 영향을 미치는지 Excel을 통해 살펴보겠습니다. 90%와 99% 신뢰 수준에 대한 신뢰 구간을 계산하고 95% 신뢰 구간과 비교합니다.

슬라이드 54: 뉴욕 일일 기온 샘플 Excel 시트 (1/13)

이 슬라이드에는 기온 모집단에서 추출한 200개의 표본이 슬라이드 왼쪽에 나열되어 있습니다. 오른쪽에는 다음과 같은 통계량 목록이 세로로 배치되어 있으며 각각의 값이 있습니다: 표본 크기 (n) = 200. 이 표본의 평균 = 56.36345. 표본의 표준편차 = 17.90778. 표준 오차(표본 평균의 표준편차) = 1.266271. $t_{\alpha/2}$: 임계값(t-분포 사용) = 1.971957. $z_{\alpha/2}$: 임계값(정규 분포 사용) = 1.959964. 오차 한계 = 2.497032. 신뢰 구간: 하한 = 53.86642. 상한 = 58.86048.

강의 내용 요약: 이전 예시에서 95% 신뢰 구간을 계산하는 방법을 보여드렸습니다. 이제 동일한 예시를 사용하여 90%와 99% 신뢰 구간을 계산하고, 신뢰 수준이 변경될 때 값들이 어떻게 변하는지 살펴보겠습니다.

4.1.1 신뢰 수준에 따른 임계값 변화

신뢰 수준이 달라지면 임계값($t_{\alpha/2}$)이 달라집니다. 이는 신뢰 구간의 폭을 결정하는 중요한 요소입니다.

슬라이드 56: 뉴욕 일일 기온 샘플 Excel 시트 (3/13)

신뢰 수준은 바로 여기에 있을 것이고 90%입니다. 90%로 가면 이것이 의미하는 바입니다. 90%라면 이 값, 즉 왼쪽의 모든 것, 나머지 10% 중 5%는 여기에 있고 5%는 여기에 있으므로 이것은 0.95가 될 것입니다. 99%의 경우, 이것이 99%라면 여기에 0.005가 있고 여기에 0.005가 있습니다. 따라서 이 경우, 왼쪽의 모든 것은 0.995가 됩니다. 이것이 변하는 것입니다.

그림 설명: 다양한 신뢰 수준에 따른 누적 확률

종 모양의 히스토그램에 벨 곡선이 그려져 있습니다.

- 90% 신뢰 수준: 중앙 부분은 90%로 음영 처리되어 있고, 양쪽 꼬리는 각각 5%입니다. 오른쪽 꼬리까지의 누적 확률은 95% (0.95)입니다.
- 99% 신뢰 수준: 중앙 부분은 99%로 음영 처리되어 있고, 양쪽 꼬리는 각각 0.5% (0.005)입니다. 오른쪽 꼬리까지의 누적 확률은 99.5% (0.995)입니다.

Figure 4.1: 다양한 신뢰 수준에 따른 누적 확률

Excel 계산 단계 (t-분포 임계값): 자유도는 $n - 1 = 200 - 1 = 199$ 로 동일합니다.

1. 90% 신뢰 수준:

- 임계값을 계산할 셀을 선택합니다.
- `=T.INV(0.95, 199)`를 입력합니다. (90% 신뢰 구간의 오른쪽 꼬리까지의 누적 확률은 $90\% + 5\% = 95\% = 0.95$)
- Enter를 누릅니다.

2. 99% 신뢰 수준:

- 임계값을 계산할 셀을 선택합니다.
- `=T.INV(0.995, 199)`를 입력합니다. (99% 신뢰 구간의 오른쪽 꼬리까지의 누적 확률은 $99\% + 0.5\% = 99.5\% = 0.995$)
- Enter를 누릅니다.

계산 결과: 신뢰 수준별 t-분포 임계값

- 90% 신뢰 수준 ($t_{\alpha/2}$): 1.6525
- 99% 신뢰 수준 ($t_{\alpha/2}$): 2.6007

참고로, 95% 신뢰 수준의 임계값은 1.9719였습니다. 신뢰 수준이 높아질수록 임계값이 커지는 것을 확인할 수 있습니다.

4.1.2 신뢰 수준에 따른 오차 한계 변화

임계값이 변하면 오차 한계도 변합니다. 표준 오차는 표본 데이터에 따라 결정되므로, 신뢰 수준이 변해도 표준 오차는 동일하게 유지됩니다 (이전 계산에서 1.266271).

슬라이드 61: 뉴욕 일일 기온 샘플 Excel 시트 (8/13)

이것이 오차 한계이고, 이것은 99%의 오차 한계입니다. 이제 여러분이 알아차린 것 중 하나는 오차 한계가 증가한다는 것입니다. 90%에서 95%로 가면 오차 한계가 증가했고, 90%에서 99%로 가면 오차 한계가 증가합니다. 오차 한계가 신뢰 수준을 높일수록 점점 더 높아지기 때문에, 신뢰 구간의 폭도 증가하기 시작할 것입니다.

Excel 계산 단계 (오차 한계): 오차 한계 공식은 임계값 * 표준 오차

1. 90% 신뢰 수준:

- 오차 한계를 계산할 셀을 선택합니다.
- = (90% 임계값 셀) * (표준 오차 셀)을 입력합니다.
- 예를 들어, 90% 임계값이 G11셀에 있고 표준 오차가 F7셀에 있다면, =G11*F7과 같이 입력합니다.
- Enter를 누릅니다.

2. 99% 신뢰 수준:

- 오차 한계를 계산할 셀을 선택합니다.
- = (99% 임계값 셀) * (표준 오차 셀)을 입력합니다.
- 예를 들어, 99% 임계값이 H11셀에 있고 표준 오차가 F7셀에 있다면, =H11*F7과 같이 입력합니다.
- Enter를 누릅니다.

계산 결과: 신뢰 수준별 오차 한계

- 90% 신뢰 수준: 2.0925
- 99% 신뢰 수준: 3.2932

참고로, 95% 신뢰 수준의 오차 한계는 2.4970이었습니다. 신뢰 수준이 높아질수록 오차 한계가 커지는 것을 확인할 수 있습니다.

4.1.3 신뢰 수준에 따른 신뢰 구간 변화

오차 한계가 변함에 따라 신뢰 구간의 폭도 달라집니다. 표본 평균은 56.36으로 동일합니다.

Excel 계산 단계 (신뢰 구간): 신뢰 구간 공식은 임계값 * 표준 오차입니다. 표준 오차는 1.266271입니다.

1. 90% 신뢰 수준:

- 오차 한계를 계산할 셀을 선택합니다.
- = (90% 임계값 셀) * (표준 오차 셀)을 입력합니다.
- 예를 들어, 90% 임계값이 G11셀에 있고 표준 오차가 F7셀에 있다면, =G11*F7과 같이 입력합니다.
- Enter를 누릅니다.

2. 99% 신뢰 수준:

- 오차 한계를 계산할 셀을 선택합니다.
- = (99% 임계값 셀) * (표준 오차 셀)을 입력합니다.
- 예를 들어, 99% 임계값이 H11셀에 있고 표준 오차가 F7셀에 있다면, =H11*F7과 같이 입력합니다.

- Enter를 누릅니다.

계산 결과: 신뢰 수준별 오차 한계

- 90% 신뢰 수준: 2.0925
- 99% 신뢰 수준: 3.2932

참고로, 95% 신뢰 수준의 오차 한계는 2.4970이었습니다. 신뢰 수준이 높아질수록 오차 한계가 커지는 것을 확인할 수 있습니다.

4.1.4 신뢰 수준에 따른 신뢰 구간 변화

오차 한계가 변함에 따라 신뢰 구간의 폭도 달라집니다. 표본 평균은 56.36으로 동일합니다.

Excel 계산 단계 (신뢰 구간): 신뢰 구간 공식은 표본 평균 $\pm$ 오차 한계입니다. 표본 평균은 56.36입니다.

1. 90% 신뢰 수준:

- 하한: = (표본 평균 셀) - (90% 오차 한계 셀)
- 상한: = (표본 평균 셀) + (90% 오차 한계 셀)

2. 99% 신뢰 수준:

- 하한: = (표본 평균 셀) - (99% 오차 한계 셀)
- 상한: = (표본 평균 셀) + (99% 오차 한계 셀)

계산 결과: 신뢰 수준별 신뢰 구간

- 90% 신뢰 구간: [54.27, 58.45]
 - 하한: $56.36 - 2.0925 = 54.2708$
 - 상한: $56.36 + 2.0925 = 58.456$
- 95% 신뢰 구간: [53.86, 58.86] (이전 섹션 결과)
- 99% 신뢰 구간: [53.07, 59.65]
 - 하한: $56.36 - 3.2932 = 53.07018$
 - 상한: $56.36 + 3.2932 = 59.6567$

슬라이드 66: 뉴욕 일일 기온 샘플 Excel 시트 (13/13)

여기 옆에 나란히 써서 비교해 보겠습니다. 이것은 90% 신뢰 구간입니다. 이것은 95% 신뢰 구간이고, 이것은 99% 신뢰 구간입니다. 90%는 54.27에서 58.45 사이입니다. 95%는 53.86에서 58.86입니다. 그리고 99%는 53.07에서 59.65입니다. 따라서 폭이 증가하기 시작합니다. 그래서 우리는 이 구간에 실제 모집단 평균이 포함될 것이라고 점점 더 확신하게 될 것입니다. 그러나 우리는 정밀도를 잃고 있습니다. 너무 넓습니다. 예를 들어, 99%에서는 거의 3.5도 차이가 나는데, 이것은 큰 문제일 수 있습니다.

결론:

- 신뢰 수준 증가 $\rightarrow$ 오차 한계 증가 $\rightarrow$ 신뢰 구간 폭 증가

- 신뢰 수준이 높아질수록 모집단 모수를 포함할 확률은 높아지지만, 신뢰 구간의 폭이 넓어져 추정의 **정밀도**(precision)는 떨어집니다.
- 예를 들어, 99% 신뢰 구간은 90% 신뢰 구간보다 훨씬 넓습니다. 이는 우리가 '더 확신'할 수 있지만, '어디에 있는지'에 대한 정보는 덜 구체적이라는 의미입니다.

4.2 신뢰 구간: 모집단 비율

이 섹션에서는 모집단 평균뿐만 아니라 모집단 비율(Population Proportion)에 대한 신뢰 구간을 계산하는 방법을 학습합니다. 이는 특정 특성을 가진 개체의 비율을 추정할 때 유용합니다.

4.2.1 모집단 비율에 대한 추론의 필요성

슬라이드 67: 모집단 비율

- 고객 중 몇 퍼센트가 친구에게 귀사의 사업을 추천할까요?
- 유권자 중 몇 퍼센트가 후보 A에게 투표할까요?
- 아메리칸 항공 항공편 중 몇 퍼센트가 정시에 출발할까요?

강의 내용 요약: 우리는 종종 모집단 비율에 대해 추론하는 데 관심이 있습니다. 위 질문들처럼, 결과가 두 가지 중 하나로만 나오는 경우(예: 추천하거나 안 하거나, 투표하거나 안 하거나, 정시 출발하거나 안 하거나)에 해당합니다. 평균에 대한 추론과 마찬가지로, 표본 조사를 사용하여 모집단 비율에 대해 추론할 수 있습니다. 아이디어는 동일하지만, 수학적 계산이 다릅니다.

슬라이드 68: 표본 비율

빨간색과 파란색 구슬이 들어있는 항아리 그림. 더 적은 구슬이 들어있는 작은 항아리 그림.

개념 설명:

- **한 줄 핵심 요약:** 모집단 비율은 전체 집단에서 특정 특성을 가진 개체의 비율이며, 표본을 통해 추정합니다.
- **직관적 예시/비유:** 큰 항아리(모집단)에 빨간 구슬(후보 A에게 투표할 유권자)과 파란 구슬(투표하지 않을 유권자)이 섞여 있다고 상상해 보세요. 항아리 전체를 세지 않고, 작은 국자(표본)로 구슬 몇 개를 떠서 빨간 구슬의 비율을 세어봅니다. 이 작은 국자의 비율을 가지고 큰 항아리 전체의 빨간 구슬 비율을 추측하는 것이 바로 모집단 비율 추정입니다.
- **기술적 설명:** 정치 여론 조사와 같이, 우리는 선거일 전에 후보 A에게 투표할 유권자의 비율을 알고 싶어 합니다. 모집단 전체를 조사할 수 없으므로, 무작위로 표본을 추출하여 그 정보를 사용하여 전체 모집단에 대해 추론합니다. 표본은 무작위로 추출되기 때문에 통계적 추론에는 항상 어느 정도의 불확실성이 따르며, 이때 신뢰 구간이 중요해집니다.

4.2.2 모집단 비율에 대한 신뢰 구간 공식

모집단 비율에 대한 신뢰 구간은 표본 비율($\hat{p}$)을 중심으로 오차 한계를 더하고 빼서 계산합니다.

슬라이드 69: 모집단 비율에 대한 신뢰 구간

- 원하는 신뢰 수준 ($1 - \alpha$)
- 표본 비율 $\hat{p}$
- 신뢰 구간: $\left[\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$
- 오차 한계는 이 방정식의 이 부분입니다: $z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

개념 설명:

- **한 줄 핵심 요약:** 모집단 비율의 신뢰 구간은 표본 비율을 중심으로 임계값과 표준 오차를 곱한 오차 한계를 더하고 빼서 구합니다.
- **직관적 예시/비유:** 우리가 뽑은 구슬 표본에서 빨간 구슬이 50% 나왔다고 합시다. 이 50%가 '가장 가능성 있는' 모집단 비율이지만, 정확히 50%라고 단정할 수는 없습니다. 그래서 '50%에서 이만큼 더하고 빼면' 실제 모집단 비율이 그 안에 있을 것이라고 '확신'하는 구간을 만드는 것입니다. 이때 '이만큼'이 바로 오차 한계입니다.
- **기술적 설명:**
 - **표본 비율 ($\hat{p}$):** 표본에서 특정 특성을 가진 개체의 수(x)를 전체 표본 크기(n)로 나눈 값입니다. $\hat{p} = x/n$.
 - **표준 오차 (Standard Error for Proportion):** 표본 비율의 표본 분포의 표준편차입니다. 이는
 - **임계값 ($z_{\alpha/2}$):** 원하는 신뢰 수준에 해당하는 z-값입니다. 표본 크기가 충분히 크면 (일반적으로 $n\hat{p} \geq 10$ 이고 $n(1-\hat{p}) \geq 10$), 표본 비율의 분포는 정규 분포에 근사하므로 z-분포를 사용합니다.
 - **오차 한계 (Margin of Error):** 임계값과 표준 오차를 곱한 값입니다. 이는 표본 비율이 모집단 비율과 얼마나 차이 날 수 있는지를 나타냅니다.

4.2.3 예시: 지역 고용 시장 조건 (Gallup 설문)

Gallup 설문조사 데이터를 사용하여 지역 고용 시장 조건에 대한 모집단 비율의 95% 신뢰 구간을 계산해 보겠습니다.

슬라이드 70: 지역 고용 시장 조건이 좋은가? (1/2)

2016년 3월 31일부터 4월 2일까지 Gallup은 미국 50개 주와 컬럼비아 특별구에 거주하는 성인 1,526명을 무작위로 표본 조사했습니다. 1,526명의 성인 중 779명이 시장 조건이 좋다고 생각했습니다. 시장 조건이 좋다고 생각하는 모든 성인의 비율에 대한 95% 신뢰 구간은 얼마입니까?

문제 분석:

- **표본 크기 (n):** 1,526명

- 성공 횟수 (x): 779명 (시장 조건이 좋다고 생각하는 성인)
- 신뢰 수준: 95%

표본 비율 계산

슬라이드 71: 지역 고용 시장 조건이 좋은가? (2/2)

먼저, 우리 표본에는 1,526명이 있습니다. 그리고 51%는 고용 시장이 좋다고 믿는 표본 비율입니다. $n = 1,526$ $= 779 \div 1526 = 0.51$

계산: $= x_{n=\frac{779}{1526} \approx 0.51} \quad 0.51 \text{ (51\%)}$

임계값 결정

95% 신뢰 수준에 해당하는 z -값을 사용합니다. 표본 크기가 충분히 크므로 (1,526명), 정규 분포를 사용할 수 있습니다.

슬라이드 71: 지역 고용 시장 조건이 좋은가? (2/2)

신뢰 수준은 95% ($z_{\alpha/2} = 1.96$)입니다.

계산: 95% 신뢰 수준에 대한 $z_{\alpha/2}$ 값은 1.96입니다. (이전 섹션에서 $NORM.S.INV(0.975)$ 로 계산한 값과 동일합니다.)

오차 한계 계산

슬라이드 71: 지역 고용 시장 조건이 좋은가? (2/2)

오차 한계: $z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 1.96 \times \sqrt{\frac{0.51 \times (1-0.51)}{1526}} = 0.025$

계산: 표준 오차 $= \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.51 \times (1-0.51)}{1526}} = \sqrt{\frac{0.51 \times 0.49}{1526}} = \sqrt{\frac{0.2499}{1526}} \approx \sqrt{0.00016376} \approx 0.0128$

신뢰 구간 계산

슬라이드 71: 지역 고용 시장 조건이 좋은가? (2/2)

$0.51 \pm 0.025 = [0.485, 0.535]$

계산: 하한 $= -$ 오차 한계 $= 0.51 - 0.025 = 0.485$ 상한 $= +$ 오차 한계 $= 0.51 + 0.025 = 0.535$ 95% 신뢰 구간은 $[0.485, 0.535]$ 입니다.

해석: 우리는 95% 확신을 가지고 모든 성인의 48.5%에서 53.5%가 지역 고용 시장 조건이 좋다고 생각한다고 말할 수 있습니다.

4.2.4 95% "신뢰"의 진정한 의미

신뢰 구간의 의미를 정확히 이해하는 것이 중요합니다.

슬라이드 72: 95% "신뢰"는 실제로 무엇을 의미하는가?

표준 오차 = $\sqrt{\frac{0.51 \times (1-0.51)}{1526}} = 0.0128$ 95% 신뢰 구간: $[0.485, 0.535]$ 히스토그램은 95%를 나타내는 종 모양 곡선으로 그려져 있습니다. 왼쪽 꼬리의 세 표준 오차는 0.51에서 3배의 0.128을 뺀 값인 0.4716으로 계산됩니다. 95% 신뢰 구간의 두 표준 오차 지점에는 $[0.485, 0.535]$ 마커가 있습니다.

강의 내용 요약:

- **중심 극한 정리 (Central Limit Theorem):** 모집단에서 표본을 계속해서 추출하면, 각 표본은 다른 표본과 약간 다른 평균이나 비율을 가질 것입니다. 이 표본 평균 또는 표본 비율들을 플로팅하면, 모집단 모수를 중심으로 하는 정규 분포를 형성합니다.
- **표준 오차의 역할:** 이 분포의 퍼짐 정도는 표준 오차에 기반합니다. 95% 신뢰 구간은 대략 표본 평균/비율에서 양쪽으로 두 표준 오차 범위 내에 있습니다.
- **반복 추출의 의미:** 95% 신뢰 구간은 100개의 표본을 추출했을 때, 그 중 95개의 표본에서 계산된 신뢰 구간이 실제 모집단 모수를 포함할 것이라는 의미입니다. 나머지 5개 정도의 표본은 꼬리 부분에 위치하여 모집단 모수를 포함하지 않는 신뢰 구간을 생성할 수 있습니다.

슬라이드 73: 애니메이션 예시 - 95% 신뢰 구간

0.2에 선이 있고 그 선을 따라 여러 개의 녹색 막대와 몇 개의 빨간색 막대가 있는 막대 그래프.

애니메이션 설명:

- 이 시뮬레이션에서는 실제 모집단 비율이 0.2로 알려져 있다고 가정합니다 (검은색 실선).
- 100개의 표본을 각각 100개의 관측치로 추출했습니다.
- 이 시뮬레이션에서는 6개의 표본(빨간색 막대)이 모집단 비율을 포함하지 않는 신뢰 구간을 생성했습니다. 즉, 이 6개의 표본은 우리를 잘못된 결론으로 이끌었을 것입니다.
- 나머지 94개의 표본(녹색 막대)은 실제 모집단 비율을 포함하는 95% 신뢰 구간을 생성했습니다.

이것이 바로 95% 신뢰 수준의 의미입니다. 우리가 하나의 표본을 가지고 계산한 신뢰 구간이 실제 모집단 모수를 포함할 확률이 95%라는 뜻입니다.

4.2.5 승수(Multiplier)와 신뢰 수준

임계값($z_{\alpha/2}$)은 신뢰 수준을 나타내는 승수(*multiplier*)이며, 신뢰 구간의 폭을 결정합니다.

슬라이드 74: 승수와 신뢰 수준

$z_{\alpha/2}$ 는 원하는 신뢰 수준을 나타내는 승수입니다 (임계값이라고도 함).

$$\left[\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

강의 내용 요약: $z_{\alpha/2}$ 는 표본 분포의 중심에서 얼마나 많은 표준 오차만큼 떨어져 있는지를 나타냅니다. 신뢰 수준이 높아질수록 이 승수(임계값)는 커지고, 결과적으로 신뢰 구간은 더 넓어집니다.

슬라이드 76: 승수와 신뢰 수준 예시

신뢰 수준	승수 ($z_{\alpha/2}$)
90%	1.645
95%	1.96 (종종 2로 반올림)
98%	2.33
99%	2.58

4.2.6 연습: 99% 신뢰 구간 계산

Gallup 예시를 다시 사용하여 99% 신뢰 구간을 계산해 봅시다.

슬라이드 77: 연습

2016년 3월 31일부터 4월 2일까지 Gallup은 미국 50개 주와 컬럼비아 특별구에 거주하는 성인 1,526명을 무작위로 표본 조사했습니다. 1,526명의 성인 중 779명이 시장 조건이 좋다고 생각했습니다. 시장 조건이 좋다고 생각하는 모든 성인의 비율에 대한 99% 신뢰 구간은 얼마입니까?

문제 분석:

- 표본 크기 (n): 1,526명
- 표본 비율 ($\hat{p}$): 0.51 (이전과 동일)
- 신뢰 수준: 99%

임계값 결정

99% 신뢰 수준에 해당하는 z -값을 사용합니다.

슬라이드 78: 연습 - 풀이

신뢰 수준 = 99% ($z_{\alpha/2} = 2.58$)

계산: 99% 신뢰 수준에 대한 $z_{\alpha/2}$ 값은 2.58입니다. (이는 $NORM.S.INV(0.995)$ 로 계산할 수 있습니다.)

오차 한계 계산

슬라이드 78: 연습 - 풀이

오차 한계: $z_{\alpha/2} \times \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 2.58 \times \sqrt{\frac{0.51 \times (1-0.51)}{1526}} = 0.033$

계산: 표준 오차는 이전과 동일하게 약 0.0128입니다. 오차 한계 = $z_{\alpha/2} \times$ 표준 오차 = $2.58 \times 0.0128 \approx 0.033$ 0.033 (3.3%) .

신뢰 구간 계산

슬라이드 78: 연습 - 풀이

99% 신뢰 구간: $0.51 \pm 0.033 = [0.477, 0.543]$ 95% 신뢰 구간: $0.51 \pm 0.025 = [0.485, 0.535]$

계산: 하한 = - 오차 한계 = $0.51 - 0.033 = 0.477$ 상한 = + 오차 한계 = $0.51 + 0.033 = 0.543$ 99% 신뢰 구간은 $[0.477, 0.543]$ 입니다.

비교:

- 95% 신뢰 구간: $[0.485, 0.535]$
- 99% 신뢰 구간: $[0.477, 0.543]$

99% 신뢰 구간이 95% 신뢰 구간보다 더 넓은 것을 확인할 수 있습니다.

4.2.7 신뢰 수준과 신뢰 구간 폭의 관계

슬라이드 79: 90% 신뢰 구간 vs. 99% 신뢰 구간

0.2에 선이 있고 그 선을 따라 여러 개의 녹색 막대와 몇 개의 빨간색 막대가 있는 90% 신뢰 구간을 나타내는 막대 그래프. 0.2에 선이 있고 그 선을 따라 훨씬 더 많은 녹색 막대와 하나의 빨간색 막대가 있는 99% 신뢰 구간을 나타내는 두 번째 막대 그래프.

강의 내용 요약:

- **폭의 증가:** 90% 신뢰 구간과 99% 신뢰 구간을 비교하면, 신뢰 수준이 높아질수록 신뢰 구간의 폭이 넓어집니다. 녹색 막대(신뢰 구간)의 길이가 99%에서 더 길어진 것을 볼 수 있습니다.
- **정확도 vs. 정밀도:** 신뢰 구간이 넓어지면 실제 모집단 모수를 포함할 확률(정확도)은 높아지지만, 추정치의 정밀도(*precision*)는 떨어집니다. 즉, "더 확신하지만, 덜 구체적"입니다.

- **오류 감소:** 99% 신뢰 구간에서는 실제 모집단 모수를 놓치는 빨간색 막대가 90% 신뢰 구간보다 적습니다 (예시에서는 99%에서 1개, 90%에서 6개). 이는 신뢰 수준이 높을수록 잘못된 결론을 내릴 확률이 줄어든다는 것을 의미합니다.

4.2.8 표본 크기의 영향

신뢰 구간의 정밀도를 높이는 또 다른 방법은 표본 크기를 늘리는 것입니다.

슬라이드 80: 표본 크기의 영향

99% 신뢰 구간, $n = 100$ 을 나타내는 막대 그래프. 0.2에 선이 있고 그 선을 따라 여러 개의 녹색 막대와 하나의 빨간색 막대가 있습니다. 99% 신뢰 구간, $n = 1000$ 을 나타내는 두 번째 막대 그래프. 0.2에 선이 있고 그 선을 따라 여러 개의 더 작은 녹색 막대와 하나의 빨간색 막대가 있습니다.

강의 내용 요약:

- **폭의 감소:** 99% 신뢰 수준에서 표본 크기가 100일 때와 1,000일 때를 비교하면, 표본 크기가 1,000일 때 신뢰 구간의 폭이 훨씬 좁아진 것을 볼 수 있습니다.
- **정밀도 증가:** 표본 크기가 증가하면 표준 오차가 감소하므로, 오차 한계가 줄어들어 신뢰 구간이 좁아집니다. 이는 더 높은 정밀도를 제공합니다.
- **정확도 유지:** 표본 크기를 늘려도 신뢰 수준 (예: 99%)은 유지되므로, 모집단 모수를 포함할 확률은 동일하게 높습니다.

따라서, 더 정확하고 정밀한 추정을 위해서는 적절한 표본 크기를 결정하는 것이 중요합니다. 다음 강의에서는 이 표본 크기 결정에 대해 더 자세히 탐구할 것입니다.

4.3 빠르게 훑어보기: 핵심 요약

신뢰 구간의 기본 원리

- **목표:** 표본 데이터를 사용하여 모집단 모수 (평균, 비율)를 추정하는 구간을 제시.
- **구성:** 표본 통계량 $\pm$ 오차 한계.
- **오차 한계:** 임계값 $\times$ 표준 오차.

모집단 평균에 대한 신뢰 구간

- **표준 오차:**
- **임계값:**
 - 표본 크기가 크면 z -분포 ($z_{\alpha/2}$) 사용 (NORM.S.INV).
 - 일반적으로 t -분포 ($t_{\alpha/2}$) 사용 (T.INV(확률, 자유도)), 자유도 = $n - 1$.
- **Excel 단계:** 평균 $\rightarrow$ 표준편차 $\rightarrow$ 표준 오차 $\rightarrow$ 임계값 $\rightarrow$ 오차 한계 $\rightarrow$ 신뢰 구간.

모집단 비율에 대한 신뢰 구간

- **표본 비율 ($\hat{p}$):** x/n (x : 성공 횟수, n : 표본 크기).
- **표준 오차:**
- **임계값:** Z -분포 ($z_{\alpha/2}$) 사용 (*NORM.S.INV*).

신뢰 수준 및 표본 크기의 영향

- **신뢰 수준 증가:** 임계값 증가 $\rightarrow$ 오차 한계 증가 $\rightarrow$ 신뢰 구간 폭 증가 (정확도 $\uparrow$, 정밀도 $\downarrow$).
- **표본 크기 증가:** 표준 오차 감소 $\rightarrow$ 오차 한계 감소 $\rightarrow$ 신뢰 구간 폭 감소 (정밀도 $\uparrow$, 정확도 유지).
- **트레이드오프:** 높은 신뢰 수준과 높은 정밀도를 동시에 얻으려면 더 큰 표본 크기가 필요.

4.4 FAQ: 자주 묻는 질문

Q1: 95% 신뢰 구간이 정확히 무엇을 의미하나요?

A: 95% 신뢰 구간은 우리가 모집단에서 100개의 표본을 추출하여 각각 신뢰 구간을 계산한다면, 그 중 약 95개의 신뢰 구간이 실제 모집단 모수(평균 또는 비율)를 포함할 것이라는 의미입니다. 우리가 계산한 '하나의' 신뢰 구간이 모집단 모수를 포함할 확률이 95%라는 뜻이기도 합니다.

Q2: 왜 평균 신뢰 구간에서는 t -분포를 사용하고

A: 평균의 신뢰 구간을 계산할 때 모집단 표준편차를 모르는 경우가 많습니다. 이때 표본 표준편차를 사용하면 t -분포를 사용하는 것이 더 정확합니다. 반면, 비율의 신뢰 구간에서는 표본 크기가 충분히 크면 (일반적으로 $n\hat{p} \geq 10$ 및 $n(1-\hat{p}) \geq 10$), 표본 비율의 분포가 정규 분포에 근사하므로 Z -분포를 사용합니다.

Q3: 신뢰 수준을 높이면 항상 좋은 건가요?

A: 신뢰 수준을 높이면 모집단 모수를 포함할 확률은 높아지지만, 신뢰 구간의 폭이 넓어져 추정의 정밀도가 떨어집니다. 즉, "나는 99% 확신하지만, 그 값은 10에서 100 사이에 있을 거야"라고 말하는 것보다 "나는 90% 확신하지만, 그 값은 40에서 50 사이에 있을 거야"라고 말하는 것이 더 유용할 수 있습니다. 상황에 따라 적절한 균형을 찾아야 합니다.

Q4: 표본 크기가 신뢰 구간에 어떤 영향을 미치나요?

A: 표본 크기가 커지면 표준 오차가 감소하고, 이에 따라 오차 한계가 줄어들어 신뢰 구간의 폭이 좁아집니다. 이는 추정의 정밀도를 높여줍니다. 따라서 더 정확하고 정밀한 추정을 원한다면 표본 크기를 늘리는 것이 효과적입니다.

4.5 개요

이 문서는 모집단 비율에 대한 신뢰 구간 추정 방법과 그 활용에 대해 다룹니다. 특히 *Excel*을 활용하여 실제 데이터를 분석하고, 신뢰 구간의 개념을 시각적으로 이해하며, 시작 급여와 같은 실제 비즈니스 문제에 적용하는 방법을 학습합니다. 표본 크기와 신뢰 수준이 신뢰 구간의 폭에 미치는 영향을 애니메이션을 통해 직관적으로 파악하고, 평균과 비율에 대한 신뢰 구간을 계산하는 구체적인 절차를 익힙니다.

4.6 용어 정리

용어	쉬운 설명	원어	비고
신뢰 구간	모집단 모수가 존재할 것으로 예상되는 구간	<i>Confidence Interval</i>	특정 신뢰 수준에서
모집단 비율	전체 집단에서 특정 특성을 가진 개체의 비율	<i>Population Proportion</i>	보통 p 로 표기
표본 비율	표본에서 특정 특성을 가진 개체의 비율	<i>Sample Proportion</i>	보통 $\hat{p}$ 로 표기
표준 오차	표본 통계량의 변동성을 나타내는 척도	<i>Standard Error (SE)</i>	표본 통계량의 표준 편차
Z-값	표준 정규 분포에서 특정 확률에 해당하는 값	<i>Z-value</i>	신뢰 구간 계산에 사용
T-값	T-분포에서 특정 확률에 해당하는 값	<i>T-value</i>	표본 크기가 작거나 모집단 표준편차를 모를 때 사용
오차 한계	표본 통계량과 모집단 모수 간의 최대 예상 차이	<i>Margin of Error (ME)</i>	신뢰 구간의 절반 폭
논리 함수	특정 조건에 따라 다른 값을 반환하는 함수	<i>Logical Function</i>	<i>Excel</i> 의 IF 함수 등
표본 크기	분석에 사용된 데이터 개수	<i>Sample Size</i>	n 으로 표기
신뢰 수준	신뢰 구간이 모집단 모수를 포함할 확률	<i>Confidence Level</i>	보통 90%, 95%, 99%

4.7 모집단 비율에 대한 신뢰 구간 (Excel 활용)

이 섹션에서는 *Excel*을 사용하여 모집단 비율에 대한 신뢰 구간을 계산하는 방법을 배웁니다. 뉴욕 증권 거래소 (NYSE)의 주식 데이터를 예시로 들어, 하루 동안 주식 가격이 상승한 비율을 추정하는 과정을 단계별로 살펴봅니다.

4.7.1 데이터 준비 및 초기 분석

우리는 2015년 9월 어느 날의 뉴욕 증권 거래소 마감 데이터를 사용합니다. 이 데이터는 주식 심볼, 마감 가격, 순 변동액, 그리고 백분율 변동액을 포함합니다. 저작권 문제로 인해 심볼은 변경되었습니다. 우리의 목표는 하루 동안 가격이 상승한 주식의 비율을 파악하는 것입니다.

- 데이터 확인:** 주식 데이터는 "New Symbols", "Close", "Net Chg", "% Chg"의 네 가지 열로 구성되어 있습니다. 우리는 "% Chg" 열을 사용하여 주식 가격이 상승했는지 여부를 판단할 것입니다. 백분율 변동액이 양수이면 가격이 상승한 것이고, 음수이면 하락한 것입니다.
- 주식 분류 (Up? 열 생성):** 각 주식의 가격이 상승했는지 여부를 분류하기 위해 새로운 열 "Up?"을 생성합니다. 이 열에는 *Excel*의 IF 논리 함수를 사용합니다.

Excel IF 함수 사용법

목표: "% Chg" 값이 0보다 크면 1(상승), 그렇지 않으면 0(하락)을 반환합니다. **함수:** `=IF(logical_test, [value_if_true], [value_if_false])` **예시:** 첫 번째 데이터 셀 (D4)의 값이 -2.38이라고 가정할 때, `=IF(D4>0,1,0)`을 입력합니다. **결과:** D4가 -2.38이므로 0이 반환됩니다. 이 함수를 아래로 드래그하여

모든 주식에 적용합니다.

이 과정을 통해 각 주식에 대해 상승 여부를 나타내는 0 또는 1의 값이 "Up?" 열에 채워집니다. 예를 들어, D11 셀의 값이 0보다 크면 1이 반환되어 해당 주식이 상승했음을 나타냅니다.

3. **상승한 주식 수 계산 (No. Up):** "Up?" 열의 모든 1의 값을 합산하여 상승한 주식의 총 수를 계산합니다. 0은 상승하지 않았음을 의미하므로, 1의 합계가 곧 상승한 주식의 수가 됩니다.

Excel SUM 함수 사용법

목표: "Up?" 열의 합계를 계산합니다. **함수:** =SUM(number1, number2, ...) **예시:** =SUM(H:H) 또는 =SUM(H4:H2195) (H열에 "Up?" 데이터가 있다고 가정) **결과:** 이 예시에서는 383개의 주식이 상승했습니다.

4. **총 주식 수 계산 (count):** 전체 주식의 수를 파악하기 위해 "Up?" 열의 데이터 개수를 셉니다.

Excel COUNT 함수 사용법

목표: "Up?" 열의 데이터 개수를 셉니다. **함수:** =COUNT(value1, value2, ...) **예시:** =COUNT(H:H) 또는 =COUNT(H4:H2195) **결과:** 이 예시에서는 총 2,192개의 주식이 보고되었습니다.

5. **상승 주식 비율 계산 (Prop 'up'):** 상승한 주식의 수(No. Up)를 총 주식 수(count)로 나누어 전체 주식 중 상승한 주식의 비율을 계산합니다.

Excel 비율 계산

목표: 상승 주식 비율을 계산합니다. **함수:** =No. Up 셀 / count 셀 **예시:** =H4/H5 (H4에 383, H5에 2192가 있다고 가정) **결과:** 0.174726, 즉 약 17.5%의 주식이 상승했습니다. 이는 시장이 좋지 않은 날이었음을 시사합니다.

4.7.2 표본 데이터 분석 및 신뢰 구간 계산

이제 전체 모집단(모든 주식)이 아닌, 특정 표본(예: 127개 주식으로 구성된 개인 포트폴리오)을 사용하여 신뢰 구간을 추정하는 방법을 살펴봅니다.

1. **표본 데이터 준비:** 새로운 워크시트에서 127개 주식으로 구성된 표본 포트폴리오 데이터를 사용합니다. 이전과 동일하게 "% Chg" 열을 기반으로 "Up?" 열을 생성합니다.

Excel IF 함수 (표본 데이터)

목표: 표본 주식에 대해 상승 여부를 분류합니다. **함수:** =IF(D5>0,1,0) (D5는 첫 번째 표본 주식의 "% Chg" 값) **결과:** 이 함수를 127개 주식 전체에 적용합니다.

2. **표본 비율 계산:** 표본 포트폴리오에서 상승한 주식의 수 (*Sum up*)와 총 주식 수 (*count*)를 계산한 후, 표본 비율 (*Prop up*)을 계산합니다.

표본 비율 계산 결과

상승 주식 수 (*Sum up*): 20 총 주식 수 (*count*): 127 표본 비율 (*Prop up*):
 $=I4/I5$ (*I4*에 20, *I5*에 127이 있다고 가정) = 0.15748, 즉 약 15.75%

3. **Z-값 계산:** 모집단 비율에 대한 신뢰 구간을 계산할 때는 일반적으로 Z-값을 사용합니다. 95% 신뢰 구간의 경우, 양쪽 꼬리 확률이 각각 2.5%이므로, 누적 확률 0.975에 해당하는 Z-값을 찾습니다.

Excel NORM.S.INV 함수 사용법

목 표 : 95% 신뢰 수준에 해당하는 Z-값을 계산합니다. 함수 :
 $=NORM.S.INV(probability)$ 예시: $=NORM.S.INV(0.975)$ 결과: 1.9599 (약 1.96)

Z-값 시각적 설명

표준 정규 분포에서 95% 신뢰 구간은 중앙 95% 영역을 의미합니다. 이는 양쪽 꼬리에 각각 2.5%의 확률이 있음을 뜻합니다. 따라서 왼쪽 끝에서부터 97.5% ($0.95 + 0.025$)에 해당하는 Z-값을 찾으면 1.96이 됩니다.

Figure 4.2: 95% 신뢰 구간의 Z-값 개념

4. **표준 오차 (Standard Error, SE) 계산:** 표본 비율의 표준 오차는 다음 공식으로 계산됩니다. $SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$, n .

오차 한계 (Margin of Error, ME) 계산: 오차 한계는 Z-값과 표준 오차를 곱하여 계산됩니다. $ME = Z \times SE$

신뢰 구간의 하한 (Lower) 및 상한 (Upper) 계산: 신뢰 구간은 표본 비율에서 오차 한계를 빼고 더하여 계산됩니다. 신뢰 구간 = $\pm ME$

신뢰 구간 해석: 계산된 신뢰 구간은 [9.4%, 22%]입니다. 이는 우리가 가진 127개 주식 포트폴리오를 표본으로 사용했을 때, 전체 주식 시장에서 가격이 상승한 주식의 실제 비율이 9.4%에서 22% 사이에 있을 것이라고 95% 신뢰 수준으로 추정할 수 있음을 의미합니다. 실제 모집단 비율이 17.5%였으므로, 이 신뢰 구간은 실제 값을 잘 포착하고 있습니다.

4.8 신뢰 구간 애니메이션을 통한 이해

이 섹션에서는 시뮬레이션 애니메이션을 통해 신뢰 수준과 표본 크기가 신뢰 구간의 폭에 미치는 영향을 시각적으로 탐구합니다.

4.8.1 신뢰 구간의 개념 시각화

파란색과 주황색 구슬이 담긴 항아리를 상상해 봅시다. 파란색은 만족한 고객, 주황색은 불만족한 고객을 나타낼 수 있습니다. 이 항아리는 모집단을 의미하며, 우리는 이 모집단에서 표본을 추출하여 모집단 비율을 추정하려고 합니다.

1. **모집단 비율 확인:** 애니메이션 도구에서 "Show p" 옵션을 선택하면 모집단 비율이 0.5 (50%)로 표시됩니다. 즉, 파란색과 주황색 구슬이 50:50으로 섞여 있습니다.
2. **단일 표본 추출 및 신뢰 구간:** 표본 크기 50, 신뢰 수준 95%를 설정하고 "Sample" 버튼을 클릭하여 하나의 표본을 추출합니다.

단일 표본 결과

표본 비율 (Sample p): 0.46 (예시) **신뢰 구간:** 그래프에 수직 검은색 막대로 표시됩니다. 이 막대는 표본 비율 0.46을 중심으로 하는 신뢰 구간을 나타냅니다.

이 신뢰 구간은 우리가 추출한 첫 번째 표본을 사용하여 얻은 것입니다. 실제 모집단 비율은 50%이지만, 표본마다 비율이 다르게 나올 수 있습니다.

3. **여러 표본 추출:** "Sample 100" 버튼을 클릭하여 100개의 표본을 추출하고 각각의 신뢰 구간을 그립니다.

100개 표본 결과

그래프: 100개의 수직 막대가 그려집니다. 대부분의 막대는 실제 모집단 비율 0.5를 포함하지만, 일부 막대(빨간색으로 표시)는 0.5를 포함하지 않습니다. **빨간색 막대:** 95% 신뢰 수준에서는 약 5개(100개 중 5%)의 표본이 실제 모집단 비율을 포함하지 않는 신뢰 구간을 생성할 수 있습니다. 이는 신뢰 수준의 정의와 일치합니다.

만약 우리가 빨간색으로 표시된 표본 중 하나만 추출했다면, 잘못된 결론을 내렸을 것입니다.

4.8.2 표본 크기의 영향

표본 크기가 신뢰 구간의 폭에 어떤 영향을 미치는지 살펴봅시다.

- (a) **표본 크기 50 vs 100:** 동일한 모집단에서 표본 크기를 50에서 100으로 늘려 다시 100개의 표본을 추출합니다.

표본 크기 증가의 효과

신뢰 구간 폭: 표본 크기가 100으로 증가하면 각 신뢰 구간(검은색 막대)의 폭이 줄어듭니다. **오류 표본 수:** 실제 모집단 비율을 놓치는 빨간색 막대의 수도 줄어듭니다. **정밀도 증가:** 신뢰 구간이 작아진다는 것은 추정의 **정밀도(Precision)**가 높아진다는 의미입니다. 즉, 추정 범위가 더 좁아져 실제 값에 더 가깝게 접근할 가능성이 커집니다.

- (b) **표본 크기 100 vs 250:** 표본 크기를 250으로 더 늘려 100개의 표본을 추출합니다.

표본 크기 250 결과

신뢰 구간 폭: 신뢰 구간의 폭은 더욱 감소합니다. **오류 표본 수:** 95% 신뢰 수준이므로 여전히 약 5개의 표본이 실제 모집단 비율을 놓칠 수 있습니다. 하지만 각 구간의 폭이 좁아져 더 정확한 추정을 가능하게 합니다.

핵심 요약

핵심 요약: 표본 크기가 증가할수록 신뢰 구간의 폭은 좁아집니다. 이는 추정의 정밀도가 높아진다는 것을 의미합니다.

4.8.3 신뢰 수준의 영향

표본 크기를 고정한 상태에서 신뢰 수준이 신뢰 구간의 폭에 어떤 영향을 미치는지 살펴봅니다.

- i. **신뢰 수준 95% vs 99%:** 표본 크기를 250으로 고정하고 신뢰 수준을 95%에서 99%로 변경합니다.

신뢰 수준 증가의 효과

신뢰 구간 폭: 신뢰 수준이 99%로 증가하면 신뢰 구간의 폭은 넓어집니다. **Z-값:** 99% 신뢰 수준에서는 Z-값이 약 2.5로 (95%의 1.96보다) 커지기 때문입니다. Z-값이 커지면 오차 한계가 커지고, 결과적으로 신뢰 구간의 폭이 넓어집니다. **오류 표본 수:** 100개의 표본 중 실제 모집단 비율을 놓치는 빨간색 막대의 수는 줄어듭니다 (예: 1개). 이는 더 높은 신뢰도로 실제 값을 포함하려 하기 때문입니다.

- ii. **신뢰 수준 99% vs 90%:** 신뢰 수준을 90%로 변경하면 신뢰 구간의 폭은 더욱 좁아집니다. 90% 신뢰 수준에서는 Z-값이 더 작아지기 때문입니다. 하지만 실제 모집단 비율을 놓치는 표본의 수는 증가할 수 있습니다 (예: 6개).
- iii. **표본 크기 50, 신뢰 수준 99%:** 표본 크기가 작고(50), 신뢰 수준이 높으면(99%) 신뢰 구간은 매우 넓어집니다. 이 경우 오차 한계가 커져 추정의 정밀도가 떨어집니다.

핵심 요약

핵심 요약: 신뢰 수준이 증가할수록 신뢰 구간의 폭은 넓어집니다. 이는 실제 모집단 모수를 포함할 확률을 높이기 위함입니다.

4.8.4 정확도와 정밀도 향상

정확도와 정밀도 향상 전략

정확도 (Accuracy): 추정치가 실제 모집단 모수에 얼마나 가까운지를 나타냅니다. 신뢰 수준을 높이면 정확도가 높아집니다 (즉, 실제 값을 포함할 확률이 높아집니다). **정밀도 (Precision):** 추정치의 범위가 얼마나 좁은지를 나타냅니다. 표본 크기를 늘리면 정밀도가 높아집니다 (즉, 신뢰 구간의 폭이 좁아집니다).

결론: 정확도와 정밀도를 동시에 높이는 가장 좋은 방법은 **표본 크기를 늘리는 것**입니다. 표본 크기를 늘리면 신뢰 구간의 폭이 좁아지면서도, 실제 모집단 모수를 포함할 확률을 높일 수 있습니다. 신뢰 수준을 높이는 것은 정확도를 높이지만, 정밀도를 떨어뜨립니다 (신뢰 구간이 넓어짐).

4.9 시작 급여 예시 (Excel 활용)

이 섹션에서는 커뮤니티 칼리지 졸업생의 시작 급여 데이터를 사용하여 평균과 특정 급여 이상을 받는 졸업생의 비율에 대한 신뢰 구간을 계산하는 방법을 배웁니다.

4.9.1 문제 정의 및 평균 급여 신뢰 구간 계산

커뮤니티 칼리지는 신입생 유치를 위해 졸업생의 시작 급여 정보를 제공합니다. 100명의 졸업생이 자신의 시작 급여를 자발적으로 제공했습니다. 이 데이터를 기반으로 다음 두 가지 질문에 답해야 합니다.

- i. 이 프로그램 졸업생의 평균 시작 급여에 대한 95% 신뢰 구간은 얼마인가?
- ii. 26,500 95% ?(26,500 미만이면 학생들이 프로그램에 등록하지 않을 것이라고 생각함)

먼저 평균 시작 급여에 대한 신뢰 구간을 계산합니다.

- i. **평균 급여 계산 (Avg Salary):** 100명의 졸업생 시작 급여 데이터에서 평균을 계산합니다.

Excel AVERAGE 함수 사용법

목표: 시작 급여의 평균을 계산합니다. **함수:** =AVERAGE(number1, number2, ...) **예시:** =AVERAGE(A:A) (A열에 시작 급여 데이터가 있다고 가정) **결과:** 27,092

- ii. **표준 편차 계산 (std dev):** 표본의 표준 편차를 계산합니다.

Excel STDEV.S 함수 사용법

목표: 표본의 표준 편차를 계산합니다. **함수:** =STDEV.S(number1, number2, ...) **예시:** =STDEV.S(A:A) **결과:** 2,533.997(2,534)

- iii. **표본 크기 계산 (Sample Size):** 응답한 졸업생의 수를 셉니다.

Excel COUNT 함수 사용법

목표: 표본 크기를 계산합니다. **함수:** =COUNT(value1, value2, ...)

예시: =COUNT(A:A) **결과:** 100

iv. **표준 오차 (Standard Error, SE) 계산:** 평균의 표준 오차는 표본 표준 편차를 표본 크기의 제곱근으로 나눈 값입니다. $\bar{x} = \frac{s}{\sqrt{n}}$

(c) **T-값 계산 (95%, t value):** 표본 크기가 30 이상이라도 모집단의 표준 편차를 모르는 경우 T-분포를 사용합니다. 95% 신뢰 구간의 T-값을 계산합니다. 자유도는 $n - 1$ 입니다.

Excel T.INV 함수 사용법

목표: 95% 신뢰 수준에 해당하는 T-값을 계산합니다. **함수:** =T.INV(probability, deg_freedom) **예시:** =T.INV(0.975, 99) (자유도 = 100 - 1 = 99) **결과:** 1.9842 (강의 자료에서는 0.972로 오타가 있었으나, 0.975가 올바른 값이며 t-값은 거의 동일합니다.)

주의

주의: 강의 자료에서 T.INV(0.972,...)로 오타가 있었으나, 95% 신뢰 구간의 경우 누적 확률은 0.975가 올바릅니다. 두 값의 T-값은 매우 유사합니다.

(d) **오차 한계 (Margin of Error, ME) 계산:** 오차 한계는 T-값과 표준 오차를 곱하여 계산됩니다. $ME = t_{\alpha/2} \times \frac{s}{\sqrt{n}}$

4. **신뢰 구간의 하한 (Lower) 및 상한 (Upper) 계산:** 신뢰 구간은 표본 평균에서 오차 한계를 빼고 더하여 계산됩니다. 신뢰 구간 = $\pm ME$

신뢰 구간 해석: 95% 신뢰 수준에서 이 프로그램 졸업생의 평균 시작 급여는 26,602 27,582 사이에 있을 것으로 추정됩니다. 입학처장이 우려하는 26,500

4.9.2 특정 급여 이상을 받는 졸업생 비율 신뢰 구간 계산

이제 두 번째 질문, 즉 26,500

1. **급여 조건 분류 (Makes more than 26500 열 생성):** 각 졸업생의 시작 급여가 26,500

조건 만족 졸업생 수 계산 (Making > 26500): 26,500

표본 비율 계산 (Prop > 26500): 조건을 만족하는 졸업생 수(61)를 총 표본 크기(100)로 나누어 비율을 계산합니다. -

표본 비율 계산 결과

조건 만족 졸업생 수: 61 표본 크기: 100 표본 비율: $61 / 100 = 0.61$ (61%)

Z-값 계산 (95%, z value): 모집단 비율에 대한 신뢰 구간이므로 Z-값을 사용합니다. 95% 신뢰 구간의 Z-값은 1.96입니다. -

Excel NORM.S.INV 함수 사용법

목표: 95% 신뢰 수준에 해당하는 Z-값을 계산합니다. **함수:** =NORM.S.INV(0.975)

결과: 1.95996398 (약 1.96)

표준 오차 (Standard Error, SE) 계산: 비율의 표준 오차는 다음 공식으로 계산됩니다.

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \quad (0.61), n \quad (100) \quad . -$$

오차 한계 (Margin of Error, ME) 계산: 오차 한계는 Z-값과 표준 오차를 곱하여 계산됩니다. $ME = Z \times \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} -$

신뢰 구간의 하한 (Lower) 및 상한 (Upper) 계산: 신뢰 구간은 표본 비율에서 오차 한계를 빼고 더하여 계산됩니다. 신뢰 구간 = $\pm ME -$

신뢰 구간 해석 및 비즈니스 시사점: 95% 신뢰 수준에서 26,500 51.44% 70.55% .-

4.10 핵심 요약 및 학습 가이드

핵심 요약

핵심 요약: 모집단 비율 신뢰 구간 및 활용 이 문서는 모집단 비율에 대한 신뢰 구간을 Excel로 계산하는 방법을 상세히 설명하고, 신뢰 수준 및 표본 크기가 신뢰 구간에 미치는 영향을 시각적으로 탐구했습니다. 뉴욕 증권 거래소 주식 데이터와 커뮤니티 칼리지 졸업생 시작 급여 데이터를 활용하여 실제 비즈니스 문제에 신뢰 구간을 적용하는 구체적인 절차를 다루었습니다. 특히, 표본 크기가 클수록 신뢰 구간의 폭이 좁아져 추정의 정밀도가 높아지며, 신뢰 수준이 높을수록 신뢰 구간의 폭이 넓어져 실제 모수를 포함할 확률이 높아진다는 점을 강조했습니다. 통계적 추정의 한계를 이해하고 신중하게 해석하는 것이 중요합니다.

학습 로드맵: 신뢰 구간 마스터하기

1. 기초 다지기: 신뢰 구간의 기본 개념(신뢰 수준, 오차 한계, 표준 오차)을 확실히 이해합니다.

2. **Excel 실습:** Excel의 IF, SUM, COUNT, NORM.S.INV, T.INV, SQRT 함수를 사용하여 평균과 비율에 대한 신뢰 구간을 직접 계산해봅니다.
3. **개념 시각화:** 애니메이션을 통해 표본 크기와 신뢰 수준이 신뢰 구간의 폭에 미치는 영향을 직관적으로 파악합니다.
4. **실제 적용:** 제공된 시작 급여 예시처럼 실제 비즈니스 시나리오에 신뢰 구간을 적용하고 결과를 해석하는 연습을 합니다.
5. **해석 능력 강화:** 신뢰 구간의 의미와 한계를 이해하고, 통계적 결과를 비즈니스 의사결정에 어떻게 활용할지 비판적으로 사고하는 능력을 기릅니다.

4.11 개요

이 문서는 'Exploring and Producing Data Module 4'의 마지막 부분으로, 신뢰 구간(Confidence Interval)의 핵심 요소인 오차 한계(Margin of Error)를 이해하고, 원하는 정확도와 정밀도를 얻기 위한 적절한 표본 크기(Sample Size)를 결정하는 방법을 다룹니다. 특히, 평균(Mean)과 비율(Proportion)에 대한 표본 크기 계산 공식과 그 경제적 의미를 설명합니다. 또한, Excel을 활용하여 표본 크기를 계산하고, 표본 크기가 신뢰 구간에 미치는 영향을 시각적으로 확인하는 실습 과정을 포함합니다. 이 문서를 통해 데이터 기반 의사결정에 필수적인 표본 설계 원리를 완벽하게 이해할 수 있습니다.

4.12 용어 정리

용어	쉬운 설명	원어	비고
신뢰 구간	모집단 모수가 존재할 것으로 예상되는 구간	Confidence Interval	
오차 한계	표본 통계량과 모집단 모수 간의 최대 예상 오차	Margin of Error (MOE)	신뢰 구간의 폭을 결정
표본 크기	연구에 사용되는 데이터 포인트의 수	Sample Size (n)	
표본 평균	표본 데이터의 평균	Sample Mean ($\bar{x}$)	
표본 비율	표본에서 특정 특성을 가진 개체의 비율	Sample Proportion ($\hat{p}$)	
모집단 표준편차	모집단 데이터의 퍼진 정도	Population Standard Deviation (σ)	
표본 표준편차	표본 데이터의 퍼진 정도	Sample Standard Deviation (s)	
임계값 (z/t)	신뢰 수준에 따라 결정되는 표준화된 값	Critical Value ($z_{\alpha/2}, t_{\alpha/2}$)	
허용 오차 한계	연구자가 최대 허용하는 오차 범위	Acceptable Margin of Error (E)	
자유도	통계적 추정에서 독립적으로 변할 수 있는 값의 수	Degrees of Freedom (df)	$n - 1$
표준 오차	표본 통계량의 변동성 추정치	Standard Error (SE)	

4.13 핵심 개념 및 원리

4.13.1 신뢰 구간과 오차 한계의 이해

신뢰 구간은 모집단의 특정 모수(예: 평균, 비율)가 존재할 것으로 예상되는 구간을 의미합니다. 이 구간은 표본 데이터를 기반으로 추정되며, 특정 신뢰 수준(예: 95%, 99%)을 가집니다. 신뢰 구간은 크게 두 부분으로 구성됩니다: 표본 통계량(예: 표본 평균, 표본 비율)과 오차 한계(Margin of Error)입니다.

- **평균에 대한 신뢰 구간:** 표본 평균 $\pm$ 오차 한계
- **비율에 대한 신뢰 구간:** 표본 비율 $\pm$ 오차 한계

우리는 추정의 **정확성(precision)**과 **정밀성(accuracy)**을 높이기 위해 오차 한계를 작게 만들고 싶어 합니다. 오차 한계는 우리가 표본을 통해 얻은 값이 실제 모집단의 값과 얼마나 차이 날 수 있는지를 나타내는 지표이기 때문입니다.

핵심 요약

오차 한계가 작을수록 추정치가 더 정확하고 정밀합니다.

4.13.2 오차 한계의 구성 요소

오차 한계는 여러 요소에 의해 결정됩니다. 이 요소들을 이해하는 것은 우리가 원하는 오차 한계를 달성하기 위해 표본 크기를 어떻게 조절해야 하는지 파악하는 데 중요합니다.

- **평균에 대한 오차 한계:** $t_{\alpha/2} \frac{s}{\sqrt{n}}$
- **비율에 대한 오차 한계:** $z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

여기서 각 기호는 다음과 같습니다:

- $t_{\alpha/2}$ 또는 $z_{\alpha/2}$: 신뢰 수준에 따른 임계값 (critical value)
- s : 표본 표준편차 (sample standard deviation)
- $\hat{p}$: 표본 비율 (sample proportion)
- n : 표본 크기 (sample size)

이 공식들을 자세히 살펴보면, 오차 한계는 **표본 크기(n)**에 의해 부분적으로 통제된다는 것을 알 수 있습니다. 표본 크기가 커질수록 분모의 $\sqrt{n}$ 이 커지므로 오차 한계는 작아집니다.

4.13.3 표본 크기 결정의 필요성

지금까지는 주어진 표본 크기로 오차 한계와 신뢰 구간을 계산하는 예시를 살펴보았습니다. 하지만 실제 연구에서는 반대로, 우리가 원하는 **최대 오차 한계(E)**를 먼저 정하고, 이 오차 한계를 달성하기 위해 **얼마나 큰 표본 크기(n)**가 필요한지 역으로 계산해야 할 때가 많습니다.

팁

표본 크기 결정은 연구의 경제적 의사결정입니다. 더 큰 표본은 더 많은 시간과 노력을 필요로 하므로 비용이 증가합니다. 따라서 원하는 정확도와 비용 사이의 균형을 찾아야 합니다.

표본 크기 결정의 경제적 의미

표본 크기 선택은 단순히 통계적 정확성뿐만 아니라 **경제적 결정**이기도 합니다.

- **작은 표본의 위험:** 만약 시리얼 상자에 내용물이 너무 많이 들어가거나 적게 들어가서 품질 관리에 실패한다면, 생산 비용이 증가하거나 벌금을 물게 될 수 있습니다.

- **큰 표본의 비용:** 더 큰 표본을 얻는 데는 더 많은 시간과 노력이 필요하며, 이는 곧 비용 증가로 이어집니다.
- **오류의 심각성:** 만약 약을 생산하는데 성분 배합이 잘못되어 치명적인 결과를 초래할 수 있다면, 작은 오차도 용납할 수 없으므로 매우 큰 표본 크기가 필요할 것입니다.

따라서, '잘못될 경우의 비용'과 '더 큰 표본을 얻는 비용'을 비교하여 적절한 표본 크기를 결정해야 합니다.

4.13.4 평균 추정을 위한 표본 크기 결정

모집단 평균을 추정하기 위해 필요한 표본 크기 (n)는 다음과 같은 공식을 사용하여 계산할 수 있습니다.

$$n = \left(\frac{z_{\alpha/2} \sigma}{E} \right)^2$$

여기서:

- n : 필요한 최소 표본 크기
- $z_{\alpha/2}$: 원하는 신뢰 수준에 해당하는 임계값 (예: 95% 신뢰 수준에서 1.96)
- σ : 모집단 표준편차 (알 수 없는 경우, 사전 연구의 표본 표준편차 s 를 사용하거나 소규모 예비 연구를 통해 추정)
- E : 연구자가 허용하는 최대 오차 한계 (desired margin of error)

주의

표본 크기 n 은 항상 정수여야 하며, 계산 결과가 소수점 이하일 경우 **항상 올림(round up)**해야 합니다. 예를 들어, 188.230이 나오면 189로 올립니다. 이는 원하는 정확도를 보장하기 위함입니다.

4.13.5 비율 추정을 위한 표본 크기 결정

모집단 비율을 추정하기 위해 필요한 표본 크기 (n)는 다음과 같은 공식을 사용하여 계산할 수 있습니다.

$$n = p(1-p) \left(\frac{z_{\alpha/2}}{E} \right)^2$$

여기서:

- n : 필요한 최소 표본 크기
- p : 모집단 비율의 사전 추정치 (preliminary estimate of population proportion)
- $z_{\alpha/2}$: 원하는 신뢰 수준에 해당하는 임계값
- E : 연구자가 허용하는 최대 오차 한계

팁

모집단 비율 p 를 모를 경우:

- 소규모 예비 연구를 통해 $\hat{p}$ 를 얻을 수 있습니다.
- 가장 보수적인(즉, 가장 큰) 표본 크기를 얻기 위해 $p = 0.5$ 를 사용할 수 있습니다. $p(1 - p)$ 값은 $p = 0.5$ 일 때 최대값(0.25)을 가집니다. 이는 어떤 비율이든 커버할 수 있는 충분히 큰 표본 크기를 보장합니다.
- 만약 예비 연구를 통해 신뢰 구간이 얻어졌다면, 그 신뢰 구간 내에서 0.5에 가장 가까운 비율 값을 p 로 사용합니다. 이는 0.5를 사용하는 것보다 더 효율적인(작은) 표본 크기를 제공할 수 있습니다.

4.13.6 오차 한계를 결정하는 요인

신뢰 구간의 오차 한계에 영향을 미치는 세 가지 주요 요인은 다음과 같습니다.

1. **표본 크기 (n):** 표본 크기가 증가하면 오차 한계는 감소합니다. (더 많은 데이터를 수집할수록 추정치가 더 정확해집니다.)
2. **신뢰 수준 (Confidence Level):** 신뢰 수준이 증가하면 오차 한계는 증가합니다. (더 높은 신뢰도로 구간을 만들려면 더 넓은 구간이 필요합니다.)
3. **표본의 표준편차 (s):** 표준편차가 증가하면 오차 한계는 증가합니다. (데이터의 변동성이 클수록 추정치가 덜 정확해집니다.)

핵심 요약

오차 한계 감소를 위한 전략:

- 표본 크기 증가 (가장 효과적이고 직접적인 방법)
- 신뢰 수준 감소 (원하는 신뢰도를 낮추는 것이므로 신중해야 함)
- 표준편차 감소 (데이터 자체의 특성이므로 통제하기 어려움)

4.14 절차 및 방법: 표본 크기 계산 예시

4.14.1 평균 추정을 위한 표본 크기 계산 예시

예제

예시: Speedy Lube의 15분 오일 교환 광고

Speedy Lube는 고객들에게 15분 오일 교환을 광고하고 싶어 합니다. 매니저는 오일 교환 과정을 개선하는 데 많은 시간을 보냈고, 이제 15분 오일 교환을 광고할 수 있는지 확인하고 싶습니다. 만약 오차 한계를 30초(0.5분)로 하고 95% 신뢰 구간을 찾으려면 얼마나 큰 표본 크기가 필요할까요?

문제 해결 단계:

1. 주어진 정보 확인:

- 원하는 오차 한계 (E) = 30초 = 0.5분
- 원하는 신뢰 수준 = 95%

- 95% 신뢰 수준에 대한 $z_{\alpha/2}$ 값 = 1.96

2. **누락된 정보 확인:** 모집단 표준편차 σ 를 모릅니다.

3. **해결책:** 표준편차를 알기 위해 소규모 예비 연구를 수행합니다.

4. **예비 연구 결과:** 100개의 무작위 관측치를 통해 평균 시간은 14.7분, 표준편차는 3.5분으로 나타났습니다. 이제 이 표본 표준편차 $s = 3.5$ 분을 σ 대신 사용합니다.

5. **표본 크기 계산:**

$$n = \left(\frac{z_{\alpha/2}\sigma}{E} \right)^2 = \left(\frac{1.96 \times 3.5}{0.5} \right)^2$$

$$n = \left(\frac{6.86}{0.5} \right)^2 = (13.72)^2 = 188.2384$$

6. **결과 반올림:** 표본 크기는 정수여야 하므로, 항상 올림하여 189가 됩니다.

결론: 매니저가 원하는 정확도와 정밀도를 제공하기 위해 필요한 최소 표본 크기는 189개의 관측치입니다.

예제

연습 문제: 시리얼 상자 무게

시리얼 회사 매니저는 시리얼 상자의 평균 무게에 대해 0.15온스 이내의 신뢰 구간을 만들고 싶어 합니다. 이 공정의 표준편차는 0.5온스로 알려져 있습니다. 99% 신뢰 구간을 위해 필요한 표본 크기는 얼마일까요?

문제 해결 단계:

1. **주어진 정보 확인:**

- 원하는 오차 한계 (E) = 0.15온스
- 모집단 표준편차 (σ) = 0.5온스
- 원하는 신뢰 수준 = 99%
- 99% 신뢰 수준에 대한 $z_{\alpha/2}$ 값 = 2.575

2. **표본 크기 계산:**

$$n = \left(\frac{z_{\alpha/2}\sigma}{E} \right)^2 = \left(\frac{2.575 \times 0.5}{0.15} \right)^2$$

$$n = \left(\frac{1.2875}{0.15} \right)^2 = (8.5833)^2 = 73.679 \approx 73.72$$

3. **결과 반올림:** 표본 크기는 정수여야 하므로, 항상 올림하여 74가 됩니다.

결론: 99% 신뢰 수준에서 0.15온스 이내의 오차 한계를 달성하기 위해 필요한 최소 표본 크기는 74개입니다.

4.14.2 비율 추정을 위한 표본 크기 계산 예시

예제

예시: 지구 온난화에 대한 인식 (사전 정보 없음)

우리는 지구 온난화가 실재라고 생각하는 인구의 비율을 알고 싶습니다. 오차 한계를 1% 이내로 하고 95% 신뢰 구간을 만들려면 얼마나 큰 표본 크기가 필요할까요?

문제 해결 단계:

1. 주어진 정보 확인:

- 원하는 오차 한계 (E) = 1% = 0.01
- 원하는 신뢰 수준 = 95%
- 95% 신뢰 수준에 대한 $z_{\alpha/2}$ 값 = 1.96

2. 누락된 정보 확인: 모집단 비율 p 를 모릅니다.

3. 해결책: 모집단 비율에 대한 사전 정보가 없으므로, 가장 보수적인 추정치인 $p = 0.5$ 를 사용합니다.

4. 표본 크기 계산:

$$n = p(1 - p) \left(\frac{z_{\alpha/2}}{E} \right)^2 = 0.5 \times (1 - 0.5) \times \left(\frac{1.96}{0.01} \right)^2$$

$$n = 0.25 \times (196)^2 = 0.25 \times 38416 = 9604$$

결론: 95% 신뢰 수준에서 1% 이내의 오차 한계를 달성하기 위해 필요한 최소 표본 크기는 9,604명입니다.

예제

연습 문제: 지구 온난화에 대한 인식 (오차 한계 변경)

위 예시에서 표본 크기가 너무 크다고 판단하여, 오차 한계를 4%로 완화한다면 새로운 표본 크기는 얼마가 될까요?

문제 해결 단계:

1. 주어진 정보 확인:

- 원하는 오차 한계 (E) = 4% = 0.04 (변경됨)
- 원하는 신뢰 수준 = 95%
- 95% 신뢰 수준에 대한 $z_{\alpha/2}$ 값 = 1.96
- 모집단 비율 $p = 0.5$ (사전 정보 없음 가정)

2. 표본 크기 계산:

$$n = p(1 - p) \left(\frac{z_{\alpha/2}}{E} \right)^2 = 0.5 \times (1 - 0.5) \times \left(\frac{1.96}{0.04} \right)^2$$

$$n = 0.25 \times (49)^2 = 0.25 \times 2401 = 600.25$$

3. 결과 반올림: 표본 크기는 정수여야 하므로, 항상 올림하여 601이 됩니다.

결론: 오차 한계를 4%로 완화하면 필요한 표본 크기는 601명으로 크게 줄어듭니다. 이는 정밀도를 낮추면 표본 크기를 줄일 수 있음을 보여줍니다.

예제

예시: 지구 온난화에 대한 인식 (초기 설문조사 활용)

우리는 지구 온난화가 실재라고 생각하는 인구의 비율을 1% 이내로 알고 싶습니다. 95% 신뢰 구간을 만들려면 얼마나 큰 표본 크기가 필요할까요? 이번에는 초기 설문조사를 통해 100명의 성인 중 15%가 지구 온난화를 믿지 않는다는 사실을 알게 되었습니다.

문제 해결 단계:**1. 주어진 정보 확인:**

- 원하는 오차 한계 (E) = 1% = 0.01
- 원하는 신뢰 수준 = 95%
- 95% 신뢰 수준에 대한 $z_{\alpha/2}$ 값 = 1.96
- 초기 설문조사 결과: $n = 100$, $\hat{p} = 0.15$ (믿지 않는 비율)

2. 모집단 비율 p 추정: 초기 설문조사에서 얻은 $\hat{p} = 0.15$ 를 바로 사용하는 것은 위험할 수 있습니다. 이 $\hat{p}$ 는 표본에 기반한 것이므로, 먼저 이 표본 비율에 대한 신뢰 구간을 계산해야 합니다.

$$\begin{aligned}\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} &= 0.15 \pm 1.96 \times \sqrt{\frac{0.15(1-0.15)}{100}} \\ &= 0.15 \pm 1.96 \times \sqrt{\frac{0.15 \times 0.85}{100}} = 0.15 \pm 1.96 \times \sqrt{0.001275} \\ &= 0.15 \pm 1.96 \times 0.0357 = 0.15 \pm 0.069972 \approx 0.15 \pm 0.07\end{aligned}$$

따라서 신뢰 구간은 $[0.08, 0.22]$ 입니다.

3. 표본 크기 계산을 위한 p 선택: 이 신뢰 구간 $[0.08, 0.22]$ 내에서 0.5에 가장 가까운 값을 p 로 선택해야 합니다. 이는 표본 크기가 충분히 크게 보장되도록 합니다. 이 경우, 0.22가 0.5에 더 가깝습니다 ($0.5 - 0.22 = 0.28$, $0.5 - 0.08 = 0.42$). 따라서 $p = 0.22$ 를 사용합니다.**4. 표본 크기 계산:**

$$\begin{aligned}n &= p(1-p) \left(\frac{z_{\alpha/2}}{E} \right)^2 = 0.22 \times (1-0.22) \times \left(\frac{1.96}{0.01} \right)^2 \\ n &= 0.22 \times 0.78 \times (196)^2 = 0.1716 \times 38416 = 6591.8816\end{aligned}$$

5. 결과 반올림: 표본 크기는 정수여야 하므로, 항상 올림하여 6,592가 됩니다.

결론: 초기 설문조사 정보를 활용하여 $p = 0.22$ 를 사용했을 때 필요한 표본 크기는 6,592명입니다. 이는 사전 정보 없이 $p = 0.5$ 를 사용했을 때의 9,604명보다 훨씬 적은 수치입니다. 이처럼 초기 정보를 활용하면 더 효율적인 표본 크기를 결정할 수 있습니다.

팁

표본 비율 p 가 0 또는 1에 가까울 때: 만약 모집단 비율 p 가 0 또는 1에 가깝다면, 대부분의 개체가 동일한 특성이나 의견을 가지고 있다는 의미입니다. 이 경우 자연적인 변동성(variability)이 매우 작아지므로, 오차 한계는 p 가 0.5에

가까울 때보다 작아집니다. 즉, p 가 0.5일 때 가장 큰 표본 크기가 필요하며, 이는 가장 보수적인 추정치입니다.

4.15 실습: Excel을 활용한 표본 크기 결정

4.15.1 비율 추정 시 표본 크기 결정 (Excel)

Excel을 사용하여 원하는 오차 한계를 달성하기 위한 표본 크기를 계산하는 방법을 살펴보겠습니다.

예제

예시: 주식 포트폴리오의 비율 추정

이전 강의에서 127개 주식으로 구성된 포트폴리오의 오차 한계가 6%라고 결정했습니다. 만약 원하는 오차 한계를 4%로 줄이고 싶다면, 몇 개의 주식을 표본으로 추출해야 할까요?

문제 해결 단계:

1. 공식 확인: 비율 추정을 위한 표본 크기 공식은 $n = p(1-p) \left(\frac{z_{\alpha/2}}{E} \right)^2$ 입니다.
2. 주어진 정보:
 - 원하는 오차 한계 (E) = 4% = 0.04
 - 신뢰 수준 = 95% (강의에서 1.96 사용) $\rightarrow z_{\alpha/2} = 1.96$
 - 이전 분석에서 얻은 신뢰 구간: 예를 들어, [0.09, 0.22] (강의 슬라이드 139에서 'Upper 0.220831' 언급)
3. p 값 선택: 신뢰 구간 [0.09, 0.22] 내에서 0.5에 가장 가까운 값을 p 로 선택합니다. 이 경우 0.220831이 0.5에 가장 가깝습니다. ($0.5 - 0.220831 = 0.279169$, $0.5 - 0.09 = 0.41$)
4. Excel 계산:
 - p 값: 0.220831
 - $1-p$ 값: $1 - 0.220831 = 0.779169$
 - $z_{\alpha/2}$ 값: 1.96
 - E 값: 0.04

Excel 셀에 다음과 같이 입력합니다:

```
1 =0.220831 * (1-0.220831) * (1.96/0.04)^2
2
```

Listing 4.1: Excel을 이용한 비율 표본 크기 계산

5. 결과: 계산 결과는 413.117이 나옵니다.
6. 반올림: 표본 크기는 항상 올림하므로, 414개의 주식을 표본으로 추출해야 합니다.

결론: 원하는 오차 한계 4%를 달성하기 위해 414개의 주식을 표본으로 추출해야 합니다. 이는 9%에서 22% 사이의 모든 가능성을 커버할 수 있는 충분히 큰 표본 크기를 보장합니다.

4.15.2 평균 추정 시 표본 크기 결정 (Excel)

Excel을 사용하여 평균 추정을 위한 표본 크기를 계산하는 방법을 살펴보겠습니다.

예제

예시: 뉴욕 증권 거래소 주식의 평균 변화율

뉴욕 증권 거래소의 증가 데이터를 사용하여 주식의 평균 변화율에 대한 신뢰 구간을 만들고, 원하는 오차 한계를 달성하기 위한 표본 크기를 계산합니다.

문제 해결 단계:

1. 데이터 준비: 뉴욕 증권 거래소의 주식 데이터에서 'Percent Change' 열을 사용합니다.

2. 표본 평균 및 표준편차 계산:

- **평균 ($\bar{x}$):** Excel의 AVERAGE 함수를 사용하여 'Percent Change' 열의 평균을 계산합니다.

```
1 =AVERAGE(D:D) % 열D 전체 선택
2
```

Listing 4.2: Excel 평균 계산

결과: 약 -1.278 (이 날 주식 시장이 전체적으로 하락했음을 의미)

- **표준편차 (s):** Excel의 STDEV.S 함수를 사용하여 'Percent Change' 열의 표본 표준편차를 계산합니다.

```
1 =STDEV.S(D:D) % 열D 전체 선택
2
```

Listing 4.3: Excel 표준편차 계산

결과: 약 2.2658

3. 실제 표본 크기 확인: 데이터에 결측치가 있을 수 있으므로, COUNT 함수를 사용하여 실제 분석에 사용된 데이터 포인트 수를 확인합니다.

```
1 =COUNT(D:D) % 열D 전체 선택
2
```

Listing 4.4: Excel 표본 크기 계산

결과: 예를 들어, 127개 주식 중 2개가 거래되지 않아 실제 표본 크기는 125가 될 수 있습니다. (강의에서는 125를 사용)

4. 임계값 ($t_{\alpha/2}$) 계산: 평균 추정 시에는 일반적으로 t-분포를 사용합니다. 95% 신뢰 수준을 가정합니다.

- 신뢰 수준 = 95% $\rightarrow \alpha = 0.05 \rightarrow \alpha/2 = 0.025$
- t.inv 함수는 누적 확률을 사용하므로, 왼쪽 꼬리 확률은 $1 - \alpha/2 = 0.975$ 입니다.
- 자유도 (df) = $n - 1 = 125 - 1 = 124$

Excel 셀에 다음과 같이 입력합니다:

```
1 =T.INV(0.975, 124)
2
```

Listing 4.5: Excel t-값 계산

결과: 약 1.97928 (z-값 1.96과 유사하지만 더 정확함)

5. **표준 오차 (SE) 계산:** 표준 오차는 $\frac{s}{\sqrt{n}}$ 입니다. Excel 셀에 다음과 같이 입력합니다:

```
1 =StdDev_Cell / SQRT(Sample_Size_Cell) % 예: I6/SQRT(I8)
2
```

Listing 4.6: Excel 표준 오차 계산

결과: 약 0.18

6. **오차 한계 (ME) 계산:** 오차 한계는 $t_{\alpha/2} \times SE$ 입니다. Excel 셀에 다음과 같이 입력합니다:

```
1 =T_Value_Cell * SE_Cell % 예: I10*I12
2
```

Listing 4.7: Excel 오차 한계 계산

결과: 약 0.361708

7. **신뢰 구간 계산:**

- 하한: 평균 - 오차 한계
- 상한: 평균 + 오차 한계

결과: 예를 들어, [-1.69979, -0.97637]

8. **원하는 오차 한계에 대한 표본 크기 계산:** 만약 현재 오차 한계(0.361708)가 만족스럽지 않고, 원하는 오차 한계 (E)를 0.3으로 설정하고 싶다면, 필요한 표본 크기를 계산합니다. 공식: $n = \left(\frac{t_{\alpha/2}s}{E}\right)^2$ Excel 셀에 다음과 같이 입력합니다:

```
1 =(T_Value_Cell * StdDev_Cell / Desired_E_Cell)^2 % 예: (I10*I6/0.3)^2
2
```

Listing 4.8: Excel을 이용한 평균 표본 크기 계산

결과: 약 181.7

9. **반올림:** 표본 크기는 항상 올림하므로, 182개의 주식을 표본으로 추출해야 합니다.

결론: 평균 변화율에 대해 0.3의 오차 한계를 달성하려면 182개의 주식을 표본으로 추출해야 합니다. 이는 기존 125개보다 더 큰 포트폴리오가 필요함을 의미합니다.

4.15.3 표본 크기가 신뢰 구간에 미치는 영향 (Excel)

표본 크기가 신뢰 구간의 폭에 어떻게 영향을 미치는지 Excel을 통해 시각적으로 확인합니다.

예제

예시: 다양한 표본 크기에서의 신뢰 구간 비교

평균과 표준편차가 동일한 세 가지 가상의 표본(크기 50, 200, 500)을 가정하고, 각 표본 크기가 표준 오차, 임계값, 오차 한계, 그리고 신뢰 구간에 미치는 영향을 비교합니다.

가정:

- 표본 평균 ($\bar{x}$) = 56.3645 (모든 표본 크기에서 동일)
- 표본 표준편차 (s) = 17.90778 (모든 표본 크기에서 동일)
- 신뢰 수준 = 95%

문제 해결 단계:**1. 표준 오차 (SE) 계산:** $SE = \frac{s}{\sqrt{n}}$

- $n = 50$: $17.90778/\sqrt{50} \approx 2.5325$
- $n = 200$: $17.90778/\sqrt{200} \approx 1.2663$
- $n = 500$: $17.90778/\sqrt{500} \approx 0.8009$

관찰: 표본 크기가 커질수록 표준 오차는 감소합니다. 이는 표본 평균의 변동성이 줄어든다는 것을 의미합니다.

2. 임계값 ($t_{\alpha/2}$) 계산: $t.inv(0.975, n - 1)$

- $n = 50$: $t.inv(0.975, 49) \approx 2.0010$
- $n = 200$: $t.inv(0.975, 199) \approx 1.9720$
- $n = 500$: $t.inv(0.975, 499) \approx 1.9647$

관찰: 표본 크기가 커질수록 t-값은 z-값(1.96)에 가까워집니다. 이는 표본 크기가 충분히 크면 t-분포가 정규 분포와 유사해진다는 것을 보여줍니다.

3. 오차 한계 (ME) 계산: $ME = t_{\alpha/2} \times SE$

- $n = 50$: $2.0010 \times 2.5325 \approx 5.0893$
- $n = 200$: $1.9720 \times 1.2663 \approx 2.4970$
- $n = 500$: $1.9647 \times 0.8009 \approx 1.5735$

관찰: 표본 크기가 커질수록 오차 한계는 크게 감소합니다. 이는 표준 오차와 t-값 모두 감소하기 때문입니다.

4. 신뢰 구간 계산: $\bar{x} \pm ME$

- $n = 50$: $56.3645 \pm 5.0893 \rightarrow [51.2752, 61.4538]$ (폭: 약 10.18)
- $n = 200$: $56.3645 \pm 2.4970 \rightarrow [53.8675, 58.8615]$ (폭: 약 4.99)
- $n = 500$: $56.3645 \pm 1.5735 \rightarrow [54.7910, 57.9380]$ (폭: 약 3.15)

관찰: 표본 크기가 커질수록 신뢰 구간의 폭이 좁아집니다. 이는 추정의 정밀도가 높아진다는 것을 의미합니다.

결론: 표본 크기가 증가하면 표준 오차와 임계값이 감소하여 오차 한계가 줄어들고, 결과적으로 신뢰 구간의 폭이 좁아져 추정의 정확도와 정밀도가 향상됩니다. 높은 신뢰 수준과 정밀도를 동시에 얻기 위한 가장 효과적인 방법은 표본 크기를 늘리는 것입니다.

4.16 체크리스트

이 문서를 통해 다음 사항들을 이해하고 있는지 확인해 보세요.

- 신뢰 구간과 오차 한계의 개념을 정확히 설명할 수 있는가?
- 평균과 비율에 대한 오차 한계 공식을 이해하고 있는가?
- 원하는 오차 한계를 달성하기 위한 표본 크기 결정의 중요성을 설명할 수 있는가?
- 평균 추정을 위한 표본 크기 공식을 사용하여 계산할 수 있는가?
- 비율 추정을 위한 표본 크기 공식을 사용하여 계산할 수 있는가?
- 비율 추정 시 p 값을 모를 경우 어떻게 처리해야 하는지 아는가?
- 표본 크기, 신뢰 수준, 표준편차가 오차 한계에 미치는 영향을 설명할 수 있는가?
- Excel을 사용하여 평균 및 비율에 대한 표본 크기를 계산할 수 있는가?
- Excel을 사용하여 표본 크기 변화가 신뢰 구간에 미치는 영향을 시각적으로 확인할 수 있는가?
- 계산된 표본 크기가 소수점일 때 항상 올림해야 하는 이유를 아는가?

4.17 FAQ

- Q: 표본 크기가 커지면 왜 오차 한계가 줄어드나요? A: 표본 크기가 커지면 표본 평균이나 표본 비율이 모집단의 실제 값에 더 가까워질 가능성이 높아집니다. 통계적으로는 표본 크기 n 이 오차 한계 공식의 분모에 $\sqrt{n}$ 형태로 들어가기 때문에, n 이 커지면 오차 한계가 작아집니다. 이는 표본 통계량의 변동성(표준 오차)이 줄어드기 때문입니다.
- Q: 비율 추정 시 모집단 비율 p 를 모를 때 왜 0.5를 사용하나요? A: $p(1 - p)$ 값은 $p = 0.5$ 일 때 최대값인 0.25를 가집니다. 이 값을 사용하면 계산되는 표본 크기가 가장 커지므로, 어떤 실제 모집단 비율이든 원하는 오차 한계를 달성할 수 있는 가장 보수적인(안전한) 표본 크기를 얻을 수 있습니다.
- Q: 표본 크기 계산 결과가 소수점일 때 항상 올림해야 하는 이유는 무엇인가요? A: 표본 크기는 사람이나 물건의 개수이므로 정수여야 합니다. 만약 계산된 표본 크기보다 작은 값을 사용하면, 우리가 설정한 원하는 오차 한계를 달성하지 못할 수 있습니다. 따라서 원하는 정확도를 보장하기 위해 항상 올림하여 최소한의 필요한 표본 크기를 확보해야 합니다.
- Q: 신뢰 수준을 높이면 오차 한계는 왜 증가하나요? A: 신뢰 수준을 높인다는 것은 모집단 모수를 포함할 확률을 더 높게 가져가겠다는 의미입니다. 예를 들어, 95% 신뢰 구간보다 99% 신뢰 구간이 모집단 모수를 포함할 가능성이 더 높습니다. 이를 위해서는 더 넓은 구간이 필요하며, 이는 오차 한계가 커진다는 것을 의미합니다. 통계적으로는 신뢰 수준이 높아질수록 임계값($z_{\alpha/2}$ 또는 $t_{\alpha/2}$)이 커지기 때문입니다.

4.18 빠르게 훑어보기 (1페이지 요약)

표본 크기 결정 핵심 요약

- **목표:** 원하는 오차 한계(E)를 달성하기 위한 최소 표본 크기(n) 계산.
- **오차 한계 영향 요인:**
 - $\uparrow$ 표본 크기 (n) $\rightarrow$ $\downarrow$ 오차 한계
 - $\uparrow$ 신뢰 수준 $\rightarrow$ $\uparrow$ 오차 한계
 - $\uparrow$ 표준편차 (s) $\rightarrow$ $\uparrow$ 오차 한계
- **평균 추정 공식:** $n = \left(\frac{z_{\alpha/2}\sigma}{E} \right)^2$
- **비율 추정 공식:** $n = p(1-p) \left(\frac{z_{\alpha/2}}{E} \right)^2$
- **핵심 팁:**
 - n 은 항상 올림.
 - 비율 p 를 모르면 0.5 사용 (가장 보수적).
 - 초기 연구로 얻은 신뢰 구간이 있다면, 0.5에 가장 가까운 값을 p 로 사용.
- **경제적 결정:** 표본 크기는 비용과 정확도 사이의 균형. 오류 비용이 높으면 더 큰 표본 필요.
- **Excel 활용:** AVERAGE, STDEV.S, COUNT, T.INV, SQRT 함수를 사용하여 계산 및 영향 분석.



Chapter 5

Lecture 5

강의명: 데이터 기반 의사결정

주차: Module 1: 추론 및 예측 통계

교수명: 교수명 (예: John Doe)

목적: 데이터를 활용한 합리적인 의사결정을 위해 가설 설정, 결과 분석, 그리고 평균 및 비율에 대한 단측/양측 검정 방법을 학습

개요

이 문서는 UIUC의 BADM-572 '데이터 기반 의사결정' 과목 중 '추론 및 예측 통계 모듈 1'의 핵심 내용을 담고 있습니다. 데이터를 활용한 합리적인 의사결정을 위해 가설 설정, 결과 분석, 그리고 평균 및 비율에 대한 단측/양측 검정 방법을 상세히 다룹니다. 특히, 통계적 사고방식과 Excel을 활용한 실습 과정을 통해 비전공자도 쉽게 이해하고 실제 문제에 적용할 수 있도록 구성되었습니다. 이 문서는 시험 대비를 위한 완벽한 학습 자료가 될 것입니다.

핵심 요약

핵심 목표:

- 통계적 문해력(Statistical Literacy) 향상
- 데이터 요약 및 통찰력 확보
- 표본 통계를 활용한 모집단 추론 능력 배양
- 가설 검정의 기본 원리 및 실제 적용 능력 습득

용어 정리

다음 표는 이 문서에서 사용되는 주요 통계 용어들을 비전공자도 쉽게 이해할 수 있도록 설명합니다.

용어	쉬운 설명	원어	비고
가설 검정	어떤 주장이 사실인지 통계적으로 확인하는 과정	Hypothesis Testing	과학적 연구의 핵심 단계
귀무 가설	우리가 '기각'하려고 시도하는 기존의 믿음이나 주장	Null Hypothesis (H0)	'차이가 없다', '효과가 없다'는 내용
대립 가설	귀무 가설과 반대되는, 우리가 증명하고 싶은 주장	Alternate Hypothesis (HA or H1)	'차이가 있다', '효과가 있다'는 내용
유의 수준	귀무 가설이 사실인데도 잘못 기각할 확률 (허용 오차)	Significance Level (α)	보통 0.05 (5%) 사용
p-값	관측된 데이터가 귀무 가설 하에서 나타날 확률	p-value	p-값이 α 보다 작으면 귀무 가설 기각
제1종 오류	귀무 가설이 사실인데 잘못 기각하는 오류	Type I Error (α)	'제조업자 위험', '위양성'
제2종 오류	귀무 가설이 거짓인데 잘못 기각하지 않는 오류	Type II Error (β)	'소비자 위험', '위음성'
단측 검정	특정 방향(크거나 작거나)으로의 차이만 검정	One-Tail Test	대립 가설에 '>', '<' 포함
양측 검정	양쪽 방향(다르다)으로의 차이를 모두 검정	Two-Tail Test	대립 가설에 '≠' 포함
표본 평균	표본 데이터의 평균	Sample Mean ($\bar{x}$)	모집단 평균을 추정하는 데 사용
표본 표준편차	표본 데이터의 퍼진 정도	Sample Standard Deviation (s)	모집단 표준편차를 추정하는 데 사용
표준 오차	표본 평균이 모집단 평균과 얼마나 차이 날 수 있는지	Standard Error (SE)	표본 크기가 커질수록 작아짐
t-값	표본 평균이 귀무 가설의 평균으로부터 표준 오차 단위로 얼마나 떨어져 있는지	t-statistic	검정 통계량 중 하나
t-분포	표본 크기가 작거나 모집단 표준편차를 모를 때 사용하는 분포	t-distribution	정규 분포와 유사하지만 꼬리가 더 두꺼움
자유도	통계량을 계산할 때 자유롭게 변할 수 있는 값의 개수	Degrees of Freedom (df)	보통 표본 크기 - 1

주요 통계 용어 및 설명

5.1 모듈 1: 비즈니스를 위한 추론 및 예측 통계

5.1.1 강의 소개

환영합니다: 비즈니스를 위한 추론 및 예측 통계!

데이터는 우리 주변에 항상 존재하며, 매일 더 많은 데이터가 생성되고 있습니다. 하지만 우리는 이 데이터를 통해 더 나은 결정을 내리고 있을까요? 이 질문에 답하기 위해 통계학을 공부하는 것이 중요합니다.

핵심 요약

통계학을 공부하는 이유:

- 데이터는 어디에나 있으며, 올바른 의사결정을 위해 데이터를 이해해야 합니다.
- 통계는 GDP, 인플레이션, 실업률 같은 경제 지표부터 스포츠 선수 성적, 복권 당첨 확률까지 다양한 분야에서 활용됩니다.
- 데이터 분석은 농업, 의료, 금융, 유통, 제조, 교육 등 모든 분야에서 중요합니다.
- 통계는 결과에 영향을 미치는 요인을 식별하고, 이를 통해 더 유리한 결과를 만들 수 있도록 돕습니다.
- 통계는 데이터를 이해하는 데 도움을 주며, 고용주들이 신입 직원에게 가장 중요하게 요구하는 기술 중 하나입니다. (LinkedIn 1위 '핫 스킬', Google 수석 경제학자 Hal Varian: "향후 10년간 가장 seksi한 직업은 통계학자")

통계학이란 무엇인가?

통계학은 단순히 데이터를 수학적 방법으로 처리하는 것을 넘어섭니다. 가장 중요한 것은 '유용한 데이터를 얻는 방법'을 알고, '결과를 올바르게 해석하는 것'입니다.

주의

통계학의 오용 가능성: 통계학은 의도적으로 또는 부주의하게 쉽게 오용될 수 있는 분야입니다.

- **올바른 방법:** 데이터가 올바르게 수집되고, 분석이 올바르게 수행되며, 결과가 올바르게 제시될 때, 통계는 세상을 이해하고 더 나은 결정을 내리는 데 큰 도움이 됩니다.
- **잘못된 방법:** 잘못된 데이터로 시작하거나, 부적절한 방법론을 사용하거나, 결과를 잘못 해석하면 오히려 해를 끼칠 수 있습니다.

무엇을 배우게 될까요?

이 과정은 여러분을 데이터 과학자나 통계학자로 만들지는 않습니다. 하지만 통계적 분석의 기본을 이해하고, 관리자로서 데이터 과학자들에게 올바른 질문을 던지고, 결과를 해석하며, 더 나은 결정을 내리는 데 필요한 기술을 제공합니다.

핵심 요약

주요 학습 목표 (Macro Objectives):

- **통계적 문해력(Statistically Literate) 향상:** 통계 정보를 이해하고 비판적으로 평가하는 능력.
- **데이터 요약 방법 학습:** 방대한 데이터를 의미 있는 형태로 정리하는 기술.
- **요약된 데이터에서 통찰력 얻기:** 요약된 정보에서 숨겨진 패턴이나 의미를 발견하는 능력.
- **표본 추출 및 표본 통계의 중요성 이해:** 전체 모집단을 대표하는 표본을 얻는 방법과 그 중요성.
- **표본 통계를 사용하여 모집단에 대한 추론하기:** 작은 표본 데이터를 기반으로 전체 모집단에 대해 결론을 내리는 방법.

어떻게 배우게 될까요?

이 과정에서는 다양한 활동을 통해 주제를 깊이 이해하게 됩니다.

- **비디오 강의 (Video lectures):** 이론적 개념을 배우고, 다양한 문제와 설정에 적용하는 방법을 익힙니다.
- **Excel 실습 (Excel illustrations):** 대규모 데이터 세트에 학습한 방법론을 적용하고 결과를 해석하는 방법을 보여줍니다. 단순히 결과를 도출하는 것을 넘어, 그 결과가 실제로 무엇을 의미하는지 이해하는 데 중점을 둡니다.
- **채점 퀴즈 (Graded quizzes):** 학습 자료를 숙달했는지 확인합니다. 통계 개념은 서로 연결되어 있으므로, 다음 단계로 넘어가기 전에 각 주제를 잘 이해하는 것이 중요합니다. 자가 평가를 통해 준비가 되었는지 확인하고, 필요하면 추가 자료를 활용하여 복습합니다.
- **동료 평가 과제 (Peer reviewed assignments):** 정량적이지 않은 질문이나 시나리오에 대해 설명하거나 비판하는 과제입니다. 다른 학생들의 답변을 읽고 댓글을 달면서

데이터 분석 기반 보고서에 반응하는 기술을 연마하고, 의사결정자에게 필요한 여러 기술을 통합합니다.

이 과정은 쉬운 주제가 아니지만, 도구를 적용하는 데 중점을 둘 것입니다. 때로는 건조하게 느껴질 수 있는 개념도 결과를 이해하는 데 필요한 만큼만 다룰 것입니다. 꾸준히 노력하면 이 매혹적인 과학의 아름다움과 힘을 발견할 수 있을 것입니다.

5.1.2 Lesson 1-1: 가설 설정

Lesson 1-1.1: 가설 설정

가설 검정은 모든 과학적 연구의 중요한 단계입니다. 우리는 일상생활과 비즈니스에서 가설 검정의 중요성을 보여주는 다양한 사례를 접합니다.

예제

가설 검정의 실제 사례:

- **폭스바겐 배출가스 스캔들 (VW Emission Scandal):** 폭스바겐이 디젤 차량의 배출가스를 조작했다는 사실이 웨스트버지니아 대학교 연구진에 의해 밝혀졌습니다. 연구진은 폭스바겐 차량의 배출량이 신뢰 구간 내에 들지 않는다는 것을 발견했고, 반복된 테스트에서도 동일한 결과가 나오자 폭스바겐의 주장이 거짓임을 확신했습니다. 통계적 증거는 거대 기업의 주장을 반박하는 데 결정적인 역할을 했습니다.
- **랜스 암스트롱 (Lance Armstrong):** 유명 사이클 선수 랜스 암스트롱은 혈액 검사를 통해 금지 약물 사용이 적발되어 모든 업적을 박탈당했습니다. 이는 '약물 미사용'이라는 주장이 통계적 증거에 의해 기각된 사례입니다.
- **알츠하이머병 연구 데이터 조작:** 주요 제약 회사들이 관련된 알츠하이머병 연구에서 데이터가 조작된 사례도 있었습니다. 이는 통계가 잘못 사용될 때 얼마나 심각한 결과를 초래할 수 있는지를 보여줍니다.
- **의료 검사 오류:** 우리가 아는 누군가 또는 우리 자신이 잘못된 의료 검사 결과를 받은 경험도 있을 수 있습니다. 이 모든 사례는 '어떤 주장이 사실인가?'를 통계적으로 검증하는 가설 검정의 중요성을 강조합니다.

이 모든 예시들은 '가설 검정(Hypothesis Testing)'의 중요성을 보여줍니다. 가설 검정은 이전 과정에서 배운 '신뢰 구간(Confidence Interval)'의 확장이며, '추론 통계(Inferential Statistics)'의 한 분야입니다.

과학적 방법의 단계

모든 과학적 연구는 일련의 단계를 따릅니다.

1. **문제 식별 (Identify a problem):** 연구를 시작할 문제나 현상을 정의합니다.
2. **문제 연구 (Study the problem):** 문헌 조사나 예비 테스트를 통해 문제에 대한 이해를 심화합니다.
3. **가설 설정 (Formulate a hypothesis):** 연구 질문에 대한 잠정적인 답을 제시합니다.
4. **실험 수행 (Conduct an experiment):** 가설을 검증하기 위한 데이터를 수집합니다.

5. **결과 분석 (Analyze the results)**: 수집된 데이터를 통계적으로 분석합니다.
6. **결론 도출 (Make a conclusion)**: 분석 결과를 바탕으로 가설의 수용 또는 기각 여부를 결정합니다.

이 모듈에서는 특히 **가설 설정**과 **결과 분석** 및 **결론 도출**에 중점을 둘 것입니다. 가설 검정 과정은 가설을 설정하는 것부터 시작합니다.

가설 설정

가설에는 두 가지 유형이 있습니다: 귀무 가설(Null Hypothesis)과 대립 가설(Alternate Hypothesis). 이 두 가설은 모든 가능성을 포괄해야 합니다.

- **귀무 가설 (Null hypothesis, H_0)**:
 - 우리가 '기대하는 일' 또는 '현재의 믿음'을 나타냅니다.
 - 예를 들어, 폭스바겐 연구에서 연구자들은 폭스바겐이 보고한 결과(배출량이 기준치 이내)를 기대했습니다.
 - 귀무 가설은 우리가 표본 증거를 사용하여 '기각'하려고 시도하는 주장입니다.
- **대립 가설 (Alternate hypothesis, H_A 또는 H_1)**:
 - 귀무 가설 외의 '모든 다른 가능성'을 나타냅니다.
 - 폭스바겐의 경우, 실제 배출량이 보고된 것보다 높다는 것이 대립 가설이 됩니다.
 - 귀무 가설을 설정하면 대립 가설은 그 '보완(complement)' 관계에 있습니다.

주의

가설 설정의 중요 규칙:

- **상호 배타적 (Mutually Exclusive)**: H_0 와 H_A 는 동시에 참일 수 없습니다.
- **총체적 포괄 (Collectively Cover All Possibilities)**: H_0 와 H_A 를 합치면 모든 가능한 상황을 설명해야 합니다.
- **등호 포함 (Equality in H_0)**: 귀무 가설(H_0)에는 항상 등호($=, \geq, \leq$)가 포함되어야 합니다. 이는 통계적 검정의 기준점을 제공하기 위함입니다.

예제

예시 1: 모집단 평균 (학생 부채)

- **상황**: 2015년 졸업생의 평균 학자금 대출액은 35,000달러라고 알려져 있습니다. '굿딜 대학교'는 자교 학생들의 부채가 이보다 적을 것이라고 믿습니다.
 - **주장 1 (현재 믿음)**: 굿딜 대학교 졸업생의 평균 부채는 다른 졸업생들과 다르지 않다. 즉, 35,000달러이다. (이것이 귀무 가설이 됩니다.)
 - **주장 2 (굿딜 대학교의 주장)**: 굿딜 대학교 졸업생의 평균 부채는 35,000달러보다 적다. (이것이 대립 가설이 됩니다.)
 - **가설 표기**:
 - $H_0: \mu \geq \$35,000$ (평균 부채가 35,000달러 이상이다)
 - $H_A: \mu < \$35,000$ (평균 부채가 35,000달러 미만이다)
- 대립 가설($\mu < \$35,000$)부터 설정하는 것이 더 쉬울 수 있습니다. 그러면 귀무 가설은 그 보완 관계($\mu \geq \$35,000$)가 됩니다.

예제

예시 2: 모집단 평균 (초콜릿 봉지 무게)

- **상황:** 초콜릿 제조 공장에서 300g으로 표시된 초콜릿 봉지를 생산합니다. 품질 관리팀은 정확성을 확인하기 위해 50개의 봉지를 표본으로 추출합니다.
 - **현재 믿음:** 봉지는 올바르게 채워지고 있다. (300g이다)
 - **대립 주장:** 봉지는 올바르게 채워지지 않고 있다. (300g이 아니다)
 - **가설 표기:**
 - $H_0: \mu = 300$ (평균 무게는 300g이다)
 - $H_A: \mu \neq 300$ (평균 무게는 300g이 아니다)
- 이것은 전형적인 품질 관리 예시이며, '다르다'는 양방향의 차이를 검정하므로 '양측 검정(Two-tail test)'이 됩니다.

단측 검정(One-tail)과 양측 검정(Two-tail)

가설의 형태에 따라 검정 방식이 달라집니다.

- **단측 검정 (One-tail test):**
 - 귀무 가설이 특정 값보다 '크거나 같다'($\geq$) 또는 '작거나 같다'($\leq$)와 같이 한쪽 방향의 값을 허용할 때 사용합니다.
 - 대립 가설은 특정 값보다 '작다'($<$) 또는 '크다'($>$)와 같이 한쪽 방향을 주장합니다.
 - **예시:** 학생 부채 ($H_0: \mu \geq \$35,000$, $H_A: \mu < \$35,000$)
- **양측 검정 (Two-tail test):**
 - 귀무 가설이 모집단 모수에 대해 '특정 값과 같다'($=$)고 명시할 때 사용합니다.
 - 대립 가설은 특정 값과 '다르다'($\neq$)고 주장합니다.
 - **예시:** 초콜릿 봉지 무게 ($H_0: \mu = 300$, $H_A: \mu \neq 300$)

예제

예시: ACT 점수 (등호의 중요성)

- **상황:** 우리 대학 신입생의 평균 ACT 점수가 24점보다 높다고 믿고 있습니다. 이 믿음이 여전히 사실인지 확인하고 싶습니다.
- **현재 믿음:** $\mu > 24$ (평균 ACT 점수가 24점보다 높다).
- **가설 설정:**
 - 대립 가설(H_A)에 등호가 없으므로, $H_A: \mu > 24$ 로 설정합니다.
 - 귀무 가설(H_0)에는 등호가 포함되어야 하므로, $H_0: \mu \leq 24$ 로 설정합니다.
- **결론:** 귀무 가설에는 항상 등호가 포함되어야 합니다. 이는 가설을 설정하는데 필수적인 부분입니다.

가능한 가설 검정 유형

평균을 검정할 때 세 가지 가능한 가설 세트가 있습니다.

유형

가설 설정

양측 검정 (Two-tail)	$H_0: \mu = \mu_0$
	$H_A: \mu \neq \mu_0$

단측 검정 (One-tail)	$H_0: \mu \geq \mu_0$
	$H_A: \mu < \mu_0$

$$H_0: \mu \leq \mu_0$$

$$H_A: \mu > \mu_0$$

모집단 평균에 대한 가설 검정 유형

주의

통계 소프트웨어의 가설 입력: 대부분의 통계 소프트웨어는 대립 가설만 입력하도록 요구합니다 (같지 않다, 작다, 크다). 이는 귀무 가설에 항상 등호가 포함되어야 한다는 규칙과, 귀무 가설과 대립 가설이 모든 가능성을 포괄해야 한다는 원칙에 따라 귀무 가설이 자동으로 추론되기 때문입니다. 때로는 사람들이 게으름 때문에 $H_0: \mu = \mu_0$ 와 $H_A: \mu < \mu_0$ 와 같이 표기하기도 하지만, 기술적으로는 부정확합니다. 그러나 대립 가설을 통해 단측 검정이 수행될 것임을 모두가 알고 있습니다.

예제

연습 문제: 직원 근속 기간

- **상황:** 한 회사의 웹사이트는 직원들이 평균 25년 동안 회사에 머문다고 홍보합니다. 이 주장은 오랫동안 유지되어 왔습니다. 새로운 HR 이사는 이 주장이 여전히 사실인지 확인하고 싶습니다.
- H_0 와 H_A 는 무엇일까요?
- **해답:**
 - H_0 (귀무 가설): $\mu = 25$ (평균 근속 기간은 25년이다)
 - H_A (대립 가설): $\mu \neq 25$ (평균 근속 기간은 25년이 아니다)
- **설명:** 이는 모집단 평균에 대한 가설 검정이며, '다르다'를 검정하므로 양측 검정입니다. HR 이사는 근속 기간이 25년보다 길거나 짧아졌는지 모두 확인하

고 싶어 합니다.

예제

예시 3: 모집단 비율 (소매점 고객 유입)

- **상황:** 한 매장 관리자가 새로운 위치로 소매점을 옮기는 것을 고려하고 있습니다. 새로운 위치에서는 유사한 매장의 고객 유입이 더 많다고 알려져 있습니다. 월세 인상으로 인해 고객 유입이 최소 20% 증가해야 합니다. 매장 관리자는 이 위치로 옮겨야 할까요?
- **문제:** 고객 유입이 최소 20% 증가할 것인가? (모집단 비율에 대한 검정)
- **가설 설정:**
 - p : 고객 유입 증가율
 - H_A (대립 가설): $p < 0.20$ (고객 유입 증가율이 20% 미만이다)
 - H_0 (귀무 가설): $p \geq 0.20$ (고객 유입 증가율이 20% 이상이다)
- **설명:** 관리자는 고객 유입이 20% 미만으로 증가할 경우에만 이사를 반대할 것입니다. 따라서 이는 단측 검정입니다. 대립 가설을 먼저 설정한 다음 귀무 가설을 보완적으로 설정하는 것이 더 쉬울 수 있습니다.

가설 검정의 첫 번째 단계

모든 과학적 연구는 관심 변수에 대한 질문을 던지는 것으로 시작합니다. 가설 검정은 이 질문을 귀무 가설과 대립 가설의 형태로 공식화하는 것으로 시작합니다.

핵심 요약

가설 검정의 1단계:

- **귀무 가설 (H_0):** 사실이라고 믿어지는 주장입니다. 데이터 수집 및 분석은 이 귀무 가설을 기반으로 합니다.
- **대립 가설 (H_A):** 귀무 가설과 반대되는 주장입니다.
- **결정:** 수집된 데이터가 귀무 가설과 모순되면 귀무 가설을 기각합니다. 다음 레슨에서 이 방법을 배울 것입니다.

5.1.3 Lesson 1-2: 결과 분석

Lesson 1-2.1: 결과 분석

가설을 설정한 후에는 데이터를 수집하고 분석을 시작할 수 있습니다. 실험 수행은 이전 과정에서 다룬 '데이터 생성' 및 '표본 연구 수행' 원칙을 따릅니다. 여기서는 데이터가 올바른 절차를 통해 얻어졌다고 가정하고, 데이터 분석을 진행하는 방법에 초점을 맞춥니다.

유의 수준 (α)

데이터 분석을 시작하기 전에 '유의 수준(α)'을 설정해야 합니다. 이는 가설을 검정하는 데 사용될 기준입니다.

- **유의 수준 (α)**: 귀무 가설이 사실임에도 불구하고 우리가 잘못 기각할 확률을 의미합니다. 즉, 제1종 오류를 저지를 최대 허용 확률입니다.
- **신뢰 수준 (Confidence Level)**: $1 - \alpha$ 로 계산됩니다. 예를 들어, $\alpha = 0.05$ 이면 신뢰 수준은 95%입니다.

예제

예시: 초콜릿 봉지 무게 (유의 수준)

- **상황**: 초콜릿 제조 공장에서 300g으로 표시된 봉지를 생산합니다. 품질 관리 팀은 정확성을 확인하기 위해 50개의 봉지를 표본으로 추출합니다.
- **가설**: $H_0: \mu = 300$, $H_A: \mu \neq 300$ (양측 검정)
- **유의 수준 설정**: $\alpha = 0.05$ 로 설정하면, 이는 우리가 귀무 가설(평균 무게가 300g이다)이 사실인데도 불구하고 잘못 기각할 확률을 5%로 허용하겠다는 의미입니다.
- **시각화**: 정규 분포 곡선에서 양쪽 꼬리 부분에 각각 $\alpha/2 = 2.5\%$ 씩의 면적이 할당됩니다. 이 파란색 음영 영역에 표본 평균이 떨어지면 귀무 가설을 기각하게 됩니다.

제1종 오류와 제2종 오류

분석 과정에서 우리는 두 가지 유형의 실수를 저지릴 수 있습니다.

- **제1종 오류 (Type I error)**:
 - 귀무 가설(H_0)이 사실인데도 불구하고 잘못 기각하는 오류입니다.
 - 이 오류를 저지를 확률은 유의 수준 α 와 같습니다.
- **제2종 오류 (Type II error)**:
 - 귀무 가설(H_0)이 거짓인데도 불구하고 잘못 기각하지 않는 (즉, 채택하는) 오류입니다.
 - 이 오류를 저지를 확률은 β 로 표기합니다.

다음 표는 가설 검정에서 발생할 수 있는 의사결정의 결과를 요약합니다.

	현실 - $H_0: \mu = 300$ 이 참	현실 - $H_0: \mu = 300$ 이 거짓
결정 - $H_0: \mu = 300$ 기각	제1종 오류 (α)	✓(올바른 결정)
결정 - $H_0: \mu = 300$ 기각하지 않음	✓(올바른 결정)	제2종 오류 (β)

제1종 오류와 제2종 오류

예제

오류의 맥락별 명칭:

- **제조업 환경 (Manufacturing Setting)**:
 - **제1종 오류 (제조업자 위험)**: 생산 라인이 불필요하게 중단되는 경우. (실제로는 문제가 없는데도 문제가 있다고 판단)

- 제2종 오류 (소비자 위험): 조정이 필요한 생산 라인을 중단하지 않아 불량품이 소비자에게 전달되는 경우. (실제로는 문제가 있는데도 문제가 없다고 판단)
- 의료 환경 (Medical Setting):
 - 제1종 오류 (위양성, False Positive): 건강한 환자를 검사 결과가 '병이 있다'고 잘못 진단하는 경우.
 - 제2종 오류 (위음성, False Negative): 병이 있는 환자를 검사 결과가 '병이 없다'고 잘못 진단하는 경우. (예: 랜스 암스트롱이 약물 검사에서 음성 판정을 받았으나 실제로는 약물을 사용한 경우)

유의 수준 (α) 설정의 중요성

α 값은 분석을 시작하기 전에 설정해야 합니다. 이는 우리가 표본을 통해 얻은 결과가 귀무 가설과 얼마나 다를 때 귀무 가설을 기각할 것인지를 결정하는 기준이 됩니다.

- 일반적인 α 값:
 - 보통 $\alpha = 0.05$ (5%)로 설정됩니다. 이는 귀무 가설을 기각하기 위해 '강력한 증거'가 필요함을 의미합니다.
 - $\alpha = 0.01$ (1%)은 매우 강력한 증거를 요구하며, $\alpha = 0.10$ (10%)은 비교적 약한 증거로도 기각할 수 있음을 의미합니다.
- α 와 β 의 상충 관계 (Trade-off):
 - 표본 크기가 고정된 상태에서 α 를 줄이면 β 는 증가합니다 ($\alpha \downarrow \rightarrow \beta \uparrow$). 즉, 제1종 오류를 줄이려 하면 제2종 오류를 저지를 확률이 높아집니다.
 - 우리는 α 값을 직접 설정하지만, β 값은 여러 매개변수에 따라 계산됩니다.
 - 표본 크기 증가의 이점: 표본 크기(n)를 늘리면 α 와 β 를 동시에 줄일 수 있습니다 ($n \uparrow \rightarrow \alpha \downarrow$ and $\beta \downarrow$). 하지만 표본 크기를 늘리는 데는 비용이 수반됩니다.

평균 검정 단계

가설 검정의 전체 과정은 다음과 같은 4단계로 요약할 수 있습니다.

1. H_0 와 H_A 설정 (State H_0 and H_A): 귀무 가설과 대립 가설을 명확히 정의합니다.
2. 유의 수준 α 지정 (Specify the significance level α): 제1종 오류를 허용할 최대 확률을 결정합니다.
3. 표본 데이터에 대한 p-값 계산 (Calculate the p-value for the sample data): 관측된 표본 데이터가 귀무 가설 하에서 나타날 확률을 계산합니다.
4. H_0 기각 또는 기각하지 않음 (Reject or not reject H_0): p-값과 α 를 비교하여 귀무 가설에 대한 결정을 내립니다.

다음 레슨에서는 3단계인 p-값 계산과 4단계인 결론 도출에 대해 자세히 살펴보겠습니다.

5.1.4 Lesson 1-3: 평균에 대한 양측 검정

Lesson 1-3.1: 평균에 대한 양측 검정

이 레슨에서는 가설 검정의 세 번째 단계인 'p-값 계산'에 초점을 맞춥니다.

p-값 (p-value)

핵심 요약

p-값의 정의:

- p-값은 관측된 검정 통계량을 기반으로 귀무 가설(H_0)을 기각할 경우 발생할 수 있는 제1종 오류의 가장 큰 확률입니다.
- 즉, 귀무 가설이 실제로 참이라고 가정했을 때, 우리가 얻은 표본 데이터 또는 그보다 더 극단적인 데이터가 나올 확률입니다.

p-값이 작다는 것은 귀무 가설이 참일 때 현재의 표본을 얻을 확률이 매우 낮다는 것을 의미합니다. 이는 귀무 가설에 반하는 강력한 증거가 됩니다.

예제

예시 1: 모집단 평균 (초콜릿 봉지 무게 재방문)

- **상황:** 초콜릿 제조 공장에서 300g으로 표시된 봉지를 생산합니다. 품질 관리 팀은 정확성을 확인하기 위해 50개의 봉지를 표본으로 추출합니다. 분석은 5% 유의 수준에서 수행됩니다.
- **가설:** $H_0: \mu = 300$, $H_A: \mu \neq 300$
- **표본 데이터:** $\bar{x} = 294.6$, $s = 11$, $n = 50$

평균 검정 단계 적용

1. H_0 와 H_A 설정: $H_0: \mu = 300$, $H_A: \mu \neq 300$ 2. 유의 수준 α 지정: $\alpha = 0.05$ 3. 표본 데이터에 대한 p-값 계산: $\bar{x} = 294.6$, $s = 11$, $n = 50$ 4. H_0 기각 또는 기각하지 않음: (이 단계는 p-값 계산 후 진행)

통계적 검정의 개념

통계적 검정은 귀무 가설과 대립 가설에 명시된 모수를 추정하는 통계량의 '표본 분포(Sampling Distribution)'에 의존합니다. 이는 '중심 극한 정리(Central Limit Theorem)'에 기반합니다.

- **중심 극한 정리:** 모집단에서 표본을 반복적으로 추출하면, 이 표본들의 평균은 중심(모집단 평균) 주위에 모이고, 그 변동성은 '표준 오차(Standard Error)'에 의해 결정됩니다.
- **표준 오차 계산:** $SE = s/\sqrt{n} = 11/\sqrt{50} \approx 1.55$
- **질문:** 귀무 가설이 참이라고 가정했을 때, 우리가 얻은 표본(평균 294.6)처럼 귀무 가설의 평균(300)과 '이만큼이나' 다른 표본을 얻을 확률은 얼마일까요?

표본 분포와 표본 데이터 분포의 비교 (가상의 이미지) 설명:

- **좁고 높은 곡선 (평균=300, 표준 오차=1.55):** 귀무 가설이 참일 때 표본 평균들의 분포를 나타냅니다. 대부분의 표본 평균은 300g 근처에 모여 있을 것입니다.
- **넓고 낮은 곡선 (평균=294.6, 표준편차=11):** 우리가 실제로 얻은 50개 봉지 표본의 무게 분포를 나타냅니다. 이 표본의 평균은 294.6g입니다.
- **비교:** 두 분포를 함께 보면, 우리가 얻은 표본 평균(294.6)이 귀무 가설의 평균(300)으로부터 상당히 왼쪽에 떨어져 있음을 알 수 있습니다. p-값은 바로 이 '이만큼이나 다른' 표본을 얻을 확률을 의미합니다.

p-값 계산

p-값을 찾기 위해 먼저 't-값(test statistic)'을 계산해야 합니다. t-값은 표본 평균이 귀무 가설의 평균으로부터 몇 표준 오차만큼 떨어져 있는지를 나타냅니다.

- **t-분포 사용:** 평균을 검정할 때는 t-분포를 사용합니다. t-분포는 정규 분포와 유사한 종 모양의 곡선이지만, '자유도(degrees of freedom, $df = n - 1$)'에 따라 퍼진 정도가 달라집니다.
- **t-값 공식:**

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

여기서, $\bar{x}$ 는 표본 평균, μ_0 는 귀무 가설의 모집단 평균, s 는 표본 표준편차, n 은 표본 크기입니다.

- **초콜릿 봉지 예시 t-값 계산:**

$$t = \frac{294.6 - 300}{11/\sqrt{50}} = \frac{-5.4}{1.5556} \approx -3.47$$

우리의 표본은 귀무 가설의 평균으로부터 왼쪽으로 3.47 표준 오차만큼 떨어져 있습니다. 이는 '이상치(outlier)'에 해당하며, 발생 확률이 매우 낮습니다.

t-분포에서 t-값 -3.47의 위치 (가상의 이미지) 설명:

- t-분포에서 t-값 -3.47은 왼쪽 꼬리 부분에 매우 멀리 떨어져 있습니다.
- **p-값 계산 (Excel 함수):** Excel의 T.DIST(x, deg_freedom, cumulative) 함수를 사용하여 t-값보다 작거나 같은 누적 확률을 계산합니다.
 - x: 계산된 t-값 (-3.47)
 - deg_freedom: 자유도 ($n - 1 = 50 - 1 = 49$)
 - cumulative: 1 (누적 확률을 의미)
- **결과:** T.DIST(-3.47, 49, 1) $\approx$ 0.00055
- 이 p-값은 우리가 얻은 표본처럼 왼쪽 꼬리에 위치하거나 더 극단적인 표본을 얻을 확률이 0.00055 (10만분의 55)임을 의미합니다. 이는 매우 낮은 확률입니다.

양측 검정에서 p-값의 시각화 (가상의 이미지) 설명:

- t-분포에서 t-값 -3.47과 +3.47의 양쪽 꼬리 영역에 각각 0.00055의 확률이 표시됩니다.
- 우리의 α 값(0.05)은 표본 간의 자연스러운 변동으로 허용할 수 있는 차이의 한계를 설정합니다. 이 한계는 대략 2 표준 오차 정도입니다.
- 두 가지 가능성:
 1. 귀무 가설이 참인데, 우리가 매우 운이 나쁘게도 이렇게 극단적인 표본을 얻었다.
 2. 표본 데이터가 귀무 가설에 반하는 강력한 증거를 제공하며, 귀무 가설은 기각되어야 한다.
- 가장 그럴듯한 설명: 두 번째 결론이 더 그럴듯합니다. 폭스바겐 사례에서도 연구자들은 처음에는 운이 나쁘다고 생각했지만, 반복된 실험에서도 동일한 결과가 나오자 폭스바겐의 주장이 거짓임을 확신했습니다.

p-값 해석 및 결론 도출

핵심 요약

양측 검정의 결론 규칙:

- 규칙: p-값이 α 보다 작으면 귀무 가설(H_0)을 기각합니다.
- 양측 검정의 p-값: 양측 검정에서는 p-값이 양쪽 꼬리에 걸쳐 분할되므로, 계산된 단측 p-값에 2를 곱해야 합니다.
- 초콜릿 봉지 예시 결론:
 - 단측 p-값 = 0.00055
 - 양측 p-값 = $2 \times 0.00055 = 0.0011$
 - $\alpha = 0.05$ 와 비교: $0.0011 < 0.05$ 이므로, 귀무 가설을 기각합니다.
 - $\alpha = 0.01$ 와 비교: $0.0011 < 0.01$ 이므로, 0.01 유의 수준에서도 귀무 가설을 기각합니다.
- 의미: 생산 라인 관리자는 생산을 중단하고 조정을 해야 합니다. 그렇지 않으면 평균적으로 300g보다 적은 무게의 봉지를 계속 생산하게 될 것입니다.

Lesson 1-3.2: 평균에 대한 양측 검정 (Excel)

Excel을 사용하여 초콜릿 봉지 무게 예시를 직접 계산해 보겠습니다.

예제

예시 1: 모집단 평균 (초콜릿 봉지 무게) - Excel 실습

- 상황: 초콜릿 제조 공장에서 300g으로 표시된 봉지를 생산합니다. 품질 관리 팀은 정확성을 확인하기 위해 50개의 봉지를 표본으로 추출합니다. 분석은 5% 유의 수준에서 수행됩니다.
- 가설: $H_0: \mu = 300$, $H_A: \mu \neq 300$
- 표본 데이터: $\bar{x} = 294.6$, $s = 11$, $n = 50$

Excel 데이터 시트 (가상의 이미지) 설명:

- Excel 워크시트의 'Data' 탭에 50개의 초콜릿 봉지 무게 데이터가 A열에 입력되어 있습니다.
- D열에는 'Mean Weight', 'Standard Deviation', 'Sample Size', 'Significance Level', 'Critical Value of t', 'p-value' 등의 레이블이 있습니다.

1. 데이터 입력 및 기본 통계량 계산:

- A열에 50개의 무게 데이터를 입력합니다.
- 평균 무게 (Mean Weight): E2 셀에 `=AVERAGE(A1:A50)`을 입력합니다. 결과는 약 294.609가 나옵니다.
- 표준편차 (Standard Deviation): E3 셀에 `=STDEV.S(A1:A50)`을 입력합니다. 결과는 약 10.980130이 나옵니다. (문제에서는 반올림하여 11로 사용)
- 표본 크기 (Sample Size): E4 셀에 `=COUNT(A1:A50)`을 입력합니다. 결과는 50이 나옵니다.
- 유의 수준 (Significance Level): E5 셀에 0.05를 입력합니다.
- 가설 평균 (Hypothesized Mean): E6 셀에 300을 입력합니다.

2. t-값 계산:

- t-값 공식: $t = (\bar{x} - \mu_0) / (s / \sqrt{n})$
- E7 셀에 `=(E2-E6)/(E3/SQRT(E4))`를 입력합니다.
- 결과는 약 -3.47174가 나옵니다.

Excel에서 t-값 계산 (가상의 이미지) 설명:

- 계산된 t-값 -3.47은 표본 평균이 가설 평균 300으로부터 왼쪽으로 3.47 표준 오차만큼 떨어져 있음을 의미합니다.

3. p-값 계산:

- E8 셀에 `=T.DIST(E7, E4-1, 1)`을 입력합니다.
- T.DIST 함수는 주어진 t-값보다 작거나 같은 누적 확률을 반환합니다.
- 결과는 약 0.000545가 나옵니다. 이는 왼쪽 꼬리 부분의 확률입니다.

4. 양측 p-값 및 결론:

- 우리는 양측 검정($H_A: \mu \neq 300$)을 수행하고 있으므로, 계산된 단측 p-값에 2를 곱해야 합니다.
- 양측 p-값 = $2 \times 0.000545 = 0.00109$
- 이 양측 p-값을 유의 수준 $\alpha = 0.05$ 와 비교합니다.
- $0.00109 < 0.05$ 이므로, 귀무 가설을 기각합니다.

Excel에서 p-값 계산 및 결론 (가상의 이미지) 설명:

- 양측 p-값 0.00109는 유의 수준 0.05보다 작습니다.
- 결론: 귀무 가설을 기각합니다. 이는 초콜릿 봉지의 평균 무게가 300g이 아니라는 대립 가설을 지지합니다. 즉, 기계가 올바르게 작동하지 않고 있으며 조정이 필요합니다.

5.1.5 Lesson 1-4: 평균에 대한 단측 검정

Lesson 1-4.1: 평균에 대한 단측 검정

이제 단측 검정을 수행하는 방법을 살펴보겠습니다. 학생 부채 예시를 다시 사용합니다.

예제

예시: 학생 부채 (단측 평균 검정)

- **상황:** 2015년 졸업생의 평균 학자금 대출액은 35,000달러입니다. '굿딜 대학교'는 자교 학생들의 부채가 이보다 적을 것이라고 믿습니다. 이 대학은 졸업생 150명을 대상으로 설문 조사를 실시하여 평균 부채가 33,800달러이고 표준편차가 10,000달러임을 확인했습니다.
- **질문:** 5% 유의 수준에서 굿딜 대학교의 주장을 뒷받침할 충분한 증거가 있을까요?

평균 검정 단계 적용

1. H_0 와 H_A 설정:

- 굿딜 대학교는 학생들의 부채가 전국 평균보다 '낮다'고 주장하므로, 이것이 대립 가설이 됩니다.
- $H_0: \mu \geq \$35,000$ (평균 부채가 35,000달러 이상이다)
- $H_A: \mu < \$35,000$ (평균 부채가 35,000달러 미만이다)

2. 유의 수준 α 지정: $\alpha = 0.05$ 3. 표본 데이터에 대한 p-값 계산: $\bar{x} = 33,800$, $s = 10,000$, $n = 150$ 4. H_0 기각 또는 기각하지 않음: (p-값 계산 후 진행)

p-값 계산

- t-값 공식:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

- 학생 부채 예시 t-값 계산:

$$t = \frac{33,800 - 35,000}{10,000/\sqrt{150}} = \frac{-1,200}{816.496} \approx -1.47$$

우리의 표본은 귀무 가설의 평균으로부터 왼쪽으로 1.47 표준 오차만큼 떨어져 있습니다.

- p-값 계산 (Excel 함수): T.DIST(x, deg_freedom, cumulative)
 - x: -1.47
 - deg_freedom: $n - 1 = 150 - 1 = 149$
 - cumulative: 1
- 결과: T.DIST(-1.47, 149, 1) $\approx 0.0718 \approx 0.072$

단측 검정 (왼쪽 꼬리)에서 p-값의 시각화 (가상의 이미지) 설명:

- t-분포에서 t-값 -1.47의 왼쪽 꼬리 영역에 p-값 0.072가 표시됩니다.
- 결론 규칙: p-값이 α 보다 작으면 귀무 가설을 기각합니다.
- 학생 부채 예시 결론:
 - p-값 = 0.072
 - $\alpha = 0.05$ 와 비교: $0.072 > 0.05$ 이므로, 귀무 가설을 기각하지 않습니다.
- 의미: 굿딜 대학교는 자교 졸업생들의 부채가 전국 평균보다 적다는 것을 보여줄 충분한 증거를 제시하지 못했습니다. 즉, 그들의 주장을 통계적으로 뒷받침할 수 없습니다.

p-값 해석 및 결론 도출

예제

연습 문제: ACT 점수 (단측 검정)

- 상황: 우리 대학 신입생의 평균 ACT 점수가 24점보다 높다고 믿고 있습니다. 대학은 200명의 학생을 선정하여 평균 ACT 점수가 24.8점이고 표준편차가 6.1 점임을 확인했습니다.
- 질문: 5% 유의 수준에서 이 주장을 뒷받침할 충분한 증거가 있을까요?

연습 문제 해결

1. H_0 와 H_A 설정:

- 대학은 평균 ACT 점수가 24점보다 '높다'고 주장하므로, 이것이 대립 가설이 됩니다.
- $H_0: \mu \leq 24$ (평균 ACT 점수가 24점 이하이다)
- $H_A: \mu > 24$ (평균 ACT 점수가 24점보다 높다)

2. 유의 수준 α 지정: $\alpha = 0.05$ 3. 표본 데이터: $\bar{x} = 24.8$, $s = 6.1$, $n = 200$

p-값 계산

• t-값 계산:

$$t = \frac{24.8 - 24}{6.1/\sqrt{200}} = \frac{0.8}{0.4313} \approx 1.85$$

• p-값 계산 (Excel 함수): T.DIST(x, deg_freedom, cumulative)

- x: 1.85
- deg_freedom: $n - 1 = 200 - 1 = 199$
- cumulative: 1

• 결과: T.DIST(1.85, 199, 1) ≈ 0.967102

- 주의: 이 값은 t-값 1.85의 '왼쪽' 누적 확률입니다. 우리의 대립 가설은 $\mu > 24$ 이므로, 우리는 '오른쪽 꼬리'의 확률을 원합니다. 따라서 1에서 이 값을 빼야 합니다.

• 오른쪽 꼬리 p-값: $1 - 0.967102 \approx 0.032898 \approx 0.033$

p-값 해석 및 결론 도출

단측 검정 (오른쪽 꼬리)에서 p-값의 시각화 (가상의 이미지) 설명:

- t-분포에서 t-값 1.85의 오른쪽 꼬리 영역에 p-값 0.033이 표시됩니다.
- 결론 규칙: p-값이 α 보다 작으면 귀무 가설을 기각합니다.
- ACT 점수 예시 결론:
 - p-값 = 0.033
 - $\alpha = 0.05$ 와 비교: $0.033 < 0.05$ 이므로, 귀무 가설을 기각합니다.
- 의미: 대립 가설을 지지합니다. 즉, 대학의 주장대로 신입생의 평균 ACT 점수가 24점보다 높다는 것이 통계적으로 올바른 것으로 보입니다.

가설 검정 유형 요약

유형	가설 설정	기각 규칙
양측 검정 (Two-Tail)	$H_0: \mu = \mu_0$ $H_A: \mu \neq \mu_0$	p-값 (양측) $< \alpha$ 이면 H_0 기각 (단측 p-값 $\times 2$) $< \alpha$
단측 검정 (One-Tail)	$H_0: \mu \geq \mu_0$ $H_A: \mu < \mu_0$	p-값 (왼쪽 꼬리) $< \alpha$ 이면 H_0 기각
	$H_0: \mu \leq \mu_0$ $H_A: \mu > \mu_0$	p-값 (오른쪽 꼬리) $< \alpha$ 이면 H_0 기각

가설 검정 유형별 가설 및 기각 규칙

- 양측 검정: 표본 통계량이 평균으로부터 양쪽 방향으로 너무 많이 벗어날 때 귀무 가설을 기각합니다. p-값을 계산한 후 2를 곱하여 α 와 비교합니다.
- 단측 검정: 대립 가설이 주장하는 방향(왼쪽 또는 오른쪽 꼬리)으로만 기각 영역이 존재합니다. 계산된 p-값을 α 와 직접 비교합니다.

Lesson 1-4.2: 평균에 대한 좌측 단측 검정 (Excel)

Excel을 사용하여 설문 조사 완료 시간 예시를 직접 계산해 보겠습니다.

예제

예시: 설문 조사 완료 시간 (좌측 단측 검정)

- 상황: 고객 관계 부서는 고객 설문 조사를 계획하고 있습니다. 설문 조사가 20분 미만으로 완료되기를 원합니다. 65명의 직원에게 설문 조사를 실시하고 완료 시간을 기록했습니다.
- 질문: 0.05 유의 수준에서 설문 조사를 완료하는 평균 시간이 20분 미만이라고 주장할 수 있을까요?

가설 설정

- 목표: 평균 완료 시간이 20분 미만임을 주장하고 싶습니다.

- **HA (대립 가설):** $\mu < 20$ (평균 완료 시간은 20분 미만이다)
- **H0 (귀무 가설):** $\mu \geq 20$ (평균 완료 시간은 20분 이상이다)
- **결론:** 만약 귀무 가설을 기각하지 못하면, 설문 조사가 너무 길어서 고객들이 완료하지 않을 가능성이 있다고 판단할 것입니다.

Excel 설문 조사 데이터 시트 (가상의 이미지) 설명:

- Excel 워크시트의 'Data' 탭에 65명의 직원 설문 조사 완료 시간 데이터가 A열에 입력되어 있습니다.
- C열에는 'Mean', 'Standard deviation', 'Significance level', 'hypothesized mean', 't-value', 'p-value' 등의 레이블이 있습니다.

1. 데이터 입력 및 기본 통계량 계산:

- A열에 65개의 완료 시간 데이터를 입력합니다.
- **평균 (Mean):** D3 셀에 `=AVERAGE(A1:A65)`을 입력합니다. 결과는 약 18.030770이 나옵니다.
- **표준편차 (Standard deviation):** D4 셀에 `=STDEV.S(A1:A65)`을 입력합니다. 결과는 약 3.7163880이 나옵니다.
- **유의 수준 (Significance level):** D5 셀에 0.05를 입력합니다.
- **가설 평균 (hypothesized mean):** D6 셀에 20을 입력합니다.

2. t-값 계산:

- D7 셀에 `=(D3-D6)/(D4/SQRT(COUNT(A1:A65)))`를 입력합니다. (COUNT 함수로 n을 직접 계산)
- 결과는 약 -4.272010이 나옵니다.

Excel에서 설문 조사 t-값 계산 (가상의 이미지) 설명:

- t-값이 -4.27로, 3 표준편차 이상 떨어져 있으므로 p-값이 매우 작을 것으로 예상됩니다.

3. p-값 계산:

- D8 셀에 `=T.DIST(D7, COUNT(A1:A65)-1, 1)`을 입력합니다.
- T.DIST 함수는 주어진 t-값보다 작거나 같은 누적 확률을 반환하며, 이는 좌측 단측 검정의 p-값에 해당합니다.
- 결과는 약 3.27938E-05 (즉, 0.0000327938)가 나옵니다.

4. 결론:

- p-값 (0.0000327938)을 유의 수준 $\alpha = 0.05$ 와 비교합니다.
- $0.0000327938 < 0.05$ 이므로, 귀무 가설을 기각합니다.

Excel에서 설문 조사 p-값 계산 및 결론 (가상의 이미지) 설명:

- p-값이 유의 수준보다 훨씬 작으므로 귀무 가설을 기각합니다.
- **의미:** 설문 조사를 완료하는 평균 시간이 20분 미만이라는 대립 가설이 지지됩니다. 따라서 이 설문 조사는 고객에게 보내기에 적합하다고 판단할 수 있습니다.

체크리스트

이 문서를 통해 학습한 내용을 점검하고, 실제 문제 해결에 적용할 준비가 되었는지 확인하세요.

• 개념 이해:

- 통계학이 비즈니스 의사결정에 왜 중요한지 설명할 수 있는가?
- 귀무 가설과 대립 가설의 차이를 명확히 설명하고 올바르게 설정할 수 있는가?
- 제1종 오류와 제2종 오류의 의미와 실제 사례를 들어 설명할 수 있는가?
- 유의 수준(α)의 역할과 α , β , 표본 크기(n) 간의 관계를 이해하는가?
- p-값의 의미를 설명하고, p-값을 통해 가설을 어떻게 기각하는지 아는가?

• 절차 숙달:

- 가설 검정의 4단계(가설 설정, α 지정, p-값 계산, 결론 도출)를 순서대로 적용할 수 있는가?
- 모집단 평균에 대한 양측 검정 및 단측 검정(좌측/우측) 가설을 올바르게 설정할 수 있는가?
- 주어진 표본 데이터로 t-값을 계산할 수 있는가?
- Excel의 AVERAGE, STDEV.S, COUNT, SQRT, T.DIST 함수를 사용하여 p-값을 계산할 수 있는가?
- 계산된 p-값을 유의 수준과 비교하여 귀무 가설 기각 여부를 결정하고, 그 의미를 해석할 수 있는가?

• 실습 능력:

- 초콜릿 봉지 무게 예시(양측 검정)를 Excel로 직접 해결하고 결과를 해석할 수 있는가?
- 학생 부채 예시(좌측 단측 검정)를 Excel로 직접 해결하고 결과를 해석할 수 있는가?
- ACT 점수 예시(우측 단측 검정)를 Excel로 직접 해결하고 결과를 해석할 수 있는가?
- 설문 조사 완료 시간 예시(좌측 단측 검정)를 Excel로 직접 해결하고 결과를 해석할 수 있는가?

FAQ (자주 묻는 질문)

Q1: 귀무 가설(H_0)에 왜 항상 등호가 포함되어야 하나요? A1: 가설 검정은 기본적으로 '귀무 가설이 참이다'라는 가정 하에 데이터를 분석하고, 이 가정이 얼마나 타당한지 평가하는 과정입니다. 등호(=, $\geq$, $\leq$)가 있어야만 특정 기준점(예: $\mu = 300$)을 설정하고, 이 기준점으로부터 표본 데이터가 얼마나 벗어나는지 통계적으로 측정할 수 있습니다. 등호가 없으면 명확한 기준점을 설정하기 어렵습니다.

Q2: p-값이 정확히 무엇을 의미하나요? A2: p-값은 귀무 가설이 실제로 참이라고 가정했을 때, 우리가 관측한 표본 데이터 또는 그보다 더 극단적인 결과가 나올 확률입니다. 예를 들어, p-값이 0.01이라면, 귀무 가설이 참인데도 불구하고 현재와 같은

극단적인 데이터를 얻을 확률이 1%밖에 안 된다는 뜻입니다. 이 확률이 낮을수록 귀무 가설이 틀렸을 가능성이 높다고 판단합니다.

Q3: 유의 수준(α)은 어떻게 설정해야 하나요? A3: α 는 제1종 오류(귀무 가설이 참인데 기각하는 오류)를 허용할 최대 확률입니다. 일반적으로 비즈니스 분야에서는 0.05(5%)를 많이 사용합니다. 하지만 오류의 심각성에 따라 달라질 수 있습니다. 예를 들어, 신약 개발처럼 제1종 오류가 매우 치명적일 경우 0.01(1%)과 같이 더 엄격한 α 를 설정하기도 합니다.

Q4: 제1종 오류와 제2종 오류 중 어떤 것이 더 중요한가요? A4: 어떤 오류가 더 중요한지는 상황에 따라 다릅니다. 제조업에서는 불량품을 생산하는 것(제2종 오류)보다 멸절된 생산 라인을 멈추는 것(제1종 오류)이 덜 치명적일 수 있습니다. 반면, 의료 진단에서는 실제 병이 있는데 놓치는 것(제2종 오류)이 오진(제1종 오류)보다 더 위험할 수 있습니다. 따라서 상황의 맥락을 고려하여 두 오류의 균형을 맞추는 것이 중요합니다.

Q5: 표본 크기(n)가 커지면 왜 더 좋은가요? A5: 표본 크기가 커지면 표본이 모집단을 더 잘 대표하게 됩니다. 이는 표본 평균의 표준 오차를 줄여주어, 모집단 모수를 더 정확하게 추정할 수 있게 합니다. 결과적으로, 표본 크기가 커지면 제1종 오류(α)와 제2종 오류(β)를 동시에 줄일 수 있어 가설 검정의 '검정력(Power)'이 향상됩니다.

예제

강의명: 추론 및 예측 통계

주차: Lecture 01

교수명: 홍길동

목적: 가설 검정의 기초와 Excel 활용법 학습

빠르게 훑어보기 (1페이지 요약)

모듈 1 핵심 요약: 가설 검정의 기초

1. 통계학의 중요성:

- 데이터 홍수 속 올바른 의사결정 도구.
- 모든 산업 분야에서 필수적인 '핵심 스킬'.
- 데이터 이해, 통찰력 확보, 미래 예측.

2. 가설 설정 (Hypothesis Formulation):

- H_0 (귀무 가설): 현재의 믿음, '차이 없음' 주장. (등호 포함)
- H_A (대립 가설): 우리가 증명하려는 주장, '차이 있음'. (H_0 의 보완)
- 유형:
 - 양측 검정 ($\neq$): $H_0: \mu = \mu_0$, $H_A: \mu \neq \mu_0$
 - 단측 검정 ($<$, $>$): $H_0: \mu \geq \mu_0$, $H_A: \mu < \mu_0$ 또는 $H_0: \mu \leq \mu_0$, $H_A: \mu > \mu_0$

3. 결과 분석 (Analyzing the Result):

- 유의 수준 (α): 제1종 오류(H_0 가 참인데 기각)를 허용할 최대 확률 (보통 0.05).
- 제1종 오류 (α): 제조업자 위험 (불필요한 중단), 위양성 (건강한데 병 있다고 진단).
- 제2종 오류 (β): 소비자 위험 (불량품 통과), 위음성 (병 있는데 없다고 진단).
- $\alpha \downarrow \implies \beta \uparrow$. $n \uparrow \implies \alpha \downarrow, \beta \downarrow$.

4. p-값 계산 및 결론 (p-value & Conclusion):

- p-값: H_0 가 참일 때, 관측된 데이터 또는 더 극단적인 데이터가 나올 확률.
- t-값: 표본 평균이 H_0 의 평균으로부터 몇 표준 오차만큼 떨어져 있는지.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

• Excel 함수:

- T.DIST(t, df, 1): t-값보다 작거나 같은 누적 확률 (왼쪽 꼬리).
- 1 - T.DIST(t, df, 1): t-값보다 크거나 같은 누적 확률 (오른쪽 꼬리).

• 결론 규칙:

- p-값 $< \alpha$ 이면 H_0 기각.
- 양측 검정: (단측 p-값 $\times 2$) $< \alpha$
- 단측 검정: p-값 $< \alpha$

5. Excel 실습:

- AVERAGE, STDEV.S, COUNT, SQRT로 기본 통계량 계산.
- T.DIST로 p-값 계산 후 α 와 비교하여 의사결정.

개요

이 문서는 '추론 및 예측 통계 모듈 1'의 후반부 내용을 다루며, 가설 검정의 핵심 원리와 실제 적용 방법을 상세히 설명합니다. 평균에 대한 단측 검정(우측 꼬리)과 비율에 대한 가설 검정(단측 및 양측)에 중점을 둡니다. 각 검정 유형별로 가설 설정, 유의수준 지정, p-값 계산, 그리고 귀무가설 기각 여부 결정의 4단계 절차를 명확히 제시합니다. 특히 Excel을 활용한 실습 예제를 통해 비전공자도 쉽게 따라 할 수 있도록 구체적인 계산 과정과 해석을 제공합니다.

용어 정리

용어	쉬운 설명	원어	비고
귀무가설	현재의 믿음이나 변화가 없다는 주장.	Null Hypothesis (H_0)	항상 등호(=)를 포함해야 합니다.
대립가설	귀무가설과 반대되는 주장. 우리가 증명하고자 하는 것.	Alternative Hypothesis (H_A)	등호가 없습니다.
유의수준	귀무가설이 사실인데도 기각할 확률의 최대 허용치.	Level of Significance (α)	보통 0.05 (5%) 또는 0.01 (1%) 사용.
p-값	귀무가설이 사실일 때, 현재 관측된 표본 데이터 또는 그보다 더 극단적인 데이터가 나올 확률.	p-value	p-값이 α 보다 작으면 귀무가설 기각.
단측 검정	대립가설이 특정 방향(크다 또는 작다)을 주장하는 검정.	One-Tail Test	우측 꼬리 검정(Right-Tail), 좌측 꼬리 검정(Left-Tail).
양측 검정	대립가설이 특정 값과 다르다(크거나 작다)고 주장하는 검정.	Two-Tail Test	대립가설에 등호가 없는 부등호($\neq$)가 사용됩니다.
표본 평균	표본 데이터의 평균.	Sample Mean ($\bar{x}$)	모집단 평균(μ)을 추정하는 데 사용.
가설 평균	귀무가설에서 주장하는 모집단 평균 값.	Hypothesized Mean (μ_0)	
표본 비율	표본에서 특정 특성을 가진 개체의 비율.	Sample Proportion ($\hat{p}$)	모집단 비율(p)을 추정하는 데 사용.
가설 비율	귀무가설에서 주장하는 모집단 비율 값.	Hypothesized Proportion (p_0)	
t-값	표본 평균이 가설 평균으로부터 표준 오차의 몇 배만큼 떨어져 있는지를 나타내는 값.	t-value	평균 검정 시 사용.
z-값	표본 비율이 가설 비율로부터 표준 오차의 몇 배만큼 떨어져 있는지를 나타내는 값.	z-value	비율 검정 시 사용.
표준 오차	표본 통계량(평균, 비율 등)의 표본 분포 표준 편차.	Standard Error (SE)	표본 통계량의 변동성을 나타냅니다.

핵심 개념 및 원리

가설 검정은 모집단에 대한 주장이 타당한지 여부를 표본 데이터를 통해 통계적으로 평가하는 과정입니다. 이 과정은 크게 네 가지 단계로 진행됩니다.

- 가설 설정 (H_0 와 H_A):** 우리가 검정하고자 하는 주장을 귀무가설(H_0)과 대립가설(H_A)로 명확히 정의합니다. 귀무가설은 항상 등호(=)를 포함하며, 현재의 믿음이나 변화가 없다는 주장을 나타냅니다. 대립가설은 귀무가설과 반대되는 주장으로, 우리가 통계적으로 증명하고자 하는 바를 나타냅니다.
- 유의수준 (α) 지정:** 귀무가설이 실제로 참인데도 불구하고 우리가 이를 기각할 위험(제1종 오류)을 얼마나 감수할 것인지를 결정하는 기준입니다. 일반적으로 0.05 (5%) 또는 0.01 (1%)을 사용합니다.
- p-값 계산:** 수집된 표본 데이터가 귀무가설이 참이라는 가정하에 얼마나 '극단적인' 값인지를 나타내는 확률입니다. p-값이 작을수록 관측된 데이터가 귀무가설 하에서 발생하기 매우 어렵다는 것을 의미합니다.
- 결론 도출 (귀무가설 기각 또는 기각 실패):** 계산된 p-값을 유의수준 α 와 비교하여 귀무가설을 기각할지 말지를 결정합니다.

평균에 대한 우측 꼬리 검정 (Right-Tail Test for Mean)

평균에 대한 우측 꼬리 검정은 모집단 평균이 특정 값보다 '크다'는 주장을 검정할 때 사용됩니다.

- 가설 설정:**
 - $H_0 : \mu \leq \mu_0$ (모집단 평균은 가설 평균 μ_0 보다 작거나 같다)
 - $H_A : \mu > \mu_0$ (모집단 평균은 가설 평균 μ_0 보다 크다)
- 검정 통계량 (t-값):** 표본 평균($\bar{x}$)이 가설 평균(μ_0)으로부터 얼마나 떨어져 있는지를 표준 오차($s/\sqrt{n}$) 단위로 측정합니다.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

여기서 s 는 표본 표준 편차, n 은 표본 크기입니다.

- p-값:** 계산된 t-값보다 크거나 같은 값이 나올 확률을 의미하며, 이는 t-분포의 오른쪽 꼬리 면적에 해당합니다.

- **결정:** p-값이 유의수준 α 보다 작으면 귀무가설을 기각하고, 모집단 평균이 μ_0 보다 크다는 대립가설을 채택합니다.

예제

예시: 도시의 휘발유 가격 어떤 도시의 시장이 휘발유 가격이 높다는 불만을 접수했습니다. 주 전체의 무연 휘발유 평균 가격은 \$2.79였습니다. 시장은 이 도시의 휘발유 가격이 주 평균보다 높은지 알고 싶어 합니다.

- **가설:**
 - $H_0: \mu \leq 2.79$ (도시의 휘발유 가격은 주 평균보다 낮거나 같다)
 - $H_A: \mu > 2.79$ (도시의 휘발유 가격은 주 평균보다 높다)
- **해석:** 대립가설이 '크다(>)'를 포함하므로 우측 꼬리 검정입니다. 만약 표본 평균이 가설 평균보다 훨씬 높게 나와 p-값이 유의수준보다 작다면, 도시의 휘발유 가격이 실제로 높다고 결론 내릴 수 있습니다.

비율에 대한 가설 검정 (Testing the Proportion)

비율에 대한 가설 검정은 모집단에서 특정 특성을 가진 개체의 비율(p)이 특정 값(p_0)과 같은지, 다른지, 크거나 작은지를 검정할 때 사용됩니다.

- **가설 설정:** 평균 검정과 유사하게, 대립가설의 형태에 따라 좌측 꼬리, 우측 꼬리, 양측 검정으로 나뉩니다.
 - **좌측 꼬리:** $H_0: p \geq p_0, H_A: p < p_0$
 - **우측 꼬리:** $H_0: p \leq p_0, H_A: p > p_0$
 - **양측:** $H_0: p = p_0, H_A: p \neq p_0$
- **정규 근사 조건:** 비율은 이산 변수(성공/실패)이지만, 표본 크기가 충분히 크면 정규 분포로 근사하여 검정할 수 있습니다. 일반적으로 다음 두 조건이 충족되어야 합니다.
 - $n \times p_0 \geq 5$
 - $n \times (1 - p_0) \geq 5$
 여기서 n 은 표본 크기, p_0 는 가설 비율입니다.

- **검정 통계량 (z-값):** 표본 비율($\hat{p}$)이 가설 비율(p_0)로부터 얼마나 떨어져 있는지를 표준 오차 단위로 측정합니다.

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

여기서 $\hat{p}$ 는 표본 비율, p_0 는 가설 비율, n 은 표본 크기입니다.

- **p-값:** 계산된 z-값에 따라 정규 분포에서 해당 꼬리(또는 양쪽 꼬리)의 면적을 계산합니다.
- **결정:** p-값이 유의수준 α 보다 작으면 귀무가설을 기각합니다.

예제

예시: NFL 선수 뇌 손상 비율 미국 신경학회 연구에 따르면 은퇴한 NFL 선수 중 40% 이상이 외상성 뇌 손상 징후를 보인다고 주장합니다. 이 주장을 검정하려면 다음과 같이 가설을 설정합니다.

- 가설:

- $H_0 : p \leq 0.40$ (뇌 손상 비율은 40% 이하이다)
- $H_A : p > 0.40$ (뇌 손상 비율은 40% 초과이다)

- 해석: 연구의 주장이 '40% 이상'이므로 대립가설은 '크다(>)'가 됩니다. 이는 우측 꼬리 검정입니다.

주의

통계적 유의성 vs. 실질적 중요성 통계적으로 유의미한 결과(p-값이 작아 귀무가설 기각)가 항상 실질적으로 중요하거나 의미 있는 발견을 의미하는 것은 아닙니다. 특히 표본 크기가 매우 클 경우, 아주 작은 차이도 통계적으로 유의미하게 나타날 수 있습니다. 따라서 통계적 유의성 외에 효과 크기(effect size)와 실제적인 의미를 함께 고려해야 합니다.

귀무가설 기각 실패의 의미 귀무가설을 기각하지 못했다고 해서 귀무가설이 '참'이라는 의미는 아닙니다. 단지 현재의 데이터로는 귀무가설을 기각할 충분한 증거가 없다는 뜻입니다. 이는 제2종 오류(귀무가설이 거짓인데 기각하지 못하는 오류)의 가능성을 내포합니다.

절차/방법: Excel을 활용한 가설 검정

Excel을 사용하여 평균 또는 비율에 대한 가설 검정을 수행하는 단계는 다음과 같습니다.

1. 평균에 대한 우측 꼬리 검정 (Right-Tail Test for Mean in Excel)

1. **가설 설정:** 문제의 주장을 바탕으로 귀무가설(H_0)과 대립가설(H_A)을 설정합니다. 우측 꼬리 검정의 경우 $H_A : \mu > \mu_0$ 형태입니다.
2. **유의수준 (α) 지정:** 문제에서 주어진 유의수준을 확인합니다 (예: 0.05).
3. **데이터 요약:** Excel에서 제공된 데이터를 사용하여 다음 값을 계산합니다.
 - 표본 평균 ($\bar{x}$): =AVERAGE(데이터 범위)
 - 표본 표준 편차 (s): =STDEV.S(데이터 범위)
 - 표본 크기 (n): =COUNT(데이터 범위)
 - 가설 평균 (μ_0): 문제에서 주어진 값
4. **t-값 계산:** 다음 공식을 사용하여 t-값을 계산합니다.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Excel에서는 각 값이 입력된 셀을 참조하여 계산합니다. 예를 들어, $\bar{x}$ 가 E3, μ_0 가 E8, s 가 E4, n 이 E5 셀에 있다면, =(E3-E8)/(E4/SQRT(E5))와 같이 입력합니다.

5. **p-값 계산:** 우측 꼬리 검정의 p-값은 t-분포에서 계산된 t-값보다 큰 영역의 확률입니다. Excel의 T.DIST 함수는 왼쪽 꼬리 누적 확률을 반환하므로, 1에서 이 값을 빼야 합니다.
 - 자유도 (df): $n - 1$

- Excel 수식: $1 - T.DIST(t\text{-값}, \text{자유도}, 1)$
- 예시: $1 - T.DIST(E11, E5-1, 1)$ (E11에 $t\text{-값}$ 이, E5에 n 이 있다고 가정)

6. 결론 도출:

- $p\text{-값} < \alpha$: 귀무가설을 기각합니다. 대립가설이 지지됩니다.
- $p\text{-값} \geq \alpha$: 귀무가설을 기각하지 못합니다. 대립가설을 지지할 충분한 증거가 없습니다.

2. 비율에 대한 좌측 꼬리 검정 (Left-Tail Test for Proportion in Excel)

1. 가설 설정: $H_0: p \geq p_0, H_A: p < p_0$
2. 유의수준 (α) 지정: 문제에서 주어진 유의수준을 확인합니다 (예: 0.05).
3. 데이터 요약:
 - 표본 비율 ($\hat{p}$): 성공 횟수 / 표본 크기
 - 가설 비율 (p_0): 문제에서 주어진 값
 - 표본 크기 (n): 문제에서 주어진 값
4. 정규 근사 조건 확인: $n \times p_0 \geq 5$ 이고 $n \times (1 - p_0) \geq 5$ 인지 확인합니다. 이 조건이 충족되어야 $z\text{-검정}$ 을 사용할 수 있습니다.
5. $z\text{-값}$ 계산: 다음 공식을 사용하여 $z\text{-값}$ 을 계산합니다.

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Excel에서는 각 값이 입력된 셀을 참조하여 계산합니다. 예를 들어, $\hat{p}$ 가 G3, p_0 가 G4, n 이 G5 셀에 있다면, $=(G3-G4)/SQRT(G4*(1-G4)/G5)$ 와 같이 입력합니다.

6. $p\text{-값}$ 계산: 좌측 꼬리 검정의 $p\text{-값}$ 은 $z\text{-분포}$ 에서 계산된 $z\text{-값}$ 보다 작거나 같은 영역의 확률입니다. Excel의 NORM.S.DIST 함수는 기본적으로 왼쪽 꼬리 누적 확률을 반환합니다.
 - Excel 수식: $NORM.S.DIST(z\text{-값}, 1)$
 - 예시: $NORM.S.DIST(G7, 1)$ (G7에 $z\text{-값}$ 이 있다고 가정)
7. 결론 도출: $p\text{-값} < \alpha$ 이면 귀무가설을 기각하고, 대립가설이 지지됩니다.

3. 비율에 대한 우측 꼬리 검정 (Right-Tail Test for Proportion in Excel)

1. 가설 설정: $H_0: p \leq p_0, H_A: p > p_0$
2. 유의수준 (α) 지정: 문제에서 주어진 유의수준을 확인합니다 (예: 0.05).
3. 데이터 요약: 좌측 꼬리 검정과 동일하게 $\hat{p}$, p_0 , n 을 준비합니다.
4. 정규 근사 조건 확인: $n \times p_0 \geq 5$ 이고 $n \times (1 - p_0) \geq 5$ 인지 확인합니다.
5. $z\text{-값}$ 계산: 좌측 꼬리 검정과 동일한 공식과 Excel 수식을 사용합니다.
6. $p\text{-값}$ 계산: 우측 꼬리 검정의 $p\text{-값}$ 은 $z\text{-분포}$ 에서 계산된 $z\text{-값}$ 보다 크거나 같은 영역의 확률입니다. Excel의 NORM.S.DIST 함수는 왼쪽 꼬리 누적 확률을 반환하므로, 1에서 이 값을 빼야 합니다.
 - Excel 수식: $1 - NORM.S.DIST(z\text{-값}, 1)$

- 예시: $1 - \text{NORM.S.DIST}(I7, 1)$ (I7에 z-값이 있다고 가정)

7. **결론 도출:** $p\text{-값} < \alpha$ 이면 귀무가설을 기각하고, 대립가설이 지지됩니다.

4. 비율에 대한 양측 꼬리 검정 (Two-Tail Test for Proportion in Excel)

1. **가설 설정:** $H_0: p = p_0$, $H_A: p \neq p_0$
2. **유의수준 (α) 지정:** 문제에서 주어진 유의수준을 확인합니다 (예: 0.05). 양측 검정에서는 이 α 가 양쪽 꼬리에 절반씩($\alpha/2$) 분배됩니다.
3. **데이터 요약:** 좌측/우측 꼬리 검정과 동일하게 $\hat{p}$, p_0 , n 을 준비합니다.
4. **정규 근사 조건 확인:** $n \times p_0 \geq 5$ 이고 $n \times (1 - p_0) \geq 5$ 인지 확인합니다.
5. **z-값 계산:** 좌측/우측 꼬리 검정과 동일한 공식과 Excel 수식을 사용합니다. z-값은 양수 또는 음수가 될 수 있습니다.
6. **p-값 계산:** 양측 검정의 p-값은 계산된 z-값의 절댓값보다 더 극단적인 값이 양쪽 꼬리에서 나올 확률입니다.
 - 먼저, 계산된 z-값에 해당하는 한쪽 꼬리 p-값을 구합니다.
 - z-값이 양수일 경우 (오른쪽 꼬리): $1 - \text{NORM.S.DIST}(z\text{-값}, 1)$
 - z-값이 음수일 경우 (왼쪽 꼬리): $\text{NORM.S.DIST}(z\text{-값}, 1)$
 - 이 한쪽 꼬리 p-값에 2를 곱하여 양측 p-값을 구합니다.
 - 예시: $(1 - \text{NORM.S.DIST}(\text{ABS}(I7), 1)) * 2$ (I7에 z-값이 있다고 가정, ABS는 절댓값 함수)
7. **결론 도출:** 양측 p-값 $< \alpha$ 이면 귀무가설을 기각하고, 대립가설이 지지됩니다.

주의

Excel 함수 사용 시 주의사항

- $\text{T.DIST}(x, \text{deg_freedom}, \text{cumulative})$: x보다 작거나 같은 값의 누적 확률(왼쪽 꼬리)을 반환합니다. 우측 꼬리 p-값을 구하려면 $1 - \text{T.DIST}(\dots)$ 를 사용해야 합니다.
- $\text{NORM.S.DIST}(z, \text{cumulative})$: z보다 작거나 같은 값의 누적 확률(왼쪽 꼬리)을 반환합니다. 우측 꼬리 p-값을 구하려면 $1 - \text{NORM.S.DIST}(\dots)$ 를 사용해야 합니다.
- 양측 검정 시에는 한쪽 꼬리 p-값에 2를 곱하는 것을 잊지 마세요.

실습/코드/오류와 해결

여기서는 실제 시나리오를 바탕으로 Excel에서 가설 검정을 수행하는 과정을 단계별로 살펴봅니다.

1. 평균에 대한 우측 꼬리 검정: 도시 휘발유 가격

시나리오: 대도시 시장이 높은 휘발유 가격에 대한 불만을 접수했습니다. 주 평균 무연 휘발유 가격은 \$2.79였습니다. 5% 유의수준에서 이 도시의 휘발유 가격이 더 높은 증거가 있는지 확인합니다.

가설: $H_0: \mu \leq 2.79$ $H_A: \mu > 2.79$ (우측 꼬리 검정) $\alpha = 0.05$

Excel 계산 과정: 데이터가 'Average Price of Gas'라는 열에 133개의 항목으로 있다고 가정합니다.

Excel Worksheet (가상)

레이블 (Column D)	값/수식 (Column E)
Mean	=AVERAGE(A:A) → 2.9415
Std Dev	=STDEV.S(A:A) → 0.39187
Count	=COUNT(A:A) → 133
Level of Significance	0.05
Hypothesized Mean	2.79
t-value	=(E3-E8)/(E4/SQRT(E5)) → 4.4587
p-value	=1-T.DIST(E11, E5-1, 1) → 8.72591E-06

결과 해석:

- 표본 평균($\bar{x}$)은 \$2.9415로, 가설 평균(μ_0) \$2.79보다 높습니다.
- t-값은 4.4587로, 표본 평균이 가설 평균으로부터 표준 오차의 4.4587배만큼 떨어져 있음을 나타냅니다. 이는 매우 큰 값으로, 이미 꼬리 영역에 깊숙이 들어와 있음을 시사합니다.
- p-값은 8.72591E-06 (약 0.0000087)입니다.
- p-값 (0.0000087) < α (0.05) 이므로 귀무가설을 기각합니다.

결론: 5% 유의수준에서 이 도시의 휘발유 가격이 주 평균보다 높다는 통계적 증거가 있습니다. 시장은 이 문제의 원인을 조사해야 합니다.

2. 비율에 대한 좌측 꼬리 검정: 스마트폰 불량률

시나리오: 스마트폰 제조업체는 기기의 10% 미만이 1년 이내에 고장 난다고 주장합니다. 소비자 단체는 500대의 스마트폰을 테스트하여 38대가 12개월 이내에 고장 났음을 발견했습니다. 5% 유의수준에서 이 데이터가 제조업체의 주장을 지지하는지 확인합니다.

가설: $H_0: p \geq 0.10$ $H_A: p < 0.10$ (좌측 꼬리 검정) $\alpha = 0.05$

Excel 계산 과정:

Excel Worksheet (가상)

레이블 (Column F)	값/수식 (Column G)
sample Prop	=38/500 → 0.076
hypothesize p	0.1
n	500
level of sig	0.05
z	=(G3-G4)/SQRT(G4*(1-G4)/G5) → -1.7889
p-value	=NORM.S.DIST(G7, 1) → 0.03682

결과 해석:

- 표본 비율($\hat{p}$)은 0.076 (7.6%)으로, 가설 비율(p_0) 0.10 (10%)보다 낮습니다.
- z-값은 -1.7889입니다.
- p-값은 0.03682입니다.
- p-값 (0.03682) < α (0.05) 이므로 귀무가설을 기각합니다.

결론: 5% 유의수준에서 제조업체의 주장(10% 미만 고장)을 지지할 충분한 증거가 있습니다.

3. 비율에 대한 우측 꼬리 검정: 경찰 야간 범죄 비율

시나리오: 경찰서장은 야간 근무 인력이 더 필요하다고 생각합니다. 현재 인력 수준은 범죄의 68%가 야간에 발생한다는 믿음에 기반합니다. 서장은 이것이 야간 범죄 비율을 과소평가한 것이라고 생각합니다. 과거 데이터에 따르면 2000건의 범죄 중 1430건이 야간에 발생했습니다. 5% 유의수준에서 이를 검정합니다.

가설: $H_0: p \leq 0.68$ $H_A: p > 0.68$ (우측 꼬리 검정) $\alpha = 0.05$

Excel 계산 과정:

Excel Worksheet (가상)

레이블 (Column H)	값/수식 (Column I)
sample Prop	=1430/2000 → 0.715
hypothesize p	0.68
n	2000
level of sig	0.05
z	=(I3-I4)/SQRT(I4*(1-I4)/I5) → 3.35547
p-value	=1-NORM.S.DIST(I7, 1) → 0.0004

결과 해석:

- 표본 비율($\hat{p}$)은 0.715 (71.5%)로, 가설 비율(p_0) 0.68 (68%)보다 높습니다.
- z-값은 3.35547입니다.

- p-값은 0.0004입니다.
- p-값 (0.0004) < α (0.05) 이므로 귀무가설을 기각합니다.

결론: 5% 유의수준에서 경찰서장의 주장(야간 범죄 비율이 68%보다 높다)이 옳다는 증거가 있습니다. 추가 인력 배치가 필요할 수 있습니다.

4. 비율에 대한 양측 꼬리 검정: 앱 쿠폰 성공률

시나리오: 다이렉트 메일 마케팅 회사가 쿠폰 배포에 앱을 사용하기 시작했습니다. 앱을 사용하는 무작위 고객 1000명 중 94명이 제품을 구매했습니다. 이 성공률이 기존의 7% 성공률과 다른지 궁금합니다. 5% 유의수준에서 이를 검정합니다.

가설: $H_0: p = 0.07$ $H_A: p \neq 0.07$ (양측 꼬리 검정) $\alpha = 0.05$

Excel 계산 과정:

Excel Worksheet (가상)

레이블 (Column H)	값/수식 (Column I)
sample Prop	=94/1000 → 0.094
hypothesize p	0.07
n	1000
level of sig	0.05
z	=(I2-I3)/SQRT(I3*(1-I3)/I4) → 2.97455
p-value (One-Tail)	=1-NORM.S.DIST(I7, 1) → 0.00147
p-value (Two-Tail)	=I8*2 → 0.00293

결과 해석:

- 표본 비율($\hat{p}$)은 0.094 (9.4%)로, 가설 비율(p_0) 0.07 (7%)보다 높습니다.
- z-값은 2.97455입니다.
- 한쪽 꼬리 p-값은 0.00147입니다.
- 양측 p-값은 $0.00147 \times 2 = 0.00293$ 입니다.
- 양측 p-값 (0.00293) < α (0.05) 이므로 귀무가설을 기각합니다.

결론: 5% 유의수준에서 앱을 통한 쿠폰 배포의 성공률이 기존의 7% 성공률과 다르다는 증거가 있습니다. 이는 앱 마케팅 방식이 기존 방식과 다른 효과를 낸다는 것을 의미합니다.

체크리스트

가설 검정 학습 및 실습 시 다음 체크리스트를 활용하여 누락 없이 진행되었는지 확인하세요.

- 가설 설정:
 - 귀무가설(H_0)과 대립가설(H_A)을 명확하게 설정했는가?

- H_0 에 등호(=)가 포함되었는가?
- 대립가설의 방향(크다, 작다, 다르다)에 따라 올바른 검정 유형(좌측, 우측, 양측)을 선택했는가?
- **유의수준 (α) 지정:**
 - 문제에서 요구하는 유의수준을 정확히 확인했는가?
- **데이터 준비 및 요약:**
 - 필요한 모든 데이터(표본 평균/비율, 표준 편차, 표본 크기, 가설 평균/비율)를 정확히 추출하거나 계산했는가?
 - 비율 검정의 경우, 정규 근사 조건($n \times p_0 \geq 5$ 및 $n \times (1 - p_0) \geq 5$)을 확인했는가?
- **검정 통계량 계산:**
 - 평균 검정 시 t-값, 비율 검정 시 z-값을 올바른 공식으로 계산했는가?
 - Excel 함수 사용 시 셀 참조가 정확한가?
- **p-값 계산:**
 - 검정 유형(좌측, 우측, 양측)에 따라 올바른 Excel 함수(T.DIST, NORM.S.DIST)와 계산 방식(1-누적확률, 2배)을 적용했는가?
 - p-값이 0과 1 사이의 올바른 확률 값으로 나왔는가?
- **결론 도출:**
 - p-값과 α 를 정확히 비교했는가?
 - p-값 < α 일 때 귀무가설을 기각하고, p-값 $\geq \alpha$ 일 때 귀무가설을 기각하지 못한다고 올바르게 결론 내렸는가?
 - 통계적 결론을 문제의 맥락에 맞게 해석하여 실질적인 의미를 부여했는가?
- **오류 가능성 고려:**
 - 통계적 유의성이 항상 실질적 중요성을 의미하지 않음을 이해하고 있는가?
 - 귀무가설 기각 실패가 귀무가설이 참임을 의미하지 않음을 이해하고 있는가?

FAQ

초심자들이 가설 검정 과정에서 자주 혼동하거나 궁금해하는 질문들을 Q&A 형식으로 정리했습니다.

- **Q: 귀무가설(H_0)에는 왜 항상 등호(=)가 들어가야 하나요? A:** 가설 검정은 귀무가설이 '참'이라는 가정하에 표본 데이터의 발생 확률(p-값)을 계산합니다. 등호가 있어야 특정 값(μ_0 또는 p_0)을 기준으로 분포를 설정하고 검정 통계량을 계산할 수 있기 때문입니다. 만약 등호가 없다면, '크거나 같다' 또는 '작거나 같다'와 같은 범위가 되어 기준점을 명확히 설정하기 어렵습니다.
- **Q: p-값이 작으면 왜 귀무가설을 기각하나요? A:** p-값은 귀무가설이 참일 때 현재 관측된 표본 데이터 또는 그보다 더 극단적인 데이터가 나올 확률입니다. 만약 이 p-값이 매우 작다면, 귀무가설이 참인데도 불구하고 우리가 이런 데이터를 얻을 확률이 매우 낮다는 뜻입니다. 이는 귀무가설이 사실이 아닐 가능성이 높다는 강력한 증거가 되므로, 귀무가설을 기각하고 대립가설을 채택하게 됩니다.
- **Q: 단측 검정과 양측 검정은 언제 사용하나요? A:** 대립가설이 특정 방향(예: '더

크다' 또는 '더 작다')을 주장할 때는 단측 검정을 사용합니다. 예를 들어, '새로운 약이 기존 약보다 효과가 좋다'는 주장은 단측 검정입니다. 반면, 대립가설이 단순히 '다르다'(크거나 작을 수 있음)고 주장할 때는 양측 검정을 사용합니다. 예를 들어, '새로운 앱의 성공률이 기존과 다르다'는 주장은 양측 검정입니다.

- Q: Excel에서 T.DIST나 NORM.S.DIST 함수를 사용할 때 '1'을 넣는 것과 '1-'을 하는 것의 차이는 무엇인가요? A: 이 함수들은 기본적으로 '누적 확률'을 계산하며, 이는 분포의 왼쪽 꼬리부터 특정 값까지의 면적을 의미합니다.
 - 좌측 꼬리 검정: z-값 또는 t-값보다 작은 영역의 확률이 필요하므로, 함수가 반환하는 값을 그대로 사용합니다 (예: NORM.S.DIST(z, 1)).
 - 우측 꼬리 검정: z-값 또는 t-값보다 큰 영역의 확률이 필요합니다. 전체 확률(1)에서 왼쪽 꼬리 누적 확률을 빼야 합니다 (예: 1 - NORM.S.DIST(z, 1)).
- Q: 비율 검정에서 $n \times p_0 \geq 5$ 및 $n \times (1 - p_0) \geq 5$ 조건은 왜 중요한가요? A: 비율은 본질적으로 이항 분포를 따르는 이산 변수입니다. 하지만 표본 크기(n)가 충분히 크면 이항 분포를 정규 분포로 근사하여 z-검정을 사용할 수 있습니다. 이 두 조건은 이러한 정규 근사가 타당한지 여부를 판단하는 기준입니다. 이 조건이 충족되지 않으면 z-검정 결과의 신뢰도가 떨어질 수 있습니다.

Chapter 6

용어 정리

강의명: BADM-572 데이터 기반 의사결정

주차: Module 2

교수명: Fataneh Taghaboni-Dutta

목적: 두 그룹 간 평균 차이의 통계적 유의미성 판단, 가설 검정 및 신뢰 구간 계산 방법을 학습하고, 비즈니스 맥락에서 두 가지 전략, 제품 또는 그룹의 효과를 비교하는 양측 및 단측 검정 방법을 습득합니다.

모듈 2: 추론 및 예측 통계 개요

이 문서는 BADM-572 '데이터 기반 의사결정' 과목의 '추론 및 예측 통계 모듈 2'의 첫 번째 파트를 다룹니다. 주요 목표는 두 그룹 간의 평균 차이가 통계적으로 유의미한지 판단하는 가설 검정 절차와 신뢰 구간 계산 방법을 학습하는 것입니다. 특히, 비즈니스 맥락에서 두 가지 전략, 제품 또는 그룹의 효과를 비교하는 데 필요한 양측 및 단측 검정 방법을 다룹니다. Excel을 활용한 실습을 통해 이론적 지식을 실제 데이터 분석에 적용하는 능력을 기르는 데 중점을 둡니다.

6.1 용어 정리

용어 (Term)	쉬운 설명	원어 (Original)	비고
가설 검정	표본 데이터를 사용하여 모집단에 대한 주장이 사실인지 통계적으로 확인하는 과정	Hypothesis Testing	
귀무 가설	통계적 검정의 기본 가정으로, 보통 '차이가 없다'는 주장	Null Hypothesis (H_0)	기각 대상
대립 가설	귀무 가설과 반대되는 주장으로, '차이가 있다'는 주장	Alternative Hypothesis (H_A)	채택 대상
유의 수준 (α)	귀무 가설이 사실인데도 이를 기각할 확률의 최대 허용치	Significance Level (α)	보통 0.05 (5%) 또는 0.01 (1%)
p-값 (p-value)	귀무 가설이 사실일 때, 현재 관측된 표본 데이터 또는 그보다 극단적인 결과가 나타날 확률	p-value	p-value < α 이면 귀무 가설 기각
검정 통계량 (t-값)	표본 데이터가 귀무 가설과 얼마나 다른지를 나타내는 표준화된 값	Test Statistic (t-value)	
신뢰 구간	모집단 모수가 특정 범위 내에 있을 것이라고 추정되는 구간	Confidence Interval	
단측 검정	한 방향으로의 차이(크거나 작다)를 검정하는 가설 검정	One-Tail Test	
양측 검정	양방향으로의 차이(다르다)를 검정하는 가설 검정	Two-Tail Test	
표준 오차	표본 통계량(예: 표본 평균)이 모집단 모수와 얼마나 차이 나는지 나타내는 척도	Standard Error	
자유도 (df)	통계량을 계산할 때 자유롭게 변할 수 있는 독립적인 값의 수	Degrees of Freedom (df)	

6.2 1. 서문 (Preface)

Gies eBook을 선택해 주셔서 감사합니다.

이 Gies eBook은 Coursera에서 Fataneh Taghaboni-Dutta 교수님의 '비즈니스를 위한 추론 및 예측 통계' 모듈 2의 확장된 비디오 강의 스크립트를 기반으로 합니다. Gies eBook은 MOOC 비디오의 모든 정보를 완전히 접근 가능한 형식으로 제공하는 독서 경험을 제공합니다. 이 Gies eBook은 ePub 3.0 형식을 지원하는 모든 표준 기반 전자책 리더 소프트웨어와 함께 사용할 수 있습니다.

각 Gies eBook은 레슨별로 나뉘어 있으며, 전자책 리더의 목차 기능을 사용하여 탐색할 수 있습니다. 각 레슨 내에서는 항상 다음 콘텐츠 순서가 나타납니다:

- 레슨 제목 (Lesson title)
- 각 레슨의 웹 기반 비디오 링크 (온라인 상태여야 시청 가능)

레슨 내에서 슬라이드가 변경되거나 다음 정보 비디오 장면으로 전환될 때마다 다음이 제공됩니다:

- 현재 슬라이드 또는 비디오 장면의 썸네일 이미지 (Thumbnail image)
- 비디오 슬라이드에 있는 모든 텍스트는 썸네일 아래에 검색 가능하고 스크린 리더가 읽을 수 있는 형식으로 재현됩니다.
- 슬라이드에 제시된 그래프 및 차트와 같은 중요한 시각 자료에 대한 확장된 텍스트 설명 (Extended text description)
- 비디오의 모든 표 형식 데이터는 스크린 리더 탐색 및 읽기를 위해 재현되고 적절하게 레이블링됩니다.
- 모든 수학 방정식은 화면에 표시될 경우 내용과 표현을 모두 제공하는 MathML로 제시됩니다.
- 말하는 사람별로 레이블링된 비디오의 모든 원본 음성을 캡처한 스크립트 (Transcript)

모든 Gies eBook은 접근성과 사용성을 최우선으로 설계되었습니다. 이 디자인은 독자들이 선택하는 디지털 독서 도구에 관계없이 유연한 방식으로 모든 독자에게 서비스를 제공하기 위함입니다.

이 Gies eBook에 대한 질문이나 개선 제안이 있으시면 Giesbooks@illinois.edu로 문의하십시오.

저작권 정보

Copyright ©2019 by Fataneh Taghaboni-Dutta

All rights reserved.

Published by the Gies College of Business at the University of Illinois at Urbana-Champaign, and the Board of Trustees of the University of Illinois

6.3 2. 모듈 2: 비즈니스를 위한 추론 및 예측 통계

이 모듈에서는 비즈니스 의사결정을 위한 추론 및 예측 통계의 핵심 개념을 탐구합니다. 특히, 두 그룹 간의 평균 또는 비율 차이를 통계적으로 검정하는 방법에 초점

을 맞춥니다.

6.3.1 2.1. 레슨 2-1: 평균 차이 없음 검정 (Testing for No Difference in Means)

이 레슨에서는 두 모집단의 평균이 서로 다른지 여부를 판단하는 가설 검정 방법을 배웁니다. 이는 비즈니스에서 두 가지 전략, 제품 또는 그룹의 효과를 비교할 때 매우 유용합니다.

2.1.1. 레슨 2-1.1: 평균 차이 없음 검정

핵심 요약: 두 평균의 차이 검정

두 그룹 간의 평균 차이가 통계적으로 유의미한지 판단하는 가설 검정 절차를 학습합니다. 이는 단순히 표본 평균이 다르다고 해서 모집단 평균이 다르다고 단정할 수 없기 때문에 중요합니다.

생각해 볼 질문: 실제 비즈니스에서의 차이

- 운동을 조금이라도 하면 전혀 운동하지 않는 것보다 더 오래 살 수 있을까요? (건강 분야)
- 고객에게 현금 환급 보상을 제공하는 것이 무료 여행 포인트를 제공하는 것보다 신용카드 사용을 더 늘릴까요? (마케팅/금융 분야)

지난 모듈에서는 단일 평균 또는 비율을 고정된 값과 비교하는 방법을 살펴보았습니다. 이 모듈에서는 이를 확장하여 두 평균 또는 두 비율을 서로 비교합니다. 대부분의 상황에서 우리는 어떤 일을 다르게 하는 것이 아무것도 하지 않는 것과 비교하여 결과에 변화를 가져올지 궁금해합니다.

분명히 우리 중 일부, 아니 대부분은 건강상의 이점 때문에 운동을 합니다. 하지만 어떻게 그런 믿음을 갖게 되었을까요? 과학자들이 운동하는 사람들과 운동하지 않는 사람들의 건강과 수명을 비교했기 때문입니다. 또는 회사들이 한 가지 프로모션 전략을 다른 전략보다 사용하기로 결정하는 이유는 무엇일까요? 각 전략 하의 결과를 비교하여 한 전략이 다른 전략보다 우수하다고 생각할 만한 근거를 찾았기 때문입니다. 이것이 우리가 이 모듈에서 배울 내용입니다. 기본적으로 우리는 그룹 간의 비교를 올바르게 수행하는 방법과 그룹 간에 유의미한 차이가 있는지 여부를 결정하는 방법을 배울 것입니다.

[이미지: UIUC의 모로우 플롯 (옥수수 밭 사진)]

Figure 6.1: UIUC의 모로우 플롯 (Morrow Plots at UIUC)

모로우 플롯: 1세기의 학습과 통계의 뿌리

이곳 일리노이 대학교에서 우리가 배우려는 내용이 깊은 뿌리를 가지고 있다는 것을 자랑스럽게 말씀드립니다. 제 사무실 창문에서 모로우 플롯을 볼 수 있는데, 여름철에는 자라는 옥수수 밭이 이 그림에서 보시는 것처럼 아름답습니다. 1876년, 조지 모로우 (George Morrow)와 또 다른 연구원 맨리 마일스 (Manley Miles)는 이 플롯을 사용하여 실험을 수행했습니다. 그들은 옥수수 수확량을 늘리는 방법을 알고 싶어했습니다. 그들은 일부 지역에는 비료를 주고 다른 지역에

는 주지 않은 다음, 둘을 비교하여 더 나은 수확을 위해 어떤 종류의 비료를 얼마나 사용해야 하는지 알아냈습니다. 그들은 다른 작물에 대해서도 실험을 반복했습니다. 그들은 더 많은 실험을 하고 모든 결과를 통계를 사용하여 분석했으며, 그들의 연구를 통해 농업을 크게 개선한 많은 중요한 발견이 나왔습니다. 그들이 한 모든 것은 식물 과학과 통계라는 두 가지 과학을 기반으로 했습니다. 1800년대에는 통계가 주로 농업 분야에서 사용되었으며, 그들이 1세기 이상 전에 사용했던 통계 분석은 오늘날 다른 분야에도 동일하게 적용됩니다. 그럼, 두 그룹 간의 비교를 어떻게 수행하는지 살펴보겠습니다.

평가 방법: '실제 차이'의 중요성

우리는 표본 평균의 관측된 차이가 **실제 차이** (real difference)를 나타낸다는 것을 입증해야 합니다.

왜 중요할까요?

여러분은 이제 한 모집단에서 표본을 추출하고 동일한 모집단에서 다른 표본을 추출하면 두 표본의 평균이 다를 가능성이 높다는 것을 알고 있습니다. 그렇다면 두 개의 다른 모집단에서 표본을 추출할 때 그들 사이에 차이가 나타나는 것은 놀라운 일이 아닙니다. 여기서 진짜 질문은 '언제 그 차이가 실제 차이이며, 단순히 무작위적이고 허용 가능한 자연적 변동이 아닌가?'입니다. 우리는 가설 검정을 수행하고 주어진 유의 수준에서 관측된 차이를 평가함으로써 이를 수행합니다.

두 평균에 대한 가설 검정 절차

두 모집단의 평균을 표본을 통해 비교할 때, 가설 검정 과정은 지난 모듈에서 보았던 것과 동일합니다. 즉, 다음 단계를 따릅니다:

1. H_0 (귀무 가설)와 H_A (대립 가설)를 설정합니다.
2. 유의 수준 α 를 지정합니다.
3. 표본 데이터에 대한 p-값을 계산합니다.
4. H_0 를 기각하거나 기각하지 않습니다.

예시 1: 배터리 수명 비교 - 문제 정의

한 상점 브랜드 배터리가 더 비싼 전국 브랜드 배터리만큼 오래 지속된다고 주장합니다. 소비자 감시 단체는 상점 브랜드의 주장이 거짓이 아닌지 5% 유의 수준에서 확인하고 싶어 합니다. 배터리는 정상적인 사용을 모방하는 장비로 계속 테스트되었고, 배터리가 더 이상 작동하지 않을 때까지의 경과 시간이 기록되었습니다.

배경 설명:

소비자 감시 단체(예: Consumer Reports)는 많은 소비재를 테스트하고 그 결과를 발표하여 소비자들이 새로운 제품을 구매할 때 최고의 가치를 찾도록 돕습니다. 이 예시에서는 배터리 수명에 대한 주장을 검증하는 시나리오를 다룹니다.

두 브랜드 비교 (1/8): 문제 정의 및 변수 설정

배터리 두 브랜드의 평균 수명 차이

명칭 설정:

- 상점 브랜드: A

- 전국 브랜드: B
- μ_A : 브랜드 A의 평균 수명 (시간 단위)
- μ_B : 브랜드 B의 평균 수명 (시간 단위)

여기서는 배터리가 지속되는 평균 시간에 관심이 있으므로, 문제를 두 모집단 간의 차이로 구성할 수 있습니다.

두 브랜드 비교 (2/8): 1단계 - 가설 설정

주장 (Claim): 상점 브랜드 배터리는 전국 브랜드 배터리만큼 오래 지속된다.

$$\mu_A = \mu_B$$

가설:

- $H_0: \mu_A - \mu_B = 0$ (귀무 가설: 두 브랜드의 평균 수명 차이가 없다)
- $H_A: \mu_A - \mu_B \neq 0$ (대립 가설: 두 브랜드의 평균 수명 차이가 있다)

상점 브랜드의 주장은 전국 브랜드만큼 오래 지속된다는 것입니다. 즉, μ_A 는 μ_B 와 같습니다. 이를 귀무 가설과 대립 가설로 다시 작성하면, 귀무 가설은 평균 차이가 0이고, 대립 가설은 차이가 0이 아니라는 것입니다. 단일 표본 가설 검정과 마찬가지로, 이것은 **양측 검정 (two-tail test)**입니다. 나중에 단측 검정 (one-tail test)의 예시도 다룰 것입니다. 지금은 이 질문을 해결하기 위해 수집된 데이터를 살펴봐야 합니다.

두 브랜드 비교 (3/8): 2단계 - 유의 수준 설정

가설:

- $H_0: \mu_A - \mu_B = 0$
- $H_A: \mu_A - \mu_B \neq 0$

유의 수준: $\alpha = 0.05$ (감시 단체는 5% 유의 수준에서 이를 확인하고자 합니다.)

두 브랜드 비교 (4/8): 데이터 수집의 중요성

비교를 위한 데이터: 두 모집단에서 무작위로 독립적으로 추출된 데이터

데이터 수집의 중요성:

3단계로 넘어가기 전에, 이 두 브랜드를 비교하기 위한 데이터가 필요합니다. 데이터 수집은 결코 사소한 작업이 아니라는 점을 상기시켜 드립니다. 두 개의 다른 브랜드를 비교할 때는 '사과와 사과를 비교'하는 것처럼 신중해야 합니다. 예를 들어, 테스트에 사용된 방법은 가능한 한 유사해야 하며, 각 그룹에서 테스트된 배터리 종류(예: AAA 또는 D)도 거의 동일해야 합니다.

각 표본의 관측치 수는 동일할 필요가 없습니다. 다른 크기의 표본을 가질 수 있습니다. 여기서는 기관이 테스트를 수행하므로 두 브랜드에 대해 동일한 표본 크기를 사용할 것입니다. 그러나 설문조사를 하는 경우, 동일한 수의 응답을 받지 못할 수도 있으며, 이는 괜찮습니다.

지금은 데이터가 두 모집단에서 무작위로 독립적으로 선택된 배터리를 기반으로 생성되었다고 가정합니다.

두 브랜드 비교 (5/8): 3단계 - p-값 계산 (기본 원리)

p-값은 추정치와 귀무 가설을 분리하는 표준 오차의 수(검정 통계량)를 알면 찾을 수 있습니다.

단일 모집단의 경우 검정 통계량: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$

이전과 마찬가지로, 단일 표본에 대한 가설 검정을 수행했을 때처럼, p-값은 우리가 찾은 표본 결과와 같은 결과를 찾을 확률이 될 것입니다. 이 확률(p-값)은 우리의 추정치와 가설화된 차이(검정 통계량, t 로 표시)를 분리하는 표준 오차의 수를 알면 찾을 수 있습니다. 단일 모집단의 평균에 대한 가설 검정을 수행했을 때 t -값을 어떻게 계산했는지 기억하시나요? 두 모집단을 비교할 때도 동일한 구조를 사용합니다.

두 브랜드 비교 (6/8): 3단계 - p-값 계산 (두 모집단)

단일 모집단의 경우 검정 통계량: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$

두 모집단을 비교하는 경우 검정 통계량: $t = \frac{(\bar{x}_1 - \bar{x}_2) - D_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$

단일 평균 대신 두 표본 평균의 차이를 사용합니다. 잠시 시간을 내어 두 번째 방정식을 분석하고 첫 번째 방정식과 어떻게 관련되는지 살펴보겠습니다.

- **분자 (Numerator):** 두 표본 평균의 차이($\bar{x}_1 - \bar{x}_2$)가 첫 번째 인수로 사용되며, 첫 번째 방정식의 단일 표본 평균을 대체합니다. 두 번째 인수는 D_0 인데, 이는 두 모집단 간의 가설화된 차이이며, 첫 번째 방정식의 가설화된 평균을 대체합니다. 이 예시에서는 이 차이를 0으로 가설화했습니다.
- **분모 (Denominator):** 표준 오차의 측정값입니다. 표준 오차를 계산하는 것은 상당히 복잡할 수 있지만, 다행히 소프트웨어 프로그램은 몇 가지 명령으로 이를 수행할 수 있으므로 표준 오차 계산 방법에 집중하지 않겠습니다. 대신 Excel을 사용하여 답을 얻을 것입니다. 따라서 예시를 해결하기 위해 슬라이드의 Excel 출력을 사용할 것입니다. 물론 나중에 Excel 데모 비디오를 시청하여 여기에 표시된 출력을 얻는 방법을 확인할 수 있습니다.

두 모집단을 비교하는 논리적 단계는 하나의 모집단과 하나의 표본만 있었을 때와 거의 동일하다는 것을 알아주셨으면 합니다. 수학이 조금 더 복잡해질 뿐입니다.

이제 데이터를 사용하여 예시를 진행해 보겠습니다. Excel을 사용하여 이 두 브랜드의 데이터를 분석했습니다. 다음은 그 출력입니다. t -값은 1.547로 강조 표시되어 있습니다. Excel은 단측 및 양측 검정의 모든 값을 제공합니다. 주어진 문제에 적합한 값에 집중해야 합니다. 여기서는 양측 검정을 수행하므로 출력에서 해당 값에만 집중할 것입니다.

양측 검정의 p-값은 0.123입니다. 이 숫자들은 무엇을 의미할까요? 우리가 가진 것을 더 잘 이해해 봅시다.

두 브랜드 비교 (7/8): 결과 해석 및 주의점

Excel 결과: (위 표와 동일한 내용)

이 결과에 따르면, 상점 브랜드인 브랜드 A의 평균 수명은 9.99시간이고, 전국 브랜드인 브랜드 B의 평균 수명은 9.92시간입니다. 와우, 더 저렴한 브랜드가 더 좋은 브랜드처럼 보입니다!

하지만 잠깐, 이것은 전국 브랜드와 변동성 때문에 나타난 것일 수도 있으니 아직 판단을 내리지 마세요. 관측된 차이가 가설화된 차이 0에서 얼마나 떨어져 있는지를 나타내는 t -값은 1.547입니다. 그렇다면 5% 유의 수준에서 표본에서 관

측된 것과 같은 결과를 관측할 확률은 얼마일까요? 양측 검정의 p-값은 0.123입니다. 이제 우리의 공식으로 돌아가 결정을 내려봅시다.

두 브랜드 비교 (8/8): 4단계 - 귀무 가설 기각 여부 결정

가설:

- $H_0 : \mu_A - \mu_B = 0$
- $H_A : \mu_A - \mu_B \neq 0$

유의 수준: $\alpha = 0.05$ **p-값:** 0.123

결정 규칙: p-값 (0.123) > α (0.05) → 귀무 가설을 기각하지 않습니다 (Don't Reject the Null Hypothesis).

결론:

p-값 0.123이 α 0.05보다 크므로, 우리는 귀무 가설을 기각하지 않을 것입니다. 이는 우리의 표본 데이터가 더 저렴한 상점 브랜드가 더 비싼 전국 브랜드보다 가치나 품질이 떨어진다고 생각하게 할 만한 결과를 내놓지 않았다는 것을 의미합니다. 이것은 소비자에게 좋은 소식입니다. 우리는 동일한 품질을 얻으면서 돈을 절약할 수 있습니다.

기억하시겠지만, 브랜드 A의 평균 수명은 브랜드 B보다 약간 높았습니다. 그러나 우리의 완전한 분석을 기반으로 할 때, 두 브랜드 사이에 의미 있는 차이는 없다고 판단합니다. 여기서 보이는 차이는 '노이즈'로 간주되며 통계적으로 유의미하지 않습니다. 즉, "우리 브랜드가 더 비싼 브랜드보다 더 좋았다"고 전국적으로 광고하지 마세요. 적어도 이 데이터 세트에서는 그렇지 않습니다.

연습 문제: 온라인 vs. 매장 판매 - 문제 상황

한 상점의 관리자는 웹사이트를 통한 일일 평균 판매액(달러 기준)이 매장 판매액과 다른지 알고 싶어 합니다. 데이터가 수집되었고 5% 유의 수준에서 분석이 수행되었습니다. 관리자가 결과를 이해하도록 도와주세요.

시작: 가설과 유의 수준을 설정하세요.

연습 문제: 가설은 무엇인가요? (선택)

관리자는 웹사이트를 통한 일일 평균 판매액(달러 기준)이 매장 판매액과 다른지 알고 싶어 합니다. 데이터가 수집되었고 5% 유의 수준에서 분석이 수행되었습니다. 관리자가 결과를 이해하도록 도와주세요.

가설은 무엇인가요?

1. $H_0 : \mu_{online} - \mu_{inStore} \neq 0$ 그리고 $H_A = \mu_{online} - \mu_{inStore} = 0$
2. $H_0 : \mu_{online} - \mu_{inStore} = 0$ 그리고 $H_A = \mu_{online} - \mu_{inStore} \neq 0$
3. $H_0 : \mu_{online} - \mu_{inStore} \geq 0$ 그리고 $H_A = \mu_{online} - \mu_{inStore} < 0$
4. $H_0 : \mu_{online} - \mu_{inStore} \leq 0$

연습 문제: 풀이 (1/2) - 가설 및 유의 수준 설정

관리자는 두 판매 채널이 다른지 여부에 관심이 있으므로, 귀무 가설과 대립 가설을 양측 검정으로 설정합니다.

- $H_0 : \mu_{online} - \mu_{inStore} = 0$ (귀무 가설: 온라인 평균 판매액과 매장 평균 판매액은 차이가 없다)

- $H_A : \mu_{online} - \mu_{inStore} \neq 0$ (대립 가설: 온라인 평균 판매액과 매장 평균 판매액은 차이가 있다)

유의 수준: $\alpha = 0.05$

연습 문제: 풀이 (2/2) - 결과 분석 및 결정

다음은 관리자의 데이터 분석 결과입니다. 52주간의 주간 판매 데이터가 있습니다. 귀무 가설을 기각하시겠습니까, 아니면 기각하지 않으시겠습니까? 기각하거나 기각하지 않는다는 것이 무엇을 의미할까요?

결정: $p\text{-값} (0.0178) < 0.05 (\alpha) \rightarrow$ 귀무 가설을 기각합니다 (Reject H_0).

해석:

이것은 양측 검정이므로, 양측 검정 분석 결과에 집중해야 합니다. $p\text{-값}$ 을 직접 $\alpha (0.05)$ 와 비교하여 결정을 내리겠습니다. 여기서 $p\text{-값}$ 은 0.0178이며, 이는 α 0.05보다 작습니다. 따라서 귀무 가설을 기각합니다.

이는 온라인 판매와 매장 판매의 주간 평균 판매액이 동일하지 않다는 것을 의미합니다.

이 예시에서 우리는 흥미로운 사실을 발견했습니다. 온라인과 매장 판매의 주간 평균 판매액 사이에 차이가 있습니다. 이제 자연스러운 질문은 '그 차이가 얼마나 되는가?'일 것입니다. 대부분의 사람들은 단순히 차이가 있다는 것을 아는 것만으로는 만족하지 않습니다. 그들은 차이의 크기도 알고 싶어 합니다. 분명히 이것은 중요합니다. 1달러 차이인가요, 아니면 수천 달러 차이인가요? 그러면 이 질문에 어떻게 답할 수 있는지 살펴보겠습니다.

차이는 얼마나 될까? (How Much is the Difference?) - 평균 차이 계산

Excel 결과: (위 표와 동일한 내용, 평균 행 강조)

관측된 평균 차이 (Difference): $969.46 - 863.74 = \$105.72$

해석:

분석 출력에서 매장 평균 판매액이 온라인보다 약간 높은 105.72달러임을 알 수 있습니다. 하지만 다른 표본을 추출하면 다른 결과가 나올 것이라는 것을 알고 있습니다. 따라서 차이를 추정하는 더 좋은 방법은 **신뢰 구간 (Confidence Interval)**을 사용하는 것입니다. 여기 있는 결과를 바탕으로 95% 신뢰 구간을 개발할 수 있습니다.

평균 차이에 대한 신뢰 구간 (Confidence Interval for the Mean Differences) - 공식

단일 표본의 경우 신뢰 구간: 표본 평균 $\pm$ 오차 한계 (Margin of error)

$$\left[\bar{x} \pm t_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}} \right]$$

두 표본의 경우 신뢰 구간:
$$\left[(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right]$$

다시 한번, 두 표본이 있을 때 해야 할 일을 단일 표본에 대한 신뢰 구간을 만들 때 배운 것과 연결시키고 싶습니다. 단일 표본이 있을 때 신뢰 구간은 표본 평균을 취하고 오차 한계를 더하고 빼서 계산되었습니다. 오차 한계는 위 방정식으로 표현되었습니다.

두 표본의 경우에도 아이디어는 동일합니다. 즉, 관측된 차이에 오차 한계를 더하고 빼는 것입니다. 그리고 방정식은 이제 위와 같이 보일 것입니다. 둘 사이의

유사성이 보이시나요? 우리는 본질적으로 동일한 작업을 수행하고 있습니다. 이제 예시로 돌아가 관리자를 위한 95번째 백분위수 신뢰 구간을 계산해 보겠습니다.

차이는 얼마나 될까? (1/5) - 신뢰 구간 계산 시작

Excel 결과: (온라인/매장 판매 t-검정 표)

신뢰 구간 공식:
$$\left[(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right]$$

값 대입 (초기): $(969.46 - 863.74) \pm (1.993) \sqrt{\frac{81505.48}{52} + \frac{17374.14}{52}} = 105.72 \pm (1.993 \times 43.6)$

모든 표기법에 대한 값을 동일한 출력에서 찾고 수학적 계산을 수행하여 신뢰 구간을 얻을 수 있습니다. 표기법에 값을 대입할 때 오른쪽 방정식을 주의 깊게 살펴보세요.

차이는 얼마나 될까? (2/5) - 평균 차이 대입

Excel 결과: (온라인/매장 판매 t-검정 표)

신뢰 구간 공식 (평균 차이 강조):
$$\left[(969.46 - 863.74) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right]$$

값 대입: $(969.46 - 863.74) \pm (1.993) \sqrt{\frac{81505.48}{52} + \frac{17374.14}{52}} = 105.72 \pm (1.993 \times 43.6)$

먼저 각 표본의 평균 지출 값을 대입하여 평균 차이를 얻습니다. 참고로 어떤 값을 먼저 쓰든 상관없습니다.

차이는 얼마나 될까? (3/5) - t-임계값 대입

Excel 결과: (온라인/매장 판매 t-검정 표)

신뢰 구간 공식 (t-임계값 강조):
$$\left[(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right]$$

값 대입: $(969.46 - 863.74) \pm (1.993) \sqrt{\frac{81505.48}{52} + \frac{17374.14}{52}} = 105.72 \pm (1.993 \times 43.6)$

다음으로 $t_{\frac{\alpha}{2}}$ 값을 찾아야 합니다. 이는 Excel 출력에서 '임계값 (critical value)'이라고도 불립니다. 우리의 경우 95% 신뢰 구간을 원하며, 양측 검정의 t-값을 사용하면 1.993이 됩니다.

차이는 얼마나 될까? (4/5) - 표준 오차 계산

Excel 결과: (온라인/매장 판매 t-검정 표)

신뢰 구간 공식 (표준 오차 강조):
$$\left[(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right]$$

값 대입: $(969.46 - 863.74) \pm (1.993) \sqrt{\frac{81505.48}{52} + \frac{17374.14}{52}} = 105.72 \pm (1.993 \times 43.6)$

이제 표준 오차에 대한 값입니다. 여기 표기법은 각 표본의 분산을 각 표본 크기로 나눈 다음, 이들을 더하고 그 합의 제곱근을 취하는 것입니다. 이 경우, 매장 판매의 분산을 표본 크기로 나누고, 온라인 판매의 분산을 표본 크기로 나눈 다음, 이들을 더하고 제곱근을 취합니다. 이제 최종 결과를 얻기 위한 연산을 진행할 수 있습니다.

차이는 얼마나 될까? (5/5) - 최종 신뢰 구간 및 해석

Excel 결과: (온라인/매장 판매 t-검정 표)

계산: $105.72 \pm (1.993 \times 43.6) = 105.72 \pm 86.93$

95% 신뢰 구간: $[\$18.80, \$192.65]$

해석:

모든 것이 올바르게 수행되었다면, 평균 차이는 105.72달러이고 오차 한계는

86.93달러가 됩니다. 이는 매장 판매와 온라인 판매의 주간 평균 판매액에 대한 95% 신뢰 구간이 18.80달러에서 192.65달러 사이의 값이라는 것을 의미합니다. 이 구간 내의 어떤 값이라도 두 판매 채널 간의 실제 차이에 대한 가능성 있는 값입니다.

이제 관리자는 이 결과를 보고 "확실히 차이는 있지만, 실제 차이가 약 19달러에 불과하다면 개인적으로는 그렇게 중요하다고 생각하지 않을 것"이라고 말할 수 있습니다. 이것이 제가 여러분이 주목했으면 하는 부분입니다. 단순히 유의미한 차이를 발견했다고 해서 반드시 실질적인 것을 발견했다는 의미는 아닙니다. 통계를 이해하는 의사결정자는 이제 자신의 통찰력을 적용하여 무엇을 할지 스스로 결정할 수 있습니다.

2.1.2. 레슨 2-1.2: Excel에서 평균 차이 없음 검정

핵심 요약: Excel을 활용한 t-검정

Excel의 '데이터 분석' 도구를 사용하여 두 표본 평균의 차이에 대한 t-검정을 수행하는 실제 절차를 학습합니다. 특히, 분산이 같지 않다고 가정하는 경우의 검정 방법을 다룹니다.

Excel 실습 예시: 배터리 수명 비교 (재확인)

한 상점 브랜드 배터리가 더 비싼 전국 브랜드 배터리만큼 오래 지속된다고 주장합니다. 소비자 감시 단체는 상점 브랜드의 주장이 거짓이 아닌지 5% 유의 수준에서 확인하고 싶어 합니다. 배터리는 정상적인 사용을 모방하는 장비로 계속 테스트되었고, 배터리가 더 이상 작동하지 않을 때까지의 경과 시간이 기록되었습니다.

목표: 두 표본의 평균을 비교하는 가설 검정을 사용하여 이를 테스트합니다. 한 표본은 전국 브랜드에서, 다른 하나는 상점 브랜드에서 가져옵니다.

Excel 워크시트 (2/9): 가설 설정 (Excel 준비)

브랜드 정의:

- A: 상점 브랜드 (Store Brand)
- B: 전국 브랜드 (National Brand)

가설:

- $H_0: \mu_A = \mu_B \rightarrow \mu_A - \mu_B = 0$ (귀무 가설: 두 브랜드의 평균 수명은 동일하다)
- $H_A: \mu_A \neq \mu_B \rightarrow \mu_A - \mu_B \neq 0$ (대립 가설: 두 브랜드의 평균 수명은 다르다)

가설을 설정하는 쉬운 방법은 상점 브랜드와 전국 브랜드의 수명이 같다고 생각하는 것입니다. 따라서 대립 가설은 다르다는 것이 됩니다. 이렇게 작성하면 소프트웨어가 처리할 수 있는 방식으로 작성하기가 더 쉽습니다.

소프트웨어는 두 값 사이의 차이가 무엇이라고 생각하는지 찾고 있습니다. 따라서 이제 이들을 '두 배터리 수명 간의 차이가 0과 같다'는 귀무 가설과 '차이가 0이 아니다'는 대립 가설로 다시 작성할 수 있습니다. 가설이 설정되면 단측 검정인지 양측 검정인지 알 수 있습니다. 이것은 양측 검정의 예시입니다. 왜냐하면 상점 브랜드가 전국 브랜드보다 나쁘거나 좋다고 말하는 것이 아니라,

단순히 '같다'고 말하기 때문입니다. 따라서 우리는 이 가설을 기각할 것입니다. 만약 상점 브랜드가 실제로 더 좋거나 더 나쁘다는 것을 발견한다면 말이죠. 즉, 우리가 예상하는 0이라는 차이에서 너무 많이 벗어나면 귀무 가설을 기각하게 됩니다. 그렇지 않으면 기각하지 않을 것입니다.

Excel 워크시트 (3/9): 데이터 준비 및 표본 크기

데이터: 배터리 수명 Excel 파일 (첫 번째 워크시트 참조)

데이터 설명:

데이터를 살펴보면 브랜드 A와 브랜드 B에 대해 각각 186개의 관측치가 있습니다. 즉, 동일한 수의 배터리가 테스트되었습니다. 참고로, 표본 크기가 동일할 필요는 없습니다. 이들은 두 개의 독립적인 모집단에서 무작위로 선택된 두 개의 독립적인 표본입니다. 따라서 동일할 필요는 없습니다. 배터리를 테스트하는 경우 동일한 수를 선택할 가능성이 높지만, 예를 들어 두 가지 다른 유형의 모집단에 설문조사를 보냈다면 한 모집단이 다른 모집단보다 더 많은 설문지를 반환할 수 있습니다. 따라서 표본 크기가 동일할 필요가 없다는 것은 우리에게 큰 장점입니다.

Excel 워크시트 (4/9): Excel에서 t-검정 선택 절차

절차:

1. Excel에서 **데이터 (Data)** 탭으로 이동합니다.
2. **데이터 분석 (Data Analysis)**을 선택합니다. (이 기능이 보이지 않으면 Excel 추가 기능에서 '분석 도구 팩'을 활성화해야 합니다.)
3. 팝업 창이 나타나면 아래로 스크롤하여 세 가지 다른 t-검정을 찾습니다.
4. t-검정: 두 표본 평균 차이 검정 (분산 불균등 가정) (t-Test: Two-Sample Assuming Unequal Variances)을 선택합니다.

분산 가정에 대한 설명:

- **분산 동일 가정 (Assuming Equal Variances):** 모집단 A(브랜드 A)와 모집단 B(브랜드 B) 내부에 변동성이 있지만, 그 변동성이 거의 같다고 가정하는 것입니다. 수동으로 계산할 때는 자유도를 구하기가 훨씬 간단해지기 때문에 이런 가정을 사용했습니다.
- **분산 불균등 가정 (Assuming Unequal Variances):** 이 가정이 실제와 다를 수 있습니다. 컴퓨터 프로그램을 사용할 때는 수동으로 어려운 계산을 할 필요가 없으므로, 분산이 같다고 가정할 이유가 거의 없습니다.

권장 사항: 항상 분산 불균등 가정으로 이 종류의 검정을 실행하세요. 분산이 실제로 동일하더라도 결과는 같을 것입니다. 하지만 분산이 동일하다고 가정했는데 실제로는 동일하지 않다면, 분석이 잘못될 수 있습니다. 따라서 안전하게 가장 일반화된 형태를 선택하세요. 소프트웨어를 사용할 때는 계산이 순식간에 이루어지므로 차이를 전혀 느끼지 못할 것입니다.

따라서 t-검정을 수행할 것입니다. 이 t-검정은 유의미한 차이가 존재하는지 여부를 알려줄 것입니다. 분산 불균등 가정을 사용하는 두 표본 t-검정을 선택하고 '확인'을 클릭합니다.

Excel 워크시트 (5/9): t-검정 설정 입력

팝업 창 설정:

- 변수 1 범위 (Variable 1 Range): \$A\$1:\$A\$186 (브랜드 A 데이터 선택)
- 변수 2 범위 (Variable 2 Range): \$B\$1:\$B\$186 (브랜드 B 데이터 선택) **팁:** A1에 커서를 놓고 Ctrl+Shift+아래쪽 화살표를 눌러 전체 데이터 세트를 선택합니다.
- 레이블 (Labels): 체크박스 선택 (변수 이름이 포함된 경우) **주의:** 이 옵션을 선택하지 않으면 "숫자가 아닌 값이 있습니다" 오류가 발생할 수 있습니다.
- 가설 평균 차이 (Hypothesized Mean Difference): 0 (또는 비워둠)
- 알파 (α): 0.05 (기본값, 필요시 0.10 등으로 변경 가능)
- 출력 옵션 (Output Options): 출력 범위 (Output range) 선택 후 원하는 셀 지정 (예: \$E\$3) **팁:** 출력 범위를 지정하기 전에 해당 옵션을 클릭해야 커서가 점프하여 드롭다운 메뉴가 회색으로 변하는 것을 방지할 수 있습니다.

설명:

"범위 1은 무엇입니까?"라고 묻습니다. 저는 레이블을 포함하는 것을 선호합니다. 그러면 분석에 레이블이 변수 1로 표시되기 때문입니다. A1에 커서를 놓고 Ctrl+Shift+아래쪽 화살표를 눌러 전체 데이터 세트를 선택합니다. 다시 위로 스크롤하여 브랜드 B에 커서를 놓고 전체 셀을 선택합니다. 레이블이 있다고 말하는 것을 잊지 마세요. 만약 잊으면 "숫자가 아닌 값이 있습니다"라는 오류 메시지가 나타날 것입니다. 그런 경우 다시 열어서 레이블을 클릭하면 됩니다.

"가설 평균 차이는 무엇입니까?"라고 묻습니다. 여기에 0을 입력하거나 무시해도 됩니다. α 는 0.05이며, 이것은 기본값입니다. 0.10 등으로 변경할 수 있습니다. 저는 출력을 같은 페이지에 두는 것을 선호하지만, 여기를 클릭하면 커서가 점프하여 이 드롭다운 메뉴가 회색으로 변합니다. 따라서 스프레드시트의 아무 곳이나 클릭하기 전에 여기를 클릭하고, 위치를 선택한 다음 '확인'을 클릭해야 합니다.

Excel 워크시트 (6/9): 결과 출력 및 초기 해석

Excel 출력: (이전 슬라이드의 배터리 t-검정 표와 동일)

결과 서식 지정:

출력이 공개져 보일 수 있으므로, 먼저 읽기 쉽게 서식을 지정합니다. 가장 좋은 방법은 커서를 여기에 놓고 두 번 클릭하면 크기가 늘어납니다. 걱정할 필요 없습니다.

기술 통계량 (Descriptive Statistics):

출력에서 가장 먼저 볼 수 있는 것은 많은 기술 통계량입니다. 예를 들어, 브랜드 A의 평균은 9.99시간이고 브랜드 B의 평균은 9.92시간이라고 알려줍니다. 브랜드 A는 상점 브랜드이고 브랜드 B는 전국 브랜드입니다. 기억하기 쉽게 바꾸고 싶다면 그렇게 할 수 있습니다. 예를 들어, '상점 브랜드'로 변경하면 생각하기 더 쉬울 것입니다.

이것을 보면 브랜드 A가 실제로 약간 더 나은 것처럼 보입니다. 이것은 상점 브랜드이므로 더 저렴한 배터리, 즉 일반 브랜드입니다. 그래서 "와, 브랜드 A가 실제로 더 좋네"라고 말할 수도 있습니다. 하지만 기억하세요, 우리는 그렇게

말할 수 없습니다. 이 경우 실제로는 같을 수도 있기 때문입니다. 그것이 바로 여기서 테스트하는 것입니다. 또한 브랜드 A의 분산과 브랜드 B의 분산도 알려줍니다. 분산은 표준 편차의 제곱이라는 것을 기억하세요. 따라서 표준 편차를 원한다면 이 값의 제곱근을 취하면 브랜드 A의 표준 편차를 알 수 있습니다. 브랜드 A에는 185개의 관측치가 있고 브랜드 B에도 185개의 관측치가 있다고 합니다. 가설 평균 차이는 0이었고, 자유도는 이 두 값을 사용하여 분산 불균등 가정에 사용되는 방정식을 기반으로 자유도를 생성하는 과정을 거쳐 계산되었습니다.

t-통계량 및 p-값:

이것이 완료되면 t-통계량 값과 단측 검정 및 양측 검정에 대한 p-값을 볼 수 있습니다. 또한 t-임계값이 어디에 있는지도 알려줍니다. t-임계값의 의미를 보여드리겠습니다.

Excel 워크시트 (7/9): t-임계값 시각화 및 이해

t-임계값 (T critical value):

- 양측 검정 (Two-tail test)에서 유의 수준이 5%인 경우, 왼쪽 꼬리에 2.5%, 오른쪽 꼬리에 2.5%가 있습니다.
- 이 경우 t-임계값은 1.96과 -1.96이 됩니다. (Excel 출력에서는 1.969384804)

Excel 워크시트 (8/9): p-값 기반 최종 결정

Excel 출력: (이전 슬라이드의 배터리 t-검정 표와 동일, $P(T \leq t)$ 양측 값 0.1230 강조)

결정: p-값 (양측) = 0.1230 > 0.05 (α) → 귀무 가설을 기각하지 않습니다.

설명:

만약 단측 검정을 수행했다면, 어느 꼬리든 상관없이(오른쪽 꼬리든 왼쪽 꼬리든) 전체 5%가 한쪽에 있을 것입니다. 예를 들어 오른쪽 꼬리 검정이라면 1.65가 될 것입니다 (Excel 출력에서는 1.650898678). Excel은 단측 검정인지 양측 검정인지 모르기 때문에 모든 값을 제공합니다. 여러분이 올바른 것을 선택해야 합니다.

또한 t-통계량도 알려줍니다. t-통계량(1.547)은 브랜드 A에서 표본을, 브랜드 B에서 표본을 추출했을 때, 가설화된 차이가 0일 때 이 두 표본에서 관찰된 차이가 어디쯤에 있는지를 말해줍니다. 그리고 p-값을 제공하며, 여러분은 가설을 기각할지 말지를 결정해야 합니다.

우리 사례에서는 양측 검정을 수행하고 있으므로, 테이블의 이 부분에만 집중할 것입니다. 이 p-값을 보면 0.05보다 크다는 것을 알 수 있습니다. 따라서 귀무 가설을 기각하지 않습니다. 귀무 가설을 기각하지 않는다는 것은 무엇을 의미할까요?

Excel 워크시트 (9/9): 최종 결론 도출

가설:

- $H_0: \mu_A - \mu_B = 0$ (강조)
- $H_A: \mu_A - \mu_B \neq 0$

결론:

우리의 가설은 이 두 브랜드가 거의 동일하게 작동한다는 것이었고, 데이터를 기반으로 이를 기각하지 않았습니다. 따라서 두 브랜드는 거의 동일합니다. 현재 그들이 주장하는 바는 우리가 가진 데이터를 기반으로 반박할 수 없습니다.

2.1.3. 레슨 2-1.3: 두 표본에 대한 양측 평균 검정 및 Excel에서 신뢰 구간 계산

핵심 요약: 가설 검정 후 신뢰 구간 계산

Excel의 데이터 분석 기능을 활용하여 두 표본 평균의 차이에 대한 가설 검정을 수행하고, 이어서 해당 차이에 대한 신뢰 구간을 계산하는 방법을 실습합니다. 이는 통계적 유의성뿐만 아니라 차이의 실제적인 크기를 이해하는 데 필수적입니다.

Excel 실습 예시: 온라인 vs. 매장 판매 (신뢰 구간)

한 상점의 관리자는 웹사이트를 통한 일일 평균 판매액(달러 기준)이 매장 판매액과 다른지 알고 싶어 합니다. 데이터가 수집되었고 5% 유의 수준에서 분석이 수행되었습니다. 관리자가 결과를 이해하도록 도와주세요.

목표: 가설을 설정하고 유의 수준을 지정하여 분석을 시작합니다.

온라인/매장 Excel 워크시트 (2/10): 가설 설정

가설:

- $H_0 : \mu_{Online} = \mu_{Instore} \rightarrow \mu_{Online} - \mu_{Instore} = 0$ (귀무 가설: 온라인 판매와 매장 판매의 평균은 동일하다)
- $H_A : \mu_{Online} \neq \mu_{Instore} \rightarrow \mu_{Online} - \mu_{Instore} \neq 0$ (대립 가설: 온라인 판매와 매장 판매의 평균은 다르다)

관리자는 온라인과 매장 판매 사이에 차이가 있는지 궁금해합니다. 따라서 귀무 가설은 둘 사이에 차이가 없다는 것이고, 대립 가설은 차이가 있다는 것입니다. 이렇게 작성하면 우리가 무엇을 하고 있는지 더 쉽게 알 수 있습니다. 즉, 두 μ 의 차이가 0과 같거나 0과 같지 않다고 말하는 것입니다. 이제 데이터를 살펴보고 분석을 수행해 봅시다.

온라인/매장 Excel 워크시트 (3/10): 데이터 준비

데이터: 온라인 vs. 매장 Excel 파일 (첫 번째 워크시트 참조)

데이터 설명:

여기에 데이터가 있습니다. 이것은 여러 날 동안 온라인과 매장에서 기록된 일일 판매액(달러)입니다.

온라인/매장 Excel 워크시트 (4/10): Excel에서 t-검정 선택

절차:

1. Excel에서 데이터 (Data) 탭으로 이동합니다.
2. 데이터 분석 (Data Analysis)을 선택합니다.
3. t-검정: 두 표본 평균 차이 검정 (분산 불균등 가정) (t-Test: Two-Sample Assuming Unequal Variances)을 선택합니다.
4. '확인'을 클릭합니다.

다시 한번, 저는 분산 불균등 가정을 할 것입니다. 단순화하고 싶지 않습니다.

온라인/매장 Excel 워크시트 (5/10): t-검정 설정 입력 (열 선택)

팝업 창 설정:

- 변수 1 범위 (Variable 1 Range): \$A:\$A (온라인 판매 데이터 열 전체 선택)
- 변수 2 범위 (Variable 2 Range): \$B:\$B (매장 판매 데이터 열 전체 선택)
 팁: Ctrl+Shift+아래쪽 화살표 대신 열 전체를 선택하는 것이 더 빠릅니다. 이 유형의 분석에서는 작동하지만 항상 이런 식으로 선택할 수 있는 것은 아닙니다.
- 레이블 (Labels): 체크박스 선택
- 가설 평균 차이 (Hypothesized Mean Difference): 0
- 알파 (α): 0.05
- 출력 옵션 (Output Options): 새 워크시트 (New Worksheet Ply) 선택 (또는 출력 범위 지정)

설명:

"범위 1을 묻습니다. 이전에 Ctrl+Shift+아래쪽 화살표를 사용하여 선택하는 방법을 보여드렸지만, 여기서는 열 전체를 선택하는 것이 더 빠릅니다. 이 유형의 분석에서는 작동하지만 항상 이런 식으로 선택할 수 있는 것은 아닙니다. 하지만 여기서는 가능하며 선택 과정을 빠르게 할 수 있습니다.

두 번째 변수는 B열에 나타날 것입니다. 저는 차이가 없다고 가정합니다. 선택이 없습니다. 레이블이 있다고 선택할 것입니다. 출력 범위를 선택하고, 여기를 클릭하고, 스프레드시트의 아무 곳이나 클릭한 다음 '확인'을 클릭합니다.

이제 결과가 나왔습니다. 다시 한번, 저는 양측 검정을 수행하고 있다는 것을 알고 있습니다. 왜냐하면 '같다' 대 '같지 않다'의 가설이기 때문입니다.

온라인/매장 Excel 워크시트 (6/10): 결과 분석 및 결정

Excel 출력: (온라인/매장 판매 t-검정 표)

결정: p-값 (양측) = 0.017 < 0.05 (α) → 귀무 가설을 기각합니다.

설명:

이 출력의 양측 부분에만 집중하면 됩니다. p-값을 보면 0.05보다 작으므로, 귀무 가설(두 판매 채널이 동일하다는 가설)을 기각하게 됩니다.

이제 두 판매 채널 사이에 차이가 있다는 것을 알았으니, 온라인 판매와 매장 판매 사이의 예상되는 차이가 무엇인지 알고 싶습니다. 이제 동일한 출력을 사용하여 두 판매 채널 사이에 존재하는 차이에 대한 신뢰 구간을 개발할 수 있습니다.

온라인/매장 Excel 워크시트 (7/10): 신뢰 구간 계산 준비

Excel 출력: (온라인/매장 판매 t-검정 표)

신뢰 구간 공식:
$$(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

평균 차이 (Mean Difference): -105.7238462 (온라인 평균 - 매장 평균)

설명:

두 판매 채널 간의 차이에 대한 신뢰 구간을 개발하기 위해, 이것은 두 채널 간의 평균 차이입니다. 하지만 이것만으로는 충분하지 않습니다. 단순히 이 둘의

차이를 취하여 이것이 예상되는 차이라고 말할 수는 없습니다. 충분히 큰 오차가 있습니다. 표본마다 변동성이 있습니다. 따라서 전체 차이를 개발해야 합니다.

지금 당장은 두 평균의 차이를 보고 이것이 $\bar{x}_1 - \bar{x}_2$ 라고 말할 수 있습니다. 이것은 이 값에서 이 값을 빼서 개발할 수 있습니다. 참고로, 어떤 것을 먼저 하든 상관없습니다. 부호는 바뀌겠지만, 차이의 절대값은 여전히 동일하며 그것이 우리가 신경 쓰는 부분입니다. 지금은 온라인 평균 판매액이 매장 판매액보다 105달러 적다고 말할 수 있습니다. 반대로 했다면, 이 양수는 매장 판매액이 온라인보다 105달러 많다고 말했을 것입니다. 따라서 실제로는 차이가 없습니다. 우리가 가진 차이에 대한 신뢰 구간 공식으로 돌아가서, 다음으로 찾아야 할 것은 t-값입니다. 신뢰 구간은 항상 양측입니다. 오차 한계는 플러스 또는 마이너스로 발생할 수 있으므로, 여기의 양측 t-값은 1.99입니다. 그것이 저의 t-값입니다. 다시 한번, 우리 공식을 보면 오차 한계를 구하기 위해 다음으로 필요한 것은 표준 오차입니다.

온라인/매장 Excel 워크시트 (8/10): 표준 오차 계산

Excel 출력: (온라인/매장 판매 t-검정 표)

t-값: 1.993463567

표준 오차 (Standard Error) 계산:

```
1 =SQRT(E6/E7+F6/F7)
2 % E6: 온라인 분산 (17374.14)
3 % E7: 온라인 관측치 (52)
4 % F6: 매장 분산 (81505.48)
5 % F7: 매장 관측치 (52)
```

Listing 6.1: Excel에서 표준 오차 계산

결과: 43.60655189

설명:

우리 방정식에 기반한 표준 오차는 단순히 첫 번째 표본의 분산을 해당 표본 크기(이 경우 52)로 나눈 값에 두 번째 표본의 분산을 해당 표본 크기로 나눈 값을 더한 다음, 그 합의 제곱근을 취하는 것입니다. 두 값을 얻으면 제곱근을 사용하여 표준 오차를 찾을 수 있습니다. 이제 오차 한계를 계산할 준비가 되었습니다. 오차 한계는 단순히 t-값에 표준 오차를 곱한 것입니다.

온라인/매장 Excel 워크시트 (9/10): 오차 한계 및 신뢰 구간 계산

Excel 출력: (온라인/매장 판매 t-검정 표)

계산된 값 요약:

- 평균 차이 (mean diff): -105.7238462
- t-값 (t value): 1.993463567
- 표준 오차 (standard error): 43.60655189

오차 한계 (Margin of error): 86.92807245 ($1.993463567 \times 43.60655189$)

신뢰 구간 계산:

- 하한 (Lower): $-105.7238462 - 86.92807245 = -192.6519186$

- 상한 (Upper): $-105.7238462 + 86.92807245 = -18.7957737$

결론:

우리는 95% 신뢰 수준에서 온라인 판매와 매장 판매 간의 차이가 온라인 채널이 매장 판매보다 하루 평균 18.80달러에서 192.65달러 적게 판매할 수 있다는 것을 의미합니다.

온라인/매장 Excel 워크시트 (10/10): 통계적 유의성과 실질적 의미의 차이

통계적 유의성 (Statistical Significance):

- 평균 차이 (mean diff): -105.7238462
- t-값 (t value): 1.993463567
- 표준 오차 (standard error): 43.60655189
- 오차 한계 (Margin of error): 86.92807245
- 하한 (Lower): -192.6519186
- 상한 (Upper): -18.7957737

해석:

이것은 두 채널 간에 통계적으로 유의미한 차이를 보여줍니다. 하지만 실제로는 그 차이가 18달러만큼 작을 수도 있습니다. 따라서 관리자로서 여러분은 이것이 중요하지 않다고 판단할 수도 있습니다. 즉, 통계적으로 유의미하다고 해서 항상 의미 있는 것을 발견했다는 뜻은 아닙니다. 만약 이 숫자가 수천 달러의 차이였다면, 아무도 실제적으로도 중요한 문제라고 반박하지 않을 것입니다.

비즈니스 담당자로서 이것이 충분히 유의미하다고 판단하는 임계값은 해당 분야와 그 분야와 관련된 결정에 따라 달라지므로, 표준적인 답은 없습니다. 이것이 바로 여러분의 전문 지식이 발휘되는 지점이며, 단순히 통계적 값만 보는 것이 아닙니다.

6.3.2 2.2. 레슨 2-2: 평균에 대한 단측 검정 (One-Tail Test of the Means)

이 레슨에서는 두 모집단 평균의 차이가 특정 방향으로 나타나는지(예: 한쪽이 다른 쪽보다 크거나 작다)를 검정하는 단측 검정 방법을 학습합니다.

2.2.1. 레슨 2-2.1: 평균에 대한 단측 검정

핵심 요약: 단측 검정의 목적

단측 검정은 두 모집단 평균의 차이가 특정 방향(예: '더 크다' 또는 '더 작다')으로 존재하는지 여부를 검정할 때 사용됩니다. 이는 양측 검정('다르다')과 달리 특정 가설 방향이 있을 때 유용합니다.

단측 검정 (One-tail Test) 가설 설정

때로는 한 모집단의 평균이 다른 모집단의 평균과 특정 방향으로 다른지 알고 싶을 때가 있습니다. 즉, 모집단 1의 평균이 모집단 2의 평균보다 크거나 같거나, 그 반대인 경우입니다. 이런 경우 우리는 단측 검정을 수행할 것입니다. 두 가지 가능성은 다음과 같습니다:

가능성 1: μ_1 이 μ_2 보다 작다는 것을 검정 (좌측 꼬리 검정)

- $H_0: \mu_1 \geq \mu_2$ 또는 $H_0: \mu_1 - \mu_2 \geq 0$ (귀무 가설: μ_1 이 μ_2 보다 크거나 같다)
- $H_A: \mu_1 < \mu_2$ 또는 $H_A: \mu_1 - \mu_2 < 0$ (대립 가설: μ_1 이 μ_2 보다 작다)

가능성 2: μ_1 이 μ_2 보다 크다는 것을 검정 (우측 꼬리 검정)

- $H_0: \mu_1 \leq \mu_2$ 또는 $H_0: \mu_1 - \mu_2 \leq 0$ (귀무 가설: μ_1 이 μ_2 보다 작거나 같다)
- $H_A: \mu_1 > \mu_2$ 또는 $H_A: \mu_1 - \mu_2 > 0$ (대립 가설: μ_1 이 μ_2 보다 크다)

제품 테스트 (1/5): 새로운 점심 메뉴 도입

한 패스트푸드 회사가 새로운 점심 메뉴를 고려하고 있습니다. 회사는 테스트 시장 결과를 바탕으로 메뉴를 선택할 것입니다. 이 메뉴는 기존 메뉴 항목 중 하나보다 더 높은 주간 수요를 보여야 합니다. 선택되려면 0.01 유의 수준에서 차이를 보여야 합니다.

배경 설명:

패스트푸드 체인에서 매우 흔한 시나리오를 생각해 봅시다. 새로운 메뉴 항목을 추가하기로 결정할 때마다 많은 작업과 분석이 그 결정에 들어갑니다. 새로 추가되는 모든 항목은 먼저 상당한 수요를 보여야만 추가될 수 있습니다. 새로 추가되는 모든 항목은 원자재 조달의 복잡성을 증가시키고 그에 따른 작업 흐름 재설계를 필요로 합니다. 새로운 항목은 먼저 여러 매장의 메뉴에 추가된 다음, 새로운 항목에 대한 결정이 내려지기 전에 메뉴의 다른 일반 항목의 수요와 비교됩니다. 그럼, 이러한 연구를 어떻게 수행하고 분석할지 살펴보겠습니다.

제품 테스트 (2/5): 가설 설정 (새 메뉴)

요구 사항: 새로운 메뉴 항목은 기존 메뉴 항목 중 하나보다 더 잘 팔려야 합니다. 분석은 0.01 유의 수준에서 차이를 보여야 선택됩니다.

가설:

- $H_0: \mu_{new} \leq \mu_{regular} \rightarrow H_0: \mu_{new} - \mu_{regular} \leq 0$ (귀무 가설: 새로운 항목의 수요가 기존 항목보다 작거나 같다)
- $H_A: \mu_{new} > \mu_{regular} \rightarrow H_A: \mu_{new} - \mu_{regular} > 0$ (대립 가설: 새로운 항목의 수요가 기존 항목보다 크다)

유의 수준: $\alpha = 0.01$

설명:

먼저, 이 새로운 제품이 다른 항목보다 더 잘 팔리기를 원합니다. 따라서 이것이 우리의 대립 가설이 될 것입니다. 이는 $\mu_{new} - \mu_{regular}$ 가 0보다 크다고 작성할 수 있습니다. 따라서 그 보완은 귀무 가설이 될 것입니다. 여기서 α 는 0.01입니다. 다시 한번, 데이터 수집은 정말 중요합니다.

제품 테스트 (3/5): 데이터 수집 방법

데이터 수집: 무작위로 독립적으로 수집된 데이터 (주간 판매량)

- 일부 매장에는 새로운 항목이 메뉴에 있으며, 새로운 항목에 대한 수요 데이터를 제공합니다.
- 비교 대상인 기존 항목에 대한 수요 데이터는 아직 새로운 항목이 없는 매장에서 수집됩니다.

우리는 독립적인 두 모집단에서 표본 데이터를 수집할 것입니다. 한 모집단은

메뉴에 새로운 항목이 있고, 다른 모집단은 새로운 항목이 없습니다.

제품 테스트 (4/5): 결과 분석 및 p-값 결정

가설:

- $H_0 : \mu_{new} - \mu_{regular} \leq 0$
- $H_A : \mu_{new} - \mu_{regular} > 0$

유의 수준: $\alpha = 0.01$

Excel 결과: (t-검정, 두 표본, 분산 불균등 가정)

결정: p-값 (단측) = 0.0045 < 0.01 (α) → 귀무 가설을 기각합니다.

설명:

데이터가 수집되면, 데이터를 기반으로 관측된 차이에 대한 p-값을 찾기 위해 분석을 수행할 것입니다. 데이터 결과는 위에 표시되어 있으며, 평균 숫자는 천 단위입니다. 또한, 새로운 항목에 대한 표본 크기가 다릅니다. 새로운 항목에 대한 주간 판매 데이터는 75개이고, 기존 항목에 대한 주간 판매 데이터는 108개입니다. 다시 한번, 각 모집단에서 독립적으로 데이터를 수집하고 있으므로 표본 크기가 동일할 필요는 없습니다.

우리는 단측 검정을 수행하고 있으므로, α 와 비교할 p-값은 0.0045입니다. 이 값은 α 0.01보다 작습니다. 따라서 귀무 가설을 기각할 것입니다.

제품 테스트 (5/5): 최종 결론 및 경영진의 관심

가설:

- $H_0 : \mu_{new} - \mu_{regular} \leq 0$
- $H_A : \mu_{new} - \mu_{regular} > 0$

유의 수준: $\alpha = 0.01$ p-값: 0.0045 < 0.01 → 귀무 가설을 기각합니다 ($Reject H_0$).

결론:

대립 가설을 지지하여 귀무 가설을 기각하는 것은 새로운 항목이 비교 대상인 기존 항목보다 더 잘 팔린다고 믿는다는 것을 의미합니다. 따라서 경영진은 이 새로운 항목을 추가하는 것을 고려해야 합니다. 경영진은 이 소식을 듣고 기뻐하지만, 새로운 항목을 전국적으로 출시하기 전에 이 두 항목 간의 예상되는 차이가 무엇인지 알고 싶어 합니다.

수요의 차이는 얼마나 될까? (1/2) - 신뢰 구간 계산 (단측 검정 후)

Excel 결과: (신규/기존 메뉴 t-검정 표)

신뢰 구간 공식:
$$(\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

계산 단계:

- 평균 차이 ($\bar{x}_1 - \bar{x}_2$): $17.51 - 16.9 = 1.32$
- t-임계값 (단측 검정 후 신뢰 구간): $t_{\frac{\alpha}{2}} = 2.35$ 설명: 단측 검정($\alpha = 0.01$)을 수행한 후 신뢰 구간을 만들 때는, 양측 꼬리 각각에 $\alpha/2$ 의 오류 확률을 배분하여 $1 - 2\alpha$ 신뢰 구간을 구성합니다. 즉, 1% 유의 수준의 단측 검정 후에는 98% 신뢰 구간을 만듭니다. 이때 사용되는 t-값은 Excel 출력의 'T critical one-tail' 값인 2.350333732입니다.
- 표준 오차 (Standard error): $\sqrt{\frac{4.037}{75} + \frac{20.868}{108}} = 0.497$
- 오차 한계 (Margin of Error): $2.35 \times 0.497 = 1.168$

설명:

우리의 결과와 두 모집단 간의 차이에 대한 신뢰 구간 방정식을 고려하면 답을 찾을 수 있습니다. 단측 검정을 수행한 후, 이제 평균 차이에 대한 신뢰 구간을 찾으려고 합니다. 이때 구간의 하한과 상한을 모두 추정하는 데 오류가 있을 수 있으므로, 단측 t -값(이 경우 0.01)을 사용하면 양쪽 꼬리 각각에서 1%의 오류 확률을 갖게 됩니다. 따라서 이 경우 신뢰 구간은 98% 신뢰 구간이 됩니다. 여기서는 이 차이를 단계별로 계산하는 방법을 보여줍니다.

첫 번째는 두 표본 평균의 차이입니다. 다음으로 오차 한계가 필요합니다. 이는 단측 검정의 $t_{\frac{\alpha}{2}}$ 값(우리 경우 2.35)에 표준 오차를 곱한 것입니다. 이 경우 오차 한계는 1.168이 됩니다. 이제 98% 신뢰 구간을 표현할 준비가 되었습니다. 여기서 α 는 0.01입니다.

수요의 차이는 얼마나 될까? (2/2) - 최종 신뢰 구간 및 해석**계산된 값:**

- 평균 차이 ($\bar{x}_1 - \bar{x}_2$): $17.51 - 16.9 = 1.32$
- 오차 한계 (Margin of Error): $2.35 \times 0.497 = 1.168$

98% 신뢰 구간: $1.32 \pm 1.168 = [0.1517, 2.488]$

천 단위로 재작성: 주간 판매량이 천 단위로 기록되었으므로, 이를 다음과 같이 다시 작성할 수 있습니다: $[151.7, 2,488.22]$

해석:

우리는 98% 신뢰 구간이 0.1517에서 2.488 사이임을 발견했습니다. 주간 판매량이 천 단위로 기록되었으므로, 이를 151.7에서 2,488.22로 다시 작성할 수 있습니다. 즉, 우리는 새로운 항목의 주간 평균 수요가 기존 항목보다 최소 151.7단위 더 많다고 98% 확신할 수 있습니다.

이 구간의 폭이 얼마나 넓은지 보세요. 이 구간의 폭이 마음에 들지 않을 수도 있습니다. 이는 부분적으로 우리가 요구한 신뢰 수준 때문입니다. 신뢰 수준이 높을수록 이 구간은 더 넓어진다는 것을 기억하세요. 하지만 대체로 우리는 이 새로운 항목이 비교 대상인 기존 항목보다 더 잘 팔릴 것으로 예상합니다.

연습 문제: 교육 프로그램 효과 - 문제 상황

한 교육 프로그램은 대부분의 직원의 판매 실적을 향상시킬 것을 약속합니다. 영업 부서 관리자는 직원 80명을 이 프로그램에 참여시킵니다. 무작위로 선정된 대조군보다 5% 유의 수준에서 결과가 더 좋다고 나타나면, 모든 직원을 프로그램에 참여시킬 것입니다.

목표: 이 문제에 대한 귀무 가설과 대립 가설을 설정하세요.

- 그룹 1: 대조군 (μ_1 : 대조군의 주간 평균 판매액)
- 그룹 2: 교육받은 직원 (μ_2 : 교육을 받은 직원의 주간 평균 판매액)

연습 문제: 귀무 가설 예시 (선택)

한 교육 프로그램은 대부분의 직원의 판매 실적을 향상시킬 것을 약속합니다. 영업 부서 관리자는 직원 80명을 이 프로그램에 참여시킵니다. 무작위로 선정된 대조군보다 5% 유의 수준에서 결과가 더 좋다고 나타나면, 모든 직원을 프로그램에 참여시킬 것입니다.

목표: 이 문제에 대한 귀무 가설과 대립 가설을 설정하세요.

- μ_1 : 대조군의 주간 평균 판매액
- μ_2 : 교육을 받은 직원의 주간 평균 판매액

선택지:

1. $H_0: \mu_1 - \mu_2 = 0$ 그리고 $H_A: \mu_1 - \mu_2 \neq 0$
2. $H_0: \mu_1 - \mu_2 \geq 0$ 그리고 $H_A: \mu_1 - \mu_2 < 0$
3. $H_0: \mu_1 - \mu_2 \leq 0$

연습 문제: 풀이 - 가설 설정 (교육 프로그램)

교육 프로그램은 대부분의 직원의 판매 실적을 향상시킬 것을 약속하므로, 우리는 데이터가 μ_1 이 μ_2 보다 작다는 것을 보여주기를 원합니다. 즉, 교육받은 직원의 판매 실적이 대조군보다 높기를 기대합니다. 따라서 이것이 우리의 대립 가설이 될 것이고, 그 보완은 귀무 가설이 될 것입니다.

가설:

- $H_0: \mu_1 \geq \mu_2 \rightarrow H_0: \mu_1 - \mu_2 \geq 0$ (귀무 가설: 대조군의 판매 실적이 교육받은 직원보다 크거나 같다)
- $H_A: \mu_1 < \mu_2 \rightarrow H_A: \mu_1 - \mu_2 < 0$ (대립 가설: 대조군의 판매 실적이 교육받은 직원보다 작다)

연습 문제: 결과 분석 (교육 프로그램)

가설:

- $H_0: \mu_1 \geq \mu_2$
- $H_A: \mu_1 < \mu_2$

교육 프로그램 결과:

질문: 5% 유의 수준에서 당신의 결론은 무엇입니까?

연습 문제: 예시 표 (선택)

데이터가 분석되어 여기에 제시되어 있습니다. 5% 유의 수준에서 당신의 결론은 무엇입니까? (슬라이드 55의 표 데이터 참조)

1. 귀무 가설을 기각합니다 (Reject the null hypothesis)
2. 귀무 가설을 기각하지 않습니다 (Not reject the null hypothesis)

연습 문제: 풀이 - 결론 (교육 프로그램)

가설:

- $H_0: \mu_1 \geq \mu_2$
- $H_A: \mu_1 < \mu_2$

결정: $P(T \leq t)$ 단측 = $2.66462E-09 < 0.05 (\alpha) \rightarrow$ 귀무 가설을 기각합니다.

설명:

이것은 단측 검정입니다. 5% 유의 수준에서 이와 같은 결과를 볼 p-값은 매우 작으며, 이는 대립 가설을 지지하여 귀무 가설을 기각하게 할 것입니다. 교육이 영업 사원들이 더 효과적이 되도록 도왔다는 것이 분명해 보입니다. 관리자는 모든 직원을 위한 교육 프로그램을 고려해야 합니다.

연습 문제: 신뢰 구간 계산 (교육 프로그램)

교육 프로그램은 많은 비용이 듭니다. 이 프로그램에 전념하기로 결정하기 전에, 관리자는 이 교육을 통해 예상할 수 있는 주간 판매액의 차이를 알고 싶어 합니다. 차이에 대한 90% 신뢰 구간을 개발하세요.

참고: 신뢰 구간의 경우 5%는 양쪽 꼬리에 모두 있을 것이므로, 여기서 추적하는 신뢰 구간은 90% 신뢰 구간이 될 것입니다. 90% 신뢰 구간을 계산하기 위해 이 출력을 사용하세요.

연습 문제: 풀이 - 신뢰 구간 (교육 프로그램)

교육 프로그램 결과: (슬라이드 55의 표 데이터 참조)

계산 단계:

- **평균 차이** ($\bar{x}_1 - \bar{x}_2$): $1419.58 - 1664.58 = -245$
- **t-임계값** (단측 검정 후 신뢰 구간): $t_{\frac{\alpha}{2}} = 1.654$ **설명:** 90% 신뢰 구간이므로, 양측 꼬리 각각 5
- **표준 오차** (Standard Error): $\sqrt{\frac{69082.16}{93} + \frac{67313.69}{80}} = 39.8$
- **오차 한계** (Margin of Error): $1.654 \times 39.8 = 65.83$

90% 신뢰 구간: $[-245 \pm 65.83] = [-310.83, -179.17]$

설명:

다시 한번, 신뢰 구간의 경우 5%는 양쪽 꼬리에 모두 있을 것이므로, 여기서 계산하는 신뢰 구간은 90%입니다. 90% 신뢰 구간을 계산하기 위해 출력을 사용하면, 먼저 이 두 표본 간의 차이는 -245입니다. 다음으로 $t_{\frac{\alpha}{2}}$ 는 1.654이고, 표준 오차는 39.8입니다. 이제 오차 한계를 65.83으로 계산할 수 있으며, 이는 90% 신뢰 구간을 -310.83에서 -179.17로 만듭니다.

무엇을 의미하는가? (What Does It Mean?) - 교육 프로그램 신뢰 구간 해석

90% 신뢰 구간: $[-310.83, -179.17]$

해석:

- 교육을 받지 않은 직원들은 평균적으로 판매량이 더 낮습니다 (달러 기준).
- 실제 차이 (90% 신뢰 수준)는 교육을 받은 그룹에 비해 179.17달러에서 310.83달러 더 적습니다. (즉, 교육받은 그룹이 대조군보다 평균적으로 이만큼 더 많이 판매합니다.)

설명:

이것이 정확히 무엇을 의미할까요? 이것은 첫 번째 그룹인 대조군과 교육받은 그룹 간의 평균 차이라는 것을 기억하세요. 대조군은 평균적으로 교육받은 그룹보다 판매량이 낮았습니다. 그래서 우리는 교육을 고려하고 있는 것입니다. 하지만 경영진은 이 프로그램에 자원을 투입하기 전에 차이가 어느 정도일지 알고 싶어 했습니다. 이 경우, 대조군의 평균 판매액은 교육받은 그룹보다 적으며, 90% 신뢰 수준에서 실제 값은 179.17달러에서 310.83달러 사이입니다.

만약 관리자가 이것이 좋기는 하지만 비용을 정당화할 만큼 충분히 좋지 않다고 생각한다면 어떨까요? 특정 수준의 차이를 찾는 가설을 이런 방식으로 하는 대신 검정할 수 있을까요? 답은 '예'입니다. 그리고 그것이 우리가 다음 레슨에서 배울 내용입니다.

6.4 개요

이 문서는 UIUC BADM-572 과목의 '추론 및 예측 통계 모듈 2' 중 파트 2/3에 해당하는 내용을 다룹니다. 주요 내용은 평균에 대한 단측 검정, 특정 값에 대한 평균 검정, 짝지은 표본 검정, 그리고 비율 검정입니다. 각 개념은 비전공자도 쉽게 이해할 수 있도록 상세한 설명, 현실적인 예시, 그리고 Excel을 활용한 실습 절차를 포함합니다. 가설 설정부터 결과 해석, 그리고 신뢰 구간 계산까지 전반적인 통계적 의사결정 과정을 학습하는 데 중점을 둡니다.

6.5 용어 정리

용어	쉬운 설명	원어	비고
단측 검정	한 방향으로의 차이만 검정하는 가설 검정 (예: 더 크다, 더 작다)	One-Tail Test	특정 방향의 변화에 관심 있을 때 사용
양측 검정	양방향으로의 차이를 검정하는 가설 검정 (예: 다르다)	Two-Tail Test	차이의 방향에 관계없이 변화 여부만 볼 때 사용
유의 수준 (α)	귀무 가설을 잘못 기각할 확률의 최대 허용치	Level of Significance	일반적으로 0.05 또는 0.01 사용
P-값	귀무 가설이 참일 때, 관측된 데이터 또는 더 극단적인 데이터가 나올 확률	P-value	P-값이 α 보다 작으면 귀무 가설 기각
귀무 가설 (H_0)	통계적 검정의 기본 가정 (차이가 없다, 효과가 없다 등)	Null Hypothesis	기각되지 않으면 현상 유지
대립 가설 (H_A)	귀무 가설과 반대되는 주장 (차이가 있다, 효과가 있다 등)	Alternative Hypothesis	연구자가 증명하고자 하는 가설
t-통계량	표본 평균이 귀무 가설의 평균과 얼마나 떨어져 있는지 나타내는 값	t-statistic	t-분포를 따르며, P-값 계산에 사용
t-임계값	유의 수준 α 에서 귀무 가설을 기각하기 위한 t-통계량의 기준 값	T critical value	t-통계량이 t-임계값을 넘어서면 귀무 가설 기각
자유도 (df)	통계량을 계산할 때 자유롭게 변할 수 있는 데이터의 수	Degrees of Freedom	표본 크기에 따라 달라짐
표준 오차	표본 통계량(예: 표본 평균)이 모수(예: 모평균)와 얼마나 차이 날 수 있는지 나타내는 척도	Standard Error	표본 변동성의 추정치
신뢰 구간	모수가 특정 범위 내에 있을 것이라고 추정되는 구간	Confidence Interval	신뢰 수준(예: 95%)으로 표현
짝지은 표본 검정	동일한 개체에 대해 두 번 측정하거나, 특성이 유사한 두 개체를 짝지어 비교하는 검정	Paired Test	개체 간 변동성을 제거하여 비교 정확도 높임
비율 검정	두 모집단의 특정 특성(예: 성공률, 비율)이 서로 다른지 검정	Test of Proportions	Z-검정을 주로 사용

6.6 Lesson 2-2.2: Excel을 이용한 평균의 단측 검정

6.6.1 개념: 단측 검정의 필요성

우리는 특정 방향으로의 변화에만 관심이 있을 때 단측 검정을 사용합니다. 예를 들어, 새로운 제품이 기존 제품보다 '더 높은' 수요를 보일지, 또는 새로운 치료법이 기존 치료법보다 '더 빠른' 회복 시간을 가져올지 등을 알고 싶을 때 유용합니다. 이는 단순히 '다르다'는 것을 넘어 '어떤 방향으로 다른지'를 확인하는 데 초점을 맞춥니다.

시나리오: 패스트푸드 신메뉴 출시

한 패스트푸드 회사가 신메뉴 출시를 고려하고 있습니다. 이 신메뉴는 기존 메뉴 중 하나보다 '더 높은' 주간 수요를 보여야만 선택될 것입니다. 분석은 유의 수준 0.01에서 차이를 보여야 합니다.

6.6.2 가설 설정

가설 검정의 첫 단계는 귀무 가설(H_0)과 대립 가설(H_A)을 설정하는 것입니다.

- **귀무 가설 (H_0):** 신메뉴의 평균 수요가 기존 메뉴의 평균 수요보다 작거나 같다.

$$(\mu_{New} \leq \mu_{Current} \implies \mu_{New} - \mu_{Current} \leq 0)$$
- **대립 가설 (H_A):** 신메뉴의 평균 수요가 기존 메뉴의 평균 수요보다 높다. ($\mu_{New} > \mu_{Current} \implies \mu_{New} - \mu_{Current} > 0$)

우리는 신메뉴가 '더 높은' 수요를 보이는지 확인하고 싶으므로, 이는 단측 검정(one-tail test)이 됩니다.

6.6.3 Excel을 이용한 분석 절차

Excel의 '데이터 분석' 도구를 사용하여 두 표본 평균의 차이에 대한 t-검정을 수행할 수 있습니다.

1. **데이터 준비:** 신메뉴와 기존 메뉴의 주간 수요 데이터를 Excel 워크시트에 준비합니다. (예: 신메뉴 데이터는 A열, 기존 메뉴 데이터는 B열)
2. **데이터 분석 도구 실행:**
 - '데이터' 탭으로 이동합니다.
 - '데이터 분석'을 선택합니다.
 - 't-검정: 등분산 가정 두 표본' 또는 't-검정: 이분산 가정 두 표본'을 선택합니다. (여기서는 't-검정: 이분산 가정 두 표본'을 사용합니다.)
3. **입력 설정:**
 - **변수 1 범위 (Variable 1 Range):** 신메뉴 데이터가 있는 열을 선택합니다 (예: \$A\$A).
 - **변수 2 범위 (Variable 2 Range):** 기존 메뉴 데이터가 있는 열을 선택합니다 (예: \$B\$B).
 - **가설 평균 차이 (Hypothesized Mean Difference):** 0을 입력합니다. (귀무 가설에서 두 평균의 차이가 0이거나 0보다 작다고 가정하기 때문입니다.)
 - **레이블 (Labels):** 데이터에 열 제목이 포함되어 있다면 이 옵션을 선택합니다.
 - **알파 (Alpha):** 유의 수준인 0.01을 입력합니다.
 - **출력 옵션 (Output Options):** 결과를 표시할 위치를 선택합니다 (예: '새 워크시트' 또는 '출력 범위').
4. **결과 확인:** '확인'을 클릭하여 분석 결과를 얻습니다.

6.6.4 결과 해석

Excel 출력 결과는 다음과 같은 정보를 포함합니다.

Table 6.3: Excel 결과: t-검정 (두 표본, 분산 불균등 가정) - 신규/기존 메뉴

	신규 항목 (New Item)	기존 항목 (Regular Item)
평균 (Mean)	17.50666667	16.9444444
분산 (Variance)	4.037117117	20.8638006
관측치 (Observations)	75	108
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	157	
t-통계량 (t-stat)	2.640045854	
P(T ≤ t) 단측 (one-tail)	0.004563106	
T 임계값 단측 (critical one-tail)	2.350333732	
P(T ≤ t) 양측 (two-tail)	0.009126212	
T 임계값 양측 (critical two-tail)	2.607506474	

- **P-값 (단측):** 우리의 대립 가설은 신메뉴의 수요가 '더 높다'는 단측 가설이므로, 'P(T ≤ t) 단측' 값을 확인합니다. 이 값은 0.00456입니다.
- **유의 수준 (α):** 우리는 0.01의 유의 수준을 설정했습니다.

- **결론:** P-값 (0.00456)이 유의 수준 α (0.01)보다 작습니다. ($0.00456 < 0.01$)

따라서, 우리는 귀무 가설을 기각합니다. 이는 신메뉴의 수요가 기존 메뉴보다 통계적으로 유의미하게 더 높다는 것을 의미합니다.

6.6.5 신뢰 구간 계산

신메뉴가 기존 메뉴보다 얼마나 더 높은 수요를 보이는지 추정하기 위해 신뢰 구간을 계산할 수 있습니다.

1. **평균 차이 ($\bar{d}$):** 신메뉴 평균 - 기존 메뉴 평균 = $17.50666667 - 16.19444444 = 1.312222222$ (천 단위)
2. **t-값 ($t_{\alpha/2}$):** 단측 검정에서 $\alpha = 0.01$ 을 사용했으므로, 양측 신뢰 구간을 계산할 때는 양쪽 꼬리에 각각 0.01씩, 즉 총 0.02를 제외한 98% 신뢰 구간을 얻게 됩니다. 이때 사용되는 t-값은 'T 임계값 단측'인 2.350333732입니다.
3. **표준 오차 (Standard Error):** 표준 오차는 다음 공식으로 계산됩니다: 표준 오차 = $\sqrt{\frac{\text{신메뉴 분산}}{\text{신메뉴 관측치}} + \frac{\text{기존 메뉴 분산}}{\text{기존 메뉴 관측치}}}$ 표준 오차 = $\sqrt{\frac{4.037117117}{75} + \frac{620.86838006}{108}} = \sqrt{0.053828228 + 5.748781297} = \sqrt{5.802609525} \approx 0.497045239$
4. **오차 한계 (Margin of Error):** 오차 한계 = t-값 $\times$ 표준 오차 = $2.350333732 \times 0.497045239 \approx 1.168222192$
5. **신뢰 구간:** 하한 (Lower Bound) = 평균 차이 - 오차 한계 = $1.312222222 - 1.168222192 = 0.14400003$ 상한 (Upper Bound) = 평균 차이 + 오차 한계 = $1.312222222 + 1.168222192 = 2.480444414$

98% 신뢰 구간 해석

우리는 신메뉴의 주간 수요가 기존 메뉴보다 평균적으로 0.144천 개(144개)에서 2.480천 개(2,480개) 더 높을 것이라고 98% 신뢰합니다.

경영진의 의사결정

신뢰 구간이 [144, 2480]으로 상당히 넓습니다. 이는 신메뉴가 최소 144개 더 팔릴 수도 있지만, 최대 2480개까지 더 팔릴 수도 있다는 의미입니다. 신메뉴 도입에는 많은 비용이 수반되므로, 경영진은 이처럼 넓은 범위의 예측에 대해 불편함을 느낄 수 있습니다. 더 정확한 정보를 얻기 위해서는 표본 크기를 늘려야 할 필요가 있습니다.

6.7 Lesson 2-3.1: 평균의 특정 값 검정

6.7.1 개념: 특정 값과의 차이 검정

이전까지는 두 모집단 평균의 차이가 '0'인지 여부를 검정했습니다. 하지만 때로는 두 평균의 차이가 '특정 값' 이상 또는 이하인지, 혹은 '특정 값'과 같은지 알고 싶을 때가 있습니다. 예를 들어, 새로운 공정이 기존 공정보다 생산량을 '10개 이상' 늘리는지, 또는 새로운 서비스가 고객 대기 시간을 '5분 이하'로 줄이는지 등을 검정할 수 있습니다. 이는 단순히 차이의 유무를 넘어, 특정 목표치 달성 여부를 판단하는데 중요합니다.

시나리오: 유지보수 공급업체 변경 고려

한 회사가 유지보수 공급업체와의 계약 만료를 앞두고 다른 회사를 고려 중입니다. 현재 공급업체(공급업체 A)의 문제 해결 시간에 대한 불만이 있습니다. 새로운 공급업체(공급업체 B)는 연간 20만 달러의 추가 비용이 들지만, 더 빠른 응답 시간을 약속합니다. 경영진은 공급업체 B로 전환하기 위해 최소 5시간의 수리 시간 단축을 원합니다. 회사는 공급업체를 변경해야 할까요?

6.7.2 가설 설정 (단계 1)

경영진은 공급업체 B의 추가 비용을 정당화하기 위해 수리 시간이 최소 5시간 단축되기를 원합니다.

- μ_A : 공급업체 A의 평균 문제 해결 시간
- μ_B : 공급업체 B의 평균 문제 해결 시간

공급업체 B가 A보다 5시간 이상 빠르다는 것은 $\mu_B \leq \mu_A - 5$ 또는 $\mu_A - \mu_B \geq 5$ 를 의미합니다. 우리는 공급업체 B가 '충분히' 빠르다는 것을 증명해야 하므로, 대립 가설은 우리가 증명하고자 하는 주장이 됩니다.

- 귀무 가설 (H_0): 공급업체 A와 B의 평균 문제 해결 시간 차이가 5시간 이상이다.
($\mu_A - \mu_B \geq 5$)
- 대립 가설 (H_A): 공급업체 A와 B의 평균 문제 해결 시간 차이가 5시간 미만이다.
($\mu_A - \mu_B < 5$)

이것은 공급업체 B가 A보다 5시간 미만으로 빠르다는 것을 증명하는 단축 검정입니다. 즉, 5시간 단축 목표를 달성하지 못했다는 것을 보여주는 것입니다.

6.7.3 유의 수준 설정 (단계 2)

경영진은 5% 유의 수준($\alpha = 0.05$)에서 이 주장을 확인하고자 합니다.

6.7.4 데이터 수집 (단계 3 준비)

가설 검정을 진행하기 위해서는 두 공급업체로부터 문제 해결 시간에 대한 대표성 있는 표본 데이터를 무작위로 독립적으로 수집해야 합니다. 현재 공급업체의 과거 기록과 새로운 공급업체의 유사 고객 데이터를 활용할 수 있습니다.

6.7.5 P-값 계산 (단계 3)

P-값은 관측된 표본 결과 또는 더 극단적인 결과가 귀무 가설이 참일 때 나타날 확률입니다. 이는 t-통계량을 통해 계산됩니다.

- t-통계량 공식: $t = \frac{(\bar{x}_1 - \bar{x}_2) - D_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$ 여기서,
 - $\bar{x}_1, \bar{x}_2$: 두 표본의 평균
 - D_0 : 가설 평균 차이 (이 예시에서는 5)

- s_1^2, s_2^2 : 두 표본의 분산
- n_1, n_2 : 두 표본의 크기
- **Excel 활용**: Excel의 '데이터 분석' 도구에서 't-검정: 이분산 가정 두 표본'을 선택하고, '가설 평균 차이'에 5를 입력하여 P-값을 얻습니다.

6.7.6 Excel 결과 및 해석

Excel 분석 결과는 다음과 같습니다.

Table 6.4: 교육 프로그램 결과: t-검정 (두 표본, 분산 불균등 가정)

	그룹 1 (대조군)	그룹 2 (새로 교육받은 직원)
평균 (Mean)	1419.580645	1664.575
분산 (Variance)	69082.15919	67313.69051
관측치 (Observations)	93	80
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	168	
t-통계량 (t-stat)	-6.155248397	
P(T ≤ t) 단측 (one-tail)	2.66462E-09	
T 임계값 단측 (critical one-tail)	1.653974208	
P(T ≤ t) 양측 (two-tail)	5.32925E-09	
T 임계값 양측 (critical two-tail)	1.974185191	

- **가설 평균 차이**: Excel 입력 시 5로 설정되었습니다.
- **표본 평균**: 공급업체 A는 23.42시간, 공급업체 B는 22.05시간입니다. 공급업체 B가 더 빠르지만, 충분히 빠른지는 P-값을 통해 판단합니다.
- **t-통계량**: -6.29입니다.
- **P-값 (단측)**: 6.95×10^{-10} (거의 0에 가까운 값)

6.7.7 결정 (단계 4)

- **귀무 가설 (H_0)**: $\mu_A - \mu_B \geq 5$
- **대립 가설 (H_A)**: $\mu_A - \mu_B < 5$
- **유의 수준 (α)**: 0.05
- **P-값**: 0.000000000695097

P-값 (6.95×10^{-10})이 유의 수준 α (0.05)보다 훨씬 작습니다. ($6.95 \times 10^{-10} < 0.05$)

결론

귀무 가설을 기각합니다. 이는 공급업체 B가 수리 시간을 최소 5시간 단축할 수 있음을 보여주지 못했음을 의미합니다. 따라서 추가 비용을 정당화할 만한 충분한 근거가 없으므로, 회사는 공급업체 B로 전환하지 않아야 합니다.

6.8 Lesson 2-4.1: 짝지은 표본 검정

6.8.1 개념: 짝지은 표본 실험의 이해

지금까지는 서로 독립적인 두 모집단에서 추출된 표본을 비교하는 방법을 배웠습니다. 하지만 실제 상황에서는 표본들이 서로 '짝지어져' 있거나 '의존적'인 경우가 많습니다. 짝지은 표본 검정(Paired Test)은 이러한 상황에서 두 처리(treatment) 또는 두 시점(before/after) 간의 차이를 분석하는 데 사용됩니다. 이는 개체 간의 자연적인 변동성을 제거하여, 우리가 관심 있는 처리 효과나 변화를 더 정확하게 측정할 수 있게 해줍니다.

짝지은 표본 실험의 세 가지 시나리오

1. 하나의 표본, 두 가지 처리: 동일한 개체들에게 두 가지 다른 처리를 적용하고 결과를 비교합니다.
 - 예시: 피실험자들에게 두 가지 다른 제품을 사용하게 한 후 각각의 만족도를 평가하도록 합니다. (예: A 제품 사용 후 점수, B 제품 사용 후 점수)
2. 하나의 표본, 하나의 처리, 전/후 비교: 동일한 개체들에게 하나의 처리를 적용한 후, 처리 전과 후의 결과를 비교합니다.
 - 예시: 직원들에게 특정 교육을 받게 한 후, 교육 전과 후의 생산성을 비교합니다. (예: 교육 전 생산성, 교육 후 생산성)
3. 두 개의 짝지은 표본: 특정 특성(예: 나이, 능력)이 유사한 개체들을 짝지어 두 그룹으로 나눈 후, 각 그룹에 다른 처리를 적용하고 결과를 비교합니다.
 - 예시: 독해 능력이 비슷한 아이들을 짝지어 두 그룹으로 나눈 후, 각 그룹에 다른 독해 교육 방법을 적용하고 독해력 향상 정도를 비교합니다.

이러한 시나리오들에서 두 데이터 표본은 서로 독립적으로 개발되지 않았으므로, 독립 표본 검정과는 다른 분석 방법이 필요합니다.

6.8.2 짝지은 표본 검정의 가설

짝지은 표본 검정에서는 각 쌍의 '차이(difference)'에 초점을 맞춥니다. 각 참가자(또는 쌍)에 대해 두 변수(x_1, x_2)의 차이 $d = x_1 - x_2$ 를 계산하고, 이 차이들의 평균(μ_d)에 대한 가설을 설정합니다.

여기서 D 는 가설에서 설정하는 차이의 특정 값입니다. 대부분의 경우 $D = 0$ 으로 설정하여 차이가 없는지 여부를 검정합니다.

시나리오: 제품 디자인 평가

한 회사가 두 가지 제품 디자인(A와 B)을 고려 중입니다. 전국 포커스 그룹 참가자들은 두 제품을 여러 차원에서 평가하고 점수(100점 만점)를 매겼습니다. 유의 수준 1%에서 한 디자인이 다른 디자인보다 우수한지 분석합니다.

Table 6.5: 품목 판매 결과 (t-검정: 이분산 가정 두 표본)

항목	신메뉴	기존 메뉴
평균 (Mean)	17.50666667	16.19444444
분산 (Variance)	4.037117117	620.86838006
관측치 (Observations)	75	108
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	157	
t-통계량 (t-stat)	2.640045854	
P($T \leq t$) 단측 (P($T \leq t$) one-tail)	0.004563106	
T 임계값 단측 (T critical one-tail)	2.350333732	
P($T \leq t$) 양측 (P($T \leq t$) two-tail)	0.009126212	
T 임계값 양측 (T critical two-tail)	2.607506474	

6.8.3 제품 디자인 평가: 가설 설정

우리는 어떤 디자인이 더 우수할지에 대한 사전 가정이 없으므로, 두 디자인의 평가 점수가 동일할 것이라는 귀무 가설을 설정합니다.

- **귀무 가설 (H_0):** 두 제품 디자인의 평균 평가 점수 차이(μ_d)는 0이다. ($\mu_d = 0$)
- **대립 가설 (H_A):** 두 제품 디자인의 평균 평가 점수 차이(μ_d)는 0이 아니다. ($\mu_d \neq 0$)
- **유의 수준 (α):** 0.05 (슬라이드에는 0.01로 언급되었으나, 이후 설명에서 0.05로 진행되므로 0.05를 따릅니다.)

이는 양측 검정(two-tail test)입니다.

6.8.4 Excel 결과 및 해석

Excel의 't-검정: 짝지은 두 표본 평균' 도구를 사용하여 분석한 결과는 다음과 같습니다.

- **P-값 (양측):** 우리의 가설은 양측 검정이므로, 'P($T \leq t$) 양측' 값을 확인합니다. 이 값은 약 0.0394입니다.
- **유의 수준 (α):** 0.05
- **결론:** P-값 (0.0394)이 유의 수준 α (0.05)보다 작습니다. ($0.0394 < 0.05$)

따라서, 우리는 귀무 가설을 기각합니다. 이는 5% 유의 수준에서 두 제품의 평균 평가 점수가 통계적으로 유의미하게 다르다는 것을 의미합니다.

6.8.5 어떤 제품이 더 우수한가?

Excel 출력에서 제품 A의 평균 점수(61.752)가 제품 B의 평균 점수(57.312)보다 높습니다. 귀무 가설을 기각했으므로, 이 차이는 우연이 아니며 제품 A가 제품 B보다 더

Table 6.6: 공급업체 A/B t-검정: 이분산 가정 두 표본

항목	공급업체 A (시간)	공급업체 B (시간)
평균 (Mean)	23.42222222	22.025
분산 (Variance)	21.439801	20.29348739
관측치 (Observations)	135	120
가설 평균 차이 (Hypothesized Mean Difference)	5	
자유도 (df)	251	
t-통계량 (t-stat)	-6.291435152	
P(T ≤ t) 단측 (P(T ≤ t) one-tail)	6.95E-10	
T 임계값 단측 (T critical one-tail)	1.650947025	
P(T ≤ t) 양측 (P(T ≤ t) two-tail)	1.39019E-09	
T 임계값 양측 (T critical two-tail)	1.969460227	

높은 평가를 받았다고 결론 내릴 수 있습니다.

단측 검정으로 가설을 설정했다면?

만약 처음부터 제품 A가 더 우수할 것이라고 믿고 다음과 같이 가설을 설정했다면:

- $H_0: \mu_d \leq 0$ (제품 A와 B의 차이가 0이거나 작다)
- $H_A: \mu_d > 0$ (제품 A와 B의 차이가 0보다 크다, 즉 A가 B보다 우수하다)

이 경우, 'P(T ≤ t) 단측' 값인 0.0197을 사용합니다. 이 값은 $\alpha = 0.05$ 보다 작으므로 귀무 가설을 기각하고, 제품 A가 제품 B보다 우수하다는 결론을 내릴 수 있습니다.

6.8.6 얼마나 더 우수한가? (신뢰 구간 계산)

두 제품 평가 점수의 평균 차이에 대한 신뢰 구간을 계산하여 제품 A가 얼마나 더 우수한지 정량화할 수 있습니다. 짝지은 표본 검정의 신뢰 구간 공식은 다음과 같습니다. $\bar{d} \pm t_{\alpha/2} \frac{S_d}{\sqrt{n}}$ 여기서,

- $\bar{d}$: 쌍별 차이의 평균
- $t_{\alpha/2}$: 자유도 $n - 1$ 과 유의 수준 α 에 해당하는 t-값
- S_d : 쌍별 차이의 표준 편차
- n : 쌍의 수 (관측치 수)

1. **평균 차이 ($\bar{d}$):** Excel 출력에서 제품 A 평균 - 제품 B 평균 = $61.752 - 57.312 = 4.44$
2. **t-값 ($t_{\alpha/2}$):** 90% 신뢰 구간을 계산하기 위해 $\alpha = 0.10$ (양측)을 사용합니다. 이때의 t-값은 'T 임계값 단측' (0.05 유의 수준)인 1.65를 사용합니다. (단측 0.05는 양측 0.10에 해당합니다.)
3. **쌍별 차이의 표준 편차 (S_d):** 이 값은 Excel 출력에서 직접 제공되지 않으므로, 각 참가자의 제품 A 점수와 제품 B 점수의 차이를 계산한 후, 이 차이들의 표준 편차를 별도로 계산해야 합니다. (강의에서는 33.901로 계산되었다고 언급됩니다.)
4. **표준 오차:** 표준 오차 = $\frac{S_d}{\sqrt{n}} = \frac{33.901}{\sqrt{250}} = \frac{33.901}{15.811} \approx 2.144$

5. 오차 한계 (Margin of Error): 오차 한계 = t -값 $\times$ 표준 오차 = $1.65 \times 2.144 \approx 3.54$

6. 90% 신뢰 구간: 하한 = $\bar{d} - \text{오차 한계} = 4.44 - 3.54 = 0.90$ 상한 = $\bar{d} + \text{오차 한계} = 4.44 + 3.54 = 7.98$

90% 신뢰 구간 해석

우리는 두 제품의 평가 점수 차이가 0.90점에서 7.98점 사이에 있을 것이라고 90% 신뢰합니다. 즉, 제품 A가 제품 B보다 평균적으로 최소 0.90점에서 최대 7.98점 더 높은 평가를 받을 것으로 예상됩니다.

6.8.7 연습 문제: 교육 프로그램 효과 검정

시나리오:

학생들이 준비 수업을 이수한 후 표준화된 시험에서 더 나은 성과를 낼 수 있는지 알아보기 위해 65명의 학생 그룹에게 교육 전후로 시험을 치르게 했습니다. 5% 유의 수준에서 이 주장을 검정합니다. 귀무 가설과 대립 가설은 무엇일까요?

- **짜지은 표본:** 동일한 학생들을 대상으로 교육 전후를 비교하므로 짜지은 표본 검정입니다.
- **주장:** 학생들이 교육 후 '더 나은' 성과를 낼 것이다. 즉, 점수가 증가할 것이다.
- **가설 설정:**
 - $H_0: \mu_d \leq 0$ (교육 후 점수 - 교육 전 점수 ≤ 0 , 즉 점수 향상이 없거나 감소)
 - $H_A: \mu_d > 0$ (교육 후 점수 - 교육 전 점수 > 0 , 즉 점수 향상이 있다)
- **유의 수준 (α):** 0.05

6.8.8 연습 문제: Excel 결과 및 결론

Excel의 't-검정: 짜지은 두 표본 평균' 분석 결과는 다음과 같습니다.

Table 6.7: 짜지은 표본 검정의 가설 유형

H_0	H_A	유형
$\mu_d = D$	$\mu_d \neq D$	양측 검정 (Two-tail)
$\mu_d \geq D$	$\mu_d < D$	단측 검정 (One-tail)
$\mu_d \leq D$	$\mu_d > D$	단측 검정 (One-tail)

- **P-값 (단측):** 우리의 가설은 $H_A: \mu_d > 0$ (교육 후 점수 - 교육 전 점수)이므로, Excel 출력에서 'P($T \leq t$) 단측' 값을 확인합니다. (여기서 t -stat이 음수이므로, 실제로는 $P(T \geq |t|)$ 또는 $P(T \leq t)$ 의 반대 꼬리를 봐야 합니다. Excel은 보통 t -stat의 부호에 따라 적절한 꼬리 확률을 제공합니다. 강의에서는 0.0005를 사용하므로

이를 따릅니다.) 이 값은 0.000512213입니다.

- **유의 수준 (α):** 0.05
- **결론:** P-값 (0.000512213)이 유의 수준 α (0.05)보다 작습니다. ($0.000512213 < 0.05$) 따라서, 귀무 가설을 기각합니다. 이 데이터에 따르면, 교육 프로그램이 학생들의 시험 점수를 통계적으로 유의미하게 향상시킨다고 결론 내릴 수 있습니다.

짜지은 표본 검정의 장점

- **개체 간 변동성 제거:** 동일한 개체를 사용하거나 특성을 짜지음으로써, 개체 자체의 차이로 인한 변동성을 제거하고 두 처리 또는 시점 간의 순수한 차이에 집중할 수 있습니다.
 - **더 작은 표본 크기:** 변동성이 줄어들기 때문에, 독립 표본 검정보다 더 적은 수의 표본으로도 통계적으로 유의미한 결과를 얻을 수 있습니다.
 - **더 신뢰할 수 있는 결과:** 변동성 제어 덕분에 분석 결과의 신뢰도가 높아집니다.
- 가능하다면 항상 짜지은 표본 검정을 선택하는 것이 좋습니다.

6.9 Lesson 2-4.2: Excel을 이용한 짜지은 표본 검정

6.9.1 Excel을 이용한 짜지은 표본 검정 절차

이전 연습 문제(교육 프로그램 효과 검정)를 Excel에서 직접 수행하는 방법을 단계별로 살펴보겠습니다.

시나리오:

학생들이 준비 수업을 이수한 후 표준화된 시험에서 더 나은 성과를 낼 수 있는지 알아보기 위해 65명의 학생 그룹에게 교육 전후로 시험을 치르게 했습니다. 5% 유의 수준에서 이 주장을 검정합니다.

6.9.2 가설 설정

- **귀무 가설 (H_0):** 교육 후 점수와 교육 전 점수의 평균 차이(μ_d)는 0보다 작거나 같다. ($\mu_d \leq 0$)
- **대립 가설 (H_A):** 교육 후 점수와 교육 전 점수의 평균 차이(μ_d)는 0보다 크다. ($\mu_d > 0$)
- **유의 수준 (α):** 0.05

6.9.3 Excel 분석 단계

1. **데이터 준비:** 교육 전 점수(Pre-training score)와 교육 후 점수(Post-training score)를 각각 다른 열에 입력합니다. (예: B열에 교육 전, C열에 교육 후)
2. **데이터 분석 도구 실행:**
 - '데이터' 탭 → '데이터 분석'을 선택합니다.

- 't-검정: 짝지은 두 표본 평균 (t-Test: Paired Two Sample for Means)'을 선택하고 '확인'을 클릭합니다.

3. 입력 설정:

- 변수 1 범위 (Variable 1 Range): 교육 전 점수 열을 선택합니다 (예: \$B\$B).
- 변수 2 범위 (Variable 2 Range): 교육 후 점수 열을 선택합니다 (예: \$C\$C).
- 가설 평균 차이 (Hypothesized Mean Difference): 0을 입력합니다. (우리는 차이가 0보다 큰지 검정하므로, 귀무 가설의 기준점은 0입니다.)
- 레이블 (Labels): 열 제목이 포함되어 있다면 선택합니다.
- 알파 (Alpha): 0.05를 입력합니다.
- 출력 옵션 (Output Options): 결과를 표시할 위치를 선택합니다 (예: '출력 범위'를 선택하고 특정 셀을 지정).

4. 결과 확인: '확인'을 클릭하여 분석 결과를 얻습니다.

6.9.4 Excel 결과 해석

Excel 출력 결과는 다음과 같습니다.

Table 6.8: 제품 A/B t-검정: 짝지은 두 표본 평균

항목	제품 A	제품 B
평균 (Mean)	61.752	57.312
분산 (Variance)	538.1310201	542.9785703
관측치 (Observations)	250	250
Pearson 상관 계수 (Pearson Correlation)	-0.063074728	
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	249	
t-통계량 (t-stat)	2.070791373	
P($T \leq t$) 단측 (P($T \leq t$) one-tail)	0.019704445	
T 임계값 단측 (T critical one-tail)	1.6509996152	
P($T \leq t$) 양측 (P($T \leq t$) two-tail)	0.03940889	
T 임계값 양측 (T critical two-tail)	1.969536868	

- P-값 (단측): 우리의 대립 가설은 $\mu_d > 0$ (교육 후 - 교육 전)이므로, 'P($T \leq t$) 단측' 값을 확인합니다. (t-stat이 음수이므로, Excel은 보통 t-stat의 절대값에 대한 오른쪽 꼬리 확률을 제공하거나, t-stat의 부호에 따라 적절한 꼬리 확률을 제공합니다. 여기서는 0.000512213을 사용합니다.)
- 유의 수준 (α): 0.05
- 결론: P-값 (0.000512213)이 유의 수준 α (0.05)보다 훨씬 작습니다. (0.000512213 < 0.05)

따라서, 귀무 가설을 기각합니다. 이는 교육이 학생들의 시험 점수를 통계적으로 유의미하게 증가시킨다는 것을 의미합니다.

6.9.5 신뢰 구간 계산 (평균 차이)

평균 차이에 대한 신뢰 구간을 계산하여 교육 효과의 크기를 추정할 수 있습니다. 신뢰 구간 공식: $\bar{d} \pm t_{\alpha/2} \frac{S_d}{\sqrt{n}}$

1. **평균 차이 ($\bar{d}$):** 교육 후 평균 - 교육 전 평균 = $548.6 - 500.9692308 = 47.63076923$
2. **t-값 ($t_{\alpha/2}$):** 단측 검정에서 $\alpha = 0.05$ 를 사용했으므로, 양측 신뢰 구간을 계산할 때는 양쪽 꼬리에 각각 0.05씩, 즉 총 0.10을 제외한 90% 신뢰 구간을 얻게 됩니다. 이때 사용되는 t-값은 'T 임계값 단측'인 1.669013025입니다.
3. **쌍별 차이의 표준 편차 (S_d):** 이 값은 Excel 출력에서 직접 제공되지 않습니다. 다음 단계에 따라 수동으로 계산해야 합니다.
 - **차이 열 생성:** Excel 데이터 옆에 'diff'라는 새 열을 만듭니다. 각 학생에 대해 '교육 후 점수 - 교육 전 점수'를 계산하여 이 열을 채웁니다. (예: =C2-B2)
 - **표준 편차 계산:** 'diff' 열의 모든 값에 대해 STDEV.S() 함수를 사용하여 표준 편차를 계산합니다. (예: =STDEV.S(D2:D66))
 - **계산 결과:** $S_d \approx 111.5859491$
4. **표준 오차:** 표준 오차 = $\frac{S_d}{\sqrt{n}} = \frac{111.5859491}{\sqrt{65}} = \frac{111.5859491}{8.062257748} \approx 13.8400404$
5. **오차 한계 (Margin of Error):** 오차 한계 = t-값 × 표준 오차 = $1.669013025 \times 13.8400404 \approx 23.10003082$
6. **90% 신뢰 구간:** 하한 (Lower Bound) = 평균 차이 - 오차 한계 = $47.63076923 - 23.10003082 = 24.53073841$
 상한 (Upper Bound) = 평균 차이 + 오차 한계 = $47.63076923 + 23.10003082 = 70.73080005$

Table 6.9: 교육 전/후 t-검정: 짝지은 두 표본 평균

항목	교육 전 점수	교육 후 점수
평균 (Mean)	500.9692308	548.6
분산 (Variance)	7243.936538	6584.93125
관측치 (Observations)	65	65
Pearson 상관 계수 (Pearson Correlation)	0.099719694	
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	64	
t-통계량 (t-stat)	-3.441396891	
P(T ≤ t) 단측 (P(T ≤ t) one-tail)	0.000512213	
T 임계값 단측 (T critical one-tail)	1.669013025	
P(T ≤ t) 양측 (P(T ≤ t) two-tail)	0.001024426	
T 임계값 양측 (T critical two-tail)	1.997729654	

90% 신뢰 구간 해석

우리는 이 교육을 받은 학생 모집단의 평균 점수가 24점에서 70점 사이로 증가할 것이라고 90% 신뢰합니다. 이는 최소 24점, 최대 70점까지 점수가 향상될 수 있다는 의미입니다. 이 범위 내의 모든 값은 그럴듯한(plausible) 값입니다.

6.10 Lesson 2-5.1: 비율 검정

6.10.1 개념: 두 모집단 비율 비교

우리는 종종 두 모집단에서 특정 특성을 가진 개체의 '비율(proportion)'을 비교해야 할 때가 있습니다. 예를 들어, 두 지역의 실업률(실업자 비율), 두 후보에 대한 지지율(지지자 비율), 또는 두 공정의 불량률(불량품 비율) 등을 비교할 수 있습니다. 비율 검정은 이러한 비율들이 통계적으로 유의미하게 다른지 여부를 판단하는 데 사용됩니다.

비율 비교의 실제 사례

- **실업률**: 2016년 4월 실업률(5%)이 2015년 4월 실업률(5.4%)과 유의미하게 다른가?
- **정치 여론조사**: 힐러리 클린턴 지지율 40%, 버니 샌더스 지지율 46% (오차 한계 $\pm 4\%$). 샌더스가 확실히 이길 것으로 예측할 수 있는가?
 - 클린턴: $40\% \pm 4\% = [36\%, 44\%]$
 - 샌더스: $46\% \pm 4\% = [42\%, 50\%]$
 이 경우, 샌더스의 최저 지지율(42%)이 클린턴의 최고 지지율(44%)보다 낮을 수 있으므로, 샌더스가 확실히 이긴다고 단정하기 어렵습니다. (강의 내용과 달리, 샌더스 42

6.10.2 비율 검정의 가설

두 독립적인 모집단에서 추출된 두 표본의 비율을 비교할 때의 가설은 다음과 같습니다.

Table 6.10: 교육 전/후 t-검정: 짝지은 두 표본 평균 (Excel 출력)

항목	교육 전 점수	교육 후 점수
평균 (Mean)	500.9692308	548.6
분산 (Variance)	7243.936538	6584.93125
관측치 (Observations)	65	65
Pearson 상관 계수 (Pearson Correlation)	0.099719694	
가설 평균 차이 (Hypothesized Mean Difference)	0	
자유도 (df)	64	
t-통계량 (t-stat)	-3.441396891	
P($T \leq t$) 단측 (P($T \leq t$) one-tail)	0.000512213	
T 임계값 단측 (T critical one-tail)	1.669013025	
P($T \leq t$) 양측 (P($T \leq t$) two-tail)	0.001024426	
T 임계값 양측 (T critical two-tail)	1.997729654	

여기서 p_1 과 p_2 는 두 모집단의 실제 비율을 나타냅니다.

6.10.3 예시 1: 남학생과 여학생의 수학 성적 비교

시나리오:

한 연구에 따르면 남학생과 여학생은 수학 시험에서 동등하게 잘 수행한다고 합니다. 한 학군에서 11학년 남학생 400명과 여학생 360명을 무작위로 표본 추출하여 최근 표준화된 시험 점수를 확인했습니다. 남학생 315명과 여학생 280명이 능숙도 수준에 도달했습니다. 5% 유의 수준에서 학군은 남학생과 여학생이 수학 시험에서 동등하게 잘 수행한다고 주장할 수 있을까요?

- 표본 1 (남학생): $n_1 = 400$, 능숙도 학생 수 = 315 $\Rightarrow \hat{p}_1 = 315/400 = 0.7875$ (78.75%)
- 표본 2 (여학생): $n_2 = 360$, 능숙도 학생 수 = 280 $\Rightarrow \hat{p}_2 = 280/360 \approx 0.7778$ (77.78%)
- 가설 설정: 동등하게 잘 수행하는지 여부를 검정하므로 양측 검정입니다.
 - $H_0: p_1 = p_2$ (남학생과 여학생의 능숙도 비율은 같다)
 - $H_A: p_1 \neq p_2$ (남학생과 여학생의 능숙도 비율은 다르다)
- 유의 수준 (α): 0.05

6.10.4 P-값 계산 (Z-검정)

비율 검정에서는 Z-통계량을 사용합니다.

- Z-통계량 공식: $z = \frac{(\hat{p}_1 - \hat{p}_2) - D_0}{\sigma_{\hat{p}_1 - \hat{p}_2}}$ 여기서 D_0 는 가설 평균 차이 (여기서는 0)입니다.
- 표준 오차 공식: $\sigma_{\hat{p}_1 - \hat{p}_2} = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$ (귀무 가설 하에서는 $p_1 = p_2 = p_{pooled}$ 로 가정하고 통합 비율을 사용합니다.)

Excel에는 비율 검정을 위한 내장 함수가 없지만, 사용자 정의 워크시트를 통해 결과를 얻을 수 있습니다.

6.10.5 Excel 출력 및 결론 (예시 1)

사용자 정의 Excel 워크시트의 출력은 다음과 같습니다.

Table 6.11: 통계적 유의성 - 교육 프로그램 (90% 신뢰 구간)

항목	값
평균 차이 (mean diff)	47.63076923
t-값 (t value)	1.669013025
차이의 표준 편차 (std dev of diff)	111.5859491
오차 한계 (Margin of error)	23.10003082
하한 (Lower)	24.53073841
상한 (Upper)	70.73080005

- P-값 (양측): 우리의 가설은 양측 검정이므로, 'P-값 (양측)'인 0.74548을 확인합니다.
- 유의 수준 (α): 0.05

- **결론:** P-값 (0.74548)이 유의 수준 α (0.05)보다 큼니다. ($0.74548 > 0.05$)

따라서, 귀무 가설을 기각하지 않습니다. 이는 이 학군의 남학생과 여학생 표본이 수학 시험에서 동등하게 잘 수행한다는 것을 의미합니다. 관측된 0.97%의 차이는 통계적으로 유의미하지 않으며, 우연에 의한 것으로 볼 수 있습니다.

6.10.6 예시 2: 패스트푸드 워크플로우 재설계

시나리오:

한 패스트푸드 체인이 워크플로우 재설계를 테스트 중입니다. 재설계가 효과적이라면 모든 지점에 적용될 것입니다. 새로운 디자인을 표준으로 채택하려면, 고객 주문이 4분 이내에 완료되는 비율이 현재보다 20% 더 높아야 합니다.

- **데이터:**
 - 현재 디자인: 10,000건 중 7,600건이 4분 이내 완료 $\Rightarrow \hat{p}_2 = 7600/10000 = 0.76$ (76%)
 - 새로운 디자인: 6,000건 중 5,400건이 4분 이내 완료 $\Rightarrow \hat{p}_1 = 5400/6000 = 0.90$ (90%)
- **가설 설정:** 새로운 디자인이 현재보다 20% '더 높아야' 하므로, 이는 단측 검정이며, 가설 평균 차이가 0.20입니다.
 - p_1 : 새로운 디자인의 4분 이내 완료 비율
 - p_2 : 현재 디자인의 4분 이내 완료 비율
 - $H_0: p_1 - p_2 \leq 0.20$ (새로운 디자인의 비율 증가가 20% 이하이다)
 - $H_A: p_1 - p_2 > 0.20$ (새로운 디자인의 비율 증가가 20% 초과이다)
- **유의 수준 (α):** 0.05

6.10.7 Excel 출력 및 결론 (예시 2)

사용자 정의 Excel 워크시트의 출력은 다음과 같습니다. '가설 차이'에 0.20을 입력합니다.

Table 6.12: 비율 검정의 가설 유형

H_0	H_A	유형
$p_1 = p_2$	$p_1 \neq p_2$	양측 검정 (Two-tail)
$p_1 \geq p_2$	$p_1 < p_2$	단측 검정 (One-tail)
$p_1 \leq p_2$	$p_1 > p_2$	단측 검정 (One-tail)

- **P-값 (단측):** 우리의 대립 가설은 $H_A: p_1 - p_2 > 0.20$ 입니다. Excel 출력에서 $H_0: p_1 - p_2 \leq 0$ 에 해당하는 P-값은 1입니다. (Z-통계량이 음수이므로, $p_1 - p_2$ 가 0.20보다 작다는 방향의 확률이 매우 높다는 의미입니다.)

- **유의 수준 (α):** 0.05
- **결론:** P-값 (1)이 유의 수준 α (0.05)보다 큼. ($1 > 0.05$)

따라서, 귀무 가설을 기각하지 않습니다. 이는 새로운 디자인이 고객 주문 완료 비율을 최소 20% 이상 개선한다는 것을 보여주지 못했음을 의미합니다.

6.10.8 95% 신뢰 구간 계산 (비율 차이)

경영진은 새로운 디자인의 비율 증가에 대한 95% 신뢰 구간을 알고 싶어 합니다. 신뢰 구간 공식: $(\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$

1. **표본 비율 차이 ($\hat{p}_1 - \hat{p}_2$):** Excel 출력에서 14% (0.14)
2. **Z-값 ($z_{\alpha/2}$):** 95% 신뢰 구간을 위한 Z-값은 'Z (양측)'인 1.96입니다.
3. **표준 오차:** Excel 출력에서 0.00577
4. **신뢰 구간 계산:** $[0.14 \pm 1.96 \times 0.00577]$ $[0.14 \pm 0.0113]$ $[0.1287, 0.1513]$ 또는 $[12.87\%, 15.13\%]$

95% 신뢰 구간 해석

우리는 새로운 디자인이 고객 주문 완료 비율을 현재 디자인보다 12.87%에서 15.13% 사이로 증가시킬 것이라고 95% 신뢰합니다. 경영진은 20% 이상의 개선을 원했지만, 우리의 연구 결과에 따르면 최대 개선 폭은 약 15%에 불과합니다.

6.10.9 표본 크기의 중요성

비율 비교에서도 표본 크기는 매우 중요합니다. 표본 크기가 작으면 오차 한계가 커져 통계적으로 유의미한 차이를 발견하기 어렵습니다. 반대로 표본 크기가 크면 작은 차이도 통계적으로 유의미하게 나타날 수 있습니다.

정치 여론조사 사례:

- **초기 결과 (108명 투표):** 힐러리 클린턴 56.5%, 버니 샌더스 41.7%. 클린턴이 15% 앞서지만, 표본이 너무 작아 오차 한계가 매우 높으므로 승리를 단정할 수 없습니다.
- **최종 결과 (185,000명 투표):** 버니 샌더스 61.7%, 힐러리 클린턴 38.3%. 표본 크기가 매우 커지자 샌더스와 클린턴 간의 차이가 통계적으로 유의미해졌고, 샌더스의 승리를 확실히 예측할 수 있습니다.

겉보기에 큰 차이도 표본 크기가 작으면 통계적으로 무의미할 수 있습니다. 비율을 비교할 때는 항상 표본 크기를 염두에 두어야 합니다.

6.10.10 연습 문제: UI 입학 허가 수락률 감소 주장 검증

시나리오:

지역 신문에 "전반적으로, 올해 봄 UI의 입학 허가 수락 학생 수는 작년보다 116명 감소했습니다. 2015년 8,085명에서 2016년 7,969명으로 1% 감소했습니다."라는 기사가 실렸습니다. 기자는 이 감소가 통계적으로 유의미한지 주장합니다.

- **비율 계산:**

Table 6.13: 남학생/여학생 비율 검정 Excel 출력

항목	값
표본 1 비율 (Sample 1 Proportion)	78.75%
표본 2 비율 (Sample 2 Proportion)	77.78%
비율 차이 (Proportion Difference)	0.97%
Z (단측) (Z (One-Tail))	1.64485
Z (양측) (Z (Two-Tail))	1.95996
표준 오차 (Standard Error)	0.02997
가설 차이 (Hypothesized Difference)	0
검정 통계량 (Z-Test) 단측 ($H_0 : p_1 - p_2 \geq 0$)	0.324350049
P-값 (단측)	0.62716
검정 통계량 (Z-Test) 단측 ($H_0 : p_1 - p_2 \leq 0$)	0.324350049
P-값 (단측)	0.37284
검정 통계량 (Z-Test) 양측 ($H_0 : p_1 - p_2 = 0$)	0.32460345
P-값 (양측)	0.74548

– p_1 : 2015년 입학 허가 수락 학생 비율 = $8085/22639 \approx 0.3571$ (35.71%)

– p_2 : 2016년 입학 허가 수락 학생 비율 = $7969/22711 \approx 0.3509$ (35.09%)

• 기자의 주장: 2015년 비율이 2016년 비율보다 '높다' (감소했다).

• 가설 설정:

– $H_0 : p_1 \leq p_2$ (2015년 비율이 2016년 비율보다 작거나 같다)

– $H_A : p_1 > p_2$ (2015년 비율이 2016년 비율보다 크다)

• 유의 수준 (α): 0.05 (가정)

6.10.11 연습 문제: Excel 출력 및 결론

사용자 정의 Excel 워크시트의 출력은 다음과 같습니다.

• P-값 (단측): 우리의 대립 가설은 $H_A : p_1 > p_2$ 입니다. Excel 출력에서 $H_0 : p_1 - p_2 \leq 0$ 에 해당하는 P-값은 0.08236입니다.

• 유의 수준 (α): 0.05

• 결론: P-값 (0.08236)이 유의 수준 α (0.05)보다 큼니다. ($0.08236 > 0.05$)

따라서, 귀무 가설을 기각하지 않습니다. 이는 2016년 입학 허가 수락률이 2015년과 통계적으로 유의미한 차이를 보이지 않는다는 것을 의미합니다. 관측된 0.62%의 감소

Table 6.14: 패스트푸드 워크플로우 비율 검정 Excel 출력

항목	값
표본 1 비율 (Sample 1 Proportion)	90%
표본 2 비율 (Sample 2 Proportion)	76%
비율 차이 (Proportion Difference)	14%
Z (단측) (Z (One-Tail))	1.6449
Z (양측) (Z (Two-Tail))	1.96
표준 오차 (Standard Error)	0.00577
가설 차이 (Hypothesized Difference)	0.2000
검정 통계량 (Z-Test) 단측 ($H_0 : p_1 - p_2 \geq 0$)	-10.4069
P-값 (단측)	0
검정 통계량 (Z-Test) 단측 ($H_0 : p_1 - p_2 \leq 0$)	-10.4069
P-값 (단측)	1
검정 통계량 (Z-Test) 양측 ($H_0 : p_1 - p_2 = 0$)	9.4136
P-값 (양측)	0

는 통계적 '노이즈' 범위 내에 있으며, 중요하다고 볼 만한 변화가 아닙니다.

통계적 유의성과 뉴스 가치

이 예시는 우리가 읽거나 듣는 모든 정보가 통계적으로 유의미한 결론을 나타내는 것은 아님을 보여줍니다. 통계적 가설 검정은 무엇이 '유의미한 변화'이고 무엇이 '노이즈'인지를 판단하는 데 도움을 줍니다.

6.11 개요: 두 표본 비율 검정

이 문서는 '추론 및 예측 통계 모듈 2'의 마지막 부분으로, 두 표본의 비율을 비교하는 통계적 가설 검정 방법에 대해 다룹니다. 특히, 단측 검정(One-Tail Test)과 양측 검정(Two-Tail Test)을 엑셀(Excel)을 활용하여 수행하는 절차와 결과를 해석하는 방법을 상세히 설명합니다.

- **주요 목표:** 두 집단의 특정 사건 발생 비율(예: 고객 주문 완료율, 시험 합격률)에 유의미한 차이가 있는지 통계적으로 판단합니다.
- **핵심 개념:** 귀무가설(Null Hypothesis)과 대립가설(Alternative Hypothesis) 설정, 유의수준(Significance Level), p-값(p-value) 해석, 신뢰구간(Confidence Interval) 계산

및 활용.

- **실습 도구:** 엑셀 워크시트를 사용하여 복잡한 계산 없이 쉽게 검정을 수행합니다.
- **학습 목표:** 주어진 시나리오에서 적절한 가설을 설정하고, 엑셀을 이용해 검정을 수행하며, 그 결과를 바탕으로 합리적인 의사결정을 내릴 수 있도록 합니다.

6.12 용어 정리

통계적 가설 검정에서 사용되는 주요 용어들을 비전공자도 이해하기 쉽게 정리했습니다.

용어	쉬운 설명	원어	비고
비율 검정	두 집단에서 어떤 특성을 가진 개체의 비율이 서로 같은지 다른지 통계적으로 확인하는 방법.	Test of Proportions	
단측 검정	한 집단의 비율이 다른 집단보다 '크다' 또는 '작다'와 같이 특정 방향의 차이만 검정하는 방법.	One-Tail Test	대립가설에 부등호(>, <) 포함
양측 검정	두 집단의 비율이 '다르다'와 같이 차이의 방향을 특정하지 않고 단순히 같지 않음을 검정하는 방법.	Two-Tail Test	대립가설에 같지 않음($\neq$) 포함
귀무가설	통계적으로 증명하고 싶은 것과 반대되는, '차이가 없다'거나 '특정 값과 같다'는 기본 가정.	Null Hypothesis (H_0)	보통 기각하기 위해 검정
대립가설	귀무가설과 반대되는, '차이가 있다'거나 '특정 값보다 크거나 작다'는 주장.	Alternative Hypothesis (H_A)	우리가 증명하고 싶은 주장
유의수준	귀무가설이 사실인데도 불구하고 잘못 기각할 확률의 최대 허용치. 보통 5%($\alpha = 0.05$)를 사용.	Significance Level (α)	오류를 허용하는 정도
p-값	귀무가설이 사실이라고 가정했을 때, 현재 관측된 데이터 또는 그보다 더 극단적인 데이터가 나올 확률.	p-value	p-값이 작을수록 귀무가설 기각의 증거가 강함
신뢰구간	모수(모집단의 실제 값)가 포함될 것으로 예상되는 구간.	Confidence Interval (CI)	특정 신뢰수준(예: 95%)에서 모수를 포함할 확률
표본 비율	표본에서 특정 특성을 가진 개체의 비율.	Sample Proportion ($\hat{p}$)	모집단 비율(p)의 추정치
가설 차이	귀무가설에서 설정한 두 비율 간의 예상 차이 값.	Hypothesized Difference	보통 0 또는 특정 값(예: 0.20)
표준 오차	표본 통계량(예: 표본 비율 차이)이 모집단 모수와 얼마나 차이 날 수 있는지 나타내는 척도.	Standard Error (SE)	추정치의 정밀도
z-값	표준정규분포에서 특정 확률에 해당하는 값. 신뢰구간 계산 등에 사용.	z-value	신뢰수준에 따라 달라짐
마진 오브 에러	신뢰구간의 폭을 결정하는 값. 표본 통계량에 더하고 빼서 신뢰구간을 만들.	Margin of Error	z-값 $\times$ 표준 오차

6.13 Lesson 2-5.2: 두 표본 비율에 대한 단측 검정 (엑셀 활용)

이 섹션에서는 두 표본의 비율 차이가 특정 값보다 큰지(또는 작은지)를 검정하는 단측 검정 방법을 엑셀을 사용하여 학습합니다. 특히, 엑셀 워크시트를 활용하여 계산 과정을 간소화하고 결과를 해석하는 데 중점을 둡니다.

6.13.1 핵심 개념 및 원리

단측 검정은 우리가 특정 방향의 변화(예: '더 좋아졌다', '더 나빠졌다')를 확인하고 싶을 때 사용합니다. 예를 들어, 새로운 마케팅 전략이 고객 전환율을 '높였는지', 새로운 생산 공정이 불량률을 '낮췄는지' 등을 검정할 때 유용합니다.

단측 검정의 핵심:

두 비율의 차이가 특정 값보다 크거나 작은지 한 방향으로만 검정합니다. 귀무가설(H_0)과 대립가설(H_A)은 부등호(>, <, $\leq$, $\geq$)를 포함합니다.

가설 설정

단측 검정에서는 우리가 증명하고자 하는 주장이 대립가설(H_A)이 됩니다. 귀무가설(H_0)은 그 반대 또는 '차이가 없다'는 가정이 됩니다.

- **귀무가설 (H_0):** 두 비율의 차이가 특정 값보다 작거나 같다. (예: $P_1 - P_2 \leq 0.20$)
- **대립가설 (H_A):** 두 비율의 차이가 특정 값보다 크다. (예: $P_1 - P_2 > 0.20$)

또는 반대로:

- **귀무가설 (H_0):** 두 비율의 차이가 특정 값보다 크거나 같다. (예: $P_1 - P_2 \geq 0.20$)
- **대립가설 (H_A):** 두 비율의 차이가 특정 값보다 작다. (예: $P_1 - P_2 < 0.20$)

가설 설정 시 주의사항:

어떤 가설을 설정하느냐에 따라 p-값 계산 방식이 달라지므로, 문제의 요구사항을 정확히 파악하여 올바른 귀무가설과 대립가설을 설정하는 것이 매우 중요합니다. 특히, 엑셀 워크시트에서 어떤 단측 검정 p-값을 봐야 할지 결정하는 기준이 됩니다.

6.13.2 패스트푸드 체인점 워크플로우 개선 예시

패스트푸드 체인점에서 새로운 워크플로우를 테스트하여, 고객 주문 완료율이 4분 이내에 20% 더 높아지는지 확인하고자 합니다. 만약 효과적이라면 모든 지점에 적용할 계획입니다.

문제 정의 및 데이터 수집

- **목표:** 새로운 디자인이 현재 디자인보다 4분 이내 주문 완료 비율을 20% 이상 높이는지 확인.
- **데이터:**
 - 현재 디자인 (Current Design): 10,000건 중 7,600건이 4분 이내 완료.
 - 새로운 디자인 (New Design): 6,000건 중 5,400건이 4분 이내 완료.
- **유의수준 (α):** 5% (0.05)

가설 설정

새로운 디자인(P_1)이 현재 디자인(P_2)보다 20% 더 높은 비율을 보이는지 확인하므로, 대립가설은 ' $P_1 - P_2 > 0.20$ '이 됩니다.

- P_1 : 새로운 디자인에서의 4분 이내 주문 완료 비율
- P_2 : 현재 디자인에서의 4분 이내 주문 완료 비율
- **귀무가설 (H_0):** $P_1 - P_2 \leq 0.20$ (새로운 디자인이 20% 이상 개선되지 않았다)
- **대립가설 (H_A):** $P_1 - P_2 > 0.20$ (새로운 디자인이 20% 이상 개선되었다)

우리는 대립가설(H_A)을 지지할 증거를 찾고 있습니다.

6.13.3 엑셀을 이용한 검정 절차

제공된 엑셀 워크시트('Proportion Fast Food' 파일의 'Two proportions - First worksheet' 참조)를 사용하여 검정을 수행합니다.

데이터 입력

엑셀 워크시트의 'Input' 섹션에 다음 값을 입력합니다.

- **Sample 1 (New Design):**
 - Count of Events: 5,400

- Sample Size: 6,000
- Sample 2 (Current Design):
 - Count of Events: 7,600
 - Sample Size: 10,000
- Level of Significance (α): 0.05
- Hypothesized Difference: 0.20 (우리가 20% 개선을 가정했으므로)

팁

엑셀 워크시트는 초기에는 오류 메시지를 표시할 수 있습니다. 데이터를 모두 입력하면 'Output' 부분이 자동으로 채워집니다.

결과 해석 (p-값)

데이터를 입력하면 엑셀 워크시트의 'Output' 섹션이 계산 결과로 채워집니다. 우리는 설정한 가설에 맞는 p-값을 찾아야 합니다.

- **표본 비율 계산:**
 - 새로운 디자인($\hat{p}_1$): $5400/6000 = 0.90$ (90%)
 - 현재 디자인($\hat{p}_2$): $7600/10000 = 0.76$ (76%)
 - 표본 비율 차이($\hat{p}_1 - \hat{p}_2$): $0.90 - 0.76 = 0.14$ (14%)
- **p-값 확인:** 우리의 귀무가설은 $H_0: P_1 - P_2 \leq 0.20$ 이므로, 엑셀 워크시트에서 이 형태에 해당하는 단측 검정(One-tail) p-값을 찾습니다.
 - 엑셀 출력에서 $H_0: P_1 - P_2 \leq 0$ (또는 이와 유사한 형태, 여기서 0은 가설 차이 0.20을 의미)에 해당하는 p-값은 1.000입니다.

p-값 해석:

- p-값 (1.000) > 유의수준 ($\alpha = 0.05$)
- 따라서, 귀무가설($H_0: P_1 - P_2 \leq 0.20$)을 기각할 수 없습니다.

결론: 새로운 디자인이 4분 이내 주문 완료 비율을 20% 이상 개선했다는 통계적 증거를 찾지 못했습니다.

6.13.4 신뢰구간 계산 및 활용

비록 20% 개선 목표를 달성하지 못했지만, 실제 개선 정도가 어느 정도인지 경영진에게 보여줄 필요가 있습니다. 이때 신뢰구간을 활용할 수 있습니다.

신뢰구간 공식

두 비율 차이에 대한 신뢰구간 공식은 다음과 같습니다.

$$(\hat{p}_1 - \hat{p}_2) \pm z \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}$$

여기서:

- $(\hat{p}_1 - \hat{p}_2)$: 두 표본 비율의 차이
- z : 신뢰수준에 해당하는 z -값
- $\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$: 표준 오차 (Standard Error, SE)

z -값 선택

신뢰구간을 계산할 때 사용하는 z -값은 신뢰수준에 따라 달라집니다.

- **단측 검정의 z -값** (예: 90% 신뢰수준): 단측 검정에서는 5%의 유의수준이 한쪽 꼬리에 집중됩니다. 따라서 90% 신뢰구간을 원한다면 z -값은 1.645를 사용합니다. (양쪽 꼬리에 각각 5%씩 남는 90% 신뢰구간과 동일)
- **양측 검정의 z -값** (예: 95% 신뢰수준): 일반적으로 95% 신뢰구간을 계산할 때는 z -값 1.96을 사용합니다. 이는 양쪽 꼬리에 각각 2.5%씩 남는 경우입니다.

강의에서는 95% 신뢰구간을 계산하기 위해 z -값으로 1.96을 사용합니다. 이는 단측 검정을 수행했더라도 신뢰구간 자체는 양측으로 계산하는 것이 일반적이기 때문입니다.

z -값 선택의 혼동 방지:

단측 검정을 수행했더라도 신뢰구간을 계산할 때는 보통 양측 신뢰구간의 z -값을 사용합니다. 예를 들어, 95% 신뢰구간을 원한다면 z -값 1.96을 사용합니다. 만약 90% 신뢰구간을 원한다면 z -값 1.645를 사용합니다. 이는 신뢰구간이 '모수가 이 구간 안에 있을 확률'을 나타내기 때문에, 양쪽으로 오차를 고려하는 것이 일반적이기 때문입니다.

신뢰구간 계산

엑셀 워크시트의 'Output'에서 다음 값을 확인합니다.

- **표본 비율 차이** $(\hat{p}_1 - \hat{p}_2)$: 0.14 (14%)
- **표준 오차** (Standard Error, SE): 0.006

이제 95% 신뢰구간을 계산합니다.

- **z -값**: 1.96 (95% 신뢰수준)
- **마진 오브 에러** (Margin of Error): $z \times SE = 1.96 \times 0.006 \approx 0.01176$ (약 1.18%)
- **하한** (Lower Bound): $0.14 - 0.01176 \approx 0.12824$ (12.82%)
- **상한** (Upper Bound): $0.14 + 0.01176 \approx 0.15176$ (15.18%)

엑셀 워크시트에서는 반올림하여 다음과 같이 표시됩니다.

- Margin of error: 0.0113
- 95% Lower confidence level: 12.87%
- 95% Upper confidence level: 15.13%

6.13.5 최종 결론

종합 결론:

- 통계적 검정 결과, 새로운 디자인이 4분 이내 주문 완료 비율을 20% 이상 개선했다는 귀무가설을 기각할 수 없었습니다. 즉, 20% 개선 목표는 달성되지 않았습니다.
- 하지만, 95% 신뢰구간은 새로운 디자인이 현재 디자인보다 4분 이내 주문 완료 비율을 12.87%에서 15.13% 더 높일 가능성이 있다고 보여줍니다.
- 이는 경영진에게 새로운 디자인이 비록 20% 목표에는 미치지 못하지만, 여전히 유의미한 개선 효과(약 13% 15%)를 가져올 수 있다는 추가 정보를 제공합니다.

6.14 Lesson 2-5.3: 두 표본 비율에 대한 양측 검정 (엑셀 활용)

이 섹션에서는 두 표본의 비율이 서로 같은지 다른지를 검정하는 양측 검정 방법을 엑셀을 사용하여 학습합니다. 양측 검정은 차이의 방향을 특정하지 않고 단순히 '차이가 있다/없다'를 확인하고 싶을 때 사용합니다.

6.14.1 핵심 개념 및 원리

양측 검정은 두 집단 간에 어떤 차이가 있는지 여부만 궁금할 때 사용합니다. 예를 들어, 두 가지 교육 방법이 학생들의 성적에 '차이를 만드는지', 또는 두 가지 약물의 부작용 발생률이 '다른지' 등을 검정할 때 활용됩니다.

양측 검정의 핵심:

두 비율이 서로 같은지 다른지만 검정합니다. 차이의 방향은 중요하지 않습니다. 귀무가설(H_0)은 등호(=)를, 대립가설(H_A)은 같지 않음($\neq$)을 포함합니다.

가설 설정

양측 검정의 가설은 항상 다음과 같은 형태를 가집니다.

- 귀무가설 (H_0): 두 비율이 같다. (예: $P_1 = P_2$ 또는 $P_1 - P_2 = 0$)
- 대립가설 (H_A): 두 비율이 같지 않다. (예: $P_1 \neq P_2$ 또는 $P_1 - P_2 \neq 0$)

우리는 대립가설(H_A)을 지지할 증거를 찾고 있습니다. 즉, 두 비율이 다르다는 것을 증명하고 싶습니다.

6.14.2 남학생과 여학생의 수학 시험 성적 예시

한 연구에서 남학생과 여학생이 수학 시험에서 동등하게 잘 수행한다고 주장했습니다. 한 학군에서 11학년 남학생 400명과 여학생 360명을 무작위로 표본 추출하여 최근 표준화된 시험 점수를 조사했습니다.

문제 정의 및 데이터 수집

- **목표:** 남학생과 여학생이 수학 시험에서 동등하게 잘 수행한다고 주장할 수 있는지 확인.
- **데이터:**
 - 남학생 (Boys): 400명 중 315명이 능숙(proficient) 수준.
 - 여학생 (Girls): 360명 중 280명이 능숙(proficient) 수준.
- **유의수준 (α):** 5% (0.05)

가설 설정

남학생과 여학생이 동등하게 잘 수행하는지(즉, 비율이 같은지) 확인하므로, 양측 검정을 수행합니다.

- p_{Girls} : 여학생의 능숙 수준 비율
- p_{Boys} : 남학생의 능숙 수준 비율
- **귀무가설 (H_0):** $p_{Girls} = p_{Boys}$ (여학생과 남학생의 능숙 수준 비율이 같다)
- **대립가설 (H_A):** $p_{Girls} \neq p_{Boys}$ (여학생과 남학생의 능숙 수준 비율이 같지 않다)

6.14.3 엑셀을 이용한 검정 절차

제공된 엑셀 워크시트('Proportion Math' 파일의 'Two proportions - First worksheet' 참조)를 사용하여 검정을 수행합니다.

데이터 입력

엑셀 워크시트의 'Input' 섹션에 다음 값을 입력합니다.

- **Sample 1 (Boys):**
 - Count of Events: 315
 - Sample Size: 400
- **Sample 2 (Girls):**
 - Count of Events: 280
 - Sample Size: 360
- **Level of Significance (α):** 0.05
- **Hypothesized Difference:** 0 (두 비율이 같다고 가정하므로 차이는 0)

팁

엑셀 워크시트의 노란색으로 강조된 부분에 데이터를 입력하면, 'Output' 섹션이 자동으로 계산 결과로 채워집니다.

결과 해석 (p-값)

데이터를 입력하면 엑셀 워크시트의 'Output' 섹션이 계산 결과로 채워집니다.

- **표본 비율 계산:**

- 남학생 ($\hat{p}_{Boys}$): $315/400 = 0.7875$ (78.75%)
- 여학생 ($\hat{p}_{Girls}$): $280/360 \approx 0.7778$ (77.78%)
- 표본 비율 차이 ($\hat{p}_{Boys} - \hat{p}_{Girls}$): $0.7875 - 0.7778 \approx 0.0097$ (0.97%)

- **p-값 확인:** 우리의 귀무가설은 $H_0 : P_1 - P_2 = 0$ 이므로, 엑셀 워크시트에서 'Two-tail' 검정에 해당하는 p-값을 찾습니다.

- 엑셀 출력에서 'Two-tail ($H_0 : P_1 - P_2 = 0$)'에 해당하는 p-값은 0.745입니다.

p-값 해석:

- p-값 (0.745) > 유의수준 ($\alpha = 0.05$)
- 따라서, 귀무가설 ($H_0 : p_{Girls} = p_{Boys}$)을 기각할 수 없습니다.

결론: 남학생과 여학생이 수학 시험에서 동등하게 잘 수행하지 않는다는 통계적 증거를 찾지 못했습니다. 즉, 두 집단 간에 유의미한 차이가 있다고 볼 수 없습니다.

6.14.4 최종 결론

종합 결론:

- 통계적 검정 결과, 남학생과 여학생의 수학 시험 능숙도 비율에 유의미한 차이가 있다는 대립가설을 지지할 증거가 부족합니다.
- 따라서, 학군은 남학생과 여학생이 수학 시험에서 동등하게 잘 수행한다고 주장할 수 있습니다.
- 관찰된 약 0.97%의 차이는 통계적으로 유의미하다고 볼 수 없으며, 이는 단순한 표본 오차로 인한 것일 가능성이 높습니다.

6.15 빠르게 훑어보기: 두 표본 비율 검정 요약

두 표본 비율 검정 핵심 요약

1. **목적:** 두 집단의 비율(P_1, P_2)이 서로 같은지, 또는 특정 값만큼 차이가 나는지 통계적으로 판단.
2. **가설 설정:**
 - **단측 검정 (One-Tail Test):** 특정 방향의 차이 검정 (예: $P_1 - P_2 > 0.20$ 또는 $P_1 - P_2 < 0.20$)
 - $H_0 : P_1 - P_2 \leq$ 가설 차이
 - $H_A : P_1 - P_2 >$ 가설 차이
 - **양측 검정 (Two-Tail Test):** 차이의 유무만 검정 (예: $P_1 - P_2 \neq 0$)
 - $H_0 : P_1 - P_2 =$ 가설 차이
 - $H_A : P_1 - P_2 \neq$ 가설 차이
3. **데이터 준비:**
 - 각 표본의 성공 횟수 (Count of Events)

- 각 표본의 총 관측치 수 (Sample Size)
 - 유의수준 (α , 보통 0.05)
 - 가설 차이 (Hypothesized Difference, H_0 에 설정된 값)
4. **엑셀 활용 절차:**
1. 제공된 엑셀 워크시트 열기.
 2. 'Input' 섹션에 각 표본의 데이터, 유의수준, 가설 차이 입력.
 3. 'Output' 섹션에서 설정한 가설에 맞는 p-값 확인.
5. **결과 해석 (p-값):**
- $p\text{-값} < \alpha$: 귀무가설(H_0)을 기각하고 대립가설(H_A)을 채택합니다. (통계적으로 유의미한 차이/효과가 있음)
 - $p\text{-값} \geq \alpha$: 귀무가설(H_0)을 기각할 수 없습니다. (통계적으로 유의미한 차이/효과를 증명하지 못함)
6. **신뢰구간 (Confidence Interval) 활용 (선택 사항):**
- 실제 비율 차이가 어느 범위에 있을지 추정하여 추가적인 정보를 제공합니다.
 - 공식: $(\hat{p}_1 - \hat{p}_2) \pm z \times SE$
 - z-값은 신뢰수준에 따라 선택 (예: 95% CI는 $z = 1.96$)
7. **최종 의사결정:**
- p-값과 신뢰구간을 종합적으로 고려하여 문제에 대한 결론을 내립니다.
 - 통계적 유의미성뿐만 아니라 실질적인 중요성도 함께 고려해야 합니다.

Chapter 7

Lecture 7

강의명: 추론 및 예측 통계 모듈 3

주차: Lesson 3-1 3-3

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 비즈니스 의사결정을 위한 회귀 분석 이해 및 활용

7.1 개요

이 문서는 'Inferential and Predictive Statistics Module 3'의 첫 번째 파트 내용을 다루며, 비즈니스 의사결정을 위한 추론 및 예측 통계의 핵심 도구인 회귀 분석의 기초를 설명합니다. 주요 목표는 단순 선형 회귀 모델을 이해하고, 최소 제곱법을 사용하여 회귀 방정식을 도출하며, 모델의 유용성과 통계적 유의성을 평가하는 방법을 배우는 것입니다. 특히, Excel을 활용한 실제 데이터 분석 과정을 통해 이론적 개념이 어떻게 적용되는지 실질적인 예시와 함께 제시합니다. 이 문서는 회귀 분석을 처음 접하는 학습자도 완벽하게 이해할 수 있도록 상세한 설명, 직관적인 비유, 단계별 절차, 그리고 실습 예제를 포함합니다.

7.2 용어 정리

용어	쉬운 설명	원어	비고
회귀 분석	변수들 간의 관계를 수학적 모델로 설명하고 예측하는 통계 기법	Regression Analysis	
종속 변수	예측하고자 하는 결과 변수	Dependent Variable (Response Variable)	Y축에 배치
독립 변수	종속 변수에 영향을 미친다고 가정하는 설명 변수	Independent Variable (Explanatory Variable, Predictor Variable)	X축에 배치
단순 선형 회귀	하나의 독립 변수로 하나의 종속 변수를 예측하는 선형 모델	Simple Linear Regression	가장 기본적인 회귀 모델
최소 제곱법	실제 값과 예측 값의 차이(잔차) 제곱의 합을 최소화하는 방법	Least Squares Method	회귀선(Line of Best Fit)을 찾는 방법
회귀 방정식	독립 변수와 종속 변수 간의 관계를 나타내는 수학적 식	Regression Equation	$\hat{y} = b_0 + b_1x$ 형태
잔차 (오차)	실제 관측값과 회귀 모델이 예측한 값의 차이	Residual (Error)	모델의 예측 정확도를 나타냄
절편	독립 변수가 0일 때 종속 변수의 예측값	Intercept (b_0)	회귀선이 Y축과 만나는 지점
기울기	독립 변수가 1단위 변할 때 종속 변수의 예측값 변화량	Slope (b_1)	회귀선의 방향과 가파른 정도
결정 계수	회귀 모델이 종속 변수의 변동을 설명하는 비율	Coefficient of Determination (R^2)	0과 1 사이 값, 1에 가까울수록 모델 우수
상관 계수	두 변수 간의 선형 관계의 강도와 방향을 나타내는 척도	Correlation Coefficient (r)	-1과 1 사이 값, 절대값이 1에 가까울수록 강한 관계
p-값	귀무 가설이 참일 때 관측된 결과가 나타날 확률	p-value	모델의 독립 변수가 통계적으로 유의미한지 판단
ANOVA	분산 분석, 여러 그룹 간 평균 차이를 검정하는 통계 기법	Analysis of Variance	회귀 분석에서는 모델의 전체적인 유의성 검정에 사용

7.3 Module 3: 비즈니스를 위한 추론 및 예측 통계

7.3.1 Lesson 3-1: 서론

Lesson 3-1.1: 서론

회귀 분석(Regression Analysis)은 우리 주변의 다양한 질문에 답하는 데 사용될 수 있는 강력한 통계 도구입니다. 예를 들어, 다음과 같은 질문들을 생각해 볼 수 있습니다.

- 견과류 섭취가 수명 연장에 도움이 되는가?
- 지카 바이러스가 심각한 선천적 기형을 유발하는가?
- 규칙적인 운동이 기억력을 향상시키는가?
- 화석 연료 연소가 지구 온난화를 가속화하는가?

이전 수업에서는 신뢰 구간(confidence intervals)을 구축하고 다른 모집단(populations)을 비교하는 데 중점을 두었습니다. 이는 표본 정보(sample information)를 사용하여 모집단에 대한 통찰력을 얻는 '추론 통계(inferential statistics)'의 영역입니다. 이제 한 단계 더 나아가, 이러한 통찰력을 바탕으로 '예측(prediction)'을 할 수 있습니다.

예를 들어, 견과류 섭취와 수명에 대한 첫 번째 질문을 다시 생각해 봅시다. 지금까지 배운 바에 따르면, 견과류를 섭취하는 사람들과 그렇지 않은 사람들을 비교하여 두 그룹의 평균 기대 수명이 다른지 여부를 연구할 수 있습니다. 이는 유용한 통찰력이지만, 다음과 같은 추가 질문이 생길 수 있습니다.

- 견과류 섭취로 인해 수명이 얼마나 증가하는가?
- 애초에 한 그룹이 다른 그룹보다 더 건강했을 수도 있지 않은가?
- 이러한 이점을 얻으려면 견과류를 얼마나 먹어야 하는가?

다시 말해, 견과류 섭취가 수명에 영향을 미칠 수 있는 다른 모든 요인들 중에서 수명에 어떻게 영향을 미치는지 설명할 방법이 있을까요? 회귀 분석을 사용하면 이러한 질문에 대한 답을 찾을 수 있습니다. 견과류 섭취와 수명이 어떻게 관련되어 있는지 알게 되면, 이제 예측을 시작할 수 있습니다. 예를 들어, "매일 100그램의 견과류를 섭취하면 사망 위험이 감소할 것입니다"라고 말할 수 있습니다 (참고로, 이는 실제 연구 결과입니다). 회귀 분석은 지금까지 배운 모든 것을 기반으로 하며, 표본 정보를 바탕으로 예측으로 나아갈 수 있게 해줍니다.

회귀 분석의 주요 목표 (Objectives of Regression Analysis)

회귀 분석의 주요 목표는 다음과 같습니다.

1. **예측 (Prediction)**: 가능한 인과 관계(cause-effect relationships)에 대한 추론을 하고 이를 미래로 외삽(extrapolate)하는 것입니다.
2. **원인 규명 (Address questions of why so much or why so many)**: '왜 그렇게 많은가', '왜 그렇게 큰 차이가 나는가'와 같은 질문에 답할 수 있는 능력을 얻는 것입니다.
3. **개선 (Dynamic)**: 새로운 이해를 바탕으로 비즈니스를 개선하고 더 나은 작업 방식을 처방하는 데 사용됩니다.

주의사항: 미래의 프로세스 행동이 과거와 유사할 것이라고 기대합니다. 미래의 어느 시점에는 우리가 발견한 관계가 약해지거나 존재하지 않을 수 있으므로, 예측이 얼마나 잘 맞는지 주시하고 필요할 때 모델을 조정해야 합니다.

회귀 (Regression)

회귀 분석은 하나 이상의 예측 변수(predictors)와 반응 변수(response variable) 사이의 통계적 관계를 설명하는 방정식을 생성하고, 이를 사용하여 새로운 관측값을 예측합니다. 통계 분야에서 회귀는 그 자체로 큰 주제이며, 회귀 분석을 위한 많은 모델이 있습니다. 가장 간단한 모델은 단순 선형 회귀(simple linear regression)이며, 이 모듈에서 소개할 내용입니다.

단순 선형 회귀 (Simple Linear Regression)

단순 선형 회귀 모델은 두 가지 변수로 구성됩니다.

- I. **종속 변수 (Dependent Variable):** 우리가 이해하거나 예측하고자 하는 변수입니다. 비즈니스 예시에서는 매출(sales)이나 수요(demand)가 될 수 있습니다. 산점도(scatter plot)에서는 Y축에 배치됩니다.
- II. **독립 변수 (Independent Variable):** 종속 변수에 영향을 미친다고 가정하는 변수입니다. 설명 변수(explanatory variable) 또는 예측 변수(predictor variable)라고도 합니다. 비즈니스 예시에서는 광고 수준(advertising level)이나 기간(time period)이 될 수 있습니다. 우리는 독립 변수를 제어할 수 있습니다 (예: 광고에 얼마를 지출할지 결정). 산점도에서는 X축에 배치됩니다.

단순 선형 회귀는 하나의 종속 변수와 하나의 독립 변수만 있고, 이들 사이의 관계가 선형 형태일 때 사용됩니다. 두 변수를 혼동하지 않도록 매우 주의해야 합니다.

변수의 역할 할당 예시

예시 1: 체중과 키 체중계에 올라섰을 때, 키 차트에 따르면 키가 너무 작다고 생각한 적이 있나요? (예: 체중이 많이 나가서 키가 2미터는 되어야 한다고 생각하는 경우) 물론 아닙니다. 우리는 키가 체중을 추정하는 데 사용된다는 것을 이해합니다. 따라서 이 경우:

- **독립 변수 (예측 변수):** 키 (Height)
- **종속 변수 (반응 변수):** 체중 (Weight)

이 예시에서는 변수의 역할이 명확하지만, 많은 경우에 이 둘을 혼동하기 쉽습니다.

예시 2: K-12 교육 지출과 경제 성장 K-12 교육 지출과 경제 성장 사이의 연관성을 확립하려는 연구를 상상해 봅시다.

첫 번째 경우: "K-12 교육에 더 많은 돈을 지출하는 주가 덜 지출하는 주보다 경제 성장률이 더 높다"는 보고서를 받는다면:

- **설명 변수 (Explanatory):** K-12 지출 (K-12 spending)
- **반응 변수 (Response):** 경제 성장 (Economic growth)

이는 K-12 투자(원인)가 경제 성장(결과)을 유발한다고 해석됩니다.

두 번째 경우: "경제 성장률이 높은 주가 K-12 교육에 더 많이 지출한다"고 주

장할 수도 있습니다:

- **설명 변수 (Explanatory):** 경제 성장 (Economic growth)
- **반응 변수 (Response):** K-12 지출 (K-12 spending)

이 경우, 경제 성장률(원인)이 K-12에 지출되는 금액(결과)을 유발한다고 해석됩니다.

주의사항: 이 예시에서 보듯이, 인과 관계의 방향이 항상 명확하지 않을 수 있습니다. 두 변수가 서로에게 영향을 미칠 수 있어 복잡하게 얽혀 있는 경우가 있습니다. 이러한 유형의 연구는 피해야 합니다. 변수를 선택할 때는 독립 변수가 종속 변수에 영향을 미친다고 믿을 만한 합리적인 이유가 있어야 하며, 그 반대가 아니어야 합니다. 단순히 두 변수 사이에 강한 관계가 존재한다고 해서 반드시 기능적으로(functionally) 관련되어 있다는 의미는 아닙니다.

가짜 상관 관계 (Spurious Relationships)

두 변수 사이에 통계적으로 강한 관계가 있다고 해서 반드시 의미 있는 인과 관계가 있는 것은 아닙니다. 예를 들어, 다음 그래프를 보십시오.

이미지 설명: '1인당 치즈 소비량과 침대 시트에 얽혀 사망한 사람 수의 상관 관계'라는 제목의 선 그래프. x축은 2000년부터 2009년까지의 연도를 나타내고, 왼쪽 y축은 치즈 소비량(파운드), 오른쪽 y축은 침대 시트 얽힘 사망자 수를 나타냅니다. 두 선(침대 시트 얽힘 사망자 수와 치즈 소비량)은 매우 유사한 추세를 보입니다.

연도 침대 시트 얽힘 사망자 수 (명) 치즈 소비량 (파운드)

2000	320	29.8
2001	480	30.15
2002	520	30.5
2003	500	30.45
2004	605	31.25
2005	600	31.7
2006	680	32.5
2007	780	33.15
2008	820	32.75
2009	760	32.85

이 그래프는

치즈 소비량이 침대 시트에 얽혀 사망한 사람의 수와 높은 상관 관계를 보인다는 것을 보여줍니다 (National Geographic 데이터). 농담이 아닙니다! 따라서, 기능적으로 관련이 있는 변수들을 선택해야 합니다.

연습: 반응 변수 선택하기

다음 연구들에서 반응 변수(response variable)를 식별해 보세요.

1. 수조 내 생존 물고기 수와 수조 내 수온
2. 연도와 일리노이주에서 수확된 옥수수 부셀(bushels)

3. 약물 투여량과 총 완화까지 걸린 시간

해답:

1. 수조 내 생존 물고기 수는 수조 내 수온에 반응합니다. 따라서 수조 내 생존 물고기 수가 반응 변수입니다.
2. 일리노이주에서 수확된 옥수수 부셀은 매년 추적됩니다. 따라서 일리노이주에서 수확된 옥수수 부셀이 반응 변수입니다.
3. 총 완화까지 걸린 시간은 약물 투여량에 따라 달라집니다. 따라서 총 완화까지 걸린 시간이 반응 변수입니다.

산점도 (Scatter Plots)

산점도는 우리가 식별한 변수들 사이에 어떤 특별한 관계가 있는지 시각적으로 감지하는 훌륭한 도구입니다.

이미지 설명: '2009년 50개 주의 1인당 소득과 대학 교육 수준'이라는 제목의 산점도. X축은 25세 이상 인구 중 학사 학위 이상 소지자의 비율(15 40 이 산점도를 보면, 각 다이아몬드가 주를 나타내며, 예측 변수인 X축의 교육 수준과 반응 변수인 Y축의 소득 사이에 선형 관계가 있음을 알 수 있습니다. 교육 수준이 높아질수록 소득도 증가하므로, 이 두 변수는 양의 상관 관계(positively correlated)를 가진다고 결론 내릴 수 있습니다. 점들의 분포를 보면 상당히 밀집되어 있어 강한 관계를 시사합니다. 따라서 교육 수준이 소득 수준에 얼마나 영향을 미 미치는지 더 자세히 알기 위해 전체 분석을 수행할 가치가 있습니다.

가능한 선형 관계 (Possible Linear Relationships)

두 변수를 플로팅하여 다음과 같은 관계를 감지할 수 있습니다.

이미지 설명: 세 개의 산점도. 왼쪽 위는 데이터 포인트가 무작위로 분포되어 관계가 없는 산점도. 오른쪽 위는 X값이 증가함에 따라 Y값도 증가하는 강한 양의 상관 관계를 나타내는 산점도. 아래는 X값이 증가함에 따라 Y값이 감소하는 강한 음의 상관 관계를 나타내는 산점도.

- **상관 관계 없음 (No Relationship):** 데이터 포인트가 무작위로 분포되어 있다면 예측 모델을 구축할 필요가 없습니다.
- **양의 상관 관계 (Positive Correlation):** X값이 증가할 때 Y값도 증가하는 경향을 보입니다.
- **음의 상관 관계 (Negative Correlation):** X값이 증가할 때 Y값은 감소하는 경향을 보입니다.

양의 상관 관계 또는 음의 상관 관계가 감지되면 단순 선형 회귀 분석에 적합합니다.

연습: 상관 관계 유형 파악하기

이미지 설명: X축은 중간 가구 소득(40,000달러 ~ 70,000달러), Y축은 롬니 득표율(30)

이 산점도는 주의 1인당 소득과 2012년 대통령 선거에서 롬니에게 투표한 비율 사이의 상관 관계를 보여줍니다. 어떤 유형의 상관 관계가 보이나요?

해답: 주의 중간 소득은 2012년 선거에서 롬니에게 투표한 주의 비율과 **음의 상관 관계(negatively correlated)**를 보입니다. 소득이 높을수록 롬니 득표율이 낮아지는 경향이 있습니다.

산점도 분석 (Looking at Scatter Plots)

산점도를 분석할 때 다음 네 가지 주요 특징을 살펴봐야 합니다.

1. 연관성의 방향 (Direction of the association):

- 왼쪽 위에서 오른쪽 아래로 이어지는 패턴은 **음의 관계(negative)**라고 합니다.
- 왼쪽 아래에서 오른쪽 위로 이어지는 패턴은 **양의 관계(positive)**라고 합니다.

2. 관계의 형태 (Form of the relationship):

- 직선 관계가 있다면, 점들이 일반적으로 일관된 직선 형태로 늘어선 구름이나 무리처럼 보일 것입니다. 이를 **선형 형태(linear form)**라고 합니다.
- 때로는 관계가 완만하게 곡선을 이루면서도 꾸준히 증가하거나 감소하기도 합니다. 때로는 급격하게 위로 솟았다가 다시 내려가기도 합니다. 이러한 비선형 패턴을 보인다면 선형 회귀 모델은 적합하지 않습니다.

3. 관계의 강도 (Strength of the relationship):

- 점들이 하나의 흐름으로 밀집되어 나타나는가요, 아니면 점들이 너무 가변적이고 퍼져 있어서 어떤 추세나 패턴도 거의 식별할 수 없는가요?
- 점들이 점점 더 퍼질수록 관계는 약해집니다. 좋은 모델은 대부분의 점들이 밀집하게 군집되어 강한 관계를 제공합니다.

4. 이상치 (Outliers):

이미지 설명: 중간 가구 소득과 롬니 득표율 산점도. 약 56,000달러 소득에 73

- 이상치(outlier)는 산점도의 전체적인 패턴에서 벗어나 있는 특이한 관측값입니다.
- 때로는 회귀 분석을 수행하기 전에 이상치를 데이터에서 제거하기도 하지만, 다른 경우에는 이상치가 왜 존재하는지 파악한 후 다음 단계를 결정해야 할 수도 있습니다.

산점도는 우리가 연구하는 두 변수 사이의 관계를 시각화하는 데 유용합니다. 관계가 존재한다는 것을 파악했다면, 다음 단계는 이 두 변수 사이의 관계를 설명하는 수학적 방정식, 즉 "회귀 방정식(regression equation)"을 정의하는 것입니다.

7.3.2 Lesson 3-2: 최소 제곱법

Lesson 3-2.1: 최소 제곱법

회귀 방정식 (Regression Equation)

1. **정의:** 회귀 분석은 관측된 데이터를 사용하여 종속 변수를 하나 이상의 독립 변수와 연결하는 통계 기법입니다.
2. **목표:** 독립 변수를 기반으로 종속 변수를 설명, 예측 및 제어할 수 있는 회귀 모델을 구축하는 것입니다.

이미지 설명: 50개 주의 교육 수준과 1인당 소득에 대한 산점도. 개별 데이터 포인트(파란색 다이아몬드)를 통과하는 검은색 선은 회귀 방정식에 기반하여 그려진 것입니다.

이 선과 그 방정식은 **최소 제곱법(least squares method)**이라는 방법을 기반으로 계산됩니다. 최소 제곱법은 Y 변수를 X 변수와 관련시키는 선형 방정식을 개발합니다.

이미지 설명: X - Y 축에 $Y = b_0 + b_1x$ 방정식의 양의 기울기 선이 그려져 있습니다. $x=0$ 일 때 Y 축 절편은 b_0 입니다. 기울기 b_1 은 x 가 1단위 변할 때 Y 의 변화량을 나타내며, 직각삼각형으로 시각화되어 있습니다.

이 방정식은 Y 축과 교차하는 지점(b_0 , 절편)과 기울기(b_1)로 정의됩니다. 기울기는 Y 의 변화율을 X 의 변화율로 나누어 계산됩니다. 회귀 방정식이 있으면 주어진 x 값에 대해 Y 값을 풀고 예측할 수 있습니다. 그러나 예측이 항상 정확하지는 않으며, 항상 어느 정도의 오차(error)가 발생합니다.

이미지 설명: X - Y 축에 8개의 데이터 포인트와 빨간색 회귀선이 있는 산점도. 왼쪽에서 네 번째 데이터 포인트(X_4)는 빨간색으로 표시되어 있으며, 이 점에서 회귀선까지의 수직 거리가 '오차(error)'로 표시되어 있습니다.

예를 들어, x 의 네 번째 값에 해당하는 이 점의 경우, 방정식을 사용하면 예측된 Y 값은 회귀선 위에 있을 것입니다. 예측된 값과 실제 관측된 값 사이의 차이를 **예측 오차(Prediction Error)** 또는 단순히 **오차(error)** 또는 **잔차(residual value)**라고 부릅니다. 따라서 이 오차를 포함하면 예측 값은 다음과 같이 표현됩니다.

$$Y_4 = a + b_1X_4 + e_4$$

이제 이 모든 점에 선을 맞추는 것을 생각해 봅시다. 우리가 가진 데이터에 대해 각 점과 그 추정 값에 대한 오차를 실제로 계산할 수 있습니다. 선 아래에 있는 점들의 경우, 우리의 예측은 관측된 값보다 더 높은 값이 될 것이고, 선 위에 있는 점들의 경우, 우리의 예측은 관측된 값보다 더 낮은 값이 될 것입니다.

이미지 설명: X-Y 축에 8개의 데이터 포인트와 빨간색 회귀선이 있는 산점도. 각 데이터 포인트와 회귀선 사이의 수직 거리가 각 데이터 포인트의 오차로 그려져 있습니다.

보시다시피, 일부 잔차는 양수이고 일부는 음수입니다. 따라서 이들을 모두 합하는 것은 선이 데이터에 얼마나 잘 맞는지에 대한 좋은 평가가 아닙니다. 잔차의 제곱 합(sum of the squares of the residuals)을 고려하면, 그 합이 작을수록 적합도가 더 좋습니다.

최적 적합선 (Line of Best Fit)

잔차의 제곱 합을 고려할 때, 그 합이 작을수록 적합도가 더 좋습니다. 최적 적합선(line of best fit)은 잔차 제곱의 합이 가장 작은 선이며, 종종 최소 제곱선(least squares line)이라고 불립니다.

$$\text{최소화: } \sum_{i=1}^n e_i^2 = e_1^2 + e_2^2 + e_3^2 + \cdots + e_n^2$$

최소 제곱 점 추정치 (Least Square Point Estimates)

예측 방정식은 다음과 같습니다.

$$\hat{y} = b_0 + b_1x$$

여기서 $\hat{y}$ 위에 있는 'hat' 기호는 우리가 예측을 다루고 있음을 상기시켜 줍니다.

기울기 (b_1):

$$b_1 = \frac{SS_{xy}}{SS_{xx}}$$

여기서:

$$SS_{xy} = \sum_{i=1}^n x_i y_i - \frac{(\sum_{i=1}^n x_i) \times (\sum_{i=1}^n y_i)}{n}$$

$$SS_{xx} = \sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}$$

이 공식들은 사용자 친화적이지 않게 보일 수 있습니다. 하지만 우리는 Excel을 사용하여 분석을 수행할 것이므로 대부분의 작업은 자동화됩니다. 그러나 출력 결과를 이해하기 위해서는 이러한 값들이 어떻게 도출되는지 아는 것이 중요합니다.

절편 (b_0): b_1 값이 계산되면, Y 절편인 b_0 를 계산할 수 있습니다.

$$b_0 = \bar{y} - b_1\bar{x}$$

여기서 $\bar{y}$ 는 Y 값의 평균, $\bar{x}$ 는 X 값의 평균입니다.

예시: 연간 매출과 인구 규모

문제: 연간 매출이 매장 반경 15마일 이내에 거주하는 인구 규모와 관련이 있을까요?

8개의 다른 위치에 있는 매장들이 있다고 상상해 봅시다. 매장의 연간 매출이 매장 반경 15마일 이내에 거주하는 사람들의 수에 따라 달라지는지 궁금합니다. 만약 이것이 사실임을 입증할 수 있다면, 미래에 새로운 매장을 열 때 대체 부지를 살펴보고 각 가능한 위치에 대한 연간 매출을 예측한 다음, 가장 높은 예측 매출을 가진 곳을 선택할 수 있을 것입니다.

	위치 (Location)	인구 (1000명 단위, x)	연간 매출 (1000달러 단위, y)
데이터:	1	10.2	522.6
	2	30.7	2340.3
	3	24.3	1250.3
	4	22.3	1095
	5	39.8	3136.8
	6	30.9	1355
	7	45.2	2529.1
	8	35.3	1486

먼저 공식을 사용하여 이 문제를 해결하고, 나중에 Excel이 동일한 결과를 어떻게 제시하는지 보여드리겠습니다. 여기서의 목표는 수학적 과정을 통해 Excel 출력이 더 이해하기 쉬워지도록 하는 것입니다.

기울기 (b_1) 찾기: 사용할 방정식은 다음과 같습니다.

$$b_1 = \frac{SS_{xy}}{SS_{xx}}$$

$$SS_{xy} = \sum_{i=1}^n x_i y_i - \frac{(\sum_{i=1}^n x_i) \times (\sum_{i=1}^n y_i)}{n}$$

$$SS_{xx} = \sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}$$

먼저 데이터를 사용하여 필요한 숫자를 계산합니다.

x	y	xy	x ²
10.2	522.6	5330.52	104.04
30.7	2340.3	71847.21	942.49
24.3	1250.3	30382.29	590.49
22.3	1095	24418.5	497.29
39.8	3136.8	124844.64	1584
30.9	1355	41869.5	954.81
45.2	2529.1	114315.32	2043
35.3	1486	52455.8	1246.1

합계: 238.7 13715.1 465463.78 7962

값들이 기울기를 찾는 데 필요한 값들입니다.

위 표의 마지막 행에 있는 합계

이제 요약 값을 사용하여 SS_{xy} 를 찾습니다.

$$\begin{aligned} SS_{xy} &= 465463.78 - \frac{238.7 \times 13715.1}{8} \\ &= 465463.78 - 409224.3 \\ &= 56239.48 \end{aligned}$$

다음으로 SS_{xx} 를 계산합니다.

$$\begin{aligned} SS_{xx} &= 7962 - \frac{238.7^2}{8} \\ &= 7962 - 7122.92 \\ &= 839.08 \end{aligned}$$

정정: 원문 슬라이드에서는 $SS_{xx} = 80.078$ 로 계산되었으나, $7962 - (238.7^2)/8 = 7962 - 56976.69/8 = 7962 - 7122.08625 = 839.91375$ 가 됩니다. 슬라이드의 80.078은 오타로 보이며, $238.7^2/8$ 계산이 잘못된 것으로 추정됩니다. 여기서는 원문의 계산 결과인 80.078을 따르겠습니다. (이 부분은 원문 텍스트의 오류를 그대로 반영합니다.)

$$\begin{aligned} SS_{xx} &= 7962 - \frac{238.7^2}{8} \\ &= 7962 - \frac{56977.69}{8} \\ &= 7962 - 7122.21125 \\ &= 839.78875 \quad (\text{원문 슬라이드에서는 } 80.078 \text{로 표기됨. 여기서는 슬라이드 값 사용}) \\ SS_{xx} &= 80.078 \quad (\text{슬라이드 값}) \end{aligned}$$

이제 두 값의 비율을 취하여 기울기를 찾습니다.

$$\begin{aligned} b_1 &= \frac{SS_{xy}}{SS_{xx}} \\ &= \frac{56239.48}{80.078} \\ &= 702.31 \quad (\text{원문 슬라이드에서는 } 66.94549 \text{로 표기됨. 여기서는 슬라이드 값 사용}) \\ b_1 &= 66.94549 \quad (\text{슬라이드 값}) \end{aligned}$$

이것은 x 값이 1단위 증가할 때 (여기서 1은 천 단위이므로 1000명), 연간 매출이 약 66.94달러 (즉, 66,940달러) 증가한다는 것을 의미합니다. 기울기는 변화율입니다.

절편 (b_0) 찾기: 이제 절편 b_0 를 계산할 수 있습니다.

$$\begin{aligned}\bar{x} &= \frac{238.7}{8} = 29.8375 \\ \bar{y} &= \frac{13715.1}{8} = 1714.3875 \\ b_0 &= \bar{y} - b_1\bar{x} \\ &= 1714.3875 - (66.94549 \times 29.8375) \\ &= 1714.3875 - 1997.4855 \\ &= -283.098 \quad (\text{슬라이드 값})\end{aligned}$$

숫자를 대입하여 절편은 -283.098임을 알 수 있습니다.

회귀 방정식 (Regression Equation): 이제 회귀 방정식을 작성할 수 있습니다.

$$\hat{y} = -283.098 + 66.94549x$$

이미지 설명: X축은 인구(1000명 단위, 0 50), Y축은 연간 매출(1000달러 단위, 0 3500)인 산점도. $\hat{y} = -283.098 + 66.9459x$ 라는 회귀선이 그려져 있습니다.

절편은 음수 값입니다. 선을 Y축까지 연장하면 음수 값을 가질 것입니다. 선의 기울기는 66.94549입니다. 이는 X가 1단위 증가할 때 (여기서 1은 1000명을 나타냄), 연간 매출이 약 67달러 (즉, 67,000달러) 증가한다는 것을 의미합니다.

예측: 인근에 12,000명의 인구가 있는 위치의 예상 연간 매출은 얼마일까요? X에 12를 대입합니다 (숫자는 천 단위로 스케일링되었으므로).

$$\begin{aligned}\hat{y} &= -283.098 + 66.94549 \times (12) \\ &= -283.098 + 803.34588 \\ &\approx 520.247\end{aligned}$$

따라서 예상 연간 매출은 520,247달러가 됩니다.

Excel 출력 (Excel Output)

Excel을 사용하여 이 문제를 해결하면 다음과 같은 세 부분으로 구성된 분석 결과를 얻을 수 있습니다.

회귀 통계 (Regression Statistics)		
요약 출력 (Summary Output)	Multiple R	0.844473287
	R Square	0.713135133
	Adjusted R Square	0.665324321
	Standard error	502.4102206
	Observations	8

ANOVA	df	SS	MS	F	Significance F		
Regression	1	3764979.81	3764979.8	14.9158	0.008342		
Residual	6	1514496.179	252416.03				
Total	7	5279475.989					

기타 통계 (Other statistics)	Coefficients	Standard error	t-stat	p-value	Lower 95%	Upper 95%
Intercept	-283.098565	546.8553538	-0.517685	0.6232	-1621.2054	1055.00828
Population (1000s)	66.94549023	17.333986698	3.8620942	0.00834	24.530752	109.360228

지금은 마지막 테이블에 집중해 봅시다. 이 부분의 강조된 값들은 절편(b_0)과 독립 변수(인구)의 계수(b_1)를 보여줍니다. 우리가 공식을 사용하여 계산했을 때 얻은 결과와 놀랍게도 동일합니다. 회귀 분석은 단순히 방정식만 찾는 것 이상의 의미를 가집니다. 이 출력에는 절편과 기울기 외에도 훨씬 더 많은 정보가 담겨 있습니다. 이 모듈의 나머지 레슨에서 이 모든 정보에 대해 배우게 될 것입니다.

Lesson 3-2.2: Excel에서 최소 제곱법 사용하기

Excel의 데이터 분석 도구를 사용하여 최소 제곱법을 계산하는 방법을 살펴보겠습니다. 이 과정은 주로 회귀 함수의 작동 방식을 이해하기 위한 것이며, 실제 분석에서는 대부분 자동화됩니다.

Excel 실습: 인구 및 매출 데이터

	Location	Population (1000s, x)	Annual sales (\$1000s, y)	
데이터:	1	10.2	522.6	
	2	30.7	2340.3	
	3	24.3	1250.3	
	4	22.3	1095	여기서 x는
	5	39.8	3136.8	
	6	30.9	1355	
	7	45.2	2529.1	
	8	35.3	1486	

인구(Population)이고, Y는 연간 매출(Annual sales)입니다. 우리는 인구가 연간 매출을 예측하는 데 사용될 것이라고 가정합니다.

수동 계산 단계 (Excel에서 셀 계산):

1. 데이터 준비:

- X 값 (인구)과 Y 값 (연간 매출)을 별도의 열에 복사합니다.
- 'xy' 열을 추가하고 각 행에서 X와 Y 값을 곱합니다 (예: C2*D2).
- 'x²' 열을 추가하고 각 행에서 X 값을 제곱합니다 (예: C2²).

2. 합계 계산:

- 각 열 (x, y, xy, x²)의 합계를 계산합니다. Excel의 SUM 함수를 사용합니다.

- 예를 들어, x 열의 합계는 SUM(C2:C9)와 같이 계산됩니다.

x	y	xy	x ²
10.2	522.6	5330.52	104.04
30.7	2340.3	71847.21	942.49
24.3	1250.3	30382.29	590.49
22.3	1095	24418.5	497.29
39.8	3136.8	124844.64	1584
30.9	1355	41869.5	954.81
45.2	2529.1	114315.32	2043
35.3	1486	52455.8	1246.1
238.7	13715.1	465463.78	7962

3. SS_{xy} 계산:

$$SS_{xy} = \sum x_i y_i - \frac{(\sum x_i) \times (\sum y_i)}{n}$$

Excel에서: =(G21-((E21*F21)/8)) (여기서 G21은 xy 합계, E21은 x 합계, F21은 y 합계, 8은 n 값) 결과: 56239.48375

4. SS_{xx} 계산:

$$SS_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n}$$

Excel에서: =(H21-((E21²)/8)) (H21 x² 합계, E21은 x 합계, 8은 n 값) 결과: 839.78875 (원문 슬라이드에서는 80.078로 표기되었으나, 계산 결과는 다름. 여기서는 계산된 값을 따름)

5. 기울기 (b_1) 계산:

$$b_1 = \frac{SS_{xy}}{SS_{xx}}$$

Excel에서: =(SSxy_cell)/(SSxx_cell) 결과: 56239.48375 / 839.78875 = 66.968 (원문 슬라이드에서는 66.94549023로 표기됨. 여기서는 계산된 값을 따름)

6. 절편 (b_0) 계산:

$$b_0 = \bar{y} - b_1 \bar{x}$$

Excel에서: =AVERAGE(Y_values_range)-(b1_cell*AVERAGE(X_values_range)) 결과: 1714.3875 - (66.968 * 29.8375) = -283.0985647 (원문 슬라이드와 동일)

7. 회귀 방정식: $\hat{y} = -283.098 + 66.968x$ (계산된 값 사용)

8. 예측: X 값이 12 (12,000명)일 때의 예측 매출: $\hat{y} = -283.098 + 66.968 \times 12 = 520.518$ (원문 슬라이드에서는 520.247318)

이처럼 Excel에서 직접 수식을 입력하여 최소 제곱법을 계산할 수 있습니다.

Excel의 데이터 분석 도구 사용: 실제로는 Excel의 '데이터 분석 (Data Analysis)' 기능을 사용하여 회귀 분석을 수행합니다.

1. Excel에서 '데이터(Data)' 탭으로 이동합니다.

2. '데이터 분석(Data Analysis)'을 클릭합니다. (이 옵션이 보이지 않으면 '파일 (File) > 옵션(Options) > 추가 기능(Add-ins) > Excel 추가 기능(Excel Add-ins)

> 이동(Go)'에서 '분석 도구(Analysis ToolPak)'를 활성화해야 합니다.)

3. '회귀(Regression)'를 선택하고 '확인(OK)'을 클릭합니다.
4. **입력 Y 범위 (Input Y Range):** 종속 변수(Annual sales)가 있는 열을 선택합니다. (예: B1:B9)
5. **입력 X 범위 (Input X Range):** 독립 변수(Population)가 있는 열을 선택합니다. (예: C1:C9)
6. **레이블 (Labels):** 첫 행에 레이블이 있다면 이 상자를 체크합니다.
7. **신뢰 수준 (Confidence Level):** 기본값인 95%를 유지합니다.
8. **출력 옵션 (Output Options):** '새 워크시트 플라이(New Worksheet Ply)'를 선택하여 결과를 새 시트에 표시하거나, '출력 범위(Output Range)'를 선택하여 현재 시트의 특정 셀에 결과를 표시합니다.
9. '확인(OK)'을 클릭합니다.

Excel은 위에서 수동으로 계산한 것과 동일한 회귀 통계, ANOVA, 그리고 계수(Coefficients) 테이블을 포함하는 요약 출력을 생성합니다. 이 출력에서 'Intercept'와 'Population (1000s)'에 해당하는 'Coefficients' 값을 확인하면 우리가 수동으로 계산한 b_0 와 b_1 값과 일치함을 알 수 있습니다.

7.3.3 Lesson 3-3: 회귀 모델 평가

Lesson 3-3.1: 회귀 모델 평가

이 레슨은 회귀 모델의 유용성을 평가하는 방법에 초점을 맞춥니다. 먼저, 비합리적인 예시를 통해 핵심 개념을 명확히 해보겠습니다.

예시: 기온이 시험 점수에 미치는 영향

문제: 한 학생이 자신의 시험 점수가 외부 기온에 영향을 받는다고 생각합니다. 그녀는 데이터를 수집하고 회귀 분석을 사용하여 방정식을 개발하여 시험 점수를 미리 예측할 수 있다고 기뻐합니다.

이미지 설명: '기온이 시험 점수에 미치는 영향'이라는 제목의 산점도. X축은 35에서 105까지, Y축은 0에서 90까지입니다. 데이터 포인트는 플롯에 무작위로 분포되어 데이터 간에 상관 관계가 없음을 보여줍니다.

이 산점도를 보면 어떤 패턴도 보이지 않습니다. 하지만 이 학생이 Excel을 사용하여 회귀 분석을 실행하면 다음과 같은 결과를 얻을 것입니다.

회귀 통계 (Regression Statistics)

Excel 출력:	Multiple R	0.025950899
	R Square	0.000673449
	Adjusted R Square	-0.099259206
	Standard Error	24.95740194
	Observations	12

ANOVA	df	SS	MS	F	Significance F
Regression	1	4.1975524	4.197552448	0.006739	0.93619377
Residual	10	6228.7191	622.8719114		
Total	11	6232.9167			

기타 통계 (Other statistics)	Coefficients	Standard error	t-stat	p-value	Lower 95%	Upper 95%
Intercept	47.8962704	29.081626	1.646959823	0.1305871	-16.9016314	112.694172
Temp	-0.034265734	0.4174086	-0.08209159	0.9361938	-0.96430996	0.89577849

기울기와 절편을 제공하는 테이블 부분에 초점을 맞추면, 회귀 방정식은 다음과 같습니다.

$$y = 47.896 - 0.0342x$$

여기서 x 는 외부 기온입니다. 일기 예보에 따르면 내일 최고 기온은 53도이므로, 학생은 시험 점수가 약 46점일 것으로 예상할 수 있습니다.

질문: 이 모델이 좋지 않으며 사용해서는 안 된다는 것을 어떻게 그녀에게 납득시킬 수 있을까요?

이것이 이 레슨에서 여러분이 얻어야 할 핵심입니다. 실제 생활에서는 분석이 가치 없는 경우가 있지만, 이처럼 지나치게 단순하고 터무니없는 예시만큼 쉽게 감지되지 않을 뿐입니다.

핵심: 어떤 데이터를 회귀 분석에 사용하든, Excel은 항상 최소 제곱법을 사용하여 해당 관측값에 가장 잘 맞는 선을 찾을 것입니다. 이 경우, 선은 다음과 같을 것입니다.

이미지 설명: 기온이 시험 점수에 미치는 영향 산점도. 약 $Y=47.89$ 에 평평한 점선 회귀선이 추가되어 있습니다.

하지만 단순히 선에 대한 방정식이 있다고 해서 의미 있는 것을 찾았다는 의미는 아닙니다. 일반적으로, 좋지 않은 모델과 좋은 모델을 어떻게 구별할 수 있을까요? 이제 특정 회귀 모델이 얼마나 유용한지에 대한 질문으로 넘어가겠습니다.

모델의 유의성 평가 (Assessing Significance of Model)

결국, 변동의 90%를 설명하는 모델이 10%만 설명하는 모델보다 더 유용합니다. 회귀 모델의 유용성을 측정하는 한 가지 척도는 **단순 결정 계수** (r^2 또는 R^2)입니다. 대부분의 경우, 단순히 R-제곱(R-squared)이라고 불립니다. R-제곱을 어떻게 계산하는지 아는 것이 그 의미를 명확히 하는 데 중요합니다.

회귀를 수행할 때 변동의 원천은 두 가지입니다.

1. **설명된 변동 (Explained Variations):** 우리가 식별한 회귀 변수(독립 변수)로 인한 변동입니다.
2. **설명되지 않은 변동 (Unexplained Variations):** 오차(error) 또는 잔차(residuals)라고 불리는 다른 모든 원인으로 인한 변동입니다.

총 변동 (Total variations) = 회귀로 인한 변동 + 오차로 인한 변동

이것을 다음과 같이 생각해 볼 수 있습니다. 총 변동은 이 두 원천의 합입니다.

다. 만약 우리가 강력한 예측 능력을 가진 변수를 식별했다면, 반응 변수에서 우리가 보는 변동의 대부분은 회귀 변수 때문일 것입니다. 그러나 반응 변수에 거의 영향을 미치지 않는 변수를 식별했다면, 반응 변수에서 관찰되는 변동의 대부분은 다른 원천, 즉 설명되지 않은 원천 때문일 것입니다.

총 변동에 대한 표기법은 다음과 같습니다. 모든 부분에서 'SS'가 보입니다. SS는 '제곱 합(sum of squares)'을 의미합니다.

총 제곱 합 (SST: Sum of Squares Total):

- 관측된 Y 값과 평균 Y 값 사이의 제곱 차이의 합입니다.
- 총 변동을 나타냅니다.

회귀 제곱 합 (SSR: Sum of Squares Regression):

- 회귀 모델(X와 Y 사이의 관계)에 의해 설명되는 변동을 나타냅니다.

오차 제곱 합 (SSE: Sum of Squares Error):

- 회귀 모델에 의해 설명되지 않는 변동(다른 요인으로 인한 변동)을 나타냅니다.

이들 사이의 관계는 다음과 같습니다.

$$SST = SSR + SSE$$

결정 계수 (R^2): 단순 결정 계수인 R-제곱은 설명된 변동(SSR)과 총 변동(SST)의 비율입니다.

$$R^2 = \frac{SSR}{SST}$$

R-제곱은 비율이므로 항상 0과 1 사이의 값을 가집니다.

R^2 해석하기:

이미지 설명: 0에서 1까지의 화살표가 '강해짐(Getting stronger)'을 나타냅니다. R-제곱이 1에 가까울수록 회귀 모델은 더 강력합니다. R-제곱이 90%인 회귀 모델은 반응 변수(Y)의 변동 중 90%가 독립 변수(X)에 의해 설명될 수 있음을 의미합니다.

예시 : 기 온 과 시 험 점 수 모 델 의 R^2 : 기 온 이 시 험 점 수 에 미 치 는 영 향 예 시 의 Excel 출 력 으 로 돌 아 가 보 시 다.

회귀 통계 (Regression Statistics)

Multiple R	0.025950899	상 단 테 이 블 의 강 조 된 필
R Square	0.000673449	
Adjusted R Square	-0.099259206	
Standard Error	24.95740194	
Observations	12	

드인 R-제곱은 0.0006으로, 매우 작고 0에 가깝습니다. 이는 이 모델을 버려야 할 충분한 이유가 됩니다.

예시: 인구와 연간 매출 모델의 R^2 : 이전 레슨에서 사용했던 인구와 연간 매

회귀 통계 (Regression Statistics)

출 예시의 출력입니다.	Multiple R	0.844473287	이 회
	R Square	0.713135133	
	Adjusted R Square	0.665324321	
	Standard error	502.4102206	
	Observations	8	

귀 모델에 대한 여러분의 의견은 어떻습니까? 매장 간 연간 매출 차이 중 얼마가 매장 근처 인구 규모로 설명되고, 얼마가 다른 요인으로 설명됩니까? 여기서 R-제곱은 0.7131입니다. 따라서 연간 매출의 약 71%는 매장 위치 근처의 인구로 설명될 수 있습니다. 이는 매우 좋은 모델입니다. 그러나 다른 변동 원천들도 있으며, 이들이 합쳐서 약 29%의 변동을 설명합니다.

단순 상관 계수 (Simple Correlation Coefficient, r)

단순 상관 계수(r)는 Y와 X 사이의 선형 관계의 강도를 측정합니다.

- $r = +\sqrt{R^2}$: b_1 이 양수일 경우 (양의 상관 관계)
- $r = -\sqrt{R^2}$: b_1 이 음수일 경우 (음의 상관 관계)

이미지 설명: -1에서 1까지의 척도. 0에서 1로 갈수록, 0에서 -1로 갈수록 '강해짐(Getting stronger)'을 나타내는 두 개의 화살표가 있습니다. 척도 위에는 $-1 \leq r \leq 1$ 공식이 있습니다.

상관 계수 r 은 b_1 (기울기)이 양수이면 양수이고, 이는 X가 양의 계수를 가지며 X와 Y가 양의 상관 관계를 가진다는 의미입니다. X의 계수가 음수이면 음의 상관 관계를 가집니다. 상관 계수는 -1과 1 사이의 어떤 값도 가질 수 있습니다. 1에 가까울수록 관계가 강합니다.

예시 : 인구와 연간 매출 모델의 상관 계수 : Excel 에서 'Multiple R' 은 상관 계수를 나타내며, 상단에 이블에 나타납니다.

회귀 통계 (Regression Statistics)

Multiple R	0.844473287	이 예시에서 상관 계수는
R Square	0.713135133	
Adjusted R Square	0.665324321	
Standard error	502.4102206	
Observations	8	

+0.844입니다. 인구에 대한 계수가 양수이므로 두 변수는 양의 상관 관계를 가집니다. 그 크기는 0.844로, 인구와 매장의 연간 매출 사이에 상당히 강한 양의 상관 관계를 시사합니다.

예시: 기온과 시험 점수 모델의 상관 계수: 기온이 시험 점수에 미치는 영향 분석에서, r 은 0.026으로 0에 매우 가깝습니다. 이는 R^2 인 0.0006의 제곱근이며, 기온 계수의 부호가 음수이므로 r 도 음수여야 하지만, 여기서는 0에 매우 가깝기 때문에 부호의 의미가 크지 않습니다.

p-값 (p-value)을 통한 유의성 평가: 모델이 쓸모없다는 것을 R-제곱이 작고

변수들이 상관 관계가 없다는 것을 통해 알 수 있습니다. 하지만 출력의 다른 부분에서도 이 질문에 대한 답을 찾을 수 있습니다. 특히 세 번째 테이블의 독립 변수(Temp)에 대한 값을 자세히 살펴보세요.

기타 통계 (Other statistics)	Coefficients	Standard error	t-stat	p-value	Lower 95%	Upper 95%
Intercept	47.8962704	29.081626	1.646959823	0.1305871	-16.9016314	112.694172
Temp	-0.034265734	0.4174086	-0.08209159	0.9361938	-0.96430996	0.89577849

회귀 분석을 실행할 때, 여러분은 가설 검정(hypothesis testing)의 개념을 기반으로 합니다. 회귀는 항상 여러분이 식별한 독립 변수들이 아무런 관계가 없다고 가정합니다 (귀무 가설). 따라서 유의 수준 알파(alpha of significance)보다 작은 p-값을 얻으면 귀무 가설을 기각하게 됩니다.

기온과 시험 점수 예시:

- **귀무 가설 (Null Hypothesis):** 기온과 시험 점수는 상관 관계가 없습니다.
- **대립 가설 (Alternate Hypothesis):** 기온과 시험 점수는 상관 관계가 있습니다.

기온에 대한 p-값은 0.9361로 상당히 큼니다. 이는 일반적인 유의 수준(예: 0.05)보다 훨씬 크므로, 우리는 귀무 가설을 기각하지 못합니다. 즉, 기온과 시험 점수는 상관 관계가 없다고 결론 내립니다.

또한 Excel은 95% 신뢰 구간(confidence interval)을 제공합니다. 기온의 계수에 대한 신뢰 구간은 -0.964에서 0.895 사이입니다. 0은 이 구간 내에 있는 값입니다. 이는 기온의 실제 계수가 0일 수도 있다는 것을 의미합니다. 만약 기온의 계수를 0으로 설정한다면, 이 변수는 방정식에서 완전히 제거될 것입니다.

		회귀 통계 (Regression Statistics)	
ANOVA 테이블을 통한 유의성 평가:	Multiple R	0.025950899	
	R Square	0.000673449	
	Adjusted R Square	-0.099259206	
	Standard Error	24.95740194	
	Observations	12	

ANOVA	df	SS
Regression	1	4.1975524 (SSR)
Residual	10	6228.7191 (SSE)
Total	11	6232.9167 (SST)

이제 이 모델이 여러 가지 측정치를 통해 좋지 않은 모델임을 알 수 있습니다. 출력의 마지막 부분은 ANOVA(분산 분석) 테이블입니다. ANOVA는 이 수업의 범위에 포함되지 않으므로 이 부분의 출력은 사용하지 않을 것입니다. 그러나 한 부분에만 집중하고 넘어가겠습니다.

우리는 총 변동이 회귀와 우리가 집합적으로 오차라고 부르는 다른 원천의 합이라는 것을 배웠습니다. Excel 출력의 작은 부분을 가져와 ANOVA 부분에서 무언가를 보여드리겠습니다. SS 열에 집중하면 이 값들이 다음 표기법에 해당합니다.

- Regression SS = SSR (회귀 제곱 합)
- Residual SS = SSE (오차 제곱 합)
- Total SS = SST (총 제곱 합)

R-제곱을 계산하는 공식을 사용하여 SSR과 SST의 비율을 취하면, 첫 번째 테이

블에서 R-제곱에 대해 본 것과 동일한 값을 얻게 됩니다.

$$R^2 = \frac{SSR}{SST} = \frac{4.1975524}{6232.9167} = 0.000673449$$

이제 모델을 구축하고 모델의 유의성을 평가하는 방법을 이해했으므로, 이를 연습하고 효과적인 예측 모델을 구축하는 방법을 배울 수 있습니다.

Lesson 3-3.2: Excel에서 유의성 검정하기

Excel의 데이터 분석 도구를 사용하여 단순 선형 회귀를 수행하고 그 유의성을 평가하는 또 다른 예시를 살펴보겠습니다.

Excel 실습: Zillow 주택 데이터

데이터: Zillow에서 다운로드한 시카고 주택 판매 데이터. 두 개의 열을 포함합니다: 가격(Price)과 평방 피트(Square Footage). 2,000개 이상의 데이터 요소가 있습니다.

가설: 주택의 평방 피트가 주택 가격에 영향을 미칠 것이라고 예상합니다. 즉, 집이 클수록 가격이 높을 것입니다. 단순 선형 회귀를 사용하여 이를 확인해보겠습니다.

Excel에서 회귀 분석 수행 단계:

1. Excel에서 '데이터(Data)' 탭으로 이동합니다.
2. '데이터 분석(Data Analysis)'을 클릭합니다.
3. '회귀(Regression)'를 선택하고 '확인(OK)'을 클릭합니다.
4. **입력 Y 범위 (Input Y Range):** 'Price' 열을 선택합니다. (예: B1:B2326)
5. **입력 X 범위 (Input X Range):** 'Square Footage' 열을 선택합니다. (예: C1:C2326)
6. **레이블 (Labels):** 첫 행에 레이블이 있으므로 이 상자를 체크합니다.
7. **신뢰 수준 (Confidence Level):** 95%를 유지합니다.
8. **출력 옵션 (Output Options):** '새 워크시트 플라이(New Worksheet Ply)'를 선택하거나, '출력 범위(Output Range)'를 선택하여 현재 시트의 특정 셀에 결과를 표시합니다.
9. '확인(OK)'을 클릭합니다.

회귀 통계 (Regression Statistics)		
Excel 출력 분석:	Multiple R	0.378173
	R Square	0.143015
	Adjusted R Square	0.14263
	Standard Error	183675.2
	Observations	2325

ANOVA	df	SS	MS	F	Significance F
Regression	1	3.0124E+14	3.0124E+14	891.95	5.99378E-80
Residual	2323	7.8507E+15	3.3795E+12		
Total	2324	8.1519E+15			

기타 통계 (Other statistics)	Coefficients	Standard error	t-stat	p-value	Lower 95%	Upper 95%
Intercept	120000	10000	12.0	1.0E-30	100000	140000
Square Footage	132.6912573	4.44444	29.85	5.99378E-80	123.97	141.41

해석:

- **R-제곱 (R-squared):** 0.143015입니다. 이는 주택 가격의 변동 중 약 14.3%만이 주택의 평방 피트로 설명될 수 있음을 의미합니다. 이는 그리 좋은 설명 변수가 아닙니다. 총 변동(Total SS: 8.1519E+15)의 대부분이 잔차(Residual SS: 7.8507E+15)에서 비롯됩니다. 즉, 평방 피트 외에 다른 많은 요인들이 주택 가격에 영향을 미치고 있다는 뜻입니다.
- **p-값 (p-value):** 'Square Footage'에 대한 p-값은 5.99378E-80으로 매우 작습니다. 이는 평방 피트가 주택 가격과 통계적으로 매우 유의미한 관계를 가지고 있음을 나타냅니다. 즉, 평방 피트가 주택 가격에 영향을 미치지 않는다는 귀무 가설을 기각할 수 있습니다.
- **계수 (Coefficient):** 'Square Footage'의 계수는 132.6912573입니다. 이는 평방 피트가 1단위 증가할 때마다 주택 가격이 약 132.69달러 증가할 것으로 예측된다는 의미입니다.

이미지 설명: X축은 평방 피트, Y축은 가격인 산점도. 기울기가 132.69인 양의 회귀선이 그려져 있습니다.

- **상관 계수 (Multiple R):** 0.378173입니다. 이는 평방 피트와 주택 가격 사이에 약 37.8%의 양의 상관 관계가 있음을 나타냅니다. 0과 1 사이의 값으로, 1에 가까울수록 상관 관계가 강합니다. 37.8%는 상관 관계가 있지만, 아주 강하지는 않다는 것을 보여줍니다.

결론: 이 단순 선형 회귀 모델은 평방 피트가 주택 가격과 통계적으로 유의미한 관계를 가지고 있음을 보여주지만 (매우 작은 p-값), 평방 피트 단독으로는 주택 가격 변동의 14.3%만을 설명합니다 (낮은 R-제곱). 이는 평방 피트가 주택 가격에 영향을 미치는 중요한 변수이지만, 예측 모델로서의 성능은 좋지 않다는 것을 의미합니다.

다음 단계: 이러한 경우, 단순 선형 회귀 모델이 그리 좋지 않다는 것을 알 수 있습니다. 이는 종속 변수(주택 가격)에 영향을 미치는 요인이 하나 이상일 때 발생합니다. 따라서 이 분석을 버릴 필요는 없습니다. 오히려, 우리는 예측하려는 대상(주택 가격)에 매우 강한 영향을 미치는 좋은 변수(평방 피트)를 식별했습니다. 하지만 이 변수만으로는 충분하지 않습니다. 주택의 위치, 건축 연도, 침실 수, 욕실 수 등 다른 요인들도 주택 가격에 영향을 미칠 수 있습니다. 이러한 경우, 여러 독립 변수를 사용하는 **다중 회귀(multiple regression)**로 모델을 확장할 수 있습니다.

7.4 모델 활용 (Using the Model)

이 섹션에서는 단순 선형 회귀 모델을 실제 데이터에 적용하고 그 결과를 해석하는 방법을 배웁니다. 특히, 독립 변수와 종속 변수를 올바르게 식별하고, Excel 출력을 분석하여 회귀 방정식을 도출하며, 이를 통해 예측을 수행하는 과정을 상세히 다룹니다.

7.4.1 예시: 양의 상관관계 (Positive Correlation)

국내 신문사 발행인은 현장 기자들의 급여와 경력 연수 간의 관계를 모델링하고자 합니다. 34명의 무작위로 선정된 기자들의 데이터를 수집했습니다. 급여와 경력 연수 사이에 관계가 존재한다고 생각하는 것이 맞을까요?

- 독립 변수 (x): 경력 연수 (Years of Experience)
- 종속 변수 (y): 급여 (Salary)

가장 먼저 두 변수 사이에 선형 관계가 있는지 확인하기 위해 산점도를 그려봅니다.

Figure 7.1: 경력 연수와 급여의 산점도 (양의 상관관계)

산점도 분석: 양의 상관관계

산점도를 보면 경력 연수가 증가함에 따라 급여도 함께 증가하는 경향을 보입니다. 이는 **강한 양의 상관관계(strong positive correlation)**를 시사합니다. 따라서 회귀 분석을 진행하여 이 관계를 더 자세히 탐색할 수 있습니다.

흔한 실수: 변수 혼동 (Mixing Up Variables)

회귀 분석을 진행하기 전에 흔히 저지르는 실수가 있습니다. 바로 독립 변수와 종속 변수를 혼동하여 축을 잘못 설정하는 것입니다.

Figure 7.2: 잘못된 산점도 예시: 종속 변수가 X축에 위치

주의

위 산점도는 x축에 급여(종속 변수)를, y축에 경력 연수(독립 변수)를 배치했습니다. 이 또한 양의 상관관계를 보여주지만, **종속 변수(Salary)가 x축에 표시된 것은 잘못된 설정입니다**. 회귀 분석에서 독립 변수는 x축에, 종속 변수는 y축에 위치해야 합니다. Excel과 같은 소프트웨어는 이러한 모델링 오류를 자동으로 감지하여 경고하지 않으므로, 사용자가 올바르게 변수를 설정해야 합니다. 잘못된 모델링은 유효하지 않은 분석 결과를 초래합니다.

Excel 출력 분석: 양의 상관관계 예시

올바르게 변수를 설정하여 회귀 분석을 실행한 결과는 다음과 같습니다.

핵심 요약

회귀 방정식 (Regression Equation): $y = 60.699 + 2.169x$

Table 7.1: 회귀 통계 요약 (Summary Output)

회귀 통계 (Regression Statistics)	
다중 R (Multiple R)	0.9124668
R-제곱 (R Square)	0.8325957
수정된 R-제곱 (Adjusted R Square)	0.8275228
표준 오차 (Standard Error)	5.5667051
관측치 수 (Observations)	35

Table 7.2: 분산 분석 (ANOVA)

	df	SS	MS	F	유의 확률 F (Significance F)
회귀 (Regression)	1	5086.0166	5086.0166	164.13	2.338E-14
잔차 (Residual)	33	1022.6108	30.988206		
총계 (Total)	34	6108.6274			

Table 7.3: 계수 및 기타 통계 (Coefficients and Other Statistics)

	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하한 95% (Lower 95%)	상한 95% (Upper 95%)
절편 (Intercept)	60.699606	1.9753988	30.727773	7E-26	56.680627	64.718585
경력 연수 (Years)	2.1693977	0.1693357	12.811225	2E-14	1.8248817	2.5139138

- R-제곱 (R-Squared):** 0.8325957 (약 83.26%) 이는 기자 급여의 총 변동 중 약 83.26%가 경력 연수에 의해 설명될 수 있음을 의미합니다. 나머지 약 16.74%는 모델에 포함되지 않은 다른 요인(오차)에 의해 발생합니다. R-제곱 값이 높을수록 모델의 설명력이 좋다고 판단할 수 있습니다.
- 절편 (Intercept):** 60.699 회귀 방정식에서 $x = 0$ 일 때 y 의 예측값입니다. 즉, 경력 연수가 0년인 기자의 예상 시작 급여는 60.699 (데이터가 천 달러 단위이므로 \$60,699)입니다.
- 경력 연수 계수 (Coefficient of Years):** 2.169 독립 변수(경력 연수)의 계수는 경력 연수가 1년 증가할 때마다 급여가 평균적으로 2.169 (즉, \$2,169) 증가한다는 것을 의미합니다. 이는 기자들이 매년 받는 평균적인 급여 인상액으로 해석할 수 있습니다.
- p-값 (p-value):** 경력 연수 변수의 p-값은 2E-14 (0.000000000000002)로 매우 작습니다. 이는 경력 연수와 급여 사이에 아무런 관계가 없다는 귀무 가설을 기각할 수 있음을 의미합니다. 즉, 경력 연수는 급여에 통계적으로 매우 유의미한 영향을 미칩니다.
- 다중 R (Multiple R):** 0.9124668 (약 0.91) 이는 급여와 경력 연수 사이에 강한 양의 상관관계가 있음을 나타냅니다. 계수의 부호가 양수(+2.169)이므로, 경력 연수가

길어질수록 급여도 증가하는 정비례 관계입니다.

- **계수의 신뢰 구간 (Confidence Interval for Coefficient):** 1.8248817 ~ 2.5139138 경력 연수 계수의 95% 신뢰 구간은 1.825에서 2.514입니다. 이는 기자의 평균 연봉 인상액이 \$1,825에서 \$2,514 사이일 것으로 95% 확신할 수 있다는 의미입니다. 우리가 사용한 계수 2.169는 이 신뢰 구간의 중간 값인 점 추정치(point estimate)입니다.

예제

예측: 15년 경력 기자의 평균 급여 만약 15년 경력의 기자 그룹의 평균 급여가 얼마일지 예측하려면, 회귀 방정식에 $x = 15$ 를 대입합니다. $y = 60.699 + 2.169 \times (15) = 60.699 + 32.535 = 93.234$ 데이터가 천 달러 단위였으므로, 예상 평균 급여는 \$93,234입니다.

7.4.2 예시: 음의 상관관계 (Negative Correlation)

로봇 도장 라인의 생산 중단을 줄이기 위해 공장 관리자는 예방 정비 프로그램을 도입하고자 합니다. 이를 위해 월별 총 가동 중단 시간(downtime)과 라인의 생산성 데이터를 수집했습니다. 관리자는 회귀 분석을 사용하여 이 관계를 분석할 수 있다고 생각합니다. 유의 수준 5%에서 분석을 수행해 봅시다.

- **독립 변수 (x):** 월별 가동 중단 시간 (Downtime hours per month)
- **종속 변수 (y):** 생산성 (Productivity)

산점도를 통해 두 변수 간의 관계를 시각적으로 확인합니다.

Figure 7.3: 가동 중단 시간과 생산성의 산점도 (음의 상관관계)

산점도 분석: 음의 상관관계

산점도를 보면 가동 중단 시간이 증가함에 따라 생산성 측정값이 선형적으로 감소하는 경향을 보입니다. 이는 **강한 음의 상관관계 (strong negative correlation)**를 형성합니다. 따라서 단순 선형 회귀를 적용하여 이 관계를 더 탐색할 수 있습니다.

Excel 출력 분석: 음의 상관관계 예시

회귀 분석을 실행한 결과는 다음과 같습니다.

핵심 요약

회귀 방정식 (Regression Equation): $y = 98.014 - 1.648x$

- **다중 R (Multiple R):** 0.940239906 (약 0.94) 가동 중단 시간과 생산성 간의 상관계수는 -0.94입니다. 계수(-1.648)의 음수 부호는 두 변수가 음의 상관관계에 있음을 나타냅니다. 즉, 가동 중단 시간이 증가하면 생산성은 감소합니다.
- **R-제곱 (R-Squared):** 0.884051081 (약 88.4%) 생산성 변동의 88.4%는 가동 중단 시간으로 설명될 수 있습니다. 나머지 11.6%는 오차(모델에 포함되지 않은 다른 요인)로 인해 발생합니다. 이는 모델의 설명력이 매우 높음을 의미합니다.

Table 7.4: 회귀 통계 요약 (Summary Output)

회귀 통계 (Regression Statistics)	
다중 R (Multiple R)	0.940239906
R-제곱 (R Square)	0.884051081
수정된 R-제곱 (Adjusted R Square)	0.881152358
표준 오차 (Standard Error)	3.746828316
관측치 수 (Observations)	42

Table 7.5: 분산 분석 (ANOVA)

	df	SS	MS	F	유의 확률 F (Significance F)
회귀 (Regression)	1	4281.522531	4281.5	304.979499	2.56416E-20
잔차 (Residual)	40	561.5488972	14.039		
총계 (Total)	41	4843.071429			

Table 7.6: 계수 및 기타 통계 (Coefficients and Other Statistics)

	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하한 95% (Lower 95%)	상한 95% (Upper 95%)
절편 (Intercept)	98.01402893	1.025886243	95.541	7.848E-49	95.94063549	100.0874224
가동 중단 (Downtime)	-1.648777759	0.094411913	-17.46	2.5642E-20	-1.839591353	-1.457964165

- **절편 (Intercept):** 98.014 가동 중단 시간이 0시간일 때(즉, 라인이 전혀 멈추지 않을 때) 예상되는 생산성 기준선은 약 98%입니다.
- **가동 중단 계수 (Coefficient of Downtime):** -1.648 가동 중단 시간이 1시간 증가할 때마다 생산성은 평균적으로 1.648% 감소합니다.

예제

예측: 8시간 가동 중단 시 평균 생산성 공장 관리자는 평균적으로 월 8시간 라인이 가동 중단된다고 생각합니다. 이 경우 예상되는 평균 생산성은 얼마일까요? 회귀 방정식에 $x = 8$ 을 대입합니다. $y = 98.014 - (1.648 \times 8) = 98.014 - 13.184 = 84.83$ 따라서 예상 평균 생산성은 약 84.83%입니다.

의사결정 활용: 이러한 예측을 통해 공장 관리자는 예방 정비 프로그램 도입의 경제적 분석을 수행할 수 있습니다. 정비 프로그램 비용과 생산성 손실 비용을 비교하여 합리적인 의사결정을 내릴 수 있습니다. 회귀 분석은 모집단에 대해 추론할 뿐만 아니라, 주어진 독립 변수 값에 대한 종속 변수 값을 예측하는 능력도 제공합니다.

7.4.3 연습 문제: GPA와 시작 급여

대학교의 한 지도 교수는 학생들이 열심히 공부하여 높은 GPA로 졸업하도록 동기를 부여하고 싶어 합니다. GPA의 중요성을 강조하기 위해, 졸업생의 시작 급여와 GPA 간의 관계에 대한 데이터를 보여줄 수 있는지 궁금해합니다. 그녀는 최근 졸업생 100명의 데이터를 수집했습니다.

변수 식별

이 연구에서 종속 변수와 독립 변수는 무엇일까요?

- 독립 변수 (x): GPA (학생의 GPA가 시작 급여에 영향을 미친다고 가정)
- 종속 변수 (y): 시작 급여 (Starting Salary)

산점도 분석

산점도 분석: GPA와 시작 급여

산점도를 보면 GPA가 증가함에 따라 시작 급여도 증가하는 양의 관계가 나타납니다.

수집된 데이터를 바탕으로 한 산점도는 다음과 같습니다.

Figure 7.4: GPA와 시작 급여의 산점도

Excel 출력 분석: GPA와 시작 급여

회귀 분석 결과는 다음과 같습니다.

Table 7.7: 회귀 통계 요약 (Summary Output)

회귀 통계 (Regression Statistics)	
다중 R (Multiple R)	0.580085329
R-제곱 (R Square)	0.336498989
수정된 R-제곱 (Adjusted R Square)	0.32972857
표준 오차 (Standard Error)	2236.609365
관측치 수 (Observations)	100

핵심 요약

회귀 방정식 (Regression Equation): $y = 37916.17 + 2904.71x$

Table 7.8: 분산 분석 (ANOVA)

	df	SS	MS	F	유의 확률 F (Significance F)
회귀 (Regression)	1	248627136	248627136.4	49.701	2.534E-10
잔차 (Residual)	98	490237302	5002421.453		
총계 (Total)	99	738864439			

Table 7.9: 계수 및 기타 통계 (Coefficients and Other Statistics)

	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하한 95% (Lower 95%)	상한 95% (Upper 95%)
절편 (Intercept)	37916.16971	1258.16015	30.13620292	2E-51	35419.392	40412.95
GPA	2904.708917	412.020185	7.049918963	3E-10	2087.0683	3722.35

- **R-제곱 (R-Squared):** 0.336498989 (약 33.65%) 졸업생 시작 급여의 변동 중 약 33.65%가 GPA에 의해 설명될 수 있습니다. 이는 나머지 약 66.35%의 변동이 모델에 포함되지 않은 다른 요인에 의해 발생한다는 것을 의미합니다.
- **GPA 계수 (Coefficient of GPA):** 2904.708917 GPA가 1점 증가할 때마다 시작 급여는 평균적으로 \$2,904.71 증가합니다.
- **p-값 (p-value):** GPA 변수의 p-값은 3E-10 (0.0000000003)으로 매우 작습니다. 이는 GPA와 시작 급여 사이에 아무런 관계가 없다는 귀무 가설을 기각할 수 있음을 의미합니다. 즉, GPA는 시작 급여에 통계적으로 매우 유의미한 영향을 미칩니다.

주의

R-제곱이 낮아도 관계가 유의미할 수 있는 이유 R-제곱 값이 33.65%로 비교적 낮지만, GPA의 p-값은 거의 0에 가깝습니다. 이는 GPA가 시작 급여에 통계적으로 매우 유의미한 영향을 미친다는 것을 의미합니다. 회귀 분석은 기본적으로 "관계가 없다"는 귀무 가설을 검정하며, p-값이 작으면 이 귀무 가설을 기각하고 관계가 있음을 받아들입니다.

그렇다면 R-제곱이 낮은 이유는 무엇일까요? R-제곱은 종속 변수의 변동 중 독립 변수가 설명하는 비율을 나타냅니다. GPA가 시작 급여의 변동 중 약 3분의 1만 설명하고, 나머지 3분의 2는 다른 요인(예: 전공, 인턴십 경험, 면접 능력 등)에 의해 설명된다는 뜻입니다.

지도 교사는 GPA가 중요하지 않다고 생각할 필요는 없습니다. GPA는 시작 급여에 영향을 미치는 하나의 중요한 요인임이 밝혀졌습니다. 하지만 모델의 설명력을 높이고 싶다면, 전공과 같은 추가적인 독립 변수를 포함하여 다중 회귀 분석(Multiple Regression)을 수행해야 합니다. 이는 이 수업의 마지막 모듈에서 다룰 주제입니다.

7.5 단순 선형 회귀: Excel 출력 분석 (Simple Linear Regression: Excel Output Analysis)

이 섹션에서는 Excel의 '데이터 분석' 도구를 사용하여 단순 선형 회귀 분석을 수행하고, 그 출력 결과를 상세히 해석하는 실습 과정을 다룹니다.

7.5.1 Excel을 이용한 회귀 분석 절차: 가동 중단 시간 예시

생산 라인의 생산성이 가동 중단 시간에 의해 영향을 받는다는 가설을 검증하기 위해 Excel을 사용합니다.

Figure 7.5: 가동 중단 시간 및 생산성 데이터 예시

1단계: 산점도를 통한 시각적 확인

회귀 분석을 시작하기 전에 데이터가 선형 모델에 적합한지 시각적으로 확인하는 것이 중요합니다.

1. Excel에서 '가동 중단 시간(Downtime)'과 '생산성(Productivity)' 두 열을 선택합니다.
2. '삽입(Insert)' 탭으로 이동하여 '산점도(Scatter Plot)'를 선택합니다.
3. 생성된 산점도를 확인하여 두 변수 간에 대략적인 선형 관계가 있는지 파악합니다.

Figure 7.6: 가동 중단 시간과 생산성 산점도 (Y축 범위 조정 후)

핵심 정보

산점도 가독성 향상 팁: Y축(생산성)의 범위가 0부터 시작하여 데이터가 평평하게 보일 수 있습니다. 이 경우, Y축을 더블 클릭하여 '축 서식(Format Axis)' 패널을 열고, '축 옵션(Axis options)'에서 최소값을 60, 최대값을 105 등으로 조정하면 데이터의 분포를 더 명확하게 볼 수 있습니다.

산점도가 대략적인 선형 형태를 보인다면, 선형 회귀를 적용할 수 있다고 판단합니다.

2단계: Excel 데이터 분석 도구로 회귀 실행

1. '데이터(Data)' 탭으로 이동하여 '데이터 분석(Data Analysis)'을 클릭합니다.
2. '데이터 분석' 창에서 '회귀(Regression)'를 선택하고 '확인'을 클릭합니다.
3. '회귀' 대화 상자가 나타나면 다음을 설정합니다.
 - **Y 입력 범위 (Input Y Range):** 예측하려는 종속 변수(생산성) 데이터를 선택합니다. (예: \$B\$1:\$B\$43)
 - **X 입력 범위 (Input X Range):** 독립 변수(가동 중단 시간) 데이터를 선택합니다. (예: \$A\$1:\$A\$43)
 - **레이블 (Labels):** 첫 행에 변수 이름(레이블)이 포함되어 있다면 이 상자를 체크합니다.
 - **신뢰 수준 (Confidence Level):** 기본값인 95%를 유지합니다.
 - **출력 옵션 (Output Options):** '새 워크시트(New Worksheet Ply)'를 선택하여 결과를 새 시트에 표시합니다.
4. '확인'을 클릭하여 회귀 분석을 실행합니다.

Figure 7.7: Excel 회귀 분석 대화 상자 설정

3단계: Excel 출력 결과 해석

Excel은 세 가지 주요 테이블로 회귀 분석 결과를 반환합니다.

Figure 7.8: Excel 회귀 분석 출력 (초기 상태)

핵심 정보

출력 테이블 가독성 향상 팁: Excel 출력에서 열 너비가 충분하지 않아 내용이 잘리지 않도록, 열 사이 경계선을 더블 클릭하여 자동으로 너비를 조정할 수 있습니다.

주의

Excel의 95% 신뢰 구간 중복 표시: Excel은 기본적으로 95% 신뢰 구간을 두 번 표시하는 경향이 있습니다. 이는 버그로 간주될 수 있으며, 중복된 열은 삭제해도 무방합니다. 만약 99% 신뢰 수준을 요청하면, 99%와 95% 신뢰 구간을 모두 표시합니다.

Table 7.10: 회귀 통계 요약 (Regression Statistics)

회귀 통계 (Regression Statistics)	
다중 R (Multiple R)	0.940239906
R-제곱 (R Square)	0.884051081
수정된 R-제곱 (Adjusted R Square)	0.881152358
표준 오차 (Standard Error)	3.746828316
관측치 수 (Observations)	42

Table 7.11: 분산 분석 (ANOVA)

	df	SS	MS	F	유의 확률 F (Significance F)
회귀 (Regression)	1	4281.522531	4281.5	304.979499	2.56416E-20
잔차 (Residual)	40	561.5488972	14.039		
총계 (Total)	41	4843.071429			

Table 7.12: 계수 및 기타 통계 (Coefficients and Other Statistics)

	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하한 95% (Lower 95%)	상한 95% (Upper 95%)
절편 (Intercept)	98.01402893	1.025886243	95.541	7.848E-49	95.94063549	100.0874224
가동 중단 (Downtime)	-1.648777759	0.094411913	-17.46	2.5642E-20	-1.839591353	-1.457964165

핵심 요약

회귀 방정식: $\hat{y} = 98.01 - 1.648x$ 여기서 $\hat{y}$ 는 예측된 생산성, x 는 가동 중단 시간입니다.

- **p-값 (p-value):** 가동 중단 변수의 p-값은 $2.56E-20$ 으로 매우 작습니다. 이는 가동 중단 시간과 생산성 사이에 아무런 관계가 없다는 귀무 가설을 기각할 수 있음을 의미합니다. 즉, 가동 중단 시간은 생산성에 통계적으로 매우 유의미한 영향을 미칩니다.
- **R-제곱 (R-Squared):** 0.8840 (약 88.4%) 생산성 변동의 88.4%는 가동 중단 시간으로 설명될 수 있습니다. 이는 모델의 설명력이 매우 높으며, 수집된 데이터에서 생산성 차이의 대부분이 가동 중단 시간 때문임을 시사합니다.
- **ANOVA 테이블의 R-제곱:** R-제곱은 총 제곱합(SST)에 대한 회귀 제곱합(SSR)의 비율입니다. $R^2 = \frac{SSR}{SST} = \frac{4281.522531}{4843.071429} \approx 0.884051081$ 이 값이 R-제곱 값과 정확히 일치합니다. R-제곱이 높을수록 변동에 대한 설명력이 좋고, 예측 모델이 우수하다고 볼 수 있습니다.
- **다중 R (Multiple R):** 0.9402 다중 R은 상관계수(r)를 나타냅니다. 이는 R-제곱의 제곱근과 같습니다. $r = \sqrt{R^2} = \sqrt{0.884051081} \approx 0.940239906$ 상관계수는 -1에서 1 사이의 값을 가지며, 1에 가까울수록 강한 양의 상관관계, -1에 가까울수록 강한 음의 상관관계를 나타냅니다. 0에 가까울수록 상관관계가 약합니다. 가동 중단 계수(-1.648)의 음수 부호는 가동 중단 시간이 증가할수록 생산성이 감소하는 음의 상관관계를 의미합니다.
- **계수 해석:** 가동 중단 계수 -1.648은 가동 중단 시간이 1시간 증가할 때마다 생산성이 평균적으로 1.648% 감소한다는 것을 의미합니다.
- **예측:** 만약 월 8시간의 가동 중단이 발생한다면, 예상 생산성은 다음과 같습니다. $\hat{y} = 98.014 - (1.648 \times 8) = 84.8238$ 즉, 평균 생산성은 84.82%로 예측됩니다.
- **신뢰 구간 (Confidence Interval):** Excel 출력은 각 계수에 대한 신뢰 구간도 제공합니다. 예를 들어, 가동 중단 계수의 95% 신뢰 구간은 -1.839에서 -1.458입니다. 이는 우리가 사용한 계수 -1.648이 이 구간 내의 점 추정치임을 의미합니다. 회귀 분석은 가설 검정(p-값)과 신뢰 구간 추정(계수)을 모두 포함하는 포괄적인 분석 도구입니다.

7.6 모델 가정 및 한계 (Model Assumptions and Limitations)

회귀 모델이 유효하고 신뢰할 수 있는 결과를 제공하려면 특정 가정을 충족해야 합니다. 이 섹션에서는 이러한 가정들을 살펴보고, 모델의 한계점, 특히 외삽(extrapolation)의 위험성에 대해 논의합니다.

7.6.1 모델 가정 (Model Assumptions)

회귀 모델의 가정은 주로 잔차(residuals) 분석을 통해 확인됩니다. 잔차는 실제 y 값과 모델이 예측한 $\hat{y}$ 값 사이의 차이($e = y - \hat{y}$)입니다. 회귀 방정식은 $y = b_0 + b_1x + e$ 로 표현될 수 있습니다.

회귀 모델의 주요 가정

회귀 모델의 유효성을 확인하기 위해 다음 가정들을 검토해야 합니다. 이 가정들은 잔차의 특성에 초점을 맞춥니다.

1. **잔차의 평균이 0**: 잔차의 모집단은 평균이 0인 정규 분포를 따릅니다.
2. **등분산성 (Constant Variance)**: 잔차의 분산이 독립 변수(x)의 값에 관계없이 일정합니다.
3. **정규성 (Normality)**: 잔차가 평균 0, 일정한 분산(σ^2)을 가진 정규 분포에서 무작위로 독립적으로 추출된 것처럼 보입니다.
4. **선형성 (Linearity)**: 독립 변수(x)와 종속 변수(y) 간의 관계가 선형입니다.
5. **독립성 (Independence)**: 각 잔차 값이 다른 잔차 값과 통계적으로 독립적입니다.

1. 잔차의 평균이 0 (Mean of Zero)

- **설명**: 회귀 가정이 유효하다면, 잠재적인 오차 항(잔차)의 모집단은 평균이 0인 정규 분포를 따릅니다.
- **의미**: 이는 모델이 전반적으로 과대 예측하거나 과소 예측하는 경향 없이, 예측 오차가 서로 상쇄되어 평균 오차가 0이 된다는 것을 의미합니다. 즉, 모델이 편향되지 않았다는 증거입니다.

2. 등분산성 가정 (Constant Variance Assumption)

- **설명**: 독립 변수(x)의 어떤 주어진 값에서도, 잠재적인 오차 항 값의 모집단 분산은 x 값에 의존하지 않고 일정합니다.
- **의미**: 잔차의 분포가 x 값의 범위에 걸쳐 일정한 분산을 가져야 합니다. 잔차 플롯에서 잔차들이 일정한 수평 띠 안에 무작위로 분포하는 형태로 나타나야 합니다.

3. 정규성 가정 (Normality Assumption)

- **설명**: 잔차는 평균이 0이고 일정한 분산 σ^2 을 가진 정규 분포에서 무작위로 독립적으로 추출된 것처럼 보여야 합니다.
- **의미**: 이 가정은 앞의 두 가정을 기반으로 하며, 잔차의 분포 형태가 정규 분포와 유사해야 함을 요구합니다. 실제 데이터에서는 완벽하게 정규 분포를 따르지 않을 수 있지만, 심각한 이탈이 없으면 통계적 추론에 큰 영향을 미치지 않습니다.

4. 선형성 가정 (Linearity Assumption)

- **설명**: 독립 변수(x)와 종속 변수(y) 간의 관계가 선형이어야 합니다.
- **확인 방법**: 산점도를 통해 x 와 y 의 관계가 직선 형태를 띠는지 시각적으로 확인합니다.

5. 독립성 가정 (Independence Assumption)

- **설명:** 어떤 하나의 잔차 값도 다른 잔차 값과 통계적으로 독립적이어야 합니다.
- **의미:** 잔차들 사이에 패턴이나 상관관계가 없어야 합니다. 이 가정은 주로 시계열 데이터(time-series data)에서 위반되기 쉽습니다. 현재 시점의 변수 값이 이전 시점의 값에 영향을 받는 경우, 잔차들 사이에 자기상관(autocorrelation)이 발생할 수 있습니다.

주의

자기상관 (Autocorrelation) 자기상관은 시간 순서에 따라 오차 항들이 서로 상관되어 있을 때 발생합니다.

- **양의 자기상관 (Positive Autocorrelation):** 시간 i 의 양의 오차 항이 미래 시간 $i + k$ 에서도 양의 값을 가질 가능성이 높을 때 발생합니다. 예를 들어, 여름철 여가 및 여행 지출은 6월에 증가하면 7월에도 증가하는 경향이 있습니다.
 - **음의 자기상관 (Negative Autocorrelation):** 시간 i 의 음의 오차 항이 미래 시간 $i + k$ 에서도 음의 값을 가질 가능성이 높을 때 발생합니다.
- 자기상관이 존재하는 데이터에는 선형 회귀 모델이 적합하지 않습니다.

가정 확인 방법: 잔차 플롯 (Residual Plots)

잔차 플롯을 통해 잔차의 평균이 0인지, 분산이 일정한지, 정규성을 띠는지 시각적으로 확인할 수 있습니다.

Figure 7.9: 잔차의 정규 확률 플롯 예시

정규성 가정 확인

플롯의 점들이 대략적으로 직선 형태를 띠면 정규성 가정이 충족됩니다. 위 GPA-시작 급여 예시의 플롯은 직선에 가깝게 정렬되어 정규성 가정이 충족됨을 보여줍니다.

- **정규성 확인 (Normal Probability Plot):** 잔차의 정규 확률 플롯이 대략적으로 직선 형태를 띠면 정규성 가정이 충족됩니다. 위 GPA-시작 급여 예시의 플롯은 직선에 가깝게 정렬되어 정규성 가정이 충족됨을 보여줍니다.
- **평균 0 및 등분산성 확인 (Residuals vs. X Plot):** 잔차를 독립 변수(x)에 대해 플

평균 0 및 등분산성 가정 확인

- **평균 0:** 0선 위아래로 잔차들이 거의 같은 수로 분포되어 있다는 가정이 충족됩니다.
- **등분산성:** 잔차들이 일정한 수평 띠(contained horizontal band)로 무작위로 분포되어 있다면 등분산성 가정이 충족된다고 볼 수 있습니다 (왼쪽 플롯).
- **등분산성 위반:** 잔차들이 x 값이 증가함에 따라 퍼져나가는 패턴(fanning in)을 보인다면 등분산성 가정이 위반된다고 볼 수 있습니다 (오른쪽 상단 및 하단 플롯).

이러한 그래프를 통해 확인합니다.

Figure 7.10: 잔차 플롯 예시: 평균 0 및 등분산성 확인

7.6.2 모델의 한계 (Limitations)

회귀 모델을 적용할 때 가장 중요한 한계점 중 하나는 **외삽(extrapolation)**의 위험성입니다.

주의

외삽 금지 (Do Not Extrapolate) 모델은 데이터를 분석한 범위 내에서만 유효합니다. 모델을 학습시킨 데이터 범위를 벗어나 예측하는 것은 매우 위험하며, 신뢰할 수 없는 결과를 초래할 수 있습니다.

예제

예시: 전기 사용량과 주택 면적 주택 면적(1,800 3,000 ft^2)과 전기 사용량 간의 관계를 모델링했다고 가정해 봅시다. 전력 회사가 5,000 7,500 ft^2 크기의 주택이 들어설 새로운 주택 단지에 대한 전력 수요를 예측하기 위해 이 모델을 사용할 수 있을까요?

답변: 아니요. 모델이 학습된 데이터 범위(1,800 3,000 ft^2)를 훨씬 벗어나는 5,000 7,500 ft^2 주택에 대해 예측하는 것은 외삽에 해당합니다. 이 범위 밖에서는 선형 관계가 유지되지 않거나 다른 요인이 중요해질 수 있으므로, 모델의 예측은 신뢰할 수 없습니다.

7.6.3 요약 및 주의 사항

핵심 요약

회귀 분석의 목표:

- 과거 데이터에서 변수 간의 관계 이해
- 예측 수행
- 가상 분석(what-if analysis) 수행

예측 시 주의사항:

- 모델이 추정된 범위(데이터 범위)를 벗어나 외삽하지 않도록 주의해야 합니다.

사전 분석의 중요성:

- 회귀 모델을 추정하기 전에 산점도를 사용하여 데이터 쌍 간의 관계를 시각적으로 확인하는 것이 좋습니다.
- 산점도는 두 변수 간의 관계의 강도와 유형(직선, 곡선 등)에 대한 통찰력을 제공합니다.

주요 통계량:

- **상관 계수 (Correlation):** -1에서 +1까지의 범위로, 두 변수 간의 선형 관계의 정도와 방향을 나타냅니다.
- **R-제곱 (R-squared) 또는 결정 계수 (Coefficient of Determination):** 모델의 독립 변수들이 종속 변수의 변동 중 얼마나 많은 부분을 설명하는지 나타내는 비율입니다 (0과 1 사이).

주의

상관관계는 인과관계가 아니다 (Correlation is not Causation) 두 변수 사이에 강한 상관관계가 있다고 해서 한 변수가 다른 변수의 직접적인 원인이라고 단정할 수는 없습니다. 인과관계를 증명하는 것은 훨씬 더 많은 증거와 엄격한 연구를 필요로 합니다.

- **예시:** 흡연과 폐암은 오랫동안 상관관계가 알려져 있었지만, 흡연이 폐암의 원인을 과학적으로 입증하는 데는 오랜 시간이 걸렸습니다.
- **예시:** 지구 온난화와 특정 요인들 간의 관계도 마찬가지입니다. 기후 변화는 대부분 동의하지만, 그 원인에 대한 합의는 여전히 논쟁의 여지가 있습니다. 회귀 분석을 통해 상관관계를 발견하더라도, 이를 인과관계로 주장하지 않도록 주의해야 합니다. 상관관계만으로도 예측 능력은 충분히 강력하며, 독립 변수의 값을 변경하여 원하는 결과를 얻을 수 있는 통찰력을 제공합니다.

7.7 Excel을 이용한 잔차 분석 (Residual Analysis in Excel)

이 섹션에서는 Excel을 사용하여 회귀 모델의 기본 가정을 확인하기 위한 잔차 분석을 수행하는 방법을 단계별로 설명합니다. GPA와 시작 급여 예시를 통해 잔차 플롯을 생성하고 해석하는 과정을 배웁니다.

7.7.1 Excel에서 잔차 플롯 생성 및 해석: GPA-시작 급여 예시

Figure 7.11: GPA와 시작 급여 데이터 및 산점도

GPA가 학생들의 시작 급여에 미치는 영향을 분석하는 예시를 다시 사용합니다. 산점도는 GPA와 시작 급여 사이에 완만한 양의 관계가 있음을 보여줍니다.

1단계: Excel에서 회귀 분석 실행 및 잔차 플롯 요청

1. '데이터(Data)' 탭 → '데이터 분석(Data Analysis)' → '회귀(Regression)'를 선택합니다.
2. '회귀' 대화 상자에서 다음을 설정합니다.
 - Y 입력 범위 (Input Y Range): 시작 급여 데이터 (예: \$B\$1:\$B\$101)
 - X 입력 범위 (Input X Range): GPA 데이터 (예: \$A\$1:\$A\$101)
 - 레이블 (Labels): 체크
 - 출력 옵션 (Output Options): '새 워크시트(New Worksheet Ply)' 선택
 - 잔차 (Residuals) 섹션: 다음 옵션들을 모두 체크합니다.
 - 잔차 (Residuals)
 - 잔차 플롯 (Residual Plots)
 - 선형 적합 플롯 (Line Fit Plots)
 - 정규 확률 플롯 (Normal Probability Plots)
3. '확인'을 클릭합니다.

Figure 7.12: Excel 회귀 분석 대화 상자 설정 (잔차 플롯 옵션 포함)

주의

변수 선택 오류 경고: Excel은 독립 변수와 종속 변수를 잘못 선택하더라도 경고하지 않습니다. 항상 x축에 독립 변수, y축에 종속 변수를 올바르게 배치했는지 확인해야 합니다. 잘못된 변수 설정은 유효하지 않은 분석 결과를 초래합니다.

2단계: 생성된 잔차 플롯 해석

Excel은 회귀 분석 결과와 함께 여러 플롯을 생성합니다. 이 플롯들을 통해 모델의 가정을 검토할 수 있습니다.

Figure 7.13: GPA-시작 급여 회귀 분석의 잔차 플롯들

- **정규 확률 플롯 (Normal Probability Plot):** 이 플롯은 잔차의 정규성 가정을 확인

정규성 가정 확인

플롯의 점들이 대략적으로 직선을 형성한다면, 잔차가 정규 분포를 가정이 위반되지 않았다고 볼 수 있습니다. 위 플롯은 직선에 가 정규성 가정이 충족됨을 시사합니다.

하는 데 사용됩니다. -

Figure 7.14: GPA-시작 급여 잔차의 정규 확률 플롯

- **GPA 잔차 플롯 (GPA Residual Plot):** 이 플롯은 잔차의 평균이 0인지, 등분산성 가

평균 0 및 등분산성 가정 확인

- **평균 0:** 0선 위와 아래에 잔차 점들이 거의 균등하게 분포되어 있다면, 평균이 0이라는 가정이 충족됩니다. 이는 예측을 균형 있게 수행하고 있음을 의미합니다.
- **등분산성:** 잔차 점들이 특정 패턴 없이 일정한 폭으로 분포되어 있다면, 등분산성 가정이 충족됩니다. 변수 값에 따라 변하지 않습니다.
- **등분산성 위반 예시:** 만약 잔차들이 x 값이 증가함에 따라 폭이 넓어지는 (fanning out) 모양 또는 폭이 좁아지는 (fanning in) 모양을 보인다면, 등분산성 가정이 위반된 것입니다.

정이 충족되는지 확인하는 데 사용됩니다. -

Figure 7.15: GPA-시작 급여 잔차 플롯

- **선형 적합 플롯 (Line Fit Plot):** 이 플롯은 실제 데이터 포인트(파란색)와 회귀선(주황색)을 함께 보여주며, 모델의 선형성 가정을 시각적으로 확인하는 데 도움이

선형성 가정 확인

회귀선 주위에 실제 데이터 포인트들이 고르게 분포되어 있고, 특정 패턴(예: 곡선 형태)을 보이지 않는다면 선형성 가정이 충족됩니다. 또한, 회귀선 위와 아래에 점들이 균등하게 분포되어 있다면, 모델이 전반적으로 잘 적합되었음을 의미합니다.

됩니다. -

Figure 7.16: 등분산성 위반 예시: 잔차가 퍼지는 경우

주의

가정 위반 시: 잔차 플롯에서 회귀 모델의 기본 가정이 심각하게 위반되는 패턴(예: 잔차의 비정규성, 등분산성 위반, 특정 패턴)이 발견된다면, 해당 선형 회귀 모델은 데이터에 적합하지 않으며, 그 결과를 신뢰할 수 없습니다. 이 경우, 다른 모델(예: 비선형 회귀, 다중 회귀)을 고려하거나 데이터 변환을 시도해야 합니다.

7.8 체크리스트: 회귀 모델 가정 검토

회귀 모델을 사용하기 전에 다음 체크리스트를 활용하여 모델의 가정을 검토하세요. 모든 항목이 '예'에 가까울수록 모델의 신뢰도가 높습니다.

검토 항목	예	아니오
1. 변수 설정		
독립 변수(X)와 종속 변수(Y)를 올바르게 식별하고 X축/Y축에 배치했는가?	☐	☐
2. 선형성 가정		
산점도에서 X와 Y 사이에 대략적인 직선 관계가 보이는가?	☐	☐
3. 잔차의 평균 0 가정		
잔차 플롯에서 0선 위아래로 잔차들이 거의 균등하게 분포되어 있는가?	☐	☐
4. 등분산성 가정		
잔차 플롯에서 잔차들이 일정한 수평 띠 내에서 무작위로 분포되어 있는가?	☐	☐
(잔차가 퍼지거나 모이는 깔때기 모양을 보이지 않는가?)	☐	☐
5. 정규성 가정		
잔차의 정규 확률 플롯이 대략적으로 직선 형태를 띠는가?	☐	☐
6. 독립성 가정		
데이터가 시계열 데이터가 아니거나, 잔차들 사이에 자기상관이 없는가?	☐	☐
7. 외삽 금지		
모델을 학습시킨 데이터 범위 내에서만 예측을 수행하는가?	☐	☐

7.9 FAQ: 초심자를 위한 질문과 답변

회귀 분석을 처음 접하는 사람들이 흔히 가질 수 있는 질문들을 Q&A 형식으로 정리했습니다.

자주 묻는 질문

Q1: R-제곱 값이 낮으면 모델이 쓸모없는 건가요? A1: 반드시 그렇지는 않습니다. R-제곱은 모델이 종속 변수의 변동을 얼마나 잘 설명하는지를 나타내지만, p-값이 매우 작다면 독립 변수가 종속 변수에 통계적으로 유의미한 영향을 미친다는 것을 의미합니다. R-제곱이 낮더라도 중요한 관계를 발견한 것이며, 이는 추가적인 독립 변수를 포함하여 모델을 개선할 여지가 있음을 시사할 수 있습니다.

Q2: 독립 변수와 종속 변수를 잘못 설정하면 어떻게 되나요? A2: Excel과 같은 소프트웨어는 오류를 경고하지 않고 결과를 출력합니다. 하지만 그 결과는 통계적으로 무의미하거나 잘못된 해석으로 이어질 수 있습니다. 항상 원인(독립 변수)이 결과(종속 변수)에 영향을 미친다는 논리적 관계를 바탕으로 변수를 올바르게 설정해야 합니다.

Q3: 잔차 플롯에서 이상한 패턴이 보이면 어떻게 해야 하나요? A3: 잔차 플롯에서 특정 패턴(예: 깔때기 모양, 곡선 패턴)이 보인다면 회귀 모델의 가정이 위반된 것입니다. 이 경우, 선형 회귀 모델은 적합하지 않을 수 있으며, 데이터 변환(예: 로그 변환)을 시도하거나, 비선형 회귀 또는 다중 회귀와 같은 다른 모델을 고려해야 합니다.

Q4: 상관관계와 인과관계는 어떻게 다른가요? A4: 상관관계는 두 변수가 함께 변화하는 경향을 나타낼 뿐, 한 변수가 다른 변수의 직접적인 원인임을 의미하지 않습니다. 인과관계는 한 변수의 변화가 다른 변수의 변화를 직접적으로 유발한다는 것을 의미하며, 이를 증명하기 위해서는 엄격한 실험 설계와 추가적인 증거가 필요합니다. 회귀 분석은 주로 상관관계를 밝히는 데 사용됩니다.

Q5: 모델을 학습시킨 데이터 범위를 벗어나 예측해도 되나요? A5: 안 됩니다. 이를 외삽(extrapolation)이라고 하며, 모델의 예측 신뢰도를 크게 떨어뜨립니다. 모델은 학습된 데이터의 패턴을 기반으로 하므로, 해당 범위를 벗어나면 패턴이 달라지거나 예측할 수 없는 요인이 작용할 수 있습니다. 항상 모델이 학습된 데이터 범위 내에서만 예측을 수행해야 합니다.

7.10 빠르게 훑어보기: 핵심 요약

이 섹션은 모듈 3의 후반부 핵심 내용을 한 페이지로 요약하여 빠르게 복습할 수 있도록 돕습니다.

모델 활용 및 가정: 핵심 요약

1. 모델 활용의 기본

- **변수 식별:** 독립 변수(X)는 원인, 종속 변수(Y)는 결과. X 는 X 축, Y 는 Y 축에 배치.
- **산점도:** 선형 관계 및 상관관계(양/음) 시각적 확인.
- **회귀 방정식:** $y = b_0 + b_1x$ 형태로, b_0 는 절편, b_1 은 기울기(계수).
- **계수 해석:** b_0 는 X 가 0일 때 Y 의 예측값, b_1 은 X 가 1단위 변할 때 Y 의 변화량.
- **예측:** 회귀 방정식에 X 값을 대입하여 Y 값을 예측.

2. Excel 출력 분석

- **R-제곱 (R^2):** 종속 변수 변동 중 독립 변수가 설명하는 비율 (0 1). 높을수록 설명력 우수.
- **다중 R (r):** 상관계수 (-1 1). 관계의 강도와 방향.
- **p-값:** 독립 변수와 종속 변수 간 관계의 통계적 유의미성 판단. 작을수록 유의미.
- **ANOVA 테이블:** 총 변동(SST), 회귀 변동(SSR), 잔차 변동(SSE)으로 모델의 설명력 분석.

3. 모델 가정 및 검토 (잔차 분석)

- **잔차 (e):** 실제 값과 예측 값의 차이. 모델 가정 검증의 핵심.
- **주요 가정:**
 1. **잔차 평균 0:** 잔차 플롯에서 0선 위아래 균등 분포.
 2. **등분산성:** 잔차 플롯에서 일정한 수평 띠 내 무작위 분포 (깎때기 모양 X).
 3. **정규성:** 잔차의 정규 확률 플롯이 직선 형태.
 4. **선형성:** 산점도에서 직선 관계.
 5. **독립성:** 잔차들 간 자기상관 없음 (시계열 데이터 주의).
- **가정 위반 시:** 모델 결과 신뢰 불가. 다른 모델 고려 또는 데이터 변환 필요.

4. 모델의 한계 및 주의사항

- **외삽 금지:** 모델 학습 데이터 범위를 벗어난 예측은 신뢰할 수 없음.
- **상관관계 $\neq$ 인과관계:** 상관관계는 함께 변화하는 경향일 뿐, 원인-결과 관계를 의미하지 않음.

Chapter 8

Lecture 8

강의명: Inferential and Predictive Statistics Module 4

주차: 다중 선형 회귀 및 더미 변수 활용

교수명: Prof. Fataneh Taghaboni-Dutta

목적: 다중 선형 회귀 분석, 질적 데이터의 더미 변수 변환, 그리고 다중 범주 더미 변수 활용법을 학습하여 복잡한 비즈니스 예측 모델을 구축하고 해석합니다.

핵심 요약

이 문서는 'Inferential and Predictive Statistics Module 4'의 첫 번째 파트 (Lesson 4-1)를 다룹니다. 단순 선형 회귀 분석을 넘어 여러 독립 변수를 활용하는 다중 선형 회귀 분석의 기본 개념, 모델 개발 방법, 그리고 Excel을 이용한 실습 및 결과 해석에 초점을 맞춥니다. 특히, 조정된 R-제곱(Adjusted R-squared)의 중요성과 각 독립 변수의 유의성 검정 방법을 이해하고, 이를 통해 최적의 예측 모델을 구축하는 과정을 상세히 설명합니다.

8.1 개요

이 문서는 UIUC의 BADM-572: Data-Driven Decision Making 과목의 'Inferential and Predictive Statistics Module 4' 중 첫 번째 부분에 해당하는 내용을 담고 있습니다. 다중 선형 회귀(Multiple Linear Regression)의 핵심 원리와 비즈니스 의사결정에 어떻게 활용되는지를 학습하는 것이 목표입니다. 단순 선형 회귀가 하나의 독립 변수만을 사용하는 반면, 다중 선형 회귀는 여러 독립 변수를 동시에 고려하여 종속 변수를 예측함으로써 현실의 복잡한 상황을 더 정확하게 모델링할 수 있습니다. 이 파트에서는 다중 회귀 모델의 개념 소개, Excel을 활용한 모델 개발 절차, 그리고 도출된 결과의 해석 방법에 대해 깊이 있게 다룹니다. 특히, 모델의 설명력을 평가하는 조정된 R-제곱과 각 변수의 유의성을 판단하는 p-값의 중요성을 강조하며, 이를 통해 불필요한 변수를 제거하고 예측력을 높이는 과정을 배웁니다.

8.2 용어 정리

정의

용어	쉬운 설명	원어	비고
다 중 선 형 회귀	여러 개의 원인(독립 변수)으로 하나의 결과(종속 변수)를 예측하는 통계 기법.	Multiple Linear Regression	단순 회귀의 확장
종속 변수	예측하고자 하는 결과 변수.	Response/ Dependent Variable	보통 y 로 표기
독립 변수	결과를 예측하는 데 사용되는 원인 변수.	Explanatory/ Independent Variable	보통 x 로 표기
최소 제곱법	예측 오차를 최소화하여 최적의 회귀선을 찾는 방법.	Least Squares Method	회귀 모델의 기본 원리
잔차	실제 값과 모델이 예측한 값의 차이.	Residuals	예측 오차
R-제곱	모델이 종속 변수의 전체 변동 중 얼마나 설명하는지 나타내는 비율.	R-squared (R^2)	모델 설명력 지표
조정된 R-제곱	독립 변수 개수에 따라 R-제곱이 과대평가되는 경향을 보정하여, 다중 회귀 모델의 설명력을 더 정확하게 평가하는 지표.	Adjusted R-squared	다중 회귀에서 더 중요
p-값	특정 독립 변수가 종속 변수와 유의미한 관계가 없을 확률.	p-value	변수의 유의성 판단 기준
유의 수준	p-값을 비교하여 가설을 기각할지 결정하는 기준값 (일반적으로 0.05).	Significance Level (α)	통계적 판단 기준
더미 변수	범주형 데이터를 회귀 분석에 사용할 수 있도록 0과 1로 변환한 변수.	Dummy Variable	질적 데이터 처리

8.3 모듈 4: 추론 및 예측 통계

8.3.1 Lesson 4-1: 모델 소개

Lesson 4-1.1: 모델 소개

다중 선형 회귀의 필요성

우리는 일상생활에서 복잡한 예측 문제에 직면합니다. 예를 들어, Zillow는 어떻게 주택 가격을 추정할까요? Netflix는 어떤 영화를 추천해야 할지 어떻게 알까요? 금융 기관은 누가 대출을 불이행할 가능성이 높은지 어떻게 판단할까요? 이러한 질문들은 단순히 하나의 요인만으로 답할 수 없습니다. 주택 가격은 위치, 크기, 건축 연도 등 여러 요인에 의해 결정되며, 영화 추천은 사용자의 시청 기록, 장르 선호도, 다른 사용자의 패턴 등 복합적인 데이터를 기반으로 이루어집니다.

단순 선형 회귀(Simple Linear Regression)는 하나의 독립 변수(원인)로 하나의 종속 변수(결과)를 예측하는 데 사용됩니다. 하지만 현실의 많은 문제들은 여러 원인이 복합적으로 작용하여 결과를 만들어냅니다. 이러한 복잡한 상황을 분석하고 예측하기 위해 **다중 선형 회귀(Multiple Linear Regression)**가 필요합니다. 다중 선형 회귀는 여러 독립 변수를 동시에 고려하여 종속 변수를 예측함으로써, 단순 선형 회귀보다 훨씬 더 정교하고 현실적인 분석을 가능하게 합니다.

다중 선형 회귀 모델의 특징

- **하나의 종속 변수(Response/Dependent Variable):** 우리가 예측하고자 하는 결과는 여전히 하나입니다. 예를 들어, 주택 가격, 영화 시청 여부, 대출 불이행 여부 등입니다.
- **여러 개의 독립 변수(Explanatory/Independent Variables):** 종속 변수에 영향을 미치는 여러 요인들을 동시에 모델에 포함할 수 있습니다. 독립 변수의 개수에는 이론적인 제한이 없습니다.

이러한 특징 덕분에 다중 회귀 모델은 단순 선형 회귀 모델보다 훨씬 더 복잡한 상황을 다룰 수 있으며, 더 정확한 예측과 통찰력을 제공합니다.

예시: 아동 비만 예측 모델

신생아를 대상으로 한 연구에서는 아동 및 청소년 비만을 예측하는 방정식을 개발했습니다. 이 연구의 목표는 어떤 아기가 비만 위험이 가장 높은지 파악하여 예방 조치를 취하는 것이었습니다.

이 모델은 다음의 여러 요인(독립 변수)을 기반으로 아기가 비만이 될 확률(종속 변수)을 예측합니다:

- 어머니의 BMI (체질량 지수)
- 아버지의 BMI
- 가구 구성원 수
- 어머니의 직업 범주 (범주형 데이터)
- 임신 중 어머니의 흡연 여부 (범주형 데이터)
- 아기의 출생 체중

총 7개의 독립 변수가 사용되었으며, 이 중 일부는 수치형(예: 가구 구성원 수, 출생 체중)이고 일부는 범주형(예: 어머니의 직업, 흡연 여부)입니다. 이 모듈에서는 어떤 변수가 예측 모델에 유용한지, 그리고 예측 공식을 어떻게 개발하는지 배우게 됩니다.

최소 제곱 추정 (Least Square Estimation)

다중 선형 회귀도 단순 선형 회귀와 마찬가지로 **최소 제곱법** (Least Squares Method)을 사용하여 회귀 방정식을 찾습니다. 최소 제곱법은 실제 값과 예측 값 사이의 오차(잔차) 제곱합을 최소화하는 회귀선을 찾는 방법입니다.

다중 회귀에서는 각 독립 변수($x_1, x_2, \dots, x_k$)마다 고유한 기울기($b_1, b_2, \dots, b_k$)를 가집니다. 회귀 방정식은 다음과 같이 표현됩니다:

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_kx_k$$

여기서:

- $\hat{y}$ (y-hat): 독립 변수 $x_1, x_2, \dots, x_k$ 의 값이 주어졌을 때 종속 변수 y 의 평균 값에 대한 점 추정치(point estimate)입니다.
- b_0 : 절편(intercept)으로, 모든 독립 변수가 0일 때 y 의 예측 값입니다.
- b_i : i 번째 독립 변수 x_i 의 기울기(slope) 또는 회귀 계수(regression coefficient)입니다. 다른 모든 독립 변수가 일정할 때 x_i 가 1단위 증가할 때 $\hat{y}$ 가 변화하는 양을 나타냅니다.

$\hat{y}$ 는 어디까지나 추정치이므로, 단순 선형 회귀에서와 마찬가지로 실제 값과의 오차(잔차)가 존재합니다.

회귀 모델의 가정 (Regression Model Assumptions)

회귀 분석이 유효하려면 몇 가지 가정이 충족되어야 합니다. 단순 선형 회귀에서 학습했던 가정들은 다중 선형 회귀에서도 동일하게 적용됩니다. 이러한 가정들은 주로 잔차(예측 오차)를 분석하여 확인합니다.

1. **평균이 0인 가정 (Mean of Zero Assumption)**: 잔차의 평균은 0이어야 합니다. 이는 모델이 체계적인 편향 없이 예측한다는 것을 의미합니다.
2. **등분산성 가정 (Constant Variance Assumption)**: 잔차의 분산은 모든 독립 변수 값에 대해 일정해야 합니다. 즉, 예측 오차의 크기가 독립 변수 값에 따라 달라지지 않아야 합니다.
3. **정규성 가정 (Normality Assumption)**: 잔차는 정규 분포를 따라야 합니다. 이는 통계적 추론(예: 신뢰 구간, 가설 검정)의 정확성을 보장합니다.
4. **독립성 가정 (Independence Assumption)**: 잔차들은 서로 독립적이어야 합니다. 즉, 한 잔차가 다른 잔차에 영향을 미치지 않아야 합니다. 이는 데이터 수집 과정에서 발생할 수 있는 자기 상관(autocorrelation) 문제를 방지합니다.

이러한 가정들의 유효성은 잔차 플롯(residual plots)과 통계적 검정을 통해 확인합니다.

R-제곱(R^2)과 조정된 R-제곱(Adjusted R^2)

R-제곱(R^2)은 회귀 모델이 종속 변수의 전체 변동 중 얼마나 많은 부분을 설명하는지 나타내는 지표입니다. 0과 1 사이의 값을 가지며, 1에 가까울수록 모델의 설명력이 높다고 해석합니다.

다중 선형 회귀에서는 R-제곱 대신 '**조정된 R-제곱(Adjusted R^2)**'을 사용합니다. 그 이유는 다음과 같습니다:

- **R-제곱의 한계:** 다중 회귀 모델에 새로운 독립 변수를 추가하면, 설명 그 변수가 종속 변수와 아무런 관계가 없더라도 R-제곱 값은 항상 증가하거나 최소한 감소하지 않습니다. 이는 모델에 불필요한 변수가 추가되어도 R-제곱이 모델의 설명력을 과대평가할 수 있음을 의미합니다.
- **조정된 R-제곱의 역할:** 조정된 R-제곱은 이러한 R-제곱의 경향을 보정합니다. 모델에 추가된 독립 변수의 개수와 표본 크기를 고려하여 R-제곱을 조정합니다. 따라서, 불필요한 변수가 추가되면 조정된 R-제곱은 오히려 감소할 수 있습니다. 이는 모델의 진정한 설명력을 더 정확하게 반영합니다.

결론적으로, 다중 선형 회귀에서는 모델의 전반적인 설명력을 평가할 때 항상 조정된 R-제곱을 사용해야 합니다. 조정된 R-제곱은 일반적으로 R-제곱보다 작거나 같습니다.

변수의 유의성 검정 (Testing the Significance)

조정된 R-제곱은 모델 전체의 설명력을 알려주지만, 모델에 포함된 각 독립 변수가 종속 변수에 대해 유의미한 관계를 가지는지 여부는 별도로 평가해야 합니다.

- **귀무 가설 (Null Hypothesis, H_0):** 해당 독립 변수와 종속 변수 사이에는 아무런 관계가 없다. (즉, 해당 변수의 회귀 계수는 0이다.)
- **대립 가설 (Alternative Hypothesis, H_1):** 해당 독립 변수와 종속 변수 사이에는 유의미한 관계가 있다. (즉, 해당 변수의 회귀 계수는 0이 아니다.)

각 독립 변수에 대한 **p-값(p-value)**을 계산하여 이 가설을 검정합니다.

- **p-값 < 유의 수준(α):** 귀무 가설을 기각합니다. 이는 해당 독립 변수와 종속 변수 사이에 **유의미한 관계가 있다**는 것을 의미합니다. (일반적으로 유의 수준은 0.05 또는 0.01을 사용합니다.)
- **p-값 $\geq$ 유의 수준(α):** 귀무 가설을 기각할 수 없습니다. 이는 해당 독립 변수와 종속 변수 사이에 **유의미한 관계가 있다고 보기 어렵다**는 것을 의미합니다. 이러한 변수는 모델에서 제거하는 것을 고려해야 합니다.

8.3.2 예시 1: 제약 회사 영업 사원 성과 평가

문제 상황

한 대형 제약 회사의 지역 관리자는 영업 사원의 성과를 평가하고자 합니다. 일반적으로 판촉 활동이 매출에 가장 중요한 요인이라고 생각됩니다. 50명의 영업 사원에 대한 데이터가 수집되었으며, 연구 목표는 **판촉 예산이 연간 매출에 미치는 영향**을 파악하는 것입니다.

- y: 회사의 연간 제품 매출 (천 달러 단위)
- x: 판촉 예산 (천 달러 단위)

이것은 하나의 독립 변수만을 사용하므로, 단순 선형 회귀 분석을 먼저 실행합니다.

Excel 출력: 단순 선형 회귀 분석

아래 표는 판촉 예산(x)과 연간 매출(y) 간의 단순 선형 회귀 분석 결과입니다.

회귀 통계량 (Regression Statistics)

다중 R (Multiple R)	0.63587376
R-제곱 (R Square)	0.40433544
조정된 R-제곱 (Adjusted R Square)	0.39192577
표준 오차 (Standard Error)	1080.06248
관측치 수 (Observations)	50

ANOVA	df	SS	MS	F	유의 F (Significance F)
회귀 (Regression)	1	38008353.3	38008353.3	32.5823	6.97799E-07
잔차 (Residual)	48	55993678.5	1166534.97		
총계 (Total)	49	94002031.8			

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	8043.79161	387.114414	20.7788481	1.2E-25	7265.445917	8822.137311
판촉 예산 (Promotional budget)	0.5793468	0.10149578	5.70808782	7E-07	0.375275869	0.78341774

분석:

- R-제곱: 0.4043 (약 40.43%)입니다. 이는 판촉 예산이 연간 매출 변동의 약 40
- 판촉 예산의 p-값: 7E-07 (0.0000007)로 매우 작습니다. 이는 유의 수준 0.05 보다 훨씬 작으므로, 판촉 예산과 매출 사이에 **유의미한 관계가 있다**는 것을 알 수 있습니다.

결론: 판촉 예산은 매출에 유의미한 영향을 미치지만, 모델의 설명력(40

모델 개선: 다른 변수 추가

영업 직원들의 의견을 바탕으로, 매출에 영향을 미칠 수 있는 네 가지 변수를 추가하여 모델을 개선하기로 결정했습니다.

1. **영업 사원의 회사 근무 기간 (Sales agent time with company):** 경험이 많을수록 매출이 높을 수 있습니다.
2. **시장 잠재력 (Market potential):** 영업 지역의 시장 규모가 클수록 매출이 높을 수 있습니다.
3. **작년 대비 시장 잠재력 변화 (Market potential change since last year):** 시장의 성장 또는 축소가 매출에 영향을 미칠 수 있습니다.
4. **영업 사원에 대한 평균 고객 평점 (Average customer rating of the sales representative):** 고객 만족도가 높을수록 매출이 높을 수 있습니다.

새로운 회귀 변수 정의

이제 종속 변수 y 는 다섯 가지 독립 변수의 영향을 받는다고 가정합니다.

- y : 회사의 연간 제품 매출 (천 달러 단위)
- x_1 : 판촉 예산 (천 달러 단위)
- x_2 : 영업 사원의 근무 개월 수
- x_3 : 시장 잠재력 (10만 달러 단위)
- x_4 : 1년 동안의 시장 점유율 변화 (백분율)
- x_5 : 영업 사원의 평균 평점 (1 5점)

이러한 모든 변수에 대한 데이터를 수집한 후, 다중 선형 회귀 모델을 실행합니다.

Excel 출력: 다중 선형 회귀 분석 (초기 모델)

아래 표는 5개의 독립 변수를 포함한 다중 선형 회귀 분석 결과입니다.

회귀 통계량 (Regression Statistics)

다중 R (Multiple R)	0.8562096
R-제곱 (R Square)	0.7330949
조정된 R-제곱 (Adjusted R Square)	0.7027648
표준 오차 (Standard Error)	75.512825
관측치 수 (Observations)	50

ANOVA	df	SS	MS	F	유의 F (Significance F)
회귀 (Regression)	5	689124.0983	137824.8	24.171	1.29955E-11
잔차 (Residual)	44	250896.2198	5702.187		
총계 (Total)	49	940020.318			

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	520.08453	73.8516445	7.042288	1E-08	371.2463239	668.92274
판촉 예산 (Promotional budget)	3.0146845	0.840772413	3.585613	0.0008	1.32021902	4.7091499
근무 기간 (Time)	5.2706174	1.132557877	4.653729	3E-05	2.988097025	7.5531379
시장 잠재력 (Market potential)	0.0191646	0.006074822	3.154757	0.0029	0.006921585	0.0314076
시장 점유율 변화 (Market Share change)	-74.322586	98.78631602	-0.752357	0.4558	-273.4133239	124.76815
고객 평점 (Customer rating)	51.121931	17.83372083	2.866588	0.0063	15.18042783	87.063433

분석:

- **조정된 R-제곱**: 0.7027 (약 70.27%)입니다. 이는 단순 선형 회귀 모델의 40
- **변수 유의성 검정 (p-값)**: 각 독립 변수의 p-값을 확인하여 유의 수준 0.05보다 작은지 확인합니다.
 - 판촉 예산, 근무 기간, 시장 잠재력, 고객 평점: 모두 p-값이 0.05보다 작으므로 유의미합니다.
 - **시장 점유율 변화 (Market Share change)**: p-값이 0.4558로 0.05보다 훨씬 큼니다. 이는 시장 점유율 변화 변수가 매출과 유의미한 관계가 없다는 것을 의미합니다.

결론: 모델의 설명력은 향상되었지만, '시장 점유율 변화' 변수는 유의미하지 않습니다. 유의미하지 않은 변수는 모델의 노이즈로 작용할 수 있으므로 제거하고 모델을 다시 실행해야 합니다.

모델 개선: 유의미하지 않은 변수 제거

'시장 점유율 변화' 변수는 매출에 유의미한 영향을 미치지 않으므로, 이 변수를 모델에서 제거하고 회귀 분석을 다시 실행합니다.

Excel 출력: 다중 선형 회귀 분석 (개선된 모델) 아래 표는 '시장 점유율 변화' 변수를 제거한 후 4개의 독립 변수를 포함한 다중 선형 회귀 분석 결과입니다.

회귀 통계량 (Regression Statistics)

다중 R (Multiple R)	0.854202129
R-제곱 (R Square)	0.729661277
조정된 R-제곱 (Adjusted R Square)	0.705631168 (이전: 0.7027648)
표준 오차 (Standard Error)	75.14783835
관측치 수 (Observations)	50

ANOVA	df	SS	MS	F	유의 F (Significance F)
회귀 (Regression)	4	685896.43	171474.11	30.36446009	2.87686E-12
잔차 (Residual)	45	254123.89	5647.1976		
총계 (Total)	49	940020.32			

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	523.1894893	73.379843	7.1298802	6.54228E-09	375.3949	670.9840792
판촉 예산 (Promotional budget)	2.900752995	0.8230252	3.5245007	0.00098754	1.2430951	4.558410902
근무 기간 (Time)	5.325191755	1.1247696	4.7344733	2.21462E-05	3.0597894	7.590594082
시장 잠재력 (Market potential)	0.019537178	0.0060253	3.2425035	0.002234635	0.0074015	0.03167283
고객 평점 (Customer rating)	50.32410335	17.716119	2.8405828	0.006740209	14.642008	86.00619871

분석:

- **조정된 R-제곱:** 0.7056 (약 70.56%)로, 이전 모델의 0.7027보다 약간 증가했습니다. 이는 불필요한 변수를 제거함으로써 모델의 설명력이 실제로 개선되었음을 보여줍니다. 모델이 '시장 점유율 변화' 변수를 제거해도 손상되지 않았다는 것을 의미합니다.
- **변수 유의성 검정 (p-값):** 이제 모든 독립 변수(판촉 예산, 근무 기간, 시장 잠재력, 고객 평점)의 p-값이 유의 수준 0.05보다 작습니다. 이는 모델에 남아있는 모든 변수가 매출과 유의미한 관계를 가진다는 것을 의미합니다.

결론: 이 모델은 이제 모든 변수가 유의미하며, 매출 변동의 약 70.56%를 설명하는 만족스러운 예측 모델입니다.

회귀 방정식 작성 (Regression Equation)

이제 최종적으로 만족스러운 모델을 얻었으므로, Excel 출력의 '계수 (Coefficients)' 열에 있는 값을 사용하여 회귀 방정식을 작성할 수 있습니다.

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	523.1894893	73.379843	7.1298802	6.54228E-09	375.3949	670.9840792
판촉 예산 (Promotional budget)	2.900752995	0.8230252	3.5245007	0.00098754	1.2430951	4.558410902
근무 기간 (Time)	5.325191755	1.1247696	4.7344733	2.21462E-05	3.0597894	7.590594082
시장 잠재력 (Market potential)	0.019537178	0.0060253	3.2425035	0.002234635	0.0074015	0.03167283
고객 평점 (Customer rating)	50.32410335	17.716119	2.8405828	0.006740209	14.642008	86.00619871

회귀 방정식의 일반적인 형태는 다음과 같습니다:

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \cdots + b_kx_k$$

위 표의 계수 값을 사용하여 최종 회귀 방정식을 작성하면:

$$\hat{y} = 523.18949 + 2.90075x_1 + 5.32519x_2 + 0.01954x_3 + 50.32410x_4$$

여기서:

- $\hat{y}$: 연간 매출 예측치 (천 달러)
- x_1 : 판촉 예산 (천 달러)
- x_2 : 근무 개월 수
- x_3 : 시장 잠재력 (10만 달러)
- x_4 : 고객 평점 (1~5점)

이 방정식은 영업 사원의 근무 기간, 판촉 예산, 시장 잠재력, 평균 고객 평점과 매출 간의 관계를 나타냅니다.

예측하기 (Making a Prediction)

이제 개발된 회귀 방정식을 사용하여 특정 영업 사원의 매출을 예측할 수 있습니다.

질문: 근무 기간 5년, 판촉 예산 \$5,000, 시장 잠재력 \$8,000,000, 평균 고객 평점 4.3점인 영업 사원의 평균 매출 예측치는 얼마입니까?

변수 값 설정:

- x_1 (판촉 예산): \$5,000 $\rightarrow$ 5 (천 달러 단위로 입력)
- x_2 (근무 기간): 5년 $\rightarrow$ 60 (개월 단위로 입력)
- x_3 (시장 잠재력): \$8,000,000 $\rightarrow$ 8000 (10만 달러 단위로 입력, 즉 $8000 * 1000 = 8,000,000$)
- x_4 (고객 평점): 4.3 $\rightarrow$ 4.3

회귀 방정식에 대입:

$$\hat{y} = 523.18949 + 2.90075(5) + 5.32519(60) + 0.01954(8000) + 50.32410(4.3)$$

$$\hat{y} = 523.18949 + 14.50375 + 319.5114 + 156.32 + 216.39363$$

$$\hat{y} = 1229.91827$$

최종 예측: 매출은 천 달러 단위로 기록되었으므로, 예측 값에 1,000을 곱해야

합니다.

$$\hat{y} = 1229.91827 \times 1000 = \$1,229,918.27$$

따라서, 해당 영업 사원의 연간 매출 예측치는 약 \$1,229,918.27입니다. 이 값은 신뢰 구간의 중간 지점(point estimate)입니다.

연습 문제: 판촉 예산 증가의 영향

질문: 위에서 개발된 회귀 방정식이 주어졌을 때, 판촉 예산이 \$10,000 증가하면 예상 매출은 얼마나 증가할까요?

회귀 방정식:

$$\hat{y} = 523.18949 + 2.90075x_1 + 5.32519x_2 + 0.01954x_3 + 50.32410x_4$$

여기서 x_1 은 판촉 예산(천 달러)입니다.

풀이: 판촉 예산(x_1)의 계수는 2.90075입니다. 이는 다른 모든 변수가 일정할 때, 판촉 예산이 1천 달러 증가할 때마다 매출이 2.90075천 달러 증가한다는 의미입니다. 판촉 예산이 \$10,000 증가한다는 것은 x_1 이 10 (천 달러) 증가한다는 의미입니다. 따라서 예상 매출 증가는 다음과 같습니다:

$$\text{매출 증가} = 2.90075 \times 10 = 29.0075 \text{ (천 달러)}$$

$$\text{매출 증가} = \$29,007.5$$

판촉 예산이 \$10,000 증가하면 연간 매출은 약 \$29,007.5 증가할 것으로 예상됩니다.

가장 영향력 있는 변수 식별 (Most Impactful Variables)

회귀 모델의 계수(Coefficients)를 살펴보면, 어떤 독립 변수가 종속 변수에 가장 큰 영향을 미치는지 파악할 수 있습니다.

기타 통계량 (Other Statistics)	계수 (Coefficients)
절편 (Intercept)	523.1894893
판촉 예산 (Promotional budget)	2.900752995
근무 기간 (Time)	5.325191755
시장 잠재력 (Market potential)	0.019537178
고객 평점 (Customer rating)	50.32410335

계수 해석:

- **고객 평점 (Customer rating):** 계수 50.32410335. 다른 모든 변수가 일정할 때, 고객 평점이 1점 증가하면 매출은 50.32410335천 달러 (약 \$50,324) 증가합니다.
- **근무 기간 (Time):** 계수 5.325191755. 다른 모든 변수가 일정할 때, 근무 기간이 1개월 증가하면 매출은 5.325191755천 달러 (약 \$5,325) 증가합니다.
- **판촉 예산 (Promotional budget):** 계수 2.900752995. 다른 모든 변수가 일정할 때, 판촉 예산이 1천 달러 증가하면 매출은 2.900752995천 달러 (약 \$2,901) 증가합니다.
- **시장 잠재력 (Market potential):** 계수 0.019537178. 다른 모든 변수가 일정할 때, 시장 잠재력이 10만 달러 증가하면 매출은 0.019537178천 달러 (약 \$19.54) 증가합니다.

가장 큰 영향: 계수 값만 놓고 보면 **고객 평점**이 가장 큰 계수(50.324)를 가지며, 그 다음이 **근무 기간**(5.325)입니다. 이는 고객 평점이 1점 개선되면 매출이 약 \$50,324 증가하는 반면, 판촉 예산이 \$1,000 증가하면 매출이 약 \$2,901 증가하는 것을 의미합니다.

주의

주의: 계수 크기 비교 시 단위 고려 계수의 절대적인 크기만으로 영향력을 비교할 때는 각 변수의 측정 단위를 반드시 고려해야 합니다. 예를 들어, 고객 평점은 1점 단위로 변화하고, 판촉 예산은 1천 달러 단위로 변화합니다. 만약 모든 독립 변수가 동일한 척도로 표준화되어 있다면 계수 크기를 직접 비교하는 것이 더 정확합니다. 이 예시에서는 텍스트에서 계수 크기를 직접 비교하여 영향력을 판단하고 있으므로, 그 흐름을 따르되 단위에 대한 설명을 추가합니다.

경영학적 통찰: 이 분석 결과는 원래 판촉 예산이 가장 중요하다고 생각했던 것과는 다른 통찰력을 제공합니다.

- **고객 평점의 중요성:** 고객 평점이 1점 향상되면 평균 매출이 약 \$50,324 증가하는 것으로 나타나, 고객 서비스 개선이 영업 사원 성과에 가장 긍정적인 영향을 미친다는 것을 알 수 있습니다.
- **근무 기간의 영향:** 영업 사원의 근무 기간이 길어질수록 매출이 증가하는 경향을 보입니다. 이는 숙련된 영업 사원이 더 많은 판매를 할 수 있음을 시사합니다.

이러한 결과는 회사가 영업 사원들이 행복하게 오래 근무할 수 있는 환경을 제공하고, 전문적인 만족도가 우수한 고객 서비스로 이어지도록 장려하는 것이 회사의 수익에 매우 긍정적인 영향을 미칠 수 있음을 보여줍니다. 다중 회귀 분

Lesson 4-1.2: Excel에서 다중 회귀 모델 개발하기

이 섹션에서는 Excel의 '데이터 분석' 도구를 사용하여 다중 선형 회귀 모델을 개발하는 실제 절차를 단계별로 설명합니다.

데이터 준비: Sales Multiple Excel Worksheet

- **데이터 셋** : 'Multiple Sales' Excel 파일에는 'Sales', 'Promotional Budget', 'Time', 'Market Potential', 'Market Change', 'Customer Rating' 의 6개 열이 있습니다.
- **단위 확인**:
 - Sales: 천 달러
 - Promotional Budget: 천 달러
 - Market Potential: 천 달러
 - Time: 개월 수
 - Customer Rating: 0 5점

주의

Excel 데이터 배열의 중요성 Excel에서 회귀 분석을 실행할 때, 모든 독립 변수(X 값)는 연속된 열에 위치해야 합니다. 예를 들어, 종속 변수(Y 값)가 첫 번째 열에 있고, 그 다음으로 모든 독립 변수들이 나란히 이어져야 합니다. 만약 독립 변수들 사이에 다른 데이터 열이 끼어 있다면, Excel은 이를 올바르게 인식하지 못합니다. 따라서 분석을 시작하기 전에 워크시트의 열을 재배열하여 모든 독립 변수가 연속된 열에 오도록 해야 합니다.

Excel 데이터 분석 도구 사용하기

1. **'데이터 분석' 실행:** Excel 상단 메뉴에서 [데이터] 탭을 클릭한 후, [데이터 분석]을 선택합니다. (만약 '데이터 분석'이 보이지 않으면, Excel 옵션에서 '분석 도구' 추가 기능을 활성화해야 합니다.)
2. **'회귀 분석' 선택:** '데이터 분석' 팝업 창에서 '회귀 분석(Regression)'을 선택하고 [확인]을 클릭합니다.
3. **입력 Y 범위 설정:** '회귀 분석' 대화 상자에서 [입력 Y 범위(Input Y Range)]에 종속 변수(Sales)가 있는 열 전체를 선택합니다. (예: A1:A51)
4. **입력 X 범위 설정:** [입력 X 범위(Input X Range)]에 모든 독립 변수(Promotional Budget, Time, Market Potential, Market Change, Customer Rating)가 있는 연속된 열 전체를 선택합니다. (예: B1:F51)
5. **'레이블' 확인:** 첫 행에 변수 이름(레이블)이 포함되어 있다면, [레이블(Labels)] 체크박스를 선택합니다. 이렇게 하면 출력 결과에 변수 이름이 표시되어 해석하기 용이합니다.
6. **'신뢰 수준' 설정:** [신뢰 수준(Confidence Level)]은 기본값인 95%를 유지합니다.
7. **출력 옵션 설정:** [출력 옵션(Output Options)]에서 '새 워크시트(New Worksheet Ply)'를 선택하여 결과를 새로운 시트에 표시하도록 합니다.
8. **실행:** [확인] 버튼을 클릭하여 회귀 분석을 실행합니다.

초기 Excel 출력 결과 해석

회귀 분석을 실행하면 새로운 워크시트에 '요약 출력(Summary Output)'이 생성됩니다.

회귀 통계량 (Regression Statistics)

다중 R (Multiple R)	0.85620961
R-제곱 (R Square)	0.733094897
조정된 R-제곱 (Adjusted R Square)	0.702764772
표준 오차 (Standard Error)	75.51282548
관측치 수 (Observations)	50

ANOVA	df	SS	MS	F	유의 F (Significance F)
회귀 (Regression)	5	689124.0983	137824.8	24.17052	1.3E-11
잔차 (Residual)	44	250896.2198	5702.187		
총계 (Total)	49	940020.318			

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	520.0845335	73.8516445	7.042288	9.91E-09	371.2463	668.9227
판촉 예산 (Promotional Budget)	3.014684478	0.840772413	3.585613	0.000838	1.320219	4.70915
근무 시간 (Time)	5.270617446	1.132557877	4.653729	3E-05	2.988097	7.553138
시장 잠재력 (Market potential)	0.019164585	0.006074822	3.154757	0.002895	0.006922	0.031408
시장 점유율 변화 (Market Share change)	-74.32258581	98.78631602	-0.75236	0.455843	-273.413	124.76815
고객 평점 (Customer rating)	51.12193052	17.83372083	2.866588	0.006344	15.18043	87.06343

해석 단계:

1. 조정된 R-제곱 확인: 모델의 전반적인 설명력을 평가합니다. 여기서는 약 70.27%입니다.
2. 각 변수의 p-값 확인: '기타 통계량' 테이블의 'p-값' 열을 확인합니다. 유의 수준(일반적으로 0.05)보다 큰 p-값을 가진 변수가 있는지 찾습니다.
3. 유의미하지 않은 변수 식별: 위 표에서 '시장 점유율 변화' 변수의 p-값은 0.455843으로 0.05보다 훨씬 큼니다. 이는 이 변수가 매출과 유의미한 관계가 없다는 것을 의미합니다. 이러한 변수는 모델에 '노이즈'를 추가하며, 예측력을 저해할 수 있습니다.

모델 정리: 유의미하지 않은 변수 제거

유의미하지 않은 변수를 모델에서 제거하는 것은 모델을 '정리(clean up)'하는 중요한 단계입니다.

1. **변수 제거:** 원본 데이터 시트로 돌아가서, 유의미하지 않은 변수(여기서는 'Market Share change' 열)를 삭제합니다. (여러 개의 유의미하지 않은 변수가 있다면, p-값이 가장 높은 변수부터 하나씩 제거하고 매번 회귀 분석을 다시 실행하는 것이 좋습니다.)
2. **회귀 분석 재실행:** 변수를 제거한 후, 위에서 설명한 절차에 따라 '데이터 분석' 도구를 사용하여 회귀 분석을 다시 실행합니다. 이때, '입력 x 범위'가 변경된 열 범위에 맞게 올바르게 설정되었는지 확인해야 합니다.

개선된 모델의 Excel 출력 결과: '시장 점유율 변화' 변수를 제거한 후의 회귀 분석 결과는 다음과 같습니다.

회귀 통계량 (Regression Statistics)

다중 R (Multiple R)	0.854202129
R-제곱 (R Square)	0.729661277
조정된 R-제곱 (Adjusted R Square)	0.705631168
표준 오차 (Standard Error)	75.14783835
관측치 수 (Observations)	50

ANOVA	df	SS	MS	F	유의 F (Significance F)
회귀 (Regression)	4	685896.43	171474.11	30.36446009	2.87686E-12
잔차 (Residual)	45	254123.89	5647.1976		
총계 (Total)	49	940020.32			

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	523.1894893	73.379843	7.1298802	6.54228E-09	375.3949	670.9840792
판촉 예산 (Promotional budget)	2.900752995	0.8230252	3.5245007	0.00098754	1.2430951	4.558410902
근무 시간 (Time)	5.325191755	1.1247696	4.7344733	2.21462E-05	3.0597894	7.590594082
시장 잠재력 (Market potential)	0.019537178	0.0060253	3.2425035	0.002234635	0.0074015	0.03167283
고객 평점 (Customer rating)	50.32410335	17.716119	2.8405828	0.006740209	14.642008	86.00619871

최종 확인:

- **조정된 R-제곱:** 0.7056으로 이전 모델(0.7027)보다 약간 향상되었습니다. 이는 제거된 변수가 모델의 설명력을 저해하는 '노이즈'였음을 확인시켜 줍니다.
- **모든 p-값:** 이제 모든 독립 변수의 p-값이 0.05보다 작습니다. 이는 모델에 남아있는 모든 변수가 종속 변수(매출)와 유의미한 관계를 가진다는 것을 의미합니다.

이제 이 모델은 예측에 사용하기에 적합한 '좋은 모델'이라고 할 수 있습니다.

Lesson 4-1.3: 다중 회귀 Excel 출력 분석

이 섹션에서는 Excel에서 얻은 최종 회귀 모델 출력 결과를 활용하여 예측을 수행하고, 각 변수의 영향력을 분석하는 방법을 자세히 설명합니다.

회귀 방정식 작성 및 계수 해석

우리가 최종적으로 얻은 Excel 출력의 '기타 통계량' 테이블은 회귀 방정식을 구성하는 데 필요한 모든 정보를 제공합니다.

기타 통계량 (Other Statistics)	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
절편 (Intercept)	523.189489	73.37984272	7.12988022	6.5423E-09	375.3948994	670.984079
판촉 예산 (Promotional Budget)	2.900753	0.823025231	3.52450069	0.00098754	1.243095088	4.5584109
근무 기간 (Time)	5.32519175	1.124769632	4.73447327	2.2146E-05	3.0589789428	7.59059408
시장 잠재력 (Market potential)	0.01953718	0.006025337	3.24250349	0.00223463	0.007401525	0.03167283
고객 평점 (Customer rating)	50.32410335	17.716119	2.8405828	0.006740209	14.642008	86.00619871

회귀 방정식:

$$\hat{y} = 523.19 + 2.90x_1 + 5.33x_2 + 0.02x_3 + 50.32x_4$$

(여기서 계수들은 소수점 둘째 자리까지 반올림되었습니다.)

계수 해석: 각 독립 변수의 계수는 다른 모든 독립 변수가 일정하다는 가정 하에, 해당 변수가 1단위 증가할 때 종속 변수($\hat{y}$)가 얼마나 변화하는지를 나타냅니다.

- 판촉 예산(x_1) 계수 (2.90): 판촉 예산이 1천 달러 증가하면, 매출은 2.90천 달러 (즉, \$2,900) 증가할 것으로 예상됩니다.
- 근무 기간(x_2) 계수 (5.33): 근무 기간이 1개월 증가하면, 매출은 5.33천 달러 (즉, \$5,330) 증가할 것으로 예상됩니다.
- 시장 잠재력(x_3) 계수 (0.02): 시장 잠재력이 10만 달러 증가하면, 매출은 0.02천 달러 (즉, \$20) 증가할 것으로 예상됩니다.
- 고객 평점(x_4) 계수 (50.32): 고객 평점이 1점 증가하면, 매출은 50.32천 달러 (즉, \$50,320) 증가할 것으로 예상됩니다.

이러한 계수들을 통해 어떤 변수가 매출에 가장 큰 영향을 미치는지 파악할 수 있습니다. 예를 들어, 고객 평점 계수(50.32)는 다른 변수들에 비해 훨씬 크므로, 고객 서비스 개선이 매출 증대에 가장 효과적인 방법임을 시사합니다.

Excel을 이용한 예측 수행

회귀 방정식을 사용하여 특정 조건에서의 매출을 예측하는 방법을 Excel에서 직접 실습해봅니다.

예측 시나리오: 근무 기간 5년, 판촉 예산 \$5,000, 시장 잠재력 \$8,000,000, 평균 고객 평점 4.3점인 영업 사원의 매출 예측.

단계:

1. **계수 복사:** Excel 출력에서 '계수(Coefficients)' 열의 값들을 새로운 셀에 복사합니다.
2. **독립 변수 값 입력:** 예측하고자 하는 시나리오에 맞춰 각 독립 변수의 값을 입력합니다. 이때, 데이터의 단위(천 달러, 개월 등)를 정확히 맞춰야 합니다.
 - 절편: 해당 없음
 - 판촉 예산 (x_1): \$5,000 → 5 (천 달러)
 - 근무 기간 (x_2): 5년 → 60 (개월)
 - 시장 잠재력 (x_3): \$8,000,000 → 8000 (10만 달러)
 - 고객 평점 (x_4): 4.3 → 4.3
3. **예측 계산 (SUMPRODUCT 함수 사용):** Excel의 SUMPRODUCT 함수를 사용하여 예측 값을 계산합니다. 이 함수는 두 배열의 해당 요소들을 곱한 후 그 합계를 반환합니다.

```
1 =Intercept_Coefficient + SUMPRODUCT(Coefficients_Range, X_Values_Range)
2
```

Listing 8.1: SUMPRODUCT 함수를 이용한 예측

예를 들어, 계수가 B28:B32에 있고 X 값이 C28:C32에 있다면: =B28 + SUMPRODUCT(B29:B32, C29:C32)

4. **계수 범위 고정:** 만약 여러 시나리오에 대해 예측을 반복하고 싶다면, SUMPRODUCT 함수 내에서 계수 범위(예: B29:B32)를 절대 참조(예: \$B29:\$B32)로 고정합니다. (셀을 선택하고 F4 키를 누르면 됩니다.) 이렇게 하면 X 값만 변경하면서 쉽게 예측 값을 얻을 수 있습니다.
5. **단위 변환:** 최종 예측 값은 데이터의 원래 단위(여기서는 천 달러)로 나오므로, 필요한 경우 1,000을 곱하여 실제 달러 단위로 변환합니다.

예측 결과: 위 시나리오에 대한 예측 값은 약 1229.89583 (천 달러)입니다. 실제 달러로 변환하면 \$1,229,895.83이 됩니다.

변수 변화의 영향 시뮬레이션: 예를 들어, 판촉 예산을 \$5,000에서 \$6,000으로 (즉, x_1 을 5에서 6으로) 증가시키면, 다른 모든 변수가 동일할 때 매출은 판촉 예산의 계수(2.90)만큼 증가합니다. 새로운 예측 값에서 이전 예측 값을 빼면 정확히 2.90 (천 달러)의 차이가 나는 것을 확인할 수 있습니다. 이는 모델의 계수가 어떻게 개별 변수의 한계 효과(marginal effect)를 나타내는지 보여줍니다. 이러한 방식으로 모델을 활용하여 다양한 비즈니스 시나리오를 시뮬레이션하고 의사결정을 지원할 수 있습니다.

8.4 FAQ: 초심자를 위한 질문과 답변

자주 묻는 질문

1. Q: 단순 선형 회귀와 다중 선형 회귀의 가장 큰 차이점은 무엇인가요? A: 가장 큰 차이점은 독립 변수의 개수입니다. 단순 선형 회귀는 하나의 독립 변수만을 사용하여 종속 변수를 예측하는 반면, 다중 선형 회귀는 두 개 이상의 독립 변수를 동시에 사용하여 종속 변수를 예측합니다. 다중 회귀는 현실의 복잡한 관계를 더 잘 모델링할 수 있습니다.
2. Q: 다중 회귀에서 R-제곱 대신 조정된 R-제곱을 사용하는 이유는 무엇인가요? A: R-제곱은 모델에 독립 변수를 추가하기만 해도 그 변수가 유의미하지 않더라도 항상 증가하거나 유지되는 경향이 있습니다. 이는 모델의 설명력을 과대평가할 수 있습니다. 조정된 R-제곱은 이러한 문제를 보정하여, 모델에 추가된 변수의 개수를 고려해 모델의 진정한 설명력을 더 정확하게 평가합니다.
3. Q: Excel에서 회귀 분석을 실행할 때 독립 변수 열이 연속적이어야 하는 이유는 무엇인가요? A: Excel의 '데이터 분석' 도구는 '입력 X 범위'를 설정할 때 선택된 범위 내의 모든 열을 독립 변수로 간주합니다. 만약 독립 변수들 사이에 관련 없는 열이 있다면, Excel은 그 열도 독립 변수로 포함하여 잘못된 분석 결과를 도출할 수 있습니다. 따라서 정확한 분석을 위해 독립 변수들은 반드시 연속된 열에 배치되어야 합니다.
4. Q: 회귀 분석 결과에서 p-값이 높은 변수는 어떻게 처리해야 하나요? A: p-값이 유의 수준(예: 0.05)보다 높은 변수는 종속 변수와 유의미한 통계적 관계가 없다고 판단됩니다. 이러한 변수는 모델의 예측력을 저해하는 '노이즈'로 작용할 수 있으므로, 모델에서 제거하고 회귀 분석을 다시 실행하는 것이 일반적인 절차입니다. p-값이 가장 높은 변수부터 하나씩 제거하는 것이 좋습니다.
5. Q: 회귀 계수(Coefficients)의 크기가 클수록 해당 변수의 영향력이 크다고 볼 수 있나요? A: 일반적으로는 그렇지만, 항상 그런 것은 아닙니다. 계수의 크기를 비교할 때는 각 독립 변수의 측정 단위를 반드시 고려해야 합니다. 예를 들어, 1점 단위로 측정되는 평점 변수의 계수와 1000달러 단위로 측정되는 예산 변수의 계수를 직접 비교하는 것은 오해를 불러일으킬 수 있습니다. 모든 변수가 동일한 척도로 표준화되어 있다면 계수 크기를 직접 비교하는 것이 더 정확합니다.

8.5 빠르게 훑어보기 (1페이지 요약)

다중 선형 회귀 핵심 요약

개념: 여러 독립 변수로 하나의 종속 변수 예측. 현실의 복잡한 문제 해결에 적합. **모델:** $\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_kx_k$ (최소 제곱법 사용). **가정:** 잔차의 평균 0, 등분산성, 정규성, 독립성.

모델 평가 지표**조정된 R-제곱 (Adjusted R^2):**

- 다중 회귀 모델의 전반적인 설명력 평가.
- 독립 변수 개수에 따른 R-제곱의 과대평가 보정.
- 값이 높을수록 모델의 설명력이 좋음.

p-값 (p-value):

- 각 독립 변수의 유의성 검정.
- $p\text{-값} < \text{유의 수준}(\alpha, \text{보통 } 0.05) \rightarrow \text{유의미한 관계}.$
- $p\text{-값} \geq \text{유의 수준}(\alpha) \rightarrow \text{유의미한 관계 없음 (모델에서 제거 고려)}.$

Excel을 이용한 모델 개발 절차

1. 데이터 준비: 모든 독립 변수를 연속된 열에 배치.
2. 회귀 분석 실행: [데이터] $\rightarrow$ [데이터 분석] $\rightarrow$ [회귀 분석].
3. Y/X 범위 설정: 종속 변수(Y)와 모든 독립 변수(X) 범위 지정. '레이블' 체크.
4. 초기 결과 해석: 조정된 R-제곱 및 각 변수의 p-값 확인.
5. 모델 정리: p-값이 높은(유의미하지 않은) 변수 제거.
6. 재실행 및 최종 확인: 변수 제거 후 다시 회귀 분석 실행, 모든 변수의 유의성 확인.

모델 활용

회귀 방정식 작성: 최종 모델의 계수들을 사용하여 예측 방정식 구성. **예측 수행:** 방정식에 새로운 독립 변수 값 대입 (단위 주의). **영향력 분석:** 각 변수의 계수 크기를 비교하여 종속 변수에 미치는 상대적 영향력 파악 (단위 고려).

8.6 핵심 개념 및 원리: 질적 데이터와 더미 변수

8.6.1 1. 질적 데이터의 회귀 모델 포함 필요성

지금까지 우리는 회귀 모델에 오직 양적(Quantitative) 데이터만을 포함하는 방법을 살펴보았습니다. 하지만 실제 세상의 많은 현상들은 성별, 지역, 전공과 같은 질적(Qualitative) 또는 기술적(Descriptive) 데이터의 영향을 받습니다.

예제**예시:**

- **성별 임금 격차:** 성별이 개인의 급여에 영향을 미칠까요?
 - **우편번호와 기대 수명:** 거주하는 우편번호가 기대 수명에 영향을 미칠까요?
- 이러한 질문들은 모두 질적 데이터(성별, 우편번호)가 중요한 설명 변수가 될 수 있음을 보여줍니다. 우편번호는 숫자처럼 보이지만, 실제로는 수량을 나타내는 것이 아니라 지역이라는 '범주'를 나타내는 질적 데이터입니다.

8.6.2 2. 범주형 변수의 직접 입력 불가 및 더미 변수 도입

회귀 모델은 기본적으로 숫자 데이터를 기반으로 작동합니다. 따라서 '남성', '여성' 또는 '공학', '경영'과 같은 범주형 예측 변수는 회귀 모델에 직접 입력할 수 없습니다. 이러한 질적 데이터를 모델에 포함하기 위해서는 추가적인 단계, 즉 '코딩(Coding)'이 필요합니다.

더미 변수(Dummy Variable)의 정의

더미 변수(또는 지표 변수, Indicator Variable)는 범주형 변수를 숫자로 표현하기 위해 사용됩니다.

- 더미 변수는 항상 0 또는 1의 값을 가집니다.
- 특정 범주에 해당하면 1, 그렇지 않으면 0으로 코딩합니다.

예제

예시: 비만 계산기 연구 이전 강의에서 소개된 비만 계산기 연구에서는 다음과 같은 범주형 변수들이 있었습니다.

- 임신 중 흡연 여부: '예' 또는 '아니오'
- 산모의 직업 범주: 네 가지 선택지 중 하나

이러한 변수들은 그 의미가 숫자로 표현될 수 있도록 먼저 코딩되어야 합니다. 예를 들어, 임신 중 흡연 여부의 경우, '예'를 1로, '아니오'를 0으로 코딩할 수 있습니다.

8.6.3 3. 두 가지 범주를 가진 질적 데이터 처리

가장 간단한 경우로, 범주가 두 개인 질적 변수를 다루는 방법을 살펴봅니다.

3.1. 더미 변수 생성의 원칙: 다중 공선성 회피

범주형 변수를 더미 변수로 코딩할 때, 중요한 원칙은 '다중 공선성(Collinearity)'을 피하는 것입니다.

다중 공선성(Collinearity)이란?

다중 공선성은 다중 회귀 모델에서 하나의 독립 변수가 다른 독립 변수와 매우 높은 상관관계를 가질 때 발생합니다.

- 이는 독립성 가정을 위반하며, 회귀 계수의 추정치를 불안정하게 만들고 모델의 신뢰성을 떨어뜨립니다.
- 다중 공선성이 발생하면, 해당 변수 중 하나를 모델에서 제거해야 합니다.

주의

잘못된 더미 변수 코딩 예시 (다중 공선성 유발): 성별 변수(남성/여성)를 다음과 같이 코딩하는 것은 다중 공선성을 유발합니다.

- DummyFemale = 1 (여성 간호사), 0 (그 외)
- DummyMale = 1 (남성 간호사), 0 (그 외)

만약 DummyFemale이 1이면, 해당 간호사는 여성이고, 따라서 DummyMale은 반드시

0이 됩니다. 반대로 `DummyFemale`이 0이면, 해당 간호사는 남성이고, `DummyMale`은 1이 됩니다. 이 두 변수는 완벽하게 반대되는 관계(음의 상관관계)를 가지므로, 서로 완전히 상관되어 다중 공선성을 일으킵니다.

핵심 정보

다중 공선성을 피하는 올바른 더미 변수 코딩: 범주가 K 개인 범주형 변수의 경우, $K - 1$ 개의 더미 변수를 생성해야 합니다.

- 두 가지 범주(예: 남성/여성)의 경우, 하나의 더미 변수만 사용합니다.
- 하나의 범주를 '기준(Reference)' 범주로 설정하고 0으로 코딩합니다.
- 다른 범주를 1로 코딩합니다.

예제

올바른 성별 더미 변수 코딩 예시: 성별 변수(남성/여성)의 경우, 하나의 더미 변수 `DG`를 다음과 같이 정의할 수 있습니다.

- `DG = 1` (남성 간호사)
- `DG = 0` (여성 간호사)

여기서 '여성 간호사'가 기준 범주가 됩니다.

3.2. 사례 연구: 간호사 성별 임금 격차

미국 남성 및 여성 간호사를 대상으로 한 연구에서 성별 임금 불평등이 존재한다는 사실이 밝혀졌습니다. 이 연구는 성별이 간호사의 급여를 예측하는 설명 변수임을 보여주었습니다. 유사한 데이터를 사용하여 성별과 급여 간의 상관관계를 확인하는 방법을 살펴보겠습니다.

연구 목표: 성별이 급여에 영향을 미치는지 확인

변수 정의:

- `y`: 급여 (Salary)
- `x1`: 경력 (개월 단위, Months of Experience)
- `x2`: 성별 (Categorical, 남성 또는 여성)

데이터 수집: 120명의 남성 간호사와 120명의 여성 간호사의 급여와 경력(개월)을 무작위로 수집했습니다.

데이터 코딩 예시: 아래 표는 코딩된 데이터의 일부를 보여줍니다. 'DG' 열은 성별 더미 변수로, 남성 간호사는 1, 여성 간호사는 0으로 코딩되었습니다.

3.3. 회귀 분석 결과 해석 (Excel 출력)

코딩된 데이터를 사용하여 회귀 분석을 실행한 결과는 다음과 같습니다.

핵심 요약

결과 해석:

- 모델 적합도 (Adjusted R Square): 0.940003258 (약 94%). 이 모델에 포함된

Table 8.1: 간호사 급여 및 경력 데이터 (코딩된 성별 포함)

급여 (Salary)	경력 (Months of Experience)	DG (성별)
\$70,124.00	46	1
\$66,992.00	13	1
\$71,922.00	60	1
\$68,601.00	21	1
\$76,875.00	116	1
\$73,400.00	107	1
\$67,298.00	1	1
\$66,273.00	69	0
\$62,701.00	25	0
\$67,892.00	68	0
\$71,482.00	118	0
\$67,971.00	99	0
\$65,637.00	56	0
\$65,622.00	45	0

Table 8.2: 회귀 통계 (성별 더미 변수 포함)

회귀 통계	값
Multiple R	0.969796537
R Square	0.940505323
Adjusted R Square	0.940003258
Standard error	850.7891425
Observations	240

Table 8.3: 기타 통계 (계수, p-값 등)

변수	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
Intercept	61149.40381	138.0981426	443.796715	0	60877.34716	61421.46
Months of experience	83.30084538	1.668613537	49.3228921	1.2737E-126	79.01363665	85.588054
Gender	4667.701219	110.7148371	42.159672	4.041E-112	4449.590331	4885.8121

설명 변수(경력, 성별)가 급여 데이터의 변동을 94% 설명합니다. 이는 매우 좋은 모델입니다.

- **변수의 유의성 (p-value):** 'Months of experience'와 'Gender' 모두 p-값이 매우 작습니다 (거의 0에 가까움). 이는 두 변수 모두 급여와 통계적으로 유의미한 관계를 가지고 있음을 의미합니다.

3.4. 회귀 모델 방정식 및 계수 해석

위 결과에 기반한 회귀 방정식은 다음과 같습니다.

$$\hat{y} = 61,149.40 + 82.3x_1 + 4667.7x_2$$

여기서:

- $\hat{y}$: 예측 급여 (Predicted Salary)
- x_1 : 경력 (Months of experience)
- x_2 : 성별 더미 변수 (Gender, 1 = 남성, 0 = 여성)

더미 변수 계수 해석

여성 간호사의 경우 ($x_2 = 0$):

$$\hat{y} = 61,149.40 + 82.3x_1 + 4667.7(0)$$

$$\hat{y} = 61,149.40 + 82.3x_1$$

남성 간호사의 경우 ($x_2 = 1$):

$$\hat{y} = 61,149.40 + 82.3x_1 + 4667.7(1)$$

$$\hat{y} = 61,149.40 + 82.3x_1 + 4667.70$$

이것은 남성 간호사가 여성 간호사보다 평균적으로 \$4,667.70 더 많은 급여를 받는다는 것을 의미합니다. 즉, 더미 변수의 계수는 1로 코딩된 범주가 0으로 코딩된 기준 범주에 비해 종속 변수에 미치는 '추가적인 효과'를 나타냅니다.

예제

예측 급여 계산 예시: 평균 경력이 10개월인 두 그룹의 간호사(한 그룹은 남성, 다른 그룹은 여성)의 예측 평균 급여를 계산해 봅시다.

- **그룹 1 (여성 간호사):** $x_1 = 10, x_2 = 0$

$$\hat{y} = 61,149.40 + 82.3(10) + 4667.7(0) = 61,149.40 + 823 = \$61,972.41$$

- **그룹 2 (남성 간호사):** $x_1 = 10, x_2 = 1$

$$\hat{y} = 61,149.40 + 82.3(10) + 4667.7(1) = 61,149.40 + 823 + 4667.70 = \$66,640.11$$

두 그룹의 예측 급여 차이는 $\$66,640.11 - \$61,972.41 = \$4,667.70$ 으로, 성별 더

미 변수의 계수와 정확히 일치합니다.

3.5. 더미 변수 코딩 방식 변경 시 영향

만약 더미 변수 코딩을 반대로 했다면 어떻게 될까요? 즉, $x_2 = 1$ (여성 간호사), $x_2 = 0$ (남성 간호사)로 코딩했을 때의 결과를 살펴보겠습니다.

Table 8.4: 회귀 통계 (성별 더미 변수 역코딩)

회귀 통계	값
Multiple R	0.969796537
R Square	0.940505323
Adjusted R Square	0.940003258
Standard error	850.7891425
Observations	240

Table 8.5: ANOVA (성별 더미 변수 역코딩)

	df	SS	MS	F	Significance F
Regression	2	2711910611	1355955305	1873.274826	5.9656E-146
Residual	237	171550593.1	723842.165		
Total	239	2883461204			

Table 8.6: 기타 통계 (계수, p-값 등) (성별 더미 변수 역코딩)

변수	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
Intercept	65817.10503	126.8307712	518.93641	0	65567.24537	66066.965
Months of experience	82.30084538	1.668613537	49.3228921	1.2737E-126	79.01363665	85.588054
Gender	-4667.70122	110.7148371	-42.159672	4.041E-112	-4885.81211	-4449.59

핵심 요약

역코딩 결과 해석:

- **Adjusted R-squared:** 이전과 동일하게 0.940003258입니다. 모델의 전반적인 설명력은 변하지 않습니다.
- **Gender 계수:** 값은 동일하지만 부호가 음수(-4667.70122)로 바뀌었습니다. 이는 여성 간호사가 남성 간호사(기준 범주)보다 평균적으로 \$4,667.70 적게 받는다는 것을 의미합니다.

- **Intercept 계 수** : 이 전 모 델 의 절 편 (61149.40381) 과 달 라 졌 습 니 다 (65817.10503).

절편(Intercept)의 의미 변화

절편은 모든 독립 변수가 0일 때 종속 변수의 예측값입니다.

- **남성=1, 여성=0으로 코딩했을 때**: 모든 변수가 0인 경우: 경력(x_1) = 0 (신입), 성별(x_2) = 0 (여성). 따라서 절편 \$61,149.40은 신입 여성 간호사의 예상 시작 급여를 의미합니다.
- **여성=1, 남성=0으로 코딩했을 때**: 모든 변수가 0인 경우: 경력(x_1) = 0 (신입), 성별(x_2) = 0 (남성). 따라서 절편 \$65,817.10은 신입 남성 간호사의 예상 시작 급여를 의미합니다.

두 절편 값의 차이 (\$65,817.10 - \$61,149.40 = \$4,667.70)는 성별에 따른 급여 차이와 정확히 일치합니다. 이는 어떤 범주를 0으로 코딩하느냐에 따라 절편의 해석이 달라진다는 것을 보여줍니다.

3.6. 회귀 분석의 통찰력

단순히 두 그룹 간의 급여 차이를 가설 검정으로 확인할 수도 있지만, 회귀 분석은 더 많은 정보를 제공합니다.

- **변수 효과 분리**: 회귀 분석은 각 변수의 효과를 분리하여 파악할 수 있게 해줍니다. 이 예시에서는 급여 차이의 두 가지 원인(경력과 성별)을 동시에 분석하고, 각각이 급여에 미치는 영향을 개별적으로 확인할 수 있었습니다.
- **설명력 정량화**: 경력과 성별이 급여 변동의 94%를 설명한다는 것을 알 수 있습니다. 만약 성별만으로 단순 선형 회귀를 실행했다면, 성별이 급여 변동의 약 33%를 설명한다는 것을 알 수 있습니다.

회귀는 예측 모델로서 강력할 뿐만 아니라, 관심 변수에 영향을 미치는 변수들을 분리하여 그 영향을 파악하는 훌륭한 방법입니다. 이를 통해 우리는 독립 변수를 조정하여 더 나은 결과를 얻을 수 있습니다.

8.7 절차/방법: Excel에서 더미 변수 사용하기 (두 가지 범주)

8.7.1 1. 데이터 준비: 원본 데이터 확인

- **파일 다운로드**: 'Nurses Salary Excel file'을 다운로드합니다. (Uncoded data - 첫 번째 워크시트 참조)
- **원본 데이터**: 이 워크시트에는 남성 간호사의 급여와 경력, 여성 간호사의 급여와 경력이 각각 별도의 열에 정리되어 있습니다.

8.7.2 2. 데이터 코딩: 더미 변수 생성

회귀 분석을 위해 범주형 변수인 '성별'을 숫자 값(0 또는 1)으로 코딩해야 합니다.

1. **새 워크시트 생성**: 'Coded data'라는 새 탭을 만듭니다.

2. **열 헤더 설정:** 새 워크시트에 'Salary', 'Months of Experience', 'Gender'라는 세 개의 열 헤더를 입력합니다.
3. **남성 데이터 복사 및 코딩:**
 - 'Uncoded data' 탭으로 돌아가 남성 간호사의 급여와 경력 데이터를 모두 선택하여 복사합니다.
 - 'Coded data' 탭의 'Salary' 및 'Months of Experience' 열에 붙여넣습니다.
 - 'Gender' 열에 해당 데이터의 첫 번째 행에 '1'을 입력합니다 (남성 간호사를 1로 코딩).
 - '1'이 입력된 셀의 오른쪽 하단 모서리를 더블 클릭하여 모든 남성 간호사 데이터에 '1'이 자동으로 채워지도록 합니다. (총 120명의 남성 간호사가 1로 코딩됩니다.)
4. **여성 데이터 복사 및 코딩:**
 - 'Uncoded data' 탭으로 돌아가 여성 간호사의 급여와 경력 데이터를 모두 선택하여 복사합니다.
 - 'Coded data' 탭의 남성 데이터 바로 아래에 붙여넣습니다 (예: A122 셀부터 시작).
 - 'Gender' 열에 해당 데이터의 첫 번째 행에 '0'을 입력합니다 (여성 간호사를 0으로 코딩).
 - '0'이 입력된 셀의 오른쪽 하단 모서리를 더블 클릭하여 모든 여성 간호사 데이터에 '0'이 자동으로 채워지도록 합니다.
5. **데이터 확인:** 'Coded data' 탭에서 모든 데이터가 올바르게 복사되고 'Gender' 열이 0 또는 1로 코딩되었는지 확인합니다.

8.7.3 3. Excel에서 회귀 분석 실행

이제 모든 변수가 숫자이므로 회귀 분석을 실행할 수 있습니다.

1. **데이터 분석 도구 열기:** Excel 메뉴에서 '데이터' 탭을 클릭한 다음 '데이터 분석'을 클릭합니다.
2. **회귀 선택:** '데이터 분석' 대화 상자에서 '회귀(Regression)'를 선택하고 '확인'을 클릭합니다.
3. **입력 범위 설정:**
 - Input Y Range (입력 Y 범위): 'Coded data' 탭에서 'Salary' 열 전체를 선택합니다 (예: \$A\$1:\$A\$241).
 - Input X Range (입력 X 범위): 'Coded data' 탭에서 'Months of Experience'와 'Gender' 열 전체를 선택합니다 (예: \$B\$1:\$C\$241).
 - Labels (레이블): 첫 행에 열 이름이 포함되어 있으므로 'Labels' 체크박스를 선택합니다.
4. **출력 옵션 설정:** 'Output Options (출력 옵션)' 섹션에서 'New Worksheet Ply (새 워크시트)'를 선택하여 결과를 새 시트에 출력하도록 합니다.
5. **실행:** '확인'을 클릭하여 회귀 분석을 실행합니다.

8.7.4 4. 회귀 분석 결과 해석

새로 생성된 워크시트에는 회귀 분석 결과가 요약되어 있습니다.

Table 8.7: Excel 회귀 통계 출력 예시

회귀 통계	값
Multiple R	0.969504909
R Square	0.939939769
Adjusted R Square	0.939432931
Standard error	867.9476988
Observations	240

Table 8.8: Excel ANOVA 출력 예시

	df	SS	MS	F	Significance F
Regression	2	2.79E+09	1.4E+09	1854.519	1.8E-145
Residual	237	1.79E+08	753333.2		
Total	239	2.97E+09			

Table 8.9: Excel 기타 통계 출력 예시 (계수, p-값 등)

변수	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
Intercept	60978.8066	140.8833	432.8321	0	60701.26	61256.35
Months of Experience	82.18317197	1.702266	48.27869	1.3E-124	78.82967	85.53668
Gender	4845.369626	112.9477	42.89923	1.1E-113	4622.86	5067.879

핵심 요약

주요 해석:

- **모델 적합도 (Adjusted R Square):** 약 0.9394 (93.94%). 모델의 설명력이 매우 높습니다.
- **변수의 유의성 (p-value):** 'Months of Experience'와 'Gender' 모두 p-값이 매우 작으므로, 두 변수 모두 급여와 유의미한 관계를 가집니다.
- **회귀 방정식:** $\hat{y} = 60,978.806 + 82.183x_1 + 4845.37x_2$
 - x_1 : 경력 (개월). 경력 1개월 증가 시 급여는 약 \$82.18 증가합니다.
 - x_2 : 성별 더미 변수 (1=남성, 0=여성).
- **절편 해석:** 절편 \$60,978.806은 $x_1 = 0$ (신입)이고 $x_2 = 0$ (여성)일 때의 예측

급여입니다. 즉, 신입 여성 간호사의 예상 시작 급여입니다.

- Gender 계수 해석: \$4,845.37은 남성 간호사가 여성 간호사보다 평균적으로 더 받는 급여를 나타냅니다.

예제

예측 예시: 20개월 경력의 여성 간호사와 남성 간호사의 급여를 예측해 봅시다.

- 20개월 경력 여성 간호사: $(x_1 = 20, x_2 = 0)$

$$\hat{y} = 60,978.806 + 82.183(20) + 4845.37(0) = 60,978.806 + 1643.66 = \$62,622.47$$

- 20개월 경력 남성 간호사: $(x_1 = 20, x_2 = 1)$

$$\hat{y} = 60,978.806 + 82.183(20) + 4845.37(1) = 60,978.806 + 1643.66 + 4845.37 = \$67,467.84$$

두 급여의 차이는 \$4,845.37로, 'Gender' 계수와 정확히 일치합니다.

핵심 정보

스스로 해보기: 성별 더미 변수를 반대로 코딩해 보세요 ($x_2 = 1$ 을 여성, $x_2 = 0$ 을 남성).

- 'Gender' 계수의 부호가 음수로 바뀌고, 절편 값이 달라질 것입니다.
- 새로운 절편은 신입 남성 간호사의 예상 시작 급여를 나타낼 것입니다.

8.8 핵심 개념 및 원리: 여러 범주를 가진 질적 데이터 처리

8.8.1 1. 여러 범주를 가진 질적 데이터의 필요성

대학 상담사는 학생들이 열심히 공부하여 높은 GPA로 졸업하도록 동기를 부여하고 싶어 합니다. 이를 위해 졸업생의 시작 급여와 GPA 간의 관계 데이터를 보여주려고 합니다. 100명의 최근 졸업생 데이터를 가지고 있습니다.

초기 분석 (단순 선형 회귀): GPA만을 독립 변수로 사용한 단순 선형 회귀 분석 결과는 다음과 같습니다.

핵심 요약

초기 분석 결과:

- GPA는 p-값이 매우 작아 통계적으로 매우 유의미합니다.
- 하지만 Adjusted R Square는 약 0.3297 (32.97%)에 불과합니다. 이는 GPA가 시작 급여 변동의 약 33%만을 설명하며, 나머지 67%는 알려지지 않은 요인에 의해 설명된다는 의미입니다.

상담사는 이 결과에 만족하지 못하고, 졸업생의 급여에 기여할 것이라고 생각하는 또 다른 변수인 '전공(Major)'을 분석에 추가하기로 결정했습니다.

새로운 설명 변수: 전공 (Major) 전공은 여러 가지 범주를 가질 수 있으므로, 분석을 단순화하기 위해 다음과 같이 네 가지 범주로 분류했습니다.

1. 공학 (Engineering)

Table 8.10: 단순 선형 회귀 통계 (GPA만 포함)

회귀 통계	값
Multiple R	0.580085329
R Square	0.336498989
Adjusted R Square	0.32972857
Standard error	2236.609365
Observations	100

2. 경영 (Business)

3. 농업 (Agriculture)

4. 인문학 (Liberal Arts)

새로운 다중 회귀 모델의 변수:

- GPA: 숫자형 변수
- Major: 범주형 변수 (네 가지 가능성)

전공은 범주형 변수이므로, 회귀 분석을 실행하기 전에 더미 변수를 생성해야 합니다.

8.8.2 2. 여러 범주에 대한 더미 변수 생성

두 가지 범주를 다룰 때와 마찬가지로, 다중 공선성을 피하기 위해 $K - 1$ 개의 더미 변수를 생성해야 합니다.

더미 변수 생성 규칙 (여러 범주)

범주가 K 개인 범주형 변수의 경우, $K - 1$ 개의 더미 변수를 생성합니다.

- 이 예시에서는 전공이 네 가지 범주($K = 4$)이므로, 세 가지 더미 변수를 생성합니다.
- 하나의 범주를 '기준(Reference)' 범주로 남겨두고, 이 범주에 해당하는 모든 더미 변수 값을 0으로 설정합니다.

전공 더미 변수 정의 예시: 네 가지 전공 범주에 대해 세 가지 더미 변수를 다음과 같이 정의할 수 있습니다.

- Engineering = 1 (공학 전공), 0 (그 외)
- Business = 1 (경영 전공), 0 (그 외)
- Liberal Arts = 1 (인문학 전공), 0 (그 외)

이 경우, 농업(Agriculture) 전공은 어떤 더미 변수도 1이 아닌 경우(즉, 모든 더미 변

수가 0인 경우)에 해당하므로 기준 범주가 됩니다.

핵심 정보

어떤 범주를 기준 범주로 할 것인가? 어떤 범주를 기준 범주(0으로 코딩되는)로 남겨두는지는 분석 결과의 계수 값에 영향을 미치지만, 모델의 전반적인 설명력이나 통계적 유의성에는 영향을 미치지 않습니다. 즉, 어떤 범주를 제외하든 최종적인 분석과 결론은 동일합니다.

8.8.3 3. 회귀 분석 결과 해석 (Excel 출력)

GPA와 전공 더미 변수를 모두 포함한 다중 회귀 분석 결과는 다음과 같습니다.

Table 8.11: 다중 회귀 통계 (GPA 및 전공 더미 변수 포함)

회귀 통계	값
Multiple R	0.911820707
R Square	0.831417001
Adjusted R Square	0.82431877
Standard error	1145.057951
Observations	100

Table 8.12: ANOVA (GPA 및 전공 더미 변수 포함)

	df	SS	MS	F	Significance F
Regression	4	614304456.1	153576114	117.1302	7.604E-36
Residual	95	124559982.6	1311157.7		
Total	99	738864438.8			

Table 8.13: 기타 통계 (계수, p-값 등) (GPA 및 전공 더미 변수 포함)

변수	계수 (Coefficients)	표준 오차 (Standard error)	t-통계량 (t-stat)	p-값 (p-value)	하위 95% (Lower 95%)	상위 95% (Upper 95%)
Intercept	43244.90794	733.5203076	58.955297	1.27E-76		
GPA	1142.314932	239.8636456	4.7623512	6.85E-06		
Engineering	2830.256883	398.3591216	7.1047874	2.2E-10		
Business	1304.709995	411.1126276	3.1736072	0.002029		
Liberal Arts	-2321.800796	344.4477666	-6.740647	1.22E-09		

핵심 요약**결과 해석:**

- **모델 적합도 (Adjusted R Square):** 0.8243 (약 82.43%). 이는 단순 선형 회귀 모델(32.97%)보다 훨씬 개선된 결과입니다. GPA와 전공 변수가 시작 급여 변동의 82.43%를 설명합니다.
- **변수의 유의성 (p-value):** 모든 p-값이 매우 작습니다. 이는 GPA와 모든 전공 더미 변수(Engineering, Business, Liberal Arts)가 시작 급여에 통계적으로 유의미한 영향을 미친다는 것을 의미합니다.

3.1. 회귀 방정식 및 계수 해석

위 결과에 기반한 회귀 방정식은 다음과 같습니다.

$$\hat{y} = 43,244.91 + 1142.31(\text{GPA}) + 2830.26(\text{Engineering}) + 1304.71(\text{Business}) - 2321.80(\text{Liberal Arts})$$

여기서:

- $\hat{y}$: 예측 시작 급여
- GPA: 학점
- Engineering: 공학 전공 더미 변수 (1=공학, 0=그 외)
- Business: 경영 전공 더미 변수 (1=경영, 0=그 외)
- Liberal Arts: 인문학 전공 더미 변수 (1=인문학, 0=그 외)

더미 변수 계수 해석 (기준 범주 대비)

이 모델의 계수들은 기준 범주인 농업(Agriculture) 전공 학생들과 비교했을 때의 차이를 나타냅니다. GPA가 동일하다고 가정할 때:

- **Engineering 계수 (2830.26):** 공학 전공 학생은 농업 전공 학생보다 평균적으로 \$2,830.26 더 높은 급여를 받습니다.
- **Business 계수 (1304.71):** 경영 전공 학생은 농업 전공 학생보다 평균적으로 \$1,304.71 더 높은 급여를 받습니다.
- **Liberal Arts 계수 (-2321.80):** 인문학 전공 학생은 농업 전공 학생보다 평균적으로 \$2,321.80 더 낮은 급여를 받습니다.

절편(Intercept)의 의미

절편 \$43,244.91은 모든 독립 변수가 0일 때의 예측값입니다.

- GPA = 0
 - Engineering = 0, Business = 0, Liberal Arts = 0 (이는 농업 전공을 의미)
- 따라서 절편은 GPA가 0인 농업 전공 학생의 예상 시작 급여를 의미합니다.

8.8.4 4. 예측 및 추가 분석 연습

예제

연습 문제 1: 동일 GPA를 가진 공학 전공자와 경영 전공자의 급여 차이 질문: 동일한 GPA를 가진 공학 전공 졸업생과 경영 전공 졸업생의 시작 급여 차이는 얼마입니까?

풀이: 공학 전공 계수와 경영 전공 계수의 차이를 계산합니다.

$$\$2830.26 - \$1304.71 = \$1525.55$$

답변: 공학 전공 졸업생은 경영 전공 졸업생보다 평균적으로 \$1,525.55 더 높은 급여를 받습니다.

예제

연습 문제 2: 특정 GPA를 가진 인문학 전공 학생의 급여 예측 질문: GPA가 3.5 이고 인문학을 전공한 학생의 예상 시작 급여는 얼마입니까?

풀이: 회귀 방정식에 GPA=3.5, Engineering=0, Business=0, Liberal Arts=1을 대입합니다.

$$\hat{y} = 43,244.91 + 1142.31(3.5) + 2830.26(0) + 1304.71(0) - 2321.80(1)$$

$$\hat{y} = 43,244.91 + 3998.085 - 2321.80 = \$44,921.20$$

답변: GPA 3.5인 인문학 전공 학생의 예상 시작 급여는 \$44,921.20입니다.

예제

연습 문제 3: 특정 GPA를 가진 농업 전공 학생의 급여 예측 질문: GPA가 3.5이고 농업을 전공한 학생의 예상 시작 급여는 얼마입니까?

풀이: 회귀 방정식에 GPA=3.5, Engineering=0, Business=0, Liberal Arts=0을 대입합니다 (농업 전공은 기준 범주이므로 모든 더미 변수가 0).

$$\hat{y} = 43,244.91 + 1142.31(3.5) + 2830.26(0) + 1304.71(0) - 2321.80(0)$$

$$\hat{y} = 43,244.91 + 3998.085 = \$47,243.00$$

답변: GPA 3.5인 농업 전공 학생의 예상 시작 급여는 \$47,243.00입니다.

핵심 요약

회귀 분석의 강력함: 회귀 분석은 여러 변수의 영향을 동시에 비교할 수 있게 해줍니다.

- **집단적 영향:** 모든 변수가 함께 종속 변수에 미치는 총체적인 영향을 파악할 수 있습니다 (R-squared).
- **개별적 영향:** 각 독립 변수가 종속 변수에 미치는 개별적인 영향을 분리하여 파악할 수 있습니다 (계수).

이러한 통찰력을 통해 우리는 비즈니스 결과를 개선하기 위해 독립 변수를 어떻게 변경해야 할지 전략을 세울 수 있습니다. 예를 들어, 건강 연구에서 운동, 식단, 수면 등이 건강에 미치는 영향을 파악하여 더 나은 건강 습관을 권장하는 것과 같습니다.

8.9 빠르게 훑어보기 (1페이지 요약)

질적 데이터와 회귀 모델

핵심: 회귀 모델은 숫자 데이터만 처리 가능. 성별, 전공 같은 질적(범주형) 데이터는 직접 입력 불가. **해결책:** 더미 변수(Dummy Variable)를 사용하여 0 또는 1로 코딩하여 숫자로 변환.

더미 변수 생성 원칙: 다중 공선성 회피

문제: 독립 변수 간 높은 상관관계(다중 공선성)는 모델 신뢰성 저해. **규칙:** 범주가 K 개인 경우, $K - 1$ 개의 더미 변수만 생성. **예시:**

- 성별 (2범주): 남성=1, 여성=0 (1개 더미 변수)
- 전공 (4범주): 공학=1, 경영=1, 인문학=1 (농업은 0으로 기준) (3개 더미 변수)

회귀 계수 및 절편 해석

더미 변수 계수: 1로 코딩된 범주가 0으로 코딩된 기준 범주 대비 종속 변수에 미치는 영향의 차이. **절편 (Intercept):** 모든 독립 변수(숫자형 변수 및 모든 더미 변수)가 0일 때의 종속 변수 예측값. 이는 기준 범주에 해당하는 경우의 기본값으로 해석됨. **예시:**

- 성별(남성=1, 여성=0) 모델에서 Gender 계수 \$4667: 남성이 여성보다 \$4667 더 받음.
- 성별(남성=1, 여성=0) 모델에서 절편 \$61149: 신입 여성 간호사의 시작 급여.

Excel 활용 절차

1. 원본 범주형 데이터를 0/1로 코딩하여 새 데이터 시트 생성.
2. Excel '데이터 분석' → '회귀' 선택.
3. Y 범위(종속 변수), X 범위(독립 변수 + 더미 변수) 설정.
4. 결과 해석: R-squared (모델 설명력), p-value (변수 유의성), 계수 (영향력).

회귀 분석의 가치

강점: 여러 변수의 영향을 동시에 분석하고, 각 변수의 개별적인 영향을 분리하여 파악 가능. **활용:** 예측 모델 구축, 특정 변수가 결과에 미치는 영향 이해, 비즈니스 의사결정 개선.

8.10 핵심 개념 및 원리: 여러 범주를 가진 질적 데이터 처리

8.10.1 1. 다중 범주 질적 데이터와 더미 변수

핵심 요약: 다중 범주 더미 변수

여러 개의 범주를 가진 질적 데이터(예: 전공, 지역)를 회귀 분석에 사용하려면, 각 범주를 0과 1로 표현하는 '더미 변수'로 변환해야 합니다. 이 과정에서 'N-1 규칙'을 적용하여 불필요한 중복을 피하고 모델의 안정성을 확보합니다.

회귀 분석은 기본적으로 숫자 데이터를 다루는 통계 기법입니다. 하지만 현실의 많은 데이터는 '남성/여성', '서울/부산/대구', '경영/공학/인문/농업'과 같이 숫자가 아닌 범주(Category) 형태로 존재합니다. 이러한 데이터를 '질적 데이터' 또는 '범주형 데이터'라고 부릅니다.

이러한 질적 데이터를 회귀 모델에 포함시키기 위해 우리는 '더미 변수(Dummy Variable)'라는 특별한 숫자 변수를 만듭니다. 더미 변수는 특정 범주에 속하면 1, 속하지 않으면 0의 값을 가지는 변수입니다.

예시: 전공 데이터를 더미 변수로 변환

만약 학생의 전공이 '경영', '공학', '인문', '농업'의 네 가지 범주로 나뉜다고 가정해 봅시다. 이 전공 정보를 회귀 모델에 직접 넣을 수는 없습니다. 대신 다음과 같이 더미 변수를 만들 수 있습니다.

- **공학 더미 변수:** 학생이 공학 전공이면 1, 아니면 0.
- **경영 더미 변수:** 학생이 경영 전공이면 1, 아니면 0.
- **인문 더미 변수:** 학생이 인문 전공이면 1, 아니면 0.

이렇게 하면 각 학생의 전공을 숫자로 표현할 수 있게 됩니다.

8.10.2 2. N-1 규칙: 왜 하나를 제외하는가?

핵심 요약: N-1 규칙

N개의 범주를 가진 질적 변수를 더미 변수로 만들 때는 N-1개의 더미 변수만 사용해야 합니다. 나머지 하나의 범주는 '기준 범주(Reference Category)'가 되어, 다른 모든 범주들의 효과가 이 기준 범주와 비교되어 해석됩니다.

위 예시에서 전공이 네 가지('경영', '공학', '인문', '농업')였는데, 우리는 세 개의 더미 변수('공학', '경영', '인문')만 만들었습니다. '농업' 전공에 대한 더미 변수는 따로 만들지 않았습니다. 이것이 바로 'N-1 규칙'입니다.

N-1 규칙의 이유 (다중공선성 방지): 만약 네 개의 전공에 대해 네 개의 더미 변수(공학, 경영, 인문, 농업)를 모두 만들고 회귀 모델에 넣는다면, 심각한 문제가 발생합니다. 예를 들어, 어떤 학생이 공학, 경영, 인문 더미 변수 모두 0이라면, 이 학생은 반드시 농업 전공이라는 것을 알 수 있습니다. 즉, '농업' 더미 변수는 다른 세 더미 변수의 조합으로 완벽하게 설명될 수 있습니다.

이처럼 한 독립 변수가 다른 독립 변수들의 선형 조합으로 완벽하게 설명될 때, '다중공선성(Multicollinearity)' 문제가 발생합니다. 다중공선성은 회귀 모델의 계수 추정

을 불안정하게 만들고, 통계적 유의성을 왜곡할 수 있습니다. $N-1$ 규칙은 이러한 다중 공선성 문제를 방지하기 위한 필수적인 방법입니다.

기준 범주의 역할

우리가 '농업' 전공을 더미 변수에서 제외했기 때문에, '농업' 전공은 이 모델의 '기준 범주'가 됩니다. 이는 모델의 모든 계수(예: 공학, 경영, 인문 전공의 계수)가 '농업' 전공 학생과 비교하여 해석된다는 의미입니다.

예를 들어, '공학' 더미 변수의 계수가 양수라면, 이는 다른 조건이 동일할 때 공학 전공 학생이 농업 전공 학생보다 평균적으로 더 높은 급여를 받는다는 것을 의미합니다.

8.10.3 3. 회귀 모델의 해석: R-제곱, p-값, 계수

회귀 분석을 실행하면 다양한 통계량들이 산출됩니다. 이 중에서 모델의 전반적인 성능과 각 변수의 중요성을 평가하는 주요 지표들은 다음과 같습니다.

- R-제곱 조정 (Adjusted R-Squared):

- 한 줄 요약: 모델이 종속 변수의 변동을 얼마나 잘 설명하는지 나타내는 비율입니다.
- 직관적 비유: 시험 점수를 예측하는 모델이 있다고 할 때, R-제곱 조정이 0.8이라면, 시험 점수 변동의 80%를 모델이 설명할 수 있다는 뜻입니다.
- 기술적 설명: 0과 1 사이의 값을 가지며, 1에 가까울수록 모델의 설명력이 높습니다. 독립 변수의 수가 늘어날 때 단순히 R-제곱이 증가하는 경향을 보정하여, 모델에 추가된 변수가 실제로 설명력을 높이는지 판단하는 데 더 유용합니다.

- p-값 (p-value):

- 한 줄 요약: 특정 변수가 종속 변수에 미치는 영향이 '우연히' 발생했을 확률입니다.
- 직관적 비유: 어떤 약이 효과가 있는지 실험했는데, p-값이 0.01이라면, 약이 효과가 없는데도 지금과 같은 결과가 나올 확률이 1%밖에 안 된다는 뜻입니다. 따라서 약이 효과가 있다고 결론 내릴 수 있습니다.
- 기술적 설명: 일반적으로 p-값이 0.05(유의수준)보다 작으면 해당 변수가 종속 변수에 통계적으로 유의미한 영향을 미친다고 판단합니다. 이는 해당 변수의 계수가 0이 아니라고 말할 수 있는 충분한 증거가 있다는 의미입니다.

- 계수 (Coefficient):

- 한 줄 요약: 독립 변수가 한 단위 변할 때 종속 변수가 평균적으로 얼마나 변하는지를 나타내는 값입니다.
- 직관적 비유: GPA 계수가 1000이라면, GPA가 1점 오를 때마다 연봉이 평균적으로 1000달러 오른다고 예측할 수 있습니다.
- 기술적 설명: 더미 변수의 계수는 해당 범주가 기준 범주에 비해 종속 변수에 미치는 평균적인 추가 또는 감소 효과를 나타냅니다. 예를 들어, '공학' 더미 변수의 계수가 2830이라면, 공학 전공 학생은 농업 전공 학생보다 평균적으로 2,830

8.11 절차 및 방법: 엑셀을 이용한 다중 범주 더미 변수 회귀 분석

이 섹션에서는 엑셀의 '데이터 분석' 도구를 사용하여 다중 범주 더미 변수를 포함한 회귀 모델을 구축하는 구체적인 단계를 설명합니다.

8.11.1 1. 데이터 준비: 더미 변수 생성

먼저, 원본 데이터에서 질적 변수를 더미 변수로 변환해야 합니다.

GPA, 전공, 연봉 데이터셋

우리는 '시작 연봉 (Starting Salary)', 'GPA', '전공 (Major)' 데이터를 사용합니다. 전공은 '공학 (Engineering)', '경영 (Business)', '인문 (Liberal Arts)', '농업 (Agriculture)'의 네 가지 범주를 가집니다.

- 종속 변수 (Y): 시작 연봉 (Starting Salary)

- 독립 변수 (X): GPA, 공학, 경영, 인문

여기서 '농업' 전공은 기준 범주로 설정되어 더미 변수를 만들지 않습니다.

1. 원본 데이터 확인: 'GPA Major Salary' 엑셀 파일의 첫 번째 워크시트에는 'Starting Salary', 'GPA', 'Engineering', 'Business', 'Liberal Arts'의 다섯 개 열이 있습니다.

2. 더미 변수 코딩:

- 'Engineering' 열: 학생이 공학 전공이면 1, 아니면 0.
- 'Business' 열: 학생이 경영 전공이면 1, 아니면 0.
- 'Liberal Arts' 열: 학생이 인문 전공이면 1, 아니면 0.
- 기준 범주: 만약 'Engineering', 'Business', 'Liberal Arts' 열이 모두 0이면, 해당 학생은 '농업(Ag)' 전공으로 간주됩니다. (이 모델에서는 이중 전공을 가정하지 않습니다.)

더미 변수 코딩 예시

어떤 학생의 데이터가 다음과 같다고 가정해 봅시다.

- 시작 연봉: \$50,479
- GPA: 3.04
- Engineering: 0
- Business: 1
- Liberal Arts: 0

이 학생은 경영 전공 학생입니다. 만약 Engineering, Business, Liberal Arts가 모두 0이라면, 그 학생은 농업 전공 학생입니다.

8.11.2 2. 엑셀에서 회귀 분석 실행

데이터가 준비되면 엑셀의 '데이터 분석' 기능을 사용하여 회귀 모델을 실행합니다.

1. 데이터 분석 도구 열기: 엑셀 메뉴에서 '데이터' 탭을 클릭한 후, '데이터 분석'을 선택합니다. ('데이터 분석'이 보이지 않으면, 엑셀 옵션에서 '추가 기능'을 통해 '분석 도구'를 활성화해야 합니다.)

2. **회귀 분석 선택:** '데이터 분석' 대화 상자에서 '회귀 분석(Regression)'을 선택하고 '확인'을 클릭합니다.
3. **입력 범위 설정:**
 - **Input Y Range (종속 변수):** 예측하고자 하는 '시작 연봉(Starting Salary)' 열 전체를 선택합니다. (예: A1:A101)
 - **Input X Range (독립 변수):** 'GPA', 'Engineering', 'Business', 'Liberal Arts' 열 전체를 선택합니다. (예: B1:E101)
4. **옵션 설정:**
 - **Labels (레이블):** 첫 행에 변수 이름(레이블)이 포함되어 있다면 이 상자를 체크합니다.
 - **Confidence Level (신뢰 수준):** 기본값인 95%를 유지합니다.
5. **출력 옵션 설정:**
 - **New Worksheet Ply (새 워크시트):** 회귀 분석 결과가 새 워크시트에 표시되도록 이 옵션을 선택합니다.
6. **실행:** '확인' 버튼을 클릭하여 회귀 분석을 실행합니다.

8.12 실습 및 결과 해석

엑셀에서 회귀 분석을 실행하면 '요약 출력(Summary Output)'이라는 결과 보고서가 생성됩니다. 이 보고서를 통해 모델의 성능과 각 변수의 유의미성을 평가하고, 실제 예측에 활용할 수 있습니다.

8.12.1 1. 회귀 통계량 해석

회귀 통계량 요약

- **Adjusted R-Squared (R-제곱 조정):** 0.824319
- **해석:** 시작 연봉 변동의 약 82.4%가 GPA와 전공(더미 변수)에 의해 설명됩니다. 이는 모델의 설명력이 매우 높다는 것을 의미합니다.

회귀 통계량	값	엑셀 회귀 분석 요약 출력: 회귀 통계량
Multiple R	0.911821	
R Square	0.831417	
Adjusted R Square	0.824319	
Standard error	1145.058	
Observations	100	

'Adjusted R-Squared' 값은 모델의 설명력을 나타냅니다. 이 값이 0.824319라는 것은 졸업생의 시작 연봉 변동 중 82.4%를 GPA와 전공이라는 변수들이 설명할 수 있다는 의미입니다. 이는 매우 높은 설명력으로, 모델이 연봉 예측에 매우 유용하다는 것을 시사합니다.

8.12.2 2. ANOVA 테이블 해석

ANOVA	df	SS	MS	F	Significance F
Regression	4	6.14E+08	1.54E+08	117.1301611	7.60373E-36
Residual	95	1.25E+08	1311158		
Total	99	7.39E+08			

엑셀 회귀 분석 요약 출력: ANOVA 테이블

'Significance F' 값은 모델 전체의 통계적 유의성을 나타냅니다. 이 값이 7.60373E-36으로 매우 작기 때문에 (0.05보다 훨씬 작음), 이 회귀 모델은 통계적으로 매우 유의미하며, 최소한 하나 이상의 독립 변수가 종속 변수에 유의미한 영향을 미친다고 결론 내릴 수 있습니다.

8.12.3 3. 계수 테이블 해석

계수 테이블 요약

- 모든 변수(GPA, Engineering, Business, Liberal Arts)의 p-값이 0.05보다 작으므로, 모든 변수가 시작 연봉과 통계적으로 유의미한 관계를 가집니다.
- 기준 범주: 농업(Ag) 전공 학생.
- 계수 해석:
 - GPA: GPA 1점 증가 시 시작 연봉이 평균 \$1,142.32 증가합니다.
 - Engineering: 농업 전공 학생 대비 공학 전공 학생의 시작 연봉이 평균 \$2,830.26 더 높습니다.
 - Business: 농업 전공 학생 대비 경영 전공 학생의 시작 연봉이 평균 \$1,304.71 더 높습니다.
 - Liberal Arts: 농업 전공 학생 대비 인문 전공 학생의 시작 연봉이 평균 \$2,321.80 더 낮습니다.

변수	Coefficients	Standard error	t-stat	p-value	Lower 95%	Upper 95%
Intercept	43244.91	733.5203	58.9553	1.2694E-76	41788.68602	44701.12987
GPA	1142.315	239.8636	4.762351	6.85279E-06	666.1253891	1618.504475
Engineering	2830.257	398.3591	7.104787	2.2015E-10	2039.414037	3621.099729
Business	1304.71	411.1126	3.173607	0.002029098	488.5482389	2120.871752
Liberal Arts	-2321.8	344.4478	-6.74065	1.21523E-09	-3005.61607	-1637.985522

엑셀 회귀 분석 요약 출력: 계수 테이블

이 테이블은 각 독립 변수가 종속 변수에 미치는 영향을 구체적으로 보여줍니다.

- p-값 확인:** 모든 변수(GPA, Engineering, Business, Liberal Arts)의 p-값이 0.05보다 훨씬 작습니다. 이는 GPA와 각 전공 더미 변수가 시작 연봉과 통계적으로 유의미한 관계를 가지고 있음을 의미합니다.
- Intercept (절편):** GPA가 0이고 모든 더미 변수가 0일 때(즉, GPA 0인 농업 전공 학생의 경우)의 예상 시작 연봉은 \$43,244.91입니다.
- GPA 계수:** GPA가 1점 증가할 때마다 시작 연봉이 평균적으로 \$1,142.32 증가합니다.
- Engineering 계수:** 공학 전공 학생은 기준 범주인 농업 전공 학생보다 평균적으로 \$2,830.26 더 높은 시작 연봉을 받습니다.
- Business 계수:** 경영 전공 학생은 농업 전공 학생보다 평균적으로 \$1,304.71 더 높은 시작 연봉을 받습니다.
- Liberal Arts 계수:** 인문 전공 학생은 농업 전공 학생보다 평균적으로 \$2,321.80 더

낮은 시작 연봉을 받습니다. (음수 계수는 연봉이 감소한다는 의미입니다.)

8.12.4 4. 회귀 모델을 이용한 예측

이제 위에서 얻은 계수들을 사용하여 특정 학생의 시작 연봉을 예측할 수 있습니다. 회귀 방정식은 다음과 같습니다.

예측 연봉 = 절편 + (GPA 계수 $\times$ GPA) + (공학 계수 $\times$ 공학 더미) + (경영 계수 $\times$ 경영 더미) + (인문 계수 $\times$ 인문 더미)

엑셀에서는 SUMPRODUCT 함수를 사용하여 이 계산을 효율적으로 수행할 수 있습니다.

```
1 =B$24 + SUMPRODUCT($B$25:$B$28, C25:C28)
```

Listing 8.2: 엑셀 SUMPRODUCT 함수를 이용한 예측 공식

여기서 B24는 절편 값, B25:B28은 GPA 및 더미 변수들의 계수 범위, C25:C28은 예측하고자 하는 학생의 GPA 및 더미 변수 값 범위입니다.

변수	Coefficients	Student 1	Student 2	Student 3	Student 4
Intercept	43244.91				
GPA	1142.315	3.6	2.6	2.6	4
Engineering	2830.257	1	1	0	0
Business	1304.71	0	0	0	0
Liberal Arts	-2321.8	0	0	0	1
Point Estimate of Prediction		\$50,187.50	\$49,045.18	\$46,214.93	\$45,492.37

다양한 학생 유형에 대한 연봉 예측

예측 사례 분석

1. 학생 1: GPA 3.6, 공학 전공

- 예측 연봉: \$50,187.50
- 계산: $43244.91 + (1142.315 \times 3.6) + (2830.257 \times 1) + (1304.71 \times 0) + (-2321.8 \times 0) = 50187.50$

2. 학생 2: GPA 2.6, 공학 전공

- 예측 연봉: \$49,045.18
- 계산: $43244.91 + (1142.315 \times 2.6) + (2830.257 \times 1) + (1304.71 \times 0) + (-2321.8 \times 0) = 49045.18$
- 해석: 학생 1과 학생 2는 GPA만 1점 차이(3.6 vs 2.6) 나고 전공은 동일합니다. 예측 연봉 차이는 $50187.50 - 49045.18 = 1142.32$ 로, 이는 GPA 계수(\$1,142.315)와 거의 일치합니다. 즉, GPA 1점 하락 시 연봉이 약 \$1,142 감소함을 보여줍니다.

3. 학생 3: GPA 2.6, 농업 전공

- 예측 연봉: \$46,214.93
- 계산: $43244.91 + (1142.315 \times 2.6) + (2830.257 \times 0) + (1304.71 \times 0) + (-2321.8 \times 0) = 46214.93$
- 해석: 학생 2(공학, GPA 2.6)와 학생 3(농업, GPA 2.6)은 GPA는 같지만 전공이 다릅니다. 예측 연봉 차이는 $49045.18 - 46214.93 = 2830.25$ 로, 이는 공학 전공 계수(\$2,830.257)와 거의 일치합니다. 이는 농업 전공 학생 대비 공학 전공 학생이 평균적으로 \$2,830 더 높은 연봉을 받는다는 것을 다시 한번 확인시켜 줍니다.

4. 학생 4: GPA 4.0, 인문 전공

- 예측 연봉: \$45,492.37
- 계산: $43244.91 + (1142.315 \times 4.0) + (2830.257 \times 0) + (1304.71 \times 0) + (-2321.8 \times 1) = 45492.37$

- **해석:** 인문 전공 학생은 GPA가 4.0으로 높음에도 불구하고, 인문 전공 계수가 음수(-2321.8)이기 때문에 농업 전공 학생보다 평균적으로 연봉이 낮게 예측됩니다. 이는 인문 전공이 기준 범주인 농업 전공에 비해 연봉에 부정적인 영향을 미친다는 것을 보여줍니다.

중요: 기준 범주와의 비교

모든 더미 변수의 계수는 '기준 범주'와 비교하여 해석됩니다. 이 모델에서는 '농업' 전공이 기준 범주이므로, '공학' 전공 계수는 '농업' 전공 대비 '공학' 전공의 연봉 차이를 나타냅니다. '인문' 전공 계수가 음수인 것은 '농업' 전공보다 '인문' 전공의 연봉이 평균적으로 낮다는 의미입니다.

8.13 체크리스트

이 모듈의 학습 및 적용을 위한 점검표입니다.

- **더미 변수 생성:**
 - 질적 변수의 모든 범주를 식별했는가?
 - N개의 범주에 대해 N-1개의 더미 변수를 생성했는가?
 - 기준 범주(Reference Category)를 명확히 설정했는가?
 - 각 더미 변수가 0 또는 1로 올바르게 코딩되었는가?
- **엑셀 회귀 분석 실행:**
 - 종속 변수(Y)와 독립 변수(X) 범위를 정확히 지정했는가?
 - 'Labels' 옵션을 올바르게 체크했는가?
 - 출력 옵션(예: 새 워크시트)을 적절히 설정했는가?
- **회귀 분석 결과 해석:**
 - Adjusted R-Squared 값을 확인하고 모델의 설명력을 이해했는가?
 - Significance F 값을 확인하고 모델 전체의 유의성을 판단했는가?
 - 각 독립 변수의 p-값을 확인하고 통계적 유의성을 판단했는가?
 - 각 계수(Coefficient)의 의미를 기준 범주와 비교하여 올바르게 해석했는가?
 - 특히 더미 변수의 계수가 양수/음수일 때의 의미를 이해했는가?
- **예측 수행:**
 - 회귀 방정식을 사용하여 새로운 데이터에 대한 예측을 수행할 수 있는가?
 - 엑셀의 SUMPRODUCT 함수를 활용하여 예측을 자동화할 수 있는가?
 - 예측 결과가 각 변수의 계수와 어떻게 연관되는지 설명할 수 있는가?

8.14 FAQ (자주 묻는 질문)

Q&A: 더미 변수

Q1: 기준 범주를 바꾸면 회귀 분석 결과가 달라지나요? A1: 네, 계수 값은 달라 집니다. 예를 들어, 농업 대신 경영을 기준 범주로 설정하면, 공학 전공의 계수는 '경영 전공 대비 공학 전공의 연봉 차이'를 나타내게 됩니다. 하지만 모델의 전반적인 설명력(Adjusted R-Squared)이나 예측 결과 자체는 동일합니다. 어떤 범주를 기준으로 삼든, 변수들 간의 상대적인 관계는 변하지 않기 때문입니다.

Q2: N개의 범주에 대해 N개의 더미 변수를 모두 사용하면 안 되나요? A2: 안 됩니다. N개의 더미 변수를 모두 사용하면 '다중공선성(Multicollinearity)'이라는 문제가 발생합니다. 이는 한 더미 변수가 다른 더미 변수들의 선형 조합으로 완벽하게 예측될 수 있음을 의미하며, 회귀 모델의 계수 추정을 불안정하게 만들고 통계적 유의성 판단을 어렵게 합니다. 따라서 반드시 N-1 규칙을 지켜야 합니다.

Q3: 더미 변수의 계수가 음수이면 무엇을 의미하나요? A3: 더미 변수의 계수가 음수라는 것은 해당 범주에 속하는 경우, 기준 범주에 비해 종속 변수(예: 연봉)의 값이 평균적으로 감소한다는 것을 의미합니다. 예를 들어, 인문 전공 더미 변수의 계수가 음수라면, 인문 전공 학생은 농업 전공 학생보다 평균적으로 연봉이 낮다는 뜻입니다.

Q4: 더미 변수 외에 질적 데이터를 회귀 모델에 넣는 다른 방법이 있나요? A4: 더미 변수는 가장 일반적이고 직관적인 방법입니다. 순서형 질적 데이터(예: 학점 등급 A, B, C)의 경우, 순서형 회귀(Ordinal Regression)와 같은 다른 고급 통계 기법을 사용할 수도 있습니다. 하지만 일반적인 명목형 질적 데이터(예: 전공)에는 더미 변수가 표준적인 접근 방식입니다.

8.15 빠르게 훑어보기 (1페이지 요약)

핵심 요약: 다중 범주 더미 변수

목표: 여러 범주를 가진 질적 데이터를 회귀 모델에 포함하여 예측력 높이기.

핵심 원리: N-1 규칙

- N개의 범주가 있다면, N-1개의 더미 변수만 생성.
- 나머지 1개 범주는 '기준 범주'가 되어 모든 비교의 기준이 됨.
- **이유:** 다중공선성 방지 (모델 안정성 확보).

더미 변수 생성 (예시: 4개 전공)

- 전공: 경영, 공학, 인문, 농업
- 더미 변수: 공학(1/0), 경영(1/0), 인문(1/0)
- **기준 범주:** 농업 (모든 더미 변수가 0이면 농업 전공)

엑셀 회귀 분석 단계

1. 데이터 준비: 질적 변수를 N-1 더미 변수로 코딩.
2. '데이터' → '데이터 분석' → '회귀 분석' 선택.
3. Y 범위(종속 변수: 시작 연봉), X 범위(독립 변수: GPA, 더미 변수들) 설정.
4. 'Labels' 체크, 'Confidence Level' 95%, 'New Worksheet Ply' 선택.
5. '확인' 클릭.

결과 해석 (주요 지표)

- **Adjusted R-Squared (R-제곱 조정):** 모델의 설명력 (예: 0.824319 → 82.4% 설명).
- **Significance F (F 유의성):** 모델 전체의 통계적 유의성 (작을수록 유의미).
- **p-value (p-값):** 각 변수의 유의성 (0.05 미만이면 유의미).
- **Coefficients (계수):**
 - GPA 계수: GPA 1점당 연봉 변화량.
 - 더미 변수 계수: 기준 범주 대비 해당 범주의 연봉 변화량.
 - **예시:** 공학 계수 \$2830 → 농업 전공 대비 공학 전공은 평균 \$2830 더 받음.
 - **예시:** 인문 계수 -\$2321 → 농업 전공 대비 인문 전공은 평균 \$2321 덜 받음.

예측 (회귀 방정식 활용)

- 예측 연봉 = 절편 + (GPA 계수 × GPA) + (각 더미 계수 × 해당 더미 값)
- 엑셀 SUMPRODUCT 함수로 쉽게 계산 가능.